

SCX (State-Conditioned eXpertise) 核心数学 框架深度分析

本文档对 SCX 状态条件专家可靠性框架进行逐层解构，追溯每个数学对象的统计/信息论/博弈论源头，证伪/证成三条核心命题，并给出理论边界。

目录

- 数学根源追溯
 - 1.1 条件风险与 Kolmogorov 体系
 - 1.2 统计决策理论与贝叶斯风险
 - 1.3 状态划分：充分统计量与信息瓶颈
 - 1.4 数据价值：Shapley 值与合作博弈论
 - 1.5 专家可靠性：Dawid-Skene 与 IRT
 - 1.6 噪声与可学习性：Tsybakov 与 Huber
 - 1.7 主动采样：OED、信息论与 Bandit
 - 1.8 SCX-Compress: Coreset 与蒸馏
 - 1.9 专家路由：MoE 谱系
- 三个命题的完整证明框架
 - 2.1 命题一：全局专家排序不足
 - 2.2 命题二：高误差采样在噪声下非最优
 - 2.3 命题三：状态条件专家权重优于全局固定权重
- 状态空间构造方法
- 子模块数据流与协调
- SCX 理论边界

1. 数学根源追溯

1.1 条件风险与 Kolmogorov 公理体系

1.1.1 核心对象再定义 SCX 分析的基础是状态条件专家风险：

$$R_m(s) = \mathbb{E}_{x \sim P(\cdot|s)}[\ell(f_m(x), f^*(x))]$$

这一定义看似平凡，实则嵌套了 Kolmogorov 概率公理体系中三个最深刻的概念：条件期望、正则条件概率和 Radon-Nikodym 导数。

1.1.2 Kolmogorov 条件期望的正式定义 设 $(\Omega, \mathcal{F}, P)$ 为概率空间， X 为随机变量满足 $\mathbb{E}[|X|] < \infty$ ， $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数。则存在 P -几乎必然唯一的 $\mathcal{G}$ -可测函数 $\mathbb{E}[X|\mathcal{G}]$ ，满足：

$$\forall G \in \mathcal{G} : \int_G \mathbb{E}[X|\mathcal{G}] dP = \int_G X dP$$

存在性由 Radon-Nikodym 定理保证：定义有限符号测度 $\nu(G) = \int_G X dP$ ，则 $\nu \ll P|_{\mathcal{G}}$ ，其 RN 导数即为 $\mathbb{E}[X|\mathcal{G}]$ 。

SCX 中的 $R_m(s)$ 本质上是 $\mathbb{E}[\ell(f_m(X), f^*(X)) | X \in s]$ 。设 s 为 $\mathcal{X}$ 中的一个可测子集，则状态 s 对应条件事件， $R_m(s) = \mathbb{E}[L_m | \mathbf{1}_s(X) = 1]$ ，其中 $L_m = \ell(f_m(X), f^*(X))$ 。

1.1.3 正则条件概率 严格处理 $P(\cdot|s)$ 需要正则条件概率 (Regular Conditional Probability)。给定随机元 $X : \Omega \rightarrow \mathcal{X}$ 和子 σ -代数 $\mathcal{G} \subset \mathcal{F}$ ，若存在映射 $P(\cdot|\mathcal{G})(\cdot) : \mathcal{F} \times \Omega \rightarrow [0, 1]$ 满足：

1. 对 P -a.e. ω ， $P(\cdot|\mathcal{G})(\omega)$ 是 $(\Omega, \mathcal{F})$ 上的概率测度；
2. 对每个 $F \in \mathcal{F}$ ， $P(F|\mathcal{G})(\cdot)$ 是 $\mathbb{E}[\mathbf{1}_F|\mathcal{G}]$ 的一个版本；

则称 $P(\cdot|\mathcal{G})(\cdot)$ 为正则条件概率。

在 SCX 中，状态 s 诱导出条件分布 $P_{X|s}$ 。当 $\mathcal{X} = \mathbb{R}^d$ 为 Polish 空间时，正则条件概率存在（这由 Blackwell 定理保证）。因此 $P(x|s)$ 在测度论意义下是良定义的。

1.1.4 损失函数 ℓ 的可积性条件 $R_m(s)$ 的良定义需要 $\ell(f_m(x), f^*(x))$ 对 $P(\cdot|s)$ 可积。对于回归问题 (ℓ_2 损失) 或分类问题 (0-1 损失)，只要 f_m 和 f^* 是平方可积函数，条件期望存在。更一般地，若 ℓ 是凸的且 $f^*(x) = \arg \min_y \mathbb{E}[\ell(Y, y)|X = x]$ (贝叶斯最优)，则相关测度论条件自动满足。

1.2 统计决策理论与贝叶斯风险

1.2.1 从 Wald 到 SCX Abraham Wald 在 1950 年代建立的统计决策理论框架为 SCX 的条件风险提供了上层结构：

- **决策空间 $\mathcal{D}$** ：专家选择（从 M 个专家中选择路由），或标签分配 (acquire/relabel)
- **损失函数 $L(d, \theta)$** ：选择专家 d 而真实状态为 θ 的代价
- **风险函数 $R(\pi, d) = \int_{\Theta} R(\theta, d) d\pi(\theta)$** ：先验 π 下的贝叶斯风险

SCX 的创新在于将这一框架**局部化**到每个状态 s ：

$$R_m(s) = \int_{\mathcal{X}} \ell(f_m(x), f^*(x)) dP_{X|s}(x)$$

这正是状态条件的贝叶斯风险，其先验由状态 s 的指示函数给出。

1.2.2 Berger 的广义贝叶斯分析 Berger (1985) 指出，任意合理的决策规则都是某个（可能为 improper）先验下的广义贝叶斯规则。SCX 状态条件路由 $m^*(x) = \arg \min_m \sum_s \gamma_s(x) R_m(s)$ 可理解为：将输入 x 的不确定性通过状态的软赋值 $\gamma_s(x)$ 分散到多个“局部先验”上，然后取后验期望损失最小的专家。

1.2.3 与 PAC-Bayes 的联系 状态条件风险 $R_m(s)$ 与 PAC-Bayes 边界也有深层联系。令 $\mathcal{Q}$ 为专家假设空间上的后验分布，标准 PAC-Bayes 边界为：

$$\mathbb{E}_{h \sim \mathcal{Q}}[R(h)] \leq \mathbb{E}_{h \sim \mathcal{Q}}[\hat{R}(h)] + \sqrt{\frac{KL(\mathcal{Q}||\mathcal{P}) + \log(n/\delta)}{2n}}$$

SCX 中，状态条件权重 $w_m(x) \propto \exp(-\alpha \sum_s \gamma_s(x) \hat{R}_m(s))$ 可以看作一个状态依赖的后验 $\mathcal{Q}_x$ ，其 KL 散度相对于均匀先验的惩罚项通过 α 参数控制，实现了状态水平的 PAC-Bayes 边界。

1.3 状态划分：充分统计量与信息瓶颈

1.3.1 状态的定义 SCX 中的“状态” s 是输入空间 $\mathcal{X}$ 的一个子集或一个区域。状态划分的数学本质是找到一个映射 $\phi: \mathcal{X} \rightarrow \mathcal{S}$ ，使得：

$$P(Y|X) \approx P(Y|\phi(X))$$

即 $\phi(X)$ 是 Y 关于 X 的近似充分统计量。

1.3.2 充分统计量理论 Fisher (1922) 提出：统计量 $T(X)$ 对参数 θ 是充分的，当且仅当：

$$P(X|T(X), \theta) = P(X|T(X))$$

等价地，由 Neyman-Fisher 因子分解定理：

$$p(x|\theta) = g(T(x), \theta) \cdot h(x)$$

在 SCX 中，状态 s 的角色类似于一个离散的充分统计量：给定 $x \in s$ ，专家的条件风险 $R_m(s)$ 应能充分反映专家在该区域的性能，而不需要更细粒度的 x 信息。

更精确地说，SCX 的最优状态划分 $\mathcal{S}^*$ 应满足：

$$R_m(s) = \mathbb{E}[\ell(f_m(X), f^*(X)) | X \in s] \approx \mathbb{E}[\ell(f_m(X), f^*(X)) | X = x], \quad \forall x \in s$$

即状态内部的条件风险方差最小化。

1.3.3 信息瓶颈原理 Tishby, Pereira 与 Bialek (1999) 提出的信息瓶颈 (IB) 原理为状态划分提供了变分框架：

$$\min_{p(\tilde{X}|X)} I(X; \tilde{X}) - \beta I(\tilde{X}; Y)$$

其中 $\tilde{X}$ 是 X 的压缩表示。在 SCX 中，状态变量 $S = \phi(X)$ 扮演了 $\tilde{X}$ 的角色。IB 拉格朗日量：

$$\mathcal{L}_{IB} = I(X; S) - \beta I(S; Y)$$

- $I(X; S)$: 状态划分的复杂度（需要多少信息来指定状态）
- $I(S; Y)$: 状态对标签的预测能力
- β : 压缩-预测的权衡参数

SCX 的状态划分隐式地解决了 IB 目标：它寻找一个状态空间 $\mathcal{S}$ ，使得：1. 同一状态内的样本有相似的专家表现（高 $I(S; R_m)$ ）2. 状态数量可控（低 $I(X; S)$ ）

当 $\beta \rightarrow \infty$ 时，IB 退化为每个 x 对应唯一状态（完全不压缩）， $M^* =$ 专家数量；当 $\beta \rightarrow 0$ 时， $|S| = 1$ （全局池化），退化为全局专家排序。

1.3.4 率失真理论视角 状态划分也是率失真理论 (Rate-Distortion Theory) 的一个实例。定义失真度量：

$$d(x, x') = |R_m(x) - R_m(x')|$$

其中 $R_m(x) = \mathbb{E}[\ell(f_m(X), f^*(X)) | X = x]$ 为点态条件风险。状态划分等价于对 $(\mathcal{X}, d)$ 进行量化（quantization），率失真函数为：

$$R(D) = \min_{P(S|X): \mathbb{E}[d(X, S)] \leq D} I(X; S)$$

SCX 的聚类过程（如 K-means on 嵌入空间）正是 $R(D)$ 的一个经验近似。

1.4 数据价值：Shapley 公理与合作博弈论

1.4.1 数据价值函数的形式 SCX 定义状态 s 的数据价值为：

$$V(s) = \bar{r}(s) \cdot \rho(s) \cdot L(s) \cdot [1 - D(s)] \cdot \max_m SCX_m(s)$$

这是五个因子的乘积。其根源可追溯到合作博弈论中的 **Shapley 公理体系** 和 **数据 Shapley** (Ghorbani & Zou, 2019)。

1.4.2 Shapley 值的公理 Shapley (1953) 定义了合作博弈 $v : 2^N \rightarrow \mathbb{R}$ 中单个玩家 i 的价值：

$$\phi_i(v) = \frac{1}{|N|!} \sum_{\pi \in \Pi(N)} [v(S_\pi^i \cup \{i\}) - v(S_\pi^i)]$$

其中 S_π^i 是排列 π 中 i 之前玩家的集合。Shapley 值是唯一满足以下公理的分配方案：

1. **有效性 (Efficiency)**: $\sum_{i \in N} \phi_i(v) = v(N)$
2. **对称性 (Symmetry)**: 若 $v(S \cup \{i\}) = v(S \cup \{j\})$ 对所有 $S \subseteq N \setminus \{i, j\}$, 则 $\phi_i = \phi_j$
3. **虚拟性 (Dummy)**: 若 $v(S \cup \{i\}) = v(S)$ 对所有 S , 则 $\phi_i = 0$
4. **可加性 (Additivity)**: $\phi_i(v + w) = \phi_i(v) + \phi_i(w)$

1.4.3 SCX 价值函数与 Shapley 的偏离 SCX 的 $V(s)$ 不是精确的 Shapley 值, 而是其可分解代理。真正计算数据点级别的 Shapley 值是 $O(2^N)$ 的。SCX 做了关键简化：

- **状态级而非样本级**: 先聚合成状态 s , 再计算状态价值, 复杂度 $O(2^{|S|})$ 其中 $|S| \ll N$

- **乘法分解**：将边际贡献分解为五个可理解的因子

将 $V(s)$ 的因子逐个与博弈论概念对应：

因子	博弈论对应	解释
$\bar{r}(s)$	边际收益	该状态当前的残差越高，改善的潜在收益越大
$\rho(s)$	概率权重	罕见状态的预期收益需打折扣
$L(s)$	可达收益	噪声大或无结构的状态无法通过学习改善
$1 - D(s)$	多样性惩罚	冗余高的点贡献为负（已有类似信息）
$\max_m SCX_m(s)$	可实现性	必须有可靠的专家来获取收益

这种分解是**启发式但可解释的**，其代价是放弃 Shapley 的加法公理。

1.4.4 与 Data Shapley 的精确关系 Ghorbani & Zou (2019) 的数据 Shapley 将每个训练点 z_i 的价值定义为：

$$\phi_i = \frac{1}{N} \sum_{k=1}^N \frac{1}{\binom{N-1}{k-1}} \sum_{S \subseteq N \setminus \{i\}, |S|=k-1} [v(S \cup \{i\}) - v(S)]$$

其中 $v(S)$ 是在数据集 S 上训练的模型的验证性能。

SCX 的 $V(s)$ 可以看作一个**代理函数** $\tilde{V}(s)$ ，它满足：

$$V(s) \approx \mathbb{E}_{i \in s} [\phi_i] \cdot |s|$$

但 $V(s)$ 的乘法分解意味着 SCX 假设价值函数具有**因子可分离性**：

$$v(S) \approx \prod_{s \in \mathcal{S}} g_s(|S \cap s|, \text{stats}(s))$$

这在 v 为次模函数时是合理的近似（Shapley 值在次模博弈中具有凹性）。

1.5 专家可靠性：Dawid-Skene 与 IRT

1.5.1 Dawid-Skene 标注者模型 Dawid & Skene (1979) 提出了著名的标注者（专家）可靠性模型。设 J 个标注者对 N 个样本进行分类，每个样本的真实类别为 $y_i \in \{1, \dots, K\}$ 。标注者 j 的混淆矩阵为：

$$\pi_{kl}^{(j)} = P(\text{标注者 } j \text{ 将类别 } k \text{ 标为 } l)$$

观测似然为：

$$P(\text{数据} | \pi, y) = \prod_{i=1}^N \prod_{j=1}^J \pi_{y_i, z_{ij}}^{(j)}$$

EM 算法交替估计 $\pi^{(j)}$ 和 y_i 的后验分布。

SCX 的 $SCX_m(s) = P(\ell(f_m(x), y) < \tau | x \in s)$ 是 Dawid-Skene 框架的推广：

- Dawid-Skene 假设标注者可靠性是全局常数（ $\pi_{kl}^{(j)}$ 不依赖 x ）
- SCX 允许可靠性随状态 s 变化，即 $\pi_{kl}^{(j,s)}(x) = P(\ell(f_j(x), y) < \tau | x \in s)$

这一推广的关键数学结果：当存在状态 s_1, s_2 使得 Dawid-Skene 全局混淆矩阵 $\pi^{(j)}$ 无法同时预测 s_1 和 s_2 上的表现时，状态条件建模是必要的。这正是命题一的本质。

1.5.2 项目反应理论 (IRT) Rasch 模型 (1960) 是 IRT 的基础模型:

$$P(Y_{ij} = 1 | \theta_i, b_j) = \frac{\exp(\theta_i - b_j)}{1 + \exp(\theta_i - b_j)}$$

其中 θ_i 是样本 i 的”能力”， b_j 是标注者 j 的”难度阈值”。

SCX 的 $SCX_m(s)$ 可以映射到 Rasch 模型:

$$\log \left(\frac{SCX_m(s)}{1 - SCX_m(s)} \right) = \theta_s - b_m$$

其中 θ_s 是状态 s 的”可处理性”参数 (容易与否), b_m 是专家 m 的能力阈值。

更丰富的 IRT 模型如 2-PL (两参数逻辑模型):

$$P(Y_{ij} = 1 | \theta_i, a_j, b_j) = \frac{\exp(a_j(\theta_i - b_j))}{1 + \exp(a_j(\theta_i - b_j))}$$

对应 SCX 中引入专家确度斜率 a_j , 允许不同专家对状态变化的敏感度不同——这正是 SCX 中 $\max_m SCX_m(s)$ 的核心假设。

1.5.3 与贝叶斯众包的联系 Raykar et al. (2010) 的贝叶斯众包模型进一步考虑了标注者的敏感度和特异度。SCX 在状态水平上的 $SCX_m(s)$ 可以看作在状态 s 上的标注者性能矩阵的奇异值分解的第一个分量——即最能区分”可靠/不可靠”维度的投影。

1.6 噪声与可学习性：Tsybakov 与 Huber

1.6.1 Tsybakov 噪声条件 Tsybakov (2004) 提出了分类问题中噪声条件的关键定义。对于二分类问题，设 $\eta(x) = P(Y = 1|X = x)$ ，则 Tsybakov 噪声条件为：存在常数 $C > 0$ 和 $\alpha \geq 0$ ，使得：

$$P_X(|\eta(X) - 1/2| \leq t) \leq Ct^\alpha, \quad \forall t > 0$$

α 控制决策边界附近的噪声程度：- $\alpha = 0$ ：无结构噪声（最坏情况）- $\alpha \rightarrow \infty$ ：无噪声（马吉尼-差距条件，Massart 条件）

在 Tsybakov 条件下，分类器的收敛速率为 $n^{-\frac{1+\alpha}{2+\alpha}}$ 。

SCX 的 噪声分数：

$$\text{NoiseScore}(x_i) = r_i \cdot \frac{1}{\rho(s_i) + \varepsilon} \cdot [1 - C(s_i)]$$

中的 $C(s)$ （状态内部一致性）与 Tsybakov 参数 α 有深层联系：

$$C(s) \approx 1 - 2 \cdot \mathbb{E}_{x \in s}[|\eta(x) - 1/2|]$$

当 $C(s) \rightarrow 1$ 时，状态内部近似为贝叶斯最优决策（ $\alpha \rightarrow \infty$ ）；当 $C(s) \rightarrow 0$ 时，状态内标签接近随机（ $\alpha \rightarrow 0$ ）。

具体地，若在状态 s 内有 $P_X(|\eta(x) - 1/2| \leq t | x \in s) \leq C_s t^{\alpha_s}$ ，则 $C(s) = \Phi(\alpha_s)$ ，其中 Φ 是单调增函数（如 $\Phi(\alpha) = 1 - e^{-\alpha}$ 或 $\Phi(\alpha) = \alpha/(1 + \alpha)$ ）。

1.6.2 Huber 污染模型 Huber (1964) 的 ε -污染模型：

$$F = (1 - \varepsilon)F_0 + \varepsilon G$$

其中 F_0 是真实分布， G 是污染分布， $\varepsilon \in [0, 1]$ 是污染比例。

SCX 的噪声分数 $N(s)$ 对应状态 s 的污染比例 ε_s ：

$$P_{X|s} = (1 - N(s)) \cdot P_{X|s}^0 + N(s) \cdot P_{X|s}^{\text{noise}}$$

其中 $P_{X|s}^0$ 是干净数据的条件分布， $P_{X|s}^{\text{noise}}$ 是噪声分布。

可学习性 $L(s) = C(s) \cdot [1 - N(s)]$ 可以严谨定义为：

$$L(s) = \inf_{f \in \mathcal{F}} \left[\frac{R(f|s) - R^*(s)}{R^*(s)} \right]^{-1}$$

其中 $R(f|s) = \mathbb{E}[\ell(f(X), Y) | X \in s]$ ， $R^*(s) = \inf_f R(f|s)$ 是贝叶斯风险。
 $L(s) \rightarrow 0$ 表示状态在现有函数类 $\mathcal{F}$ 下不可学习。

1.6.3 Natarajan 维度与噪声 在噪声条件下学习的样本复杂度由 Natarajan 维度刻画。对于多分类问题，Natarajan (1989) 给出了噪声存在的泛化边界：

$$R(f) \leq \hat{R}_\gamma(f) + \tilde{O} \left(\sqrt{\frac{d}{n\gamma^2}} \right)$$

其中 d 是 Natarajan 维度。SCX 的 $L(s)$ 隐式编码了 $\frac{d_s}{n_s}$ 的比值——状态 s 的“有效复杂度”。

1.7 主动采样：OED、信息论与 Bandit

1.7.1 MacKay 信息论主动学习 MacKay (1992) 的主动学习框架基于信息增益：

$$x^* = \arg \max_x H[\theta|\mathcal{D}] - H[\theta|\mathcal{D} \cup \{x, y\}]$$

其中 $H[\cdot]$ 是 Shannon 熵。在 SCX 的数据四分类中，**valuable** 数据点正是具有高信息增益的点。

SCX 的采样策略等价于优化期望信息增益：

$$\Delta H(s) = H[R_m|\mathcal{D}] - \mathbb{E}_{y \sim P(\cdot|s)}[H[R_m|\mathcal{D} \cup (s, y)]]$$

$V(s)$ 正比于 $\Delta H(s)$ 的代理。

1.7.2 最优实验设计 (OED) 在经典 OED 中，目标是选择实验 x 使得 Fisher 信息矩阵的某个标量函数最优：

- **A-optimality:** $\min \text{tr}(I(x)^{-1})$
- **D-optimality:** $\min \det(I(x)^{-1})$
- **E-optimality:** $\min \lambda_{\max}(I(x)^{-1})$

SCX 的 $V(s)$ 中的 $\bar{r}(s) \cdot L(s)$ 因子对应与参数估计的不确定性成比例的采样准则。当 $\bar{r}(s)$ 大且 $L(s)$ 高时，标注 (s, y) 对 Fisher 信息矩阵的更新贡献大。

1.7.3 Bandit 视角：探索-利用权衡 SCX 的 acquire 动作本质上是多臂 Bandit 的变体：

- 臂 (arm): 每个状态 s 是一个臂
- 收益 (reward): 标注后 $Y \sim P(Y|s)$ 带来的信息增益
- 目标: 在有限标注预算 B 下最大化总信息增益

SCX 的 $V(s)$ 是 Upper Confidence Bound (UCB) 启发式的推广:

$$V_{\text{UCB}}(s) = \underbrace{\bar{r}(s) \cdot L(s)}_{\text{利用项}} + \underbrace{\rho(s) \cdot [1 - D(s)]}_{\text{探索项}} \cdot \max_m SCX_m(s)$$

其中 $\rho(s)$ 类比于 UCB 中的 $\sqrt{\frac{\log t}{n_s}}$, 当状态样本少时 $\rho(s)$ 被低估, 需手动校准 $\frac{1}{\rho(s)+\varepsilon}$ 因子。

1.7.4 Thompson Sampling 联系 $V(s)$ 中出现的 $\max_m SCX_m(s)$ 也可以理解为 Thompson Sampling 式的后验概率: 对状态 s , 最佳专家 $m^*(s) = \arg \max_m SCX_m(s)$ 是后验下最可能的”最佳动作”。

1.8 SCX-Compress: Coreset 与蒸馏

1.8.1 Coreset 理论基础 Coreset 理论的目标是找到一个加权子集 $C \subseteq \mathcal{D}$, 使得对任意 $f \in \mathcal{F}$:

$$\left| \sum_{i \in \mathcal{D}} \ell(f(x_i), y_i) - \sum_{j \in C} w_j \ell(f(x_j), y_j) \right| \leq \varepsilon \sum_{i \in \mathcal{D}} \ell(f(x_i), y_i)$$

SCX-Compress 的四个输出类别构成了一个结构化 coreset:

类别	Coreset 角色	权重
Valuable	核心集 (必须保留)	$w_i = 1$
Redundant	可压缩 (冗余合并)	$w_i < 1/\text{密度}$
Noisy	异常值 (排除或降权)	$w_i = 0$ 或 $\ll 1$
Expert-dependent	需要路由缓存	w_i 取决于选中的专家

1.8.2 敏感度采样 Chen et al. (2018) 的 Coreset 构造通过敏感度采样实现。每个点 x_i 的敏感度为：

$$\sigma_i = \sup_{f \in \mathcal{F}} \frac{w_i |\ell(f(x_i), y_i)|}{\sum_j w_j |\ell(f(x_j), y_j)| - \varepsilon}$$

SCX 的 $V(s)$ 提供了敏感度的经验代理：

$$\sigma(s) \propto \frac{V(s)}{\sum_{s'} V(s')}$$

当 $V(s)$ 高时，该状态在 coreset 中被过采样（保留更多点）。

1.8.3 数据集蒸馏 数据集蒸馏 (Wang et al. 2018) 寻求合成样本 (x^*, y^*) 使得在其上训练的模型近似等价于在全数据集上训练的模型：

$$(x^*, y^*) = \arg \min_{(\tilde{x}, \tilde{y})} \mathcal{L}(\theta(\tilde{x}, \tilde{y}), \mathcal{D}_{\text{val}})$$

SCX-Compress 的 Redundant 类别就是蒸馏目标：同一状态内的冗余样本可以用少量代表性样本替代。

1.9 专家路由：MoE 谱系

1.9.1 Jacob et al. (1991) 自适应混合专家 这是 MoE 的开山之作。模型使用门控网络 $g(x)$ 来加权各个专家 $f_m(x)$ 的输出：

$$f(x) = \sum_{m=1}^M g_m(x) \cdot f_m(x), \quad g_m(x) = \text{softmax}(W_g x)_m$$

训练通过 EM 算法最大化对数似然（回归时为加权最小二乘）。

SCX 的专家路由 $m^*(x) = \arg \min_m \sum_s \gamma_s(x) R_m(s)$ 可以看作 Jacob 门控网络的硬化版本（hard routing vs. soft routing）。

1.9.2 Shazeer et al. (2017) 稀疏门控 MoE Shazeer 引入 top- k 门控实现稀疏性：

$$g(x) = \text{softmax}(\text{KeepTopK}(x \cdot W_g, k))$$

其中 $\text{KeepTopK}(v, k)_i = v_i$ 若 v_i 在前 k 大，否则 $-\infty$ 。

SCX 的路由不是基于 x 本身，而是基于状态条件风险 $\sum_s \gamma_s(x) R_m(s)$ 。这是 MoE 门控的一种元学习变体：门控决策不是直接学习 $x \rightarrow \text{expert}$ 的映射，而是通过估计条件风险来间接确定路由。

1.9.3 负载均衡与辅助损失 传统 MoE 需要辅助损失来平衡专家使用率：

$$\mathcal{L}_{\text{balance}} = \alpha \cdot CV(\text{expert_load})^2$$

SCX 的状态条件权重 $w_m(x) \propto \exp(-\alpha \sum_s \gamma_s(s) \hat{R}_m(s))$ 自然地实现了负载均衡：如果某专家在所有状态上都差，它的权重指数衰减；不同专家在不同状态上胜出，自动分散负载。

1.9.4 从 MoE 到 SCX 的差异

维度	传统 MoE	SCX 专家路由
门控输入	原始特征 x	状态赋值 $\gamma_s(x)$
门控参数	可学习的 W_g	估计的 $\hat{R}_m(s)$
训练方式	端到端反向传播	两阶段（先估风险，再路由）
稀疏性	hard/top-k	指数软加权
泛化保证	经验风险最小化	状态条件 PAC 边界

2. 三个命题的完整证明框架

2.1 命题一：全局专家排序不足

命题陈述：若存在状态 $s_1, s_2 \in \mathcal{S}$ 和专家 $a, b \in \{1, \dots, M\}$ ，使得 $R_a(s_1) < R_b(s_1)$ 但 $R_a(s_2) > R_b(s_2)$ ，则不存在全局最优专家。

2.1.1 形式化定义 定义 1（全局专家排序）：全局专家排序是一个全序关系 $\preceq$ 在专家集合 $\{1, \dots, M\}$ 上，满足：若 $a \preceq b$ ，则认为专家 a 整体上不劣于专家 b 。

定义 2（全局最优专家）：专家 m^* 称为全局最优，若对任意其他专家 $m \neq m^*$ 和任意状态 $s \in \mathcal{S}$ ，有 $R_{m^*}(s) \leq R_m(s)$ 。

2.1.2 证明 证法 1 (反证法): 假设存在全局最优专家 m^* 。

由全局最优的定义, 对所有 $s \in \mathcal{S}$:

$$R_{m^*}(s) \leq R_a(s) \quad \text{且} \quad R_{m^*}(s) \leq R_b(s)$$

但在状态 s_1 处: $R_{m^*}(s_1) \leq R_a(s_1) < R_b(s_1)$, 故 m^* 在 s_1 上优于 b 。记 $\Delta_1 = R_b(s_1) - R_{m^*}(s_1) > 0$ 。

在状态 s_2 处: $R_{m^*}(s_2) \leq R_b(s_2) < R_a(s_2)$, 故 m^* 在 s_2 上也优于 a 。记 $\Delta_2 = R_a(s_2) - R_{m^*}(s_2) > 0$ 。

但交叉条件 $R_a(s_1) < R_b(s_1)$ 且 $R_a(s_2) > R_b(s_2)$ 意味着:

$$R_a(s_1) - R_b(s_1) < 0 < R_a(s_2) - R_b(s_2)$$

由于 $R_{m^*}(s_1) \leq R_a(s_1)$ 且 $R_{m^*}(s_2) \leq R_b(s_2) < R_a(s_2)$, 我们有:

$$R_{m^*}(s_1) \leq R_a(s_1) < R_b(s_1)$$

$$R_{m^*}(s_2) \leq R_b(s_2) < R_a(s_2)$$

但这不产生矛盾。矛盾需要额外的条件。

修正的证明: 我们需要证明不存在单一的 m^* 能在两个状态上**同时**最优, 而非逐状态最优。

设 $\mathcal{M} = \{1, \dots, M\}$ 。定义状态条件最优集:

$$\mathcal{M}^*(s) = \arg \min_{m \in \mathcal{M}} R_m(s)$$

若 $a \in \mathcal{M}^*(s_1)$ 且 $b \in \mathcal{M}^*(s_2)$, 且 $a \neq b$, 则 $|\bigcap_{s \in \mathcal{S}} \mathcal{M}^*(s)| \leq 1$ 。若 $|\mathcal{S}| \geq 2$ 且存在至少两个不同的最优专家, 则不存在单个专家在所有状态上都是最优的。

由条件 $R_a(s_1) < R_b(s_1)$ 得 $a \in \mathcal{M}^*(s_1)$ 或 $b \notin \mathcal{M}^*(s_1)$; 由 $R_a(s_2) > R_b(s_2)$ 得 $b \in \mathcal{M}^*(s_2)$ 或 $a \notin \mathcal{M}^*(s_2)$ 。若同时有 $a \in \mathcal{M}^*(s_1)$ 和 $b \in \mathcal{M}^*(s_2)$, 则当 $a \neq b$ 时得证。

若 $a = b$, 则 $R_a(s_1) < R_a(s_1)$ (矛盾), 故 $a \neq b$ 必然成立。

因此, $\mathcal{M}^*(s_1) \neq \mathcal{M}^*(s_2)$, 即全局最优专家不存在。□

2.1.3 推广：连续状态下的退化形式 当 $\mathcal{S}$ 连续时 (如 $\mathcal{S} = [0, 1]$), 命题退化为: 若 $\exists s_1, s_2$ 使得 $R_a(s_i)$ 与 $R_b(s_i)$ 交叉, 则不存在 Lebesgue-几乎必然的全局最优专家。这用测度论语言表述为:

$$\mu \left(\left\{ s \in \mathcal{S} : m^*(s) = \arg \min_m R_m(s) \right\} \right) < 1$$

其中 μ 是 $\mathcal{S}$ 上的某参考测度 (如输入分布 P_X 的 push-forward)。

2.1.4 实证含义 这一命题直接论证了 SCX 框架的**必要性**而非充分性。它说明: - 任何全局聚合指标 (平均精度、平均 AUC、F1 宏观平均) 都会丢失信息 - 在交叉发生的数据区域, 必须引入状态条件建模 - 交叉的频次决定了状态粒度的需求: 交叉越多, 需要的状态越多

2.2 命题二：高误差采样在噪声下非最优

命题陈述：在噪声存在时，单纯基于残差 (max-residual sampling) 的主动采样策略不是最优的。

2.2.1 问题形式化 设 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ 为当前标注数据集，未标注池为 $\mathcal{U}$ 。对于 $x \in \mathcal{U}$ ，定义残差：

$$r(x) = \ell(f_{\text{current}}(x), \hat{y}(x))$$

其中 $\hat{y}(x)$ 是当前最佳预测。

max-residual 采样： $x^* = \arg \max_{x \in \mathcal{U}} r(x)$

噪声条件下，观测到的残差 $\tilde{r}(x)$ 可分解为：

$$\tilde{r}(x) = r_{\text{true}}(x) + \varepsilon(x)$$

其中 $\varepsilon(x) \sim P_{\text{noise}}(x)$ 是状态依赖的噪声过程。

2.2.2 假设

1. **噪声存在的假设：** 存在某个状态 s_0 ，使得 $\mathbb{E}[\varepsilon^2 | x \in s_0] \geq \sigma_0^2 > 0$
2. **有限采样预算：** 总标注预算为 $B \ll |\mathcal{U}|$
3. **样本间独立性：** 标注噪声在不同样本间独立（给定 x ）

2.2.3 证明 证法 1（期望风险最小化）：

定义采样策略 π 的收益为：

$$J(\pi) = \mathbb{E}_{(x_1^*, \dots, x_B^*) \sim \pi} \left[\sum_{t=1}^B \Delta R(f_t | x_t^*) \right]$$

其中 $\Delta R(f_t | x) = R(f_{t-1}) - R(f_t)$ 是标注 x 后模型的期望风险降低。

记 $r_i = r(x_i)$, $\hat{r}_i = \tilde{r}(x_i) - \varepsilon_i$ 为真实残差（不可观测）。

引理 1: max-residual 策略 π_{MR} 在 $B = 1$ 时选择:

$$x_{\text{MR}}^* = \arg \max_{i \in \mathcal{U}} \hat{r}_i + \varepsilon_i$$

引理 2: 最优策略 π^* 在 $B = 1$ 时选择:

$$x_{\pi^*}^* = \arg \max_{i \in \mathcal{U}} \mathbb{E}[\Delta R(f | x_i)] = \arg \max_{i \in \mathcal{U}} \int \Delta R(f | x_i) dP_{\varepsilon_i}(\varepsilon_i)$$

定理（命题二的正式陈述）：若存在至少一个 pair (i, j) 使得 $\hat{r}_i > \hat{r}_j$ 但 $\mathbb{E}[\Delta R(f | x_i)] < \mathbb{E}[\Delta R(f | x_j)]$, 则 $\pi_{\text{MR}} \neq \pi^*$ 。

证明:

步骤 1: 建立 ΔR 与 r 的关系。

对平滑损失 $L(f(x), y)$ 在 f_{current} 处做 Taylor 展开:

$$\Delta R(f | x) \approx r(x)^2 \cdot \left. \frac{\partial^2 \mathbb{E}[L]}{\partial f^2} \right|_{f_{\text{current}}} + \sigma_y^2(x)$$

其中 $\sigma_y^2(x)$ 是标签噪声方差。

步骤 2: 噪声 ε 引入偏差。

观察到的残差平方 $[\tilde{r}(x)]^2 = [r_{\text{true}}(x) + \varepsilon]^2$ 满足:

$$\mathbb{E}[\tilde{r}(x)^2|x] = r_{\text{true}}(x)^2 + \sigma_\varepsilon^2(x)$$

当 $\sigma_\varepsilon^2(x)$ 大时，max-residual 倾向于选择噪声大的样本而非信息量大的样本。

步骤 3: 构造反例。

假设 $\mathcal{U} = \{x_1, x_2\}$: - x_1 : $r_{\text{true}}(x_1) = 0.1$, $\sigma_\varepsilon^2(x_1) = 0.5$, $\tilde{r}(x_1) \approx 0.71$ - x_2 : $r_{\text{true}}(x_2) = 0.5$, $\sigma_\varepsilon^2(x_2) = 0.01$, $\tilde{r}(x_2) \approx 0.50$

则 max-residual 选择 x_1 , 但 $\mathbb{E}[\Delta R(f|x_1)] \approx 0.01 + \sigma_y^2(x_1) \ll \mathbb{E}[\Delta R(f|x_2)] \approx 0.25 + \sigma_y^2(x_2)$ 。

因此 max-residual 是次优的。□

2.2.4 信息论视角的补充证明 令 $I(X; Y|f)$ 为在给定当前模型时，未标注样本 X 和真实标签 Y 之间的条件互信息。max-residual 采样最大化的是 $H[\hat{Y}|f, X] = \mathbb{E}[\ell(\hat{Y}, Y)]$ ，而非 $I(X; Y|f)$ 。

由数据处理不等式：

$$I(X; Y|f) \leq H[\hat{Y}|f] - H[\hat{Y}|f, X, Y] + H[Y|f] - H[Y|f, X]$$

高噪声下， $H[Y|f, X]$ 增大，而 $I(X; Y|f)$ 减小。max-residual 无法区分”高不确定性源于信息缺失”与”高不确定性源于固有噪声”。

2.3 命题三：状态条件专家权重优于全局固定权重

命题陈述：对于专家融合 (ensemble) 问题，状态条件权重 $w_m(x)$ 的期望风险不高于任何全局固定权重 w_m 。

2.3.1 形式化设定 设 M 个专家 $f_1, \dots, f_M$ ，融合预测为：

$$f_{\text{ens}}(x) = \sum_{m=1}^M w_m(x) f_m(x) \quad (\text{状态条件})$$

$$\bar{f}_{\text{ens}}(x) = \sum_{m=1}^M \bar{w}_m f_m(x) \quad (\text{全局固定})$$

其中 $w_m(x) \geq 0$, $\sum_m w_m(x) = 1$; $\bar{w}_m \geq 0$, $\sum_m \bar{w}_m = 1$ 。

风险为 $R(f) = \mathbb{E}[\ell(f(X), f^*(X))]$ 。

2.3.2 凸性假设 损失函数 $\ell(\cdot, \cdot)$ 对第一个参数是凸的。常见损失 (MSE, 交叉熵, Hinge) 均满足。

2.3.3 证明 证法 1 (利用 Jensen 不等式和条件期望的塔性质)：

步骤 1：定义状态条件风险差。

对任意固定的全局权重 $\bar{w} = (\bar{w}_1, \dots, \bar{w}_M)$ ，全局固定融合的风险为：

$$R(\bar{f}_{\text{ens}}) = \mathbb{E}_X \left[\ell \left(\sum_m \bar{w}_m f_m(X), f^*(X) \right) \right]$$

状态条件融合的风险为：

$$R(f_{\text{ens}}) = \mathbb{E}_X \left[\ell \left(\sum_m w_m(X) f_m(X), f^*(X) \right) \right]$$

步骤 2: 对任意 x , 构造最优状态条件权重。

在给定 x 时, 最优权重 $w^*(x) = \arg \min_{w \in \Delta^{M-1}} \ell(\sum_m w_m f_m(x), f^*(x))$ 。

由于 x 已知, 最优权重可以完美匹配 x 处的点态最优专家组合, 因此对任意单点 x :

$$\ell \left(\sum_m w_m^*(x) f_m(x), f^*(x) \right) \leq \ell \left(\sum_m \bar{w}_m f_m(x), f^*(x) \right)$$

等号仅当 $\bar{w} \in \arg \min_{w \in \Delta^{M-1}} \ell(\sum_m w_m f_m(x), f^*(x))$ 时成立。

步骤 3: 在分布上取期望。

由于对每个 x 逐点不等式成立, 取期望保序:

$$\mathbb{E}_X \left[\ell \left(\sum_m w_m^*(X) f_m(X), f^*(X) \right) \right] \leq \mathbb{E}_X \left[\ell \left(\sum_m \bar{w}_m f_m(X), f^*(X) \right) \right]$$

即 $R(f_{\text{ens}}^*) \leq R(\bar{f}_{\text{ens}})$ 。

步骤 4: SCX 的 $w_m(x)$ 是 $w^*(x)$ 的近似。

SCX 权重 $w_m(x) \propto \exp(-\alpha \sum_s \gamma_s(x) \hat{R}_m(s))$ 不一定是 $w^*(x)$, 但它是基于经验风险的估计。当 $\hat{R}_m(s) \xrightarrow{p} R_m(s)$ 且 $\gamma_s(x)$ 是 x 位于状态 s 的精确后验概率时, $w_m(x)$ 将收敛到 $w_m^*(x)$ 。□

2.3.4 一个更精细的证明（通过冗余分析） 重新表述风险差：

$$\Delta R = R(\bar{f}_{\text{ens}}) - R(f_{\text{ens}})$$

利用凸性和 Taylor 展开：

$$\Delta R \geq \mathbb{E} \left[\left\langle \nabla \ell(\bar{f}_{\text{ens}}), \sum_m (\bar{w}_m - w_m(X)) f_m(X) \right\rangle \right]$$

记 $\delta_m(X) = \bar{w}_m - w_m(X)$ ，则：

$$\Delta R \geq \sum_m \mathbb{E}[\delta_m(X) \cdot \nabla \ell(\bar{f}_{\text{ens}}) \cdot f_m(X)]$$

对全局固定权重， $\mathbb{E}[\delta_m(X)] = \bar{w}_m - \mathbb{E}[w_m(X)]$ 。利用条件期望的塔性质：

$$\Delta R \geq \sum_m \mathbb{E} [\delta_m(X) \cdot \mathbb{E}[\nabla \ell(\bar{f}_{\text{ens}}) \cdot f_m(X) | X]]$$

若状态条件权重 $w_m(X)$ 与 $\nabla \ell(\bar{f}_{\text{ens}}) \cdot f_m(X)$ 负相关（这正是 SCX 设计目标——降低高损失区域的权重），则 $\Delta R > 0$ 。

2.3.5 极端情况：当状态条件权重退化为全局权重 当 $\mathcal{S} = \{\text{all}\}$ （仅一个状态）时， $\gamma_s(x) \equiv 1$ ， $w_m(x) = \frac{\exp(-\alpha \hat{R}_m)}{\sum_{m'} \exp(-\alpha \hat{R}_{m'})}$ ，此时 $w_m(x)$ 为常数，命题退化为平凡情况 $\Delta R = 0$ 。

当每个 x 独立成状态时（ $\mathcal{S} = \mathcal{X}$ ）， $\gamma_s(x) = \delta_{x,s}$ ， $w_m(x) = \frac{\exp(-\alpha \hat{R}_m(x))}{\sum_{m'} \exp(-\alpha \hat{R}_{m'}(x))}$ ，此时达到理论上界， ΔR 最大。

3. 状态空间构造方法

3.1 嵌入映射 $\phi : \mathcal{X} \rightarrow \mathbb{R}^d$

3.1.1 嵌入选择的原则 状态构造的第一步是将原始输入 x 映射到低维连续空间 $\mathbb{R}^d$ 。选择准则：

- 1. 保真性： $\phi(x)$ 应保留与专家性能 $R_m(x)$ 相关的信息
- 2. 平滑性： 相邻点 $\phi(x_i) \approx \phi(x_j)$ 应有相似的风险 $R_m(x_i) \approx R_m(x_j)$
- 3. 计算效率： ϕ 的评估应是 $O(d)$ 或 $O(\log d)$ 的

3.1.2 候选嵌入方法

方法	维度 d	特性	适用场景
原始特征	$\dim(\mathcal{X})$	无信息损失	$\mathcal{X}$ 维度低 (< 100)
PCA	可调 (k)	线性降维，最大方差	线性结构数据
t-SNE	2-3	局部结构保持，全局失真	可视化为重
UMAP	可调	保持局部和全局结构	通用
PaCMAP	可调	平衡局部/全局/频谱	高维聚类前处理
自编码器	可调	非线性压缩	复杂高维输入
对比学习嵌入	可调	语义距离保持	图像/文本
专家特征 $[f_1(x), \dots, f_M(x)]$	M	专家性能的直接表征	当专家数量少时

3.1.3 推荐方案：双视图嵌入 结合原始特征和专家输出：

$$\phi(x) = [\phi_{\text{feat}}(x), \phi_{\text{exp}}(x)] \in \mathbb{R}^{d_f + d_e}$$

其中 $\phi_{\text{feat}}(x)$ 是原始特征的降维版本， $\phi_{\text{exp}}(x) = [f_1(x), \dots, f_M(x)]$ 是专家输出向量。

3.2 降维方法对比分析

3.2.1 PCA (主成分分析) 目标：最大化投影后方差 $\max_V \text{tr}(V^\top \Sigma V)$ ，其中 $\Sigma = \text{Cov}(X)$ 。

代价： $O(nd^2 + d^3)$ 或 $O(nd \log k)$ (随机化 SVD)。

SCX 适配性：PCA 保持全局方差，但不保证局部风险同质性。在 $R_m(x)$ 变化剧烈的区域，PCA 可能将不同风险的区域投影到相邻位置。

线性限制： $R_m(x)$ 对 x 的函数可能高度非线性，PCA 的线性投影会破坏保真性。

3.2.2 t-SNE (t-distributed Stochastic Neighbor Embedding) 目标：最小化 $KL(P||Q)$ ，其中 p_{ij} 是高维高斯相似度， q_{ij} 是低维 t-分布相似度。

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)}, \quad q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}$$

代价： $O(n^2)$ ，对大 n 不适用。

SCX 适配性： - 优点：局部结构保持极好，适合发现精细的风险模式变化 -
缺点：全局结构失真严重， d 通常限于 2-3 不利于聚类

3.2.3 UMAP (Uniform Manifold Approximation and Projection)

目标: 最小化模糊集交叉熵 $CE(F, G)$, 其中 F 是高维模糊拓扑表示, G 是低维表示。

代价: $O(n \log n)$ (近似最近邻加速后)。

SCX 适配性: - 保持局部和部分全局结构 - 聚类边界清晰, 利于后续聚类 - d 可调至 10-50, 提高聚类质量

推荐: UMAP 是 SCX 中 ϕ 构建的首选方法。

3.2.4 PaCMAP (Pairwise Controlled Manifold Approximation) 目

标: 平衡三类力——近邻吸引、中程排斥、远距排斥。

$$\text{Loss} = w_{\text{near}} \cdot \text{Loss}_{\text{near}} + w_{\text{mid}} \cdot \text{Loss}_{\text{mid}} + w_{\text{far}} \cdot \text{Loss}_{\text{far}}$$

SCX 适配性: PaCMAP 对参数不敏感, 聚类鲁棒性优于 UMAP。当 SCX 需要自动化管线时, PaCMAP 减少了调参需求。

3.3 聚类方法对比分析

3.3.1 GMM (高斯混合模型) 模型:

$$P(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$$

估计: EM 算法最大化对数似然。E-step 计算后验责任:

$$\gamma_{ik} = P(z_i = k | x_i) = \frac{\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_i | \mu_j, \Sigma_j)}$$

SCX 适配性: - 天然支持软状态赋值 $\gamma_s(x) = \gamma_{ik}$! 这是 SCX 中 $\gamma_s(x)$ 的精确实现 - 协方差矩阵 Σ_k 捕捉状态内部方差 - 适用于凸形状的簇

局限性: - 需要指定 K - 假设高斯分布 (不适用于高度非凸簇) - 高维数据时协方差矩阵估计困难 (可通过 $\Sigma_k = \sigma_k^2 I$ 或对角矩阵简化)

3.3.2 DBSCAN (Density-Based Spatial Clustering of Applications with Noise) 核心概念:

- ε -邻域: $N_\varepsilon(p) = \{q \in D | \text{dist}(p, q) \leq \varepsilon\}$ - 核心点: $|N_\varepsilon(p)| \geq \text{MinPts}$ - 边界点: 处于核心点邻域内但自身不是核心点 - 噪声点: 既不是核心点也不是边界点

SCX 适配性: - 自动识别噪声状态 (Noise 分类) - 不需要预指定 K - 可发现任意形状的簇

局限性: - ε 和 MinPts 敏感 - 密度变化剧烈的数据效果差 - 边界点 $\gamma_s(x)$ 是硬赋值 (0 或 1), 不支持软状态

3.3.3 HDBSCAN (Hierarchical DBSCAN) 改进: 基于层次聚类, 消除 ε 参数。

1. 构建最小生成树 (MST)
2. 对 MST 按边长度降序构建层次树
3. 使用 $\lambda = 1/\text{distance}$ 作为稳定性度量
4. 从层次树中提取最稳定的簇

SCX 适配性: - 优于 DBSCAN: 可处理变密度数据 - 提供样本水平的状态归属概率 (通过 λ -稳定性导出) - 获取开箱即用的噪声点检测

推荐: 对 $\mathcal{X}$ 空间复杂时, HDBSCAN 是比 GMM 更好的选择。

3.3.4 Spectral Clustering 步骤: 1. 构建相似度图 $W_{ij} = \exp(-\|x_i - x_j\|^2/2\sigma^2)$ 2. 计算图拉普拉斯 $L = D - W$ 或归一化拉普拉斯 $L_{\text{sym}} = I - D^{-1/2}WD^{-1/2}$ 3. 取 L 的 K 个最小特征向量构成 $U \in \mathbb{R}^{n \times K}$ 4. 对 U 的行进行 K -means

SCX 适配性: - 擅长发现非凸簇 (环状、螺旋状) - 对专家性能局部分布复杂的场景有效 - 可导出类似软赋值的谱嵌入空间

局限性: - $O(n^3)$ 复杂度 (可近似为 $O(n^2)$) - K 需预设 - 对新样本无法直接预测 (需要 Nystroem 逼近)

3.4 软状态赋值 $\gamma_s(x)$

3.4.1 定义 软状态赋值函数 $\gamma: \mathcal{X} \times \mathcal{S} \rightarrow [0, 1]$ 满足:

$$\sum_{s \in \mathcal{S}} \gamma_s(x) = 1, \quad \forall x \in \mathcal{X}$$

3.4.2 实现方式 方法 1: GMM 后验概率

$$\gamma_s(x) = \frac{\pi_s \mathcal{N}(\phi(x) | \mu_s, \Sigma_s)}{\sum_{t \in \mathcal{S}} \pi_t \mathcal{N}(\phi(x) | \mu_t, \Sigma_t)}$$

方法 2: Kernel 加权

$$\gamma_s(x) = \frac{\kappa(\phi(x), \mu_s)}{\sum_{t \in \mathcal{S}} \kappa(\phi(x), \mu_t)}$$

其中 $\kappa(x, y) = \exp(-\|x - y\|^2/2\sigma^2)$, μ_s 是簇中心。

方法 3: t-SNE/UMAP 嵌入上的 Softmax

$$\gamma_s(x) = \text{softmax}(-\beta \cdot d(\phi(x), \mu_s))_s$$

其中 d 是欧氏距离, β 控制软度温度。

方法 4: KNN 概率

$$\gamma_s(x) = \frac{|\text{KNN}(x) \cap s|}{k}$$

基于 $\phi(x)$ 的 k 近邻中属于 s 的比例。

3.4.3 软 vs 硬赋值的权衡

维度	硬赋值 (Hard)	软赋值 (Soft)
风险估计	样本量少时方差大	借用邻域信息, 方差小
计算	快	稍慢
边界处	不连续	光滑过渡
理论分析	简单	需要处理混合分布

SCX 主框架使用软赋值, 因为 $\gamma_s(x)$ 在专家路由

$$w_m(x) \propto \exp(-\alpha \sum_s \gamma_s(x) \hat{R}_m(s))$$

中的使用需要微分连续性。

3.5 状态粒度选择

3.5.1 Silhouette Score 对点 i , 其轮廓值为:

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}$$

其中 a_i 是 i 与同一簇内点的平均距离, b_i 是与最近的其他簇的平均距离。

整体 silhouette 得分: $S(K) = \frac{1}{n} \sum_i s_i$ 。

SCX 选择准则: $K^* = \arg \max_K S(K)$ 。但 silhouette 仅基于几何距离, 不考虑风险 $R_m(s)$ 的内部方差。

3.5.2 Gap Statistic (Tibshirani et al., 2001) 比较实际数据的聚类紧凑度 W_K 与零参考分布下的期望值 $E_n^*[W_K]$:

$$\text{Gap}_n(K) = E_n^*[\log W_K] - \log W_K$$

最优 K 是使得 $\text{Gap}(K) \geq \text{Gap}(K+1) - s_{K+1}$ 的最小值。

SCX 适配性: 可替换 W_K 为聚类内风险方差之和 $\sum_{s \in \mathcal{S}} \text{Var}_{x \in s}[R_m(x)]$ 。

3.5.3 BIC (贝叶斯信息准则)

$$\text{BIC}(K) = -2 \log L + K \cdot \log n$$

SCX 上下文中, L 是给定状态划分的似然:

$$L = \prod_{i=1}^n \sum_{k=1}^K \pi_k \mathcal{N}(\phi(x_i) | \mu_k, \Sigma_k)$$

3.5.4 特定于 SCX 的粒度选择：状态风险同质性 定义状态内风险方差：

$$\text{Var}_m(s) = \frac{1}{|s|} \sum_{x \in s} (R_m(x) - R_m(s))^2$$

其中 $R_m(x) = \ell(f_m(x), f^*(x))$ 为点态风险。

总同质性度量：

$$H(K) = \sum_{m=1}^M \sum_{s \in \mathcal{S}} \text{Var}_m(s)$$

选择满足 $H(K+1) - H(K) < \varepsilon$ 的最小 K （肘部法则）。

3.5.5 推荐的 SCX 粒度选择管线

For K in $[2, K_{\max}]$:

1. 降维: $(X) \rightarrow \text{UMAP}(X, d=\min(50, n/10))$

2. 聚类: GMM(K) 或 HDBSCAN

3. 计算:

- 几何紧致度: $\text{Silhouette}(K)$

- 风险同质性: $H(K)$

- 模型复杂度: $\text{BIC}(K)$

4. 综合得分: $\text{Score}(K) = w_s \cdot S(K) + w_h \cdot (1 - H_{\text{norm}}(K)) - w_b \cdot \text{BIC}_{\text{norm}}(K)$

选择 $K^* = \arg\max \text{Score}(K)$

4. 子模块数据流与协调

4.1 整体架构

SCX 框架由以下子模块构成，形成闭环数据流：

输入数据 D

1. 状态构造引擎 (State Constructor)

嵌入 $\rightarrow$ 降维 $\rightarrow$ 聚类 + $_s(x)$

状态索引 $\{s, _s(x)\}$

2. 风险评估模块 (Risk Estimator)

$R_m(s)$ = average loss of expert m on state s

$SCX_m(s)$ = empirical reliability

噪声检测: $NoiseScore(x_i)$

$\{R_m(s), SCX_m(s), NoiseScore\}$

3. 数据价值评估器 (Value Assessor)

$V(s) = \bar{r}(s) \cdot (s) \cdot L(s) \cdot [1-D(s)] \cdot \max_m SCX_m(s)$

四分类: Valuable / Redundant / Noisy / Expert-Dep

数据分类标签

4. 动作决策引擎 (Action Engine)

$A = \{\text{acquire, relabel, downweight, discard, route, split}\}$

对每个状态 s , 选择动作 $a \in A$

acquire/relabel downweight/discard route/split

标注预算分配 数据清理 专家路由/状态细分

5. 模型更新模块 (Model Updater)

重训练 / 微调专家模型

更新风险估计 / 状态哈希

SCX-压缩
(Coreset)

(返回步骤 1, 闭环迭代)

4.2 模块间接口契约

4.2.1 状态构造引擎 → 风险评估模块

输入：原始数据 $D = \{x_i, y_i, f_m(x_i)\}$

输出：

- 状态映射：state_idx[i] $\{1, \dots, K\}$ (硬) 或 $_s(x_i)$ (软)
- 状态统计：count[s], centroid[s], density[s]
- 嵌入：(x_i) R^d (可选缓存)

数据流方向：单向，状态构造仅在数据新增或状态分裂时触发。

4.2.2 风险评估模块 → 数据价值评估器

输入：D, {state_idx}, {f_m(x_i), y_i}

输出：

- $R_m(s)$: $K \times M$ 矩阵
- $SCX_m(s)$: $K \times M$ 矩阵
- NoiseScore[i]: N 维向量
- $C(s)$: K 维一致性分数
- $N(s)$: K 维噪声分数

关键算法：

$$R_m(s) = \frac{\sum_{x_i \in s} \ell(f_m(x_i), y_i)}{|s|}$$

$$SCX_m(s) = \frac{|\{x_i \in s : \ell(f_m(x_i), y_i) < \tau\}|}{|s|}$$

$$C(s) = 1 - \frac{1}{|s|} \sum_{x_i \in s} \frac{|\ell(f_m(x_i), y_i) - \bar{\ell}(s)|}{\max \ell - \min \ell}$$

4.2.3 数据价值评估器 → 动作决策引擎

输入: $\{R_m(s)\}$, $\{SCX_m(s)\}$, $\{NoiseScore\}$, $\{C(s)\}$, $\{N(s)\}$

输出:

- Value[s]: K 维
- Class[s]: {'V', 'R', 'N', 'E'} 四分类标签
- confidence[s]: 分类置信度

四分类规则:

```

if V(s) > _v && max_m SCX_m(s) < _r:
    → Expert-dependent (E)
elif V(s) > _v && D(s) < _d:
    → Valuable (V)
elif D(s) > _d && N(s) < _n:
    → Redundant (R)
elif N(s) > _n:
    → Noisy (N)
else:
    → Expert-dependent (E) [catch-all]

```

阈值 $\tau_v, \tau_r, \tau_d, \tau_n$ 可由交叉验证或启发式规则确定。

4.2.4 动作决策引擎 → 模型更新模块

动作规范:

- acquire(s): 请求标注 batch_size 个来自状态 s 的未标注样本

- **relabel(s)**: 请求对状态 s 的样本重新标注 (高噪声状态)
- **downweight(s)**: 将状态 s 的样本权重设为 $w_s < 1$
- **discard(s)**: 清洗状态 s (标记为离群)
- **route(s, m*)**: 将状态 s 路由到专家 m^*
- **split(s)**: 将状态 s 分裂为两个子状态

每个动作触发模型更新模块的不同子流程。

4.2.5 模型更新模块 → 状态构造引擎 (反馈闭环)

输出:

- 更新后的 $\{f_m(x)\}$, $\{f_m(x_i)\}$
- 状态分裂后的新 **centroid** 映射
- SCX-Compress 后的浓缩数据集 D'

4.3 闭环更新逻辑

当新数据到达时:

1. 对新样本 x_{new} 计算嵌入 $\phi(x_{\text{new}})$
2. 用现有聚类模型计算 $\gamma_s(x_{\text{new}})$, 分配状态
3. 轻量更新状态统计量: $|s|_{\text{new}} = |s|_{\text{old}} + \gamma_s(x_{\text{new}})$
4. 增量更新 $R_m(s)$: 使用 Welford 在线算法
5. 重新评估 $V(s)$, 若变化超过阈值则触发动作

当动作触发时:

- **discard**: 从数据集中移除样本, 更新状态统计
- **split**: 在状态内重新运行聚类 ($K = 2$), 更新全局状态索引
- **relabel**: 用新标签覆盖旧标签, 重新计算风险
- **acquire**: 将新标注样本加入数据集, 触发新数据到达流程

4.4 计算复杂度分析

模块	初始构建	增量更新
UMAP 嵌入	$O(n \log n)$	$O(n_{\text{new}} \log n)$
GMM 聚类	$O(nKd)$	$O(Kd)$ (E-step only)
风险估计	$O(nM)$	$O(n_{\text{new}}M)$
价值评估	$O(KM)$	$O(KM)$
四分类	$O(K)$	$O(1)$
SCX-Compress	$O(n \log n)$	$O(n_{\text{new}} \log K)$

总复杂度： 初始构建 $O(n \log n + nM)$ ，增量更新 $O(n_{\text{new}}M)$ ，适合流式场景。

5. SCX 理论边界

5.1 收敛边界：风险估计的一致性

给定 n_s 个来自状态 s 的独立同分布样本，经验风险 $\hat{R}_m(s)$ 的收敛速度由 Hoeffding 不等式和 Bernstein 不等式控制。

5.1.1 有界损失 设 $\ell \in [0, L]$ ，对任意 $\delta > 0$ ，以概率 $1 - \delta$ ：

$$|\hat{R}_m(s) - R_m(s)| \leq L \sqrt{\frac{\log(2/\delta)}{2n_s}}$$

5.1.2 亚高斯损失 若 ℓ 是 σ -亚高斯的（如 MSE 损失在正态误差下），则：

$$P\left(|\hat{R}_m(s) - R_m(s)| \geq t\right) \leq 2 \exp\left(-\frac{n_s t^2}{2\sigma^2}\right)$$

5.1.3 多状态联合边界 对所有 K 个状态和 M 个专家应用 Bonferroni 校正，以概率 $1 - \delta$ ：

$$\max_{m,s} |\hat{R}_m(s) - R_m(s)| \leq L \sqrt{\frac{\log(2MK/\delta)}{2 \min_s n_s}}$$

警告：当某个状态 s 的 n_s 很小时（如样本稀疏状态），该边界失去意义。这是 SCX 的固有局限——状态划分越细，每个状态内的样本越少，风险估计的方差越大。

5.2 泛化边界：状态条件专家路由

对状态条件路由 $m^*(x) = \arg \min_m \sum_s \gamma_s(x) \hat{R}_m(s)$ ，其期望风险为：

$$R(m^*) = \mathbb{E}[\ell(f_{m^*(X)}(X), f^*(X))]$$

5.2.1 基于 VC 维的边界 设专家函数类 $\mathcal{F}_m$ 的 VC 维为 d_m （二分类）或伪维数为 $P_{\dim}(\mathcal{F}_m)$ （回归）。则对任意 $\delta > 0$ ，以概率 $1 - \delta$ ：

$$R(m^*) \leq \hat{R}(m^*) + \tilde{O}\left(\sqrt{\frac{\max_m d_m}{n}} + \sqrt{\frac{K \log M}{n}}\right)$$

其中第二项来自状态选择器的复杂度（ K 个状态中选择最优专家）。

5.2.2 若状态划分也是数据驱动的 如果状态 $\mathcal{S}$ 和嵌入 ϕ 是通过数据学习的（通常如此），则需要额外惩罚：

$$R(m^*) \leq \hat{R}(m^*) + \tilde{O} \left(\sqrt{\frac{\max_m d_m + d_\phi + K \log M}{n}} \right)$$

其中 d_ϕ 是嵌入函数的 Rademacher 复杂度或 VC 维（如 UMAP 的参数自由度）。

5.3 信息论下界

5.3.1 状态级最坏情况错误率 考虑最坏情况分布族 $\mathcal{P}$ （专家性能随机），任何算法都需要：

$$\inf_{\text{Alg}} \sup_{P \in \mathcal{P}} \mathbb{E}[R(\text{Alg}) - R^*] \geq \Omega \left(\sqrt{\frac{KM}{n}} \right)$$

当 $n/K < \log M$ 时，不可能以高概率识别每个状态的最优专家。这为 SCX 设定了一个必要条件的样本复杂度——每个状态至少需要 $O(\log M)$ 个样本来判断最优专家。

5.3.2 最小-最大风险比率 定义状态条件路由相对于最优固定专家权重的改进率：

$$\eta(\mathcal{S}) = \frac{R(\bar{f}_{\text{ens}}^*) - R(f_{\text{ens}}^*)}{R(\bar{f}_{\text{ens}}^*)}$$

则 $\eta(\mathcal{S})$ 的上界受限于状态间的风险异质性：

$$\eta(\mathcal{S}) \leq 1 - \frac{\min_m \sum_s P(s) R_m(s)}{\sum_s P(s) \min_m R_m(s)}$$

当所有状态的最优专家相同时, $\eta(\mathcal{S}) = 0$ (状态条件路由无改进)。

5.4 噪声条件下的边界

5.4.1 噪声分数的统计一致性 噪声分数 $\text{NoiseScore}(x_i) = r_i \cdot \frac{1}{\rho(s_i) + \varepsilon} \cdot [1 - C(s_i)]$ 作为噪声检测器, 其 Type-I/II 错误率由以下边界控制:

在 Tsybakov 噪声条件下, 存在常数 $\alpha \geq 0$ 使得:

$$P(\text{false positive}) \leq C n_s^{-\frac{1+\alpha}{2+\alpha}}, \quad P(\text{false negative}) \leq C' n_s^{-\frac{1+\alpha'}{2+\alpha'}}$$

其中 C, C' 是取决于 $\rho(s)$ 和 $C(s)$ 的常数。

5.4.2 冗余检测的精度 $D(s)$ 的估计精度由状态内 pairwise 相似度的 U-statistic 收敛速度控制:

$$|\hat{D}(s) - D(s)| = O_p\left(\frac{1}{\sqrt{n_s}}\right)$$

更精确的 Berry-Esseen 型边界:

$$P\left(\sqrt{n_s}|\hat{D}(s) - D(s)| \geq t\right) \leq 2 \exp\left(-\frac{t^2}{2\sigma_D^2}\right) + O\left(\frac{1}{\sqrt{n_s}}\right)$$

5.5 状态分裂 vs 合并的互信息权衡

5.5.1 分裂的信息增益 将状态 s 分裂为 s_1 和 s_2 的信息增益为：

$$\Delta I_{\text{split}} = I(S'; R_m) - I(S; R_m)$$

其中 S 是分裂前的状态变量， S' 是分裂后的。

若 $\Delta I_{\text{split}} < \log(2)/n$ （每个子状态的样本少于 2 个的等效信息量），则分裂不应执行。

5.5.2 最优状态数的信息论界 记 $R_{\text{gen}}(\mathcal{S})$ 为状态划分 $\mathcal{S}$ 下的期望泛化风险。由率失真理论：

$$R_{\text{gen}}(\mathcal{S}) \geq R^* + \exp(-I(S; R_m))$$

其中 $R^* = \min_{m^*(x)} \mathbb{E}[\ell(f_{m^*(X)}(X), f^*(X))]$ 是已知点态最优专家的极限风险。

因此，状态粒度选择是在两个目标间的权衡：- 减小 $R_{\text{gen}}(\mathcal{S})$ ：需要更多状态（高 $I(S; R_m)$ ）- 控制估计方差：需要更大的 n_s （减少状态）

5.6 对抗鲁棒性边界

5.6.1 对抗状态扰动 若攻击者可以操纵 $\gamma_s(x)$ （如通过中毒攻击），则状态条件路由可能被劫持。

在 ℓ_∞ 攻击下， $\tilde{\gamma}_s(x) = \gamma_s(x) + \delta_s(x)$ ， $\|\delta\|_\infty \leq \varepsilon$ 。路由决策的变化上界为：

$$P(m^*(x) \neq \tilde{m}^*(x)) \leq \frac{2\varepsilon}{\min_s \gamma_s(x) + \varepsilon}$$

当某个状态的 $\gamma_s(x)$ 接近 0 时，微扰即可翻转路由。

5.6.2 防御： γ -平滑 对 $\gamma_s(x)$ 施加 ℓ_1 正则化或标签平滑可提高鲁棒性：

$$\tilde{\gamma}_s(x) = \frac{\gamma_s(x) + \lambda/K}{1 + \lambda}$$

对应的路由决策变化概率降至 $O(\varepsilon/\lambda)$ 。

5.7 计算-统计折衷

状态数 K	统计效率	计算代价	路由精度	适用场景
$K = 1$	高 ($n_s = n$)	最低	低	全局专家差异大
$K = \sqrt{n}$	中等	中等	中-高	通用
$K = n/\log n$	低 ($n_s = \log n$)	最高	极高	专家性能高度异质

经验法则：对 $n = 10^5$ 样本, $K \in [10, 100]$ 是合理范围, 对应 $n_s \in [10^3, 10^4]$ 。

5.8 边界汇总表

边界类型	表达式	条件
风险估计误差	$O(L\sqrt{\log(MK/\delta)/n_{\min}})$	有界损失, $\ell \leq L$
路由泛化	$\tilde{O}(\sqrt{(d_{\max} + K \log M)/n})$	VC 维 $d_{\max}$, 状态数 K

边界类型	表达式	条件
信息论下界	$\Omega(\sqrt{KM/n})$	最坏情况分布
噪声检测	$O(n_s^{-(1+\alpha)/(2+\alpha)})$	Tsybakov 条件 $\alpha \geq 0$
对抗鲁棒性	$O(\varepsilon/(\gamma_{\min} + \varepsilon))$	ℓ_∞ 攻击 ε
分裂增益	$\Delta I_{\text{split}} \geq \log(2)/n$	最小可检测增益
率失真极限	$R_{\text{gen}} \geq$ $R^* + \exp(-I(S; R_m))$	任意状态划分

附录：符号对照表

符号	含义	定义位置
$R_m(s)$	专家 m 在状态 s 上的条件风险	1.1
$SCX_m(s)$	SCX 可靠性指标	1.5
$V(s)$	状态 s 的数据价值	1.4
$\gamma_s(x)$	x 属于状态 s 的软概率	3.4
$\bar{r}(s)$	状态 s 的平均残差	1.4
$\rho(s)$	状态 s 的出现概率	1.4
$L(s)$	状态 s 的可学习性	1.6
$C(s)$	状态 s 的内部一致性	1.6
$N(s)$	状态 s 的噪声分数	1.6
$D(s)$	状态 s 的冗余度	5.4
$\phi(x)$	输入嵌入映射	3.1
$\mathcal{S}$	状态空间	1.3
M	专家数量	—

符号	含义	定义位置
$K = \mathcal{S} $	状态数量	3.3
ℓ	损失函数	1.1
f_m	第 m 个专家模型	—
f^*	真实函数/最优函数	1.1