

# 竞争分析报告：数据估值与主动学习

SCX (State-Conditioned eXpertise) 框架的竞争格局全景分析覆盖  
时间范围：2023-2026 生成日期：2026-06-25

## 目录

- 方法论说明
- A. Data Valuation 方法
- B. LLM 数据选择
- C. Active Learning
- D. 竞争格局总结
- E. SCX 的独特定位
- 参考文献

## 1. 方法论说明

本报告通过系统化 Web 搜索 + 论文检索 + 源码分析三种渠道，对四大领域的近 30 种方法进行逐一评估。每个方法按照统一模板分析：解决什么问题、数学对象是什么、与 SCX 的核心差异、SCX 的相对优势。

SCX 框架的核心定义（供对手比较使用）：

- 专家可靠性**:  $SCX_m(s) = P(f_m(x), y) < \dots | x, s)$  — 不是全局常数，而是状态条件函数

- **数据价值:**  $V(s) = \bar{r}(s) \cdot (s) \cdot L(s) \cdot [1 - D(s)] \cdot \max_m SCX_m(s)$  — 不是样本固有属性
  - **状态划分:**  $s: X \rightarrow S$ , 状态空间由学习/聚类自动发现
  - **两类获取:** state-wise acquisition (先选高价值状态) 和 point-wise acquisition (状态内选代表点)
- 

## A. Data Valuation 方法

### A.1 Data Shapley 及其变体

#### A.1.1 经典 Data Shapley

- **论文:** Ghorbani & Zou, “Data Shapley: Equitable Valuation of Data for Machine Learning”, ICML 2019
- **链接:** <https://arxiv.org/abs/1904.02868>

**解决问题:** 对每个训练样本赋予一个公平的”价值分数”，衡量其对模型性能的边际贡献。

**数学对象:** 合作博弈论中的 Shapley 值。对样本  $i$ :

$$\phi_i = (1/N!) \sum_{\Pi} [v(S_{-}(i) \cup \{i\}) - v(S_{-}(i))]$$

其中  $v(S)$  是训练集  $S$  上训练模型的性能,  $\Pi$  是所有排列,  $S_{-}(i)$  是排列中  $i$  之前的样本集。

**与 SCX 的核心差异:** 1. **全局价值 vs 条件价值:** Data Shapley 给每个样本一个全局标量; SCX 的价值是状态条件的——一个样本在状态  $s$  中的价值取决于当前模型在该状态的缺陷和专家的可靠性。2. **单模型 vs 多专家:**

Data Shapley 基于一个模型  $v(S)$ ；SCX 天然处理多个专家。3. **计算开销：**Data Shapley 精确计算  $O(2^N)$ ，MC 近似仍需要  $O(N^2)$  次重训练。

**SCX 相对优势：** - Data Shapley 无法区分“一个困难状态的样本”和“一个噪声样本”——两者都可以有高 Shapley 值。SCX 通过状态内部一致性  $C(s)$  做区分。 - Data Shapley 无法利用专家先验知识——它对每个样本的估值从头计算。SCX 可用专家条件可靠性加速估值。 - Data Shapley 的估值对模型重训练敏感，SCX 的状态划分更稳定。

---

#### A.1.2 截断 Monte Carlo Shapley (TMC-Shapley)

- **论文：**Ghorbani & Zou, ICML 2019（同上）
- **变体：**对 Shapley 值的 MC 估计进行截断：当边际贡献收敛时提前终止排列采样

**改进：**计算量从  $O(N^2)$  降为约  $O(N \log N)$ ，仍需要大量重训练。

**SCX 差异：**TMC 只是计算加速策略，不改变全局价值的基本逻辑。SCX 的 state-wise valuation 天然可并行（各状态独立估值），且不需要排列。

---

#### A.1.3 KNN-Shapley

- **论文：**Jia et al., “Towards Efficient Data Valuation Based on the Shapley Value”, AISTATS 2019
- **链接：**<https://arxiv.org/abs/1902.10275>

**数学对象：**用 KNN 作为代理模型（surrogate model），利用 KNN 的固有性质实现精确  $O(n \log n)$  的 Shapley 值计算。

**改进：**首个实用大规模数据估值方法，不需要大量重训练。

**SCX 差异：** - KNN-Shapley 将估值绑定到一个特定代理模型（KNN）。SCX 不依赖特定模型，而是使用状态划分的密度和一致性。 - KNN 距离在高维空间失效（curse of dimensionality），SCX 的状态空间可以通过降维 + 聚类自动构造。

---

#### A.1.4 CHG Shapley

- **论文：**Li et al., “CHG Shapley: Efficient Data Valuation and Selection towards Trustworthy Machine Learning”, 2024
- **链接：**<https://arxiv.org/abs/2406.11730>

**数学对象：**提出 Compound Hardness & Gradient (CHG) 效用函数，在每个 epoch 近似子集效用，Shapley 值有闭式解。

**改进：**相比 marginal contribution 方法有二次加速。适用于标签噪声检测和类别不平衡。

**SCX 差异：**CHG 仍然输出全局标量值。SCX 的 state-conditioning 能提供更细粒度的分析——例如在状态 A 中某个样本是噪声，在状态 B 中同一样本可能是关键样本。

---

#### A.1.5 Fast-DataShapley

- **论文：**“Fast-DataShapley: Neural Modeling for Training Data Valuation”, ACM WSDM 2026
- **链接：**<https://arxiv.org/abs/2506.05281>

**数学对象：**用加权最小二乘特征化 Shapley 值，训练一个一次可重用的解释器模型。不需要为新的测试样本重新估值。

**改进：**2 倍性能提升，训练加速两个数量级。

**SCX 差异：**Fast-DataShapley 加速了传统 Shapley 计算，但仍是**事后解释**——需要先训练好模型再估值。SCX 是**主动框架**，在训练/标注过程中决定哪些数据最有价值。

---

#### A.1.6 Asymmetric Data Shapley (ADS)

- 论文：“Rethinking Data Value: Asymmetric Data Shapley for Structure-Aware Valuation”, 2025
- 链接：<https://arxiv.org/abs/2511.12863>

**数学对象：**放松经典 Shapley 的对称公理，引入方向性/时序依赖（数据增广、联邦学习、多阶段微调）。

**改进：**保持效率性、线性性和集群对称性。

**SCX 差异：**ADS 的”asymmetric”是指样本之间的关系不对称（如 A 增广出 B 则 A 价值应大于 B）。SCX 的”state-conditioned”是指价值随状态变化——两个正交的改进方向，可以结合。

---

#### A.1.7 Geometric Data Valuation via Leverage Scores

- 论文：“Geometric Data Valuation via Leverage Scores”, 2025
- 链接：<https://arxiv.org/abs/2511.02100>

**数学对象：**非 Shapley 的几何替代方案，使用统计 leverage score。满足 dummy、efficiency 和 symmetry 公理。

**与 SCX 联系：**Leverage scores 本质上衡量了样本在特征空间中的”孤立度”——这近似于 SCX 中密度 (s) 的一个特例。但 SCX 的状态空间更丰富：不仅包含几何密度，还包含标签一致性、专家可靠性和可学习性。

**SCX 优势：**几何方法只用到特征空间的几何，忽略了标签信息、专家知识和噪声结构。

## A.2 Influence Function 方法

### A.2.1 经典 Influence Functions

- **原著：**Cook & Weisberg, “Residuals and Influence in Regression”, 1982
- **ML 引入：**Koh & Liang, “Understanding Black-box Predictions via Influence Functions”, ICML 2017
- **链接：**<https://arxiv.org/abs/1703.04730>

**数学对象：**通过 Hessian 矩阵追溯模型预测对训练样本的依赖：

$$I(x_i, x_{\text{test}}) = - \frac{\partial L(x_{\text{test}})}{\partial \theta}^T H_{\theta}^{-1} \frac{\partial L(x_i)}{\partial \theta}$$

**解决问题：**回答”删除这个训练点会如何改变测试点的预测？”

**与 SCX 的核心差异：**1. **单模型 vs 多专家：**Influence Functions 分析单一模型的训练数据影响；SCX 分析多个专家在状态上的可靠性。2. **局部 vs 全局：**IF 是逐样本-逐测试点的；SCX 是状态级的。3. **Hessian 计算：**IF 需要高效的 Hessian 逆近似 (LiSSA, CG)，对大型模型极其昂贵。

**SCX 相对优势：**- IF 无法处理多个专家之间的路由决策问题。- IF 的估值

是测试点依赖的（需要知道  $x_{\text{test}}$ ），SCX 的价值是状态依赖的（不需要特定的测试点）。- IF 对模型假设敏感（需要损失函数二阶可微、模型收敛到局部极小）。

---

### A.2.2 TRAK (Tracing with the Randomly-Projected After Kernel)

- 论文: Park et al., “TRAK: Attributing Model Behavior at Scale”, ICML 2023
- 链接: <https://arxiv.org/abs/2212.02522>
- 代码: <https://github.com/JD-ETH/trak>

**数学对象：**随机投影的 NTK（Neural Tangent Kernel）版本，将梯度投影到低维空间后计算影响：

$$(\mathbf{x}_i, \mathbf{x}) = (\mathbf{x}_i), \mathbf{M}^{-1}(\mathbf{x})$$

其中  $(\mathbf{x}_i) = \mathbf{J}_-(\mathbf{x}_i) \cdot \mathbf{P}$ ,  $\mathbf{P}$  是随机投影矩阵,  $\mathbf{M}$  是经验 NTK。

**改进：**比影响函数便宜 2-3 个数量级，可扩展到大型视觉和语言模型。

**SCX 差异：**TRAK 仍然是事后归因方法，不是主动数据选择框架。TRAK 估值依赖于训练好的模型和投影矩阵。SCX 不依赖训练好的模型——它基于状态划分和专家先验。

---

### A.2.3 D-TRAK

- 论文: Zheng et al., “Intriguing Properties of Data Attribution on Diffusion Models”, ICLR 2024
- 链接: <https://github.com/qwkkkkk/D-TRAK>

**数学对象：**TRAK 在扩散模型上的适配，对理论上不合理的设计选择在实践中表现出色。

**SCX 差异：**领域特定（扩散模型），不涉及状态条件化或多专家。

---

#### A.2.4 LoGra / LogIX

- 论文：Choe et al., “What is Your Data Worth to GPT? LLM-Scale Data Valuation with Influence Functions”, NeurIPS 2025
- 链接：<https://arxiv.org/abs/2405.13954>

**数学对象：**利用梯度的 Kronecker 乘积结构（类似 LoRA），将梯度投影复杂度从  $O(nk)$  降到  $O(\sqrt{nk})$ 。LoGra 算法 + LogIX 软件框架。

**改进：**针对 Llama3-8B 在 1B token 数据上实现最高 6500x 吞吐量提升，5x GPU 内存降低。

**SCX 差异：**LoGra 专注于让传统影响函数在 LLM 规模上可行，不改变影响函数的基本范式（单模型、事后归因、逐样本估值）。SCX 的 state-conditioned 视角在方法论上正交。

---

#### A.2.5 Generalized Group Data Attribution (GGDA)

- 论文：“Generalized Group Data Attribution”, 2024
- 链接：<https://arxiv.org/abs/2410.09940>

**数学对象：**将 TRAK/IF/TracIn 从单个训练点扩展到训练点组。10x-50x 加速，适用于数据剪枝和噪声标签识别。

**SCX 差异：**GGDA 的”组”是任意预定义的（如属于同一类的所有样本），而 SCX 的”状态”是通过误差/行为模式自动发现的语义结构。GGDA 的分组先验是人工给定的，SCX 的状态可以从数据中学习。

---

### A.3 LOO / 留出法

#### A.3.1 经典 Leave-One-Out 数学对象：

$$LOO\_i = v(D) - v(D_{-i})$$

即训练全部数据 vs 去掉样本  $i$  后的性能差异。

**问题：**-  $O(N)$  次重训练，实际不可行 - 在大数据集上 LOO 值普遍趋近于零（单个样本影响小） - 不满足公平性公理（副本值不为零）

#### A.3.2 Kairos

- 论文：“Kairos: Scalable Model-Agnostic Data Valuation”, 2025
- 链接：<https://arxiv.org/abs/2506.23799>

**数学对象：**基于 MMD 的 LOO 近似，不需要重训练，支持在线增量更新  $O(mN)$ 。误差  $O(1/N^2)$ ，比 Data Shapley 快 50 倍。

**SCX 差异：**Kairos 仍是逐样本标量估值，不提供状态条件化或多专家路由能力。

---

## A.4 pyDVL 生态

- 项目: <https://github.com/aai-institute/pyDVL>
- 文档: <https://pydvl.org>
- 版本: v0.10.0 (2024)

**实现功能:** - Shapley 值 (精确、MC 排列、截断、群测试、class-wise) - Banzhaf 指数 (含 MSR Banzhaf) - Beta Shapley 等半值 - Least Core (精确和 MC) - LOO、Data-OOB、KNN Shapley、Owen 采样 - 影响函数 (DirectInfluence、CG、Block CG、LiSSA、Arnoldi、EKFAC、Nystrom、DataInf)

**与 SCX 的关系:** pyDVL 是目前最完整的开源数据估值工具库，但它是一个库——不是方法论。SCX 可以使用 **pyDVL** 作为子模块来计算某些组件 (如状态内的价值排序)，但 pyDVL 本身不提供状态划分、多专家路由或 state-wise acquisition。

---

## B. LLM 数据选择

### B.1 DataComp-LM (DCLM)

- 论文: “DataComp-LM: In search of the next generation of training sets for language models”, NeurIPS 2024
- 链接: <https://arxiv.org/abs/2406.11794>
- 网站: <https://datacomp.ai/dclm/>

**解决问题:** 为语言模型训练提供标准化的数据策展 benchmark——固定训练代码和预算，让参与者比拼数据策展策略。

**核心发现:** 基于模型的过滤 (model-based filtering) 对高质量训练集构建至

关重要。DCLM-Baseline (7B) 在 MMLU 上达到 64%，用 2.6T token 匹配 Mistral-7B (63%) 和 Llama 3 8B (66%)，但计算量减少 6.6 倍。

**与 SCX 的关系：**DCLM 是 benchmark 平台，不是数据选择算法本身。但其核心发现——**数据质量的重要性超过模型架构**——恰恰支持了 SCX 的假设。SCX 可以作为一种”智能数据策展策略”参与 DCLM 的过滤 track。DCLM 的 53 个下游评估任务可作为 SCX 状态划分效果的大规模验证平台。

**SCX 差异与优势：** - DCLM 研究的是预训练数据选择（海量 web 文本过滤）；SCX 主要针对微调/下游任务（指令数据选择、主动学习采样）- DCLM 的方法（perplexity 过滤、heuristic 过滤）是**无监督的**；SCX 利用**监督信号**（专家误差、标签一致性）- SCX 的状态划分可能比 DCLM 的简单过滤更精细化——不仅过滤掉”坏”数据，还识别”什么状态下需要什么类型的数据”

---

## B.2 LESS (Low-rank gradiEnt Similarity Search)

- 论文：Xia et al., “LESS: Selecting Influential Data for Targeted Instruction Tuning”, ICML 2024
- 链接：<https://arxiv.org/abs/2402.04333>
- 代码：<https://github.com/princeton-nlp/LESS>

**解决问题：**针对目标能力（如推理、翻译）从大规模指令数据中选出最相关的微调样本。

**数学对象：**1. 在部分数据上训练小 LoRA adapter → 计算 Adam LoRA 梯度特征 → 构建梯度数据存储 2. 对目标任务（少量验证集）计算梯度特征 → 通过内积/余弦相似度选择最相似训练样本 3. 关键适配：使影响函数与

Adam 优化器和变长指令数据兼容

**关键结果：** - 5% 的 LESS 筛选数据往往优于全部数据 - 小模型（LLaMA-2-7B）选的数据可迁移到大模型（LLaMA-2-13B, MISTRAL-7B） - 优于随机选择 2-5 个百分点（MMLU, TyDiQA, BBH）

**计算约束分析**（后续工作，arXiv:2410.16208）： - 固定训练预算：LESS 和 perplexity 方法最优 - 固定总计算预算（含选择成本）：BM25 和 embedding 方法在 7B-13B 规模更优 - 70B 规模：LESS 最优（选择成本被训练成本摊销）

**与 SCX 的核心差异：** 1. **梯度空间 vs 状态空间：** LESS 在梯度空间做相似性匹配；SCX 在语义/状态空间做划分。梯度空间维度高且解释性差，状态空间可解释且稳定。 2. **单验证集 vs 多状态：** LESS 的目标是从一个验证任务出发筛选数据；SCX 可以同时处理多个状态（即多个子任务/模式）。 3. **专家的缺失：** LESS 只用一个小模型计算梯度相似性；SCX 利用多个专家的（先验）可靠性。

**SCX 相对优势：** - LESS 不能区分”高误差是因为样本困难”还是”高误差是因为样本噪声”——这是 SCX 通过状态内一致性  $C(s)$  解决的问题。 - LESS 需要预训练 LoRA adapter 来计算梯度，SCX 的状态划分可以来自先验知识（如材料科学中的键类型）或聚类。 - LESS 的验证集假设（有少量目标任务数据）在某些场景不成立；SCX 的 state-value 可以完全无验证集（通过  $\bar{r}(s) \cdot (s) \cdot L(s) \cdot [1-D(s)]$  自动发现高价值状态）。

---

### B.3 S2L (SmallToLarge)

- **论文：** Yang et al., “SmallToLarge (S2L): Scalable Data Selection for Fine-tuning Large Language Models by Summarizing Training Trajec-

tories of Small Models”, NeurIPS 2024

- 链接: <https://arxiv.org/abs/2403.07384>
- 代码: <https://github.com/BigML-CS-UCLA/S2L>

**解决问题：**用比目标模型小 40-100 倍的小模型训练轨迹来指导大模型的数据选择。

**数学对象：**1. 在全部数据上训练小模型（如 Pythia-70M）2. 记录每个样本在多个 checkpoint 上的 loss → 构建 loss 轨迹向量 3. K-means 聚类（~100 簇）→ 从每簇均匀采样

**关键结果：**- 11% MathInstruct 数据匹配全数据性能 - 比之前方法平均高 4.7%（6 个评测集）- MATH 上 50K 筛选数据提升 Phi-2 达 16.6%

**理论基础：**同一 loss 轨迹簇内的样本具有类似梯度 → S2L 子集与全数据集有有界梯度误差。

**与 SCX 的核心差异：**1. 代理模型 vs 状态划分：S2L 用小模型 loss 轨迹聚类，需要先训练一个小模型。SCX 的状态划分可以用无监督方法（描述符 + 聚类）不需要训练。2. 单轨迹 vs 多专家：S2L 只用一个代理模型，不利用专家多样性。SCX 天然多专家。3. 均匀采样 vs 价值排序：S2L 在簇内均匀随机采样；SCX 在每个状态内按价值排序后选择。

**SCX 相对优势：**- S2L 不能处理噪声样本问题——loss 轨迹高的样本既有可能是困难样本也有可能是噪声；SCX 通过噪声分数明确区分。- S2L 不能利用领域先验（如材料科学中已知的键合状态）；SCX 的状态空间可以融合先验知识。- S2L 的 K-means 聚类需要预先指定 K 值（~100），SCX 的状态数量可以自适应。

---

## B.4 大规模指令微调数据筛选的其它进展

### B.4.1 InstructMining

- 论文: Cao et al., 2024
- 概述: 自动筛选优质指令遵循数据

### B.4.2 “Maybe Only 0.5% Data is Needed”

- 论文: Chen et al., 2023/2024
- 概述: 极小的高质量子集可能就足够了

### B.4.3 “Rethinking Data Selection at Scale: Random Selection is Almost All You Need”

- 论文: 2024
- 核心发现: 大规模下随机选择意外地有竞争力; 多样性可能比质量更重要

### B.4.4 “A Critical Look at Targeted Instruction Selection” (Nayak et al., 2025)

- 链接: <https://arxiv.org/abs/2602.14696>
- 核心发现: 梯度表示 (LESS 风格) 最具预测力; 贪心 round-robin 在低预算最优, optimal transport 在高预算最优; 随机在足够大规模下仍然强

### B.4.5 综述论文

- “A Survey on Data Selection for LLM Instruction Tuning” (Wang et al., JAIR 2025)
- “Unleashing the Power of Data Tsunami” (Qin et al., TMLR 2024)
- 链接: <https://arxiv.org/abs/2408.02085>

均将方法分为三类：**基于质量**（困惑度、IFD 分数、GPT 评分）、**基于多样性**（词汇多样性、k-center 贪心、聚类）、**基于重要性**（不确定性、loss 梯度、误差）。

**SCX 补全的视角：**所有现有方法都只考虑数据本身的质量/多样性，没有考虑当前模型的状态和专家的条件可靠性。SCX 的三因素价值公式（误差 + 密度 + 可学习性）是首个同时考虑这三个维度的统一框架。

---

## C. Active Learning

### C.1 DP-GEN (Deep Potential Generator)

- 原始论文: Zhang et al., Phys. Rev. Materials 3, 023804 (2019)
- 文档: <https://deepwiki.com/deepmodeling/dpgen/>
- 代码: <https://github.com/deepmodeling/dpgen>

**解决问题：**为 Deep Potential 分子动力学模拟自动产生高质量训练数据（DFT 标签）。

**数学对象：**训练 4 个独立初始化的 DeePMD 模型 ensemble → 计算模型偏差（Model Deviation）作为不确定性：

$$\hat{f}_{\max} = \max_i \sqrt{\|f_i - \bar{f}\|^2}$$

基于信任阈值 (trust level) 选择候选结构:  $\_f \in [\text{lower}, \text{upper}] \rightarrow$  选入;  $\_f < \text{lower} \rightarrow$  丢弃 (已准确);  $\_f > \text{upper} \rightarrow$  丢弃 (太远)。

与 SCX 的核心差异: 1. **Ensemble vs 状态**: DP-GEN 用多模型 ensemble 的不一致性衡量不确定性; SCX 用状态划分 + 专家可靠性 + 内部一致性。2. **统一阈值 vs 状态条件**: DP-GEN 对全局使用统一信任阈值 (如 0.12 eV/A); SCX 的”阈值”是状态条件的——不同状态有不同的接受标准 (因为不同状态的内在噪声水平不同)。3. **Exploration 驱动 vs 缺陷驱动**: DP-GEN 选 ensemble 不一致的区域 (exploration); SCX 选高误差 - 高密度 - 高一致性的区域 (缺陷驱动)。

**SCX 相对优势**: - DP-GEN 不能区分”模型 ensemble 不一致是因为缺乏数据”还是”因为该区域固有噪声高”。SCX 通过状态内部一致性  $C(s)$  做区分。- DP-GEN 需要训练 4 个模型同时推理, 计算开销大。SCX 的状态划分只需要一次聚类。- DP-GEN 的信任阈值是超参数 (人工调整)。SCX 的状态价值是自动计算的。

---

## C.2 MTP / MLIP-3 — Extrapolation Grade + D-Optimality

- **工具**: MLIP-2 / MLIP-3 (<https://gitlab.com/ashapeev/mlip-2>)
- **方法**: Shapeev, “Moment Tensor Potentials”, 2016

**解决问题**: 为 Moment Tensor Potential (MTP) 的主动学习选择最需要 DFT 标注的新配置。

**数学对象**: 1. **Extrapolation Grade (cfg)**: 对线性 MTP,  $(\text{cfg}) = \max_j |c_j|$ , 其中  $c = (b \dots b_m) \cdot A^{-1}$ ,  $A$  是当前 active set 的信息矩阵。若  $> 1$ , 该配置是外推的 (超出当前训练域)。2. **D-Optimality (MaxVol)**: 从候选集中选择使信息矩阵行列式最大化的一组配置。

**工作流：**MD 模拟中若  $\epsilon > \epsilon_{\text{th}}$ （通常 10），采样所有  $\epsilon > 1$  的配置  $\rightarrow$  D-optimality 选子集  $\rightarrow$  DFT 标注  $\rightarrow$  重训练。

**与 SCX 的核心差异：**1. **线性近似 vs 非线性状态：**MTP 的 extrapolation grade 基于线性模型（或线性化的非线性模型）的凸包。SCX 可以处理任意非线性的状态空间。2. **几何 vs 语义：**D-optimality 是纯几何准则（最大线性独立），不考虑标签信息。SCX 的状态同时基于特征（描述符）和误差分布。3. **单专家 vs 多专家：**MTP 自发主动学习只涉及一个模型。SCX 天然处理多个专家。

**SCX 相对优势：**- D-optimality 只关注特征空间的几何边界（extrapolation），可能遗漏内插区域的”误差热点”（如相界附近描述符平滑但能量跳变）。SCX 通过  $\bar{r}(s)$  直接感知误差。- D-optimality 不能区分噪声和外推区域。SCX 明确区分噪声（ $N(s)$ ）和可学习困难（ $L(s)$ ）。- 近期改进方向（Clustering-enhanced local D-optimality, 2025）试图解决 D-optimality 对稀有机会的遗漏——这正好是 SCX 状态划分擅长的问题。

---

### C.3 DIRECT Sampling (DIimensionality-Reduced Encoded Clusters with sTratified)

- **论文：**“DIimensionality-Reduced Encoded Clusters with sTratified (DIRECT) sampling”, Nature, 2024
- **链接：**<https://www.nature.com/articles/s41524-024-01227-4>

**解决问题：**为 MLIP（机器学习势函数）选择代表性训练数据，减少冗余、保持多样性。

**数学对象：**1. 将原子环境编码为低维表示 2. 对编码后的表示进行聚类 3. 从每个簇分层采样（stratified sampling）

**与 SCX 的关系：**DIRECT 的流程（降维 → 聚类 → 分层采样）与 SCX 的”状态划分”思想高度相似。

**核心差异：**1. **纯多样性 vs 误差感知：**DIRECT 只基于描述符空间的距离/密度，不感知模型误差。每个簇中均匀采样，不考虑哪个簇误差更高。SCX 用  $\bar{r}(s)$  自动识别高误差状态。2. **静态 vs 迭代：**DIRECT 是一次性的数据选择。SCX 是迭代主动学习框架——训练 → 评估价值 → 采集 → 再训练。3. **无专家 vs 多专家：**DIRECT 不利用专家信息。

**SCX 优势：**DIRECT 是一个优秀的”多样性基线”方法，可以被集成到 SCX 框架中作为状态划分的候选方法。但 SCX 的误差感知价值函数使它比 DIRECT 更高效——DIRECT 可能为已经准确的区域浪费标注资源。

---

#### C.4 DIRECT: Deep Active Learning under Imbalance and Label Noise

- **论文：**Zhang et al., “DIRECT: Deep Active Learning under Imbalance and Label Noise”, 2024
- **链接：**<https://arxiv.org/abs/2312.09196>

**解决问题：**在类别不平衡和标签噪声下的深度主动学习。

**数学对象：**将多类主动学习降维为一系列一维阈值学习问题。通过降维将模型高维输出映射到 1D 分数空间，识别最优分离阈值来选择有信息量的、类别平衡的样本。

**改进：**比 SOTA 主动学习节省 >60% 标注量，支持批量标注，对标签噪声鲁棒。

**SCX 差异：**这个 DIRECT 是分类任务的主动学习方法，依赖 softmax 输

出概率。SCX 可以处理回归任务（如力场拟合）和分类任务。SCX 的噪声处理更一般（不限于标签噪声，还包含状态内不一致性）。

---

## C.5 QActor — Noise-Aware Active Sampling

- 论文: Ghiassi et al., “QActor: On-line Active Learning for Noisy Labeled Stream Data”, ACML 2021
- 链接: <https://arxiv.org/abs/2001.10399>

**解决问题：**在流式数据场景中，既有噪声标签又有有限标注预算。

**数学对象：**结合两种策略：1. 质量模型（Quality Model）：选择看起来干净的样本 2. 主动查询（Active Querying）：用标注预算向 oracle 询问最具信息量的样本

在噪声率 30%-80% 的数据集上实现接近无噪声训练的精度，最多只需 6% 额外查询。

**SCX 差异：**- QActor 的”质量”是全局的（干净 vs 不干净），不区分类别或状态。- SCX 的状态条件噪声分数 ( $\text{NoiseScore}(x_i) = r_i \cdot (1/(s_i) + [1 - C(s_i)])$ ) 可以区分”高误差但可学习”和”高误差且噪声”。- QActor 面向流式数据，SCX 面向静态池 + 迭代获取。

---

D. 竞争格局总结

D.1 四象限定位图（文本描述）

|      | 全局/固定          | 状态条件             |
|------|----------------|------------------|
| 数据估值 | Data Shapley   |                  |
|      | TMC-Shapley    | SCX              |
|      | KNN-Shapley    | (本工作)            |
|      | Influence Func |                  |
|      | TRAK / LoGra   |                  |
| 数据选择 | LESS (梯度相似)    |                  |
|      | S2L (loss轨迹)   | EGP(误差分区)        |
|      | DCLM (过滤)      | DIRECT(聚类)       |
|      | InstructMining | DP-GEN(ensemble) |
|      | Random         | MTP D-opt        |

解释：- 右上象限：只有 SCX 同时做到了” 状态条件” 和” 数据价值” 的统一。EGP 不涉及数据估值，DIRECT 和 MTP 的 D-optimality 不涉及多专家路由，DP-GEN 不进行状态划分。- 左下象限：大部分现有工作（Data Shapley、Influence Functions、LESS、S2L）都在这个象限——它们都是全局/固定的。

D.2 各方法覆盖的功能矩阵

| 方法           | 数据估值 | 数据选择 | 多专家 | 状态条件 | 噪声检测 | 可学习性 |
|--------------|------|------|-----|------|------|------|
| Data Shapley | Y    | Y    | N   | N    | N    | N    |

| 方法             | 数据估值     | 数据选择     | 多专家         | 状态条件     | 噪声检测     | 可学习性     |
|----------------|----------|----------|-------------|----------|----------|----------|
| TMC-Shapley    | Y        | Y        | N           | N        | N        | N        |
| KNN-Shapley    | Y        | Y        | N           | N        | N        | N        |
| CHG Shapley    | Y        | Y        | N           | N        | Partial  | N        |
| Influence Func | Y        | Y        | N           | N        | N        | N        |
| TRAK           | Y        | Y        | N           | N        | N        | N        |
| LoGra/LogIX    | Y        | Y        | N           | N        | N        | N        |
| LESS           | N        | Y        | N           | N        | N        | N        |
| S2L            | N        | Y        | N           | N        | N        | N        |
| DCLM           | N        | Y        | N           | N        | N        | N        |
| DP-GEN         | N        | Y        | Y(ensemble) | N        | N        | N        |
| MTP D-opt      | N        | Y        | N           | N        | N        | N        |
| DIRECT(Nature) | N        | Y        | N           | Y(聚类)    | N        | N        |
| QActor         | N        | Y        | N           | N        | Y(标签)    | N        |
| <b>SCX</b>     | <b>Y</b> | <b>Y</b> | <b>Y</b>    | <b>Y</b> | <b>Y</b> | <b>Y</b> |

SCX 是唯一在所有列都覆盖的方法。

### D.3 计算复杂度比较

| 方法                | 推理复杂度                                 | 训练复杂度                          | 扩展性        |
|-------------------|---------------------------------------|--------------------------------|------------|
| Data Shapley (MC) | $O(N^2 \times \text{train})$          | N/A                            | 差 (<10 样本) |
| KNN-Shapley       | $O(n \log n)$                         | $O(n)$                         | 好 (代理模型)   |
| TRAK              | $O(N \times d \times k)$              | $O(dk^2)$                      | 好          |
| LoGra             | $O(N \times \sqrt{(dk)})$             | $O(\sqrt{(dk)})$               | 很好         |
| LESS              | $O(N \times d \times n_{\text{val}})$ | $O(d \times n_{\text{train}})$ | 中等         |
| S2L               | $O(N \times T) + \text{K-means}$      | $O(T \times n_{\text{small}})$ | 好          |

| 方法         | 推理复杂度                                          | 训练复杂度                                              | 扩展性                   |
|------------|------------------------------------------------|----------------------------------------------------|-----------------------|
| DP-GEN     | $O(4 \times N \times \text{fwd})$              | $O(4 \times \text{train})$                         | 中等 (4 model ensemble) |
| MTP D-opt  | $O(N \times d^2)$                              | $O(N \times d^2)$                                  | 好                     |
| <b>SCX</b> | <b><math>O(N \times d + K \times N)</math></b> | <b><math>O(N \times d + K\text{-means})</math></b> | <b>好</b>              |

SCX 的计算主要来自三部分：描述符计算  $O(N \times d)$ 、状态划分  $O(N \times d + K\text{-means})$ 、状态价值计算  $O(K \times M)$ 。没有模型重训练开销，非常适合大规模问题。

## E. SCX 的独特定位

### E.1 SCX 的 state-conditioned 视角填补了什么空白？

SCX 填补了机器学习四个基本问题的交叉空白：

#### 空白 1：数据价值的条件性

现有数据估值方法（Data Shapley、Influence Functions、LOO）都假设数据的“价值”是其固有属性——同一个样本在所有情境下都有相同的价值。SCX 的 Proposition 1 证明这是错的：一个样本在状态  $s$  可能是关键数据，在状态  $s$  可能是冗余数据。价值是**状态条件**的。

这与直觉一致：一个训练好的回归器在密集区域不需要更多数据，但在稀疏或高误差区域需要。现有方法无法表达这个简单直觉。

#### 空白 2：专家可靠性的局部性

现有多专家系统（MoE、集成模型）假设每个专家有一个全局“能力分数”

或权重。SCX 证明 (Proposition 1 和 3)：专家 A 可能在状态  $s$  优于专家 B，但在状态  $s$  劣于专家 B。因此专家选择必须状态条件化。

这与材料 MLIP 的实际经验一致：一个在体相材料上训练的势函数可能在表面、缺陷或相界面处完全失效——不是“不好的模型”，而是在那些状态上不适用。

### 空白 3：噪声与困难样本的混淆

现有主动学习方法 (max-residual、uncertainty sampling) 都假设高误差/高不确定性的样本最有价值。SCX 的 Proposition 2 证明：高误差集合  $H = H_{\text{learnable}} \cup H_{\text{noise}}$ 。对噪声采样浪费标注预算。必须区分“可学习困难的样本”和“固有噪声的样本”。

SCX 通过状态内一致性做区分：- 高误差 + 高密度 + 高一致性  $\rightarrow$  可学习困难 (宝贵) - 高误差 + 低密度 + 低一致性  $\rightarrow$  噪声 (应丢弃/降权)

### 空白 4：统一框架

Data Shapley (估值)、LESS/S2L (LLM 数据选择)、DP-GEN/D-opt (主动学习)、QActor (噪声感知) 这四个社区通常各自独立发展。SCX 用一个统一的数学框架 (条件风险 + 状态划分 + 专家路由) 涵盖了所有四个维度。

## E.2 为什么现有方法无法直接替代 SCX?

**不能替代的理由 1：全局无法表达局部** Data Shapley、Influence Functions、LESS、S2L、TRAK 都输出全局分数/选择。如果配置空间存在非均匀的误差分布 (MLIP 的核心假设)，全局方法必然次优。SCX 的状态划分是解决这个问题的必要机制。

**不能替代的理由 2：监督信号未被利用** DCLM、DIRECT、D-optimality 只用到了**特征空间的结构**（perplexity、距离、密度），没有用到模型误差、标签一致性或专家可靠性。SCX 的估值公式  $\bar{r}(s) \cdot (s) \cdot L(s) \cdot [1 - D(s)]$  同时利用了特征结构（ ）和监督信号（ $\bar{r}$ ,  $L$ ,  $SCX\_m$ ）。

**不能替代的理由 3：多专家未被整合** Data Shapley、LESS、S2L、DP-GEN 都只有一个模型/代理。DP-GEN 的 ensemble 是**多个相同模型**（随机种子不同），不是**不同领域的专家**。SCX 的路由框架可以处理真正异构的专家集合（如 MACE + NEP + ACE 不同类型的势函数）。

**不能替代的理由 4：噪声处理不足**

- Data Shapley 和 Influence Functions 没有噪声模型
- LESS 和 S2L 不区分高误差的来源
- DP-GEN 将 ensemble 不一致全部当作”需要数据”而不是”潜在噪声”
- MTP 的 D-optimality 只关注几何外推

SCX 是唯一在理论层面明确区分”噪声”和”可学习困难”的方法（Proposition 2 及其证明）。

**不能替代的理由 5：没有路由** SCX 的 expert routing 是其独特组件——不仅选择”要标注什么数据”，还决定”由哪个/哪些专家来标注/预测”。这在 MoE 和联邦学习等场景具有独立价值。

### E.3 与最接近方法的逐一对比

**最接近方法：S2L** - 共同点：都使用聚类划分数据空间，从各类中选代表点  
- 差异：S2L 不知道各类的误差有多大，在每类中均匀采样；SCX 知道各类

的误差，优先采样高误差类 - 差距：S2L 需要先训练小模型 → 需要 4-7 天；SCX 可以零训练启动（描述符聚类）

**最接近方法：LESS** - 共同点：都使用”相似性”筛选数据 - 差异：LESS 在梯度空间做相似性（计算昂贵），SCX 在状态空间做划分 - 差距：LESS 不能处理多专家，不能区分噪声

**最接近方法：DP-GEN** - 共同点：都是迭代主动学习，都基于当前模型的不足选择数据 - 差异：DP-GEN 用 ensemble 不确定性（需要多模型同步），SCX 用状态划分 + 误差估计 - 差距：DP-GEN 不能区分噪声，不能利用领域先验

**最接近方法：DIRECT (Nature 2024)** - 共同点：都使用降维 + 聚类划分配置空间 - 差异：DIRECT 静态一次选择，不感知误差；SCX 迭代 + 误差感知 - 差距：DIRECT 是全流程相似，但缺了 SCX 的价值函数和迭代机制

#### E.4 SCX 的潜在弱点

1. **状态划分质量依赖**：如果状态划分方法（聚类/描述符）不好，后续所有步骤都受影响。需要鲁棒的自动状态发现。
2. **专家先验可用性**：SCX 的多专家优势需要至少有 2 个可用专家（或一个能分解的专家）。单模型场景下部分功能退化。
3. **小样本状态**：当某个状态内样本数太少时，条件风险  $R_m(s)$  和可学习性  $L(s)$  的估计不可靠。需要贝叶斯平滑。
4. **状态演化的处理**：随着新数据的加入，状态边界可能变化。需要增量/在线状态更新机制。
5. **计算复杂度**：相比最简单的随机采样或 heuristic 过滤，SCX 的聚类 + 估值计算开销仍然较高。

E.5 差异化战略总结

| SCX 特性               | 不可替代性级别 | 说明                       |
|----------------------|---------|--------------------------|
| State-conditioned 价值 |         | 全局方法无法表达状态特定的价值          |
| 噪声 vs 困难的区分          |         | 没有其他方法能在理论上做此区分          |
| 多专家路由                |         | 需要有多专家可用场景（材料 MLIP 天然成立） |
| 无训练启动                |         | 只需描述符 + 聚类，比需要训练的方法便宜    |
| 统一框架                 |         | 学术价值高，单一场景不一定需要所有功能      |

7. 参考文献

Data Valuation

1. Ghorbani & Zou, “Data Shapley: Equitable Valuation of Data for Machine Learning”, ICML 2019. <https://arxiv.org/abs/1904.02868>

2. Jia et al., “Towards Efficient Data Valuation Based on the Shapley Value”, AISTATS 2019. <https://arxiv.org/abs/1902.10275>

3. Li et al., “CHG Shapley: Efficient Data Valuation and Selection”, 2024. <https://arxiv.org/abs/2406.11730>

4. “Fast-DataShapley: Neural Modeling for Training Data Valuation”, 2025. <https://arxiv.org/abs/2506.05281>

5. “Asymmetric Data Shapley for Structure-Aware Valuation”, 2025. <https://arxiv.org/abs/2511.12863>

6. “Geometric Data Valuation via Leverage Scores”, 2025. <https://arxiv.org/abs/2511.02100>

7. “Faithful Group Shapley Value”, NeurIPS 2025. <https://neurips.cc/virtual/2025/san-diego/poster/115078>

8. Park et al., “TRAK: Attributing Model Behavior at Scale”, ICML 2023. <https://arxiv.org/abs/2212.02522>
9. Zheng et al., “D-TRAK: Intriguing Properties of Data Attribution on Diffusion Models”, ICLR 2024. <https://github.com/qwkkkkk/D-TRAK>
10. Choe et al., “What is Your Data Worth to GPT? LLM-Scale Data Valuation with Influence Functions”, NeurIPS 2025. <https://arxiv.org/abs/2405.13954>
11. “Generalized Group Data Attribution”, 2024. <https://arxiv.org/abs/2410.09940>
12. “Kairos: Scalable Model-Agnostic Data Valuation”, 2025. <https://arxiv.org/abs/2506.23799>

## LLM Data Selection

13. “DataComp-LM: In search of the next generation of training sets for language models”, NeurIPS 2024. <https://arxiv.org/abs/2406.11794>
14. Xia et al., “LESS: Selecting Influential Data for Targeted Instruction Tuning”, ICML 2024. <https://arxiv.org/abs/2402.04333>
15. Yang et al., “SmallToLarge (S2L): Scalable Data Selection for Fine-tuning LLMs”, NeurIPS 2024. <https://arxiv.org/abs/2403.07384>
16. Qin et al., “Unleashing the Power of Data Tsunami: A Survey on Data Assessment and Selection for Instruction Tuning”, TMLR 2024. <https://arxiv.org/abs/2408.02085>
17. Nayak et al., “A Critical Look at Targeted Instruction Selection”, 2025. <https://arxiv.org/abs/2602.14696>
18. Wang et al., “A Survey on Data Selection for LLM Instruction Tuning”, JAIR 2025.

## Active Learning

19. Zhang et al., “DP-GEN: Deep Potential Generator”, Phys. Rev. Materials 3, 023804 (2019). <https://github.com/deepmodeling/dpgen>
20. Shapeev, “Moment Tensor Potentials”, 2016. <https://gitlab.com/ashapeev/mlip-2>
21. “DIRECT: DIimensionality-Reduced Encoded Clusters with sTratified Sampling”, Nature 2024. <https://www.nature.com/articles/s41524-024-01227-4>
22. Zhang et al., “DIRECT: Deep Active Learning under Imbalance and Label Noise”, 2024. <https://arxiv.org/abs/2312.09196>
23. Ghiassi et al., “QActor: On-line Active Learning for Noisy Labeled Stream Data”, ACML 2021. <https://arxiv.org/abs/2001.10399>

## Tools

24. pyDVL (Python Data Valuation Library). <https://github.com/aai-institute/pyDVL> — v0.10.0, 2024
25. LogIX / LoGra. <https://github.com/sangkeuncho/LogIX> — 2024