

SCX/EGP 竞争分析报告：MoE 架构、蒸馏与专家治理

生成时间：2026-06-25

覆盖范围：2023-2026 年最新文献，涵盖 Mixture-of-Experts (MoE)、Knowledge Distillation (KD)、模型合并、MLIP gauge 对齐，以及专家治理 (Expert Governance) 四大方向。

目标：评估每一项工作与 SCX/EGP 框架的关系，定位 SCX/EGP 的差异化优势及未被占领的技术空白。

目录

1. A. Mixture of Experts (MoE) in MLIP
 2. B. Knowledge Distillation for MLIP
 3. C. Expert Merging / Gauge / Energy Alignment
 4. D. Expert Compilation / Governance (SCX 核心创新区)
 5. E. 竞争格局总结与战略建议
-

A. Mixture of Experts (MoE) in MLIP

A1. DeepMD MoE/MoLE — “Scaling MLIP with Mixtures of Experts”

论文：Liu, Zhang, Peng, E, Zhang, Wang. “Scaling Machine Learning Interatomic Potentials with Mixtures of Experts.” arXiv:2603.07977 (2026).

他们解决了什么？将 MoE 架构系统性地引入 MLIP 领域。此前 MoE 在 NLP 和 CV 中已取得巨大成功，但面向原子间势函数的 MoE 架构设计（路由策略、专家结构、稀疏激活）缺乏系统研究。

核心方法：- 提出了两种架构变体：**MoLE (Mixture-of-Linear-Experts)** 和 **MoE (非线性 MLP 专家)**。- 设计三种路由策略对比：**逐元素路由** (element-wise routing) vs. **构型级路由** (configuration-level routing) vs. **全局 MoE 路由**。- 引入**共享专家 (shared expert)** 机制增强泛化。- 经由 DeepMD-kit 框架实现，基于 DP 模型架构扩展。

关键发现：- **逐元素路由 (E(3) equivariant routing)** 显著优于构型级路由，全局 MoE 路由常导致数值不稳定。- 非线性 MoE + 共享专家组合效果最优，超越 MoLE。- 路由模式呈现**化学可解释的专家分工**：不同专家倾向于处理特定元素族（与周期表趋势一致）。- 在 OMol25、OMat24、OC20M 基准上达到 SOTA。

与 SCX/EGP 的关系：- **强相关**。DeepMD MoE 是目前与 SCX/EGP 最直接的竞争方法。- 二者都使用 MoE 思想来提升势函数精度。区别在于：DeepMD MoE 在**训练时**构建 MoE 架构（端到端训练一个模型），而 SCX/EGP 是**后训练**方式——将多个独立训练的专家模型编译为联合系统。- DeepMD MoE 的专家是在训练中自动形成的（emergent expertise），而 SCX/EGP 的专家是独立训练的（pre-defined expertise）。

SCX 相对优势：- **灵活性**：SCX/EGP 可以组合任意来源的独立训练模型

(不同架构、不同训练集、不同超参数)，而 DeepMD MoE 所有专家必须在同一框架下端到端训练。- **可扩展性**：EGP 的专家可以是异构的 (MACE + NEP + SevenNet)，DeepMD MoE 的所有专家必须是同构的 DP 架构。- **增量更新**：EGP 可以随时加入新模型而无需重训，DeepMD MoE 需要整体重训。

空白填补机会：- DeepMD MoE 未讨论**专家选择的可解释性**——SCX/EGP 的输入条件路由可以明确解释”对给定结构，为何选择某专家”。- DeepMD MoE 没有蒸馏流程——SCX/EGP 的蒸馏环节可与 MoE 结合形成”MoE 预编译 + 蒸馏”流水线。

A2. Allegro/NequIP MoE — Spatial Partition + Co-training Agreement

论文：Nascimento et al. “Mixture of Experts Framework in Machine Learning Interatomic Potentials for Atomistic Simulations.” arXiv:2604.26143 (2026).

他们解决了什么？解决了**空间分区 MoE** 中的关键问题：不同复杂度模型在界面处的力学失配 (artificial stress fields)，以及高频模型在局部区域带来的计算瓶颈。

核心方法：- 基于 E(3)-equivariant **Allegro** 架构构建多保真 MoE 框架。- **空间分区 (Spatial Partitioning)**：将模拟域分为化学复杂区域（如催化反应界面）和简单区域（如体相晶格），分配不同保真度的模型。- **协同训练 (Co-training)**：损失函数包含**一致性约束 (agreement constraints)**——对共享体相环境的逐原子能量和力差异施加惩罚，迫使不同专家学习一致的体相物理描述。- **验证体系**：Pt+CO 催化系统。

结果：- 精确能量守恒 (exact energy conservation maintained) - 体相力学

响应（EOS、体模量）在专家间对齐 - 预测精度与全高保真模拟相当 - 计算速度提升超过 2 倍

与 SCX/EGP 的关系： - 互补关系。该工作解决的是空间分区问题（不同区域用不同模型），SCX/EGP 解决的是输入条件路由问题（不同条件用不同模型）。 - 二者的共识在于：单一模型不足以覆盖所有场景，需要多个专家协作。 - 该工作的”一致性约束”思想与 SCX/EGP 的”Gauge 对称化”有关联——都试图使多个模型在重叠区域保持一致预测。

SCX 相对优势： - SCX/EGP 不依赖空间分区假设，因此适用于非局域问题（如长程相互作用、全局结构变化），而空间分区 MoE 仅适用于可划分的体系。 - SCX/EGP 的专家数量不受空间维度限制，可扩展到任意多专家。

空白填补机会： - 该工作的”一致性约束”需要通过额外训练来实现；SCX/EGP 可以在不重训的情况下实现专家间一致性（通过校准层的后处理）。 - 空间分区与输入条件路由可以结合——例如在界面上同时使用两种策略。

A3. 通用 MoE — Shazeer et al. 2017, Switch Transformer

论文： - Shazeer et al. “Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer.” ICLR 2017. - Fedus, Zoph & Shazeer. “Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity.” JMLR 2022.

他们解决了什么？ Shazeer 2017 提出了稀疏门控 MoE 层的核心架构：通过一个可学习的门控网络将每个输入路由到 top-k 个专家（子网络），实现”总参数量巨大但计算量恒定”的效果。Switch Transformer 将其简化为 top-1 路由，显著降低了通信和计算开销。

核心方法： - **Noisy Top-K Gating**：在门控 logits 上加噪声后取 top-k，实现稀疏激活。 - **辅助负载均衡损失（Switch Transformer）**：通过不同化的负载均衡损失避免“富者愈富”（少数专家支配大部分输入）问题。 - **容量因子（Capacity Factor）**：控制每个专家处理的 token 数上限。 - **训练稳定技巧**：选择性精度（router 用 float32）、更小的初始化、专家 dropout。

影响：直接催生了 Mixtral 8x7B、DeepSeek-V2/V3、Llama 4 等现代 MoE LLM。

与 SCX/EGP 的关系： - **理论基础关系**。这些工作奠定了 MoE 路由、负载均衡的理论基础。SCX/EGP 的“输入条件路由”本质上是同一问题在势函数领域的应用，但面临不同挑战： - NLP MoE 的输入是离散 token，路由空间相对有限 - SCX/EGP 的输入是连续原子构型，路由空间是高维连续流形 - NLP MoE 的专家是同构 FFN 层；SCX/EGP 的专家可以是异构的完整势函数

SCX 相对优势： - SCX/EGP 的核心理念——“训练时不耦合，推理时再融合”——避免了通用 MoE 的两个致命问题：1. **训练不稳定**：通用 MoE 的路由器与专家耦合训练，常导致专家坍塌（collapse）或不稳定。2. **负载均衡的开销**：需要复杂的辅助损失函数。 - SCX/EGP 中每个专家可独立训练和验证，质量可控。

空白填补机会： - 通用 MoE 文献中丰富的理论成果（负载均衡、容量规划、路由策略）可以迁移到 SCX/EGP 框架中。 - 思考：能否借鉴 NLP MoE 的“共享专家”（shared expert）思想到 SCX/EGP 中？

B. Knowledge Distillation for MLIP

B1. MACE $\rightarrow$ NEP 蒸馏

论文：“Constructing machine learning interatomic potentials with minimum amount of ab initio data.” npj Computational Materials, s41524-026-02023-y (2026).

他们解决了什么？用最少量的 DFT 数据（~200 个构型）构建高精度 MLIP，无需昂贵的主动学习循环（通常需要数千个 DFT 计算）。

核心方法： - 两阶段教师-学生蒸馏： - Stage 1（教师）：从预训练通用模型 MACE-MP-0 开始，在 ~200 个 DFT 构型上微调。 - Stage 2（学生）：将微调后的 MACE 教师蒸馏到轻量 NEP 模型。 - 验证体系：固态电解质（LGPS、LATP、LYC）。

优势：单次（single-shot）工作流，无需主动学习循环。NEP 的推理速度远快于 MACE，适合大规模 MD 模拟。

与 SCX/EGP 的关系： - 强相关。该工作展示了”昂贵教师 $\rightarrow$ 廉价学生”的标准蒸馏流水线。SCX/EGP 的蒸馏环节本质上也是”复杂专家 $\rightarrow$ 统一学生”，但 SCX/EGP 的关键差异在于：1. 蒸馏前需规范化（Gauge 对齐）：SCX/EGP 的 Gauge 对称化确保专家间能量零点一致，而该工作假设单一教师没有问题。2. 多专家蒸馏：SCX/EGP 面临的不是单教师 $\rightarrow$ 单学生，而是多教师 $\rightarrow$ 单学生。

SCX 相对优势： - SCX/EGP 处理多专家情况下的”冲突预测”问题，该工作未涉及。 - SCX/EGP 可以蒸馏来自不同架构类型（MACE、NequIP、SevenNet 等）的教师，而该工作只有单一架构。

B2. Ensemble Knowledge Distillation (EKD) for MLIP

论文：Matin et al. “Ensemble Knowledge Distillation for Machine Learning Interatomic Potentials.” arXiv:2503.14293 (2025).

他们解决了什么？ 解决能量数据集缺少力标签的问题。在只有 QC 能量的数据集上，通过集成多个教师模型生成伪力，提高学生模型的精度。

核心方法： 1. 在 QC 能量上训练 **多个教师 MLIP**（多种初始化/架构）。2. 用集成教师生成**平均伪力**（ensemble-averaged forces）作为软标签。3. 学生模型同时学习 **QC 能量 + 集成平均力**。4. 验证于 ANI-1ccx 数据集（耦合簇级别能量），在 COMP6 基准上达到 SOTA。

与 SCX/EGP 的关系： - 弱相关但有启发性。该工作关注的是”如何生成更好的软标签”，SCX/EGP 关注的是”如何组合多个独立训练的专家”。EKD 自然地使用了集成思路，但目的是蒸馏而非专家协作。

SCX 相对优势： - EKD 的所有教师需要共享同一训练数据；SCX/EGP 的专家可以在不同数据上独立训练。- EKD 的学生架构不能是教师集的一部分；SCX/EGP 的”学生”本质上是编译器化的专家系统，保留了专家多样性。

B3. Foundation Model Distillation

论文：Gardner et al. “Distillation of atomistic foundation models across architectures and chemical domains.” arXiv:2506.10956 (2025).

他们解决了什么？ 证明合成数据蒸馏（distillation via synthetic data）可以便宜地将原子级基础模型的知识迁移到不同架构。

核心方法： - 教师：基础模型（large universal MLIP） - 生成合成数据，标记后训练轻量学生 - 演示 >10x（GNN→GNN）和 >100x（GNN→ACE）加速 - 验证体系：液态水、极端条件下的氢、多孔二氧化硅、杂化钙钛矿、有机反应

与 SCX/EGP 的关系： - 中等相关。这是”基础模型 → 专门模型”的知识迁移，SCX/EGP 是”多个专门模型 → 编译器化系统”的专家协作。二者互补——基础模型可以作为 SCX/EGP 的专家候选池之一。

空白填补机会： - 该工作的”跨架构蒸馏”可以借鉴到 SCX/EGP 的蒸馏环节（如何从异构专家蒸馏到统一学生）。 - 目前没有工作探讨”如何从多个基础模型中蒸馏”——这正是 SCX/EGP 的用武之地。

B4. Teacher-Student Training for MLIPs (RSC 2025)

论文： Matin et al. “Teacher-student training improves the accuracy and efficiency of machine learning interatomic potentials.” RSC Digital Discovery, 2025.

他们解决了什么？ 证明教师-学生训练不仅能加速推理，还能提高学生模型的准确率（甚至超过教师）。

核心方法： - 架构：**HIPNN**（Hierarchically Interacting Particle Neural Network） - 损失函数增加一项：匹配学生与教师的逐原子能量预测 - 辅助标签：教师网络隐藏层的原子能量输出 - 实验：学生模型实现 >2 倍速度、<50% 内存，且精度超越教师 - 帕累托主导（Pareto dominance）：在每个成本点上都优于对照模型

与 SCX/EGP 的关系： - 中等相关。关键启示：蒸馏可以同时提高精度和效率。SCX/EGP 的蒸馏环节应追求类似效果，而不仅仅是为了压缩。

空白填补机会：- 该工作仅使用单一教师。SCX/EGP 有机会展示”多教师蒸馏”不仅可以压缩模型，还可以通过集成效应超越任何单个专家——即 EGP 的协同效应（synergy）。

B5. 其他重要蒸馏工作

工作	年份	贡献	与 SCX/EGP 关系
SevenNet-Nano (arXiv:2604.10887)	2026	从 SevenNet-Omni 蒸馏到 Nano，>10 倍加速，极端条件验证	补偿性：单一模型蒸馏
PFD 框架 (Phys. Rev. Materials, 2025)	2025	Pre-train→Fine-tune→Distill 流水线，~100 DFT 帧训练 ~100x 加速	学生

工作	年份	贡献	与 SCX/EGP 关系
ARK Dis- tillation (npj Comput. Mater., 2026)	2026	角度关系知 识蒸馏 + 对比学习， 11.9x 催化 剂筛选加速	方法创新：蒸馏中的结构保持

ARK Distillation 特别值得关注： - 论文：Lim et al. “Angular relational knowledge distillation of machine learning interatomic potentials for scalable catalyst exploration.” npj Computational Materials, 2026. - 核心创新：用**角度关系向量（angular relational vectors）**和**对比学习**保持教师 PES 的几何结构。 - 高通量筛选：58 万结构筛选仅用 11.6 GPU-hours（对照：59.4 CPU-years）。 - 启示：SCX/EGP 的蒸馏环节可以借鉴这种”结构保持”的思想，确保编译后的学生模型不丢失专家对 PES 几何的精细刻画。

PFD 框架特别值得关注： - 论文：Wang, Gao et al. “Pre-training, fine-tuning, and distillation (PFD): Automatically generating machine learning force fields from universal models.” Phys. Rev. Materials, 2025. - 核心：DPA-2 → 微调 → DeePMD 学生，仅 ~100 帧 DFT 数据。 - SCX/EGP 可以与 PFD 结合：PFD 作为”专家生成”环节，SCX/EGP 作为”专家编译”环节。

C. Expert Merging / Gauge / Energy Alignment

C1. Model Merging (Model Soup, Git Re-Basin, 线性模式连接)

核心思想：将多个独立训练的模型权重直接平均（或经过排列对齐后平均）获得合并模型，无需再训练。**核心假设：**不同模型的解在权重空间中通过线性路径连接且损失面平坦。

关键工作：

工作	年份	贡献
Model Soups (Wortsman et al., ICML 2022)	2022	均匀/贪心平均微调模型权重，提升精度且不增推理时间
Git Re-Basin (Ainsworth et al., ICLR 2023)	2023	通过排列对齐（permutation alignment）使不同模型处于同一 basin，再平均权重
ZipIt! (ICLR 2024)	2024	可以合并来自不同任务、不同架构的模型（以特征融合代替简单平均）
AME (Lee & Ngo, NeurIPS 2025)	2025	将模型 soup 重新解释为”摊销模型集成（Amortized Model Ensembling）“，使用伪梯度进行无数据元优化

工作	年份	贡献
Soup-of-Experts (ICML 2025)	2025	参数级专家线性组合， 测试时可即时实例化任意域权重组合的模型
LLM Souping (Meta, 2025)	2025	加权平均多个微调 LLM，引入类别感知专家选择 SoCE

与 SCX/EGP 的关系： - 概念近但方法不同。模型合并和 SCX/EGP 都追求”结合多个模型的知识”。但： - 模型合并**在权重空间**操作（weight-space averaging），要求模型架构相同。 - SCX/EGP **在预测空间**操作（prediction-space ensembling），可处理异构架构。 - 模型合并是一个**融合**过程（多个模型融合为一个）；SCX/EGP 是一个**编译**过程（多个模型保持独立但通过路由系统协调）。

SCX 相对优势： - **架构无关性：**模型合并要求同构架构，SCX/EGP 可处理 MACE + NEP + SevenNet 异构组合。 - **可竞争性：**模型合并建立于”模型在权重空间中相容”的假设上，这在 MLIP 中是否成立尚待验证。SCX/EGP 不需要这种假设。 - **可解释性：**SCX/EGP 保留了每个专家的身份，可以追溯哪些专家对哪些输入负责。

空白填补机会： - 目前没有工作将模型合并方法系统应用于 MLIP 领域。 - 可以尝试”MLIP 在权重空间中的线性模式连通性”研究——这是一个开放问题。

C2. MLIP Gauge Freedom 与 Species Energy Shift

论文：“Gauge dependence of total energies and cross-functional transfer learning.” arXiv:2504.05565 (2025).

他们解决了什么？明确指出了 MLIP 中的 **Gauge 自由 (gauge freedom)** 问题：DFT 总能依赖于真空能级的标度选择，不同泛函的总能量基准不同。这个”Gauge” 的选择影响 MLIP 的迁移学习效果。

核心方法： - 分析多种迁移学习策略，对比”是否调整 AtomRef (species energy shift) “的影响。- **关键发现：**跨功能迁移学习时，**先 refit AtomRef 再训练 GNN 是最优策略**。仅重训练 AtomRef 就将 Pearson 相关系数从 0.09 提升到 0.93。- **具体结果：**Method 4 (refit AtomRef + train GNN) 能量 MAE = 17 meV/atom，而直接在源功能基上训练 GNN 是 26 meV/atom。

与 SCX/EGP 的关系： - **核心相关。** Gauge freedom 正是 SCX/EGP 中 **Gauge 对称化**环节要解决的问题。不同 MLIP 在相同结构上的总能量预测存在系统性能量偏移（例如，OUTCAR 中的”energy without entropy” 和 MACE 的预测相差数 eV）。- SCX/EGP 的 Gauge 层 (GAU) 作用就是消除这种偏移，使不同专家的能量预测在联合前可比较。

SCX 相对优势： - 该工作需要每个专家都有自己的 AtomRef 且需要在数据集上显式计算。SCX/EGP 的 Gauge 层可以在不接触原始训练数据的情况下**在线校准**——只需在重叠构型上比较预测值。- SCX/EGP 的 Gauge 对称化不仅处理能量偏移，还处理**力和应力的对齐**（通过 DOF 变换）。

空白填补机会： - 该工作中指出”formation energy” 方法是 Gauge-invariant 的替代方案。SCX/EGP 可以探索：是否在 formation energy 空间而非 total energy 空间进行专家编译？ - 目前没有工作系统地探讨**多专家之间的 Gauge 不一致性**——SCX/EGP 是第一个系统解决该问题的框架。- 该工作只跨功能基 (GGA/GGA+U $\rightarrow$ r²SCAN) 迁移。SCX/EGP 可以扩展到跨势函数的 Gauge 对齐 (SPME $\rightarrow$ MACE $\rightarrow$ NEP)。

C3. Species Energy Shift 标准做法

当前主流通用 MLIP 中的能量偏移处理：

模型	方法	说明
CHGNet	AtomRef + GNN	元素级线性偏移 + 图神经网络残差
M3GNet	AtomRef + GNN	同上
NequIP	AtomRef (subtract per-atom energy)	训练前减去参考能量
CACE	AtomRef + GNN	Composable Atomic Cluster Expansion
MACE-MP-0	平均原子能偏移	基于 MP 数据集计算平均偏移
SevenNet	隐式 offset	模型自动学习偏移

所有这些方法都是**单模型校准**——将单个模型的能量预测对齐到某个参考。
SCX/EGP 的 Gauge 对称化是第一个处理**跨模型能量对齐**的方法。

D. Expert Compilation / Governance (SCX 核心创新区)

这是 SCX/EGP 最核心的差异化领域。搜索结果显示，该方向目前**基本没有竞争工作**。以下是搜索覆盖的几个子方向：

D1. “蒸馏前的专家规范化” (Expert Normalization Before Distillation)

搜索结论：没有专门的工作。

- 现有蒸馏工作（MACE→NEP, SevenNet-Nano, PFD, ARK, EKD 等）都假设单一教师或同构集成教师。
- 当有多教师时，现有工作简单地平均伪力（如 EKD）或者忽略多教师之间的能量不一致性。
- 没有工作系统地解决”蒸馏前必须对齐专家的能量标度”这一问题。
- SCX/EGP 的 Gauge → Route → Compile 流水线是唯一明确区分”专家规范化”与”专家合并”的框架。

SCX 的机会： - 这是 SCX/EGP 最明确的技术壁垒。如果有其他工作开始研究”多教师蒸馏前的能量对齐”，SCX 需要及时跟进和引用。

D2. Expert Domain Certification

搜索结论： 没有适用于 MLIP 的专家域认证工作。

- 通用 AI 领域有一些关于”AI 伦理专家认证”（AIGP 等）的社会学/管理学研究，但这些与 MLIP 专家认证无关。
- “What Makes An Expert?” (arXiv:2411.00179, 2024) 是一篇综述，讨论了 ML 文献中”专家”定义模糊的问题，但聚焦在数据标注场景。
- 没有工作定义”MLIP 专家在哪些输入域上可信”这一概念。
- SCX/EGP 的 ECR 层（代表认证）所做的正是：评估每个专家在给定的输入条件下的置信度。这是 SCX 的原创贡献。

SCX 的机会： - 可以考虑发表专门的方法论文定义”MLIP Expert Domain Certification”的形式化框架。 - 可以借鉴 conformal prediction 的思想，为每个专家在认证域内提供保证。

D3. Multi-Expert Conflict Arbitration（多专家冲突仲裁）

搜索结论：在通用 ML 领域有探索，但在 MLIP 领域为空白。

通用 ML 领域的相关工作：

工作	类型	方法
King Solomon Protocol (2026)	人类监督仲裁	正式的仲裁框架，双助手架构，结构化人类仲裁层
HCDF (2026)	层次化认知	知识获取 → 显式风险表示 → 结构仲裁三层架构
Cognitive Hives (2026)	分布式认知	专门的冲突解决层，识别/仲裁/协调争议
LLMediator / Mediator (2025)	LLM 调解	基于不确定性路由，低冲突层平均 + 高冲突层 MoE
AEGIS-Nexus (2026)	伦理仲裁	元司法仲裁代理，平衡影响力、可靠性和严重性
Multi-Expert Fusion Networks survey	综述	软门控、稀疏路由、top-k 仲裁等分类

MLIP 领域：没有工作探讨多势函数之间的预测冲突与仲裁。

- 现有的”势函数混合”方法（如 ML-MIX, 空间分区 MoE）都回避了”多个模型在同一输入上给出不同预测时该怎么办”的问题。
- SCX/EGP 的 Route 层（RTE）本质上是一个仲裁器——它不仅选择专家，还整合专家的预测。

SCX 的机会： - 可以将通用 ML 仲裁的成果（如 HCDF 的层次化解耦、LLMediator 的不确定性路由）引入 MLIP 领域。 - 可以发表案例研究，展示 EGP 仲裁策略对预测质量的影响。

D4. 多专家性能的输入条件依赖

搜索结论： 没有系统性的工作。

- MoE 文献通常关注**平均性能**，而不是”对特定类型的输入，哪个专家更好”。
- Active learning 和 ALIP 等数据选择方法隐含了”某些区域某些模型更好”但未形式化。
- DeepMD MoE 的逐元素路由展示了”不同的元素的构型应由不同专家处理”——这是一个好的开端。
- 没有工作系统地构建”专家性能配置文件”（expert performance profile over input conditions）。

SCX 的机会： - ECR 层本质上就是一个专家性能配置文件的实时评估器。
- 可以发布一个专家性能配置文件的自动构建工具。

E. 竞争格局总结与战略建议

E1. 创新维度对比矩阵

竞争维度	DeepMD	Allegro	模型合 并	MLIP 蒸 馏	SCX/EGP
	MoE (2603)	MoE (2604)			
训练时 MoE	Y	Y	N	N	N
后训练/编译	N	N	Y	Y	Y
异构专家	N	N	N	N	Y
Gauge 对齐	N	Y(隐式)	N	N	Y
输入条件路由	Y(元素 级)	Y(空间)	N	N	Y
专家域认证	N	N	N	N	Y
蒸馏前规范化	N	N	N	N	Y
冲突仲裁	N	N	N	N	Y
训练不可知	N	N	Y	N	Y

核心结论：SCX/EGP 在”后训练编译”这个细分领域没有直接竞争。每个现有工作都只在某些维度上与 SCX/EGP 有交集，但没有任何工作覆盖 SCX/EGP 的全部创新维度。

E2. 竞争风险等级评估

风险等级	竞争方向	原因
高	DeepMD MoE (2603.07977)	DeepMD 社区大、影响力强，如果他们将路由策略扩展到后训练场景，将是直接竞争

风险等级	竞争方向	原因
高	Allegro MoE (2604.26143)	如果他们将” 空间分区” 扩展到” 输入条件分区”，会与 EGP 的路由层重叠
中	ARK 蒸馏 (npj 2026)	如果 ARK 扩展到多教师蒸馏并引入对齐步骤，将进入” 蒸馏前规范化” 领域
中	PFD 流程 (PRM 2025)	如果 PFD 扩展到” 多模型联合蒸馏”，将接近 EGP 的 Compile 层
低	模型合并 (通用 ML)	架构不可知方向不同，且合并需要同构架构
低	Foundation 蒸馏 (2506.10956)	目前聚焦单教师 → 单学生，进入多教师领域还需较大跨度

E3. SCX/EGP 必须主动占领的空白

按优先级排序：

1. 蒸馏前的专家规范化（Prerequisite Normalization）
- 这是 SCX/EGP 最独特、最差异化的贡献。

- 必须通过论文、代码、演示案例让社区认识到：**跨专家能量对齐是多专家编译的必要前提。**
2. 专家域认证 (Expert Domain Certification)
- 定义什么是”可信的专家”。
 - 建立基于 conformal prediction 或不确定性量化的认证框架。
 - 潜在应用：在提交 VASP 任务前做专家域检查，避免在专家不确定的区域做不可靠预测。
3. 跨架构专家编译演示 (Cross-Architecture Compilation)
- 展示 SCX/EGP 组合 MACE + NEP + SevenNet + NequIP 的能力。
 - 这是任何竞争对手都无法快速复制的技术壁垒——因为其他方法如模型合并、DeepMD MoE 都受限于架构同质性。
4. 多专家蒸馏的协同效应 (Synergistic Distillation)
- 证明蒸馏后的 EGP 学生可以超越任何单个专家的精度。
 - 建立”EGP 蒸馏 > 单个专家微调 > 直接蒸馏”的论证。
5. 输入条件依赖的性能评估基准 (Input-Conditioned Benchmark)
- 发布在”专家更擅长什么”问题上的系统评估。
 - 可基于 NEB 路径、声子谱、弹性常数等多维属性。
 - 建立”哪个模型处理哪种类型的最佳”的参考标准。

E4. 建议行动项

优先级	行动	说明
P0	SCX 系统论文	在 arXiv 上发表 SCX/EGP 的方法论文，建立”Expert Compilation”这一新方向的官方名称

优先级	行动	说明
P0	开源 EGP 演示	基于现有的 VASP + MACE + NEP 等模型展示完整的 Gauge→Route→Compile 流水线
P1	Gauge 对称化论文	单独发表对 MLIP Gauge freedom 的量化分析和校准方法
P1	输入条件路由 vs. DeepMD MoE 对比基准	在 OMat24 等标准基准上与 DeepMD MoE 对比
P2	专家域认证白皮书	定义 Expert Domain Certification 的形式化框架
P2	冲突仲裁方法论论文	展示 EGP 的 Route 层如何处理多专家分歧

E5. 竞争方法背后的团队/组织

团队	相关论文	对 SCX 的竞争风险
DP Technology / AIS (张林峰, 王涵等)	DeepMD MoE (2603.07977)	高——他们在 MLIP 领域影响力最大
Boris Kozinsky 组 (Harvard)	Allegro/NequIP, MoE (2604.26143)	高——势函数架构原创者

团队	相关论文	对 SCX 的竞争风险
InstaDeep	mlip JAX 库 (2605.22698)	中——工程能力强，但研究侧重不同
LANL (Sakib Matin 等)	EKD, Teacher-student RSC	中——蒸馏方向强，但短期内不会进入多专家编译
Volker Deringer 组 (Oxford)	Foundation distillation (2506.10956)	中低——学术风格偏基础模型，而非工程编译
Seoul National Univ. (Jeong Woo Han 组)	ARK Distillation	中低——集中在催化筛选应用，而非方法论
USTC (高玉祥等)	PFD 框架 (2502.20809)	中——PFD 的“自动生成”方向与 EGP 互补

参考文献

A. MoE in MLIP

1. Liu, Y. et al. “Scaling Machine Learning Interatomic Potentials with Mixtures of Experts.” arXiv:2603.07977 (2026). <https://arxiv.org/abs/2603.07977>
2. Nascimento, G.M. et al. “Mixture of Experts Framework in Ma-

- chine Learning Interatomic Potentials for Atomistic Simulations.” arXiv:2604.26143 (2026). <https://arxiv.org/abs/2604.26143>
3. Shazeer, N. et al. “Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer.” ICLR 2017. <https://arxiv.org/abs/1701.06538>
 4. Fedus, W., Zoph, B. & Shazeer, N. “Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity.” JMLR 2022. <https://arxiv.org/abs/2101.03961>
 5. Birks, T., Swinburne, T. & Kermode, J. “Efficient and accurate spatial mixing of machine learned interatomic potentials.” npj Computational Materials (2025).
 6. Nascimento, G.M. & Descoteaux, B. “Mixture-of-Experts Framework in MLIP for Atomistic Simulations.” (2026).

B. Knowledge Distillation for MLIP

7. “Constructing machine learning interatomic potentials with minimum amount of ab initio data.” npj Computational Materials, s41524-026-02023-y (2026). <https://www.nature.com/articles/s41524-026-02023-y>
8. Matin, S. et al. “Ensemble Knowledge Distillation for Machine Learning Interatomic Potentials.” arXiv:2503.14293 (2025). <https://arxiv.org/abs/2503.14293>
9. Gardner, J.L.A. et al. “Distillation of atomistic foundation models across architectures and chemical domains.” arXiv:2506.10956 (2025). <https://arxiv.org/abs/2506.10956>
10. Matin, S. et al. “Teacher-student training improves the accuracy and efficiency of machine learning interatomic potentials.” RSC Digital Discovery (2025). <https://pubs.rsc.org/en/content/articlehtml/2025/dd/d5dd00085h>
11. Kim, J. et al. “A Lightweight Universal Machine-Learning Interatomic Potential via Knowledge Distillation for Scalable Atom-

- istic Simulations (SevenNet-Nano).” arXiv:2604.10887 (2026).
<https://arxiv.org/abs/2604.10887>
12. Wang, R., Gao, Y. et al. “Pre-training, fine-tuning, and distillation (PFD): Automatically generating machine learning force fields from universal models.” *Phys. Rev. Materials* 9, 113802 (2025).
<https://arxiv.org/abs/2502.20809>
 13. Lim, H. et al. “Angular relational knowledge distillation of machine learning interatomic potentials for scalable catalyst exploration.” *npj Computational Materials* 12, 1 (2026). <https://link.springer.com/article/10.1038/s41524-026-02062-5>
 14. “Data-Efficient and Fast Machine Learning Molecular Dynamics through Integrated Active Learning and Knowledge Distillation.” *ChemRxiv* (2026).

C. Expert Merging / Gauge Alignment

15. “Gauge dependence of total energies and cross-functional transfer learning.” arXiv:2504.05565 (2025). <https://arxiv.org/abs/2504.05565>
16. Wortsman, M. et al. “Model soups: averaging weights of multiple fine-tuned models improves accuracy without increasing inference time.” *ICML 2022*.
17. Ainsworth, S. et al. “Git Re-Basin: Merging Models modulo Permutation Symmetries.” *ICLR 2023*.
18. Lee, S.H. & Ngo, R. “On Defining Neural Averaging.” *NeurIPS 2025*.
<https://arxiv.org/abs/2508.14832>
19. Ablin, P. et al. “Soup-of-Experts.” *ICML 2025*.
20. Franke et al. “Hierarchical Re-Basin.” *ESANN 2024*.

D. Governance / Arbitration (General ML)

21. Grassini Grimaldi, A. “The King Solomon Protocol: A Framework for Human Supervised Arbitration in Multi-Model AI Systems.” (2026).
22. Bie et al. “Knowledge-guided policy arbitration: A hierarchical cognitive framework for safety-critical decision-making.” Expert Systems with Applications (2026).
23. Hettiarachchi. “From Monolithic Models to Cognitive Hives: A Framework for Multimodal Reasoning Systems.” JCSTS (2026).
24. “Beyond Monoliths: Expert Orchestration for More Capable, Democratic, and Safe Large Language Models.” arXiv:2506.00051 (2025).
25. “Toward Calibrated Mixture-of-Experts Under Distribution Shift.” arXiv:2606.20544 (2026).

报告结束。本分析基于公开文献检索（截至 2026-06-25），覆盖 arXiv、Nature Portfolio、RSC、APS、Springer 等来源。SCX/EGP 在“后训练多专家编译”这一细分领域无直接竞争，但需警惕 DeepMD 和 Kozinsky 组等团队可能的后续扩展工作。