

SCX 框架的数学基础：深度追溯与证明建构

State-Conditioned eXpertise (SCX) — 一种状态条件化的专家路由与主动采样框架

本文档对其核心数学对象进行测度论溯源、严格证明建构，以及统计学习理论的全景连接。

第一部分：数学根源完整追溯

A. 条件风险 (Conditional Risk)

A.1 从 Kolmogorov 条件期望出发

SCX 的核心量 $R_m(s) = \mathbb{E}_{x \sim P(\cdot|s)}[\ell(f_m(x), f^*(x))]$ 是 Kolmogorov 意义下的条件期望。

定义 A.1 (Kolmogorov, 1933). 设 $(\Omega, \mathcal{F}, P)$ 为概率空间, Y 为可积随机变量, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数。则 $\mathbb{E}[Y | \mathcal{G}]$ 是满足以下条件的唯一 (a.s.) $\mathcal{G}$ -可测随机变量:

$$\int_A \mathbb{E}[Y | \mathcal{G}] dP = \int_A Y dP, \quad \forall A \in \mathcal{G}.$$

在 SCX 中, 令 X 为输入随机变量, s 为输入空间 $\mathcal{X}$ 的一个可测子集。定义指示事件 $\{X \in s\}$ 生成的 σ -代数为 $\sigma(\{X \in s\})$ 。则条件风险 $R_m(s)$ 是

条件期望 $\mathbb{E}[\ell(f_m(X), f^*(X)) \mid X \in s]$ 的一个版本。

性质链：

$$\begin{aligned} R_m(s) &= \frac{1}{P(X \in s)} \int_{X \in s} \ell(f_m(x), f^*(x)) dP_X(x) \\ &= \frac{\mathbb{E}[\ell(f_m(X), f^*(X)) \cdot \mathbf{1}\{X \in s\}]}{P(X \in s)}. \end{aligned}$$

当 $P(X \in s) = 0$ 时， $R_m(s)$ 可定义为 $\lim_{\epsilon \rightarrow 0^+} R_m(s_\epsilon)$ ，其中 s_ϵ 是 s 的 ϵ -邻域。

A.2 与回归函数的关系

令回归函数为 $r(x) = \mathbb{E}[Y \mid X = x]$ 。对于平方损失 $\ell(\hat{y}, y) = (\hat{y} - y)^2$ ：

$$\begin{aligned} R_m(s) &= \mathbb{E}[(f_m(X) - f^*(X))^2 \mid X \in s] \\ &= \mathbb{E}[(f_m(X) - r(X) + r(X) - f^*(X))^2 \mid X \in s] \\ &= \underbrace{\mathbb{E}[(f_m(X) - r(X))^2 \mid X \in s]}_{\text{近似误差}} + \underbrace{\mathbb{E}[(r(X) - f^*(X))^2 \mid X \in s]}_{\text{目标噪声}} \\ &\quad + 2 \underbrace{\mathbb{E}[(f_m(X) - r(X))(r(X) - f^*(X)) \mid X \in s]}_{\text{交叉项}}. \end{aligned}$$

在 f^* 为条件期望 $f^*(x) = \mathbb{E}[Y \mid X = x]$ 的特殊情况下（即 f^* 是最优可测函数），交叉项为零，得到：

$$R_m(s) = \mathbb{E}[(f_m(X) - r(X))^2 \mid X \in s] + \mathbb{E}[\text{Var}(Y \mid X) \mid X \in s].$$

这正是**偏差-方差分解**的条件版本。第一项是状态 s 内的近似误差，第二项是 s 内固有的贝叶斯风险。

A.3 与 Bayes 风险的关系

定义贝叶斯风险为 $R^* = \inf_{f \text{ 可测}} \mathbb{E}[\ell(f(X), Y)]$ 。对于每个状态 s ，可以定义状态条件贝叶斯风险：

$$R^*(s) = \inf_{f \text{ 可测}} \mathbb{E}[\ell(f(X), Y) \mid X \in s].$$

那么 SCX 中的 $R_m(s)$ 衡量的是专家 f_m 在状态 s 中相对于不可知最优 f^* 的表现，而非相对于 $R^*(s)$ 。这在 $f^* \neq \arg \inf_f \mathbb{E}[\ell(f(X), Y)]$ 时产生差异。

定理 A.1 (条件风险分解). 若 f^* 为目标函数（可能是人标注者或理想模型），则：

$$R_m(s) = \underbrace{\mathbb{E}[\ell(f_m(X), r(X)) \mid X \in s]}_{\text{可减少误差}} + \underbrace{\mathbb{E}[\ell(r(X), f^*(X)) \mid X \in s]}_{\text{不可减少的状态偏差}}.$$

A.4 与 PAC-Bayes 理论的关系

PAC-Bayes 理论 (McAllester, 1999) 给出了随机分类器（在假设空间上的后验分布）的泛化界：

$$\mathbb{E}_Q[\mathcal{R}(h)] \leq \mathbb{E}_Q[\hat{\mathcal{R}}(h)] + \sqrt{\frac{\text{KL}(Q \| P) + \log(n/\delta)}{2n - 1}}.$$

将其扩展到状态条件化 PAC-Bayes：

$$\mathbb{E}_{Q_s}[\mathcal{R}(h \mid s)] \leq \mathbb{E}_{Q_s}[\hat{\mathcal{R}}(h \mid s)] + \sqrt{\frac{\text{KL}(Q_s \| P_s) + \log(n_s/\delta)}{2n_s - 1}},$$

其中 $n_s = |\{i : x_i \in s\}|$ 为状态 s 中的样本数， Q_s 为状态条件化的后验分布。SCX 的专家路由 $m^*(x) = \arg \min_m \sum_x \gamma_s(x) R_m(s)$ 等价于在每个状态上选择一个后验集中在单个假设上的策略——这是 PAC-Bayes 的极值化形式。

A.5 与 Domain Adaptation / Covariate Shift 的关系

在协变量偏移下，训练分布 P_{train} 与测试分布 P_{test} 不同。条件风险 $R_m(s)$ 的定义天然适用于此：

$$R_m^{\text{test}}(s) = \mathbb{E}_{x \sim P_{\text{test}}(\cdot|s)}[\ell(f_m(x), f^*(x))] = \frac{\mathbb{E}_{x \sim P_{\text{train}}}[\ell(f_m(x), f^*(x)) \cdot \mathbf{1}\{x \in s\} \cdot w(x)]}{\mathbb{E}_{x \sim P_{\text{train}}}[\mathbf{1}\{x \in s\} \cdot w(x)]}.$$

其中 $w(x) = dP_{\text{test}}/dP_{\text{train}}(x)$ 为似然比。这表明 SCX 的 **状态级重要性权重** 本质上是对 covariate shift 的局部化处理——全局权重 $w(x)$ 被替换为状态条件化版本。

B. 状态划分 (State Partition)

B.1 测度论的可测划分

定义 B.1. 输入空间 $\mathcal{X}$ 的一个可测划分 $\Pi = \{s_1, s_2, \dots, s_K\}$ 满足：1. $\bigcup_{k=1}^K s_k = \mathcal{X}$ 2. $s_k \cap s_{k'} = \emptyset$ 当 $k \neq k'$ 3. 每个 s_k 是 $\mathcal{X}$ 的 Borel σ -代数中的可测集

由 Π 生成的 σ -代数 $\sigma(\Pi)$ 是所有形如 $\bigcup_{k \in I} s_k$ 的集合 ($I \subseteq \{1, \dots, K\}$) 的族。那么状态条件期望 $\mathbb{E}[Y | X \in s_k]$ 正是 $\mathbb{E}[Y | \sigma(\Pi)]$ 的一个版本。

B.2 充分统计量与信息瓶颈

定义 B.2 (充分统计量). 统计量 $T: \mathcal{X} \rightarrow \mathcal{T}$ 对参数 θ 是充分的, 当且仅当 $X \perp \theta \mid T(X)$ (或 $Y \perp X \mid T(X)$ 在预测场景中)。

SCX 的状态划分 $\{s_k\}$ 可以视为**离散化充分统计量**: 我们希望 $Y \perp X \mid s(X)$, 即给定状态后, 输入不再提供关于输出的额外信息。这等价于:

$$P(Y \mid X) = P(Y \mid s(X)), \quad \text{a.s.}$$

信息瓶颈 (Tishby et al., 1999). 状态划分是信息瓶颈问题的最优解:

$$\min_{\Pi: |\Pi|=K} I(X; \tilde{X}) - \beta I(\tilde{X}; Y),$$

其中 $\tilde{X}$ 是 X 在划分 Π 下的离散化表示。当 $\beta \rightarrow \infty$ 时, 解是在固定 K 下最大化 $I(\tilde{X}; Y)$ 的划分——即保留最多关于 Y 的信息的粗粒化。

B.3 与 Vapnik-Chervonenkis 理论的联系

状态划分对应于**分区分类器 (partition classifier)**:

$$\mathcal{H}_{\Pi} = \{h: h(x) = \sum_{k=1}^K \alpha_k \mathbf{1}\{x \in s_k\}, \alpha_k \in \mathbb{R}\}.$$

该假设类的 VC 维 (或伪维) 为 $O(K)$ 。这意味着: - 状态数 K 直接控制假设类的容量 - SCX 中的状态发现等价于在**表达力** (更多状态) 与**泛化** (更少参数) 之间做权衡 - 经典 VC bound 适用于状态级泛化误差: $\tilde{O}(\sqrt{K/n})$

B.4 与 RKHS 的关系

再生核希尔伯特空间 $\mathcal{H}_K$ 中的每个函数 f 满足 $f(x) = \langle f, K(x, \cdot) \rangle_{\mathcal{H}_K}$ 。状态划分可以通过核诱导的几何结构进行：

核 k-means 状态发现： 给定核 K ，在 RKHS 嵌入 $\phi(x) = K(x, \cdot)$ 上进行聚类：

$$\min_{\{s_k\}} \sum_{k=1}^K \sum_{x_i \in s_k} \|\phi(x_i) - \mu_k\|_{\mathcal{H}_K}^2,$$

其中 $\mu_k = \frac{1}{|s_k|} \sum_{x_i \in s_k} \phi(x_i)$ 。

这一框架将状态划分与核方法统一：不同的核选择对应不同的“相似性”度量，从而产生不同的状态结构。

B.5 与流形学习和谱聚类的关系

当数据嵌入低维流形时，最优状态划分应沿着流形的固有几何进行。谱聚类在数据图的 Laplacian 特征空间中进行 K -means：

谱状态发现： 1. 构建亲和图 $W_{ij} = \exp(-\|x_i - x_j\|^2/\sigma^2)$ 2. 计算归一化 Laplacian $L = I - D^{-1/2} W D^{-1/2}$ 3. 提取 L 的 K 个最小特征向量 $v_1, \dots, v_K$ 4. 在 $[v_1, \dots, v_K]$ 的行上进行 K -means

这等价于求解流形上的切比雪夫切割 (Cheeger cut)。SCX 在此框架下的状态发现可理解为：找到在条件风险意义上尽可能均匀的子流形区域。

C. 数据价值 (Data Value)

C.1 Shapley 值公理体系

定义 C.1 (Shapley, 1953). 设 $N = \{1, \dots, n\}$ 为数据点集合, $v: 2^N \rightarrow \mathbb{R}$ 为效用函数 (表征子集 S 的模型性能)。则数据点 i 的 Shapley 值为:

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(n - |S| - 1)!}{n!} [v(S \cup \{i\}) - v(S)].$$

Shapley 值是唯一满足以下四公理的解:

1. **有效性 (Efficiency):** $\sum_{i=1}^n \phi_i(v) = v(N) - v(\emptyset)$
2. **对称性 (Symmetry):** 若 $v(S \cup \{i\}) = v(S \cup \{j\})$ 对所有 $S \subseteq N \setminus \{i, j\}$ 成立, 则 $\phi_i(v) = \phi_j(v)$
3. **虚拟性 (Null Player):** 若 $v(S \cup \{i\}) = v(S)$ 对所有 $S \subseteq N \setminus \{i\}$ 成立, 则 $\phi_i(v) = 0$
4. **可加性 (Additivity):** $\phi_i(v + w) = \phi_i(v) + \phi_i(w)$

C.2 半值和 Banzhaf 值

定义 C.2 (半值 / Semivalue). 半值是 Shapley 值的推广, 使用一般化的概率权重:

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} p_{|S|} [v(S \cup \{i\}) - v(S)],$$

其中 $\sum_{k=0}^{n-1} \binom{n-1}{k} p_k = 1$, 且 p_k 非负。

Banzhaf 值 (Banzhaf, 1965) 是 $p_k = 1/2^{n-1}$ 的特殊半值:

$$\phi_i^B(v) = \frac{1}{2^{n-1}} \sum_{S \subseteq N \setminus \{i\}} [v(S \cup \{i\}) - v(S)].$$

在 SCX 中，噪声分数 $\text{NoiseScore}(x_i) = r_i/(\rho(s_i) + \varepsilon) \cdot [1 - C(s_i)]$ 可以解释为一种近似 **Banzhaf 影响力指标**——它衡量移除该点（或将其标记为噪声）对损失的影响。

C.3 与 Influence Function 的关系

定义 C.3 (Hampel, 1974). 给定统计泛函 $T(F)$ （其中 F 为分布），在点 x 处的 influence function 为：

$$\text{IF}(x; T, F) = \lim_{\varepsilon \rightarrow 0^+} \frac{T((1 - \varepsilon)F + \varepsilon\delta_x) - T(F)}{\varepsilon}.$$

在经验分布 $\hat{F}_n$ 下，leave-one-out 影响近似为：

$$\hat{\text{IF}}(x_i) \approx (n - 1)[T(\hat{F}_n) - T(\hat{F}_{-i})].$$

对于模型性能泛函 $T(F) = \mathbb{E}_{(x,y) \sim F}[\ell(f(x), y)]$ ，数据点 x_i 的影响函数与 Shapley 值在 $\varepsilon = 1/n$ 的一阶项上等价（Koh & Liang, 2017）：

$$\phi_i(v) \approx \frac{1}{n} \cdot \text{IF}(x_i; T, \hat{F}_n) + O(1/n^2).$$

SCX 的噪声分数 $r_i/(\rho(s_i) + \varepsilon)$ 对应于状态条件化的影响函数，它在每个状态内独立计算数据点的影响力。

C.4 与 Expected Value of Information (EVOI) 的关系

定义 C.4. 获取数据 x 的期望信息价值为：

$$\text{EVOI}(x) = \mathbb{E}_{Y|X=x}[U(\text{最优行动} \mid \text{更新后})] - U(\text{最优行动} \mid \text{当前}),$$

其中 U 为效用函数。

SCX 中的状态获取函数 $s^* = \arg \max_s V(s) = \arg \max_s \bar{r}(s) \cdot \rho(s) \cdot L(s) \cdot [1 - D(s)] \cdot \max_m \text{SCX}_m(s)$ 是一种**状态级的 EVOI 度量**：- $\bar{r}(s)$ 代表当前在 s 中的不确定性（与信息增益成正比）- $\rho(s)$ 代表该状态的先验概率（覆盖范围）- $L(s)$ 代表可学习性（信息有用性）- $1 - D(s)$ 代表尚未被探索的程度（新鲜度）- $\max_m \text{SCX}_m(s)$ 代表专家覆盖（信息利用能力）

C.5 与 Marginal Likelihood / Bayesian Model Selection 的关系

在贝叶斯框架中，模型 M 的边缘似然为：

$$P(\mathcal{D} \mid M) = \int P(\mathcal{D} \mid \theta, M) P(\theta \mid M) d\theta.$$

SCX 的状态发现可以理解为：寻找划分 Π 使得每个状态的**局部边缘似然最大化**：

$$\Pi^* = \arg \max_{\Pi} \sum_{k=1}^K \log P(\{y_i : x_i \in s_k\} \mid \{x_i : x_i \in s_k\}, \text{朴素模型}),$$

其中”朴素模型”是在状态内假设 Y 独立于 X 的简化模型。这等价于最小化状态内的互信息：

$$\sum_k |s_k| \cdot \hat{I}(X; Y | s_k),$$

这正是信息瓶颈目标。

D. 专家可靠性 (Expert Reliability)

D.1 Dawid-Skene 模型

定义 D.1 (Dawid & Skene, 1979). 设 N 个任务, M 个标注者。每个任务有真实标签 $z_j \in \{1, \dots, C\}$, 每个标注者提供标签 y_{ij} 。标注者 i 的混淆矩阵为 $\pi_{cc'}^{(i)} = P(y_{ij} = c' | z_j = c)$ 。似然为:

$$P(Y | \pi, z) = \prod_{j=1}^N P(z_j) \prod_{i=1}^M \pi_{z_j, y_{ij}}^{(i)}.$$

通过 EM 算法估计 $\pi^{(i)}$ 和 z_j 。

SCX 中的 $SCX_m(s) = P(\ell(f_m(x), y) < \tau | x \in s)$ 可以看作 Dawid-Skene 框架的特例: 每个专家 f_m 是一个“标注者”, $SCX_m(s)$ 是其混淆矩阵的对角线元素 (在阈值 τ 下二值化)。然而 SCX 的重要创新在于: **可靠性是状态条件的**——同一专家在不同状态 s 中有不同的 $SCX_m(s)$ 。

D.2 标注者建模的统计基础

多标注者模型的一般形式:

$$P(y_{ij} = c' \mid x_j, z_j = c, \theta_i) = f(x_j, c, c'; \theta_i),$$

其中 θ_i 是标注者 i 的偏差参数。常见的参数化包括：- **简单偏差模型**: $P(y_{ij} = z_j \mid x_j, \theta_i) = \theta_i$ （全局准确率）- **类条件模型**: $P(y_{ij} = c' \mid z_j = c, \theta_i) = \theta_{i,cc'}$ （每类准确率）- **特征条件模型**: $\theta_i(x) = \sigma(w_i^\top x)$ （输入依赖的可靠性）

SCX 的状态条件可靠性 $SCX_m(s)$ 对应于**输入空间分区的标注者建模**——在状态 s 内使用一个简单的可靠性参数，但在状态之间变化。

D.3 Item Response Theory (IRT)

IRT 模型（Lord, 1952; Rasch, 1960）描述了”项目难度”和”被试能力”的关系。**双参数逻辑模型 (2PL)**:

$$P(Y_{ij} = 1 \mid \theta_j, a_i, b_i) = \sigma(a_i(\theta_j - b_i)),$$

其中 θ_j 为被试 j 的能力， a_i 为区分度， b_i 为难度。

SCX 中的 $SCX_m(s)$ 与 IRT 存在深层对应：- 专家 f_m 对应一个”测试项目” - 输入 x 对应一个”被试” - 状态 s 对应一组能力相近的被试 - $SCX_m(s)$ 对应在该能力区间上的平均正确率

这与**多维 IRT (MIRT)** 的维度条件概率自然衔接。

D.4 与 Calibration / ECE 的关系

期望校准误差 (Expected Calibration Error):

$$\text{ECE} = \mathbb{E}_{\hat{P}}[|P(Y = 1 \mid \hat{P} = p) - p|].$$

SCX 的 $SCX_m(s)$ 本质上是对专家 f_m 在状态 s 上的条件校准评估：

$$\text{ECE}_m(s) = \left| \frac{1}{|s|} \sum_{x_i \in s} \mathbf{1}\{\ell(f_m(x_i), y_i) < \tau\} - \mathbb{E}_{x \in s}[SCX_m(s)] \right|.$$

当 $\tau \rightarrow 0$ 时, $SCX_m(s)$ 趋近于在状态 s 上的精确条件准确率。

D.5 与 Conformal Prediction 的关系

共形预测 (Vovk et al., 2005) 在给定置信度 $1 - \alpha$ 下构造预测集：

$$\Gamma^\alpha(x) = \{y : p_y(x) > \alpha\}, \quad p_y(x) = \frac{|\{i : s(x_i, y) \leq s(x, y)\}| + 1}{n + 1}.$$

SCX 的阈值 τ 与共形预测的校准阈值 α 有直接关系。 $SCX_m(s)$ 可以解释为：如果不合格率阈值为 τ ，则专家 f_m 在状态 s 中的共形覆盖率。

定理 D.1. 若校准集和测试集在状态 s 内是可交换的，则对于固定的 τ ：

$$\mathbb{E}[SCX_m(s)] = 1 - \alpha,$$

其中 α 为与 τ 对应的共形预测显著性水平。

E. 噪声与可学习性 (Noise & Learnability)

E.1 Tsybakov 噪声条件

定义 E.1 (Tsybakov, 2004). 在二分类中, 令 $\eta(x) = P(Y = 1 \mid X = x)$ 。称分布 P 满足 Tsybakov 噪声条件 (参数 $\kappa \geq 0$), 若存在常数 $C > 0$ 使得:

$$P_X(|\eta(X) - 1/2| \leq t) \leq Ct^\kappa, \quad \forall t > 0.$$

κ 控制着决策边界附近的不确定性质量: - $\kappa = 0$: 最坏情况 (可能有无穷多点在决策边界上) - $\kappa \rightarrow \infty$: 完美分离 (所有点远离决策边界)

Tsybakov 条件给出了最小最大最优收敛率 $\tilde{O}(n^{-\frac{1+\kappa}{2+\kappa}})$, 比无假设时的 $\tilde{O}(n^{-1/2})$ 更快。

E.2 Mammen-Tsybakov Margin Condition

定义 E.2 (Mammen & Tsybakov, 1999). 称分布 P 满足 Margin 条件 (参数 $\alpha \geq 0$), 若存在常数 $c > 0$ 使得:

$$\mathbb{E}[|2\eta(X) - 1| \cdot \mathbf{1}\{|\eta(X) - 1/2| \leq h\}] \leq ch^\alpha, \quad \forall h > 0.$$

当 $\alpha > 0$ 时, 分类器的收敛率可以提升。这与 SCX 的关系在于:

SCX 的噪声分数 $\text{NoiseScore}(x_i) = r_i/(\rho(s_i) + \varepsilon) \cdot [1 - C(s_i)]$ 中的 $1 - C(s_i)$ 可以理解为状态 s_i 中**边际条件满足程度**的代理:

$$C(s) \approx P_X(|\eta(X) - 1/2| > \tau_0 \mid X \in s),$$

即状态 s 中可清楚分类的比例。高噪声状态对应于 $\eta \approx 1/2$ 的区域。

E.3 与 Huber 污染模型的关系

定义 E.3 (Huber, 1964). 污染模型:

$$F = (1 - \varepsilon)G + \varepsilon H,$$

其中 G 为”干净”分布, H 为污染分布, $\varepsilon \in [0, 1)$ 为污染比例。

SCX 的噪声发现等价于在**每个状态内**识别污染点:

$$\text{NoiseScore}(x_i) > \tau_{\text{noise}} \Rightarrow x_i \text{ 可能来自污染组分.}$$

状态 s 中的污染参数为 $\varepsilon(s) = \frac{|\{x_i \in s: \text{NoiseScore}(x_i) > \tau\}|}{|s|}$ 。

E.4 与 EM 算法在众包学习中的关系

众包学习中, EM 算法 (Dawid-Skene) 交替进行: - **E 步**: 基于当前标注者可靠性估计真实标签 - **M 步**: 基于估计的真实标签更新标注者可靠性

SCX 的状态发现与噪声检测可以嵌入类似的 EM 框架: 1. **状态 E 步**: 给定当前状态划分 $\Pi^{(t)}$ 和专家可靠性 $SCX_m^{(t)}(s)$, 估计每个点的”可学习性”
状态 2. **状态 M 步**: 基于当前估计, 更新状态边界和专家可靠性

定理 E.1 (收敛性). 若状态发现的损失函数是划分的连续函数, 则上述 EM 过程收敛到局部最优状态划分。

F. 主动采样 (Active Acquisition)

F.1 MacKay 信息论主动学习

定义 F.1 (MacKay, 1992). 主动学习选择最大化期望信息增益的点:

$$x^* = \arg \max_x H[\theta \mid \mathcal{D}] - \mathbb{E}_{y \sim P(y|x, \mathcal{D})} [H[\theta \mid \mathcal{D} \cup \{(x, y)\}]],$$

其中 H 为 Shannon 熵。

对于高斯过程模型，这等价于最大化后验方差:

$$x^* = \arg \max_x \sigma_n^2(x) = \arg \max_x K(x, x) - \mathbf{k}_n(x)^\top (K_n + \sigma^2 I)^{-1} \mathbf{k}_n(x).$$

F.2 与最优实验设计 (OED) 的关系

最优实验设计框架定义三种最优性标准:

- **A-最优性**: 最小化 $\text{Tr}[(X^\top X)^{-1}]$ (最小平均方差)
- **D-最优性**: 最大化 $\det(X^\top X)$ (最小置信椭球体积)
- **E-最优性**: 最大化 $\lambda_{\min}(X^\top X)$ (最小最大方差)

SCX 的状态获取函数 $V(s)$ 在给定状态 s 下, 采样策略应在状态内满足 D-最优性:

$$V(s) \propto \det(\mathbb{E}_{x \in s}[xx^\top]),$$

在广义线性模型下, 这等价于最大化状态内 Fisher 信息矩阵的行列式。