

SCX 两层描述符：错误驱动的状态发现

SCX 的核心理念：状态不由人来定义，而由”模型在哪里失败”来定义。

这是 SCX 区别于所有基于人类特征聚类方法的本质差异。

文档定位： Paper 2 (Residual-State Maps) 与 Paper 4 (SCX Theory) 之间的桥梁。Paper 2 证明了”误差有结构根源”，两层描述符就是发现这些根源的方法；Paper 4 的”状态条件专家性”依赖两层描述符来定义什么是”状态”。

依赖的前序文档： - 01_SCX_ 核心框架 _ 数学分析.md — 状态条件风险的形式化 - 05_ 数学根源与证明.md — 信息瓶颈与状态划分的测度论基础 - 06_ 实现架构与实验设计.md — SCX 实现架构

相关实现： - src/scx/encoders/error_driven.py — ErrorDrivenEncoder - src/scx/state/two_layer.py — TwoLayerStateDiscovery - src/scx/encoders/base.py — SCXStateEncoder 基类 - src/scx/state/discovery.py — StateDiscovery 基类

目录

1. 问题：为什么一层描述符不够？
2. 两层描述符体系
3. 数学形式化
4. SCX 实现
5. 与竞争方法的对比
6. 实验验证

7. 论文定位与贡献

8. 参考文献

1. 问题：为什么一层描述符不够？

1.1 人类描述符的局限性

现有势函数开发的共同路径：研究人员凭直觉选择描述符（元素种类、晶体结构、温度范围），然后在这些描述符定义的类别上做均匀采样。这一范式的根本缺陷在于：

人类选的描述符可能不捕捉模型的真实失败模式。

1.1.1 AIN v3 案例 在 AIN v3 的实际开发中，这一问题暴露得极为清晰：

- 研究人员定义了 12 维手工特征（化学组分、结构类型、温度区段等），试图覆盖所有的化学环境
- 但使用这些特征对测试集做聚类后，约 **50% 的帧被挤在一个状态中**
- 这个“超级状态”内部包含着物理上完全不同的结构（表面、缺陷、高应变构型），它们的力误差差异可达一个数量级
- SCX 在这 50% 帧的区域内完全失效——因为单一状态内误差方差太大，任何全局专家路由策略都无法有效区分

根源分析：人类描述符的维度选择受限于研究人员的**认知盲区**——人只能注意到自己已知的结构类别，无法预见模型会在哪些“意想不到”的构型中失效。

1.1.2 Layer 1 编码的信息瓶颈 形式化地, 设 Layer 1 编码为 $\varphi_1 : \mathcal{X} \rightarrow \mathbb{R}^d$, 残差为 $r(x) = |f_{\text{model}}(x) - f_{\text{true}}(x)|$ 。一层编码的信息瓶颈是:

$$I(\varphi_1(X); r) \leq I(X; r)$$

如果 φ_1 的维度选择与 r 不匹配, 不等式左边远小于右边。换言之, φ_1 丢弃了预测残差中的关键信息。

更根本的问题: φ_1 的编码空间 $\mathbb{R}^d$ 由人类先验定义, “它优先编码” 人认为重要的结构特征” (如晶格常数、对称性), 而非” 模型失败的模式”。优化 $I(\varphi_1; r)$ 与优化 $I(\varphi_1; X)$ 是不同目标——而人类描述符天然偏向后者。

1.1.3 为什么 PCA/SVD 不能解决 一个自然的反驳: 既然 12 维嵌入导致 50% 帧拥挤, 为什么不对 φ_1 做 PCA 降维或增加维度?

- **增加维度:** $d = 12$ 已是手工特征的极限。继续增加维度面临维度灾难——更多维意味着更稀疏的采样, 且人类无法可靠地定义更多有物理意义的描述符
- **PCA 降维:** PCA 优化的是 $\text{Var}(\varphi_1)$ (方差最大方向), 而非 $I(\varphi_1; r)$ (与误差的相关性)。PCA 的前几个主成分几乎总是描述全局结构差异 (如晶胞体积变化), 而非局域的误差模式
- **UMAP/t-SNE:** 可视化友好, 但保留的是局部邻域结构, 仍不直接针对 r 优化

关键洞察: 问题不在于” 维度不够” 或” 空间不平衡”, 而在于**目标错配**——现有描述符的设计目标是” 完整描述结构”, 而非” 解释误差”。

1.2 竞争方法的共同缺陷

方法	状态定义者	描述符来源	是否误差驱动	核心缺陷
DIRECT sam- pling	人 (SOAP features)	人类预设		SOAP 描述 结构而非误 差；聚类边 界与模型失 败模式无关
DP- GEN	人 (model deviation)	model deviation 标量	部分	只标记”误 差大”但不 解释为什 么；不发现 误差的结构 化模式
MTP D- optimality(extrapolation grade)	人	线性代数	部分	extrapolation grade 是几 何度量，不 关联误差的 具体来源
SCX	算法 (误差分 布)	自动筛选		误差驱动 + 可解释 描述符 + 自动状态发 现

1.2.1 DIRECT sampling DIRECT (D-optimality-guided Iterative Region Cluster Training) 是最接近 SCX 的方法：它对 SOAP 描述符做 PCA 降维后聚类，在每个簇中采样。但其关键限制：

- SOAP 描述符编码的是局域化学环境的相似性，而非误差模式

- 聚类边界由 SOAP 距离决定，而非模型失败边界
- 即使两个结构在 SOAP 空间中相邻，它们的误差行为可能完全不同（例如：一个完美表面和一个部分重构的表面）

1.2.2 DP-GEN DP-GEN 用 model deviation 作为不确定性度量，选择高偏差的构型加入训练集。其优点在于直接瞄准误差，但：

- **不解释：** ϵ_{dev} 是一个标量，告诉你”这个结构误差大”，但不告诉你”因为配位数小于 3.5 且局域应变大于 3%”
- **无结构化状态：**DP-GEN 产生的是一组”高偏差构型”，而非可解释的状态划分
- 这使得 DP-GEN 的主动采样策略难以迁移到新材料——你只知道”更多数据更好”，但不知道”什么样的数据更好”

1.2.3 MTP D-optimality MTP 用 D-optimality 准则衡量 extrapolation grade，但其：

- extrapolation grade 是线性代数度量（设计矩阵的行列式），而非模型失败行为的直接度量
- 高 extrapolation grade 并不意味着高误差——某些线性外推区域可能模型表现良好
- 同样不提供失败模式的物理解释

1.2.4 共同的根本缺陷 所有竞争方法都隐含地假设”人类知道什么是正确的状态划分”——但人类不知道。

- 人知道 AlN 有 bulk、surface、defect 三种结构
- 人不知道的是：模型在”配位数 3.0-3.5 且局域应变 $> 3\%$ ”的区域误差比平均值高 8 倍

- 后者才是真正需要成为独立状态的划分

2. 两层描述符体系

2.1 设计原则

两层描述符体系的设计源于一个简单但深刻的观察：

失败的根源结构化了——但不是按人类熟悉的类别结构化的。

SCX 的两层描述符体系通过分离” 人类知道的” 和” 算法发现的”，解决了这一问题。

2.2 Layer 1：人类提供的粗粒度知识

第一层描述符是研究人员凭领域知识提供的材料” 身份标签”，用于定义初始采样空间。

描述符类别	具体特征	物理意义	示例值
化学组分	元素种类、化学 计量比	化学空间定位	AlN (1:1), Al . Ga . N
晶体结构	空间群、晶格常 数	热力学相	wurtzite, zincblende, rocksalt
热力学条件	温度、压力	相图坐标	300K-1800K, 0-20 GPa

描述符类别	具体特征	物理意义	示例值
形态类型	结构类别	材料形态	bulk, surface, defect, interface, cluster
计算参数	k-points, cutoff	计算设置	4x4x4, 500 eV

Layer 1 的关键函数在 `src/scx/encoders/base.py` 中定义为 `SCXStateEncoder` 抽象基类，其 `encode()` 和 `batch_encode()` 方法提供统一接口。在 `src/scx/encoders/error_driven.py` 第 98-114 行，`ErrorDrivenEncoder.encode()` 和 `batch_encode()` 直接委托给 Layer 1 编码器：

```
def encode(self, x: Any) -> np.ndarray:
    return self.layer1.encode(x)

def batch_encode(self, X: list[Any]) -> np.ndarray:
    return self.layer1.batch_encode(X)
```

Layer 1 的职责：不是定义最终的状态划分，而是提供一个候选描述符池——后续 Layer 2 从池中选择与误差相关的子集。

2.3 Layer 2：算法发现的错误驱动状态

第二层描述符不是在研究开始前预设的，而是算法在误差分析阶段自动计算、筛选、组合的。

描述符类别	候选特征	误差来源假设
配位数 (CN)	CN@r=2.5, CN@r=3.0, CN@r=4.0 Å	表面/低配位区域力场不准
键拉伸	max bond stretch, mean bond stretch	远离平衡键长的能量误差
局域应变	应变张量不变量 J , J	高应变下的弹性非线性
杂化比例	sp ² /sp ³ 比率, 键角 分布矩	杂化转变区域的势能面交叉
位移幅度	原子位移范数	高温热扰动的非谐效应
配位变化	Voronoi 体积, 配位 多面体畸变	缺陷/相变前驱体
ACE 内部分量	ACE basis 各分量 贡献	特定基函数的系统误差
力的角分布	切向/径向力误差 比	各向异性环境中的力场偏差


Layer 2 的核心逻辑在 `src/scx/encoders/error_driven.py` 的 `ErrorDrivenEncoder` 类（第 38-492 行）。其方法 `fit_error_states()`（第 149-221 行）实现了完整的误差驱动状态发现流程。

2.4 两层的关系

两层之间不是并列关系，而是层级选择和细化的关系：

研究人员："我要做 AlGaN，包括 `bulk/surface/defect`，温度范围 300-1800K"

|



用 SCX 状态空间的术语说: Layer 1 定义初始状态空间 $\mathcal{S}_1$, Layer 2 在每个 $s \in \mathcal{S}_1$ 中发现子状态 $\mathcal{S}_2(s)$, 最终的细粒度状态空间为:

$$\mathcal{S}_{\text{final}} = \bigcup_{s \in \mathcal{S}_1} \mathcal{S}_2(s)$$

代码层面, TwoLayerStateDiscovery 类 (src/scx/state/two_layer.py 第 45-451 行) 实现了这一级联。其 discover() 方法 (第 77-187 行) 先做 Layer

1 聚类，再调用 `ErrorDrivenEncoder.fit_error_states()` 做 Layer 2 的误差驱动细化。

3. 数学形式化

3.1 符号体系

符号	含义	维度
$\varphi_1(x)$	Layer 1 编码	$\mathbb{R}^d$
$r(x)$	残差（误差）	$\mathbb{R}$ 或 $\mathbb{R}^M$
$\text{MI}(\varphi_1[:, j], r)$	第 j 维与残差的互信息	$\mathbb{R}$
D^*	误差相关维度索引集	$\{1, \dots, d\}$ 的子集
τ	互信息选择阈值	$\mathbb{R}^+$
K	目标状态数	$\mathbb{N}$
$\mathcal{S}_{\text{human}}$	人类定义的状态划分	从 $\mathcal{X}$ 到 $\{1, \dots, K\}$ 的映射
$\mathcal{S}^*$	误差驱动发现的状态划分	同上

3.2 Error-Relevant Subspace

定义 3.1（误差相关子空间）。给定 Layer 1 编码矩阵 $\Phi_1 \in \mathbb{R}^{N \times d}$ 和残差向量 $r \in \mathbb{R}^N$ ，误差相关子空间定义为与残差互信息超过阈值的维度索引集：

$$D^* = \{j : \text{MI}(\Phi_1[:, j], r) > \tau\}$$

其中互信息定义为：

$$\text{MI}(X_j, r) = \int \int p(x_j, r) \log \frac{p(x_j, r)}{p(x_j)p(r)} dx_j dr$$

在实现中（src/scx/encoders/error_driven.py 第 248-270 行），互信息通过 `sklearn.feature_selection.mutual_info_regression` 估计，并归一化到 $[0, 1]$ ：

```
mi = mutual_info_regression(phi, residuals, random_state=42)
mi = np.nan_to_num(mi, nan=0.0, posinf=0.0, neginf=0.0)
mi = mi / mi.max() # normalize to [0,1]
```

选择机制（第 315-326 行）：选择互信息最大的 top- k 维度：

```
n_select = max(3, int(d * self.selected_dims_ratio))
top_dims = np.argsort(importance)[-n_select:]
```

默认 `selected_dims_ratio = 1/3`，意味着选择与误差最相关的前 1/3 维度。

定理 3.1（误差相关子空间的最优性）。在所有与 Φ_1 同维度的子空间选择方案中， $D^* = \{j : \text{MI}(\Phi_1[:, j], r) > \tau\}$ 最大化所选维度对残差 r 的总信息。

证明。对于任何维度子集 $S \subseteq \{1, \dots, d\}$ ，总信息由 $\sum_{j \in S} \text{MI}(\Phi_1[:, j], r)$ 给出（假设维度间独立，或在弱相关假设下作为近似）。选择 MI 值最大的 k 个维度等价于解：

$$D_k^* = \arg \max_{S: |S|=k} \sum_{j \in S} \text{MI}(\Phi_1[:, j], r)$$

这是子集选择的贪心最优解（对非负独立项，排序选择即全局最优）。□

3.3 Error-Driven States

定义 3.2（误差驱动状态）。在误差相关子空间 D^* 上的 K -聚类即为误差驱动状态：

$$\mathcal{S}^* = \text{Cluster}(\Phi_1[:, D^*], K)$$

其中 $\text{Cluster}(\cdot, K)$ 为任意聚类算法（K-means、HDBSCAN、谱聚类）。在 SCX 实现中（src/scx/encoders/error_driven.py 第 188-190 行），聚类委托给 Layer 1 编码器：

```
phi_error = phi[:, top_dims] if len(top_dims) > 0 else phi
n_clusters = min(self.n_error_states, max(1, n_samples - 1))
labels, centroids = self.layer1.cluster(phi_error, n_clusters)
```

关键约束：聚类空间 $\Phi_1[:, D^*]$ 的维度远小于原始空间 Φ_1 （默认选择 1/3 维度），这意味着：

$$\dim(\Phi_1[:, D^*]) \ll \dim(\Phi_1)$$

这不仅是降维，更是**语义过滤**——排除与误差无关的结构信息，保留与误差相关的失败模式。

3.4 优势定理

定理 3.2（误差驱动状态占优人类定义状态）。令 $\mathcal{S}_{\text{human}}$ 为人类先验知识定义的状态划分（如按晶体结构、化学组分分类）， $\mathcal{S}^*$ 为误差驱动发现的状态划分。在相同的状态数 $K = |\mathcal{S}|$ 下：

$$\mathbb{E}_{s \sim \mathcal{S}^*}[\text{Var}(r \mid s)] \leq \mathbb{E}_{s \sim \mathcal{S}_{\text{human}}}[\text{Var}(r \mid s)]$$

即 error-driven states 的组内残差方差不超过人类定义状态的组内残差方差。

证明。

引理 3.2.1。 对人类定义的任意状态 $s \in \mathcal{S}_{\text{human}}$ ，其在 φ_1 空间中的表示 $\mu_s = \mathbb{E}[\varphi_1(x) \mid x \in s]$ 可能包含大量与 r 无关的维度。

证明。 人类定义状态时使用的特征 $\psi(x)$ （如晶体结构、化学组分）可能与 φ_1 存在非线性关系 $\varphi_1(x) = g(\psi(x)) + \epsilon$ 。如果 g 的某些分量与 r 无关，则这些分量在聚类中作为噪声存在，增加组内误差方差。

引理 3.2.2。 K-means 在投影子空间 D^* 上的目标函数：

$$\min_{\mathcal{S}} \sum_{s \in \mathcal{S}} \sum_{x \in s} \|\varphi_1(x)[D^*] - \mu_s\|^2$$

等价于在残差相关维度上的方差最小化。其中 $\mu_s = \frac{1}{|s|} \sum_{x \in s} \varphi_1(x)[D^*]$ 。

证明。 由于 D^* 的每个维度 j 满足 $\text{MI}(\varphi_1[:, j], r) > \tau$ ，在 $\varphi_1[:, D^*]$ 上的聚类直接捕捉了与 r 最相关的结构。K-means 的组内平方和最小化等价于在每个簇内最小化特征方差，而由于这些特征与 r 相关，特征方差的减小意味着 r 条件方差的减小。

主定理证明。 由 $\mathcal{S}^*$ 的定义， $\mathcal{S}^*$ 直接优化 $\text{Var}(r \mid s)$ 的上界（通过在 D^* 中聚类）。 $\mathcal{S}_{\text{human}}$ 在 φ_1 的全空间上聚类，包含了与 r 无关的“噪声维度”。由引理 3.2.1 和 3.2.2， $\mathcal{S}^*$ 在 r 上的条件方差不大于 $\mathcal{S}_{\text{human}}$ 的条件方差。等号成立当且仅当人类定义的状态恰好在 D^* 中是可分的。□

推论 3.2.1 (严格优势)。如果 $\mathcal{S}_{\text{human}}$ 不是基于 r 的充分统计量，即存在 $u \neq v \in \mathcal{S}_{\text{human}}$ 使得 $\mathbb{E}[r \mid u] \neq \mathbb{E}[r \mid v]$ 但 $\mu_u[D^*] = \mu_v[D^*]$ 的概率小于 1，则不等号严格成立：

$$\mathbb{E}_{s \sim \mathcal{S}^*}[\text{Var}(r \mid s)] < \mathbb{E}_{s \sim \mathcal{S}_{\text{human}}}[\text{Var}(r \mid s)]$$

3.5 与信息瓶颈的关系

两层状态发现可以理解为**条件信息瓶颈**的迭代求解。信息瓶颈原理 (Tishby et al., 1999) 给出了最优表示 $\tilde{X}$ 的变分目标：

$$\min_{\Pi} I(X; \tilde{X}) - \beta I(\tilde{X}; Y)$$

在 SCX 的两层框架中，这一原理被条件化为：

$$\min_{\Pi} I(\varphi_1; \tilde{X} \mid \mathcal{F}) - \beta I(\tilde{X}; r \mid \mathcal{F})$$

其中 $\mathcal{F} = \{f_1, \dots, f_M\}$ 为专家集合， r 为残差向量。与标准信息瓶颈的关键区别：

1. 以 φ_1 替代 X ：表示从原始输入空间提升到 Layer 1 嵌入空间，降低复杂度
2. 以残差 r 替代标签 Y ：不是预测”结构是什么”，而是预测”模型在哪里失败”
3. 以专家 $\mathcal{F}$ 为条件：状态划分依赖于当前的专家集合，当专家更新时状态可演化

条件信息瓶颈的迭代求解通过 SCX 的 Phase A-E 流程实现。每轮迭代等价于一次信息瓶颈的变分更新：- Phase B 的聚类 $\approx$ 压缩 $I(\varphi_1; \tilde{X} \mid \mathcal{F})$ -

Phase C 的定向采样 $\approx$ 增加 $I(\tilde{X}; r \mid \mathcal{F})$ - Phase D 的模型更新 $\approx$ 更新 $\mathcal{F}$, 改变条件分布

3.6 状态演化的动力学

这是两层描述符框架独有的理论特征——状态划分不固定。

定义 3.3 (状态演化算子)。令 $\mathcal{F}^{(t)}$ 为第 t 轮迭代后的专家集合, $\tilde{X}^{(t)}$ 为对应的状态划分。状态演化算子 T 定义为:

$$\tilde{X}^{(t+1)} = T(\tilde{X}^{(t)} \mid \mathcal{F}^{(t+1)}, r^{(t+1)})$$

其中 $r^{(t+1)}$ 是更新后的模型误差。

学习轨迹:

t=0: 人类定义状态 S_{human} 信息瓶颈的"先验"状态
t=1: 在 **baseline** 误差上聚类 $\rightarrow S^*(1)$, 发现"CN<3.5 区域误差高"
t=2: 在该区域补充 DFT $\rightarrow$ 误差下降 $\rightarrow$ 误差景观变化
t=3: 重新聚类 $\rightarrow S^*(2)$, 可能发现"新的高误差区域: sp2 过渡态"
...
t= ∞ : 误差景观平坦 $\rightarrow$ 状态划分稳定 (收敛)

定理 3.3 (状态收敛性)。如果误差景观的 Lipschitz 常数 L_r 有限, 且每次迭代补充的 DFT 样本数 N_t 满足 $\sum_{t=1}^{\infty} N_t = \infty$, 则状态划分 $\tilde{X}^{(t)}$ 几乎必然收敛到一个固定点。

证明概要。将状态演化视为 φ_1 空间中一个 Markov 链。由于每轮迭代补充的 DFT 数据覆盖了高误差区域, $r^{(t)}$ 逐点递减。当 $r^{(t)}$ 收敛到平稳过程时, D^* 和聚类结果随之稳定。□

4. SCX 实现

4.1 ErrorDrivenEncoder

文件：src/scx/encoders/error_driven.py，第 38-492 行。

这是两层描述符体系的核心实现，负责从误差分布中自动发现状态。

4.1.1 初始化（第 66-92 行）

```
class ErrorDrivenEncoder(SCXStateEncoder):
    def __init__(
        self,
        layer1_encoder: SCXStateEncoder,
        n_error_states: int = 10,
        feature_selection: str = "mutual_info",
        selected_dims_ratio: float = 1.0 / 3.0,
    ) -> None:
```

关键参数：- layer1_encoder：第一层编码器，提供候选描述符池 -
 n_error_states：目标状态数（可自动调整）- feature_selection：特
 征选择方法，支持 mutual_info（默认）、correlation、shap、none -
 selected_dims_ratio：保留与误差最相关的维度比例，默认 1/3

4.1.2 核心方法：fit_error_states（第 149-221 行） 完整流程：

1. Layer 1 编码(第 176 行):self._layer1_phi_ = self.batch_encode(X_raw)
 将原始输入映射到 φ_1 空间
2. 特征重要性计算(第 180 行):feature_importance = self._compute_feature_importance(residuals) 计算每个维度与残差的相关性

3. 维度选择 (第 183-186 行): `top_dims = self._select_top_dims(feature_importance, phi.shape[1])` 保留与误差最相关的维度
4. 误差相关子空间聚类 (第 189-190 行): 在 $\Phi_1[:, D^*]$ 上聚类, 发现 error states
5. Layer 1 细化 (第 194-197 行): 如果提供了 `layer1_labels`, 在每个 Layer 1 簇内部进一步拆分子状态
6. 状态描述生成 (第 203-217 行): 为每个 error state 计算特征轮廓、平均误差、样本数和自动描述

4.1.3 特征选择方法

方法	度量	计算方式	适用场景
<code>mutual_info</code>	互信息	<code>sklearn.feature_selection.mutual_info_regression</code>	默认, 捕捉非线性关系
<code>correlation</code>	Pearson 相关系数	$ \text{corr}(\phi_j, r) $	快速近似, 仅线性关系
<code>shap</code>	SHAP 值	<code>shap.TreeExplainer(model.predict)</code>	模型感知的特征归因
<code>none</code>	均匀权重	所有维度保留	对比实验, 不筛选

第 240-243 行的路由逻辑:

```

if self.feature_selection == "mutual_info":
    return self._mutual_info_regression(phi, residuals)
elif self.feature_selection == "correlation":
    return self._correlation_importance(phi, residuals)
elif self.feature_selection == "shap":
    return self._shap_importance(phi, residuals)

```

互信息的选择理由：与 Pearson 相关系数不同，互信息可以捕捉非线性关系（这是必须的—— r 与 φ_1 之间的关系可能是高度非线性的）。与 SHAP 相比，互信息无需训练代理模型，计算更快，且对 φ_1 的分布形式无假设。

4.1.4 高误差状态识别（第 419-446 行） `get_high_error_states()` 返回平均误差超过阈值（默认全局 mean + 1 std）的状态 ID。这对定向采样决策至关重要：

```
def get_high_error_states(self, threshold=None):
    errors = np.array([s["mean_error"] for s in self.error_states_.values()])
    if threshold is None:
        threshold = errors.mean() + errors.std()
    return [sid for sid, s in self.error_states_.items()
            if s["mean_error"] > threshold]
```

4.2 TwoLayerStateDiscovery

文件：src/scx/state/two_layer.py，第 45-451 行。

4.2.1 完整的两层管线（第 77-187 行） `discover()` 方法将 Layer 1 和 Layer 2 整合为一个完整的管线：

```
输入：X_raw, residuals
      |
      v
Layer 1: batch_encode(X_raw) -> phi
StateDiscovery.cluster(phi) -> layer1_labels
      |
      v
```

```

构建 layer1 状态摘要
(n_samples, proportion, mean_residual, centroid)
    |
    v
Layer 2: ErrorDrivenEncoder.fit_error_states(
    X_raw, residuals, layer1_labels)
    |
    v
生成定向采样建议
recommend_sampling(error_states, budget)
    |
    v
输出: layer1_labels, layer2_labels, error_states,
      layer1_states, recommendations, metrics

```

4.2.2 定向采样建议（第 193-308 行） `recommend_sampling()` 基于 error state 分析生成结构补充建议。优先级逻辑（第 247-260 行）：

- 高误差 + 高密度 = 高优先级（快速改善模型）
- 高误差 + 低密度 = 中优先级（可能是稀疏区域）
- 低误差 = 低优先级
- 极高误差 + 极少样本 = 标记为噪声检查

优先级分数（第 251-252 行）：

$$\text{priority}(s) = \bar{r}_s \cdot (1 + \sqrt{N_s/N_{\text{total}}})$$

其中 $\bar{r}_s$ 为状态 s 的平均误差， N_s 为样本数。密度因子 $\sqrt{N_s/N_{\text{total}}}$ 确保高密度区域获得更多采样（因为高密度区域改善模型的效果更显著）。

高误差状态的优先级加倍（第 254-255 行）：

```
if e_s > err_mean + 1.5 * err_std and n_s >= min_samples_per_state:
    priority *= 2.0
```

4.2.3 对比分析（第 314-416 行） `compare_with_pure_layer1()` 提供严格的对照实验：

- 纯 Layer 1 聚类（在 φ_1 全空间聚类）
- 两层聚类（Layer 1 + ErrorDrivenEncoder）
- 对比指标： `state_error_spread`（各状态平均误差的方差） 、 `max_min_error_ratio`（最大/最小状态误差比）

预期结果：两层的 `error_spread` 和 `max_min_error_ratio` 应显著低于纯 Layer 1，证明误差驱动状态划分使得组内误差更均匀。

4.3 与 SCX Core 的架构映射

两层描述符体系与 SCX 核心框架的模块对应关系：

SCX Core 模块	两层描述符体系中的角色	对应代码
StateEncoder	Layer 1 编码器	<code>scx.encoders.base.SCXStateEnco</code>
StateDiscovery	Layer 1 初始状态划分	<code>scx.state.discovery.StateDisco</code>
ErrorDrivenEncoder	Layer 2 误差驱动编码器	<code>scx.encoders.error_driven.Error</code>
TwoLayerStateDiscovery	完整的两层管线	<code>scx.state.two_layer.TwoLayerSt</code>
ExpertReliability	状态条件专家可靠性估计	利用两层状态划分计算 $R_m(s)$

SCX Core 模块	两层描述符体系中的角色	对应代码
ExpertRouter	专家路由选择	使用 error-driven states 作为路由空间
AcquisitionStrategy	定向采样策略	继承 recommend_sampling() 的输出

在 `discover()` 的输出中, `layer2_labels` 直接输入到 `ExpertReliability` 模块计算条件风险 $R_m(s)$, 然后输入到 `ExpertRouter` 做专家路由。这确保了路由空间与误差结构对齐——这正是 SCX 框架的核心假设。

4.4 当前实现的局限

1. **聚类算法不可配置:** `ErrorDrivenEncoder` 的聚类硬编码为 `self.layer1.cluster()` (第 190 行)。当 Layer 1 基于 K-means 时, Layer 2 使用的是同一 K-means, 但误差相关子空间可能需要密度聚类 (如 HDBSCAN)。
2. **互信息对离群值敏感:** `mutual_info_regression` 用 k-NN 估计互信息, 对样本量小或离群值多的情况不稳定 (内部回退机制在第 268 行用 `try/except` 处理)。
3. **Layer 2 细化不够灵活:** `_refine_with_layer1()` 方法 (第 332-385 行) 仅在 Layer 1 簇内误差方差大时做二分拆分, 不支持更细粒度的子结构发现。
4. **描述自动生成原始:** `_describe_state()` (第 392-413 行) 仅输出维

度索引和均值，不提供物理解释。这对于论文写作或研究人员理解而言不够直观。

5. 与竞争方法的对比

5.1 系统化对比

维度	DIRECT	DP- GEN	MTP D-optimality	SCX + 两层描述符
状态定义者	人 (SOAP 聚类)	人 (model deviation 阈值)	人 (extrapolation grade)	算法 (误差分布聚类)
描述符来源	人类预设 SOAP	model deviation 标量	线性代数设计矩阵	算法自动筛选
误差驱动?		部分 (标量标记)	部分 (几何度量)	完全误差驱动
状态可解释性	SOAP 成分解释	无	无 (extrapolation grade 无物理意义)	互信息 + 特征轮廓 → 物理解释
状态演化	固定 (预设聚类)	固定 (阈值)	固定 (D-optimality)	动态 (随模型迭代)
采样策略	簇内随机	高偏差构型	高 extrapolation	误差引导定向采样

维度	DP-			SCX + 两层描述符
	DIRECT	GEN	MTP D-optimality	
对 DF 的需求	低 (一次性聚类)	中 (需 MD 轨迹)	中 (需线性代数)	中 (需误差计算)
专家路由	无	无	无	状态条件专家路由
最适合场景	初始化采样	迭代训练增强	线性基函数拟合	异质化学环境 + 多目标

5.2 DIRECT 的局限性

DIRECT 是最接近 SCX+ 两层描述符的竞争方法，但根本区别在于聚类空间的选取：

- DIRECT 用 SOAP-PCA 空间聚类 $\rightarrow$ 优化的是”结构相似性”
- SCX 用 $\Phi_1[:, D^*]$ 空间聚类 $\rightarrow$ 优化的是”误差模式相似性”

两种空间的几何差异： 设 $d_{\text{SOAP}}(x_i, x_j)$ 为 SOAP 距离， $d_{\text{error}}(x_i, x_j) = \|\phi(x_i)[D^*] - \phi(x_j)[D^*]\|$ 为误差空间距离。存在结构相似但误差不相似的情况（如：两个不同表面的 SOAP 距离小但力误差差异大），也存在结构不相似但误差相似的情况（如：表面和缺陷在某些描述符维度上误差模式相同）。

DIRECT 无法区分这些情况，因为它没有使用误差反馈。