

蒸馏去病毒化：数学根源与多场景推广

日期：2026-06-26 | SCX v4.0 | 从”数据防中毒”到”蒸馏去病毒”的数学基础

一、问题定义：蒸馏为什么会被”中毒”？

1.1 标准知识蒸馏（Knowledge Distillation）回顾

Hinton et al. (2015) 的框架：

Teacher $f_T: X \rightarrow Y$ ，在训练集 $D_{\text{train}} = \{(x_i, y_i^*)\}$ 上训练得到。

蒸馏：Teacher 对一组无标签数据 $\{x_i^{\text{distill}}\}$ 生成软标签或硬标签：

$$y_i^{\text{distill}} = f_T(x_i^{\text{distill}})$$

Student $f_S: X \rightarrow Y$ ，在 $D_{\text{distill}} = \{(x_i^{\text{distill}}, y_i^{\text{distill}})\}$ 上训练。

1.2 问题的数学本质

核心问题是：**Teacher 不是完美的**。定义 Teacher 的状态条件风险：

$$R_T(s) = E_{\{x \sim P(\cdot | s)\}} [(f_T(x), f^*(x))]$$

其中 $f^*(x)$ 是真实标签（未知）， s 是状态。

关键观察： $R_T(s)$ 随 s 变化很大。在 AIN v3 训练中：

状态 s (构型区域)	$R_T(s)$ (力 RMSE, eV/Å)
Phonon 区	0.008
EOS 近平衡区	0.015
Elastic 变形区	0.011
Thermal 1800K 区	0.077
MLMD stress10 区	0.036

Teacher 在 thermal 区的误差是 phonon 区的 **9.6 倍**。

蒸馏中毒机制：

Teacher 在 thermal 1800K 区生成蒸馏数据

- 蒸馏标签 $y_distill = f_T(x) = f^*(x) + _T(s)$ [$_T$ 是 teacher 在状态 s 的偏差]
- Student 拟合: $f_S(x) \quad y_distill = f^*(x) + _T(s)$
- Student 在 thermal 区的误差 $_T(s)$
- Student 从 Teacher 那里"继承"了系统偏差

这和 VASP 数据中毒的不同在于：

VASP 中毒: $f^*(x)$ 本身就错了 (DFT 标签有问题)

蒸馏中毒: $f^*(x)$ 是对的 (DFT 标签正确), 但 Teacher 没有正确学会 $f^*(x)$

两者的共同点: 都是状态条件的——中毒只在特定构型区域发生。

1.3 为什么蒸馏中毒比 VASP 中毒更难诊断

	VASP 数据中毒	蒸馏数据中毒
诊断信号	$f_{max} > 5 \text{ eV/Å}$ (可直接观察)	无直接信号

	VASP 数据中毒	蒸馏数据中毒
标签来源	DFT（已知可靠度）	Teacher（可靠度未知）
可解释性	有——构型不对 $\rightarrow$ 力不对	无——蒸馏输出看起来”正常”
所需的先验	知道物理上 $f_{\max}$ 应该 $< 1 \text{ eV/\AA}$	需要知道 Teacher 在各区域有多可靠
SCX 的角色	自动发现异常 $f_{\max}$	用 Teacher 在训练集上的 residual map 推断

二、现有方法的数学分析

2.1 Hinton KD（2015）——不提纯，全量蒸馏

做法： $T \rightarrow S$ ，所有蒸馏样本一视同仁。

隐式假设：Teacher 在所有输入区域同样可靠。

数学上：这等价于假设 $\text{Var}[f_T(x), f^*(x)] = 0$ ，即 teacher error 的方差可以忽略。但在 MLIP 场景下，Teacher 在不同构型区域的误差差异可达一个数量级——这个假设明显不成立。

2.2 置信度过滤（Confidence-based Filtering）

做法：用 Teacher 的输出熵 $H(f_T(x))$ 或最大 softmax 值作为”置信度”，过滤低置信度的蒸馏样本。

数学形式：

$$D_{\text{clean}} = \{x_i \mid \max_j f_{T^{\{(j)\}}}(x_i) > _confidence\}$$

在 MLIP 场景的失败原因：

Teacher（ACE 线性模型）输出的是能量 E 和力 F，不是概率分布。没有“置信度”概念——E 和 F 是确定性输出。置信度过滤直接不适用。

即使在分类场景下：- 高置信度 低误差。一个模型可以对错误预测高度自信（overconfidence）- 置信度不反映 state-conditioned 的可靠性结构

2.3 集成不一致度过滤（Ensemble Disagreement）

做法：训练 M 个 Teacher（不同初始化/数据子集），用它们输出的方差作为不确定性：

$$\begin{aligned} \sigma_{\text{ens}}(x) &= \text{Var}[f_{T1}(x), f_{T2}(x), \dots, f_{TM}(x)] \\ D_{\text{clean}} &= \{x_i \mid \sigma_{\text{ens}}(x_i) < \sigma_{\text{ens}}\} \end{aligned}$$

优点：比置信度更可靠，捕捉到了模型在不同区域的不确定性。

局限：- 需要训练 M 个 Teacher → 成本高（MLIP 场景下 M 个 ACE 训练 = $M \times 40$ epochs）- 集成方差反映的是“多个 Teacher 之间的一致程度”，不是“Teacher 和真实标签之间的误差”- 如果所有 Teacher 在同一个区域都犯同样的系统偏差（这是常见情况——架构限制导致的），集成方差会很低，但实际误差很大

2.4 Data Shapley / LOO 值

做法：每个训练样本算 Shapley 值或 LOO 误差，高价值样本保留，低价值丢弃。

数学上：Shapley 值在第 i 个样本上计算的是”这个样本对模型性能的边际贡献”。但这是**全局量**——它不区分在不同状态上的贡献。

局限：和置信度一样，Shapley 值不包含状态条件信息。一个对 phonon 区有贡献的样本和一个对 thermal 区有贡献的样本，Shapley 值可能相同，但 Teacher 在 thermal 区的可靠性完全不一样。

2.5 各种方法的根本缺陷

方法	需要的信号	MLIP 适 用？	区分 Teacher 区域可靠 度？	区分状态 条件？
Confidence filtering	softmax/logits	（ACE 无概率输 出）		
Ensemble disagree- ment	M 个模型方差	（可做 但成本高）	部分	
Data Shapley	所有子集重训	（计算量 不可行）		
SCX 去病 毒化	Teacher 在 D_train 上的 residual + Encoder			

所有现有方法都不区分状态——它们把 Teacher 的可靠性当作一个可以在样本级（而不是状态级）解决的同质问题。SCX 的核心贡献就是指出这个假设是错的。

三、SCX 蒸馏去病毒化的数学框架

3.1 核心思想

不是逐样本判断蒸馏数据的质量，而是在状态层面判断 Teacher 的可靠性。

直觉：- 逐样本判断：这个蒸馏帧的力标签对吗？→ 无法回答，因为没有 ground truth - 状态级判断：Teacher 在”thermal 1800K 构型区域”的整体可靠性是多少？→ 可以回答，因为 Teacher 在原始训练集的 thermal 测试帧上已经表现出高误差

3.2 形式化定义

已知（来自 Teacher 训练）：- $D_{\text{train}} = \{(x_i, y_i^*)\}$ — 原始训练集，有 DFT 标签 - Encoder : $X \rightarrow R^d$ — 状态编码器 - Teacher f_T 已训练

可计算（无需额外 DFT）：- Teacher 在 D_{train} 上每个样本的 residual: $r_i = (f_T(x_i), y_i^*)$ - 状态发现：用 聚类 → 状态划分 $S = \{s_1, \dots, s_K\}$ - 每个状态的 Teacher reliability:

$$R_T(s_k) = (1/|s_k|) \sum_{x_i \in s_k} (f_T(x_i), y_i^*)$$

这就是 **Teacher Reliability Map**——本质上是一张”Teacher 在哪些构型区域不可靠”的地图。

蒸馏数据评估：- 蒸馏数据 $D_{\text{distill}} = \{(x_j^{\text{distill}}, f_T(x_j^{\text{distill}}))\}$ - 对每个 x_j^{distill} ，编码 (x_j^{distill}) ，分配到最近状态 s_k - 如果 $R_T(s_k) > \theta$ ，标记 x_j^{distill} 为”病毒帧”

过滤后蒸馏:

$$D_{\text{clean}} = \{x_j^{\text{distill}} \mid R_T(\text{state}(x_j^{\text{distill}})) \}$$

训练 Student f_S 在 D_{clean} 上。

3.3 数学保证（启发式）

Claim: 设 Teacher 在状态 s 上的偏差为 $\epsilon_T(s) = |E[f_T(x) - f^*(x) \mid x \sim s]|$ 。Student 训练在过滤后的蒸馏集上，其在状态 s 上的期望偏差满足：

$$E[|f_S(x) - f^*(x)| \mid x \sim s] \leq \epsilon_{S_{\text{clean}}}(s) + \alpha \cdot \max(0, \epsilon_T(s) - \epsilon_{S_{\text{clean}}}(s))$$

其中 $\epsilon_{S_{\text{clean}}}(s)$ 是 Student 在清洁数据上的本征学习误差，第二项是 teacher 偏差的泄漏。

解读: 通过设置 α 过滤高偏差状态，可以控制 Teacher 系统误差向 Student 的传播。过滤越严格（ α 越小），泄漏越少，但蒸馏数据越少。

权衡:

$$V_S() = |D_{\text{clean}}| / |D_{\text{distill}}| \quad \text{— 保留比例}$$

$$Q_S() = 1 - (\epsilon_T(s) - \epsilon_{S_{\text{clean}}}(s))_+ / \epsilon_T(s) \quad \text{— 质量提升比例}$$

最优 α 的选择取决于：Teacher 在不同状态的可靠性分布、蒸馏数据的覆盖需求、以及 Student 对数据量的敏感度。

3.4 为什么两层描述符在这里特别关键

单层 Encoder（如 MLIPEncoder 12-dim）：
- 粗粒度，50% 帧挤在一个状态
- 无法区分“EOS 近平衡帧”和“thermal 1800K 帧”（它们可能被分到同一个

粗状态) - $\rightarrow$ 一个状态内混杂着 Teacher 可靠和不可靠的子区域 - $\rightarrow$ 过滤时要么”错杀”可靠帧, 要么”漏网”不可靠帧

两层 Encoder (Layer 1 + ErrorDrivenEncoder): - Layer 1 粗聚: 大区域划分 - Layer 2 误差驱动细聚类: 在每个 Layer 1 簇内, 用与 Teacher 误差相关的特征维度再聚类 - $\rightarrow$ 把 Teacher 不可靠的子区域从可靠区域中分离出来 - $\rightarrow$ 精确过滤: 只丢弃 Teacher 确实不可靠的子状态

这就是两层方法在蒸馏去病毒化中的独特价值——它能把”Teacher 的可靠区”和”Teacher 的不可靠区”在同一个粗区域内分开。

四、不同场景的蒸馏去病毒化

4.1 场景 1: MLIP 势函数蒸馏 ($ACE \rightarrow ACE/NEP$)

蒸馏方式: Teacher ACE 势函数对大量构型做单点能 + 力计算 $\rightarrow$ 生成 (构型, 能量, 力) 数据 $\rightarrow$ 训练 Student NEP/轻量 ACE。

中毒风险: Teacher 在 thermal 1800K/MLMD stress10 等极端区域的高误差传播给 Student。

SCX 方案: 1. Teacher 在 D_train (534 帧) 上训练 2. 用 D_train 计算 Teacher per-state 力 RMSE $\rightarrow$ Reliability Map 3. 蒸馏生成 5000 帧 (Teacher 对随机扰动构型做单点计算) 4. SCX Encoder 编码蒸馏帧 $\rightarrow$ 映射到状态 5. 过滤 thermal 1800K 区、MLMD stress10 区的蒸馏帧 6. 用清洁蒸馏集训练 Student

Encoder 选择: MLIPEncoder (12-dim 手工描述符), 用两层方法细化。

4.2 场景 2：图像模型蒸馏 (ResNet-50 $\rightarrow$ MobileNet)

蒸馏方式：Teacher ResNet-50 对无标签图像做推理 $\rightarrow$ (图像, soft label) $\rightarrow$ 训练 MobileNet。

中毒风险：Teacher 在特定图像子空间（如低光照、遮挡、模糊）的识别误差传播给 Student。

SCX 方案：1. Teacher 在 CIFAR/ImageNet 训练集上训练 2. 用验证集计算 Teacher per-state 分类误差 $\rightarrow$ Reliability Map 3. 蒸馏大量无标签图像 4. VisionEncoder (CNN backbone) 编码 $\rightarrow$ 映射到状态 5. 过滤 Teacher 高误差状态（如模糊图像区）的蒸馏帧 6. 用清洁蒸馏集训练 Student

Encoder 选择：VisionEncoder (simple_cnn/resnet backbone)。

和置信度过滤的关键区别：置信度过滤只看 Teacher 的 softmax 输出（“Teacher 自己有没有把握”），SCX 看 Teacher 在相似图像上的实际预测误差（“Teacher 在这个区域真的错得多不多”）。

4.3 场景 3：LLM 蒸馏 (GPT $\rightarrow$ 小模型)

蒸馏方式：Teacher LLM 生成大量 QA 对 $\rightarrow$ (prompt, response) $\rightarrow$ 训练 Student 小模型。

中毒风险：Teacher 在特定语义子空间（如推理类问题、代码生成）的幻觉/错误被蒸馏数据放大传播。

SCX 方案：1. Teacher 在 benchmark 数据集上评估 2. 用评估结果建立 Teacher per-topic 可靠性 $\rightarrow$ Reliability Map 3. 蒸馏生成大量 QA 对 4. LLMEncoder (BERT/GPT embedding) 编码 prompt $\rightarrow$ 映射到语义状态 5. 过滤 Teacher 高误差语义状态（如多步推理）的蒸馏 QA 对 6. 用清洁蒸馏集训练 Student

Encoder 选择：需要实现新的 LLMEncoder——用 sentence embedding（如 BERT）将 prompt 编码为向量，在语义空间中聚类。

独特价值：这是置信度过滤也难以做好的场景——LLM 经常对错误答案高度自信（hallucination with high confidence）。SCX 不依赖 Teacher 的自我评估，而是用外部 benchmark 上的实际表现来刻画可靠性。

4.4 场景 4：仿真保真度蒸馏（Fine-mesh FEM $\rightarrow$ Coarse-mesh + Surrogate）

蒸馏方式：精细网格 FEM 在参数空间采样 $\rightarrow$ (参数, 响应) $\rightarrow$ 训练降阶模型/粗网格修正项。

中毒风险：精细网格 FEM 在特定参数区域（如近共振、近分叉）的数值精度下降时，蒸馏数据带着数值误差。

SCX 方案：1. 精细 FEM 在验证点上评估 2. 用验证误差建立 FEM per-region 可靠性 $\rightarrow$ Reliability Map 3. FEM 在参数空间密集采样 4. TabularEncoder（仿真参数向量）编码 $\rightarrow$ 映射到参数状态 5. 过滤 FEM 高误差参数区域（如近分叉区）的仿真点 6. 用清洁仿真集训练 Student 降阶模型

Encoder 选择：TabularEncoder（仿真参数向量，如 Re, Ma, 载荷幅值...）。

五、和 SCX 已有工作的关系

SCX 四个能力的统一视角：

SCX = 状态条件数据价值判断框架

数据防中毒 (Data Poisoning Defense)

裁判: $f_{\max}$ (VASP 可直接观察)

输出: 标记 VASP 坏帧

AlN v3 验证: $F1=0.585$, 100% 命中

冗余压缩 (Redundancy Compression)

裁判: 当前模型在状态 s 的误差

输出: 低误差高密度区可压缩

AlN v3: phonon 可压缩 50-80%

蒸馏去病毒化 (Distillation De-virus) ← 新

裁判: Teacher 在状态 s 的可靠性 (来自 D_{train})

输出: 过滤 Teacher 不可靠状态的蒸馏数据

原理: 的推广——从 VASP 坏帧到 Teacher 坏预测

专家路由 (Expert Routing)

裁判: 多专家在状态 s 的可靠性差异

输出: 每个状态路由到最可靠专家

原理: 的推广——不止过滤, 还要择优

统一的数学核心: 所有四个能力都建立在对”状态条件可靠性”的估计之上。

唯一的差异是裁判信号的来源:

能力	裁判信号	信号来源
数据防中毒	fmax (VASP 输出)	DFT 计算
冗余压缩	当前模型误差	训练集
蒸馏去病毒化	Teacher 在 D_train 上的误差	Teacher 训练历史
专家路由	多专家可靠性差异	跨专家对比

六、文献调研：知识蒸馏中的质量控制

已有研究方向

方向	代表工作	和 SCX 的区别
Confidence-based	Balan et al. (2022), “Confidence-Aware KD”	置信度 准确度；不适用于确定性模型（如 ACE）
Ensemble-based	Malinin et al. (2020), “Ensemble Distillation”	需 M 个 Teacher；集成方差 真实误差
Data valuation	Ghorbani & Zou (2019), “Data Shapley”	全局量；不区分状态条件
Curriculum KD	Jin et al. (2019), “Curriculum KD”	按难度排序，不按 Teacher 可靠性排序
Contrastive KD	Tian et al. (2020), “CRD”	对比学习改进 representation，不解决 Teacher 局部不可靠

方向	代表工作	和 SCX 的区别
Online KD	Zhang et al. (2018), “Deep Mutual Learning”	互相学习，不区分 Teacher 在哪个区域强
SCX 去病毒化	本文	状态条件 Teacher 可靠性 → 过滤不可靠区域 → 提纯蒸馏数据

关键空白

所有现有 KD 质量控制共同假设：**Teacher 的可靠性是可以在样本级 (per-sample) 判断的**。SCX 的独特贡献是指出这个假设不成立——可靠性是状态级的 (per-state)，因为 Teacher 的误差是系统性集中在特定构型/特征区域的。

SCX 是第一个将”状态条件专家可靠性”概念引入知识蒸馏的工作。

七、实现路线图

Phase 1: MLIP 验证 (AlN v3, 2-3 天)

- 1. 用 AlN v3 534 帧训练 Teacher (Single ACE)
- 2. 计算 Teacher per-state 力 RMSE → Reliability Map
- 3. Teacher 蒸馏 5000 帧 (对 ASE rattle 构型做单点能+力)
- 4. SCX 两层分析蒸馏数据
- 5. 过滤 Teacher 高误差状态 (thermal 1800K, MLMD stress10)

6. 训练 Student A (全量蒸馏集) vs Student B (去病毒蒸馏集)

7. 对比两者在 thermal/MLMD 测试集的力 RMSE

预期: Student B 在 thermal 区力 RMSE 显著低于 Student A。

Phase 2: 图像验证 (CIFAR-100, 1 周)

1. Teacher ResNet-50 → MobileNet-v2 蒸馏

2. SCX 用验证集建立 Teacher per-class/per-feature-region 可靠性

3. 过滤 Teacher 高误差区域的蒸馏数据

4. 对比: Full KD vs Confidence-filtered KD vs SCX-filtered KD

Phase 3: LLM 验证 (需要实现 LLMEncoder)

Phase 4: 公开数据集清洗 (社区贡献)

MPTraj / OC20 / ColabFit → SCX 两层分析 → SCX-cleaned → GitHub Release

八、核心洞见总结

1. 蒸馏中毒是状态条件的——Teacher 的误差不是均匀分布的，它集中在特定构型/特征区域。这是 SCX 能解决问题的根本原因。
2. 所有现有方法都在样本级做判断——置信度、集成方差、Shapley 值都是 per-sample 的。它们不利用”Teacher 在状态 s 整体上不可靠”这个信息。

3. **SCX 的独特价值是把 KD 质量控制从样本级提升到状态级**——用 Teacher 在训练集上的 per-state reliability map 代替 per-sample confidence，做结构化的数据过滤。
4. **两层描述符是精确过滤的关键**——单层粗聚类会把 Teacher 可靠和不可靠的子区域混在一起；两层细化可以在误差子空间中把它们分开。
5. **这是论文级的贡献**——“State-Conditioned Knowledge Distillation” 可以成为 SCX-Theory (Paper 2) 的重要 subsection，或独立的一篇 workshop paper。