

SCX 思想扩展 — 基于 6 Agent 讨论的综合方案

TODO 部分已被 SCX_TODO_2026-06-26.md 替代 (2026-06-26)

本文档保留仅用于所述 8 方向 + 3 阶段 roadmap 的策略参考。
开发待办请查看 SCX_TODO_2026-06-26.md。

生成：2026-06-26 | 基于 356KB agent 输出的交叉分析

0. 现有基础

已完成的 (v0.1.0)

维度	状态
核心数学框架 (R_m(s), SCX_m(s), V(s))	完整定义 + 3 命题证明
数据四分类 (Valuable/Redundant/Noisy/Expert-dep)	规则引擎
Python 包 (30 files, 6269 lines, 259 tests)	全模块实现
合成实验框架	data_generator + run_experiment
数学根源追溯	Kolmogorov → PAC-Bayes
竞争格局分析	6 维度覆盖, Expert Governance 是独有
SCX-Compress (加权 coreset)	算法框架, 缺理论证明

竞争格局中的独特位置

SCX 是唯一覆盖 6 个维度的方法：
数据估值 + 数据选择 + 多专家 + 状态条件 + 噪声检测 + 可学习性

Expert Governance（蒸馏前专家规范化）是 SCX 的独有创新区
——没有已有工作在 MLIP 领域讨论跨专家冲突仲裁和域认证

1. 可发展的 8 个方向

方向 1: SCX-Compress 理论加固 P0

现状：算法已实现（weighted_random/kcenter/herding），缺理论保证。

发展内容：- **Coreset 保真定理：**证明 SCX-Compress 的冗余分数 $D(s)$ 与经验风险近似误差之间的 bound

$$\sup_{f \in \mathcal{F}} \left| \frac{1}{N} \sum_i \ell(f(x_i), y_i) - \frac{1}{N} \sum_j w_j \ell(f(x_j^*), y_j^*) \right| \leq \epsilon(D)$$

- **样本复杂度：**压缩到多少比例还能保持 95% 精度？- 与 **Dataset Distillation** 的等价性：SCX-Compress 在什么条件下等价于梯度匹配蒸馏？

实现：- 在合成数据上验证 bound - CIFAR-100 上对比 coreset baseline (K-Center, Herding, Random)

方向 2: State Discovery 鲁棒性分析 P1

现状：SCX 假设 state discovery 已完成，但真实场景中 state 是 latent 的。

发展内容：- **误指定分析：**如果状态划分有误差（merge 了两个不同状态、split 了一个同质状态），SCX 分类的结果会偏离多少？- **稳定性定理：**证明在什么条件下，状态划分的小扰动不会改变数据分类结果 - **自适应状**

态数: 不预设 K, 根据 SCX 性能自动调整 - **跨描述符稳定性:** 用不同 (ACE/SOAP/MBTR) 重复分析, 量化 cluster 一致性

实现:- 合成实验中引入 controlled mis-specification - 添加 `StateDiscovery.stability_analysis()` 方法

方向 3: SCX 与 Influence Function 的融合 P1

现状: 竞争分析显示 Data Shapley 和 Influence Function 是主要对手, 但 SCX 的 state-level 视角可以与它们互补。

发展内容: - **State-Conditioned Influence:** 传统 influence 是 $\mathcal{I}(x_i, x_j)$, SCX 版本是 $\mathcal{I}_s(x_i, x_j) = \mathcal{I}(x_i, x_j | x_i, x_j \in s)$ - **两阶段估值:** SCX 粗选状态 $\rightarrow$ Influence/Shapley 细选样本 - **与 LESS 的对比:** LESS 用梯度相似性选数据, SCX 用状态价值选数据——两者结合可以同时考虑”对模型影响大”和”状态覆盖不足”

实现:- 在 CIFAR-100 实验中加入 LESS baseline - 实现 `scx/valuation/influence.py`

方向 4: Expert Governance Protocol 形式化 P0

现状: 竞争分析确认这是 SCX 的独有创新区——没有已有工作。但当前只是概念框架。

发展内容: - **Governance 协议:** 形式化定义 expert 进入蒸馏前的必要步骤 1. Gauge Check $\rightarrow$ 2. Domain Certificate $\rightarrow$ 3. Conflict Resolution $\rightarrow$ 4. Anchor Verification $\rightarrow$ 5. Distillation Authorization - **Certification**

Bound: 给定 N 个 DFT anchor, 专家在状态 s 的可靠性估计误差不超过的概率 1- - **协议状态机:** 每个 (expert, state) pair 经过协议后得到一个状态: `certified` / `conditionally_certified` / `uncertified` / `rejected`

实现: - 在 AIN v3 数据上做 retrospective 验证 (已有 DFT 标签可以作为 anchor) - 论文级输出: Protocol specification + Certification theorem

方向 5: SCX 通用 ML 实验 P1

现状: 合成实验框架就绪, 但缺真实数据实验。竞争分析中审稿人攻击点 4b 指出”合成实验不能证明在高维数据上有效”。

发展内容: - **CIFAR-100 + 5 ResNet-18:** 每个 ResNet 在不同类别子集上训练, 模拟 multi-expert 场景 - **UCI Tabular Benchmark:** 10+ 维真实数据, 展示 SCX 不限于图像 - **对比:** Data Shapley (via pyDVL), LOO, Random, Uncertainty, Diversity + SCX - **关键指标:** 相同标注预算下模型精度提升、数据分类准确率

实现: - 扩展现有 `experiments/ml_benchmarks/` - 产出 2-3 张 Figure 级图表

方向 6: SCX 自适应阈值 P2

现状: 四分类的阈值 (`error_high=0.05`, `density_high=0.05`, `consistency_high=0.7`) 是人为预设的。审稿人攻击点 4c 指出这是”参数化的数据描述”。

发展内容: - **数据驱动的阈值选择:** 在合成数据上扫描参数空间, 找到使分类准确率最大的阈值 - **自适应阈值:** 根据数据分布自动调整——高维稀疏数据用更宽松的阈值 - **Bayesian 阈值:** 将阈值建模为随机变量, 用少量标注数据推断后验

实现: - 添加 `DataClassifier.auto_calibrate(X, y_labeled)` 方法 - Sensitivity analysis: 阈值变化 $\pm 20\%$ 对分类结果的影响

方向 7: Online SCX P3

现状: SCX 是批处理模式——收集一批数据后统一分析。

发展内容: - **增量状态更新:** 新数据到来时, 不重新聚类, 而是更新现有状态的质心和半径 - **在线专家可靠性追踪:** 用 exponential moving average 更新 $R_m(s)$ - **数据流版本的四分类:** 实时判断 incoming sample 是 valuable/redundant/noisy/expert-dependent

实现: - `scx/core/online.py` — OnlineSCXFramework - 合成数据流实验

方向 8: SCX Benchmark Suite P3

现状: 没有标准化的评估框架来比较 state-conditioned data valuation 方法。

发展内容: - **Benchmark 设计:** 5-10 个数据集 (合成 + UCI + 图像 + MLIP), 每个有预定义的 ground-truth state - **评估指标:** state discovery accuracy, expert routing precision, data classification F1, acquisition efficiency

- **Baseline 集成:** Random, Uncertainty, Diversity, Data Shapley, LESS, Coreset

实现:- experiments/benchmark/ 目录 - 标准化 API:benchmark.run(method, dataset) → results

2. 优先级矩阵

方向	优先级	理论深度	实验难度	论文贡献	时间估计
1. SCX- Compress 理论	P0	高	低	Paper 4 核心定理	2-4 周
4. Expert Gover- nance Proto- col	P0	高	中	Paper 3 核心框架	4-6 周
2. State Discov- ery 鲁 棒性	P1	高	低	Paper 4 鲁 棒性章节	2-3 周

方向	优先级	理论深度	实验难度	论文贡献	时间估计
3. SCX + Influence 融合	P1	中	中	Paper 4 实验亮点	3-4 周
5. 通用 ML 实验	P1	低	中	审稿人必需	3-5 周
6. 自适应阈值	P2	低	低	Paper 4 消融实验	1-2 周
7. Online SCX	P3	中	中	未来 Paper 5	4-8 周
8. Benchmark Suite	P3	低	高	社区影响力	6-10 周

3. Roadmap

- Phase 1 (1-2 月): 理论加固
- SCX-Compress 定理 + 证明
 - State Discovery 鲁棒性定理
 - Expert Governance Protocol 形式化

Phase 2 (2-3 月): 实验补强

CIFAR-100 + UCI 实验
 SCX + Influence 对比实验
 自适应阈值 sensitivity analysis

Phase 3 (3-6 月): 扩展

Online SCX 原型
 Benchmark Suite 设计

4. 与论文谱系的对应关系

EGP Paper 1 (egp/) → SCX-Theory → SCX-MLIP → SCX-Sim → SCX-Health

方向	贡献给	具体位置
1. SCX-Compress 理论	SCX-Theory (Paper 2)	§4 Data Value → §4.3 Compression Theory
2. State Discovery 鲁棒性	SCX-Theory (Paper 2)	§3 State Discovery → §3.4 Robustness Analysis
3. SCX + Influence 融合	SCX-MLIP (Paper 3)	§6 Experiments → §6.3 Comparison with Influence
4. Expert Governance	SCX-MLIP (Paper 3)	§3 Expert Compilation Protocol
5. 通用 ML 实验	SCX-MLIP (Paper 3)	§6.2 General ML Experiments
6. 自适应阈值	SCX-MLIP (Paper 3)	§5.1 Adaptive Threshold Calibration
7. Online SCX	SCX-Sim (Paper 4)	未来方向

方向	贡献给	具体位置
8. Benchmark Suite	社区贡献	独立 release

本方案综合了 6 份 agent 输出 (01-06, 共 356KB), 交叉分析竞争格局、数学基础、实现现状后提炼。