

SCX 核心数学定义速查

内容来源：AI 对话（2026-06-25），待形式化整理到 theory/ 目录

1. 问题设定

设：- 输入空间 X ，标签空间 Y - 未知真实标注函数 $f^*: X \rightarrow Y$ - M 个专家 $E = \{f_1, f_2, \dots, f_M\}$ - 状态映射 $s: X \rightarrow S$ （或软分配 $p(s|x)$ ）- 表示映射 $\phi: X \rightarrow \mathbb{R}^d$

2. 核心对象

Definition 1: State-Conditioned Expert Risk

$$R_m(s) = E_{x \sim P(\cdot | s)} [(f_m(x), f^*(x))]$$

专家的风险不是全局量 R_m ，而是状态条件量 $R_m(s)$ 。

Definition 2: SCX Reliability

$$SCX_m(s) = P((f_m(x), y) < \tau \mid x \sim s)$$

即专家 m 在状态 s 下做出可接受预测的概率。

Definition 3: State Data Value

$$V(s) = \bar{r}(s) \cdot (s) \cdot L(s) \cdot [1 - D(s)] \cdot \max_m SCX_m(s)$$

其中: - $\bar{r}(s) = E[(f(x), y) \mid s]$ — 当前模型在该状态的平均误差 - $(s) = P(x \mid s)$ — 状态出现概率/质量 - $L(s)$ — 可学习性 (状态内一致、非噪声) - $D(s)$ — 冗余度 (已充分覆盖程度)

Definition 4: Learnability Score

$$L(s) = C(s) \cdot [1 - N(s)]$$

- $C(s)$: 状态内一致性 (标签一致、专家预测一致)
- $N(s)$: 噪声分数

Definition 5: Noise Score (per sample)

$$\text{NoiseScore}(x_i) = r_i \cdot (1/(s_i) +) \cdot [1 - C(s_i)]$$

- 高误差 + 低密度 + 低一致性 → 更像噪声
- 高误差 + 高密度 + 高一致性 → 更像可学习困难状态

3. 数据四分类

类别	条件	动作
Valuable	$\bar{r}(s) \uparrow, (s) \uparrow, C(s) \uparrow,$ $D(s) \downarrow$	acquire
Redundant	$\bar{r}(s) \downarrow, (s) \uparrow,$ $\text{Coverage}(s) \uparrow$	skip

类别	条件	动作
Noisy	$r(x)\uparrow, (s)\downarrow, C(s)\downarrow$	downweight/discard
Expert-dependent	$m: R_m(s) \geq R_n(s)$ for $n \neq m$	route to expert m

4. 专家路由

$$m^*(x) = \arg \min_m \sum_s \pi_s(x) \cdot R_m(s) + \lambda \cdot C_m$$

或权重形式:

$$w_m(x) = \exp(-\lambda \cdot \sum_s \pi_s(x) \cdot R_m(s))$$

5. State-Wise Acquisition

$$s^* = \arg \max_s \bar{r}(s) \cdot \pi(s) \cdot L(s) \cdot [1 - D(s)]$$

先选高价值状态，再在状态内选代表点。

6. 三个核心命题

Proposition 1: Global Expert Ranking Insufficiency

若存在 s, s' 使得:

$$R_a(s) < R_b(s) \quad \text{但} \quad R_a(s') > R_b(s')$$

则不存在全局最优专家排序。专家选择必须状态条件化。

Proposition 2: High-Error Sampling Suboptimality under Noise

高误差集合 $H = H_{\text{learnable}} \cup H_{\text{noise}}$ 。若：

$$P(\Delta R < 0 \mid H_{\text{learnable}}) > P(\Delta R < 0 \mid H_{\text{noise}})$$

则 max-residual sampling ($x^* = \arg \max r(x)$) 浪费标注预算。应改用 state-value sampling ($s^* = \arg \max \bar{r}(s) \cdot \bar{c}(s) \cdot C(s)$)。

Proposition 3: State-Conditioned Weighting

最优专家权重不是全局常数，而是：

$$w_m(x) \propto \exp(-\sum_s \bar{r}_m(s) \cdot R_m(s))$$

7. 与材料 MLIP 的实例化

数学对象	材料实例
x	原子结构/局域环境
y	DFT 能量/力
f_m	ACE/NEP/MACE expert
$\bar{c}(x)$	ACE/SOAP/描述符
s	sp^2 , sp^3 , 断键, 表面, Al-Ga mixed, 高应变
$R_m(s)$	expert 在该结构状态下的误差
acquire	补 DFT 样本
relabel	DFT 仲裁
downweight	清理坏点
route	选择最合适的 expert 标注

8. 论文标题建议

**SCX: State-Conditioned eXpertise for Data Valuation
and Expert-Guided Learning**

中文：SCX：用于数据价值评估与专家引导学习的状态条件专家性框架