

SCX 在 LLM 大模型方向的战略与发展路线图

基于 2026-06-26 与 GPT 的深度讨论整理整理日期：2026-06-26

一、LLM 对 SCX 为什么重要

1.1 GPT 的核心论证：LLM 数据筛选是 SCX 的”远期外延”

GPT 多次强调一个核心判断：

SCX 在 ACE/MLIP 上已经有了强 prototype，这给了你很强的动机去往 LLM 扩展，但 ACE 成功不等于 LLM 会自动成功。

ACE/MLIP 成功的原因是：- 有明确的 DFT oracle (gold label) - 物理 descriptor 状态空间天然有意义 - 冗余非常明显 (AIMD 相邻帧相似) - 物理有约束 (能量守恒、连续性)

而 LLM 场景会遇到四个新难题：1. **表示空间不等于价值空间**：embedding 相近的两条文本，训练价值可能完全不同 2. **误差难以定义**：LLM 数据没有绝对 gold label，只能用代理量 (loss、perplexity、model disagreement 等) 3. **数据价值不是局部可加的**：一条数据的价值依赖已有数据集和当前模型 4. **冗余不能只靠相似度判断**：LLM 中”看起来重复”的数据可能增强鲁棒性

1.2 市场大小对比：材料 vs LLM

维度	材料/MLIP	LLM 数据
市场规模	较小（学术 + 材料公司）	巨大（所有 AI 公司）
竞争强度	低（SCX 是原创方向）	极高（大厂 + 学术都在做）
SCX 优势	强（有 DFT oracle + 物理描述符）	弱（标签模糊、误差不可定义）
商业化难度	中等（需要行业合作）	极高（大厂内部化）

GPT 的最终判断：SCX 不适合正面切入通用 LLM 数据评价，但适合作为远期外延和论文 discussion。

1.3 SCX 在 LLM 数据筛选中的独特优势

SCX 在 LLM 场景的合理定位不是” 又一个更准的 judge”，而是：

状态条件的 judge 可靠性校准系统 / 评价器编排框架。

具体来说，SCX 可以补的是：1. 不同 judge 在不同状态下的可靠性评估：强 GPT 也不是所有状态都强，数学强不一定医学强 2. 高分数据的真实边际价值判断：GPT 喜欢” 漂亮但重复” 的数据，SCX 加入冗余项 3. 低分数据的训练价值识别：覆盖模型薄弱状态的数据可能更值钱 4. 评价器成本感知调度：不同状态切换使用不同评价器，控制成本

二、LLM 实验需求

2.1 为什么要做 LLM 实验

要说服审稿人和客户，SCX 在 LLM 数据筛选上有效，必须有一个最小可行实验。

但 GPT 强调：**LLM 实验不能作为 SCX 的核心实验主战场**。LLM 只能作为 discussion/extension，核心实验应该在 ACE/MLIP 和医学图像上。

2.2 最小可行 LLM demo

	项目	规格
模型	0.5B-3B 小模型	+ LoRA 微调
数据	公开 instruction dataset	(几千到几万条)
硬件	单张 4090	足够

SCX 表示：sentence embedding 或模型 hidden states

误差代理：初始模型 loss 或多模型 disagreement

2.3 实验设计

冗余判断公式：

$$\text{Redundancy}(s) = [1 - \text{mean_r}(s)] * \text{density}(s) * \text{similarity}(s)$$

数据压缩策略：- 保留高误差高密度状态 - 保留边界状态 - 每个冗余状态保留 medoid - 设置随机/多样性对照组

验证对比：- full data (100%) - random 20% - diversity 20% - high-loss 20%
- SCX 20%

目标：SCX 20% 接近 full data 效果，或优于 random/diversity

2.4 具体技术路线

实验 A：冗余压缩 1. 训练基础模型，提取 embedding 2. 计算 loss 作为残差 3. 聚类形成状态 4. 对每个状态计算冗余分数 5. 只保留代表样本，加权训练 6. 对比 full data / random / uncertainty / coreset

实验 B：高误差不等于高价值 1. 人为加入 label noise 2. 比较 high-loss sampling、uncertainty sampling、SCX state-wise acquisition 3. 证明 SCX 优先选高密度、一致、可学习的高误差状态（而非噪声点）

实验 C：专家路由 1. 训练多个不同能力的 judge/expert 2. 估计每个 expert 在不同状态上的可靠性 3. 路由决策：为每个样本选择最可靠且成本最优的 judge

三、发展路线图（时间线）

阶段 1：当前（0-2 月）—— 立住根

关键里程碑： - [] 完成 EGP Paper 1 (ACE gauge-normalized expert merging) - [] 新建私人 SCX 仓库，clean-room 重写代码 - [] 完成 DEVELOPMENT_LOG.md，建立证据隔离 - [] 查 IP 协议，做专利评估 - [] 用 MedMNIST 跑通第一个 SCX-Compress demo - [] 用最小 instruction dataset 跑通第一个 LLM 小实验（验证趋势，不追求大规模）

目标：证明 SCX 不是 PPT，在 ACE/MLIP 上有强原型

阶段 2：1-2 月 —— 建理论地基

关键里程碑： - [] arXiv 发布 SCX-Theory（数学定义 + 可识别性边界 + 合成实验） - [] 抢占命名权：State-Conditioned eXpertise - [] 完成 SCX-Core 开源（轻量版，做到”足以复现论文，不足以替代产品”） - [] 跑通 HAM10000/CheXpert 医学图像实验 - [] 完成 LLM 小规模 SFT 验证实验（证明 SCX 选择的 20% 数据趋势有效） - [] 校外资 IP 律师咨询

目标：建立 SCX 的概念占位和理论地基，LLM 作为 discussion/extension

阶段 3：3-6 月 —— 攻大论文

关键里程碑： - [] 完成 SCX-Sim 大论文（DFT/MLIP + FEM/PDE + 医学图像 + OPC/TCAD toy） - [] 目标期刊：Nature Computational Science / Nature Communications - [] 找 1-2 个甲方做 paid pilot - [] 完成 SCX-Health 开源框架 - [] 构建 SCX Potential Compiler 原型（ACE + NEP + MACE + DeepMD 多专家蒸馏） - [] 完善 LLM 实验：在更大 SFT 数据集上验证 SCX routing 的性价比

目标：证明 SCX 是跨领域的科学/工程仿真数据价值评估框架；LLM 数据评价的论文讨论充分展开


阶段 4：6-12 月 —— 商业化落地

关键里程碑： - [] 成立 SCX Working Group / Consortium（多公司参与） - [] 建立 SCX 认证体系雏形（SCX-certified dataset 等） - [] 找 CEO/COO，自己退到 scientific founder 角色 - [] 将 LLM 方向的 SCX-Judge 作为企业

版功能模块（本地部署 + 数据审计报告）- [] 正式接触华为（健康/昇腾生态）、小米（可穿戴/IoT）、半导体（国产 TCAD/CMP）- [] 将“SCX 评价器编排系统”包装为企业可购买的数据审计服务

目标：从学术论文走向产业标准

LLM 方向在整个路线图中的位置



核心原则：LLM 是远期外延，不是主战场。

四、资源配置

4.1 人力需求

	角色	必要性	来源建议
你自己（学术/算法核心）	必须		SCX 理论 + 核心代码
1-2 名学生/合作者	需要		协助实验和代码
运营负责人	阶段 2-3 需要		管合同、客户、项目排期
工程负责人	阶段 3-4 需要		管平台、部署、CLI 工具

	角色	必要性	来源建议
法务/IP 顾问	优先找		管专利、许可、CLA、合作协议
商务顾问/产业导师	阶段 3 需要		帮你找甲方，不被甲方牵着走

4.2 算力需求

实验类型	最低配置	推荐配置
MedMNIST / 小型图像实验	笔记本 CPU	4090
ACE/MLIP 势函数	单卡 4090	单卡 4090
LLM 最小实验 (0.5B-3B + LoRA)	单卡 4090 (24GB)	单卡 4090
更大规模 LLM SFT	单卡 4090 (可跑 7B 量级)	A100/多卡
SCX-Potential Compiler	单卡 4090	多卡并行
工业级大规模 pipeline	-	需要集群

结论：4090 可以跑通全部学术版 demo，包括 LLM 最小实验。短期不需要追加算力投资。

4.3 资金需求估算

阶段	主要支出	预算估算
阶段 1 (0-2 月)	校外 IP 律师 (1 次咨询)、 论文投稿费	~0.5-1 万
阶段 2 (1-2 月)	arXiv 费用、开源仓库托 管、律师持续咨询	~1-2 万

阶段	主要支出	预算估算
阶段 3 (3-6 月)	Nature 系列 OA 版面费 (~2-4 万人民币)、 vaspkit/软件许可、合作差旅	~5-10 万
阶段 4 (6-12 月)	运营/工程人力、AWS/超算、法务、商务、公司注册	~20-50 万

资金来源建议： 1. 阶段 1-2：个人资金 + 课题组经费（如果切割清楚） 2. 阶段 3：paid pilot 收入 + 赞助研究 3. 阶段 4：membership fee + 企业版授权 + 可能的小规模种子轮

五、优先级决策

5.1 现在必须做（高优先级）

1. **EGP Paper 1 (ACE gauge merging)**: 这是你已有的最强资产，优先出
2. **证据隔离**: 新建私人仓库、clean-room 写代码、写 DEVELOPMENT_LOG.md
3. **IP 保护**: 查协议、问律师、考虑专利/软著/时间戳
4. **SCX-Core 最小实现**: 核心数学 + 合成数据 demo
5. **MedMNIST 跑通**: 用公开医学数据做第一个外部验证
6. **最小 LLM 实验**: 用 0.5B-3B 模型 + LoRA 验证趋势

5.2 可以等论文发表后

- 完整开源 SCX-Health
- 找甲方做 paid pilot
- 建立产业联盟
- 正式公司化
- 大规模 LLM 数据评价实验

5.3 需要合作者/资金后

- TCAD/OPC/CMP 工业数据实验（需要行业合作）
- 多中心临床医学验证（需要医院合作）
- 华为/小米可穿戴数据试点（需要企业协议）
- 分布式大规模 SCX 计算平台（需要算力投资）

5.4 对 LLM 的精力分配建议

GPT 的原始建议值得全文引用：

“大模型不适合做你的主战场。大模型是远期外延，不是核心根据地。”

“大模型数据评价已经被大厂内部化；你一个博士硬冲很难。”

“SCX 在 LLM 上的合理切口：不是造主任医师，而是造医院的分诊、会诊、质控和病历审计系统。”

具体来说：

LLM 方向	该花多少精力	原因
SCX-Theory 中讨论 LLM 作为外延	5%	论文需要提及，但不展开
最小 LLM 实验验证趋势	10%	有比没有好，但不作为核心证据
LLM-as-Judge 可靠性校准论文	15%	如果有余力可以单独发短文
通用 LLM 数据评价平台	不投入	大厂内部在做，很难差异化
垂直领域 LLM 数据审计（法律/医学/科学）	20%	大厂不愿意细做的领域，有空间

最终结论：把 70% 精力放在 SCX-MLIP + SCX-Theory + SCX-Sim 三条主线上，20% 放在医学/视觉开源，10% 放在 LLM 外延验证。

六、SCX 在 LLM 的竞争分析

6.1 现有 9 类主流方法

方法	核心思想	SCX 的关系
规则清洗（FineWeb）	启发式过滤垃圾	SCX 可以补充状态条件质量判断

方法	核心思想	SCX 的关系
质量分类器 (FinerWeb)	强模型标一小批，训练 轻量分类器	SCX 可加” 状态条件”： $Q(x$
Perplexity/Loss (Rho-1)	用 loss 判断 token 价值	SCX 可上升到 state-level selection
目标分布匹配 (DSIR)	选最像目标分布的数据	SCX 可扩展为状态条件 DSIR
Influence/Gradient (LoGra/LESS)	看数据对目标 loss 的贡 献	计算贵，SCX 可在高价值状 态上调用
LLM-as-a- Judge	用强模型评价	SCX 做 judge 可靠性校准
多样性/去重	避免重复数据	SCX 集成到价值公式 $V(x)=Q*(1-D)$
可验证任务 (数学/代码)	用标准答案验证	SCX 设为高可靠专家
Benchmark- driven (DataComp- LM)	最终看训练效果	SCX 的闭环验证

6.2 SCX 的框架优势

现有方法大多是单信号或单阶段，而 SCX 回答的是：

在当前状态 (s)、当前模型 (M)、当前数据集 (D)、可用评价
器集合 (J) 下，这个样本应该采取什么动作？

动作不是只有 keep/drop，而是：