

明日推进 TODO — 2026-06-29

全药物数据库下载 + Yajie 一次性全筛

数据库清单（全量，不仅限于 HIV）

#	数据库	内容	大小	优先级
1	ChEMBL	全量生物活性数据（所有靶点、所有化合物）	~50GB	
2	DrugBank	全部已批准 + 实验性药物，带靶点	~1GB	
3	PubChem BioAssay	全部检测数据	~50GB	
4	BindingDB	全量蛋白-配体结合亲和力	~2GB	
5	PDBbind	蛋白-配体复合物 + 结合亲和力（最精确）	~5GB	
6	TTD (Therapeutic Target Database)	已知治疗靶点 + 对应药物	~500MB	
7	DrugCentral	FDA 批准药物的靶点 + 适应症	~1GB	

#	数据库	内容	大小	优先级
8	Open Targets	靶点-疾病关联 (GWAS+ 文献)	~10GB	
9	PharmGKB	药物基因组学 (基因 × 药物 × 反应)	~2GB	
10	Stanford HIVDB	HIV 耐药突变 (保留)	<100MB	
11	SIDER	药物副作用数据 库	~1GB	
12	STITCH	化合物-蛋白相 互作用网络	~20GB	

硬盘需求

优先级 (必须): ~105GB
强推荐: ~20GB
可选: ~20GB
缓冲+解压: ~50GB

总计: ~200GB

预处理管道

- ☒ 所有 SMILES → 标准化 → ECFP4/MACCS 指纹 (screen_all_databases.py Phase 2)
- ☒ 统一 schema: drug_id, target_id, assay_type, value, units, source_db

- ☑ 去重（同一 drug-target 对在多个数据库中重复出现 = 专家共识）

Yajie 运行

- ☑ N 个专家（每数据库一个 + 物理化学性质 + 结构相似性）
- ☑ 一次性筛选：所有药物 × 所有靶点（screen_all_databases.py）
- ☑ 输出：
 - 高共识 drug-target 对（多数据库交叉验证）→ mt_high_confidence.csv
 - 数据库质量报告（哪个数据库矛盾最多）→ mt_quality_report.json
 - 新兴靶点（高新颖性低共识 → Spring 待复活）→ mt_novel_candidates.csv

验证

- 已知 HIV 药物是否被 Yajie 高分筛出
 - Yajie 是否发现已知的跨界靶点（HIV/自身免疫/炎症共靶点）
 - 假阳性分析（高分但文献无支持的 → 新发现候选）
-

arXiv 投稿

- Paper 1 (Yajie) — PDF 已编译（含 S1-S8）
 - Paper 2 (Spring) — PDF 已编译（13 页）
-

已完成

- ☒ Spring 代码 (1551 行) + Yajie fit() + HIV 审计原型
- ☒ 9 篇论文框架 + 18 层博弈论 + 445 测试全过
- ☒ 全药物数据库下载脚本 `drug-module/scripts/download_databases.py` (~1050 行)
 - 12 个数据库完整覆盖 (ChEMBL, DrugBank, PubChem BioAssay, BindingDB, TTD, Stanford HIVDB, PDBbind, DrugCentral, Open Targets, PharmGKB, SIDER, STITCH)
 - 分层下载 (Tier 1/2/3) 约 205GB
 - 每个数据库写入 `provenance.json` (SHA256 校验、下载日期、版本、URL)
 - 进度条 +ETA、断点续传、认证数据库占位符
 - 自动化解析: ChEMBL SQLite→Parquet, DrugBank XML→Parquet, BindingDB TSV→Parquet, PubChem PUG REST API, Open Targets GraphQL API
- ☒ Yajie 全数据库筛查脚本 `drug-module/scripts/screen_all_databases.py` (~930 行)
 - Phase 1: 加载所有数据库 Parquet/CSV + provenance 元数据
 - Phase 2: SMILES→ECFP4 指纹标准化 + 靶点 →UniProt ID 映射
 - Phase 3: 药物-靶点统一证据矩阵 (行 = 药靶对, 列 = 数据库专家)
 - Phase 4: Yajie 多专家共识评分 (Theorem 1: CLEAN/NOISY/AMBIGUOUS 分类)
 - Phase 5: 8 个输出文件 (MT Gold Standard CSV, 分类摘要, 数据库一致性矩阵, 高置信度对, 分歧报告, 新候选, 质量报告 JSON, 溯源审计 JSON)
 - 完全可溯源: 每对记录包含 `source_databases`, `database_links`,

download__date, mt_report__version