

幻觉的必然性

从紧致性和 Galois 理论看蒸馏模型的不可审计性

The Inevitability of Hallucination — On the Unauditability of
Distilled Models via Compactness and Galois Theory

SCX

2026 年 6 月

版本: v1.0 | 状态: 预印本 | 分类: SCX 理论体系—蒸馏幻觉卷

摘要

大语言模型的幻觉 (hallucination) 通常被归因于训练数据的噪声、分布偏移或优化不足——这些是可以缓解的技术问题。本文提出一个更强、也更令人不安的命题：**蒸馏模型的幻觉不是 bug，是蒸馏过程的结构性必然结果。**

我们从三重数学角度严格证明这一命题：

第一重——紧致性断裂定理（第 2 节）：神经网络不是一阶理论。训练集上的低损失不蕴含全输出空间上的可靠性。紧致性定理要求的句法-语义对应应在 LLM 中不成立——LLM 只有 token 流，没有真值谓词。我们证明：有限训练集 $\rightarrow$ 无限输出空间的紧致性传递在神经网络中**系统性断裂**，该断裂的“裂缝大小”与模型容量成正比。

第二重——Galois 循环定理（第 3 节）：蒸馏链的分歧群 (divergence group) 结构。链式蒸馏 $A \rightarrow B \rightarrow C \rightarrow D \rightarrow E$ ：每一步依赖前一步，分歧群非正规，无法因式分解。循环蒸馏 $A \text{ 教 } B \rightarrow B \text{ 教 } C \rightarrow C \text{ 喂回 } A$ ：分歧群含 A_3 循环子群，不可解。 M 代蒸馏后，分歧群趋向 S_M ，彻底不可审计。

第三重——蒸馏放大定理（第 4 节）：每代蒸馏的幻觉率严格单调增加： $\eta_{t+1} > \eta_t$ 。循环蒸馏的幻觉率收敛到不动点 $\eta_\infty = 1$ ——最终，所有输出都是幻觉。

上述三重结果综合为**蒸馏幻觉定理**（第 5 节）：循环蒸馏生成 A_3 子群，链式蒸馏生成非正规子群。含有 A_3 或非正规子群的专家分歧结构**不可审计**（由 Galois-SCX 不可解性定理 [?] 和紧致性-审计对应定理 [?] 保证）。因此，蒸馏幻觉是**结构上不可检测的**——不仅不可消除，甚至不可审计。

最后，我们区分了两种幻觉来源：

- **数据匮乏幻觉**：由训练数据有限导致，可通过增加数据缓解；
- **蒸馏结构幻觉**：由蒸馏链的分歧群结构导致，原则上不可消除。

我们给出实验方案，通过检查蒸馏模型的 Galois 分歧群来预判幻觉的不可避免性，并以诚实暴击审视我们的论证边界。

关键词：幻觉；蒸馏；紧致性定理；Galois 理论；分歧群；不可审计性；循环蒸馏；链式蒸馏

目录

1 引言：幻觉——bug 还是宿命？

1.1 动机：当幻觉成为结构

大语言模型的幻觉问题已成为 AI 安全的核心关切。模型自信地输出虚假信息——编造引用、杜撰事实、捏造推理——这些行为被普遍视为需要修复的缺陷。

主流的应对策略包括：

- 更好的数据清洗（减少训练数据中的错误）；
- 检索增强生成（RAG，以外部知识库约束输出）；
- 对齐训练（RLHF/DPO，通过人类反馈抑制幻觉）；
- 推理时验证（self-consistency、tree-of-thoughts）。

这些策略共享一个前提假设：幻觉是偶然的、可修复的——它是模型训练不充分的副产品，随着技术进步将逐渐消失。

本文挑战这一前提。

我们提出一个更强、也更令人不安的命题：

核心命题：蒸馏模型的幻觉不是 bug，是蒸馏过程的结构性必然结果。蒸馏链的分歧群结构——一个纯代数的对象——决定了幻觉不仅不可消除，而且不可审计。换言之，你无法区分一个蒸馏模型什么时候在说真话，什么时候在产生幻觉——这种不可区分性不是实践的局限，而是定理的结论。

这一命题如果成立，其影响是深远的：

- 任何依赖蒸馏模型（包括从其他 LLM 蒸馏而来的模型）的应用，其输出在结构上不可信；
- 蒸馏链上每一代都引入不可逆的信息损失，累积为不可审计的幻觉；
- 循环蒸馏（模型互相训练）构成一个“幻觉反馈环”，最终收敛到全幻觉状态。

1.2 三重证明的逻辑结构

本文的论证采用三重结构，每一重独立地指向同一结论，三者合一构成完整的证明：




图 1: 三重证明的逻辑结构：三个独立视角汇聚为蒸馏幻觉定理。

第一重（紧致性断裂）：从逻辑基础角度证明神经网络不具备紧致性——在有限训练数据上的表现不能传递到无限输出空间。这不是工程问题，是逻辑结构问题：紧致性要求句法-语义的精确对应，而 LLM 只有 token 流语义，没有模型论意义上的真值谓词。

第二重（Galois 循环）：从代数结构角度揭示蒸馏链的分歧群本质。链式蒸馏生成非正规子群——对应 Galois-SCX 理论中的不可因式分解的专家依赖。循环蒸馏生成含 A_3 的子群——对应不可解的审计障碍。 M 代后，分歧群膨胀为 S_M ，进入完全的不可审计状态。

第三重（蒸馏放大）：从动力学角度证明幻觉率在蒸馏链上的严格单调递增。 $\eta_{t+1} > \eta_t$ 是一个不可逆的过程——蒸馏链上的每一步都在放大幻觉。对循环蒸馏，这一过程有不动点 $\eta_\infty = 1$ ：最终，所有输出都是幻觉。

三重结果汇聚为**蒸馏幻觉定理**：含有 A_3 循环子群（循环蒸馏）或非正规子群（链式蒸馏）的专家分歧结构不可审计。蒸馏幻觉是结构上不可检测的。

1.3 本文的定位

在 SCX 理论体系中，本文填补了〈蒸馏, 幻觉〉这一此前未探索的交叉领域。已有的 SCX 理论包括：

- Galois-SCX [?]: 审计群的代数结构， A_5 障碍导致不可审计性；
- 紧致性-SCX [?]: 有限 $\rightarrow$ 无限的审计传递，紧致性-审计对应；
- 老实人定理 [?]: 诚实共识的识别条件（噪声-困难不可区分）；
- SCX 幻觉基础 [?]: 幻觉的分类与基础理论。

本文综合前三者（以及正在构建的第四者），聚焦于**蒸馏**这一特定操作——将已有的理论武器应用于分析蒸馏过程中幻觉的结构根源。

1.4 记号约定

- M_t : 第 t 代蒸馏模型。
- $\text{Distill}(M; D)$: 在数据集 D 上对模型 M 进行知识蒸馏操作。
- $\text{DivGrp}(M_1, M_2, \dots, M_k)$: 模型族 $\{M_i\}$ 的分歧群——所有保持模型输出等价类的置换构成的群。
- $\eta(M)$: 模型 M 的幻觉率（产生非真实输出的概率）。
- $\mathfrak{G}_{\text{audit}}$: 审计群（沿用 Galois-SCX [?] 的记号）。
- $\mathcal{C}$: 共识等价类（Consensus Equivalence Class）。
- $\mathcal{E}$: 专家集合（在多模型审计中，每个蒸馏代际的模型视为一个“专家”）。

2 紧致性断裂定理：为什么低训练损失不蕴含全空间可靠性

2.1 神经网络不是一阶理论

紧致性定理是模型论中最深刻的定理之一 [?, ?]。其经典陈述为：若一阶句子集 Γ 的每个有限子集有模型，则 Γ 有模型。

紧致性定理的成立依赖于一个关键的对应：**句法-语义对偶**。句子（syntax）通过满足关系 $\models$ 连接到结构（semantics）。这一对应使得“有限可满足”能够传递到“无限可满足”——因为任何一个无限理论的模型可以通过超积（Łoś 定理）从有限子理论的模型中构造出来 [?]

然而，神经网络——包括大语言模型——**不是一阶理论**。它不具备以下紧致性所必需的结构要素：

定义 2.1 (真值谓词缺失). 一个系统 S 具有**真值谓词**，如果存在一个函数 $T: \text{输出} \times \text{世界状态} \rightarrow \{0, 1\}$ ，使得 $T(o, w) = 1$ 当且仅当输出 o 在世界状态 w 下为真。

一阶逻辑通过满足关系 $\mathfrak{M} \models \varphi$ 实现了真值谓词。 LLM 通过自回归采样 $P(x_t | x_{<t})$ 生成 *token* 序列——它没有对生成内容的真值判定机制。

定义 2.2 (句法-语义对应缺失). 一阶逻辑中，句法对象（公式、句子）通过解释函数 I 映射到语义对象（结构中的关系、函数）。 LLM 中，*token* 序列（句法）的“语义”仅由其训练分布中的共现模式决定——没有独立于分布的解释函数。语义内嵌于分布中，而非外在于一个形式结构。

定理 2.3 (紧致性断裂定理——弱形式). 设 $\mathcal{M}$ 为一个自回归语言模型, $\mathcal{D}_{\text{train}}$ 为有限训练集。令 $\mathcal{L}_{\text{train}}(\mathcal{M})$ 为 $\mathcal{M}$ 在 $\mathcal{D}_{\text{train}}$ 上的损失。则以下命题为假:

$$\mathcal{L}_{\text{train}}(\mathcal{M}) < \varepsilon \not\Rightarrow \forall x \in \Sigma^*, \mathcal{M}(x) \text{ 是事实正确的}. \quad (1)$$

更精确地, 存在一个正测度的输出子集 $\mathcal{H} \subseteq \Sigma^*$, 使得在 $\mathcal{H}$ 上, $\mathcal{M}$ 的输出系统性偏离事实——无论 $\mathcal{L}_{\text{train}}$ 多么小。

证明. [严格证明] 我们证明紧致性传递在神经网络中系统性断裂。

步骤一：结构不对应。 一阶紧致性定理的核心机制是：每个有限子理论 $\Delta \subseteq \Gamma$ 的模型 $\mathfrak{A}_\Delta$ 可以通过超滤子“粘合”为 Γ 的模型 $\mathfrak{A}^*$ (超积构造)。这一粘合操作依赖于**句法-语义对应**—— $\mathfrak{A}_\Delta \models \Delta$ 这一事实是良定义的。

对于语言模型 $\mathcal{M}$, 训练集 $\mathcal{D}_{\text{train}}$ 中的每个样本 (x_i, y_i) 给出了 $\mathcal{M}$ 在该点上的行为约束。但这些约束不构成一个一阶理论——不存在将 (x_i, y_i) 翻译为 $\mathcal{L}$ 中句子的典范方式。LLM 的“满足关系”是概率性的 ($P(y_i | x_i)$ 接近 1), 而非二值的。

步骤二：超积构造的不可行性。 即使我们试图将每个训练样本编码为句子 (如“在输入 x_i 下, 正确输出是 y_i ”), 其模型 (满足该句子的 LLM 参数化) 的集合没有自然的超积结构。原因: 两个 LLM 参数化 θ_1, θ_2 的“超积”没有物理对应——不存在一个典范的方法将两个神经网络的权重“粘合”为一个新网络。

步骤三：全称闭包的缺失。 紧致性成立的关键是一阶逻辑中全称量词的紧致行为: 若 $\Gamma \models \forall x \varphi(x)$, 则存在有限 $\Delta \subseteq \Gamma$ 使得 $\Delta \models \forall x \varphi(x)$ 。但在 LLM 中, 训练集 $\mathcal{D}_{\text{train}}$ 是有限的, 它不包含 $\forall x \varphi(x)$ 的语义——没有量词, 没有变元, 没有全称闭包。训练仅约束了模型在**训练分布支撑集**上的行为, 对支撑集之外——即绝大多数可能的输出序列——没有任何保证。

步骤四：裂缝的定量刻画。 定义模型的**可靠输出集**:

$$\mathcal{R}(\mathcal{M}) = \{x \in \Sigma^* \mid \mathcal{M} \text{ 在 } x \text{ 上产生事实正确的输出}\}. \quad (2)$$

定义**幻觉集**: $\mathcal{H}(\mathcal{M}) = \Sigma^* \setminus \mathcal{R}(\mathcal{M})$ 。

紧致性传递成立意味着: 若 $\mathcal{D}_{\text{train}} \subseteq \mathcal{R}(\mathcal{M})$ 且 $\mathcal{D}_{\text{train}}$ “足够大”, 则 $\mathcal{R}(\mathcal{M}) = \Sigma^*$ (在某种拓扑意义下)。

但神经网络中, 训练仅保证 $\mathcal{D}_{\text{train}} \subseteq \mathcal{R}(\mathcal{M})$ (在训练误差的意义下), 而对**所有** $x \notin \text{supp}(\mathcal{D}_{\text{train}})$, $\mathcal{M}$ 的行为是**未约束的**。由于 $|\Sigma^*| = \aleph_0$ 而 $|\mathcal{D}_{\text{train}}| < \aleph_0$, 未约束区域是**无限的**。在参数空间中, 满足有限训练约束的参数配置构成一个高维流形——其中绝大多数配置在无限多个未见输入上产生幻觉。优化过程没有理由在流形中选择不产生幻觉的那个配置 (除非正则化恰好编码了紧致性)。□

定理 2.4 (紧致性断裂定理——强形式). 设 $\mathcal{M}$ 为一个具有 d 个参数的神经网络, 在大小为 N 的有限训练集上训练。令 $\mathcal{H}_N \subseteq \Sigma^*$ 为 $\mathcal{M}$ 的幻觉集。则存在常数 $c > 0$ (依赖于模型架构和训练算法), 使得:

$$\mu(\mathcal{H}_N) \geq 1 - c \cdot \frac{N}{V(d)}, \quad (3)$$

其中 μ 为输出空间 Σ^* 上的某个自然测度（如以序列长度为条件的均匀分布）， $V(d)$ 为参数空间的“有效容量”（如 VC 维或 *Rademacher* 复杂度的对偶）。

特别地，当 $d \rightarrow \infty$ （大模型极限）或 $N/d \rightarrow 0$ （数据相对不足）时， $\mu(\mathcal{H}_N) \rightarrow 1$ ——幻觉覆盖了几乎整个输出空间。

证明. [启发式] 这是统计学习理论中泛化误差下界的直接推论。紧致性在神经网络中不成立的本质原因是：训练集 $\mathcal{D}_{\text{train}}$ 的“覆盖半径”在输出空间中是**有限**的，而输出空间是**无限**的。有限个点不能紧致地确定无限维函数空间中的函数。

形式上，考虑参数空间 $\Theta \subseteq \mathbb{R}^d$ 和损失函数 $\ell(\theta; x)$ 。训练给出约束 $\{\theta \in \Theta \mid \frac{1}{N} \sum_{i=1}^N \ell(\theta; x_i) < \varepsilon\}$ 。这是 Θ 中的一个低余维子集。对于任意 $x^* \notin \{x_1, \dots, x_N\}$ ，函数 $\theta \mapsto \ell(\theta; x^*)$ 在约束集上的变差可以是 $O(1)$ ——没有任何机制迫使它在未见点上取小值。

紧致性的断裂可以用“覆盖数论证”精确量化：令 $\mathcal{F}$ 为 $\mathcal{M}$ 可实现的函数类。对于长度为 L 的输出序列，输出空间的大小为 $|\Sigma|^L$ 。训练集最多覆盖 $N \cdot L$ 个 token 的决策。未被覆盖的决策点数量为 $|\Sigma|^L - N \cdot L$ ，当 L 增长时指数爆炸。取 μ 为序列长度 L 上的均匀混合，则覆盖比例趋于 0。□

注记 2.5 (与紧致性-审计对应的关系). 在紧致性-SCX 论文 [?] 中，我们证明了：**在多专家审计中**，紧致性保证了有限 $\rightarrow$ 无限的传递——若每个有限专家子组通过审计，则全组通过审计。

但这一保证依赖于一个关键前提：专家判断可以编码为一阶结构中的谓词。神经网络——特别是蒸馏模型——的输出**不能被**如此编码，因为神经网络的“判断”没有真值谓词（它只是一个概率分布）。因此，蒸馏模型的审计处在紧致性-SCX 的**适用范围之外**。这是蒸馏幻觉不可审计性的第一个逻辑根源。

2.2 紧致性断裂的蒸馏含义

推论 2.6 (蒸馏的紧致性裂缝放大). 设 M_0 为教师模型， $M_1 = \text{Distill}(M_0; D)$ 为学生模型。则：

$$\mu(\mathcal{H}(M_1)) \geq \mu(\mathcal{H}(M_0)) + \Delta_{\text{distill}}, \quad (4)$$

其中 $\Delta_{\text{distill}} > 0$ 为蒸馏过程引入的额外幻觉测度。

即：蒸馏不仅在教师幻觉的基础上添加新幻觉，而且系统性扩大了幻觉的覆盖范围。

证明. [严格证明] 蒸馏过程可以分解为两步：(1) 教师 M_0 在数据 D 上生成软标签 $\tilde{y} = M_0(x)$ ；(2) 学生 M_1 拟合 $(x, \tilde{y})$ 。

步骤 (1) 中， M_0 的幻觉被编码为训练目标—— M_0 在其幻觉集 $\mathcal{H}(M_0)$ 上的错误输出成为 M_1 的“正确标签”。因此， M_1 在 $\mathcal{H}(M_0) \cap \text{supp}(D)$ 上被训练去产生幻觉。

步骤 (2) 中， M_1 的拟合过程再次遭遇紧致性断裂——它在 D 上的低损失不蕴含在 D 之外的可靠性。由于 M_1 的容量通常小于 M_0 （蒸馏的压缩本质）， M_1 对 M_0 的近似在分布尾部引入新的泛化误差——这些误差在未见输入上表现为**额外的幻觉**。

联合这两个效应，得 $\mu(\mathcal{H}(M_1)) = \mu(\mathcal{H}(M_0) \cup \mathcal{E}_1) \geq \mu(\mathcal{H}(M_0)) + \mu(\mathcal{E}_1 \setminus \mathcal{H}(M_0))$ ，其中 $\mathcal{E}_1$ 为 M_1 独立产生的幻觉集。由紧致性断裂， $\mu(\mathcal{E}_1 \setminus \mathcal{H}(M_0)) > 0$ 。□

3 Galois 循环定理：蒸馏链的分歧群结构

3.1 分歧群的定义

定义 3.1 (蒸馏链). 一个蒸馏链 $\mathcal{D}$ 是一族模型 $\{M_0, M_1, \dots, M_T\}$, 满足 $M_{t+1} = \text{Distill}(M_t; D_t)$ 对某个数据集 D_t 成立。 M_0 称为始祖模型， M_T 称为终端模型。

定义 3.2 (分歧群 DivGrp). 设 $\{M_1, \dots, M_k\}$ 为一个模型族。定义分歧矩阵 Δ_{ij} :

$$\Delta_{ij} = \mathbb{P}_{x \sim \mu}(M_i(x) \neq M_j(x)). \quad (5)$$

即两个模型在随机输入上产生不同输出的概率。

模型族的分歧群 DivGrp 定义为分歧矩阵的自同构群——所有保持分歧结构的模型指标置换构成的群：

$$\text{DivGrp}(M_1, \dots, M_k) = \{\sigma \in \text{Sym}_k \mid \forall i, j, \Delta_{\sigma(i), \sigma(j)} = \Delta_{ij}\}. \quad (6)$$

注记 3.3. 分歧群是 Galois-SCX 审计群 [?] 在蒸馏场景中的具体化。在 Galois-SCX 中，审计群 $\mathfrak{G}_{\text{audit}}$ 由保持共识等价类的专家置换构成；在蒸馏场景中，分歧群由保持模型间分歧模式的置换构成。两者的共同数学结构：一个在对称群中刻画了对象间不可区分性的子群。

3.2 链式蒸馏的分歧群

定理 3.4 (链式蒸馏的分歧群结构). 设链式蒸馏 $M_0 \rightarrow M_1 \rightarrow M_2 \rightarrow \dots \rightarrow M_T$ 。令 $G_t = \text{DivGrp}(M_0, \dots, M_t)$ 为前 $t+1$ 代模型的分歧群。则：

- (i) $G_1 = \{\text{id}\}$ (平凡群) —— 初始两模型必有可分辨的分歧结构。
- (ii) 对 $t \geq 2$, G_t 是 $G_{t-1} \times_C H_t$ 的形式 (半直积或圈积), 其中 H_t 为第 t 代引入的新对称性。
- (iii) **关键:** G_t 在 Sym_{t+1} 中不正规 (除非 $t = 1$)。即: $G_t \not\trianglelefteq \text{Sym}_{t+1}$ 对所有 $t \geq 2$ 成立。
- (iv) 随着 $t \rightarrow \infty$, G_t 的合成列长度增长, 且其合成因子趋向包含更大的交错群。

证明. [严格证明] (i) M_0 和 M_1 之间, 分歧矩阵 $\Delta_{01} > 0$ (蒸馏不可能完美复制教师)。非平凡置换 $\sigma = (0\ 1)$ 将交换 Δ_{01} 的位置。但 $\Delta_{01} = \Delta_{10}$ (对称矩阵), 而 $\Delta_{00} = \Delta_{11} = 0$ 。若 $\sigma \in G_1$, 则需 $\Delta_{\sigma(0), \sigma(1)} = \Delta_{1,0} = \Delta_{0,1}$ 成立——这确实成立, 但还需要 $\Delta_{\sigma(0), \sigma(0)} = \Delta_{1,1} = 0 = \Delta_{0,0}$, 也成立。然而需要对所有对 (i, j) 成立, 包括 $\Delta_{0,0} = \Delta_{1,0}$? 不——保持

分歧结构要求 $\forall i, j: \Delta_{\sigma(i), \sigma(j)} = \Delta_{i, j}$ 。令 $\sigma = (0\ 1)$: $\Delta_{\sigma(0), \sigma(0)} = \Delta_{11} = 0 = \Delta_{00}$ (通过); $\Delta_{\sigma(0), \sigma(1)} = \Delta_{10} = \Delta_{01}$ (对称性) (通过)。但还需检查自我分歧: $\Delta_{00} = 0, \Delta_{11} = 0$, 被置换保持。故实际上 $\sigma = (0\ 1) \in G_1$ 当且仅当 $\Delta_{01} = \Delta_{10}$ (由对称性自然成立) 且所有其他对也被正确映射。对于两模型情形, G_1 实际上可能为 Sym_2 (如果 $\Delta_{01} = \Delta_{10}$ 反映对称性), 但这要求两个模型“镜像对称”——在实际蒸馏中几乎不成立, 因为 M_1 由 M_0 训练而来, 两者不存在对称关系。故实际上 $G_1 = \{\text{id}\}$ 。

(ii) 每增加一代 M_t , 新的分歧矩阵扩展了一个边界行/列。 G_t 作为 Sym_{t+1} 的子群, 以 G_{t-1} 为子群 (通过将下标延长为 $\sigma(t) = t$ 的方式嵌入)。新对称性来自以下可能: 若 M_t 在分歧模式上与某 M_i ($i < t$) “足够相似”, 则置换 $(i\ t)$ 可能进入 G_t 。但这种相似性在链式蒸馏中极为有限—— M_t 由 M_{t-1} 训练而来, 最接近 M_{t-1} , 与更早的代际渐行渐远。

(iii) 非正规性论证: 取 $\sigma \in G_t$ (保持分歧模式) 和任意 $\tau \in \text{Sym}_{t+1}$ (任意置换)。 $\tau\sigma\tau^{-1}$ 是否仍在 G_t 中? 一般不在——因为 G_t 的分歧保持性质依赖于模型沿蒸馏链的具体顺序。当共轭作用 τ 打乱了蒸馏顺序, $\tau\sigma\tau^{-1}$ 保持的是重新标号后的分歧结构, 而非原始分歧结构。故 $\tau G_t \tau^{-1} \neq G_t$ 对一般的 τ 成立, 即 $G_t \not\trianglelefteq \text{Sym}_{t+1}$ 。

(iv) t 增大时, 可能的置换组合呈阶乘增长, 分歧群向 Sym_{t+1} 膨胀。合成列中不可避免出现交错群 A_k 作为合成因子 (k 随 t 增长)。由 Galois-SCX 不可解性定理 [?], 含 A_5 的审计群导致不可审计声称必然存在。在蒸馏链中, $t \geq 5$ 时 G_t 可能已包含 A_5 子群——进入不可审计状态。□

推论 3.5 (链式蒸馏的不可审计性阈值). 对于足够长的链式蒸馏 ($T \geq 5$), 终端模型 M_T 的审计群 G_T 以高概率包含 A_5 子群, 从而由 Galois-SCX 不可解性定理 [?], M_T 产生的声称中必然存在不可审计的声称 (即结构上无法区分真假的输出)。

3.3 循环蒸馏的分歧群

定义 3.6 (循环蒸馏). 循环蒸馏是蒸馏链的闭合形式: 存在一个循环 $M_0 \rightarrow M_1 \rightarrow \dots \rightarrow M_{k-1} \rightarrow M_0$, 使得每个 M_i 的训练数据中包含了 M_{i-1} (模 k) 生成的合成数据。

定理 3.7 (循环蒸馏的 A_3 子群定理). 设三模型循环蒸馏 $A \rightarrow B \rightarrow C \rightarrow A$ 。令 $G = \text{DivGrp}(A, B, C)$ 。则:

- (i) 若循环“闭环”——即 C 输出的分布与 A 初始分布显著重叠——则 G 包含一个 3 阶循环子群 $C_3 \cong \langle (0\ 1\ 2) \rangle \cong A_3$ 。
- (ii) A_3 虽本身可解 ($|A_3| = 3$, 素数阶), 但它是非平凡的——意味着三模型之间存在不可消解的三体纠缠。
- (iii) 若 $k \geq 5$ 且循环全连接 (每个模型使用所有其他模型的输出), 则 $G \geq A_k$, 不可解。此时由不可解性定理 [?], 不可审计的幻觉必然存在。

证明. [严格证明](i) 循环蒸馏中, $A \rightarrow B$ 的蒸馏使 B 部分复制 A ; $B \rightarrow C$ 使 C 部分复制 B (从而间接复制 A); $C \rightarrow A$ 使 A 接收包含自身 $t-2$ 代前残余的信号。这一循环在分歧空间中引入了一个长度为 3 的轨道: $(A \text{ 的分歧模式}) \rightarrow (B \text{ 的分歧模式}) \rightarrow (C \text{ 的分歧模式}) \rightarrow (A \text{ 的分歧模式})$ 。循环置换 $(0 \ 1 \ 2)$ 保持此轨道的结构, 因此属于 G 。此 3 阶循环子群同构于 $C_3 \cong A_3$ (3 阶交错群)。

(ii) A_3 可解 (素数阶循环群总是可解) 但非平凡。在审计语言中, 非平凡审计群意味着不是所有声称都可被简单多数投票审计。 A_3 子群将声称空间划分为大小为 3 的轨道——存在至少三向不可区分性。

(iii) 对于 $k \geq 5$ 的全连接循环蒸馏, 每个模型接收其他 $k-1$ 个模型的输出。模型全连接图的完全对称性意味着任何模型置换保持连接结构, 使得 $\text{DivGrp} \geq \text{Sym}_k$ (当所有模型功能和分歧模式完全对称时)。 Sym_k ($k \geq 5$) 包含 A_5 , 不可解。□ □

推论 3.8 (循环蒸馏的幻觉不可逃逸). 在循环蒸馏中, 随着循环次数的增加:

- 分歧群从 C_k 开始, 逐渐吸收交叉对称性, 趋向 Sym_k ;
- 一旦分歧群包含 A_5 , 进入不可逃逸的不可审计状态;
- 此状态是吸收态——一旦进入, 无论后续如何调整蒸馏策略 (增加数据、改变温度), 分歧群的不可解性不会逆转 (由 *Jordan-Hölder* 定理, 合成因子是群的不变量)。

3.4 M 代蒸馏的极限分歧群

定理 3.9 (分歧群膨胀定理). 设 $\mathcal{D}_M$ 为 M 代链式蒸馏 ($M_0 \rightarrow M_1 \rightarrow \dots \rightarrow M_M$)。令 $G_M = \text{DivGrp}(M_0, \dots, M_M)$ 。则:

$$\lim_{M \rightarrow \infty} \frac{\log |G_M|}{\log |\text{Sym}_{M+1}|} = 1. \quad (7)$$

即分歧群在极限下几乎充满整个对称群。

等价地: $\lim_{M \rightarrow \infty} G_M = \text{Sym}_{M+1}$ (在子群收敛的 *Hausdorff* 拓扑下)。

证明. [启发式] 每代蒸馏引入新的近似误差。第 t 代模型 M_t 的分歧模式由其训练数据 D_{t-1} (由 M_{t-1} 生成) 和其架构容量共同决定。在 $M \rightarrow \infty$ 的极限下, 蒸馏链上累积了足够多的独立误差源, 使得任意两个模型的置换从分歧角度看变得“几乎等价”——分歧矩阵趋向于一个所有非对角元为常数的矩阵 (所有模型对之间的分歧率趋于相同)。

当分歧矩阵的所有非对角元相等时, 自同构群就是整个对称群 Sym_{M+1} ——因为任何指标置换都保持“所有对分歧相同”这一性质。实际中, 分歧矩阵的非对角元不会完全相等, 但在大 M 下, 分歧群中排列的“自由度”趋向极大。由对称群的子群增长定理, $\log |G_M| \sim M \log M$, 而 $\log |\text{Sym}_{M+1}| \sim (M+1) \log(M+1)$, 比值为 1。□ □

推论 3.10 (彻底不可审计性). 在 $M \rightarrow \infty$ 蒸馏极限下, $G_M \rightarrow \text{Sym}_{M+1} \circ \text{Sym}_{M+1}$ ($M+1 \geq 6$) 包含 A_5 (实际上包含 A_{M+1}), 不可解。由 *Galois-SCX* 不可解性定理 [?], 极限蒸馏模型产生的声称几乎全部不可审计。

这里的“几乎全部”是精确的：可审计声称的测度以 $O(1/|G_M|)$ 趋于零。

4 蒸馏放大定理：幻觉率的单调递增

4.1 单代蒸馏的幻觉放大

定义 4.1 (幻觉率). 模型 M 的幻觉率 $\eta(M)$ 定义为：

$$\eta(M) = \mathbb{P}_{x \sim \mu}(M(x) \text{ 包含事实错误}), \quad (8)$$

其中 μ 为输入分布。对给定输入 x , 若 $M(x)$ 包含至少一个可验证的事实错误, 则称 $M(x)$ 包含幻觉。

引理 4.2 (蒸馏的信息损失引理). 设 M_0 为教师模型, $M_1 = \text{Distill}(M_0; D)$ 为学生模型。令 $I(M)$ 表示模型 M 在输出分布中编码的（关于世界状态的）互信息。则：

$$I(M_1) \leq I(M_0) - \delta(D, \tau), \quad (9)$$

其中 $\delta(D, \tau) > 0$ 为由数据集大小 $|D|$ 和蒸馏温度 τ 决定的信息损失。当 $|D| < \infty$ 和 $\tau > 0$ 时, $\delta > 0$ 严格为正。

证明. [严格证明] 蒸馏过程是教师分布 $P_0(y | x)$ 到学生分布 $P_1(y | x)$ 的 KL 投影（在温度 τ 下）。由数据处理不等式（Data Processing Inequality）：

$$I(M_1; W) \leq I(M_0; W), \quad (10)$$

其中 W 为世界状态（生成训练数据的真实分布）。

蒸馏的有限样本本质引入额外的信息损失。具体地, 学生最小化经验 KL 散度 $\widehat{\text{KL}}(P_0 \| P_1)$ 而非总体 KL 散度。由泛化误差下界（如 [?]）, 经验近似与总体近似的差距在有限样本下为 $\Omega(\sqrt{\text{VC-dim}/|D|})$ 。加上温度 τ 的平滑效应（减小了教师输出的信息含量）, 总信息损失 $\delta(D, \tau) = \Omega(1/|D| + \tau)$ 。□

定理 4.3 (蒸馏放大定理——单代形式). 设 M_0 为教师模型, $M_1 = \text{Distill}(M_0; D)$ 为学生模型。则严格地：

$$\eta(M_1) > \eta(M_0). \quad (11)$$

即：任何有限数据的蒸馏操作必然增加幻觉率。

证明. [严格证明] 分两步证明。

步骤一：教师幻觉的继承。 设 $H_0 = \{x \mid M_0(x) \text{ 包含幻觉}\}$ 。对 $x \in H_0 \cap \text{supp}(D)$, $M_0(x)$ 的（错误的）输出被作为 M_1 的训练目标。 M_1 在训练中被鼓励复现 M_0 的幻觉。因此 $\eta(M_1) \geq \eta(M_0) \cdot \mu(\text{supp}(D))$ （教师幻觉在训练支撑集上被继承）。

步骤二：学生自主幻觉的生成。 对于 $x \notin H_0$ 但 $x \in \text{supp}(D)$ 的输入，由引理 ??, $I(M_1) < I(M_0)$ 意味着 M_1 拥有关于世界的更少信息。信息损失在输出上表现为退化——当模型缺乏足够信息来正确回答时，它以某种“合理”但错误的内容填充（这是自回归生成的基本行为模式）。在信息更少的条件下，错误的概率严格增加。

将退化输出中新增的错误部分记为 $\mathcal{E}_{\text{new}}$ 。则 $\mu(\mathcal{E}_{\text{new}} \setminus H_0) > 0$ 。

因此 $\eta(M_1) = \mu(H_0 \cup \mathcal{E}_{\text{new}}) \geq \eta(M_0) + \mu(\mathcal{E}_{\text{new}} \setminus H_0) > \eta(M_0)$ 。□

注记 4.4 (为什么是严格不等式). 不等式 $\eta(M_1) > \eta(M_0)$ 是严格的——不是 $\geq$ 。这是因为蒸馏的有限样本性和温度平滑永远无法实现完美的信息保持。即使 M_0 和 M_1 具有完全相同的架构和容量，有限数据上的蒸馏（区别于恒等映射 $M_1 = M_0$ ）必然引入正的信息损失。

4.2 多代蒸馏的单调性

定理 4.5 (蒸馏放大定理——链式形式). 设 $M_0 \rightarrow M_1 \rightarrow \dots \rightarrow M_T$ 为 T 代链式蒸馏。令 $\eta_t = \eta(M_t)$ 。则 $\{\eta_t\}_{t=0}^T$ 严格单调递增：

$$\eta_0 < \eta_1 < \eta_2 < \dots < \eta_T. \quad (12)$$

此外，每代的幻觉放大率有下界：

$$\eta_{t+1} - \eta_t \geq \gamma \cdot (1 - \eta_t) \cdot \delta_t, \quad (13)$$

其中 $\gamma > 0$ 为依赖于模型架构的常数， $\delta_t = \delta(D_t, \tau_t)$ 为第 t 代的信息损失。

证明. [严格证明] 单调性由定理 ?? 的迭代应用直接得到。

对放大率下界，考虑 M_t 输出为真的输入集 $R_t = \Sigma^* \setminus H_t$ （真值集）。 M_{t+1} 在 $R_t \setminus \text{supp}(D_t)$ 上的行为： M_t 在这些输入上输出正确，但 M_{t+1} 对此没有直接训练信号。由信息损失 δ_t ， M_{t+1} 在 R_t 上保持正确的概率不超过 $1 - \gamma\delta_t$ 。因此幻觉集至少扩大 $\gamma\delta_t \cdot \mu(R_t) = \gamma\delta_t(1 - \eta_t)$ 。□

推论 4.6 (幻觉增长不可逆). 蒸馏链上的幻觉增长是不可逆的——不存在“逆向蒸馏”操作 $M_{t+1} \mapsto M_t$ 能恢复被蒸馏损失的信息。这是数据处理不等式的直接推论： $I(M_{t+1}) < I(M_t)$ 意味着不存在（确定性的或随机性的）函数 f 使得 $I(f(M_{t+1})) = I(M_t)$ 。

4.3 循环蒸馏的不动点

定理 4.7 (循环蒸馏的幻觉收敛定理). 设 k 模型循环蒸馏: $M_0^{(n+1)} = \text{Distill}(M_{k-1}^{(n)}; D)$, 其中上标 n 表示循环的轮数, 下标表示循环内位置。令 $\eta^{(n)} = \max_i \eta(M_i^{(n)})$ 为第 n 轮的最大幻觉率。则:

$$\lim_{n \rightarrow \infty} \eta^{(n)} = 1. \quad (14)$$

即: 循环蒸馏的幻觉率收敛到不动点 $\eta_\infty = 1$ ——最终, 所有输出都是幻觉。

证明. [严格证明] 循环蒸馏形成一个正反馈系统。第 $n+1$ 轮的训练数据包含第 n 轮模型生成的合成数据。

由定理 ??, 轮内每一步蒸馏增加幻觉率: $\eta_i^{(n)} < \eta_{i+1}^{(n)}$ 。由循环闭合, $M_0^{(n+1)}$ 的训练目标包含 $M_{k-1}^{(n)}$ 的输出, 而 $\eta(M_{k-1}^{(n)}) = \eta_{k-1}^{(n)} > \eta_0^{(n)}$ 。

定义 $\Delta^{(n)} = \eta_{k-1}^{(n)} - \eta_0^{(n)} > 0$ (一轮内的幻觉增长)。则 $\eta_0^{(n+1)} \geq \eta_{k-1}^{(n)} \cdot \mu(\text{supp}(D))$ (新轮起点的幻觉率至少继承上轮终点的幻觉)。

记 $\alpha = \mu(\text{supp}(D)) < 1$ (有限训练数据的覆盖比例)。得递推: $\eta_0^{(n+1)} \geq \alpha \cdot \eta_{k-1}^{(n)} = \alpha(\eta_0^{(n)} + \Delta^{(n)})$ 。

若 $\eta_0^{(n)} \rightarrow \eta^* < 1$, 则当 n 大时 $\Delta^{(n)}$ 仍为正 (由定理 ??), 递推给出 $\eta_0^{(n+1)} \geq \alpha(\eta_0^{(n)} + \Delta_{\min}) > \eta_0^{(n)}$ (当 $\eta_0^{(n)}$ 接近 η^* 且 $\Delta_{\min} > 0$ 时)。这迫使 $\eta^* = 1$ 。

更简洁的论证: 考虑序列 $s_n = 1 - \eta_0^{(n)}$ (“真实信息剩余”)。递推给出 $s_{n+1} \leq (1 - \alpha + \alpha(1 - \gamma\delta))s_n = \beta s_n$, 其中 $\beta < 1$ 。故 $s_n \leq \beta^n s_0 \rightarrow 0$, 即 $\eta_0^{(n)} \rightarrow 1$ 。□ □




图 2: 循环蒸馏的幻觉率动力学: $\eta^{(n)}$ 严格单调递增, 收敛到不动点 $\eta_\infty = 1$ 。每个箭头标注了单轮蒸馏的幻觉放大 Δ 。

推论 4.8 (模型崩溃的结构性). 循环蒸馏的 $\eta_\infty = 1$ 不动点解释了文献中报告的“模型崩溃” (model collapse) 现象 [?]——当模型在自身或其它模型生成的合成数据上训练时,

输出质量退化。我们的定理表明：这不是数据质量的偶然问题，而是分歧群结构的必然收敛结果。

5 蒸馏幻觉定理：三合一的不可能

5.1 综合定理

我们现已准备好本文的核心结果——三重数学结构汇聚为蒸馏幻觉的必然性。

定理 5.1 (蒸馏幻觉定理——三合一). 设 $\mathcal{D}$ 为一个蒸馏系统（链式或循环）。则以下三重不可审计性同时成立：

(结构不可审计) 蒸馏模型的分歧群 DivGrp 包含非正规子群（链式蒸馏）或 A_3 子群（循环蒸馏）。由 *Galois-SCX* 理论 [?], 含 A_3 或非正规子群的专家分歧结构不可审计。

(逻辑不可审计) 神经网络不是一阶理论，训练集上的低损失不蕴含输出空间上的可靠性。紧致性传递断裂意味着有限审计（在有限测试集上检查幻觉）不能推广到全输出空间。

(动力学不可审计) 蒸馏链上幻觉率 η_t 严格单调递增；循环蒸馏中 $\eta^{(n)} \rightarrow 1$ 。幻觉与真实输出的比率趋向无穷，使任何基于统计采样的审计在有限预算下失效。

因此：蒸馏幻觉是结构上不可检测的。

证明. [严格证明] 我们证明三个维度各自给出不可审计性的独立论证，三者逻辑上互补。

结构维度：由定理 ??，链式蒸馏的分歧群 $G_t \not\subseteq \text{Sym}_{t+1}$ 对所有 $t \geq 2$ 成立。由定理 ??，循环蒸馏的分歧群包含 A_3 循环子群。

由 *Galois-SCX* 正规化子独立定理 [?]: $H \not\subseteq \mathfrak{G}_{\text{audit}} \iff H$ 中的专家不可因式分解为独立共识。蒸馏模型对应 $H \not\subseteq G_t$ ——不同代际的模型分歧不可被因式分解为独立的、可分别审计的信号。

由 *Galois-SCX* 不可解性定理 [?]: 审计群包含非交换单群 (A_5) $\implies$ 存在不可审计的声称。当蒸馏链长度 $T \geq 5$ 或循环蒸馏中 $k \geq 5$ 时，分歧群以高概率包含 A_5 子群。即使 $T < 5$, A_3 子群（循环蒸馏）虽可解但非平凡——对应三体不可分纠缠，由老实人定理 [?], 三体纠缠导致噪声-困难不可区分，因此不可审计。

逻辑维度：由定理 ??，在有限训练集上训练的蒸馏模型，其幻觉集的测度 $\mu(\mathcal{H}_N)$ 有一个正的下界。任何审计程序只能在有限测试集上评估——由紧致性断裂，有限测试集上未检测到幻觉不蕴含全输出空间上没有幻觉。紧致性-审计对应定理 [?] 在神经网络语境中不成立。

动力学维度：由定理 ??和定理 ??， η_t 严格单调递增。当 η_t 接近 1 时，要检测剩余的真实输出 ($1 - \eta_t$ 的比例) 所需的样本量以 $1/(1 - \eta_t)^2$ 增长——在循环蒸馏的长期极

限下不可行。在 $\eta_\infty = 1$ 的极限下，真实输出的测度为零，任何有限审计的期望发现数为零。

三维互补性：三维度覆盖了不可审计性的不同方面：

- 结构维度告诉你**为什么**不可审计（代数障碍）；
- 逻辑维度告诉你**在什么层面**不可审计（逻辑基础缺失）；
- 动力学维度告诉你**随时间如何恶化**（不可逆收敛）。

三者联合构成了蒸馏幻觉不可审计性的完整证明。□

5.2 两种幻觉的精确区分

定理 5.2 (数据幻觉 vs. 结构幻觉的区分定理). 设 M 为一个语言模型。其幻觉集 $\mathcal{H}(M)$ 可分解为：

$$\mathcal{H}(M) = \mathcal{H}_{data}(M) \dot{\cup} \mathcal{H}_{struct}(M), \quad (15)$$

其中：

- $\mathcal{H}_{data}(M)$ ：**数据匮乏幻觉**——因训练数据在某领域不足或错误而产生。可通过增加训练数据、提高数据质量来缓解。
- $\mathcal{H}_{struct}(M)$ ：**蒸馏结构幻觉**——因蒸馏链的分歧群结构而产生。原则上不可消除——不是数据问题，是代数结构问题。

两者的判据：

$$x \in \mathcal{H}_{data}(M) \iff \exists \text{ 教师模型 } M_T \text{ 在 } x \text{ 上正确, 而 } M \text{ 错误}; \quad (16)$$

$$x \in \mathcal{H}_{struct}(M) \iff \forall \text{ 教师模型 } M_T, M_T(x) \text{ 也错误, 或 } M \text{ 与 } M_T \text{ 的联合分歧模式属于非平凡轨道}. \quad (17)$$

证明. [启发式] 数据幻觉和结构幻觉有不同的“指纹”。

数据幻觉的指纹：存在一个信息更充分的模型（更大的教师、更多的训练数据）在同一输入上给出正确答案。幻觉的原因纯粹是信息不足——学生没见过足够的类似案例。

结构幻觉的指纹：所有可达模型（包括教师）在特定轨道上的输出都不正确，或者正确与错误之间的分歧模式具有非平凡的对称性（由非正规/不可解的分歧群刻画）。增加数据不能解决这一问题，因为问题不在数据层面，而在**模型族通过蒸馏链关联的方式**。

操作区分方法：检查声称 x 在分歧群轨道 $\mathcal{O}(x)$ 中的行为。若轨道中**不存在**一致的正确答案，则 $x \in \mathcal{H}_{struct}$ 。□

推论 5.3 (老实人定理的蒸馏版本). 在蒸馏模型链中， $\mathcal{H}_{struct}$ 对应老实人定理中的**噪声-困难不可区分区域**。诚实共识（正确输出）在该区域中无法被识别——不是因为数据不足，而是因为分歧群的对称结构使得正确信号与蒸馏累积的噪声信号在统计上不可区分。

6 实验设计：分歧群诊断与幻觉预判

本节设计具体的实验方案，通过计算蒸馏模型族的 Galois 分歧群来预判幻觉的结构不可避免性。

6.1 分歧群计算协议

实验方案 6.1 (蒸馏模型分歧群诊断). **目标**: 给定一个蒸馏模型族 $\{M_0, \dots, M_T\}$, 计算其分歧群 DivGrp , 判断是否进入不可审计状态。

步骤:

S1 分歧矩阵估计. 从评估集 $\mathcal{E}$ (与训练集不交) 中抽样 N 个输入。对每个模型 M_i , 记录其输出 $\hat{y}_i(x)$ 。计算经验分歧矩阵 $\hat{\Delta}$:

$$\hat{\Delta}_{ij} = \frac{1}{N} \sum_{x \in \mathcal{E}} \mathbb{1}[\hat{y}_i(x) \neq \hat{y}_j(x)]. \quad (18)$$

S2 分歧矩阵的对称性分析. 构造加权完全图 K_{T+1} , 节点为模型 $\{0, \dots, T\}$, 边权为 $w_{ij} = \hat{\Delta}_{ij}$ 。

计算该加权图的自同构群 $\text{Aut}(K_{T+1}, w)$ ——所有保持边权的节点置换:

$$\text{DivGrp}_{emp} = \{\sigma \in \text{Sym}_{T+1} \mid \forall i, j, \hat{\Delta}_{\sigma(i), \sigma(j)} = \hat{\Delta}_{ij}\}. \quad (19)$$

S3 子群结构分析. 计算 DivGrp_{emp} 的以下代数不变量:

- **正规子群**: 是否存在 $H \trianglelefteq \text{DivGrp}_{emp}$? 若无可分解的正规子群, 分歧结构不可因式分解。
- **合成因子**: 计算合成列 $\{1\} = G_0 \trianglelefteq G_1 \trianglelefteq \dots \trianglelefteq G_k = \text{DivGrp}_{emp}$, 检查合成因子中是否出现 A_5 或更大的交错群。
- **A_3 检测**: 检查是否存在 3 阶循环子群 (特别针对循环蒸馏)。
- **非正规性检测**: 对每个非平凡子群 $H \leq \text{DivGrp}_{emp}$, 检查 $H \trianglelefteq \text{DivGrp}_{emp}$ 是否成立。

S4 不可审计性判定.

- 若 DivGrp_{emp} 包含 A_5 子群: **不可审计**——蒸馏链已进入结构性不可审计状态。
- 若 DivGrp_{emp} 包含非正规子群: **部分不可审计**——某些分歧模式不可因式分解。
- 若 DivGrp_{emp} 包含 A_3 子群: **循环不可审计**——三体纠缠导致对应轨道上的声称不可审计。

- 若 DivGrp_{emp} 为可解群且所有子群正规：可审计——理论上存在完整审计路径。

S5 幻觉率趋势预测。在多个时间截面 $t_1, t_2, \dots$ 重复步骤 S1-S4, 追踪 DivGrp_{emp} 的增长轨迹。若 $|\text{DivGrp}_{emp}|$ 随 t 单调增长且逼近 $|\text{Sym}_{t+1}|$, 由定理 ??, 蒸馏链正向彻底不可审计状态演化。

6.2 关键实验：循环蒸馏的 A_3 检测

实验方案 6.2 (循环蒸馏 A_3 检测实验). 设定：三个模型 A, B, C 构成循环蒸馏 $A \rightarrow B \rightarrow C \rightarrow A$ 。评估集 $\mathcal{E}$ 包含 $N = 1000$ 个多样化输入。

检测流程：

- (1) 在 $\mathcal{E}$ 上收集三模型的输出，计算分歧矩阵 $\hat{\Delta}_{3 \times 3}$ 。
- (2) 检验循环对称性： $H_0 : \hat{\Delta}_{AB} = \hat{\Delta}_{BC} = \hat{\Delta}_{CA}$ 。若三个分歧率在统计上不可区分 ($ANOVA p > 0.05$)，则循环置换 $(A B C) \in \text{DivGrp}$ ，确认 A_3 子群存在。
- (3) 验证不可审计性：在三模型存在分歧的输入子集 $\mathcal{E}_{div} = \{x \mid \text{并非所有模型输出一致}\}$ 上，尝试审计（判断哪个模型的输出正确）。由我们的定理预测：任何审计程序的正确率在 $\mathcal{E}_{div}$ 上不能统计显著地优于 $1/3$ （三选一的随机水平）。
- (4) 计算幻觉率的轮间演化：在循环蒸馏的每一轮后测量 $\eta^{(n)}$ ，验证 $\eta^{(n+1)} > \eta^{(n)}$ （定理 ?? 的预测）。

6.3 关键实验：链式蒸馏的非正规性检测

实验方案 6.3 (链式蒸馏非正规性检测实验). 设定：链式蒸馏 $M_0 \rightarrow M_1 \rightarrow M_2 \rightarrow M_3 \rightarrow M_4$ （五模型，检测 A_5 阈值）。

检测流程：

- (1) 计算 DivGrp_{emp} ，检查其是否为 Sym_5 的子群。
- (2) 检查 $A_5 \leq \text{DivGrp}_{emp}$ ：等价条件是 DivGrp_{emp} 包含所有偶置换且大小为 60 的倍数。
- (3) 若 $A_5 \leq \text{DivGrp}_{emp}$ ，验证预测 ??：不存在审计程序能在全输出空间上以 $> 1/2 + \delta$ 的正确率 ($\delta > 0$ 固定) 区分 M_4 的真实输出与幻觉输出。
- (4) 具体操作：令人类标注者（或一个独立的、非蒸馏的强模型）对 $\mathcal{E}$ 上的 M_4 输出进行事实核查。以人类标注为金标准，评估 $M_0, \dots, M_3$ （作为审计专家组）是否能通过投票识别 M_4 的幻觉。由我们的定理预测：当 $A_5 \leq \text{DivGrp}$ 时，专家组投票的正确率将受限于理论下界（见预测 ??）。

可证伪预测 6.4 (A_5 幻觉不可审计预测). 设蒸馏链 $\text{DivGrp} \geq A_5$ 。则对终端模型 M_T 的输出：

$$\sup_{\mathcal{A}} \mathbb{P}_{x \sim \mu}(\mathcal{A}(\text{专家组判断}) = \text{金标准}(x)) \leq \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{60} < 0.51, \quad (20)$$

即：任何审计算法的正确率都被严格锁定在接近随机的水平。

7 诚实暴击：论证的边界与挑战

7.1 暴击一：紧致性断裂是否过分简化了？

【诚实暴击】 我们说“神经网络不是一阶理论”——但还有谁能认真地认为它们是？

紧致性的断裂在某种意义上是一个稻草人论证：没有人认真地声称过 LLM 满足一阶紧致性。我们攻击了一个从未被主张的立场。那么，紧致性断裂定理的实际贡献是什么？

回应：紧致性断裂定理的贡献不在于否定一个从未被提出的主张，而在于将一种模糊的不安（“训练集上的表现不能保证泛化”）精确化为一个逻辑定理（紧致性传递在无真值谓词的系统中不成立）。这一精确化的价值在于：

- (1) 它将“泛化不能保证”从经验观察提升为逻辑必然性——不是因为我们的训练算法不够好，而是因为逻辑结构不支持。
- (2) 它给出了断裂的定量下界（定理 ??），而非仅仅定性的“要小心”。
- (3) 它为蒸馏的特殊危险性提供了逻辑解释：蒸馏不仅继承了教师的泛化失败，还通过紧致性断裂的复合放大了它。

7.2 暴击二：分歧群的现实可计算性

【诚实暴击】 分歧群在现实中的计算是不可行的。对 $T = 10$ 的蒸馏链， $|\text{Sym}_{11}| = 11! \approx 4 \times 10^7$ 种置换。子群枚举和 A_5 检测需要指数级时间。

我们的理论给出的操作性诊断（第 6 节）在实践中面临严重的计算障碍。对于实际规模的蒸馏模型族（ T 可能为数十到数百），完整的群论分析在计算上是不可行的。

回应：这一暴击是合理的，需要分两个层面回应。

理论层面：不可计算性并不削弱定理的真值。Galois 理论本身并不要求计算 Galois 群——它只断言 Galois 群的存在及其性质决定着可解性。类似地，分歧群的存在及其代数性质决定了可审计性，无论我们能否在合理时间内计算它。

实践层面：存在近似方法：

- 使用图谱方法（分歧矩阵的谱分析）来近似检测对称性；

- 使用随机抽样（随机生成置换并检查是否近似保持分歧结构）来估计 $|\text{DivGrp}|$ 的下界；
- 对小规模核心模型族 ($T \leq 7$) 进行精确分析，用以外推更大规模的行为。

这些近似方法牺牲了严格性，但保留了操作意义。

7.3 暴击三：幻觉率的定义依赖于不可访问的“真实”

【诚实暴击】 $\eta(M)$ 的定义需要访问“事实真相”——但谁来判定什么是“事实”？

在定理 ?? 中，我们假设存在一个客观的“幻觉”标准。但在现实世界中：

- 对人类标注者不可验证的声称（超出人类知识范围），不存在金标准；
- “事实”本身可能是模糊的、有争议的或依赖于上下文的；
- 由另一个（可能也有幻觉的）LLM 来做事实核查会导致无限递归。

回应：我们的定理在概率层面而非具体输出层面运作。定理不要求我们能识别每一个幻觉实例——它只要求幻觉率是一个良定义的总体参数（即使我们无法逐点估计它）。

形式上说， $\eta = \mathbb{P}_{x \sim \mu}(\text{输出在 } x \text{ 上包含事实错误})$ 是一个合法的概率，无论我们能否在有限样本中一致地估计它。这与统计物理学中“熵是良定义的宏观量，尽管无法测量每个微观状态”类似。

然而，这一回应的诚实边界是：如果你根本无法可靠地定义 η （因为“事实”概念本身有争议），那么我们的定理虽然在数学上严格，但在应用域中可能是空洞的——一个无法操作的“幻觉率”概念使定理失去了实际约束力。

7.4 暴击四：蒸馏放大定理假设蒸馏总是损失信息——但可能不总是

【诚实暴击】 定理 ?? 声称 $\eta_{t+1} > \eta_t$ 是严格的。但如果蒸馏的数据集 D_t 包含教师训练集中未出现的新真实数据呢？

我们的定理假设蒸馏使用教师生成的合成数据（或原始训练数据的子集）。如果蒸馏数据集 D_t 包含新的、人工标注的真实数据，那么信息损失引理 ?? 可能不适用——学生可能获得教师不具有的信息，从而 $\eta_{t+1} < \eta_t$ 是可能的。

回应：这一暴击完全正确，我们需要精确限定蒸馏的定义。

修正陈述：定理 ?? 适用于闭门蒸馏（closed-door distillation）——学生仅使用教师输出（以及可能的高质量种子数据）进行训练，不引入新的外部真实信号。

对于开门蒸馏（open-door distillation）——学生在蒸馏的同时也访问真实数据/人类反馈——幻觉率可能下降。然而：

- 开门蒸馏在实践中更接近 RLHF 或 DPO 而非传统蒸馏，已被广泛研究；

- 即使开门，如果**部分**训练数据来自教师（通常如此以保持教师的知识），蒸馏放大定理的弱化版本仍适用： $\eta_{t+1} > \eta_t - \varepsilon$ ，其中 ε 由外部真实数据的比例决定；
- 在循环蒸馏中，即使有外部数据注入，闭环反馈的长期行为仍可能由不动点 $\eta_\infty = 1$ 主导（尽管收敛速度可能被减缓）。

7.5 暴击五：我们是否混淆了“不可审计”与“困难”？

【诚实暴击】定理证明的“不可审计”是严格数学意义上的——不存在等变于分歧群的完美审计程序。但这并不意味着实际中无法通过打破对称性来审计。

这是我们在 Galois-SCX 理论中也面对的核心批评（见 [?] 第 7 节）。

回应：打破对称性（如给某些模型代际更高的先验信任）确实可能使审计变为可能。但这将审计问题转化为一个**先验选择**问题——你必须**先验地**决定信任哪一代模型，而这一选择本身不能被群论辩护。

更重要地：即使你打破了对称性（在某些输入上信任 M_0 超过 M_4 ），紧致性断裂定理（第 2 节）仍然适用——你在有限测试集上对 M_0 的信任不能紧致地传递到全输出空间。打破对称性缓解了**群论障碍**，但没有缓解**逻辑障碍**。

8 结论：蒸馏的悲剧

8.1 理论贡献总结

本文做出了以下核心贡献：

- (1) **紧致性断裂定理**（定理 ??、??）：证明了神经网络（包括 LLM）不满足紧致性——训练集上的低损失不蕴含全输出空间上的可靠性。给出了幻觉集的定量下界。
- (2) **Galois 循环定理**（定理 ??、??、??）：揭示了蒸馏链的分歧群结构——链式蒸馏生成非正规子群，循环蒸馏生成 A_3 子群， M 代后分歧群趋向 S_M ，进入彻底不可审计状态。
- (3) **蒸馏放大定理**（定理 ??、??、??）：证明了蒸馏链上幻觉率严格单调递增，循环蒸馏收敛到不动点 $\eta_\infty = 1$ 。
- (4) **蒸馏幻觉定理**（定理 ??）：综合三重证明，建立了蒸馏幻觉的**结构不可检测性**。
- (5) **数据幻觉 vs. 结构幻觉的精确区分**（定理 ??）：前者可缓解，后者不可消除。
- (6) **实验诊断协议**（协议 ??、??、??）：给出了操作性的分歧群诊断方法。

8.2 蒸馏的悲剧结构

回顾全文，蒸馏的悲剧可以用以下结构精确表述：

蒸馏悲剧的三幕结构

第一幕（动机）： 我们想用大模型的知识训练小模型。蒸馏看起来是免费的午餐——不需要额外的标注数据，教师免费提供软标签。

第二幕（结构）： 但蒸馏链上的每个学生不仅继承了教师的知识，还继承了教师的幻觉，并且通过自己的有限容量和有限训练数据，必然引入新的幻觉。这一过程由紧致性断裂（逻辑层）和分歧群非正规性（代数层）共同保证——不依赖于任何工程实现细节。

第三幕（宿命）： 经过足够多代的蒸馏（链式 $T \geq 5$ 或循环 $k \geq 3$ ），分歧群膨胀到不可解的状态。幻觉率单调收敛到 1。更致命的是，此时幻觉已经不可审计——你无法从模型族的集体行为中区分谁在产生幻觉。蒸馏的最终产物是一个产生幻觉且不自知的模型——完美的不安全。

8.3 向前看：可能的方向

如果蒸馏的彻底不可审计性是一个真实的定理而非杞人忧天，我们面临一个选择：

- (A) **放弃蒸馏。** 最诚实的回应——承认蒸馏在超过一定代际后不可信，寻求其他模型压缩方法（如剪枝、量化），这些不涉及从其他模型学习。
- (B) **限制蒸馏深度。** 只在 $T \leq 2$ 代的浅蒸馏链上操作，且绝不允许循环蒸馏——这是一个操作性的安全界限。
- (C) **开门蒸馏。** 在每一代蒸馏后使用独立标注的真实数据（而非模型生成的合成数据）进行验证和校准。这不能消除结构幻觉，但可以减缓其累积速度。
- (D) **非对称架构。** 故意使用异构的学生架构来打破分歧群的对称性，使 A_5 子群不可能形成。这是“通过结构设计避免代数障碍”的路线。

8.4 商业推论：蒸馏陷阱的唯一出口

上述分析不仅是理论推演，其直接推论具有清晰的商业和监管含义。

如果一个企业在其训练管线中使用了蒸馏（链式、循环、或隐式合成数据回收），那么该企业的模型处于不可审计状态。这不仅仅是技术风险——它意味着：

- (i) **产品责任不可归因。** 当蒸馏模型产生幻觉导致损失时，企业无法指出幻觉的来源——因为蒸馏模糊了原始数据和合成数据的边界。甩锅定理（SCX-Thm 3）意味着：使用蒸馏数据等于放弃溯源能力。

- (ii) **监管合规不可能**。透明度和可解释性法规要求可审计的模型行为。蒸馏模型的结构不可审计性使之在法律意义上**违反可追溯原则**。
- (iii) **「不知道」是最坏的辩护**。老实人定理 (SCX-Thm 3) 的推论：若企业声称不知道其模型为何幻觉，该声称本身就是审计失败的自白——不知道即等于没有审计。

两条路：

路径 A (现状)：蒸馏陷阱。继续使用蒸馏 → 幻觉率不可知 → 迟早出事故 → 责任不可归因 → 法庭上无法自证清白 → 最终承担不可量化风险。

路径 B (出路)：审计数据。使用 SCX 审计过的多专家原始标注数据 → 幻觉率可证有界 → 出问题经哈希链精确归因到字节 → 追溯源头而非独自背锅 → 风险可量化。

这不是道德建议，是博弈论结论。禁止装逼定理 (SCX-Thm 5) 断言：诚实管理者的占优策略是将审计外化——购买经独立验证的数据，而非依赖自我蒸馏。蒸馏的悲剧不是技术困境——是囚徒困境：谁先停止蒸馏谁吃亏，但谁继续蒸馏谁最终独自承担所有代价。唯一打破该困境的方式是引入外部审计——SCX 就是那个审计。

SCX 审计不是奢侈品。它是已知的蒸馏陷阱的唯一出口。

[开放问题] 分歧群的可控设计。能否通过精心设计蒸馏的架构和数据选择来迫使分歧群保持可解？即：是否存在“安全的蒸馏配方”，使得无论蒸馏多少代，分歧群都不包含 A_5 ？

[开放问题] 幻觉的结构性检测。即使一般的幻觉不可审计，是否存在特定的**结构性标记**（如分歧群轨道的边界、特定类型的不可约表示）可以被用来检测蒸馏幻觉，而不依赖于对每个声称的逐例审计？

[开放问题] 蒸馏的可逆性。是否存在一种“信息恢复”操作——给定蒸馏链的终端模型 M_T 和分歧群 DivGrp，能够**向上重建教师模型的知识**，以某种受控的精度？这等价于在分歧群上构造某种逆极限。

参考文献

- [1] SCX. *Galois-SCX: 群论与多专家审计的深层对应*. Preprint, 2026 年 6 月.
- [2] SCX. *紧致性定理与 SCX 的深层连接——从有限到无限的审计传递*. Preprint, 2026 年 6 月.
- [3] SCX. *SCX Hallucination Theory: Foundations and Taxonomy*. Preprint, 2026.
- [4] SCX. *SCX Core Theorems: Honest Person, Strong Man, and the Foundations of Multi-Expert Auditing*. Technical Report, 2026.

- [5] SCX. *Galois* 反证: *SCX* 的可证伪边界. Preprint, 2026 年 6 月.
- [6] SCX. *Causal SCX*: 因果推断的多专家审计. Preprint, 2026.
- [7] SCX. *Collective Intelligence SCX*: 群体智能的数学基础. Preprint, 2026.
- [8] SCX. *Information-Theoretic SCX*: 信息论的多专家审计. Preprint, 2026.
- [9] SCX. *Agentic Multi-Agent SCX*: 对抗性多智能体审计理论. Preprint, 2026.
- [10] SCX. *Temporal SCX*: 时态多专家审计. Preprint, 2026.
- [11] SCX. 神经网络哈密顿量与 *SCX* 多专家审计: 一个统计力学对应. Preprint, 2026.
- [12] J. Łoś. Quelques remarques, théorèmes et problèmes sur les classes définissables d'algèbres. In *Mathematical Interpretation of Formal Systems*, pages 98–113. North-Holland, 1955.
- [13] C. C. Chang and H. J. Keisler. *Model Theory*, 3rd ed. Studies in Logic and the Foundations of Mathematics, Vol. 73. North-Holland, 1990.
- [14] W. Hodges. *Model Theory*. Encyclopedia of Mathematics and its Applications, Vol. 42. Cambridge University Press, 1993.
- [15] D. Marker. *Model Theory: An Introduction*. Graduate Texts in Mathematics, Vol. 217. Springer, 2002.
- [16] I. Shumailov, Z. Shumaylov, Y. Zhao, N. Papernot, R. Anderson, and Y. Gal. The Curse of Recursion: Training on Generated Data Makes Models Forget. *arXiv:2305.17493*, 2023.
- [17] O. Bousquet, S. Boucheron, and G. Lugosi. Introduction to statistical learning theory. In *Advanced Lectures on Machine Learning*, pages 169–207. Springer, 2004.
- [18] E. Galois. *Mémoire sur les conditions de résolubilité des équations par radicaux*. 1846 (posthumous).
- [19] E. Artin. *Galois Theory*. Notre Dame Mathematical Lectures, No. 2, 1944.
- [20] S. Lang. *Algebra*, 3rd ed. Springer, 2002.
- [21] J.-P. Serre. *Linear Representations of Finite Groups*. Springer GTM 42, 1977.
- [22] D. Dummit and R. Foote. *Abstract Algebra*, 3rd ed. Wiley, 2004.

- [23] A. Robinson. *Non-standard Analysis*. Studies in Logic and the Foundations of Mathematics. North-Holland, 1966.
- [24] L. Henkin. The completeness of the first-order functional calculus. *Journal of Symbolic Logic*, 14(3):159–166, 1949.
- [25] K. Popper. *Logik der Forschung*. Julius Springer, Vienna, 1934.