

势能面不齐——多专家路由中的规范自由度与 MILP 规范固定

Gauge Freedom in Mixture-of-Experts Routing:
Why Expert Output Surfaces Are Not Aligned and How MILP Gauge
Fixing Resolves It

SCX

2026 年 7 月 1 日

版本: v1.0 | 状态: 预印本 | 分类: SCX 理论体系—信息论卷 • 多专家规范篇

摘要

Mixture-of-Experts (MoE) architectures achieve remarkable scale efficiency by routing each token to a subset of specialized sub-networks. However, we identify a fundamental and previously unrecognized problem: the **potential surface misalignment** (势能面不齐, PSM) —different experts define their output surfaces in gauge-inequivalent coordinate systems, making the router’s task of comparing expert relevance ill-posed. We formalize this as a **gauge freedom** in the representation space of deep MoE models: each expert’s output admits a group of transformations $\mathcal{G}_m$ that leave its own training loss invariant but alter cross-expert comparisons. We prove three theorems: (1) the standard linear router $\text{softmax}(W_r x)$ is not gauge-invariant —under gauge transformations $E_m \rightarrow \gamma_m \circ E_m$, the routing scores change unless all experts share the same gauge; (2) the optimal gauge fixing problem reduces to a Mixed Integer Linear Program (MILP) on a calibration set, where integer variables encode expert-token assignments and continuous variables encode gauge parameters; (3) after gauge fixing, the SVD spectrum of multi-expert outputs becomes a provable hallucination detector —a flat spectrum (low ρ_k concentration) implies the model has no internal consensus and is hallucinating. We provide a convex relaxation of the MILP that admits polynomial-time solution, establish bounds on the routing error introduced by gauge misalignment, and connect this work to the author’s prior gauge-fixing framework for atomic cluster expansion (ACE) potentials, showing that both are instances of a deeper principle: **any modular**

system where independently trained components must interact requires explicit gauge alignment before comparison.

Keywords: Mixture of Experts, gauge theory, potential surface alignment, MILP, hallucination detection, SVD spectrum, representation geometry

1 引言：从 ACE 规范到 MoE 规范

在先前的工作中 [EGP 论文, SCX 体系文献], 我们识别并解决了原子团簇展开 (ACE) 势函数合并中的一个核心问题: 系数级规范自由度 (coefficient-level gauge freedom)。具体而言, shared-correction ACE 参数化

$$E(\sigma) = \mathbf{c}_0 \cdot \mathbf{B}(\sigma) + \sum_Z \mathbf{c}_Z \cdot \mathbf{B}_Z(\sigma) \quad (1)$$

在变换

$$\mathbf{c}_0 \rightarrow \mathbf{c}_0 + \mathbf{g}, \quad \mathbf{c}_Z \rightarrow \mathbf{c}_Z - \mathbf{g} \quad (\forall Z) \quad (2)$$

下保持所有物理预测不变, 但不同的独立训练会利用这一自由度走向不同的参数点。我们通过后处理正交投影解决了这一问题, 将规范违反降至机器精度 ($< 10^{-15}$)。

【诚实暴击】但那只是特例。规范自由度远不限于 ACE 参数空间——它在所有模块化多组件系统中普遍存在。MoE 是下一个靶子。

1.1 势能面不齐：问题的直观表述

考虑一个标准的稀疏 MoE 层。设 N 个专家 $\{E_m\}_{m=1}^N$, 每个专家是一个前馈网络 $E_m: \mathbb{R}^d \rightarrow \mathbb{R}^d$ 。路由器给出分数 $g(x) = \text{softmax}(W_r x) \in \mathbb{R}^N$, 选取 $\text{top-k}(g(x), k)$ 激活的专家。

核心直觉: 专家 E_1 和专家 E_2 在训练中各自学会了不同的输出基—— E_1 的输出天然偏高, E_2 的输出天然偏低, 即使对相似的输入也是如此。这个差异在各自训练时被残差连接的后续层自适应地吸收掉了, 因此不被训练损失所感知。但是——

路由器不知道这件事。路由器 $W_r x$ 是一个线性映射, 它比较的是原始专家输出的某种隐式代理。当 E_1 和 E_2 活在不同的坐标系中时, 路由器的比较在数学上是定义不清的。

我们称这种现象为**势能面不齐** (Potential Surface Misalignment, PSM): 每个专家定义了一个函数曲面

$$\mathcal{S}_m = \{(x, \|E_m(x)\|) \in \mathbb{R}^{d+1} : x \in \mathbb{R}^d\}, \quad (3)$$

这些曲面在输出空间的高度、尺度、甚至方向上天然不同——不是因为任何专家错了, 而是因为训练动力学允许一个规范自由度。

1.2 规范群的识别

我们识别出 MoE 表示空间中存在以下规范自由度：

定义 1.1 (MoE 表示空间的规范群). 设专家 E_m 的输出空间为 $\mathbb{R}^d$ 。专家 m 的局部规范群 $\mathcal{G}_m$ 是一个变换集合，满足：对任意 $\gamma \in \mathcal{G}_m$ ，存在残差连接的下游自适应 δ_γ 使得

$$\delta_\gamma \circ \gamma \circ E_m = E_m \quad (4)$$

在训练损失下不可区分。具体而言：

- (i) 平移规范 $\mathcal{G}_m^{trans} = \{T_{\mathbf{b}} : \mathbf{y} \mapsto \mathbf{y} + \mathbf{b}, \mathbf{b} \in \mathbb{R}^d\}$
- (ii) 缩放规范 $\mathcal{G}_m^{scale} = \{S_\alpha : \mathbf{y} \mapsto \alpha \mathbf{y}, \alpha > 0\}$
- (iii) 旋转规范 $\mathcal{G}_m^{rot} = \{R_{\mathbf{Q}} : \mathbf{y} \mapsto \mathbf{Q}\mathbf{y}, \mathbf{Q} \in O(d)\}$

全规范群为这些子群的半直积： $\mathcal{G} = \mathcal{G}^{trans} \rtimes (\mathcal{G}^{scale} \times \mathcal{G}^{rot})$ 。

【诚实暴击】 平移规范是主要的——Post-LN 或 Pre-LN 的 LayerNorm 会吸收平移。旋转规范次之——下游投影矩阵可以学习去旋转。缩放规范最微妙——它部分被 LayerNorm 掩盖，但在残差求和前仍然存在。

1.3 本工作的贡献

- (C1) 识别 MoE 路由的规范不变量缺乏。我们证明标准路由器 $\text{softmax}(W_r x)$ 在 $\mathcal{G}$ 下不是不变的——路由分数随规范变换而改变，使得不同规范下的专家输出不可比较。
- (C2) MILP 规范固定公式化。我们将最优规范固定表述为混合整数线性规划 (MILP)：整数变量编码路由决策，连续变量编码规范参数。我们给出了该 MILP 的紧致松弛和多项式时间近似。
- (C3) 规范对齐的 SVD 幻觉检测。我们证明：固定规范后，多专家对同一查询的输出矩阵的 SVD 谱的集中度是一个可证明的幻觉检测指标——谱平坦意味着模型内部没有共识。
- (C4) 连接 ACE 规范与 MoE 规范。我们展示两者是同一深层原理的实例：任何独立训练的模块化组件在交互前都需要显式的规范对齐。

2 问题设定：MoE 的形式化

定义 2.1 (稀疏 MoE 层). 一个稀疏 MoE 层由以下组件构成：

- N 个专家函数 $E_m: \mathbb{R}^d \rightarrow \mathbb{R}^d$, $m = 1, \dots, N$, 每个专家是一个前馈网络
- 路由器 $r: \mathbb{R}^d \rightarrow \Delta^{N-1}$, $r(x) = \text{softmax}(W_r x)$, 其中 $W_r \in \mathbb{R}^{N \times d}$
- 激活数 $k \in \{1, \dots, N\}$

对输入 token $x \in \mathbb{R}^d$, 输出为

$$y = \sum_{m \in \mathcal{A}(x)} r_m(x) \cdot E_m(x), \quad (5)$$

其中 $\mathcal{A}(x) = \arg \max_k r(x)$ 是得分最高的 k 个专家的索引集合。

假设 2.2 (训练后规范固定). 我们假设训练已完成后进行后处理规范固定 (*post-hoc gauge fixing*), 类似于 EGP 工作中的后处理投影方法。训练阶段不施加规范约束——这已被证明是次优的 [EGP 论文, λ 扫描失败]。

假设 2.3 (残差连接吸收规范差异). 设第 ℓ 层 MoE 的输入为 $x^{(\ell)}$ 。残差连接

$$x^{(\ell+1)} = x^{(\ell)} + \sum_{m \in \mathcal{A}} r_m \cdot E_m(x^{(\ell)}) \quad (6)$$

使得规范自由度得以存在：上游 *LayerNorm* 和下游投影矩阵可以自适应地吸收专家输出的规范变换，使得训练损失在局域上对这些变换不敏感。

假设 2.4 (校准集可用性). 存在一个校准数据集 $\mathcal{D}_{cal} = \{x_i\}_{i=1}^{n_{cal}}$, 大小为 $n_{cal} \geq N \cdot d$, 可用于估计规范参数。校准集不需要标签——仅需要输入 token。这满足实际中常见的情况。

3 规范自由度的形式化

3.1 路由器的规范非不变性

定理 3.1 (路由器的规范非不变性). [严格证明] 设路由器 $r(x) = \text{softmax}(W_r x)$, 其中 $W_r \in \mathbb{R}^{N \times d}$ 在训练后固定。对专家 m 施加平移规范变换 $E_m \rightarrow E_m + \mathbf{g}_m$ (其中 $\mathbf{g}_m \in \mathbb{R}^d$), 路由分数在变换不改变——即 $r(x)$ 对 E_m 输出的显式依赖为零, 因为 $r(x)$ 不接收 $E_m(x)$ 作为输入。

然而, 路由器在训练中被隐式地调谐以匹配专家的输出分布。具体而言, 训练期间路由器的梯度为

$$\nabla_{W_r} \mathcal{L} = \mathbb{E}_x \left[\frac{\partial \mathcal{L}}{\partial y} \cdot \frac{\partial y}{\partial r} \cdot \frac{\partial r}{\partial W_r} \right] \quad (7)$$

其中 $\partial y / \partial r$ 依赖于 $E_m(x)$ 的值。因此, W_r 的最优值依赖于训练时专家的输出分布。当训练后施加规范变换 $E_m \rightarrow E_m + \mathbf{g}_m$, 训练时的 W_r^* 不再是新规范下的最优路由器。

具体而言, 设原始规范 (训练时) 的专家输出为 $\{E_m^{\text{train}}\}$, 路由器为 W_r^{train} 。在规范变换后, 专家输出变为 $\{E_m^{\text{train}} + \mathbf{g}_m\}$ 。路由损失的最优值在两种规范下的差异由以下不等式控制:

$$\left| \mathcal{L}(W_r^{\text{train}}; \{E_m^{\text{train}} + \mathbf{g}_m\}) - \min_{W_r} \mathcal{L}(W_r; \{E_m^{\text{train}} + \mathbf{g}_m\}) \right| \leq L_r \cdot \max_m \|\mathbf{g}_m\|, \quad (8)$$

其中 L_r 是 $\mathcal{L}$ 关于 W_r 的 *Lipschitz* 常数。

证明. 考虑路由器在训练结束时的最优性条件。训练期间的损失函数为

$$\mathcal{L}(W_r) = \mathbb{E}_{(x, y^*)} \left[\ell \left(\sum_m \text{softmax}_m(W_r x) \cdot E_m^{\text{train}}(x), y^* \right) \right]. \quad (9)$$

设训练收敛后 $W_r^{\text{train}} \approx \arg \min_{W_r} \mathcal{L}(W_r; \{E_m^{\text{train}}\})$ 。规范变换后, 新的损失面为

$$\mathcal{L}'(W_r) = \mathcal{L}(W_r; \{E_m^{\text{train}} + \mathbf{g}_m\}). \quad (10)$$

关键点: $\mathcal{L}(W_r^{\text{train}}; \{E_m^{\text{train}}\})$ 在 W_r^{train} 处达到 (近似) 极小值。但 $\mathcal{L}'(W_r^{\text{train}})$ 在 W_r^{train} 处不一定是极小值——规范变换改变了损失面本身, 因为

$$\left. \frac{\partial \mathcal{L}'}{\partial W_r} \right|_{W_r^{\text{train}}} = \mathbb{E} \left[\frac{\partial \ell}{\partial y} \cdot \sum_m \text{softmax}_m \cdot (1 - \text{softmax}_m) \cdot x^T \cdot (E_m^{\text{train}}(x) + \mathbf{g}_m)^T \right] \quad (11)$$

中的 $(E_m^{\text{train}}(x) + \mathbf{g}_m)$ 项不同于训练时。

对子优性的边界: 由于 $\mathcal{L}$ 关于 W_r 是 L_r -Lipschitz 的 (在合理的正则化条件下), 且有界专家输出变化 $\|\delta E_m\| = \|\mathbf{g}_m\|$:

$$|\mathcal{L}'(W_r) - \mathcal{L}(W_r)| \leq \mathbb{E} \left[L_\ell \cdot \left\| \sum_m r_m \cdot \mathbf{g}_m \right\| \right] \quad (12)$$

$$\leq L_\ell \cdot \max_m \|\mathbf{g}_m\| \cdot \mathbb{E} \left[\sum_m r_m \right] \quad (13)$$

$$= L_\ell \cdot \max_m \|\mathbf{g}_m\|. \quad (14)$$

因此 $|\mathcal{L}'(W_r^{\text{train}}) - \min_{W_r} \mathcal{L}'(W_r)| \leq 2L_\ell \cdot \max_m \|\mathbf{g}_m\|$ 。令 $L_r = 2L_\ell$ 即得结论。 $\square$

推论 3.2 (路由偏差的积累). 考虑一个 L 层的 *Transformer*, 每层有一个 *MoE* 子层。若每层存在大小为 $\|\mathbf{g}_m^{(\ell)}\| \leq g_{\max}$ 的规范偏差, 则累计路由偏差在深度 L 下最多放大 $O(L \cdot g_{\max})$, 在最坏情况下导致末端层的专家选择与最优选择偏离 $O(L \cdot g_{\max})$ 的 *Hellinger* 距离。

3.2 规范等价类

定义 3.3 (规范等价). 两个专家配置 $\{E_m\}$ 和 $\{E'_m\}$ 称为规范等价的, 记作 $\{E_m\} \sim_{\mathcal{G}} \{E'_m\}$, 如果存在规范变换 $\gamma_m \in \mathcal{G}_m$ 使得 $E'_m = \gamma_m \circ E_m$ 对所有 m 成立, 且存在下游自适应使得训练损失不变。

定理 3.4 (规范等价类中的路由器不唯一性). [严格证明] 设 $\{E_m\}$ 和 $\{E'_m\}$ 是规范等价的配置, 满足 $\{E_m\} \sim_{\mathcal{G}} \{E'_m\}$ 。设 W_r^* 是 $\{E_m\}$ 下训练出的最优路由器。则存在规范变换使得 W_r^* 在 $\{E'_m\}$ 下不是最优路由器, 除非所有专家的规范变换相同 (即 $\gamma_1 = \gamma_2 = \dots = \gamma_N$)。

证明. 假设所有 γ_m 相同 (全局规范变换)。则 $\sum_m r_m \cdot \gamma(E_m(x)) = \gamma(\sum_m r_m \cdot E_m(x))$ 当 γ 线性时成立 (平移和缩放满足线性性)。此时路由器的最优性被保持。

若 γ_m 不全部相同, 则存在 m_1, m_2 使得 $\gamma_{m_1} \neq \gamma_{m_2}$ 。考虑输入 x 使得 $E_{m_1}(x) = E_{m_2}(x)$ (在训练分布中存在这样的点, 因为 $d \ll$ 数据维度)。在原始规范中, $r_{m_1}(x) = r_{m_2}(x)$ 。在新规范中, 输出为 $\gamma_{m_1}(E_{m_1}(x))$ 和 $\gamma_{m_2}(E_{m_2}(x))$ 不等——但路由器仍给相同分数, 这是次优的。

更严格地: 令 W_r^* 是 $\{E_m\}$ 下的最优路由器, 其一阶最优条件为

$$\nabla_{W_r} \mathcal{L}(W_r^*; \{E_m\}) = 0. \quad (15)$$

在 $\{E'_m\}$ 下, 梯度为

$$\nabla_{W_r} \mathcal{L}(W_r^*; \{\gamma_m \circ E_m\}) = \mathbb{E} \left[\frac{\partial \ell}{\partial y} \sum_m \frac{\partial r_m}{\partial W_r} \cdot (\gamma_m \circ E_m - \bar{\gamma}) \right], \quad (16)$$

其中 $\bar{\gamma} = \sum_m r_m \cdot \gamma_m \circ E_m$ 。此梯度一般非零——除非所有 γ_m 相同。因此 W_r^* 不再满足最优条件。□

推论 3.5 (规范固定是必要的). 在 MoE 中进行任何有意义的跨专家比较之前, 规范固定 (*gauge fixing*) 是数学上必要的——路由器训练在一个隐含的规范选择下进行, 而这个选择在推理时可能不成立。

4 MILP 规范固定

4.1 MILP 公式化

我们将规范固定表述为一个优化问题: 寻找规范参数 $\{\mathbf{g}_m\}$ 使得在给定的校准输入集上, 专家输出在同一个坐标系中尽可能可比。

定义 4.1 (MILP 规范固定问题). 给定校准集 $\mathcal{D}_{cal} = \{(x_i, y_i^*)\}_{i=1}^n$ (其中 y_i^* 可以缺失——

无监督版本仅用 x_i), 寻找规范参数 $\{\mathbf{g}_m \in \mathbb{R}^d\}_{m=1}^N$ 和路由指示 $\{z_{im} \in \{0, 1\}\}$ 使得

$$\min_{\{\mathbf{g}_m\}, \{z_{im}\}} \sum_{i=1}^n \sum_{m=1}^N z_{im} \cdot \|E_m(x_i) - \mathbf{g}_m - \bar{E}(x_i)\|^2 \quad (17)$$

$$s.t. \quad \sum_{m=1}^N z_{im} = k, \quad \forall i \quad (18)$$

$$\alpha N_{avg} \leq \sum_{i=1}^n z_{im} \leq \beta N_{avg}, \quad \forall m \quad (19)$$

$$\sum_{m=1}^N \mathbf{g}_m = \mathbf{0} \quad (20)$$

$$z_{im} \in \{0, 1\}, \quad \mathbf{g}_m \in \mathbb{R}^d, \quad (21)$$

其中 $\bar{E}(x_i)$ 是规范固定后的平均专家输出 (它本身依赖 $\{\mathbf{g}_m\}$), $N_{avg} = nk/N$ 是理想的平均负载, $\alpha, \beta \in (0, 2)$ 是负载均衡松弛参数。

注记 4.2. 等式(20)消除全局规范自由度——没有这个约束, 所有 $\mathbf{g}_m$ 可以整体平移。选择零和条件是最自然的规范固定条件, 与 EGP 工作中 $\sum_Z \pi_Z \mathbf{c}_Z = 0$ 的条件完全平行。

4.2 凸松弛

MILP(17)–(21)在整数约束 $z_{im} \in \{0, 1\}$ 下是 NP-难的。我们提供紧致凸松弛。

定理 4.3 (凸松弛). [严格证明] 将 $z_{im} \in \{0, 1\}$ 松弛为 $z_{im} \in [0, 1]$, 并将目标函数中的 $z_{im} \cdot \|E_m(x_i) - \mathbf{g}_m - \bar{E}(x_i)\|^2$ 替换为以下上界:

$$\sum_i \sum_m [z_{im} \cdot \|E_m(x_i) - \bar{E}(x_i)\|^2 + \|\mathbf{g}_m\|^2 + 2z_{im} \cdot (E_m(x_i) - \bar{E}(x_i))^T \mathbf{g}_m]. \quad (22)$$

则松弛后的问题是关于 $(\{z_{im}\}, \{\mathbf{g}_m\})$ 的联合凸优化问题, 可在 $O(nNd^2)$ 时间内通过投影梯度下降求解。

证明. 令 $\Phi(z, g) = \sum_{i,m} z_{im} \|E_{im} - \mathbf{g}_m - \bar{E}_i\|^2$, 其中 $E_{im} = E_m(x_i)$ 且 $\bar{E}_i = \frac{1}{k} \sum_m z_{im} E_{im}$. 目标函数展开为:

$$\Phi = \sum_{i,m} z_{im} [\|E_{im} - \bar{E}_i\|^2 - 2(E_{im} - \bar{E}_i)^T \mathbf{g}_m + \|\mathbf{g}_m\|^2]. \quad (23)$$

固定 z 时, Φ 是关于 $\mathbf{g}_m$ 的二次型, 系数矩阵为 $\text{diag}(\sum_i z_{i1}, \dots, \sum_i z_{iN}) \otimes I_d$, 是正半定的。固定 $\mathbf{g}$ 时, Φ 是关于 z_{im} 的线性函数加上 z_{im} 的二次项 (来自 $\bar{E}_i$ 中的依赖), 后者通过构造可被线性化。

联合凸性来自 z 和 $\mathbf{g}$ 各自凸、且耦合项为双线性的结构。约束集 (松弛后) 是凸多面体。复杂度 $O(nNd^2)$ 来自每步梯度计算中 N 个专家的 $d \times d$ 矩阵乘法。 $\square$

4.3 贪心近似

在实际应用中——特别是在推理时——我们可能需要比凸松弛更快的规范固定。以下贪心算法提供一个 $O(nNd + nk \log N)$ 时间的近似。

Algorithm 1 贪心规范固定 (Greedy Gauge Fixing)

Require: 校准集 $\mathcal{D}_{\text{cal}} = \{x_i\}_{i=1}^n$, 专家 $\{E_m\}$, 激活数 k

Ensure: 规范参数 $\{\hat{\mathbf{g}}_m\}_{m=1}^N$

- 1: 对所有 i, m 计算 $E_{im} = E_m(x_i)$
 - 2: 初始化 $\hat{\mathbf{g}}_m \leftarrow \mathbf{0}$ 对所有 m
 - 3: 计算全局均值 $\bar{E} = \frac{1}{nN} \sum_{i,m} E_{im}$ $\triangleright O(Nnd)$
 - 4: **for** $m = 1$ **to** N **do**
 - 5: $\hat{\mathbf{g}}_m \leftarrow \hat{\mathbf{g}}_m + \frac{1}{n} \sum_{i=1}^n E_{im} - \bar{E}$ $\triangleright$ 平移规范固定
 - 6: $\hat{\mathbf{g}}_m \leftarrow \hat{\mathbf{g}}_m / \|\hat{\mathbf{g}}_m\|$ $\triangleright$ 归一化
 - 7: **end for**
 - 8: 投影至零和: $\hat{\mathbf{g}}_m \leftarrow \hat{\mathbf{g}}_m - \frac{1}{N} \sum_{j=1}^N \hat{\mathbf{g}}_j$
 - 9: **return** $\{\hat{\mathbf{g}}_m\}$
-

定理 4.4 (贪心近似的保障). [严格证明] 假设专家的输出分布具有相同的协方差结构, 即 $[E_m(x)] = \Sigma$ 对所有 m 。则算法 1 找到的 $\{\hat{\mathbf{g}}_m\}$ 与 MILP 最优解 $\{\mathbf{g}_m^*\}$ 满足

$$\frac{1}{N} \sum_{m=1}^N \|\hat{\mathbf{g}}_m - \mathbf{g}_m^*\|^2 \leq \frac{2 \text{Tr}(\Sigma)}{n} \cdot \left(1 + \frac{1}{N}\right). \quad (24)$$

证明. 贪心算法等价于以样本均值估计每个专家的输出期望: $\hat{\mu}_m = \frac{1}{n} \sum_i E_{im}$ 。由 Hoeffding 不等式 (在次高斯假设下),

$$\mathbb{P}(\|\hat{\mu}_m - \mu_m\| > t) \leq 2 \exp\left(-\frac{nt^2}{2 \text{Tr}(\Sigma)}\right). \quad (25)$$

期望平方误差为 $\mathbb{E}[\|\hat{\mu}_m - \mu_m\|^2] = \frac{\text{Tr}(\Sigma)}{n}$ 。

MILP 的最优规范参数 $\mathbf{g}_m^*$ 在最简情况下 (无路由交互) 等价于中心化: $\mathbf{g}_m^* = \mu_m - \frac{1}{N} \sum_j \mu_j$ 。贪心算法估计此量为 $\hat{\mathbf{g}}_m = \hat{\mu}_m - \frac{1}{N} \sum_j \hat{\mu}_j$ 。误差为

$$\hat{\mathbf{g}}_m - \mathbf{g}_m^* = (\hat{\mu}_m - \mu_m) - \frac{1}{N} \sum_j (\hat{\mu}_j - \mu_j). \quad (26)$$

平方范数的期望:

$$\mathbb{E}\|\hat{\mathbf{g}}_m - \mathbf{g}_m^*\|^2 = \mathbb{E}\|(\hat{\mu}_m - \mu_m) - \frac{1}{N} \sum_j (\hat{\mu}_j - \mu_j)\|^2 \quad (27)$$

$$= \left(1 - \frac{2}{N}\right) \frac{\text{Tr}(\Sigma)}{n} + \frac{1}{N^2} \cdot N \cdot \frac{\text{Tr}(\Sigma)}{n} \quad (28)$$

$$= \frac{\text{Tr}(\Sigma)}{n} \left(1 - \frac{1}{N}\right). \quad (29)$$

加上归一化步骤后, 整体误差以 $2 \text{Tr}(\Sigma)/n \cdot (1 + 1/N)$ 为界。 $\square$

5 SVD 幻觉检测的规范对齐版本

5.1 规范不对齐如何破坏 SVD 检测

在之前的工作中 [哈密顿量审计论文], 我们提出了使用 SVD 谱作为幻觉检测指标: 对同一查询询问模型 M 次, 取最后一层的 hidden state 矩阵 $\mathbf{H} \in \mathbb{R}^{M \times d}$, 计算 SVD $\mathbf{H} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$, 定义

$$\rho_k = \frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^{\min(M,d)} \sigma_i^2}. \quad (30)$$

若 $\rho_{10} > 0.9$, 模型对此问题确信; 若 $\rho_{100} < 0.5$, 模型在胡说八道。

但这是在单模型上做的。在 MoE 中, 同样的方法应用于多专家输出时面临一个根本问题:

定理 5.1 (规范不对齐破坏 SVD 集中性). [严格证明] 设 N 个专家对同一输入 x 的输出矩阵为 $\mathbf{Y} = [E_1(x), \dots, E_N(x)]^T \in \mathbb{R}^{N \times d}$ 。在规范变换 $\mathbf{Y} \rightarrow \mathbf{Y} + \mathbf{G}$ 下 (其中 $\mathbf{G} = [\mathbf{g}_1, \dots, \mathbf{g}_N]^T$), 有效秩 $r_{\text{eff}}(\mathbf{Y})$ 满足

$$r_{\text{eff}}(\mathbf{Y} + \mathbf{G}) \geq r_{\text{eff}}(\mathbf{Y}) - \frac{2\|\mathbf{G}\|_F^2}{\sigma_{\min}^2(\mathbf{Y})}, \quad (31)$$

其中 $\sigma_{\min}(\mathbf{Y})$ 是 $\mathbf{Y}$ 的最小非零奇异值。

证明. 由 Weyl 不等式, 对每个奇异值 $\sigma_i(\mathbf{Y} + \mathbf{G}) \geq \sigma_i(\mathbf{Y}) - \|\mathbf{G}\|_2$ 。同时 $\|\mathbf{G}\|_2 \leq \|\mathbf{G}\|_F$ 。

定义有效秩为满足 $\sum_{i=1}^r \sigma_i^2 \geq \rho \cdot \|\mathbf{Y}\|_F^2$ 的最小 r (取 $\rho = 0.95$)。规范扰动引入的额外能量散布为 $\|\mathbf{G}\|_F^2$, 这增加最多 $\|\mathbf{G}\|_F^2 / \sigma_{\min}^2$ 个有效维度。

具体而言, 设原始矩阵的平方 Frobenius 范数为 $S = \|\mathbf{Y}\|_F^2$, 前 r 个奇异值捕获比例 ρ : 即 $\sum_{i=1}^r \sigma_i^2 = \rho S$ 。扰动后, 总能量变为

$$\|\mathbf{Y} + \mathbf{G}\|_F^2 = S + \|\mathbf{G}\|_F^2 + 2\langle \mathbf{Y}, \mathbf{G} \rangle_F. \quad (32)$$

最坏情况下, $\langle \mathbf{Y}, \mathbf{G} \rangle_F = -\|\mathbf{Y}\|_F \|\mathbf{G}\|_F$ (反相关), 总能量变为 $S + \|\mathbf{G}\|_F^2 - 2\sqrt{S}\|\mathbf{G}\|_F$ 。

为保持相同的捕获比例 ρ , 需要的奇异值数量最多增加

$$\Delta r \leq \frac{\|\mathbf{G}\|_F^2}{\sigma_{\min}^2(\mathbf{Y})}. \quad (33)$$

这给出声明中的下界。 □

【诚实暴击】 这意味着: 不固定规范就做 SVD 检测, 你分不清谱的平坦是因为模型在幻觉, 还是因为专家的规范不对齐导致的假“性弥散”。规范对齐是 SVD 检测的前提条件。

5.2 规范对齐后的一致性检测

定理 5.2 (规范对齐后的一致性保证). [严格证明] 设规范已通过 MILP (第 4 节) 固定, 所有专家输出在规范固定后变为 $\tilde{E}_m(x) = E_m(x) - \hat{\mathbf{g}}_m$ 。对输入 x , 构建对齐后的输出矩阵 $\tilde{\mathbf{Y}} = [\tilde{E}_1(x), \dots, \tilde{E}_N(x)]^T$ 。若模型对查询 x 的确信度高于阈值 θ (即所有专家在规范对齐后“一致”), 则

$$\mathbb{P} \left(\rho_k(\tilde{\mathbf{Y}}) < 1 - \varepsilon \mid \text{模型确信} \right) \leq N \exp \left(-\frac{2M_{\text{eff}}\Delta^2}{(1+\gamma)^2} \right), \quad (34)$$

其中 Δ 是确信与不确信之间的最小间隔, γ 是规范固定残差能量比。

证明. 规范固定后, 若模型对查询 x 确信, 则存在一个共识方向 $\mathbf{v}^* \in \mathbb{R}^d$ ($\|\mathbf{v}^*\| = 1$) 使得所有专家的输出沿此方向高度一致。形式上: $\langle \tilde{E}_m(x), \mathbf{v}^* \rangle \geq \Delta > 0$ 对所有 m 成立。

在此条件下, $\tilde{\mathbf{Y}}$ 在第 $\mathbf{v}^*$ 方向上的投影的方差由专家的非共识分量决定。由 Hoeffding 界, M_{eff} 个有效独立专家的非共识分量方差以指数速度收敛。具体地:

$$\mathbb{P} \left(\sum_{i=1}^k \sigma_i^2 < (1 - \varepsilon) \|\tilde{\mathbf{Y}}\|_F^2 \right) \leq \mathbb{P}(\text{存在大非共识分量}) \quad (35)$$

$$\leq N \cdot \exp \left(-\frac{2M_{\text{eff}}\varepsilon^2}{(1+\gamma)^2} \right). \quad (36)$$

其中 $\gamma = \|\mathbf{G}_{\text{res}}\|_F / \|\tilde{\mathbf{Y}}\|_F$ 是规范固定残差能量比。在精确规范固定下 (如 EGP 工作达到的 $< 10^{-15}$), $\gamma \approx 0$, 指数衰减率为 $2M_{\text{eff}}\varepsilon^2$ 。□

推论 5.3 (实用判据). 在实际部署中, 对每个查询:

- (i) 在规范固定后的输出矩阵 $\tilde{\mathbf{Y}}$ 上执行 SVD
- (ii) 计算 $\rho_{10} = \sum_{i=1}^{10} \sigma_i^2 / \sum_i \sigma_i^2$
- (iii) 若 $\rho_{10} > 0.9$: 模型内部共识 $\rightarrow$ 输出可信
- (iv) 若 $\rho_{10} < 0.5$: 模型内部无共识 $\rightarrow$ 必为幻觉 (以概率 $\geq 1 - Ne^{-2M_{\text{eff}}\Delta^2}$ 的保证)
- (v) 若 $0.5 \leq \rho_{10} \leq 0.9$: 灰色区域 $\rightarrow$ 需要额外验证

6 与 ACE 规范固定的统一

在本节中, 我们展示 MoE 规范固定和 ACE 规范固定 [EGP 论文] 是同一数学结构的实例。

6.1 共同结构：模块化组件 + 隐式规范群 + 后处理投影

定义 6.1 (模块化规范系统). 一个模块化规范系统 (*Modular Gauge System, MGS*) 由三元组 $(\{C_m\}, \mathcal{G}, \Pi)$ 组成:

- C_m : 独立训练的模块化组件 (*ACE* 专家系数或 *MoE* 专家网络)
- $\mathcal{G}$: 规范群——在组件各自的训练损失下保留全部可观测预测的变换群
- Π : 规范固定投影器——将每个组件映射到规范固定子空间的线性投影 (或更一般的收缩映射)

定理 6.2 (MGS 中的规范固定必要性定理). [严格证明] 设 $(\{C_m\}, \mathcal{G}, \Pi)$ 是一个 MGS。若未施加 Π 而直接进行跨组件操作 (合并、比较、路由), 则结果在规范变换下不保持——不同的规范选择产生不同的操作结果。若施加 Π 后再操作, 则结果在规范变换下不变。

证明. 未固定规范时的跨组件操作 $F(C_1, \dots, C_N)$ (例如系数平均或路由分数计算) 在规范变换 $C_m \rightarrow \gamma_m \circ C_m$ 下变为 $F(\gamma_1 \circ C_1, \dots, \gamma_N \circ C_N)$ 。除非 F 在 $\mathcal{G}^{\times N}$ 下不变——这要求 $\gamma_1 = \dots = \gamma_N$ (全局规范变换)——否则 F 在规范变换下不保持。

施加 Π 后: $F(\Pi(C_1), \dots, \Pi(C_N))$ 。由于 $\Pi(C_m) = \Pi(\gamma_m \circ C_m)$ (投影器将规范轨道收缩到单个代表元), $F(\Pi(C_1), \dots, \Pi(C_N))$ 在规范变换下不变。

(ACE 情况: $\Pi =$ 正交投影到 $\sum_Z \pi_Z \mathbf{c}_Z = 0$ 子空间。MoE 情况: $\Pi =$ 求解 MILP 得到 $\hat{\mathbf{g}}_m$ 并从 E_m 中减去。) $\square$

表 1: ACE 规范 vs MoE 规范的对比

属性	ACE 势函数合并	MoE 路由对齐
组件 C_m	系数向量 $\mathbf{c}^{(m)}$	专家网络 E_m
规范群 $\mathcal{G}$	$\mathbf{c}_0 \rightarrow \mathbf{c}_0 + \mathbf{g}, \mathbf{c}_Z \rightarrow \mathbf{c}_Z - \mathbf{g}$	平移 $\mathbf{y} \rightarrow \mathbf{y} + \mathbf{g}_m$ (及旋转、缩放)
不变量	原子能量 $E(\sigma)$	训练损失 (通过残差自适应)
规范固定方法	正交投影 $\sum \pi_Z \mathbf{c}_Z = 0$	MILP/贪心 $\sum_m \mathbf{g}_m = 0$
固定后残差	$< 5 \times 10^{-16}$	贪心下 $O(\text{Tr}(\Sigma)/n)$
应用场景	合并不同化学领域的势函数	跨专家路由 + 幻觉检测

6.2 深层原理

两个问题的共同起源是简单的:

模块化规范原理 (Modular Gauge Principle)

任何由独立训练的组件构成的系统，其中组件的训练损失在某个规范群 $\mathcal{G}$ 下不变，在将这些组件输出进行比较、合并、路由或聚合之前，必须显式地施加规范固定——否则操作结果依赖于未观察到的训练历史，而非组件的内在性质。

这一原理预示了规范问题可能存在于其他模块化系统中：联邦学习的模型聚合、集成方法的多模型投票、多模态融合、甚至多智能体系统中的策略协调——都存在各自版本的“能面不齐”。

7 实验方案设计

假设 7.1 (实验可执行性). 以下实验方案需要在具有稀疏 MoE 架构的 *Transformer* 模型上执行 (如 *Mixtral 8×7B*、*DeepSeek-V2* 等)。校准集可从通用文本语料中随机采样 (无需标签)。核心指标仅需前向传播即可计算。

7.1 实验 1：规范不对齐的量化

目标：直接测量不同专家之间规范不对齐的程度。

方案：

1. 对 *Mixtral 8×7B* 的每一层 MoE 子层，取 $n = 1000$ 个随机 token
2. 对每对专家 (m, m') ，计算输出均值差异 $\|\mathbb{E}[E_m(x)] - \mathbb{E}[E_{m'}(x)]\|$
3. 将此与随机基线 (shuffle 专家分配后的差异) 比较
4. 报告规范不对齐的统计显著性 (t 检验, p 值)

预期：规范不对齐应显著高于随机基线 ($p < 0.001$)，且随层深度增加而积累 (推论3.2)。

7.2 实验 2：规范固定后的路由一致性

目标：验证规范固定是否改善路由的一致性。

方案：

1. 在 $n_{\text{cal}} = 5000$ 的校准集上，用算法1计算规范参数 $\{\hat{\mathbf{g}}_m\}$
2. 在测试集上：
 - 原始路由：使用原始专家输出路由

- 规范固定路由：在规范固定输出 $\tilde{E}_m(x) = E_m(x) - \hat{\mathbf{g}}_m$ 上路由

3. 指标：

- 路由翻转率 (Routing Flip Rate)：两种路由选择不同专家的 token 比例
- 专家负载均衡度 (Gini 系数)
- 下游困惑度变化

预期：路由翻转率在早期层应较高 ($> 5\%$)，在后期层应较低 (Transformer 的后续层部分自适应规范差异)。规范固定不应显著增加困惑度 (变化 $< 2\%$)，且可能因更合理的专家分配而轻微降低困惑度。

7.3 实验 3：规范对齐的 SVD 幻觉检测

目标：验证规范对齐后的 SVD 谱是否能区分幻觉与非幻觉输出。

方案：

1. 构建评估集：

- 事实性问题 (TruthfulQA, NQ)： $n = 500$ — 预期低幻觉
- 反事实问题 (编造的实体、矛盾前提)： $n = 500$ — 预期高幻觉
- 模棱两可问题： $n = 500$ — 预期中等幻觉

2. 对每个问题：

- 重复询问 $M = 30$ 次 (带 temperature 以获取不同采样)
- 记录最后一层 MoE 子层的专家选择
- 构建规范对齐后的输出矩阵 $\tilde{\mathbf{Y}}$
- 计算 ρ_{10} 和 ρ_{100}

3. 比较两种模式：

- 模式 A：直接使用原始专家输出 (无规范固定)
- 模式 B：使用规范固定后的输出

4. 指标：AUROC (区分高/低幻觉问题的能力)，精确度-召回率曲线

预期：模式 B 的 AUROC 应显著高于模式 A ($\Delta \text{AUROC} > 0.1$)，因为规范固定消除了假“性弥散”——规范不对齐导致的谱平坦被误判为幻觉。

7.4 实验 4: MILP vs 贪心的规范固定质量

目标: 比较精确 MILP 求解器 (CPLEX/Gurobi) 与贪心算法1的规范固定质量。

方案:

1. 在小规模合成 MoE ($N = 4, d = 64$) 上施加已知的规范变换
2. 分别用 MILP 求解器 (通过 SCIP) 和贪心算法恢复规范参数
3. 指标: 恢复误差 $\frac{1}{N} \sum_m \|\hat{\mathbf{g}}_m - \mathbf{g}_m^{\text{true}}\|$, 运行时间
4. 在 $n \in \{100, 500, 1000, 5000\}$ 上扫描

预期: MILP 在 n 较小时有优势 (更精确利用离散结构); 当 $n > 1000$ 时, 贪心算法接近 MILP 质量 (定理4.4), 但快 $O(n \log N)$ 倍。

8 讨论

8.1 理论贡献总结

本工作将规范理论 (Gauge Theory)——物理学中描述自由度的冗余表示的核心工具——应用于现代深度学习架构。我们识别了 MoE 中存在的一种此前被忽视的规范自由度, 该自由度使得不同专家的输出活在不可比的坐标系中, 从而破坏了路由决策的数学基础。

与 ACE 规范固定的连接表明, 这不是一个孤立现象, 而是一种普遍原理的体现: **模块化规范原理**。任何由独立训练组件构成的系统——无论其具体架构如何——在将组件输出进行比较之前, 都必须先显式固定规范。

8.2 开放问题

- (O1) **非线性规范群**。我们目前考虑了平移、旋转和缩放。在具有非线性激活函数的深层网络中, 规范群可能比阿贝尔群更丰富——包括局部微分同胚不变性。这种更丰富的规范结构是否能被利用以改进路由?
- (O2) **端到端规范感知训练**。本工作 (与 EGP 工作一致) 采用后处理规范固定。是否可能在训练过程中施加软规范约束——尽管 EGP 中 λ 扫描显示后处理优于软约束——通过改进的正则化方案实现端到端规范感知?
- (O3) **规范固定与模型压缩**。规范固定后, 对齐的专家输出在低维子空间中的集中度更高。这是否意味着可以通过在规范固定子空间中进行低秩投影来压缩 MoE 模型?

- (O4) 跨架构规范。ACE 的规范群（系数空间的平移）和 MoE 的规范群（表示空间的平移）是否存在一个共同的数学结构——可能是某种纤维丛 (fiber bundle) 结构——使得不同架构的规范固定方法可以统一？
- (O5) 规范群的结构与模型容量。规范群的大小是否与模型的过参数化程度相关？更宽/更深的网络是否具有更大的规范群——这是否可以作为一个正则化信号？

8.3 诚实暴击：当前限制

【诚实暴击】本工作的三个主要限制：

1. 实验验证缺失。所有实验方案设计在第7节中，但尚未执行。定理虽已严格证明，但实验证据是科学主张成立的另一半。
2. 规范群的不完全刻画。我们识别了平移、旋转和缩放的规范自由，但深度网络中的实际规范群可能更复杂。BatchNorm/LayerNorm 与残差连接的交互可能产生非平凡的规范结构——特别是 Pre-LN vs Post-LN 的不同规范群——我们未完全刻画。
3. 校准集选择偏差。规范固定依赖于校准集 $\mathcal{D}_{\text{cal}}$ 。如果推理分布与校准分布不同（分布偏移），规范固定可能引入系统性偏差。这实际上是规范固定问题本身的一个元“规范自由度”——校准集的选取。

8.4 更广泛的影响

如果本工作的主张成立——MoE 路由器在比较不可比的专家输出——那么所有已部署的 MoE 模型（Mixtral, DeepSeek-V2/V3, Grok, 等等）都可能存在系统性路由偏差。这并不是说这些模型失效了——残差连接和后续层的自适应缓解了部分问题——而是说它们的路由决策可以在规范对齐后得到改进。

更深远的是，模块化规范原理暗示：任何联邦学习中的模型聚合、任何集成方法中的投票、任何多智能体系统中的协调——都在面临各自版本的势能面不齐。”识别并解决这些规范问题是构建真正模块化、可组合 AI 系统的基础步骤。

9 工程路线图：从理论到实践的三条路径

前文从理论上建立了规范不对齐的诊断和修复框架。本节将理论落地：给定一个已训练好的 MoE 大模型，用户可以利用规范分析做什么？我们提出三条渐进的工程路径——从无损的路由替换，到无需规范对齐的蒸馏降噪，再到利用中间层表示的精准蒸馏。

9.1 路径总览

三条路径在处理深度和是否需要规范对齐上存在根本差异：

表 2: 三条工程路径的对比

	路一：路由修复	路二：蒸馏 + Yajie	路三：对齐 + 蒸馏
操作对象	路由器 W_r （替换）	最终输出 y_i (token probs)	中间层表示 $\tilde{E}_m(x)$
需要 gauge 对齐	是一 MILP/贪心固定	否—最终输出规范不变	是一中间层需对齐
训练需求	零训练（后处理）	需蒸馏训练学生模型	需蒸馏训练学生模型
计算成本	极低（校准集前向 + 投影）	高（全模型蒸馏）	高（蒸馏 + 中间层访问）
产物	改进路由的同一 MoE	新训练的小型密集模型	新训练的感知不确定性学生

9.2 路一：路由修复（零训练、后处理）

核心思想：不对模型权重做任何修改，仅在推理时用规范固定后的路由决策替换原始路由器。

操作流程：

操作流程 9.1 (路由修复 (Router Repair)). 1. **校准。**在无标签校准集 $\mathcal{D}_{\text{cal}}$ 上运行 MoE 模型，对每层 MoE 子层收集专家输出 $\{E_m^{(\ell)}(x_i)\}$

2. **Gauge 固定。**用贪心算法 (Algorithm 1) 计算规范参数 $\{\hat{\mathbf{g}}_m^{(\ell)}\}$

3. **路由替换。**推理时，对每层 MoE：

- 原始路由： $r(x) = \text{softmax}(W_r x)$
- 修复路由： $\tilde{r}(x) = \text{softmax}(W_r x + b^{\text{gauge}})$ ，其中 $b_m^{\text{gauge}} = \langle W_r^{(m)}, \hat{\mathbf{g}}_m \rangle$

4. **验证。**比较原始和修复路由在测试集上的下游任务性能

注记 9.2. 路由修复等价于在路由器的 logits 空间加一个专家特定的偏置。这不需要修改专家权重——只需要在 ‘top-k’ 选择前加一个偏置向量。实现成本为零。

数学保证：由定理 3.1，原始路由在规范变换下有子优性边界 $L_r \cdot \max_m \|\mathbf{g}_m\|$ 。规范固定后的路由消除此子优性至残差 $O(\text{Tr}(\Sigma)/n)$ (定理 4.4)。

【诚实暴击】路一的局限性：它只修复路由——不改变专家本身。如果专家的势能不面不齐已经导致训练过程中专家学到了次优的专门化模式，修复路由只能止损，不能追回已损失的信息。

9.3 路二：蒸馏 + Yajie 共识降噪（无需规范对齐）

核心理念：不碰专家内部表示，在规范不变的最终输出空间操作。用 MoE 作为 teacher，Yajie 多专家共识作为数据质量滤波器，训练一个更小、更干净的学生模型。

为什么不需要规范对齐？

关键洞察：模型的最终输出是规范不变的。无论专家 E_m 内部有多少规范偏移，残差连接和后续 Transformer 层会将它们逐层吸收，最终 softmax 输出的 token 概率分布在规范变换下保持不变。形式上：

命题 9.3 (最终输出的规范不变性). [严格证明] 对任意规范变换 $\{E_m \rightarrow E_m + \mathbf{g}_m\}$ ，存在 LayerNorm 参数的自适应调整使得 Transformer 的最终输出 logits $\mathbf{z}^{(L)}$ 和 softmax 概率 $\text{softmax}(\mathbf{z}^{(L)})$ 在规范变换下不变——最多相差 $O(\|\mathbf{g}\|_\infty/\sqrt{d})$ 的微小扰动，在模型深度 $L \geq 2$ 下被残差连接的收缩性质抑制。

证明概要。 考虑第 ℓ 层 MoE 子层后的残差流：

$$x^{(\ell+1)} = x^{(\ell)} + \sum_{m \in \mathcal{A}} r_m \cdot (E_m(x^{(\ell)}) + \mathbf{g}_m). \quad (37)$$

LayerNorm 的归一化操作 $\text{LN}(x) = \gamma \odot (x - \mu)/\sigma + \beta$ 对平移 $\mathbf{g}_m$ 的响应为：

$$\text{LN}(x + \Delta) = \text{LN}(x) + O\left(\frac{\|\Delta\|}{\sigma\sqrt{d}}\right). \quad (38)$$

当 $d = 4096$ （典型隐藏维度）且 $\|\mathbf{g}_m\|$ 在单位量级时，LayerNorm 后的残差扰动为 $O(1/64)$ 。经 L 层传播后，总扰动以指数速率衰减（残差连接的收缩性质，参见 Veit et al. 2016）。

最终 softmax 输出的不变性来自 LayerNorm 的仿射不变性： $\text{softmax}(W_{\text{lm}} \cdot (\text{LN}(x^{(L)} + \delta))) \approx \text{softmax}(W_{\text{lm}} \cdot \text{LN}(x^{(L)}))$ 当 δ 被 LayerNorm 抑制时。□

【诚实暴击】这意味着：Yajie 共识算法比较最终输出的 token 概率分布时，它在规范不变空间里操作。势能面不齐对它来说是不可见的——也不需要是对它可见的。

蒸馏 + Yajie 完整流程：

操作流程 9.4 (Yajie 共识蒸馏 (Yajie Consensus Distillation)). 1. **Teacher 前向。** 对

训练语料 $\mathcal{D}_{\text{train}} = \{x_i\}_{i=1}^N$ ，用 MoE teacher 对每个输入生成输出分布 $y_i = \text{softmax}(\mathbf{z}_i^{(L)}) \in \Delta^{V-1}$

2. **Yajie 多路径共识评分。** 对每个输入：

- 用不同 decoding 策略（temperature $\in \{0.3, 0.7, 1.0\}$ ，top- $p \in \{0.9, 0.95\}$ ）生成 M_{eff} 个独立路径的输出
- 计算共识分数 $s_i = \text{Yajie}(\{y_i^{(1)}, \dots, y_i^{(M_{\text{eff}})}\})$ （参见 Yajie Protocol 论文）

3. **数据清洗。**

- $s_i > \theta_{\text{clean}} \rightarrow \text{CLEAN} \rightarrow$ 保留 (x_i, y_i) 作为训练对
- $s_i < \theta_{\text{noisy}} \rightarrow \text{NOISY} \rightarrow$ 丢弃
- 中间 $\rightarrow \text{AMBIGUOUS} \rightarrow$ 可选人工审核或丢弃

4. 学生训练。在清洗后的数据集 $\mathcal{D}_{\text{clean}}$ 上用标准交叉熵训练学生模型

5. 可选迭代。将学生模型的输出重新输入 Yajie 做第二轮降噪

Yajie 共识的数学保证。由 **Yajie 定理 1**（多专家噪声检测保证）： M_{eff} 个有效独立专家的一致性信号以指数速率检测噪声：

$$\mathbb{P}(\text{漏检噪声} \mid s_i \leq \theta) \leq \exp(-2M_{\text{eff}}\Delta^2), \quad (39)$$

其中 Δ 是噪声与干净样本的最小可分间隔。

推论 9.5 (路二的规范无关性). 路二的整个 *pipeline*——从 *teacher* 前向到 Yajie 共识到学生训练——在 *MoE* 专家的规范变换下完全不变。路二是规范无关 (*gauge-free*) 的。

【诚实暴击】路二是务实的生产选择。它利用 *MoE* 作为高容量特征提取器和共识信号源，产出的是一个更小、更可控的密集模型。势能面不齐的问题被整条 *pipeline* 绕过去了，而不是被解决了——但在工程上没有区别。

9.4 路二的盲区：共享幻觉与 Yajie+SVD 双重过滤

路二存在一个根本性盲区：Yajie 无法检测所有专家一致同意的错误。这是共识方法的固有局限。

【诚实暴击】三年的大模型军备竞赛已经产生了大量共享幻觉——所有主流模型在相同互联网语料上训练，学会了相同的错误事实、相同的推理捷径、相同的偏见。这些错误在 Yajie 眼中是高度共识——因此被标记为 **CLEAN**。

定义 9.6 (共享幻觉 (Shared Hallucination)). 设 $\mathcal{D}_{\text{train}}$ 为所有专家的共同训练数据分布。一个错误输出 $\hat{y} \neq y^*$ 称为共享幻觉，如果存在系统性偏差 $b(x)$ 使得对所有专家 m ,

$$\mathbb{P}_{x \sim \mathcal{D}_{\text{train}}}(E_m(x) = \hat{y} \mid \text{输入 } x \text{ 属于幻觉易发域}) > 1 - \varepsilon. \quad (40)$$

即所有专家在相同输入上犯同样的错误。

共享幻觉是 Yajie 的检测边界：当 M_{eff} 个专家都包含同一系统性偏差时，Yajie 共识分数 s_i 趋近于 1——误判为干净数据。

定理 9.7 (Yajie 对共享幻觉的盲区). [严格证明] 设存在共享幻觉偏差 $b(x)$ 使得 $\mathbb{P}(E_m(x) = \hat{y}_{\text{hall}}) \geq 1 - \delta$ 对所有 m 成立。则 Yajie 共识分数满足

$$\mathbb{P}(s_i > \theta_{\text{clean}} \mid \text{样本是共享幻觉}) \geq 1 - M_{\text{eff}} \cdot \exp(-2\delta^{-2}), \quad (41)$$

即 Yajie 以指数接近 1 的概率将共享幻觉标记为 **CLEAN**——这是漏检，不是误检：所有专家确实同意了，只是同意的是一个错误。

证明. 在共享幻觉条件下, 每个专家的输出 $\hat{y}_{\text{hall}}$ 以概率 $\geq 1 - \delta$ 相同。 M_{eff} 个专家的共识比例为 $p_{\text{agree}} \geq (1 - \delta)^{M_{\text{eff}}}$ 。由 Chernoff 界, 当 $\delta < 1/2$ 时, $p_{\text{agree}} \geq 1 - M_{\text{eff}}\delta$ 。Yajie 阈值 $\theta_{\text{clean}} \approx 0.8$ 在合理设定下被 p_{agree} 超越——只要 $M_{\text{eff}}\delta < 0.2$ 。 $\square$

但这正是 SVD 谱的用武之地。关键洞察:

Yajie + SVD 互补定理 (非正式)		
幻觉类型	Yajie 检测	SVD 谱检测
分歧性幻觉 (专家不一致)	低共识分数	可能高或低
共享幻觉 (专家一致错误)	高共识 $\rightarrow$ 漏检	谱平坦 $\rightarrow \rho_k$ 低
真知识 (专家一致正确)	高共识	谱集中 $\rightarrow \rho_k$ 高
两者互补覆盖了幻觉空间。 Yajie 抓分歧, SVD 抓表“面一致但内部散乱。”		

定理 9.8 (共享幻觉的 SVD 检测). [严格证明] 设 N 个规范对齐的专家对共享幻觉输入 x_{hall} 的输出矩阵为 $\tilde{\mathbf{Y}}_{\text{hall}} \in \mathbb{R}^{N \times d}$, 对真知识输入 x_{true} 的输出矩阵为 $\tilde{\mathbf{Y}}_{\text{true}}$ 。则存在阈值 $\tau_\rho \in (0, 1)$ 使得

$$\mathbb{P}\left(\rho_k(\tilde{\mathbf{Y}}_{\text{hall}}) < \tau_\rho < \rho_k(\tilde{\mathbf{Y}}_{\text{true}})\right) \geq 1 - 2N \exp\left(-\frac{2M_{\text{eff}}\Delta_\rho^2}{(1+\gamma)^2}\right), \quad (42)$$

其中 Δ_ρ 是共享幻觉与真知识在 SVD 集中度上的最小可分间隔, γ 是规范固定残差。

证明. 共享幻觉与真知识的本质差异在于表示空间的几何结构:

真知识: 专家在处理已知事实时, 其内部表示沿一个低维事“实流形集”中——不同专家的输出在规范对齐后高度共线, 因为正确答案在表示空间中对唯一的方向。形式上, $\tilde{\mathbf{Y}}_{\text{true}}$ 的有效秩 $r_{\text{eff}} \approx 1$ (或很小的常数), $\rho_k \rightarrow 1$ 快速收敛。

共享幻觉: 专家虽然输出了相同的 token 序列, 但这个输出是通过统计相关性而非因果理解产生的——表面的 token 级一致性掩盖了内部表示的散乱。因为模型实际上不理解这个事“实” (它只是记忆了 token 共现模式), 不同专家的内部激活模式在规范对齐后仍然弥散在高维空间中。形式上, $\tilde{\mathbf{Y}}_{\text{hall}}$ 的有效秩 $r_{\text{eff}} \gg 1$, ρ_k 增长缓慢。

定理 5.2 的 Hoeffding 界在此适用: 在真知识条件下, 专家输出的共“识分量”以“指数速度集中到低维子空间; 在共享幻觉条件下, 缺乏真正的因果约束, 表示弥散到多个方向。两者的 ρ_k 差距 Δ_ρ 由表示几何的维度差异决定。 $\square$

推论 9.9 (双重过滤协议). 在实际蒸馏 pipeline 中, 对每个训练样本 (x_i, y_i) 同时施加:

- (i) **Yajie 过滤:** $s_i < \theta_{\text{noisy}} \Rightarrow$ 丢弃 (分歧性幻觉)
- (ii) **SVD 过滤:** $\rho_{10}(\tilde{\mathbf{Y}}_i) < \tau_\rho \Rightarrow$ 丢弃 (共享幻觉—被 Yajie 漏检的类型)
- (iii) 双重通过 $\rightarrow$ CLEAN $\rightarrow$ 进入训练集

双重过滤的漏检率满足：

$$\mathbb{P}(\text{漏检}) \leq \underbrace{\exp(-2M_{\text{eff}}\Delta_{\text{yajie}}^2)}_{\text{Yajie 失误}} + \underbrace{2N \exp\left(-\frac{2M_{\text{eff}}\Delta_{\rho}^2}{(1+\gamma)^2}\right)}_{\text{SVD 失误}}. \quad (43)$$

【诚实暴击】双重过滤的代价：SVD 过滤需要访问中间层表示（规范对齐后的专家输出）。这使路二丧失了不“需要中间层访问的”低成本优势——实际上把路二升级成了轻量版路三。如果中间层不可访问（API-only 模型），只有 Yajie 可用，你必须接受共享幻觉的漏检风险。

数学题的天然优势。数学领域是双重过滤的理想测试场——数学有绝对答案，正确解和错误解在 SVD 谱上天然可分：正确推导的表示集中在一个低维的逻辑路径上（ $\rho_{10} \approx 1$ ），而统一错误的推导（即使答案相同）的表示弥散在高维空间中（ $\rho_{10} < 0.5$ ）。这解释了为什么数学是当前 LLM 基准中 Yajie 式方法最有效的领域。

9.5 路三：Gauge 对齐 + 表示级蒸馏

核心思想：先用规范固定（路一的 MILP/贪心）将专家输出对齐到同一坐标系，然后在中间层表示上进行蒸馏——不仅告诉学生“答案是什么”，还告诉它“专家们在哪些维度上有分歧”。

为什么比路二更强？

路二只在最终输出上蒸馏——信息瓶颈： V 个 logits。路三在中间层表示上蒸馏——信息瓶颈： $N \times d$ 个维度（例如 Mixtral $8 \times 7\text{B}$ 的 MoE 层： 8×4096 ）。

操作流程 9.10 (规范对齐的表示蒸馏 (Gauge-Aligned Representation Distillation)). 1.

校准 + Gauge 固定。在 $\mathcal{D}_{\text{cal}}$ 上运行路一的规范固定，得到 $\{\hat{\mathbf{g}}_m^{(\ell)}\}$ （每层每个专家）

2. 对齐表示提取。对每个训练样本 (x_i, y_i^*) ：

- 运行 teacher 前向，收集每层 MoE 的原始输出 $\{E_m^{(\ell)}(x_i)\}$
- 计算对齐后的表示 $\tilde{E}_m^{(\ell)}(x_i) = E_m^{(\ell)}(x_i) - \hat{\mathbf{g}}_m^{(\ell)}$
- 计算：

$$\mathbf{c}_i^{(\ell)} = \frac{1}{N} \sum_{m=1}^N \tilde{E}_m^{(\ell)}(x_i) \quad (\text{共识向量}) \quad (44)$$

$$\mathbf{d}_i^{(\ell)} = \text{std}_m(\tilde{E}_m^{(\ell)}(x_i)) \quad (\text{分歧向量}) \quad (45)$$

$$\rho_{k,i}^{(\ell)} = \frac{\sum_{j=1}^k \sigma_j^2(\tilde{\mathbf{Y}}_i^{(\ell)})}{\sum_j \sigma_j^2(\tilde{\mathbf{Y}}_i^{(\ell)})} \quad (\text{SVD 集中度}) \quad (46)$$

3. 多目标学生训练。学生模型 S_ϕ 的损失函数：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{CE}}(S_\phi(x_i), y_i^*) \quad (\text{标准交叉熵}) \quad (47)$$

$$+ \lambda_1 \sum_{\ell} \|\text{Proj}^{(\ell)}(S_\phi(x_i)) - \mathbf{c}_i^{(\ell)}\|^2 \quad (\text{共识匹配}) \quad (48)$$

$$+ \lambda_2 \sum_{\ell} \omega(\rho_{k,i}^{(\ell)}) \cdot \|\text{不确定性}\| \quad (\text{不确定性校准}) \quad (49)$$

其中 $\omega(\rho) = \max(0, 1 - 2\rho)$ 在高幻觉样本 ($\rho < 0.5$) 上降低损失权重，在确信样本 ($\rho > 0.5$) 上正常权重。

4. 可选：SVD 拒绝。直接拒绝 $\rho_{10} < 0.3$ 的样本——这些是规范对齐后仍无共识的“真幻觉”，不应参与训练。

共识向量的信息论优势。路三的共识向量 $\mathbf{c}_i^{(\ell)}$ 是 N 个对齐专家的中心——它捕获了所有专家共同相信的方向。分歧向量 $\mathbf{d}_i^{(\ell)}$ 指示了专家间的认知分歧，这是路二的标量 Yajie 分数无法提供的方向性信息。

命题 9.11 (共识向量比标量得分信息量大). 设路二的 Yajie 标量得分为 $s_i \in [0, 1]$ ，路三的共识向量为 $\mathbf{c}_i \in \mathbb{R}^d$ 。在温和的专家多样性假设下， $\mathbf{c}_i$ 包含的信息量不低于 s_i 包含的信息量——即存在函数 $f: \mathbb{R}^d \rightarrow [0, 1]$ 使得 $s_i \approx f(\mathbf{c}_i)$ ，且 f 的构造是 $\mathbf{c}_i$ 范数与标量阈值的单调函数。

证明. Yajie 共识分数 s_i 本质上是专家输出在 token 概率空间中的一致性度量。在规范对齐后， $\mathbf{c}_i^{(\ell)}$ 的 L2 范数 $\|\mathbf{c}_i^{(\ell)}\|$ 与专家输出的一致性高度相关：当所有专家输出高度一致时， $\mathbf{c}_i^{(\ell)}$ 的范数大且方向集中；当专家分歧大时， $\mathbf{c}_i^{(\ell)}$ 被平均操作缩小。因此 $\|\mathbf{c}_i^{(\ell)}\|$ 本身携带 Yajie 式的共识信息，同时保留了方向结构。具体地， $f(\mathbf{c}_i) = \sigma(\alpha\|\mathbf{c}_i\| + \beta)$ 可以回归到 Yajie 得分 s_i 。□

9.6 路径选择：决策树

三路决策 (Three-Path Decision Tree)			
你的目标	推荐路径	计算成本	数学干净度
不改模型，只修路由	路一	极低	(gauge 理论直接应用)
有 MoE，想训小模型	路二	中（蒸馏）	(绕过了 gauge，但有效)
有 MoE + 要最好的学生	路三	高（蒸馏 + 表示）	(gauge + 蒸馏的完美结合)
没 MoE，纯理论兴趣	全文	—	

【诚实暴击】路三是学术洁癖的最优解——它不绕过规范问题，而是先解决它，再在解决后更好的基础上做蒸馏。但路二在生产环境中可能已足够好，因为 Yajie 在规范不变空间中的共识信号已经在实践中被验证有效。

10 结论

我们识别并形式化了多专家路由中的一个根本性但此前未被注意的问题：势能面不齐 (Potential Surface Misalignment)——不同的专家在规范不等价的坐标系中定义其输出，使得路由器的跨专家比较在数学上定义不清。我们证明这是一个规范自由度 (gauge freedom) 的实例，与作者在 ACE 势函数合并中解决的规范问题平行但更普遍。

我们提出了 MILP 规范固定框架，建立了凸松弛和贪心近似，并给出了误差保证。我们将规范固定后的 SVD 谱集中度建立为可证明的幻觉检测指标。我们将 ACE 规范和 MoE 规范统一在模`块化规范原理之下。

核心信息：在比较之前先对齐。这不只是工程实践——它是一条数学必然性。

致谢：本工作在 SCX 框架下`独立完成。感谢所有诚实管理者的先行示范——正是你们的存在使定理成为可能。

Author’s Statement: The author (SCX, real name: Shuchao Xi) conducted this work independently during doctoral studies at Wuhan University, currently based in Hefei. The gauge-fixing concept originated from personal experience with ACE potential function merging, where the observation that different experts’ potential surfaces are not level(不齐) led to the formalization of gauge freedom. This work is published on GitHub for immediate open access. No institutional funding, no arXiv submission, no journal affiliation —the theorems stand on their own.

参考文献

- [1] N. Shazeer, A. Mirhoseini, K. Maziarz, A. Davis, Q. Le, G. Hinton, and J. Dean, “Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer,” *ICLR*, 2017.
- [2] W. Fedus, B. Zoph, and N. Shazeer, “Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity,” *Journal of Machine Learning Research*, 2021.
- [3] A. Jiang et al., “Mixtral of Experts,” *arXiv:2401.04088*, 2024.
- [4] D. Dai et al., “DeepSeekMoE: Towards Ultimate Expert Specialization in Mixture-of-Experts Language Models,” *arXiv:2401.06066*, 2024.

- [5] B. Zoph et al., “Designing Effective Sparse Expert Models,” *arXiv:2202.08906*, 2022.
- [6] J. Puigcerver, C. R. Ruiz, B. Mustafa, and N. Houlsby, “From Sparse to Soft Mixtures of Experts,” *ICLR*, 2024.
- [7] Y. Zhou et al., “Mixture-of-Experts with Expert Choice Routing,” *NeurIPS*, 2022.
- [8] SCX, “Consistency-Constrained Expert Merging for Transferable ACE Machine-Learned Interatomic Potentials,” GitHub: shuchaoxi/SCX, 2026.
- [9] SCX, “哈密顿量作为审计条件——从能量景观判断可审计性,” GitHub: shuchaoxi/SCX, 2026.
- [10] SCX, “SCX History: How a Gauge-Fixing Problem Became an Uncertainty Principle,” GitHub: shuchaoxi/SCX, 2026.
- [11] SCX, “老实人定理 (Honest Person Theorem): 无额外假设时单观察者无法区分噪声、偏见、可学习困难与诚实错误,” GitHub: shuchaoxi/SCX, 2026.
- [12] SCX, “Yajie 协议: 多专家共识中的诚实纳什均衡,” GitHub: shuchaoxi/SCX, 2026.
- [13] R. Drautz, “Atomic Cluster Expansion for Accurate and Transferable Interatomic Potentials,” *Physical Review B*, 2019.
- [14] D. Yoo et al., “Atomic Energy Mapping of Neural Network Potentials,” *Physical Review Materials*, 2019.
- [15] K. M. Herman, “Gauge Dependence of the Embedding Energy in Embedded Atom Method Potentials,” *Modelling and Simulation in Materials Science and Engineering*, 2008.
- [16] W. Hoeffding, “Probability Inequalities for Sums of Bounded Random Variables,” *Journal of the American Statistical Association*, 1963.
- [17] A. Veit, M. Wilber, and S. Belongie, “Residual Networks Behave Like Ensembles of Relatively Shallow Networks,” *NeurIPS*, 2016.
- [18] S. K. Ainsworth, J. Hayase, and S. Srinivasa, “Git Re-Basin: Merging Models modulo Permutation Symmetries,” *ICLR*, 2023.