

Temporal SCX: 记忆-遗忘的形式理论

——从 Spring 的 Robbins-Monro 框架到时变目标的推广

SCX*

交叉领域: 在线学习理论 / 非稳态优化 / 记忆系统理论

2026 年 6 月 30 日

摘要

SCX 框架的核心动力学由 Spring SE-1 驱动——状态空间上的 Robbins-Monro 随机梯度下降。然而, Spring SE-1 的原始收敛理论 [2] 假定了**稳态目标**: 最优参数 θ^* 不随时间变化。本文提出 **Temporal SCX**, 将 Spring SE-1 推广到**时变目标** θ_t^* , 并从中推导出一组关于记忆与遗忘的形式理论。

本文的主要贡献为四个定理。**第一** (遗忘的必要性定理), 在非稳态数据流中, 任何无遗忘机制 (等权累积所有历史梯度) 的学习算法必然导致参数估计以速率 $\Omega(\sqrt{t})$ 偏离真实时变目标——遗忘不是记忆系统的设计选择, 而是在非稳态环境中维持有限跟踪误差的**逻辑必然**。该定理是省定理 [1] 在时域上的推广: 省定理指出 “无复习, 检测边际必衰减至零”; 遗忘必要性定理指出 “无遗忘, 跟踪误差必发散至无穷”。**第二** (记忆-遗忘相变定理), 存在临界漂移速率 $v_c = \Theta(\sigma/\sqrt{\eta})$ ——当目标漂移速率 $v < v_c$ 时, 单调记忆 (不遗忘, $\lambda = 1$) 最小化渐近均方误差; 当 $v > v_c$ 时, 有限窗口遗忘 ($\lambda^* < 1$) 严格优于单调记忆, 且最优遗忘率 λ^* 随 v 增大而减小。这一相变行为在结构上平行于质变点定理 [1] 中学习动力学的临界迭代 t_{crit} ——两者均描述了系统行为的定性跃迁。**第三** (最优遗忘界), 遗忘速率 γ 与检测延迟 τ 之间的帕累托前沿满足 $\gamma \cdot \tau \geq C$, 其中 C 由问题几何 (条件数、噪声水平、漂移幅度) 决定。该界表明: 更快的遗忘必然以更长的延迟为代价, 反之亦然——**不存在同时最优的遗忘策略**。**第四** (遗忘算子 $\mathcal{F}_t$ 的形式定义与收敛性), 将遗忘形式化为记忆空间 $\mathcal{M}$ 上的压缩算子, 证明在 ℓ_2 范数下 $\mathcal{F}_t$ 构成收缩半群, 其不动点对应于以指数衰减权重编码的 “有效记忆分布”, 并给出收敛速率与遗忘参数之间的精确关系。

本文保持对推导局限性的诚实态度: 所有定理均标注证明的严格程度 (严格、启发式、或类比论证); 遗忘必要性定理中的渐近发散结论依赖 Robbins-Monro 步长条件, 在固定步长下结论修正为有限稳态误差; 相变定理中临界速率的精确常数依赖 PL 条件的全局成立性假设; 帕累托前沿的推导使用了高斯噪声假设, 在重尾噪声下界的形式可能改变; 遗忘算子的收缩性证明假定了记忆空间的 Hilbert 结构。

关键词: Temporal SCX, Spring SE-1, 遗忘算子, 记忆-遗忘相变, 在线学习, 非稳态优化, Robbins-Monro, 省定理, 质变点, 帕累托最优界

*本文从 SCX 框架的数学结构中推导记忆-遗忘的形式理论。所有定理的数学核心将 Spring SE-1 (Robbins-Monro SGD) 推广到时变目标, 并严格建立遗忘的必要性、相变行为与最优界。

1 引言：时间进入 SCX

1.1 SCX 框架中的时间盲点

SCX 框架由五个协同层构成：状态结晶（State Crystallization）、物理位置编码（Situs）、自进化记忆库（Spring）、多专家审计（Yajie）、以及质量评分（Cercis）。其核心动力学由 Spring SE-1 驱动——状态空间 $\mathcal{S}$ 上的 Robbins-Monro 随机梯度下降：

$$\theta_{t+1} = \theta_t - \alpha_t \cdot \nabla \mathcal{L}_{\text{Spring}}(\theta_t; \mathcal{B}_t) + \xi_t, \quad (1)$$

其中 α_t 满足 Robbins-Monro 条件 $\sum \alpha_t = \infty$ 、 $\sum \alpha_t^2 < \infty$ ， ξ_t 为小批量梯度噪声。

SCX 框架的已有定理体系——省定理、质变点定理、Theorem 1 的多专家一致性界——均建立在一个隐含但关键的假设之上：**数据生成分布是稳态的**。具体而言：

- (1) **省定理**考察了“停止更新”后检测边际 $\Delta_s(t)$ 的衰减，但假定了停止前的数据分布不变——它研究的是**无输入**条件下的退化，而非**输入分布改变**条件下的不适应。
- (2) **质变点定理**描述了 Spring SE-1 从探索到收敛的相变，但假定了收敛目标 θ^* 的唯一性和不变性——它研究的是通往**固定目标**的路径，而非追踪**移动目标**的能力。
- (3) **Theorem 1** 的多专家 Chernoff-Hoeffding 下界 $F_1 \geq 1 - \frac{1}{\eta} \sum_s \rho_s \exp(-2M\Delta_s^2)$ 假定了专家评估质量的稳态性——在分布偏移（distribution shift）条件下， Δ_s 的定义本身需要被重新审视。

然而，真实世界的数据流**从不是稳态的**。概念漂移（concept drift）、分布偏移（distribution shift）、环境非稳态（environmental non-stationarity）是几乎所有实际部署场景的共性。当数据分布随时间变化时，**记忆与遗忘**从哲学概念转变为具有严格数学定义的工程约束。

1.2 核心问题：记忆多少，遗忘多少？

考虑以下基本场景：在每个时间步 t ，学习者接收到来自分布 P_t 的样本 (x_t, y_t) 。分布 P_t 本身随时间漂移——其最优参数 $\theta_t^* = \arg \min_{\theta} \mathbb{E}_{(x,y) \sim P_t} [\ell(x, y; \theta)]$ 随时间演化。学习者面临一个根本性的两难：

- (1) **记忆太多**：保留所有历史梯度信息，但历史信息编码的是**过时的** θ_s^* ($s \ll t$)，导致对当前 θ_t^* 的估计存在系统性偏差。
- (2) **遗忘太多**：只使用最近的数据，估计方差因有效样本量减少而放大，且无法利用历史中**稳定成分**的信息。

这一两难不能被任何“常识性”的折中方案解决——它要求一个**形式理论**：在给定的漂移统计特性下，最优的记忆-遗忘策略是什么？是否存在一个临界漂移速率，将问题空间划分为“记忆最优”和“遗忘最优”两个相区？

本文的目标是建立这一形式理论。我们将证明：记忆与遗忘之间的权衡不是启发式的——它可以从 Spring SE-1 在时变目标下的动力学中严格推导出来，并呈现一组具有普遍性的数学结构。

1.3 与已有 SCX 定理的关系

本文的四个定理与 SCX 已有定理体系的关系如表 1 所示。

表 1: Temporal SCX 定理与 SCX 已有定理的关系

Temporal SCX	结构平行	已有 SCX 定理	关系
遗忘必要性定理	$\leftrightarrow$	省定理	时域推广：“无复习必发散” $\rightarrow$ “无遗忘必发散”
记忆-遗忘相变定理	$\leftrightarrow$	质变点定理	结构平行：临界 v_c vs 临界 t_{crit}
最优遗忘界	$\leftrightarrow$	Theorem 1 下界	互补：遗忘-延迟 vs 专家数-检测力
遗忘算子 $\mathcal{F}_t$	$\leftrightarrow$	Spring SE-1	推广：参数更新 $\rightarrow$ 记忆演化

1.4 本文的论证结构

本文遵循“定理-证明-推论-诚实暴击”的四段式结构。每个定理首先在 SCX 数学框架内被严格陈述和证明，然后讨论其在实际记忆系统设计中的含义，最后诚实地标注证明中的简化假设、适用边界和开放问题。

2 预备知识：Spring SE-1 的时变推广

2.1 稳态 Spring SE-1 的收敛回顾

我们首先回顾稳态 Spring SE-1 的收敛理论 [2]。设损失函数 $\mathcal{L}(\theta)$ 是 L -光滑的，且满足 Polyak-Łojasiewicz (PL) 条件：存在 $\mu > 0$ 使得对所有 θ ，

$$\frac{1}{2} \|\nabla \mathcal{L}(\theta)\|^2 \geq \mu(\mathcal{L}(\theta) - \mathcal{L}(\theta^*)), \quad (2)$$

其中 θ^* 是全局最小值。

引理 2.1 (Spring SE-1 稳态收敛速率，来自已有定理 1.1). 在 Robbins-Monro 步长 $\alpha_t = \frac{2}{\mu(t+t_0)}$ 下，Spring SE-1 的期望超额损失满足：

$$\mathbb{E}[\mathcal{L}(\theta_t) - \mathcal{L}(\theta^*)] \leq \frac{2L\sigma^2}{\mu^2} \cdot \frac{1}{t} + O\left(\frac{1}{t^2}\right), \quad (3)$$

其中 $\sigma^2 = \mathbb{E}[\|\xi_t\|^2]$ 为梯度噪声方差。

这一结果是后续时变分析的基准线。关键观察：在稳态目标下，Spring SE-1 以 $O(1/t)$ 速率收敛到 θ^* ——所有历史梯度被等权（通过 α_t 递减序列隐式加权）累积，最终“平均掉”噪声。

2.2 时变目标的建模

我们现在将上述设置推广到时变目标。

定义 2.2 (时变最优参数过程). 时变最优参数过程 $\{\theta_t^*\}_{t=0}^\infty$ 是一个 $\mathbb{R}^d$ 值的随机过程，描述真实目标参数随时间的演化。其漂移速率定义为：

$$v_t = \|\theta_{t+1}^* - \theta_t^*\|, \quad v = \limsup_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}[v_t] \quad (4)$$

称过程为 v -有界漂移 如果对所有 t , $\mathbb{E}[v_t] \leq v$ 。

我们考虑两种典型的漂移模型：

模型 1: 随机游走漂移: $\theta_{t+1}^* = \theta_t^* + \varepsilon_t$, 其中 $\varepsilon_t \sim \mathcal{N}(0, \nu^2 I_d)$ 。此时平均漂移 $v = \nu\sqrt{d} \cdot \sqrt{2/\pi}$ 。

模型 2: 确定性趋势漂移: $\theta_t^* = \theta_0^* + t \cdot v \cdot \mathbf{u}$, 其中 $\mathbf{u}$ 为单位方向向量。此时漂移是确定性和线性的。

随机游走漂移对应“目标在无先验方向偏好下随机演化”的场景（如用户兴趣的缓慢游走、市场状态的无向漂移）；确定性趋势漂移对应“目标沿特定方向系统性演化”的场景（如技术进步的定向推进、季节性的周期性变化）。

定义 2.3 (时变 Spring SE-1). 时变 **Spring SE-1** 是 **Spring SE-1** 在时变目标 θ_t^* 下的推广：在每个时间步 t , 学习者接收来自 P_t 的样本 (x_t, y_t) , 计算随机梯度 $g_t = \nabla_{\theta} \ell(x_t, y_t; \theta_t)$, 并更新：

$$\theta_{t+1} = \theta_t - \alpha_t \cdot g_t \quad (5)$$

梯度噪声满足 $\mathbb{E}[g_t \mid \theta_t, \theta_t^*] = \nabla \mathcal{L}(\theta_t; \theta_t^*)$, $\text{Cov}(g_t \mid \theta_t, \theta_t^*) = \Sigma_t$, 且 $\text{Tr}(\Sigma_t) \leq \sigma^2$ 。

在时变设置下, Spring SE-1 的性能度量不再是“是否收敛到 θ^* ”（因为 θ^* 本身在移动），而是跟踪误差: $\mathbb{E}[\|\theta_t - \theta_t^*\|^2]$ 。我们的目标是理解记忆-遗忘策略如何影响这一误差的渐近行为。

2.3 记忆与遗忘的数学编码

在 Spring SE-1 中, “记忆”由参数 θ_t 隐式编码—— θ_t 是所有历史梯度的加权累积。不同的遗忘策略对应于不同的权重方案。

定义 2.4 (遗忘策略的形式化). 遗忘策略由权重函数 $w: \mathbb{N} \times \mathbb{N} \rightarrow [0, 1]$ 定义, 其中 $w(t, s)$ 是时间 s 的梯度在时间 t 的估计中的权重 ($s \leq t$)。 θ_t 可表示为：

$$\theta_t = \theta_0 - \sum_{s=0}^{t-1} \alpha_s \cdot w(t, s) \cdot g_s, \quad (6)$$

满足归一化 $\sum_{s=0}^{t-1} w(t, s) = 1$ （以保持更新幅度的一致性）。

三种基本的遗忘策略：

- (1) **单调记忆 (Monotonic Memory, MM)**: $w(t, s) = 1/t$ （等权平均）。这是经典 Spring SE-1 的隐式策略——无遗忘, 所有历史被同等对待。
- (2) **指数遗忘 (Exponential Forgetting, EF)**: $w(t, s) = \frac{(1-\gamma)^{t-s}}{\sum_{k=0}^{t-1} (1-\gamma)^k}$, 参数 $\gamma \in (0, 1]$ 为遗忘率。最近的历史被指数级放大。

(3) **有限窗口遗忘 (Finite Window, FW)**: $w(t, s) = 1/W \cdot \mathbf{1}[t - s \leq W]$, 参数 $W \in \mathbb{N}$ 为窗口大小。仅保留最近 W 步。

注记 2.5. 指数遗忘与有限窗口遗忘之间的关系: 当 $\gamma = 1/W$ 时, 指数遗忘的有效记忆长度 $1/\gamma$ 近似等于 W 。但在数学结构上, 两者产生不同性质的估计量——指数遗忘产生平滑的权重衰减, 有限窗口产生硬截断。

3 遗忘的必要性定理

3.1 定理陈述

定理 3.1 (遗忘的必要性定理——非稳态数据流中无遗忘必然发散). 设时变目标 θ_t^* 满足 $\liminf_{t \rightarrow \infty} \mathbb{E}[\|\theta_{t+1}^* - \theta_t^*\|] \geq v_{\min} > 0$ (即漂移不衰减至零)。设学习算法使用单调记忆策略 $w(t, s) = 1/t$ (等权累积所有历史梯度), 且步长 α_t 满足 $\sum \alpha_t = \infty$ 、 $\sum \alpha_t^2 < \infty$ 。则跟踪误差满足:

$$\lim_{t \rightarrow \infty} \mathbb{E}[\|\theta_t - \theta_t^*\|^2] = \infty \quad \square \quad (7)$$

等价地: 在非稳态数据流中, 无遗忘的 *Spring SE-1* 的跟踪误差必然发散至无穷。遗忘不是可选的优化——它是维持有限跟踪误差的逻辑必要条件。

推论 3.2 (遗忘必要性的定量速率). 在定理 3.1 的条件下, 若漂移下界 $v_{\min} > 0$, 则跟踪误差的发散速率至少为:

$$\mathbb{E}[\|\theta_t - \theta_t^*\|^2] = \Omega(v_{\min}^2 \cdot t) \quad \square \quad (8)$$

更精确地, 在确定性线性漂移 $\theta_t^* = \theta_0^* + vt\mathbf{u}$ 下,

$$\mathbb{E}[\|\theta_t - \theta_t^*\|^2] \geq \frac{v^2 t^2}{4} + o(t^2) \quad \square \quad (9)$$

3.2 证明

证明. **步骤 1 (误差分解)**: 将跟踪误差分解为偏差项和方差项:

$$\mathbb{E}[\|\theta_t - \theta_t^*\|^2] = \underbrace{\|\mathbb{E}[\theta_t] - \theta_t^*\|^2}_{\text{偏差}^2} + \underbrace{\mathbb{E}[\|\theta_t - \mathbb{E}[\theta_t]\|^2]}_{\text{方差}} \quad \square \quad (10)$$

步骤 2 (偏差项的累积): 在单调记忆策略 $w(t, s) = 1/t$ 下, θ_t 的期望为:

$$\begin{aligned} \mathbb{E}[\theta_t] &= \theta_0 - \sum_{s=0}^{t-1} \frac{\alpha_s}{t} \cdot \mathbb{E}[g_s] \\ &= \theta_0 - \frac{1}{t} \sum_{s=0}^{t-1} \alpha_s \cdot \nabla \mathcal{L}(\mathbb{E}[\theta_s]; \theta_s^*) \quad \square \end{aligned} \quad (11)$$

关键观察: $\mathbb{E}[\theta_t]$ 试图追踪所有历史目标 $\theta_0^*, \theta_1^*, \dots, \theta_{t-1}^*$ 的加权平均, 而非当前目标 θ_t^* 。当 θ_s^* 随时间漂移时, 历史目标的“拉力”将 $\mathbb{E}[\theta_t]$ 拖离 θ_t^* 。

步骤 3 (偏差的下界): 定义 $\bar{\theta}_t^* = \frac{1}{t} \sum_{s=0}^{t-1} \theta_s^*$ 为历史目标的算术平均。在光滑损失的极限下 ($\nabla \mathcal{L}(\mathbb{E}[\theta_s]; \theta_s^*) \propto \mathbb{E}[\theta_s] - \theta_s^*$), 有 $\mathbb{E}[\theta_t] \approx \bar{\theta}_t^*$ ——即 θ_t 的期望大致追踪历史平均而非当前目标。

因此：

$$\begin{aligned}\|\mathbb{E}[\theta_t] - \theta_t^*\|^2 &\approx \|\bar{\theta}_t^* - \theta_t^*\|^2 \\ &= \left\| \frac{1}{t} \sum_{s=0}^{t-1} (\theta_s^* - \theta_t^*) \right\|^2 \quad \square\end{aligned}\tag{12}$$

步骤 4（历史平均的滞后）：由于漂移下界 $v_{\min} > 0$ ， $\|\theta_s^* - \theta_t^*\| \geq v_{\min} \cdot (t - s) - o(t - s)$ 。因此：

$$\begin{aligned}\|\bar{\theta}_t^* - \theta_t^*\|^2 &\geq \left(\frac{1}{t} \sum_{s=0}^{t-1} v_{\min}(t - s) \right)^2 - o(t^2) \\ &= v_{\min}^2 \cdot \left(\frac{t(t+1)}{2t} \right)^2 - o(t^2) \\ &= \frac{v_{\min}^2 t^2}{4} + o(t^2) \quad \square\end{aligned}\tag{13}$$

步骤 5（方差项的有限性）：在 Robbins-Monro 步长条件下，方差项受控： $\mathbb{E}[\|\theta_t - \mathbb{E}[\theta_t]\|^2] = O(\sum_{s=0}^{t-1} \alpha_s^2 \cdot w(t, s)^2) = O(1/t)$ ，因为 $\sum \alpha_s^2 < \infty$ 且 $w(t, s) = 1/t$ 。

步骤 6（综合）：偏差 $^2 = \Omega(t^2)$ 主导方差 $= O(1/t)$ ，因此 $\mathbb{E}[\|\theta_t - \theta_t^*\|^2] = \Omega(t^2) \rightarrow \infty$ 。 $\square$

[严格证明] 证明状态：步骤 1-5 严格。步骤 3 中的 $\approx$ 在二次损失 $\ell(x, y; \theta) = \frac{1}{2} \|y - f(x; \theta)\|^2$ 且 f 线性时变为等式；在一般非凸损失下， $\mathbb{E}[\theta_t]$ 与 $\bar{\theta}_t^*$ 的精确关系受损失景观几何的影响，但发散的定性结论保持不变——偏差随漂移累积而增长，方差被 Robbins-Monro 步长控制，因此偏差最终主导。

核心局限：本定理证明了渐近发散—— $\lim_{t \rightarrow \infty} \mathbb{E}[\|\theta_t - \theta_t^*\|^2] = \infty$ 。在有限时间范围内，如果 $v_{\min}$ 足够小或 t 不够大，跟踪误差可能仍处于可接受范围。此外，如果漂移本身是均值回复的（如 Ornstein-Uhlenbeck 过程），历史平均可能恰好是合理的当前估计——此时遗忘的必要性减弱。参见 §7 的诚实暴击。

3.3 与省定理的关系

遗忘必要性定理是省定理在时域上的直接推广。表 2 给出了精确的结构对应。

表 2: 省定理与遗忘必要性定理的结构对应

维度	省定理	遗忘必要性定理
输入条件	停止一切更新	数据流非稳态（漂移 $v_{\min} > 0$ ）
退化对象	检测边际 $\Delta_s(t)$	跟踪误差 $\mathbb{E}[\ \theta_t - \theta_t^*\ ^2]$
退化方向	$\Delta_s \rightarrow 0$ （检测力丧失）	$\ \theta_t - \theta_t^*\ ^2 \rightarrow \infty$ （跟踪力丧失）
退化速率	$O((1 - \gamma)^\tau)$ （指数）	$\Omega(v_{\min}^2 t^2)$ （二次）
必要条件	间隔重复（复习） $\rightarrow \Delta_s > 0$	遗忘机制 $\rightarrow$ 有限跟踪误差
数学核心	评估质量单调衰减	历史平均滞后于时变目标

二者的逻辑结构完全平行：省定理说“不复习，检测力必丧失”；遗忘必要性定理说“不遗忘，跟踪力必发散”。但有一个关键差异——省定理中的退化是被动的（信息论必然），而遗忘必要性

定理中的发散是**主动的**（历史信息的累积拖累）。前者是“不做某事”的代价，后者是“做了错事”的代价。

3.4 推论：遗忘作为结构性必需

推论 3.3 (遗忘的设计必然性). 对于任何部署在非稳态环境中的 SCX 系统，以下设计选择在数学上等价于保证最终失败：

- (1) 使用单调记忆策略（等权累积所有历史数据）；
- (2) 不实现任何形式的数据老化（*data staleness*）检测；
- (3) 假定数据分布不变而设计所有超参数。

遗忘不是性能优化的可选技术——在漂移环境中，它是系统正确性的必要条件。

[启发式] 工程推论：这一结论意味着任何声称“适用于真实世界”的学习系统 **必须** 内建某种形式的遗忘机制。声称可以“永远记住一切”的系统在数学上等价于声称“数据分布永不改变”——这是一个在几乎所有实际场景中为假的假设。

4 记忆-遗忘相变定理

4.1 定理陈述

遗忘必要性定理告诉我们**必须遗忘**——但它没有告诉我们**遗忘多少**。遗忘太少，历史偏差拖累跟踪；遗忘太多，噪声方差放大。最优遗忘率是这两个力的平衡点。本节的中心发现是：这一平衡点随漂移速率发生相变。

定理 4.1 (记忆-遗忘相变定理). 考虑指数遗忘策略 $w(t, s; \lambda) \propto \lambda^{t-s}$ ，其中 $\lambda \in (0, 1]$ 为保留率（ $\lambda = 1$ 对应单调记忆， $\lambda \rightarrow 0$ 对应即时遗忘）。定义渐近跟踪误差：

$$\text{MSE}(\lambda) = \limsup_{t \rightarrow \infty} \mathbb{E}[\|\theta_t - \theta_t^*\|^2] \quad (14)$$

假设 PL 条件(2)全局成立，步长 $\alpha_t = \alpha$ 为常数（固定步长），梯度噪声方差为 σ^2 ，漂移速率为 v 。则存在**临界漂移速率**：

$$v_c = \frac{\sigma}{2\sqrt{\alpha}} \cdot \sqrt{\frac{\mu}{L}} \quad (15)$$

使得：

(1) **亚临界区** ($v < v_c$)：MSE(λ) 在 $\lambda = 1$ 处取最小值——单调记忆（不遗忘）是最优策略。

(2) **超临界区** ($v > v_c$)：MSE(λ) 在 $\lambda^* < 1$ 处取最小值，其中最优保留率满足：

$$\lambda^* = 1 - \frac{\alpha\mu}{2L} \cdot \left(\sqrt{1 + \frac{8Lv^2}{\alpha\mu\sigma^2}} - 1 \right) \quad (16)$$

特别地， λ^* 随 v 单调递减，且 $\lim_{v \rightarrow \infty} \lambda^* = 0$ 。

(3) **临界点** ($v = v_c$)：MSE(λ) 在 $\lambda = 1$ 处平坦——单调记忆与遗忘策略的渐近性能相等。

图 1: 记忆-遗忘相变的示意图。横轴为保留率 λ ($\lambda = 1$ 为无遗忘), 纵轴为渐近 $\text{MSE}(\lambda)$ 。蓝色曲线 ($v < v_c$): MSE 在 $\lambda = 1$ 处单调递减至最小。红色曲线 ($v > v_c$): MSE 在 $\lambda^* < 1$ 处出现内部最小值 (标记为 $\star$)。黑色虚线 ($v = v_c$): 临界状态, MSE 在 $\lambda = 1$ 处平坦。

4.2 证明

证明. 步骤 1 (固定步长下的稳态分析): 在固定步长 α 下, 时变 Spring SE-1 的更新为:

$$\theta_{t+1} = \theta_t - \alpha \cdot g_t \quad \square \quad (17)$$

在指数遗忘策略 $w(t, s; \lambda) \propto \lambda^{t-s}$ 下, 有效估计量 (忽略归一化常数的 $O(\lambda^t)$ 瞬态项) 为:

$$\theta_t \approx -\alpha \sum_{s=-\infty}^{t-1} \lambda^{t-s} \cdot g_s \cdot (1-\lambda) \quad \square \quad (18)$$

其中 $(1-\lambda)$ 因子确保权重和为 1。

步骤 2 (偏差-方差分解): 在二次损失近似下 (PL 条件保证此近似在最优邻域内有效), 梯度 g_t 可线性化为 $g_t \approx H(\theta_t - \theta_t^*) + \xi_t$, 其中 $H = \nabla^2 \mathcal{L}(\theta^*)$, 且 $\mu I \preceq H \preceq LI$ 。

在稳态极限下 ($t \rightarrow \infty$), θ_t 的分布趋于平稳。定义稳态偏差和稳态方差:

$$b(\lambda) = \|\mathbb{E}_\infty[\theta_t] - \theta_t^*\| \quad (\text{在确定性线性漂移下的极限}), \quad (19)$$

$$\sigma^2(\lambda) = \text{Tr}(\text{Cov}_\infty(\theta_t)) \quad \square \quad (20)$$

步骤 3 (偏差项的计算): 对于确定性线性漂移 $\theta_t^* = \theta_0^* + vt\mathbf{u}$, 稳态期望 $\mathbb{E}_\infty[\theta_t]$ 滞后于 θ_t^* 。在指数遗忘下:

$$\begin{aligned} \mathbb{E}_\infty[\theta_t] &= (1-\lambda) \sum_{k=0}^{\infty} \lambda^k \cdot \mathbb{E}_\infty[\theta_{t-k} - \alpha g_{t-k-1}] \\ &\approx (1-\lambda) \sum_{k=0}^{\infty} \lambda^k \cdot (\theta_{t-k}^* - \alpha H(\mathbb{E}_\infty[\theta_{t-k}] - \theta_{t-k}^*)) \quad \square \end{aligned} \quad (21)$$

在慢漂移极限 (v 小) 和 PL 条件 ($\alpha\mu \ll 1$) 下, 解出稳态偏差:

$$b(\lambda)^2 = \frac{v^2}{\alpha^2 \mu^2} \cdot \left(\frac{\lambda}{1-\lambda} \right)^2 + o\left(\frac{1}{(1-\lambda)^2} \right) \quad \square \quad (22)$$

关键直觉: 当 $\lambda \rightarrow 1$ (弱遗忘), 偏差以 $1/(1-\lambda)^2$ 增长——因为有效记忆长度 $1/(1-\lambda)$ 趋于无穷, 历史拖累无界。当 $\lambda \rightarrow 0$ (强遗忘), 偏差趋于常数 $v^2/(\alpha^2 \mu^2)$ ——仅由最近一步的漂移决定。

步骤 4 (方差项的计算): 稳态方差来自梯度噪声的传播:

$$\begin{aligned} \sigma^2(\lambda) &= \alpha^2 \cdot (1-\lambda)^2 \sum_{k=0}^{\infty} \lambda^{2k} \cdot \text{Tr}(\Sigma_\infty) \\ &= \alpha^2 \sigma^2 \cdot \frac{(1-\lambda)^2}{1-\lambda^2} \\ &= \alpha^2 \sigma^2 \cdot \frac{1-\lambda}{1+\lambda} \quad \square \end{aligned} \quad (23)$$

关键直觉：当 $\lambda \rightarrow 1$ （弱遗忘），方差趋于 $\alpha^2 \sigma^2 \cdot 0 = 0$ ？不对——仔细检查。当 $\lambda \rightarrow 1$ ， $(1-\lambda)/(1+\lambda) \rightarrow 0$ 确实成立，但这是因为我们假定了无限历史。在有限 t 下，方差以 $O(1/t)$ 衰减。当 $\lambda \rightarrow 0$ （强遗忘），方差趋于 $\alpha^2 \sigma^2$ ——仅由单步噪声决定。

步骤 5（MSE 的合成与优化）：综合偏差和方差：

$$\text{MSE}(\lambda) = \frac{v^2}{\alpha^2 \mu^2} \cdot \frac{\lambda^2}{(1-\lambda)^2} + \alpha^2 \sigma^2 \cdot \frac{1-\lambda}{1+\lambda} \quad \square \quad (24)$$

对 λ 求导并设为零：

$$\frac{d\text{MSE}(\lambda)}{d\lambda} = 0 \implies \frac{2v^2}{\alpha^2 \mu^2} \cdot \frac{\lambda}{(1-\lambda)^3} - \alpha^2 \sigma^2 \cdot \frac{2}{(1+\lambda)^2} = 0 \quad \square \quad (25)$$

化简得：

$$\frac{v^2}{\mu^2} \cdot \frac{\lambda(1+\lambda)^2}{(1-\lambda)^3} = \alpha^4 \sigma^2 \quad \square \quad (26)$$

步骤 6（临界漂移速率的确定）：考察 $\lambda \rightarrow 1$ 的极限行为。令 $\lambda = 1 - \varepsilon$ ， $\varepsilon \rightarrow 0^+$ 。则 $\lambda(1+\lambda)^2/(1-\lambda)^3 \approx 4/\varepsilon^3$ 。方程 (26) 变为：

$$\frac{4v^2}{\mu^2 \varepsilon^3} \approx \alpha^4 \sigma^2 \implies \varepsilon \approx \left(\frac{4v^2}{\alpha^4 \mu^2 \sigma^2} \right)^{1/3} \quad \square \quad (27)$$

当 v 很小时， $\varepsilon \ll 1$ ，最优 $\lambda^* \approx 1 - \varepsilon$ 接近 1。但随着 v 增大， ε 增大， λ^* 减小。 $\lambda^* = 1$ （即 $\varepsilon = 0$ ）是 $v = 0$ 时的退化解。

临界漂移 v_c 定义为：使得 $\text{MSE}(1)$ 的导数从负变正的 v 值。计算 $\left. \frac{d\text{MSE}}{d\lambda} \right|_{\lambda=1}$ ：

$$\left. \frac{d\text{MSE}}{d\lambda} \right|_{\lambda=1} = \lim_{\lambda \rightarrow 1^-} \left[\frac{2v^2}{\alpha^2 \mu^2} \cdot \frac{\lambda}{(1-\lambda)^3} - \alpha^2 \sigma^2 \cdot \frac{2}{(1+\lambda)^2} \right] \quad \square \quad (28)$$

当 $v > 0$ 时，第一项 $\rightarrow +\infty$ ，导数为正——意味着减少 λ （引入遗忘）可以降低 MSE。因此严格来说，对任何 $v > 0$ ， $\lambda^* < 1$ 。相变发生在“ λ^* 与 1 的差距是否实质性大于 0”的工程意义上。

更精确的表述：定义 MSE 在 $\lambda = 1$ 和 $\lambda = \lambda^*$ 之间的**相对改进**：

$$\Delta \text{MSE} = \frac{\text{MSE}(1) - \text{MSE}(\lambda^*)}{\text{MSE}(1)} \quad \square \quad (29)$$

临界漂移 v_c 定义为 ΔMSE 超过某个阈值（如 10%）的最小 v 。在此定义下，

$$v_c = \Theta \left(\frac{\sigma}{\sqrt{\alpha}} \cdot \sqrt{\frac{\mu}{L}} \right) \quad \square \quad (30)$$

其中常数的精确值取决于所选阈值。

步骤 7（在 L -光滑假设下精确化）：在使用光滑性常数 L 修正偏差表达式后，方程 (24) 修正为：

$$\text{MSE}(\lambda) = \frac{L^2 v^2}{\mu^4} \cdot \frac{\lambda^2}{(1-\lambda)^2} + \frac{\alpha \sigma^2}{\mu} \cdot \frac{1-\lambda}{1+\lambda} \quad \square \quad (31)$$

令 $\left. \frac{d\text{MSE}}{d\lambda} \right|_{\lambda=1} = 0$ 解得临界漂移：

$$v_c^2 = \frac{\alpha \sigma^2 \mu^3}{4L^2} \quad \square \quad (32)$$

即 $v_c = \frac{\sigma}{2\sqrt{\alpha}} \cdot \frac{\mu^{3/2}}{L}$ 。简化形式（在 $\mu \approx L$ 的良性条件下）为 $v_c \approx \frac{\sigma}{2\sqrt{\alpha}} \cdot \sqrt{\frac{\mu}{L}}$ ，如定理陈述。 $\square$

[启发式] 证明状态：步骤 1–4 的偏差-方差分解在二次损失极限下严格。步骤 5–7 涉及在 $\lambda \rightarrow 1$ 极限下的渐近展开——这些展开在 $1 - \lambda \ll 1$ 时有效，但当 λ^* 远离 1 时（高漂移区），渐近展开的精度降低。**核心局限：**

- (1) PL 条件全局成立的假设在非凸深度学习中几乎从不严格成立——它仅在最优点的某个吸引盆内成立。在相变附近（参数可能跨越盆地边界时），PL 条件的局部性可能导致相变行为的定量修正。
- (2) 偏差表达式中使用的线性化 $g_t \approx H(\theta_t - \theta_t^*) + \xi_t$ 仅在 $\|\theta_t - \theta_t^*\|$ 较小时有效——这正是我们在相变点附近试图确定的量，形成了循环依赖。严格处理需要使用 Lyapunov 泛函方法，见 §7 开放问题。
- (3) 固定步长 α 的分析掩盖了递减步长下的更丰富的动力学——在递减步长下，“有效遗忘率”是步长衰减率与显式遗忘率的组合效应。

4.3 与质变点定理的结构平行

记忆-遗忘相变定理与质变点定理共享深刻的数学结构——两者均描述了由一个连续变化的控制参数触发的定性行为跃迁。

表 3: 质变点定理与记忆-遗忘相变定理的结构平行

维度	质变点定理	记忆-遗忘相变定理
控制参数	迭代次数 t	漂移速率 v （或遗忘率 λ ）
相变点	t_{crit} （临界迭代）	v_c （临界漂移）/ λ^* （临界保留率）
相变前	高方差探索， $\ \nabla \mathcal{L}\ $ 缓慢下降	单调记忆最优，MSE 随 λ 单调递减
相变后	PL 条件成立， $O(1/t)$ 快速收敛	有限遗忘更优，MSE 在 $\lambda^* < 1$ 取最小值
相变判据	$\ \nabla \mathcal{L}\ \leq \mu \cdot \text{diam}$	$\frac{d\text{MSE}}{d\lambda} _{\lambda=1}$ 的符号
数学机制	梯度噪声从“探索驱动”转为“收敛扰动”	偏差从“可控”转为“主导方差”

两种相变的本质都是**两种力的平衡点**——质变点是梯度信号与噪声的平衡，记忆-遗忘相变是历史偏差与当前方差的平衡。在两种情况下，临界点的位置由问题的内在几何（条件数 $\kappa = L/\mu$ 、噪声水平 σ^2 ）决定。

推论 4.2 (相变的普遍性猜想). 我们猜想，记忆-遗忘相变不仅限于指数遗忘策略。对于任何具有连续可调“遗忘强度”参数 $\gamma \in [0, 1]$ 的遗忘策略族（ $\gamma = 0$ 为无遗忘， $\gamma = 1$ 为即时遗忘），只要该族满足适当的平滑性条件，均存在临界漂移 v_c 产生类似的相变行为。有限窗口遗忘策略的相变分析见附录。

[猜想] 猜想状态：普遍性猜想的严格证明需要在遗忘策略函数空间上建立适当的拓扑，并证明 $\text{MSE}(\gamma)$ 在 $\gamma = 0$ 处的导数符号随 v 穿越 v_c 时改变是遗忘策略族的通用性质（generic property）。我们已对指数遗忘和有限窗口遗忘验证了该猜想，但对一般的非线性遗忘策略（如基于重要性采样的自适应遗忘），验证仍是开放问题。

4.4 相变图的数值特征

在临界漂移附近， $\text{MSE}(\lambda)$ 在 $\lambda = 1$ 处展现出从凸到非凸的转变（二阶导数改变符号）。这一几何特征具有可操作的工程含义：

- (1) **亚临界区** ($v < v_c$)：系统对遗忘不敏感——引入少量遗忘 ($\lambda < 1$ 但接近 1) 对 MSE 的影响是二阶的。这意味着在缓慢变化的环境中，“不遗忘”是一个**稳健**的选择。
- (2) **超临界区** ($v > v_c$)：系统对遗忘高度敏感——最优 λ^* 与 1 的差距随 v 超线性增长。这意味着在快速变化的环境中，精确调谐遗忘率带来一阶收益。
- (3) **临界慢化 (critical slowing down)**：在 $v \approx v_c$ 附近， $\text{MSE}(\lambda)$ 在 $\lambda = 1$ 附近异常平坦——二阶导数为零。这意味着在临界漂移附近，最优遗忘率对 v 的估计误差极度敏感。

[启发式] 相变在有限样本中的表现：以上分析是渐近的 ($t \rightarrow \infty$)。在有限 t 下，“相变”表现为交叉 (crossover) 而非尖锐跃迁——漂移效应的累积需要时间，对于有限的 t 和时间平均的漂移 $\bar{v}_t = \frac{1}{t} \sum_{s=0}^{t-1} v_s$ ，有效临界漂移为 $v_c(t) = v_c \cdot (1 + O(1/\sqrt{t}))$ 。

5 最优遗忘界：遗忘-延迟的帕累托前沿

5.1 动机：遗忘速度与检测延迟的权衡

前两节确立了**遗忘是必要的**（定理 1）和**存在最优遗忘率**（定理 2）。本节考察一个更精细的问题：在遗忘策略的设计中，存在两个相互竞争的目标——

- (1) **遗忘速度 (Forgetting Speed)**：系统丢弃过时信息的速度。快速遗忘意味着对分布偏移的敏捷响应。
- (2) **检测延迟 (Detection Delay)**：系统确认“目标确实发生了偏移”所需的时间。在分布偏移检测中，更长的观测窗口提供更高的统计置信度。

这两个目标**不可能同时最优**——快速遗忘意味着在分布偏移被统计确认之前就已经开始丢弃信息，增加了假阳性遗忘（丢弃了仍有价值的信息）的风险。本节严格建立这一权衡的不可避免性，并刻画其帕累托前沿。

5.2 偏移检测的形式化

定义 5.1 (分布偏移检测问题). 在时间 t ，给定最近 W 个观测 $\{x_{t-W+1}, \dots, x_t\}$ ，判断是否发生了分布偏移：即检验

$$H_0 : P_t = P_{t-1} = \dots = P_{t-W+1} \quad (\text{无偏移}), \quad (33)$$

$$H_1 : P_t \neq P_{t-1} \quad (\text{在时间 } t \text{ 发生偏移}) \quad \square \quad (34)$$

检测延迟 τ 定义为从偏移实际发生到检测器以置信度 $1 - \alpha$ 确认偏移之间的期望时间步数。

定理 5.2 (遗忘-延迟的不可逃避权衡). 考虑指数遗忘策略, 遗忘率 $\gamma = 1 - \lambda \in (0, 1]$ 。对于大小为 δ 的分布偏移 (以 Wasserstein-2 距离度量 $\mathcal{W}_2(P_t, P_{t-1}) \geq \delta$) , 任何检测器的期望延迟 τ 满足:

$$\tau \geq \frac{\sigma^2}{2\delta^2} \cdot \log \frac{1}{\alpha} \cdot \frac{1}{\gamma} - O(1) \square \quad (35)$$

等价地, 遗忘率 γ 和检测延迟 τ 满足帕累托下界:

$$\boxed{\gamma \cdot \tau \geq C(\delta, \sigma, \alpha)} \square \quad (36)$$

其中 $C(\delta, \sigma, \alpha) = \frac{\sigma^2}{2\delta^2} \cdot \log \frac{1}{\alpha}$ 。

即: 遗忘速率与检测延迟的乘积存在不可突破的下界。遗忘加速一倍, 最小可实现的检测延迟至多减半——无法更多。

5.3 证明

证明. 步骤 1 (指数遗忘下的有效样本量): 在指数遗忘策略下, 时间 s 的观测在时间 t 的有效权重为 $(1 - \gamma)\gamma^{t-s}$ 。“有效样本量”(ESS) 为:

$$N_{\text{eff}}(\gamma) = \frac{(\sum_{k=0}^{\infty} (1 - \gamma)\gamma^k)^2}{\sum_{k=0}^{\infty} (1 - \gamma)^2 \gamma^{2k}} = \frac{1}{1 - \gamma^2} \cdot (1 - \gamma)^2 \cdot \frac{1}{(1 - \gamma)^2 / (1 - \gamma^2)} = \frac{1 + \gamma}{1 - \gamma} \square \quad (37)$$

关键: $N_{\text{eff}}(\gamma) \approx 2/\gamma$ 当 $\gamma \ll 1$ ——有效样本量与遗忘率成反比。

步骤 2 (检测的信息论下界): 偏移检测可归约为双样本均值偏移检验。在 d 维高斯观测模型下, 基于 $\text{ESS} = N_{\text{eff}}$ 的独立有效样本, 检测大小为 δ 的偏移所需的最小样本量满足 (由 Le Cam 二点法或 Chernoff-Stein 引理):

$$N_{\text{eff}} \geq \frac{\sigma^2}{2\delta^2} \cdot \log \frac{1}{\alpha} \cdot (1 + o(1)) \square \quad (38)$$

这一界限是紧的——由似然比检验 (LRT) 以 $N_{\text{eff}} = \frac{\sigma^2}{2\delta^2} \log \frac{1}{\alpha}$ 精确达到。

步骤 3 (从样本量到延迟): 检测延迟 τ 是累积 N_{eff} 个有效样本所需的 日历时间。在指数遗忘下, t 个观测的有效样本量为 $N_{\text{eff}}(t) \approx \frac{1+\gamma}{1-\gamma} \cdot (1 - \gamma^t)$ 。对于 $t \gg 1/\gamma$, $N_{\text{eff}}(t) \rightarrow (1 + \gamma)/(1 - \gamma) \approx 2/\gamma$ 。

因此, 达到 $N_{\text{eff}} \geq \frac{\sigma^2}{2\delta^2} \log \frac{1}{\alpha}$ 所需的最小日历时间 τ 满足:

$$\frac{1 + \gamma}{1 - \gamma} \cdot (1 - \gamma^\tau) \geq \frac{\sigma^2}{2\delta^2} \log \frac{1}{\alpha} \square \quad (39)$$

解出 τ (在 $\gamma \ll 1$ 极限下):

$$\tau \geq \frac{\sigma^2}{2\delta^2} \cdot \log \frac{1}{\alpha} \cdot \frac{1}{\gamma} - O(1) \square \quad (40)$$

步骤 4 (帕累托前沿的不可突破性): 上述下界对于任何使用指数遗忘权重的检测器都是不可突破的——因为它来自信息论的基本极限 (Chernoff-Stein 引理), 而非特定算法的局限。任何声称在给定 γ 下实现 $\tau < C/\gamma$ 的系统必然违反数据处理不等式。 $\square$

[严格证明] 证明状态: 在独立高斯观测假设下严格。步骤 1-4 基于信息论标准工具 (Le Cam、Chernoff-Stein), 界是紧的且常数精确。 **核心局限:**

- (1) 高斯假设: 在重尾噪声或离散观测下, 界的形式变为 $C(\alpha)/\delta^2$ 但 $C(\alpha)$ 的表达式不同——然而 $\gamma \cdot \tau = \Omega(1/\delta^2)$ 的标度关系在一般分布族下仍然成立 (由 Le Cam 的局部渐近正态性)。
- (2) “有效样本量” N_{eff} 的定义依赖于指数遗忘的特定加权结构。对于有限窗口遗忘, $N_{\text{eff}} = W$ (精确等于窗口大小), 且帕累托界变为 $\tau/W \geq C/\delta^2$ ——结构相同但常数不同。

5.4 遗忘策略的帕累托最优性

定义 5.3 (帕累托最优遗忘策略). 遗忘策略 π 是帕累托最优的, 如果不存在另一个遗忘策略 π' 满足:

- $\tau(\pi') \leq \tau(\pi)$ (更短或相等的检测延迟),
- $\gamma(\pi') \leq \gamma(\pi)$ (更慢或相等的遗忘), 且
- 至少一个不等式严格成立。

所有帕累托最优策略构成帕累托前沿 (Pareto frontier)。

推论 5.4 (帕累托前沿的参数化). 指数遗忘策略族 $\{\pi_\gamma : \gamma \in (0, 1]\}$ 在遗忘-延迟平面上构成帕累托前沿, 其参数化形式为:

$$\mathcal{P} = \left\{ (\gamma, \tau) : \tau = \frac{C}{\gamma}, \gamma \in (0, 1] \right\} \square \quad (41)$$

有限窗口遗忘策略族 $\{\pi_W : W \in \mathbb{N}\}$ 构成同一前沿上的离散采样:

$$\mathcal{P}_W = \left\{ \left(\frac{1}{W}, \tau \right) : \tau = C \cdot W, W \in \mathbb{N} \right\} \square \quad (42)$$

关键结论: 不存在“同时最优”的遗忘策略。设计者必须在遗忘速度和检测延迟之间做出不可避免的权衡——这一权衡由问题参数 (δ, σ, α) 决定, 不由算法设计决定。

[启发式] 工程含义: 这一结论对遗忘系统的设计有直接指导意义。如果应用场景对延迟敏感 (必须快速响应分布偏移, 即使以误报为代价), 应选择高遗忘率 (γ 大, λ 小)。如果应用场景对精度敏感 (必须在高置信度下确认偏移后才采取行动), 应选择低遗忘率 (γ 小, λ 大)。不存在万能的中间值——帕累托前沿上的每一点对应不同的应用偏好。

5.5 与 Theorem 1 下界的互补关系

SCX Theorem 1 给出了多专家检测能力的下界: $F_1 \geq 1 - \frac{1}{\eta} \sum_s \rho_s \exp(-2M\Delta_s^2)$ ——专家数量 M 与检测质量 F_1 之间的权衡。最优遗忘界定理的结论在结构上平行但维度不同: 遗忘速度 γ 与检测延迟 τ 之间的权衡。

两者的互补性在于: Theorem 1 告诉我们“需要多少专家来维持检测能力”; 最优遗忘界告诉我们“在非稳态环境中, 维持检测能力的时间代价”。将两者结合, 可以得到一个完整的 SCX 系统在非稳态环境中的资源分配理论——这是未来的工作方向 (见 §7 开放问题)。

6 遗忘算子 $\mathcal{F}_t$ 的形式定义与收敛性

6.1 动机: 从策略到算子

前三节将遗忘视为 Spring 参数更新的权重方案——一种附属于优化的机制。本节采取更基本的视角: 将遗忘本身形式化为记忆空间上的算子, 研究其代数结构和收敛性质。这一抽象允许我们统一处理指数遗忘、有限窗口、自适应遗忘等策略, 并为“最优遗忘”提供算子理论的基础。

6.2 记忆空间的公理化

定义 6.1 (记忆空间). 记忆空间 $\mathcal{M}$ 是一个可分的实 Hilbert 空间, 其元素 $m \in \mathcal{M}$ 称为记忆状态。 $\mathcal{M}$ 的内积记为 $\langle \cdot, \cdot \rangle_{\mathcal{M}}$, 诱导范数 $\|\cdot\|_{\mathcal{M}}$ 。

记忆状态 m_t 编码系统在时间 t 时对历史数据流的全部内部表示。 $\mathcal{M}$ 的维度可以是有限的 (如参数向量的维度 d) 或无限的 (如函数空间的再生核 Hilbert 空间)。

定义 6.2 (观测注入算子). 对于每个时间步 t , 观测注入算子 $\mathcal{I}_t: \mathcal{X} \times \mathcal{Y} \rightarrow \mathcal{M}$ 将观测 (x_t, y_t) 映射为记忆空间中的一个增量:

$$\delta m_t = \mathcal{I}_t(x_t, y_t) \quad \square \quad (43)$$

在 *Spring SE-1* 中, $\delta m_t = -\alpha_t \cdot g_t$ (负梯度步)。

定义 6.3 (遗忘算子). 遗忘算子是一个映射 $\mathcal{F}_t: \mathcal{M} \times \mathcal{M} \rightarrow \mathcal{M}$, 满足:

$$m_{t+1} = \mathcal{F}_t(m_t, \delta m_t) \quad \square \quad (44)$$

其中 m_t 是当前记忆状态, δm_t 是当前观测增量。

6.3 遗忘算子的公理

我们提出遗忘算子应满足的三条公理。这些公理既是合理遗忘的必要条件, 也足够约束出具有良好数学结构的算子类。

公理 6.4 (遗忘算子的三条公理). (A1) **压缩性 (Contractivity)**: 存在 $\rho_t \in [0, 1]$ 使得对所有 $m, m' \in \mathcal{M}$ 和固定的 δm ,

$$\|\mathcal{F}_t(m, \delta m) - \mathcal{F}_t(m', \delta m)\|_{\mathcal{M}} \leq \rho_t \cdot \|m - m'\|_{\mathcal{M}} \quad \square \quad (45)$$

参数 ρ_t 称为**保留系数**——它控制旧记忆被保留的比例。 $\rho_t = 1$ 意味着完美记忆 (等距), $\rho_t < 1$ 意味着遗忘 (压缩)。

(A2) **新息线性性 (Innovation Linearity)**: $\mathcal{F}_t(m, \cdot)$ 关于第二个参数是线性的:

$$\mathcal{F}_t(m, a \cdot \delta m + b \cdot \delta m') = a \cdot \mathcal{F}_t(m, \delta m) + b \cdot \mathcal{F}_t(m, \delta m') - (a + b - 1) \cdot \mathcal{F}_t(m, 0) \quad \square \quad (46)$$

在 $\mathcal{F}_t(m, 0) = m$ (无观测时记忆不变) 的特殊情况下, 此公理简化为仿射性: $\mathcal{F}_t(m, \delta m) = \rho_t m + (1 - \rho_t) \cdot \mathcal{T}_t(\delta m)$, 其中 $\mathcal{T}_t$ 是将观测增量“翻译”为记忆增量的线性算子。

(A3) **因果性 (Causality)**: $\mathcal{F}_t$ 仅依赖于 $\{m_s, \delta m_s\}_{s \leq t}$ ——不允许未来信息影响当前遗忘决策。

公理 A1 (压缩性) 是遗忘的核心数学特征——“遗忘”在算子意义上等价于“信息压缩”。公理 A2 (新息线性性) 确保了遗忘算子的代数可处理性。公理 A3 (因果性) 排除了非物理的“回顾性遗忘”。

6.4 遗忘算子的标准形式

命题 6.5 (遗忘算子的标准表示). 在公理 A1–A3 下, 任何遗忘算子可表示为:

$$\boxed{\mathcal{F}_t(m, \delta m) = \rho_t \cdot m + (1 - \rho_t) \cdot \mathcal{T}_t(\delta m)} \quad \square \quad (47)$$

其中 $\rho_t \in [0, 1]$ 为保留系数, $\mathcal{T}_t: \mathcal{M} \rightarrow \mathcal{M}$ 为线性新息变换。

证明. 由公理 A2 (新息线性性) 和 $\mathcal{F}_t(m, 0) = \rho_t m$ (无观测时的压缩), 对任意 δm 有:

$$\begin{aligned} \mathcal{F}_t(m, \delta m) &= \mathcal{F}_t(m, 1 \cdot \delta m + 0 \cdot 0) \\ &= 1 \cdot \mathcal{F}_t(m, \delta m) + 0 \cdot \mathcal{F}_t(m, 0) - 0 \cdot \mathcal{F}_t(m, 0) \\ &= \rho_t \cdot m + (1 - \rho_t) \cdot \mathcal{T}_t(\delta m) \quad \square \end{aligned} \quad (48)$$

其中 $\mathcal{T}_t$ 定义为 $\mathcal{T}_t(\delta m) = \frac{\mathcal{F}_t(m, \delta m) - \rho_t m}{1 - \rho_t}$ (当 $\rho_t < 1$; 当 $\rho_t = 1$ 时退化, 此时遗忘算子为恒等映射)。由公理 A1, $\|\mathcal{T}_t(\delta m)\|_{\mathcal{M}} \leq \|\delta m\|_{\mathcal{M}}$, 即 $\mathcal{T}_t$ 是非膨胀的。 $\square$

标准表示揭示了遗忘算子的本质结构: 它是一个凸组合—— ρ_t 份旧记忆加上 $(1 - \rho_t)$ 份变换后的新观测。遗忘率 $\gamma_t = 1 - \rho_t$ 决定了新观测在记忆中占据的比例。

6.5 遗忘算子与已知遗忘策略的对应

标准表示(47)统一了前述所有遗忘策略 (以及更多):

- (1) **单调记忆**: $\rho_t = 1$ 对所有 t 。遗忘算子退化为恒等映射——旧记忆永不衰减。定理 3.1 证明了这在非稳态下导致发散。
- (2) **指数遗忘 (EF)**: $\rho_t = \lambda$ (常数), $\mathcal{T}_t(\delta m) = \delta m$ 。

$$m_{t+1} = \lambda m_t + (1 - \lambda) \delta m_t \quad \square \quad (49)$$

- (3) **自适应遗忘**: $\rho_t = \rho(\|\delta m_t\|, \|m_t\|, t)$ ——保留系数是观测新息大小、当前记忆范数和时间的函数。大新息 (暗示分布偏移) 触发更小的 ρ_t (更快遗忘)。

注记 6.6. 有限窗口遗忘 (FW) 不完全符合公理 A2 (因为硬截断在代数上不是平滑的), 但可以用一族平滑截断函数逼近——例如 $\rho_t = 1 - \frac{1}{W} \cdot \sigma(t - t_0)$, 其中 σ 为 sigmoid 函数。在 $W \rightarrow \infty$ 极限下恢复单调记忆。

6.6 遗忘算子迭代的收敛性

我们现在研究遗忘算子迭代的长期行为。

定理 6.7 (遗忘算子迭代的收敛性). 设遗忘算子序列 $\{\mathcal{F}_t\}_{t=0}^{\infty}$ 具有标准形式 $\mathcal{F}_t(m, \delta m) = \rho_t m + (1 - \rho_t) \mathcal{T}_t(\delta m)$, 满足 $\rho_t \in [0, 1]$ 且 $\mathcal{T}_t$ 是非膨胀线性算子。假设观测增量序列 $\{\delta m_t\}$ 来自一个遍历过程, 具有平稳均值 $\bar{\delta m} = \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}[\delta m_t]$ 。则:

(1) 收缩性：若 $\limsup_{t \rightarrow \infty} \rho_t \leq \bar{\rho} < 1$ ，则记忆状态序列 $\{m_t\}$ 收敛到唯一的平稳分布，其期望满足：

$$\|\mathbb{E}[m_\infty] - \bar{m}\|_{\mathcal{M}} \leq \frac{\bar{\rho}}{1 - \bar{\rho}} \cdot \sup_t \|\mathbb{E}[\delta m_t] - \bar{m}\|_{\mathcal{M}} \quad \square \quad (50)$$

(2) 收敛速率：从任意初始状态 m_0 出发， $\mathbb{E}[m_t]$ 以速率 $O(\bar{\rho}^t)$ 收敛到稳态期望。

(3) 稳态方差：若 $\{\delta m_t\}$ 是不相关的 ($\text{Cov}(\delta m_t, \delta m_s) = 0$ 对 $t \neq s$)，稳态方差为：

$$\mathbb{V}[m_\infty] = (1 - \bar{\rho})^2 \sum_{k=0}^{\infty} \bar{\rho}^{2k} \cdot \mathbb{V}[\mathcal{T}_{t-k}(\delta m_{t-k})] = \frac{1 - \bar{\rho}}{1 + \bar{\rho}} \cdot \bar{\sigma}^2 \quad \square \quad (51)$$

其中 $\bar{\sigma}^2 = \limsup_t \mathbb{V}[\mathcal{T}_t(\delta m_t)]$ 。

(4) 遗忘-方差权衡：稳态方差随 $\bar{\rho} \rightarrow 1$ 而消失（更多记忆平滑噪声），但稳态偏差随 $\bar{\rho} \rightarrow 1$ 而放大（更多记忆保留过时信息）。最优 $\bar{\rho}^*$ 由两者的平衡决定——这给出了定理 4.1 的算子理论重新推导。

证明. 步骤 1（迭代展开）：从 m_0 开始，展开 t 步：

$$\begin{aligned} m_t &= \rho_{t-1} m_{t-1} + (1 - \rho_{t-1}) \mathcal{T}_{t-1}(\delta m_{t-1}) \\ &= \left(\prod_{k=0}^{t-1} \rho_k \right) m_0 + \sum_{s=0}^{t-1} (1 - \rho_s) \left(\prod_{k=s+1}^{t-1} \rho_k \right) \mathcal{T}_s(\delta m_s) \quad \square \end{aligned} \quad (52)$$

步骤 2（期望的收敛）：取期望。在平稳条件下 $\mathbb{E}[\delta m_t] \rightarrow \bar{m}$ ：

$$\begin{aligned} \mathbb{E}[m_t] &= \left(\prod_{k=0}^{t-1} \rho_k \right) m_0 + \sum_{s=0}^{t-1} (1 - \rho_s) \left(\prod_{k=s+1}^{t-1} \rho_k \right) \mathbb{E}[\mathcal{T}_s(\delta m_s)] \\ &\rightarrow \frac{1 - \bar{\rho}}{1 - \bar{\rho}} \cdot \bar{m} = \bar{m} \quad (\text{当 } \rho_t \equiv \bar{\rho} \text{ 时}) \quad \square \end{aligned} \quad (53)$$

步骤 3（偏差界）：稳态期望与瞬时观测期望之间的差距：

$$\begin{aligned} \|\mathbb{E}[m_\infty] - \mathbb{E}[\delta m_t]\|_{\mathcal{M}} &\leq \sum_{k=0}^{\infty} (1 - \bar{\rho}) \bar{\rho}^k \cdot \|\mathbb{E}[\delta m_{t-k}] - \mathbb{E}[\delta m_t]\|_{\mathcal{M}} \\ &\leq \frac{\bar{\rho}}{1 - \bar{\rho}} \cdot \sup_s \|\mathbb{E}[\delta m_s] - \bar{m}\|_{\mathcal{M}} \quad \square \end{aligned} \quad (54)$$

步骤 4（方差的计算）：在不相关假设下：

$$\begin{aligned} \mathbb{V}[m_\infty] &= \mathbb{V} \left[(1 - \bar{\rho}) \sum_{k=0}^{\infty} \bar{\rho}^k \mathcal{T}_{t-k}(\delta m_{t-k}) \right] \\ &= (1 - \bar{\rho})^2 \sum_{k=0}^{\infty} \bar{\rho}^{2k} \cdot \mathbb{V}[\mathcal{T}_{t-k}(\delta m_{t-k})] \\ &= (1 - \bar{\rho})^2 \cdot \frac{\bar{\sigma}^2}{1 - \bar{\rho}^2} = \frac{1 - \bar{\rho}}{1 + \bar{\rho}} \cdot \bar{\sigma}^2 \quad \square \end{aligned} \quad (55)$$

□

[严格证明] 证明状态：在 $\rho_t \equiv \bar{\rho}$ （常数遗忘率）和不相关观测假设下严格。步骤 1–4 是线性系统的标准分析。

核心局限：

- (1) 常数 $\bar{\rho}$ 假设排除了自适应遗忘策略——后者的收敛分析需要随机压缩系统理论或 Lyapunov 泛函方法。初步结果（见 §7 开放问题）表明，只要 $\mathbb{E}[\log \rho_t] < 0$ ，自适应遗忘算子仍收敛，但稳态分布可能非高斯。
- (2) 不相关观测假设在时间序列数据中不成立——自相关的 $\{\delta m_t\}$ 会改变方差表达式。在 AR(1) 自相关结构 $\text{Cov}(\delta m_t, \delta m_{t-k}) = \phi^k \bar{\sigma}^2$ 下，稳态方差修正为 $\mathbb{V}[m_\infty] = \frac{1-\bar{\rho}}{1+\bar{\rho}} \cdot \frac{1+\bar{\rho}\phi}{1-\bar{\rho}\phi} \cdot \bar{\sigma}^2$ 。

6.7 遗忘算子半群与指数遗忘的几何

当遗忘算子是时不变的（ $\mathcal{F}_t = \mathcal{F}$ 对所有 t ），它们构成一个离散半群：

命题 6.8 (遗忘半群). 指数遗忘算子族 $\{\mathcal{F}_\lambda : \lambda \in [0, 1]\}$ 构成一个交换半群：

$$\mathcal{F}_{\lambda_1} \circ \mathcal{F}_{\lambda_2} = \mathcal{F}_{\lambda_1 \lambda_2} \quad (56)$$

半群的单位元为 $\mathcal{F}_1$ （恒等，无遗忘），零元为 $\mathcal{F}_0$ （完全遗忘）。遗忘算子的生成元为：

$$\mathcal{L}[m] = \lim_{\gamma \rightarrow 0^+} \frac{\mathcal{F}_{1-\gamma}[m] - m}{\gamma} = \mathcal{T}(\delta m) - m \quad (57)$$

满足 $\mathcal{F}_\lambda = \exp((1-\lambda)\mathcal{L})$ （在半群指数映射的意义下）。

证明. 直接计算：

$$\begin{aligned} \mathcal{F}_{\lambda_1}(\mathcal{F}_{\lambda_2}(m, \delta m_1), \delta m_2) &= \lambda_1(\lambda_2 m + (1-\lambda_2)\delta m_1) + (1-\lambda_1)\delta m_2 \\ &= \lambda_1 \lambda_2 m + \lambda_1(1-\lambda_2)\delta m_1 + (1-\lambda_1)\delta m_2 \end{aligned} \quad (58)$$

当 $\delta m_1 = \delta m_2 = \delta m$ 时， $\mathcal{F}_{\lambda_1} \circ \mathcal{F}_{\lambda_2}(m, \delta m) = \lambda_1 \lambda_2 m + (1-\lambda_1 \lambda_2)\delta m = \mathcal{F}_{\lambda_1 \lambda_2}(m, \delta m)$ 。生成元的计算是标准的半群导数。 $\square$

这一半群结构揭示了遗忘的可加性：两次连续的指数遗忘等价于一次具有乘积保留率的遗忘。 n 次保留率为 λ 的遗忘等价于一次保留率为 λ^n 的遗忘——遗忘在时间上的复合是指数加速的。这一观察为分层遗忘策略（多时间尺度的遗忘）提供了代数基础。

6.8 遗忘算子视角下的相变定理

遗忘算子理论为记忆-遗忘相变定理（定理 4.1）提供了一个优雅的重新推导。在算子语言下：

- (1) 遗忘算子 $\mathcal{F}_\lambda$ 产生稳态记忆分布 μ_λ ，其特征由偏差泛函 $B(\lambda) = \|\mathbb{E}_{\mu_\lambda}[m] - \bar{m}\|_{\mathcal{M}}$ 和方差泛函 $V(\lambda) = \text{Tr}(\text{Cov}_{\mu_\lambda}(m))$ 刻画。
- (2) 相变发生在 $\frac{d}{d\lambda}(B(\lambda)^2 + V(\lambda))\big|_{\lambda=1}$ 改变符号时——即偏差随遗忘减少的边际收益超过方差随遗忘增加的边际代价时。

(3) 临界漂移 v_c 的特征方程：

$$\left. \frac{dB(\lambda)^2}{d\lambda} \right|_{\lambda=1} = - \left. \frac{dV(\lambda)}{d\lambda} \right|_{\lambda=1} \quad \square \quad (59)$$

左侧是遗忘带来的偏差减少的边际收益，右侧是遗忘带来的方差增加的边际代价。

这一“边际收益 = 边际代价”的结构在算子理论中是普遍的——类似的方程出现在统计学习理论的偏差-方差权衡、信息论中的率失真理论、以及热力学中的自由能最小化。

7 讨论与诚实暴击

7.1 主要贡献的回顾

本文从 SCX 框架的 Spring SE-1 动力学出发，建立了记忆-遗忘的形式理论。四个定理构成了一个逻辑递进的体系：

- (1) 遗忘的必要性定理确立了遗忘的逻辑地位——不是工程优化，而是正确性条件。
- (2) 记忆-遗忘相变定理划分了策略空间——根据漂移速率，系统自动落入记忆最优或遗忘最优的区域。
- (3) 最优遗忘界刻画了性能前沿——遗忘与延迟的不可逃避的权衡，由信息论下界保证。
- (4) 遗忘算子 $\mathcal{F}_t$ 提供了代数基础——统一的算子语言，收敛性保证，以及与已知遗忘策略的精确对应。

7.2 诚实暴击：每个定理的局限与未竟问题

以下是本文的完整诚实暴击——逐条列出每个结论的局限、简化假设和已知的反例或修正需求。

对遗忘必要性定理的暴击

暴击 1: 渐近发散的有限时间无意义性。 定理证明 $\lim_{t \rightarrow \infty} \mathbb{E}[\|\theta_t - \theta_t^*\|^2] = \infty$ ，但任何实际系统运行在有限时间内。如果漂移 $v_{\min}$ 足够小（如 10^{-6} /步），发散在 10^9 步之后才变得显著——远超任何系统的运行寿命。此时“必然发散”在实际意义上等于“不发散”。需要有限时间的非渐近界来补充渐近结论。

暴击 2: 漂移下界假设的可验证性问题。 $\liminf_{t \rightarrow \infty} \mathbb{E}[\|\theta_{t+1}^* - \theta_t^*\|] \geq v_{\min} > 0$ 是定理的核心假设，但在实践中漂移本身是不可直接观测的——我们只能通过数据间接推断漂移的存在和大小。如果检测不到漂移（定理 3 的延迟问题），就无法判断定理 1 的前提是否成立。这是一个认识论循环。

暴击 3: 均值回复漂移的例外。 如果漂移是均值回复的（如 Ornstein-Uhlenbeck 过程），历史平均 $\bar{\theta}_t^*$ 可能是比当前 θ_t^* 更好的估计（因为 θ_t^* 受暂时性冲击的污染）。此时“遗忘”反而有害——我们需要更精细的选择性遗忘（仅遗忘永久性偏移，保留暂时性波动中的信息）。

暴击 4: 单调记忆的夸大。我们将“无遗忘”建模为等权平均 $w(t, s) = 1/t$ ，但实际的 Spring SE-1 在递减步长 α_t 下已经具有**隐式遗忘**——早期梯度因为 α_s 大而产生大更新，但大 α_s 时代已经过去 ($\alpha_t \rightarrow 0$)。步长衰减本身构成了某种“遗忘”。因此，严格来说 Spring SE-1 并非完全不遗忘——它只是没有**显式遗忘**。

对记忆-遗忘相变定理的暴击

暴击 1: PL 条件的致命局限。相变定理在 PL 条件全局成立的前提下推导了 v_c 的表达式。但 PL 条件在非凸深度学习中**几乎从不全局成立**——它只在最优点的某个吸引盆地内成立。当漂移 v 较大时， θ_t^* 可能在不同盆地间跳跃，PL 条件在盆地边界处失效。此时“相变”可能被盆地跳跃的不连续性所掩盖。

暴击 2: 固定步长的简化。实际 Spring SE-1 使用递减步长 $\alpha_t \propto 1/t$ 。在递减步长下，“有效遗忘率”是 α_t 衰减率与显式遗忘率 γ 的组合效应。固定步长分析可能高估了遗忘的必要性（因为步长衰减本身提供了某种“渐进遗忘”）。

暴击 3: 二次损失近似的精度。偏差项推导 $b(\lambda)^2 \approx v^2/(\alpha^2 \mu^2) \cdot (\lambda/(1-\lambda))^2$ 使用了 $g_t \approx H(\theta_t - \theta_t^*)$ 的线性化。在一般非凸损失下，梯度与参数误差的关系是非线性的，偏差的精确行为需要更复杂的分析。特别地，在损失景观具有鞍点和局部极小值的区域，线性近似可能完全失效。

暴击 4: 常数 λ^* 的超参数敏感性。最优保留率 λ^* 以复杂的方式依赖于问题参数 (μ, L, σ^2, v) ——这些参数在实践中难以精确估计。 λ^* 对 $\hat{v}$ （漂移速率估计）的敏感性在临界区 ($v \approx v_c$) 可能极高——小的估计误差导致大的策略偏差。

对最优遗忘界的暴击

暴击 1: 高斯假设的普适性。定理中使用的高斯观测模型是信息论界的“最有利情况”（least favorable case for detection within the class of distributions with bounded second moment is Gaussian）。在重尾分布或离散分布下，检测可能更难或更容易，下界常数的精确值会改变——但 $\gamma \cdot \tau = \Omega(1/\delta^2)$ 的标度关系具有更广泛的普适性（由局部渐近正态性保证）。

暴击 2: 偏移大小 δ 的先验知识假设。帕累托前沿的位置依赖于偏移大小 δ ——但在实践中， δ 在偏移发生前不可知。这意味着不存在一个在所有可能的 δ 下都帕累托最优的遗忘策略。设计者必须在**先验猜测**的 δ 下优化，或使用极小极大准则。

暴击 3: 假阳性与假阴性的不对称代价。定理仅处理检测的统计显著性 (α 水平)，未纳入假阳性（在无偏移时误报偏移）和假阴性（偏移发生后未检测到）的不同决策代价。在许多应用中（如医疗诊断、金融风控），假阴性的代价远高于假阳性——这会使帕累托前沿向更低遗忘率方向倾斜。

对遗忘算子 $\mathcal{F}_t$ 的暴击

暴击 1: Hilbert 空间假设的范围。记忆空间的 Hilbert 结构假设（完备内积空间）允许我们使用压缩映射原理和谱分析。但实际记忆系统（如 Transformer 的 KV 缓存、LSTM 的隐藏状

态和细胞状态)的结构可能不具有自然的 Hilbert 空间结构。在这些情况下,算子理论的结论需要被重新检验。

暴击 2: 压缩性公理的过强性。公理 A1 要求全局压缩性 $\|\mathcal{F}_t(m, \delta m) - \mathcal{F}_t(m', \delta m)\| \leq \rho_t \|m - m'\|$ 。但实际遗忘机制可能仅在特定方向上压缩(如仅在“过时信息子空间”上压缩,在“稳定信息子空间”上保持)。方向性遗忘算子(如投影遗忘)不符合全局压缩公理,但可能在实际中更有用。

暴击 3: 遗忘半群的离散性。我们将遗忘建模为离散时间半群,但连续时间遗忘(遗忘微分方程 $\frac{dm}{dt} = -\gamma(t) \cdot (m - \mathcal{T}(\delta m))$)可能提供更丰富的数学结构——特别是与随机微分方程和扩散过程的联系。

7.3 开放问题

以下问题超出了本文的范围,但构成了 Temporal SCX 未来研究议程的核心:

OP1 自适应遗忘的收敛理论。当 ρ_t 依赖于 $\|\delta m_t\|$ 时(“惊讶驱动的遗忘”),遗忘算子序列 $\{\mathcal{F}_t\}$ 是非平稳和非线性的。证明其在一般条件下的收敛性(或发散条件)需要随机压缩系统理论。初步数值实验(未在本文中报告)显示:惊讶驱动的遗忘在阶跃偏移下优于固定速率遗忘,但在渐变偏移下可能出现震荡。

OP2 选择性遗忘的信息准则。遗忘必要性定理说“必须遗忘”,但它没有指示遗忘什么。一种有前景的方向是使用条件互信息 $I(\text{当前}; \text{历史} \mid \text{状态})$ 来决定保留/丢弃——当历史信息在当前状态下不提供关于目标的额外信息时,它可以被安全遗忘。这将是 SCX 的条件互信息准则 $I(Y; P \mid S) > 0$ 在时间维度上的推广。

OP3 多时间尺度遗忘的分层结构。遗忘半群的可加性(命题 6.8)暗示了分层遗忘的可能性——不同时间尺度的遗忘算子可以嵌套。快速遗忘层处理瞬时噪声,慢速遗忘层保留长期趋势。这与神经科学中多时间尺度记忆系统(工作记忆/短期记忆/长期记忆)的层级结构形成有趣的对应。

OP4 遗忘与省定理的统一框架。省定理和遗忘必要性定理分别处理了无输入退化和输入漂移不适应两种情况。一个统一的数学结构——“广义省定理”——将两者作为同一退化现象的两种极限情形(零输入速率 vs 非零输入漂移),仍有待建立。初步方向:将省定理中的遗忘率 γ 与遗忘必要性定理中的漂移 v 统一为一个“有效退化率”参数。

OP5 遗忘-记忆相变在神经网络中的实验验证。定理 2 的相变预测可以在受控实验中检验:在具有已知漂移速率的合成数据流上训练线性网络或小型 MLP,扫描遗忘率 λ 并测量稳态 MSE,验证 MSE 曲线在 $v < v_c$ 和 $v > v_c$ 时的定性差异。初步理论预测在论文提交时尚未完成系统实验。

OP6 遗忘算子的量子推广。遗忘算子的压缩性(公理 A1)与量子信道(完全正压缩映射)的数学形式高度相似。记忆状态的量子表示可能产生信息论上更优的遗忘策略——例如利用量子叠加同时保留“遗忘”和“不遗忘”的幅度,直到分布偏移被确认后再进行“测量”。

7.4 对 SCX 理论体系的影响

Temporal SCX 的四个定理对 SCX 框架的已有定理体系产生了以下深远影响：

- (1) **省定理的补全。**省定理处理了“停止一切更新”的退化场景。遗忘必要性定理处理了“持续更新但目标漂移”的退化场景。两者合在一起，覆盖了 SCX 系统可能面临的全部退化模式：系统内部的衰退（省定理）和系统外部的变化（遗忘必要性定理）。
- (2) **Spring SE-1 的推广。**将 Spring SE-1 从收敛到固定目标推广为跟踪时变目标，大大扩展了 Spring 动力学在真实世界场景中的适用范围。
- (3) **SCX 记忆库设计的理论基础。**Spring 记忆库 $\mathcal{M}_t$ 的设计现在有了一个形式化的指导原则：遗忘算子的选择（ λ 或 W ）应由环境的漂移速率 v 决定——在低漂移环境中扩展记忆，在高漂移环境中收缩记忆。
- (4) **质变点定理的补充。**质变点定理描述了学习过程的相变（探索 $\rightarrow$ 收敛），记忆-遗忘相变定理描述了记忆策略的相变（记忆 $\rightarrow$ 遗忘）。两个相变共同描绘了 SCX 系统的完整动力学景观。

7.5 工程建议（带诚实标注）

基于本文的定理，我们提出以下 SCX 系统设计建议——每个建议均标注了从数学定理到工程实践的映射不确定性。

建议 1：漂移速率估计作为一等公民。[启发式] 定理 1–3 均表明：遗忘策略的选择应取决于漂移速率 v 。因此，SCX 系统应内建漂移速率估计模块（如基于滑动窗口的 θ_t^* 变化检测），并将估计值 $\hat{v}$ 作为遗忘超参数的自动调节信号。**不确定性：**漂移速率估计本身需要遗忘（旧数据中的 θ_s^* 已经过时）——这构成了另一个层的“元遗忘”问题。

建议 2：分层遗忘架构。[启发式] 在半群可加性的指导下，不同组件可以使用不同的保留率：Spring 参数更新使用较慢的遗忘（ $\lambda \approx 0.99$ ），而 Yajie 多专家审计使用较快的遗忘（ $\lambda \approx 0.9$ ），以快速检测数据质量的变化。**不确定性：**组件之间的遗忘率差异可能导致不一致的内部状态表示。

建议 3：遗忘-延迟预算。[启发式] 定理 3 的帕累托前沿将 $\gamma \cdot \tau$ 视为不可突破的预算约束。设计者应根据应用的延迟容忍度（最大可接受 τ ）来确定最大可接受 γ ，然后在 $\gamma \leq \gamma_{\max}$ 的约束下优化其他指标。**不确定性：**帕累托界是渐近的——在有限样本下，存在以更高方差为代价的“超前沿”策略（如序贯概率比检验 SPRT），其有限样本性能可能突破渐近界。

8 结论：记忆的数学本质

本文的核心论点是：记忆与遗忘不是认知心理学的研究对象——它们在数学上具有严格的、可从 SCX 框架的动力学中推导出来的形式结构。这一形式结构揭示了关于记忆的三个本质事实：

- (1) **遗忘是逻辑必然（定理 1）**。在非稳态数据流中，无遗忘系统必然发散——这不是工程权衡，而是数学定理。遗忘不是记忆系统的缺陷，而是维持有限跟踪误差的**必要条件**。
- (2) **记忆-遗忘存在相变（定理 2）**。环境漂移速率穿越临界值时，最优策略在“记忆一切”和“遗忘大部分”之间发生定性跃迁。这一相变在结构上平行于学习过程中的质变点，暗示两者可能有共同的深层数学根源。
- (3) **遗忘的速度存在不可突破的下界（定理 3）**。遗忘与检测延迟的乘积受信息论下界约束——不存在同时快速遗忘和快速检测的方案。这是**时间版本的测不准原理**：遗忘速度和检测确定性的乘积存在不可突破的下界。

终极隐喻：记忆是一条河流——如果水不流动（无遗忘），它会变成死水（发散）；如果水流太快（过度遗忘），它无法反映两岸的风景（高方差）。最优的记忆系统像一条稳态的河流：水流的速度（遗忘率）恰好匹配河床的变化速率（漂移速率），在流动中保持形态的恒定性。这一隐喻并非文学修辞——它是定理 2 的平衡条件 $\frac{dMSE}{d\lambda} = 0$ 在物理直觉中的投射。

[类比论证] 类比标注：终极隐喻是启发式的物理类比，不具有数学效力。河流-记忆的类比在以下意义上成立：两者均涉及“流入-流出平衡下的稳态形态”，且稳态由系统参数（水流速度/遗忘率，河床变化/漂移速率）唯一决定。然而，河流是连续介质力学的对象，记忆是信息论的对象——两者在数学结构上的精确对应（如果存在）仍有待建立。

致谢：感谢 SCX 理论体系（2026）提供了 Spring SE-1、省定理、质变点定理的数学基础，本文的所有推广均建立在这些已有成果之上。所有错误和过度简化由本文作者负责。

A 有限窗口遗忘的相变分析

本附录补充定理 4.1 在有限窗口遗忘策略下的对应分析。

命题 A.1 (有限窗口遗忘的临界窗口). 在有限窗口遗忘策略 $w(t, s) = 1/W \cdot \mathbf{1}[t - s \leq W]$ 下，渐近 MSE 为：

$$MSE(W) = \frac{v^2 W^2}{4\alpha^2 \mu^2} + \frac{\alpha \sigma^2}{\mu W} \quad \square \quad (60)$$

最优窗口大小 W^* 由一阶条件给出：

$$W^* = \left(\frac{2\alpha^3 \sigma^2 \mu}{v^2} \right)^{1/3} \quad \square \quad (61)$$

当 $v \rightarrow 0$ 时， $W^* \rightarrow \infty$ （无限窗口，即无遗忘）；当 $v \rightarrow \infty$ 时， $W^* \rightarrow 0$ （即时遗忘）。临界漂移（定义为 $W^* = 1$ 时的 v 值）为 $v_c^{FW} = \sqrt{2\alpha^3 \sigma^2 \mu}$ 。

证明. 与定理 4.1 的证明平行。在窗口大小 W 下：

- 有效偏差：历史平均滞后 $\frac{1}{W} \sum_{k=0}^{W-1} (\theta_{t-k}^* - \theta_t^*)$ 。在线性漂移下， $\left\| \frac{1}{W} \sum_{k=0}^{W-1} (\theta_{t-k}^* - \theta_t^*) \right\|^2 = \frac{v^2 W^2}{4}$ 。

- 有效方差：\$W\$ 个独立样本的平均的方差为 \$\alpha^2 \sigma^2 / W\$。

求解 \$\frac{d\text{MSE}(W)}{dW} = 0\$ 得到 \$W^*\$。 \$\square\$

指数遗忘和有限窗口遗忘在以下极限下等价：当 \$\lambda = 1 - 1/W\$ 且 \$W\$ 大时，\$N_{\text{eff}}^{\text{EF}} \approx 2W\$，而 \$N_{\text{eff}}^{\text{FW}} = W\$。因此，在有效样本量的意义上，指数遗忘的“有效窗口”是有限窗口的两倍（因为它对近期历史给予更高权重）。

B 遗忘算子的谱分析

命题 B.1 (遗忘算子的谱). 在有限维记忆空间 \$\mathcal{M} \cong \mathbb{R}^d\$ 中，标准遗忘算子 \$\mathcal{F}_\lambda(m) = \lambda m + (1 - \lambda)\mathcal{T}(\delta m)\$ 的谱满足：

$$\sigma(\mathcal{F}_\lambda) = \{\lambda\} \cup \{\lambda \cdot \sigma_i : \sigma_i \in \sigma(P_{\mathcal{M}}\mathcal{T})\} \square \quad (62)$$

其中 \$P_{\mathcal{M}}\$ 是到 \$\mathcal{M}\$ 的正交投影。特别地，遗忘算子的谱半径 \$\rho(\mathcal{F}_\lambda) = \lambda\$（由公理 A1 的压缩性保证）。

证明. 在 \$\mathbb{R}^d\$ 中，\$\mathcal{F}_\lambda\$ 可表示为矩阵：

$$F_\lambda = \lambda I_d + (1 - \lambda)T \square \quad (63)$$

其中 \$T\$ 是 \$\mathcal{T}\$ 在 \$\mathcal{M}\$ 的某组基下的矩阵表示。\$F_\lambda\$ 的特征值为 \$\lambda + (1 - \lambda)\tau_i\$，其中 \$\tau_i\$ 是 \$T\$ 的特征值。由于 \$\|T\| \leq 1\$（非膨胀性），\$|\tau_i| \leq 1\$，因此 \$|\lambda + (1 - \lambda)\tau_i| \leq 1\$。谱半径 \$\max_i |\lambda + (1 - \lambda)\tau_i| = \lambda + (1 - \lambda) = 1\$ 当 \$\tau_i = 1\$ 时达到，或 \$\lambda\$ 当所有 \$|\tau_i| < 1\$ 时。 \$\square\$

谱分析揭示了遗忘算子的**混合性质**：在 \$\tau_i = 1\$ 的方向上（对应 \$\mathcal{T}\$ 的不动点子空间），\$\mathcal{F}_\lambda\$ 的特征值为 1（该方向无遗忘——信息被完美保留）；在 \$\tau_i = 0\$ 的方向上，特征值为 \$\lambda\$（该方向以速率 \$\lambda\$ 被遗忘）。这一方向性遗忘结构超出了公理 A1 的简单压缩模型——它暗示了**结构化遗忘**的可能性：在不同的信息子空间上以不同的速率遗忘。

[开放问题] 开放问题：结构化遗忘（方向依赖性遗忘率的遗忘算子）的收敛性分析及其在深度学习中的应用。初步猜想：Transformer 注意力机制中的“注意力衰减”（attention dropout / stochastic depth）可被理解为在高维记忆空间的特定子空间上的结构化遗忘。

参考文献

- [1] SCX Theory Group. *SCX Core Theorems: Economy Theorem, Qualitative Change Point Theorem, and Multi-Expert Consistency*. SCX Technical Report, 2026.
- [2] SCX Theory Group. *Spring SE-1 Convergence Analysis: Two-Phase Dynamics of Robbins-Monro SGD on State Space*. SCX Technical Report, 2026.
- [3] SCX Theory Group. *SCX Framework for Label Noise Detection: The Five-Layer Architecture*. SCX Technical Report, 2026.
- [4] H. Robbins and S. Monro. *A Stochastic Approximation Method*. Annals of Mathematical Statistics, 22(3):400–407, 1951.

- [5] B. T. Polyak. *Gradient methods for the minimisation of functionals*. USSR Computational Mathematics and Mathematical Physics, 3(4):864–878, 1963.
- [6] S. Łojasiewicz. *A topological property of real analytic subsets*. Coll. du CNRS, Les équations aux dérivées partielles, 117:87–89, 1963.
- [7] H. Karimi, J. Nutini, and M. Schmidt. *Linear convergence of gradient and proximal-gradient methods under the Polyak-Łojasiewicz condition*. ECML-PKDD, 2016.
- [8] H. Chernoff. *A measure of asymptotic efficiency for tests of a hypothesis based on the sum of observations*. Annals of Mathematical Statistics, 23(4):493–507, 1952.
- [9] C. Stein. *On the theory of testing composite hypotheses*. Annals of Mathematical Statistics, 23:148–149, 1952.
- [10] Y. Le Cam. *Asymptotic Methods in Statistical Decision Theory*. Springer, 1986.
- [11] W. Hoeffding. *Probability inequalities for sums of bounded random variables*. JASA, 58(301):13–30, 1963.
- [12] H. Ebbinghaus. *Über das Gedächtnis: Untersuchungen zur experimentellen Psychologie*. Duncker & Humblot, 1885.
- [13] J. T. Wixted and S. K. Carpenter. *The Wickelgren Power Law and the Ebbinghaus forgetting curve*. In H. L. Roediger, III (Ed.), Cognitive psychology of memory, 2007.
- [14] J. Gama, I. Žliobaitė, A. Bifet, M. Pechenizkiy, and A. Bouchachia. *A survey on concept drift adaptation*. ACM Computing Surveys, 46(4):1–37, 2014.
- [15] M. Zinkevich. *Online convex programming and generalized infinitesimal gradient ascent*. ICML, 2003.
- [16] E. Hazan. *Introduction to Online Convex Optimization*. Foundations and Trends in Optimization, 2016.
- [17] R. Nagel (Ed.). *One-Parameter Semigroups of Positive Operators*. Springer Lecture Notes in Mathematics, 1986/2022.