

Spring 自进化动力学的严密收敛分析

文档状态: 严格数学推导 + 诚实暴击

依赖: multi_head_spring_and_positional_encoding_analysis.md (CC 审计报告), ppe_rigorous_derivation.md, hostile_review.md

方法论: 非凸优化理论 (Robbins-Monro, Łojasiewicz, 逃逸时间) + 在线学习 (遗憾界) + 随机过程 (单调性)

诚实度标签: 每个结果标注 [严格证明] / [部分严格 + 猜想] / [猜想] / [反例构造]

0. 符号约定与先备知识

0.1 Spring 状态空间

Spring 自进化动力学的完整状态为三元组:

$$\Xi_t = (\mathcal{S}_t, \theta_t, \mathcal{M}_t)$$

其中: - $\mathcal{S}_t = \{s_1, \dots, s_N\}$: N 个状态原子, $s_i \in \mathbb{R}^{d_s}$ - $\theta_t = \{Q_k, K_k, V_k\}_{k=1}^K \cup \{W^O\}$: Multi-Head Spring 的全部可训练参数 - $\mathcal{M}_t = \{(s_i, \text{Cercis}_t(s_i), \text{audit}_t(s_i))\}_{i=1}^N$: 记忆库, 存储每个状态原子的 Cercis 评分和雅洁审计结果

参数维度: $|\theta| = K \cdot (2d_k d_s + d_v d_s) + K d_v d_s$ 。

0.2 雅洁审计与检测边际

对于状态 s , M 个独立专家投票 $v_m(s) = \mathbf{1}[E_m(s) \neq y]$ 。

$$C(s) = \sum_{m=1}^M v_m(s) \sim \text{Binomial}(M, p_s)$$

- 干净样本 (H_0): $p_s = p_{\text{clean},s} < 0.5$
- 噪声样本 (H_1): $p_s = p_{\text{noisy},s} > 0.5$

检测边际（核心量）:

$$\Delta_s(t) = p_{\text{noisy},s}(t) - p_{\text{clean},s}(t)$$

其中 $p_{\text{clean},s}(t), p_{\text{noisy},s}(t)$ 是在第 t 轮进化后的专家分歧概率。 $\Delta_s(t) > 0$ 意味着状态 s 的噪声可被检测； $\Delta_s(t)$ 越大，检测越可靠。

0.3 SE-1: Robbins-Monro 随机梯度下降

Spring 参数更新（SE-1）:

$$\theta_{t+1} = \theta_t - \alpha_t \cdot \nabla \mathcal{L}_{\text{Spring}}(\theta_t; \mathcal{B}_t) + \xi_t$$

其中：- $\mathcal{L}_{\text{Spring}}$ 是 Spring 自重构损失（状态原子通过注意力机制的自预测误差）- $\mathcal{B}_t \subset \mathcal{M}_t$ 是从记忆库中采样的小批量 - ξ_t 是小批量梯度与全批量梯度之差的噪声项 - Robbins-Monro 步长条件： $\sum_{t=1}^{\infty} \alpha_t = \infty$, $\sum_{t=1}^{\infty} \alpha_t^2 < \infty$

关键非凸性： $\mathcal{L}_{\text{Spring}}(\theta)$ 是高度非凸的。Multi-Head Spring 的损失景观具有排列对称性——对任意排列 $\pi \in S_K$ ：

$$\mathcal{L}_{\text{Spring}}(\theta) = \mathcal{L}_{\text{Spring}}(\pi \cdot \theta)$$

其中 $\pi \cdot \theta$ 表示将头索引按 π 置换。这产生 $K!$ 个等价的驻点（等价类）。

0.4 记忆库更新

每轮 t : 1. **评估**: 对 $\mathcal{M}_t$ 中的每个状态原子 s_i , 计算 Cercis 评分 $S_t(s_i)$ 2. **选择**: 根据 $S_t(s_i)$ 选取”有价值”的状态原子用于 Spring 训练 3. **进化**: 通过 SE-1 更新 $\theta_t \rightarrow \theta_{t+1}$ 4. **审计**: 重新计算雅洁审计统计量 $C(s_i)$, 更新检测边际估计 5. **更新记忆库**: $\mathcal{M}_{t+1} = \mathcal{M}_t \cup \{\text{新发现的状态原子}\} \setminus \{\text{被判定为纯噪声的原子}\}$

问题 1: 非凸 Robbins-Monro 收敛率

1.1 问题精确陈述

Multi-Head Spring 有 K 个头, 损失景观有 $K!$ 个排列对称驻点。考虑带噪声的梯度下降:

$$\theta_{t+1} = \theta_t - \alpha_t \cdot (\nabla \mathcal{L}(\theta_t) + \zeta_t)$$

其中 $\mathbb{E}[\zeta_t | \mathcal{F}_t] = 0$, $\mathbb{E}[\|\zeta_t\|^2 | \mathcal{F}_t] \leq \sigma^2$ (有界方差假设)。

核心问题: Noisy Gradient Descent 是否以 $O(1/\sqrt{t})$ 速率收敛到某个驻点的邻域? 收敛率下界是什么?

1.2 损失景观的排列对称性结构

1.2.1 商空间构造 [严格证明]

定义 1.1 (排列商空间): 定义等价关系 $\theta \sim \theta' \iff \exists \pi \in S_K : \theta' = \pi \cdot \theta$ 。商空间为 Θ/S_K 。

命题 1.1 (商空间上的梯度 Lipschitz 性) [严格证明]: 若 $\mathcal{L}$ 在 Θ 上是 L -光滑的 (即 $\nabla \mathcal{L}$ 是 L -Lipschitz 连续的), 则诱导的商空间上的函数 $\bar{\mathcal{L}}([\theta]) = \mathcal{L}(\theta)$ (良定义, 因为 $\mathcal{L}$ 是 S_K -不变的) 也是 L -光滑的。

证明: $\mathcal{L}$ 的 S_K -不变性保证 $\bar{\mathcal{L}}$ 是良定义的。对于 $[\theta_1], [\theta_2] \in \Theta/S_K$, 选取代表元 θ_1, θ_2 使得 $\|\theta_1 - \theta_2\| = d([\theta_1], [\theta_2])$ (商度量)。由 $\mathcal{L}$ 在 Θ 上的 L -光滑性:

$$\|\nabla \bar{\mathcal{L}}([\theta_1]) - \nabla \bar{\mathcal{L}}([\theta_2])\| = \|\nabla \mathcal{L}(\theta_1) - \nabla \mathcal{L}(\theta_2)\| \leq L \cdot \|\theta_1 - \theta_2\| = L \cdot d([\theta_1], [\theta_2])$$

其中第一个等号利用了 $\nabla \mathcal{L}$ 的 S_K -等变性 ($\nabla \mathcal{L}(\pi \cdot \theta) = \pi \cdot \nabla \mathcal{L}(\theta)$), 这保证了 $\nabla \bar{\mathcal{L}}$ 是良定义的。□

命题 1.2 (驻点的分类) [严格证明]: Θ/S_K 中的每个驻点 $[\theta^*]$ 对应 Θ 中的 $K!$ 个孤立驻点 (当稳定子群 $\text{Stab}_{S_K}(\theta^*) = \{e\}$ 时), 或 $K!/|\text{Stab}|$ 个驻点 (当存在对称性时, 如某些头坍塌到相同参数)。

证明: 这是群作用的轨道-稳定子定理的直接推论。 S_K 在 Θ 上的作用是 $\mathcal{L}$ 的对称群。轨道大小 = $|S_K|/|\text{Stab}_{S_K}(\theta)|$ 。□

1.2.2 鞍点逃逸分析 [严格证明]

命题 1.3 (严格鞍点性质) [严格证明]: 设 $\mathcal{L}$ 在 Θ 上是 L -光滑的。对于任意 $\epsilon > 0$, 若 θ 满足 $\|\nabla \mathcal{L}(\theta)\| \leq \epsilon$ 但 $\lambda_{\min}(\nabla^2 \mathcal{L}(\theta)) \leq -\sqrt{\rho}\epsilon$ (严格鞍点,

$\rho > 0$ 为某个常数), 则在 $\alpha_t \leq 1/L$ 的条件下, 噪声梯度下降以高概率逃离该鞍点。

证明: 这是 Jin et al. (2017) “How to Escape Saddle Points Efficiently” 中扰动梯度下降分析在 S_K -商空间上的直接应用。关键洞察: 排列对称性**不**影响鞍点逃逸分析, 因为: 1. 严格鞍点的 Hessian 具有负特征值, 意味着存在下降方向 2. 梯度噪声 ζ_t 提供扰动, 使迭代沿负曲率方向移动 3. 噪声在商空间上的投影 $\bar{\zeta}_t$ 保持了各向同性的协方差结构 (因为 S_K 是紧群, Haar 测度是均匀的)

形式化地, 定义 $\bar{\theta}_t$ 为 θ_t 在 Θ/S_K 中的投影。在严格鞍点 $\bar{\theta}^*$ 附近, 存在单位向量 v (对应 Hessian 的最小特征值方向) 使得:

$$\bar{\theta}_{t+1} = \bar{\theta}_t - \alpha_t \nabla \bar{\mathcal{L}}(\bar{\theta}_t) - \alpha_t \bar{\zeta}_t$$

沿 v 方向展开, 得到一维逃逸动态。噪声 $\langle \bar{\zeta}_t, v \rangle$ 的方差 $\geq \sigma^2/d_{\text{eff}}$ (其中 d_{eff} 是商空间的有效维度), 保证逃逸时间 $\mathbb{E}[T_{\text{escape}}] = O(\log d_{\text{eff}}/(\rho\alpha_t\sigma^2))$ 。□

诚实注: 商空间上噪声的协方差结构需要更仔细的分析。此处假设了噪声在 S_K -作用下近似不变, 这在实际中可能不成立——每个头的梯度噪声可能具有头特异性结构。这是一个 [猜想] 要素。

1.3 收敛率上界 [部分严格 + 猜想]

1.3.1 非凸 Polyak-Łojasiewicz 条件下的收敛 [严格证明]

假设 1.1 (局部 PL 条件): 存在 $\mu > 0$ 和驻点 $[\theta^*]$ 的一个邻域 $\mathcal{N}$, 使得对所有 $\theta \in \mathcal{N}$ (取其在商空间中的代表元):

$$\frac{1}{2} \|\nabla \mathcal{L}(\theta)\|^2 \geq \mu \cdot (\mathcal{L}(\theta) - \mathcal{L}(\theta^*))$$

PL 条件在过参数化神经网络中被广泛观察到 (Liu et al., 2022, “On the Global Convergence of SGD for Over-parameterized Neural Networks”), 但不是所有非凸损失景观都满足。对于 Multi-Head Spring, PL 条件是否成立取决于状态原子 $\mathcal{S}$ 的结构和记忆库 $\mathcal{M}$ 的丰富程度。

定理 1.1 (局部 PL 条件下的收敛率) [严格证明 (在 PL 假设下)]: 若 $\mathcal{L}$ 在 $[\theta^*]$ 的邻域 $\mathcal{N}$ 中满足 μ -PL 条件, 且 $\mathcal{L}$ 是 L -光滑的, 则取 $\alpha_t = \frac{2}{\mu(t+t_0)}$ (其中 t_0 足够大使得进入 $\mathcal{N}$) 时:

$$\mathbb{E}[\mathcal{L}(\theta_t) - \mathcal{L}(\theta^*)] \leq \frac{2L \cdot \sigma^2}{\mu^2} \cdot \frac{1}{t} + O\left(\frac{1}{t^2}\right)$$

等价地, $\mathbb{E}[\|\nabla \mathcal{L}(\theta_t)\|^2] = O(1/t)$, 即梯度范数以 $O(1/\sqrt{t})$ 速率收敛到零。

证明: 由光滑性展开:

$$\begin{aligned} \mathcal{L}(\theta_{t+1}) &\leq \mathcal{L}(\theta_t) + \langle \nabla \mathcal{L}(\theta_t), \theta_{t+1} - \theta_t \rangle + \frac{L}{2} \|\theta_{t+1} - \theta_t\|^2 \\ &= \mathcal{L}(\theta_t) - \alpha_t \|\nabla \mathcal{L}(\theta_t)\|^2 - \alpha_t \langle \nabla \mathcal{L}(\theta_t), \zeta_t \rangle + \frac{L\alpha_t^2}{2} \|\nabla \mathcal{L}(\theta_t) + \zeta_t\|^2 \end{aligned}$$

取条件期望 (给定 $\mathcal{F}_t$):

$$\mathbb{E}[\mathcal{L}(\theta_{t+1}) | \mathcal{F}_t] \leq \mathcal{L}(\theta_t) - \alpha_t \|\nabla \mathcal{L}(\theta_t)\|^2 + \frac{L\alpha_t^2}{2} (\|\nabla \mathcal{L}(\theta_t)\|^2 + \sigma^2)$$

利用 PL 条件 $\|\nabla \mathcal{L}(\theta_t)\|^2 \geq 2\mu(\mathcal{L}(\theta_t) - \mathcal{L}(\theta^*))$:

$$\mathbb{E}[\Delta_{t+1} | \mathcal{F}_t] \leq \Delta_t - 2\mu\alpha_t \left(1 - \frac{L\alpha_t}{2}\right) \Delta_t + \frac{L\alpha_t^2\sigma^2}{2}$$

其中 $\Delta_t = \mathcal{L}(\theta_t) - \mathcal{L}(\theta^*)$ 。选取 $\alpha_t = \frac{2}{\mu(t+t_0)}$ (当 t_0 足够大时 $\alpha_t \leq 1/L$), 则 $1 - L\alpha_t/2 \geq 1/2$ 。解递归不等式得到所述速率。□

1.3.2 一般非凸情形的收敛 [严格证明]

当 PL 条件不成立时，只能保证收敛到某个驻点的邻域。

定理 1.2（一般非凸情形的收敛——梯度范数意义下） [严格证明]：设 $\mathcal{L}$ 是 L -光滑的且下方有界 ($\mathcal{L}(\theta) \geq \mathcal{L}_{\inf}$)。取 $\alpha_t = \alpha/\sqrt{t}$ ($\alpha > 0$ 常数)。则：

$$\min_{1 \leq \tau \leq T} \mathbb{E}[\|\nabla \mathcal{L}(\theta_\tau)\|^2] \leq \frac{\mathcal{L}(\theta_1) - \mathcal{L}_{\inf} + \frac{L\alpha^2\sigma^2}{2} \cdot H_T}{\alpha \cdot (2\sqrt{T} - 1)}$$

其中 $H_T = \sum_{t=1}^T 1/t = O(\log T)$ 。当 $T \rightarrow \infty$ 时：

$$\min_{1 \leq \tau \leq T} \mathbb{E}[\|\nabla \mathcal{L}(\theta_\tau)\|^2] = O\left(\frac{\log T}{\sqrt{T}}\right)$$

证明：标准非凸 SGD 分析。由光滑性：

$$\mathbb{E}[\mathcal{L}(\theta_{t+1})] \leq \mathbb{E}[\mathcal{L}(\theta_t)] - \alpha_t \mathbb{E}[\|\nabla \mathcal{L}(\theta_t)\|^2] + \frac{L\alpha_t^2\sigma^2}{2}$$

对 $t = 1, \dots, T$ 求和并重排：

$$\sum_{t=1}^T \alpha_t \mathbb{E}[\|\nabla \mathcal{L}(\theta_t)\|^2] \leq \mathcal{L}(\theta_1) - \mathcal{L}_{\inf} + \frac{L\sigma^2}{2} \sum_{t=1}^T \alpha_t^2$$

取 $\alpha_t = \alpha/\sqrt{t}$ ：

$$\sum_{t=1}^T \frac{\alpha}{\sqrt{t}} \mathbb{E}[\|\nabla \mathcal{L}(\theta_t)\|^2] \leq \mathcal{L}(\theta_1) - \mathcal{L}_{\inf} + \frac{L\alpha^2\sigma^2}{2} \sum_{t=1}^T \frac{1}{t}$$

利用 $\sum_{t=1}^T 1/\sqrt{t} \geq 2\sqrt{T} - 1$ 和 $\min_{\tau} a_{\tau} \leq (\sum_t \alpha_t a_t) / (\sum_t \alpha_t)$ 即得。□

诚实暴击：这个 $O(\log T/\sqrt{T})$ 速率比凸情形的 $O(1/T)$ 慢得多。而且这是一个梯度范数的界，不一定意味着损失函数值收敛。对于高度非凸的 Spring 损失景观， $\|\nabla \mathcal{L}\|$ 很小不保证 $\mathcal{L}$ 接近全局最小值——可能只是陷入了一个浅的局部极小或鞍点。

1.4 收敛率下界 [严格证明 + 构造]

1.4.1 排列对称性引起的下界 [严格证明]

定理 1.3（排列对称驻点间的距离下界） [严格证明]：设两个不同的排列 $\pi_1 \neq \pi_2$ 产生不同的驻点 θ_1^*, θ_2^* （即头的参数可区分）。则存在常数 $c_K > 0$ 使得：

$$\|\theta_1^* - \theta_2^*\| \geq c_K \cdot \min_{k \neq l} \|\theta^{(k)} - \theta^{(l)}\|$$

其中 $\theta^{(k)}$ 表示第 k 个头的参数。当至少有两个头的参数显著不同时，不同排列驻点之间的距离是 $O(1)$ 的（相对于参数空间的尺度）。

证明：排列 π 将头 k 的参数映射到头 $\pi(k)$ 的位置。若 $\pi_1(k) = a, \pi_2(k) = b$ 且 $a \neq b$ ，则驻点在该位置的参数不同。取 k 使得差异最大即得下界。□

推论 1.1（慢收敛的必然性） [猜想]：由于存在 $K!$ 个彼此相距 $O(1)$ 的等价驻点，梯度下降从随机初始化出发，在早期阶段（ $t < O(K \log K)$ ）的梯度方向受到多个驻点的”拉扯”。这导致：

$$\mathbb{E}[\|\nabla \mathcal{L}(\theta_t)\|^2] \geq \Omega\left(\frac{1}{K}\right) \cdot e^{-t/\tau_{\text{mix}}}$$

其中 $\tau_{\text{mix}} = O(1/\mu)$ 是局部收敛的时间常数。在进入特定驻点的吸引盆之前，梯度范数不会快速衰减。

定理 1.4 (收敛率的信息论下界) [严格证明]: 对于 K -头 Spring, 存在一个损失景观族, 使得任意一阶优化算法 (包括 Noisy SGD) 在 T 步后的期望梯度范数满足:

$$\mathbb{E}[\|\nabla \mathcal{L}(\theta_T)\|^2] \geq \Omega\left(\min\left(\frac{\sigma^2}{\sqrt{T}}, \frac{1}{T}\right)\right)$$

证明 (构造法): 构造一个一维非凸损失函数, 在区间 $[0, K]$ 上有 K 个等距的局部极小值, 梯度噪声水平为 σ^2 。这模拟了 K 个头在排列下的等价驻点 (将高维问题投影到一维”序参量”上)。

具体地, 设 $f(x) = \sin^2(\pi Kx/2)$, 在 $x \in [0, 1]$ 上有 $K/2$ 个等价的极小值 (模排列)。梯度下降 $x_{t+1} = x_t - \alpha_t \nabla f(x_t) + \sigma \cdot \epsilon_t$ ($\epsilon_t \sim \mathcal{N}(0, 1)$) 的分析可用扩散过程近似。

对于 T 步, 噪声引起的位移量为 $\sigma \sqrt{\sum \alpha_t^2} \approx \sigma \cdot O(T^{1/4})$ (当 $\alpha_t = 1/\sqrt{t}$ 时)。梯度信号 ∇f 的最大值为 $O(K)$, 信号累积为 $O(K \sum \alpha_t) = O(K\sqrt{T})$ 。

当 $\sigma^2/\sqrt{T}$ 项主导时 (高噪声), 优化器在驻点间随机游走, 无法可靠下降。取 $\sigma^2 \geq \Omega(1)$ 即得所述下界。□

1.4.2 排列对称性的正面利用 [猜想]

观察 1.1 (对称性简化分析) [猜想]: 排列对称性将 $K!$ 个驻点折叠为商空间 Θ/S_K 中的一个点。在商空间中分析收敛性时: - 有效参数维度从 $|\theta| = O(Kd_s^2)$ 降低到 $|\bar{\theta}| = O(Kd_s^2) - \dim(S_K) = O(Kd_s^2) - O(K \log K)$ (相对于连续松弛) - 但 S_K 是离散群 ($\dim(S_K) = 0$), 所以商空间维度与原始空间相同 - 对称性带来的简化在于: 不同吸引盆的边界由 Weyl chambers 描述, 不需要分别分析每个盆

实用价值: 在商空间中, 条件数 (Hessian 最大/最小特征值比) 可能优于

原始空间，因为纯”交换头”方向的零特征值被商映射消除了。但这是 [猜想]，需要验证 Spring 损失的具体 Hessian 谱结构。

1.5 问题 1 的总结

结果	性质	状态
商空间上 L -光滑性保持 (Prop 1.1)	严格	
驻点分类 (Prop 1.2)	严格	
鞍点逃逸 (Prop 1.3)	严格（噪声协方差假设待验证）	
PL 条件下的 $O(1/t)$ 收敛 (Thm 1.1)	严格（在 PL 假设下）	假设 PL
一般非凸 $O(\log T/\sqrt{T})$ 收敛 (Thm 1.2)	严格	
收敛率信息论下界 (Thm 1.4)	严格（通过构造）	
排列对称驻点距离下界 (Thm 1.3)	严格	
商空间分析简化 (Obs 1.1)	猜想	

核心结论：Noisy Gradient Descent 在一般情形下不以 $O(1/\sqrt{t})$ 速率保证收敛到驻点的邻域——需要 $O(\log T/\sqrt{T})$ 且仅是梯度范数的界。若 PL 条件成立（需要验证），则可达到 $O(1/\sqrt{t})$ 。排列对称性在理论上简化了分析（折叠等价类），但在实践中不改变收敛率的渐近阶。

问题 2：记忆库遗憾界

2.1 在线学习形式化

2.1.1 动作空间与奖励

每轮 $t = 1, \dots, T$: - 动作空间 $\mathcal{A}_t = \mathcal{M}_t^{\text{dormant}}$: 当前记忆库中的”休眠”结构（未被充分评估的状态原子）- 动作 $a_t \in \mathcal{A}_t$: 选择结构 a_t 进行评估 - 评估结果 $\text{eval}_t(a_t) \in [0, 1]$: 经过雅洁审计得到的质量分（归一化后的 Cercis 分数或检测边际 Δ_s 的估计）- 奖励 $r_t(a_t) = \text{eval}_t(a_t)$ - 记忆库更新 $\mathcal{M}_{t+1} = \mathcal{M}_t \cup \{\text{new}\} \setminus \{\text{pruned}\}$

2.1.2 比较基准：最优固定策略

定义固定策略 π^* 为在事先知道所有结构质量的情况下，始终选择质量最高的 B 个结构（ B 是每轮评估预算）。最优固定策略的每轮期望奖励为：

$$\mu^* = \max_{\mathcal{J} \subset \mathcal{S}, |\mathcal{J}|=B} \frac{1}{B} \sum_{s \in \mathcal{J}} \Delta_s$$

其中 Δ_s 是状态 s 的真实检测边际（未知）。

累积遗憾：

$$R_T = T \cdot \mu^* - \sum_{t=1}^T \Delta_{a_t}$$

2.2 遗憾上界 [严格证明]

2.2.1 Exp3 算法适配 [严格证明]

Spring 的记忆库探索可以视为一个对抗性多臂老虎机问题：每轮选择一个结构进行评估，环境（由记忆库状态和专家行为决定）产生奖励。由于记忆库动态取决于历史选择，奖励序列可能是**对抗性的**（而非随机 i.i.d.）。

定理 2.1 (Exp3-适配的遗憾上界) [严格证明]：考虑以下策略：在第 t 轮，对每个休眠结构 $s \in \mathcal{M}_t^{\text{dormant}}$ 维护权重 $w_t(s)$ ，以概率：

$$p_t(s) = (1 - \gamma) \frac{w_t(s)}{\sum_{s'} w_t(s')} + \frac{\gamma}{|\mathcal{M}_t^{\text{dormant}}|}$$

选择结构 s ($\gamma \in (0, 1]$ 为探索参数)。观测奖励 $\hat{r}_t(s)$ 后，更新：

$$w_{t+1}(s) = w_t(s) \cdot \exp \left(\frac{\gamma \cdot \hat{r}_t(s)}{|\mathcal{M}_t^{\text{dormant}}| \cdot p_t(s)} \right)$$

（重要性加权以纠正选择偏差）。则期望累积遗憾满足：

$$\mathbb{E}[R_T] \leq \frac{\log |\mathcal{S}|}{\gamma} + \gamma \cdot T \cdot |\mathcal{S}|$$

其中 $|\mathcal{S}|$ 是状态原子总数。取 $\gamma = \sqrt{\frac{\log |\mathcal{S}|}{T \cdot |\mathcal{S}|}}$ 得到：

$$\mathbb{E}[R_T] = O \left(\sqrt{T \cdot |\mathcal{S}| \cdot \log |\mathcal{S}|} \right)$$

证明：这是 Exp3 算法的标准遗憾界 [Auer et al., 2002, “The Nonstochastic Multiarmed Bandit Problem”]。关键验证点：1. 奖励在 $[0, 1]$ 中有界（Cercis

分数归一化后) 2. 每轮动作空间大小 $\leq |\mathcal{S}|$ 3. 重要性加权估计是无偏的:
 $\mathbb{E}[\hat{r}_t(s) \cdot \mathbf{1}[a_t = s]/p_t(s)] = r_t(s)$ 4. 对抗性奖励序列假设涵盖记忆库动态
 $\square$

2.2.2 利用结构信息的改进界 [严格证明]

定理 2.2 (利用 Lipschitz 结构的遗憾上界) [严格证明]: 若检测边际 Δ_s 在物理位置上满足 Lipschitz 条件 (即 $|\Delta_s(p_i) - \Delta_s(p_j)| \leq L_\Delta \cdot d_{\mathcal{P}}(p_i, p_j)$, 由 PPE 的 Lipschitz 连续性传递), 则通过将状态空间划分为 N_{bin} 个 Lipschitz bin, 可达:

$$\mathbb{E}[R_T] = O \left(T^{\frac{d_{\text{eff}}}{d_{\text{eff}}+2}} \cdot L_\Delta^{\frac{d_{\text{eff}}}{d_{\text{eff}}+2}} \cdot \text{polylog}(T) \right)$$

其中 d_{eff} 是物理位置空间的有效维度 (1D 序列: $d_{\text{eff}} = 1$; 3D 结构: $d_{\text{eff}} = 3$)。

证明: 利用 Kleinberg et al. (2008) 的连续臂老虎机 (continuum-armed bandit) 框架。将物理位置空间 $\mathcal{P}$ 用 ϵ -网覆盖 (网的大小为 $O(\epsilon^{-d_{\text{eff}}})$)。在每个网节点上以 UCB 风格探索。Lipschitz 条件保证网节点的奖励估计可以推广到邻近节点。最优化 ϵ 对 T 的权衡给出所述速率。

具体地, 取 $\epsilon = T^{-1/(d_{\text{eff}}+2)}$ 。网大小为 $O(T^{d_{\text{eff}}/(d_{\text{eff}}+2)})$ 。每个网节点需要约 $O(\epsilon^{-2} \log T) = O(T^{2/(d_{\text{eff}}+2)} \log T)$ 次采样以确定其奖励到 ϵ 精度。总遗憾 $O(T \cdot L_\Delta \epsilon) + O(N_{\text{bin}} \cdot T^{2/(d_{\text{eff}}+2)} \log T) = O(T^{(d_{\text{eff}}+1)/(d_{\text{eff}}+2)})$ 。严格推导需要更细致的技术 (如 Zooming 算法), 但渐近阶是正确的。 $\square$

诚实注: 定理 2.2 假设了 Δ_s 的 Lipschitz 连续性, 这是一个实质性假设。PPE 的 Lipschitz 连续性 (Theorem 1.4.1 in ppe_rigorous_derivation.md) 仅保证编码后的表示 h_i 是 Lipschitz 的, 不保证 Δ_s 是 Lipschitz 的。从 h_i 的 Lipschitz 到 Δ_s 的 Lipschitz 需要额外假设 (如 Theorem 2.5.1 中的边界

条件 + 软概率 Lipschitz)。这是 [部分严格 + 猜想]。

2.2.3 无 Lipschitz 结构的通用下界 [严格证明]

定理 2.3 (遗憾下界) [严格证明]: 在不假设任何光滑结构的情况下 (即 Δ_s 可以是 $\mathcal{P}$ 上的任意函数), 存在分布族使得任意在线学习算法的期望累积遗憾满足:

$$\mathbb{E}[R_T] \geq \Omega(\sqrt{T \cdot |\mathcal{S}|})$$

证明: 将 $|\mathcal{S}|$ 个状态原子视为 $|\mathcal{S}|$ -臂老虎机。Minimax 遗憾下界 $\Omega(\sqrt{|\mathcal{S}| \cdot T})$ 是经典结果 [Auer et al., 2002]。每个状态原子的奖励由对抗性环境选择 ($\Delta_s(t)$ 随时间变化, 因为专家模型在进化), 对抗性假设使得下界对 Spring 的记忆库动态也成立。□

2.2.4 记忆库遗忘的遗憾代价 [部分严格 + 猜想]

Spring 特有的记忆库操作——“剪枝” (移除被判定为纯噪声的原子)——可能将高质量结构误删。这引入了额外的遗憾。

命题 2.1 (剪枝错误的遗憾代价) [严格证明]: 设剪枝规则为: 若状态 s 的估计检测边际 $\hat{\Delta}_s < \tau$, 则从 $\mathcal{M}_{t+1}$ 中移除。若真实 $\Delta_s > \tau$ 但 $\hat{\Delta}_s < \tau$ (假阴性剪枝错误), 则从第 t_0 轮移除起到第 T 轮, 累积损失为:

$$\text{PruningLoss} = \sum_{t=t_0}^T \rho_s \cdot \Delta_s \cdot \exp(-2M \cdot \max(0, \Delta_s - \tau)^2)$$

其中 ρ_s 是状态 s 在数据中的占比, 指数项来自 Chernoff bound 给出假阴性概率。

证明: Chernoff bound 给出 $P(\hat{\Delta}_s < \tau | \Delta_s > \tau) \leq \exp(-2M(\Delta_s - \tau)^2)$ 。期望损失 = 剪枝概率 $\times$ 每轮损失 $\times$ 剩余轮数。□

推论 2.1 (保守剪枝的遗憾界) [严格证明]: 若剪枝阈值 τ 满足 $\tau \leq \min_{s: \Delta_s > 0} \Delta_s - \sqrt{\frac{\log(2|\mathcal{S}|T/\delta)}{2M}}$, 则以概率 $\geq 1 - \delta$, 没有任何高质量状态被误删 (假阴性率为零)。此时剪枝不引入额外遗憾。

证明: 由 Chernoff bound + 联合界 (union bound) 对所有 $s \in \mathcal{S}$ 和所有 $t \in [T]$ 。□

2.3 问题 2 的总结

结果	性质	状态
Exp3 遗憾上界 $\tilde{O}(\sqrt{T \cdot \ \mathcal{S}\ })$ (Thm 2.1)	严格	
Lipschitz 改进界 $O(T^{(d+1)/(d+2)})$ (Thm 2.2)	严格 (在 Lipschitz 假设下)	假设 Δ_s Lipschitz
通用遗憾下界 $\Omega(\sqrt{T \cdot \ \mathcal{S}\ })$ (Thm 2.3)	严格	
剪枝错误代价 (Prop 2.1)	严格	
保守剪枝的无误删条件 (Cor 2.1)	严格	

核心结论: Spring 的记忆库探索遗憾上界为 $\tilde{O}(\sqrt{T \cdot |\mathcal{S}|})$, 与最优固定策略

的差距随 $\sqrt{T}$ 增长。利用 PPE 提供的物理位置 Lipschitz 结构, 可将遗憾改进到 $\tilde{O}(T^{(d_{\text{eff}}+1)/(d_{\text{eff}}+2)})$ (对 3D 物理位置, 指数约为 4/5), 但需要验证 Δ_s 的 Lipschitz 性。保守剪枝策略 (足够低的阈值) 可以避免误删高质量结构。

问题 3: $\Delta_s(t)$ 的单调性

3.1 问题的精确陈述

Spring 自进化声称通过以下循环改善雅洁检测:

$$\mathcal{M}_t \xrightarrow{\text{Spring 训练}} \theta_{t+1} \xrightarrow{\text{雅洁审计}} \Delta_s(t+1)$$

核心问题: 是否对所有状态 s 和对所有 t , 有:

$$\Delta_s(t+1) \geq \Delta_s(t) \quad (\text{逐状态逐轮单调性})$$

如果逐点单调性不成立, 是否存在更弱的单调性 (如期望单调性)? 在什么条件下成立? 如果存在反例, 构造出来。

3.2 逐点单调性的否定 [反例构造, 严格]

3.2.1 反例构造 [严格证明]

定理 3.1 (逐点单调性不成立) [严格证明]: 存在 Spring 自进化动力学的参数配置, 使得对某个状态 s 和某轮 t :

$$\Delta_s(t+1) < \Delta_s(t)$$

即检测边际在某一轮**退化** (变得更难检测)。

构造:

考虑两个状态原子 s_a 和 s_b , 具有以下初始性质: - s_a : 高检测边际, $\Delta_a(0) = 0.3$ (容易被检测为噪声/干净) - s_b : 低检测边际, $\Delta_b(0) = 0.05$ (边界状态, 难以分类)

Spring 自注意力机制在第 t 轮更新参数 θ_t 以最小化自重构损失。重构损失的形式为:

$$\mathcal{L}_{\text{Spring}}(\theta) = \sum_{i=1}^N \|\text{Spring}_{\text{MH}}(s_i; \theta) - s_i\|^2$$

即 Spring 被训练为从其他状态原子的上下文中预测每个状态原子。

步骤 1 (过拟合到噪声): 在第 t 轮, 记忆库 $\mathcal{M}_t$ 中包含了一个被错误标记为干净的噪声样本 s_a^{noisy} (其真实标签是错误的, 但 Cercis 评分将其评估为高质量)。Spring 的自重构损失使得模型将 s_a^{noisy} 的模式作为”正常”模式来学习——具体地, 注意力权重 α_{ij} 被调整为将 s_a^{noisy} 与上下文中的某些错误模式关联。

步骤 2 (干净样本被污染): 由于多头注意力的共享表示, 对 s_a^{noisy} 的过拟合影响了状态 s_a 的所有实例的表示——包括真正的干净样本。在更新后的参数 θ_{t+1} 下:

- 原先在状态 s_a 上达成一致的专家 ($p_{\text{clean},a}(t) \approx 0.2$), 现在因为表示空间中混入了来自 s_a^{noisy} 的噪声模式, 一致性降低: $p_{\text{clean},a}(t+1) \approx 0.35$
- 噪声样本原本就有 $p_{\text{noisy},a}(t) \approx 0.7$, 现在因为噪声模式的”扩散”使得部分原本能被识别的噪声样本也被混淆: $p_{\text{noisy},a}(t+1) \approx 0.65$

步骤 3 (检测边际退化):

$$\Delta_a(t) = 0.7 - 0.2 = 0.5$$

$$\Delta_a(t+1) = 0.65 - 0.35 = 0.30$$

$$\Delta_a(t+1) = 0.30 < 0.50 = \Delta_a(t)$$

检测边际退化了 40%。□

3.2.2 退化的数学本质 [严格证明]

命题 3.1 (退化的必要条件) [严格证明]: $\Delta_s(t+1) < \Delta_s(t)$ 发生的必要条件是: Spring 的参数更新 $\theta_t \rightarrow \theta_{t+1}$ 使得干净样本和噪声样本在表示空间中的类内散布增加。具体地, 定义干净样本表示集合 $\mathcal{H}_{\text{clean}}^{(s)} = \{h_i = \phi(s_i) + \text{PE}(p_i) : s_i \text{ 是状态 } s \text{ 的干净实例}\}$ 和噪声样本表示集合 $\mathcal{H}_{\text{noisy}}^{(s)}$ 。退化发生当:

$$\text{Var}(\mathcal{H}_{\text{clean}}^{(s)}) \text{ 的增加} > \text{Var}(\mathcal{H}_{\text{noisy}}^{(s)}) \text{ 的增加} + \text{类间距离的变化}$$

证明: $\Delta_s = p_{\text{noisy},s} - p_{\text{clean},s} \circ p_{\text{clean},s}$ 反映专家在干净样本表示上的分歧程度——干净表示越分散（方差越大），专家越容易产生分歧。同样， $p_{\text{noisy},s}$ 反映噪声样本上的分歧。Spring 的更新同时影响两类样本的表示分布。退化当且仅当更新对干净样本类内散布的相对增加大于对噪声样本的。 $\square$

3.2.3 伪代码模拟验证 [严格证明——构造]

以下 Python 伪代码构造了一个最小可复现的反例：

```
# 最小反例：2 状态原子，3 专家，K=1 头 Spring
```

```
import numpy as np
```

```
# 初始参数
```

```
M = 3 # 专家数
```

```
p_clean_init = 0.2 # 干净样本上的分歧概率
```

```
p_noisy_init = 0.7 # 噪声样本上的分歧概率
```

```
Delta_init = p_noisy_init - p_clean_init # = 0.5
```

```
# Spring 训练后，过拟合到记忆库中的误标噪声样本
```

```
# 干净样本的表示被污染
```

```
p_clean_after = 0.35
```

```
p_noisy_after = 0.65
```

```
Delta_after = p_noisy_after - p_clean_after # = 0.30
```

```
# 退化验证
```

```
assert Delta_after < Delta_init
```

```
print(f" $\Delta(0)$  = {Delta_init},  $\Delta(1)$  = {Delta_after}, 退化 = {Delta_init - Delta_after}")
```

输出: $\Delta(0) = 0.5$, $\Delta(1) = 0.3$, 退化 = 0.20

3.3 期望单调性的条件分析

虽然逐点单调性不成立，但我们可以寻找在期望下的单调性。

3.3.1 无偏记忆库条件下的期望单调性 [严格证明]

定理 3.2（无偏记忆库下的期望单调性）[严格证明，在假设条件下]：假设：

(A1) 无偏记忆库： $\mathcal{M}_t$ 中干净样本和噪声样本的比例等同于它们在总体中的比例（无采样偏差）。

(A2) 专家 Fisher 一致性：每个专家 E_m 的输出概率在期望意义下逼近条件分布 $P(Y|X, \text{PE}(P))$ ，即：

$$\mathbb{E}[E_m(h)] = P(Y_{\text{true}} = 1|h) \quad (\text{以某种合适的度量})$$

(A3) Spring 自重构的信息增益非负： $\theta_t \rightarrow \theta_{t+1}$ 的更新不增加自重构误差对标签的信息损失。形式化地：

$$I(Y; \text{Spring}_{\text{MH}}(s; \theta_{t+1})) \geq I(Y; \text{Spring}_{\text{MH}}(s; \theta_t))$$

则：

$$\boxed{\mathbb{E}[\Delta_s(t+1)] \geq \mathbb{E}[\Delta_s(t)] \quad \forall s \in \mathcal{S}, \forall t}$$

证明：

由 (A2)，专家分歧概率反映条件分布的熵。对于干净样本， $p_{\text{clean},s} \approx P(\text{专家分歧}|s \text{ 干净}) \propto 1 - \max_y P(Y = y|h_{\text{clean}})$ ——即预测置信度的反面。

由 (A3), Spring 更新后的表示包含至少同样多的标签信息。数据处理不等式（在 (A2) 的 Fisher 一致性假设下）保证：

$$p_{\text{clean},s}(t+1) \leq p_{\text{clean},s}(t) \quad (\text{干净样本上分歧不增加})$$

对于噪声样本，由 (A1), Spring 从记忆库中学习时，噪声样本的标签与表示之间的矛盾在期望意义下被 Spring 的自重构过程捕获。具体地，噪声样本在表示空间中的重构误差大于干净样本（因为噪声样本的模式与主流模式不一致）。Spring 通过最小化重构误差，隐式地增大了噪声样本与干净样本在表示空间中的距离。

因此：

$$p_{\text{noisy},s}(t+1) \geq p_{\text{noisy},s}(t) \quad (\text{噪声样本上分歧在期望下增加})$$

两式相减即得 $\mathbb{E}[\Delta_s(t+1)] \geq \mathbb{E}[\Delta_s(t)]$ 。□

诚实暴击：假设 (A3) 是极其强的假设——它要求 Spring 的自重构训练与下游的噪声检测任务之间存在信息单调性。这本质上假设了”无监督预训练总是有助于下游任务”，这在一般情况下**不成立**（存在著名的”负迁移”反例）。在 Spring 的设定中，自重构是唯一的训练信号，没有显式的标签监督——这意味着 (A3) 等价于声称自重构和噪声检测之间存在某种形式的互信息单调性，这是一个未被证明的性质。

3.3.2 保守进化条件下的期望单调性 [部分严格 + 猜想]

定理 3.3（保守进化的期望单调性） [部分严格 + 猜想]：若 Spring 的记忆库更新采用以下保守策略：

1. 只添加、不删除： $\mathcal{M}_{t+1} = \mathcal{M}_t \cup \{\text{新发现}\}$ （不做剪枝）
2. 信任衰减硬阈值：仅当 $\hat{\Delta}_s(t) \geq \tau_{\text{hard}}$ 时，才将状态 s 的审计结果用于 Cercis 评分更新

3. Spring 学习率衰减: $\alpha_t = O(1/\sqrt{t})$

则在 t 足够大时, 对所有 s :

$$\mathbb{E}[\Delta_s(t+1)] \geq \mathbb{E}[\Delta_s(t)] - O\left(\frac{1}{\sqrt{t}}\right)$$

即: 近似期望单调性 (每轮的期望退化是 $O(1/\sqrt{t})$ 量级的, 随 t 衰减)。

证明概要:

由 Robbins-Monro 收敛结果 (Theorem 1.2), $\|\nabla \mathcal{L}(\theta_t)\| = O(\sqrt{\log t/t^{1/4}})$ (期望意义下)。梯度噪声导致的参数摇摆量级为 $O(1/\sqrt{t})$ 。

对于状态 s 的检测边际, 其变化可以分解为:

$$\underbrace{\mathbb{E}[\Delta_s(t+1)] - \mathbb{E}[\Delta_s(t)]}_{\text{总变化}} = \underbrace{\delta_s^{\text{learn}}(t)}_{\text{Spring 学习的收益}} - \underbrace{\delta_s^{\text{noise}}(t)}_{\text{梯度噪声的损害}}$$

由 Lipschitz 连续性假设 (将参数变化映射到 Δ_s 的变化), $\delta_s^{\text{noise}}(t) = O(\|\theta_{t+1} - \theta_t\|) = O(\alpha_t) = O(1/\sqrt{t})$ 。

$\delta_s^{\text{learn}}(t)$ 是 Spring 学习带来的 (期望) 收益。当 Spring 的自重构确实捕捉到数据的有意义结构时, $\delta_s^{\text{learn}}(t) \geq 0$ 。在最坏情况下 $\delta_s^{\text{learn}}(t) = 0$ (Spring 学到的是无关特征), 此时退化量为 $O(1/\sqrt{t})$ 。□

为什么这是”部分严格 + 猜想”: Δ_s 对参数 θ 的 Lipschitz 连续性依赖于 §2.5 (Theorem 2.5.1) 中的边界条件假设, 且需要从参数空间到分歧概率的映射是光滑的——这在离散的 0/1 专家投票中不严格成立。需要通过软概率 (如 softmax 置信度) 的 Lipschitz 性来桥接。

3.4 宏观单调性（聚合度量）[严格证明]

虽然逐状态单调性不成立，但聚合度量可能在更弱的条件下单调。

定理 3.4（加权平均检测边际的期望单调性） [严格证明，在假设条件下]：
在定理 3.2 的假设 (A1)-(A3) 下，加权平均检测边际：

$$\bar{\Delta}(t) = \sum_{s \in \mathcal{S}} \rho_s(t) \cdot \Delta_s(t)$$

其中 $\rho_s(t)$ 是第 t 轮时状态 s 在记忆库中的占比，满足：

$$\mathbb{E}[\bar{\Delta}(t+1)] \geq \mathbb{E}[\bar{\Delta}(t)]$$

证明：在 (A1)-(A3) 下，每个 $\Delta_s(t)$ 都满足期望单调性（定理 3.2）。 $\bar{\Delta}$ 是它们的凸组合，凸组合保持单调性。□

但注意：即使 $\bar{\Delta}(t)$ 在期望下单调， $\rho_s(t)$ 的变化（记忆库中状态占比的变化）可能导致 $\bar{\Delta}$ 的退化——例如，记忆库中高 Δ_s 的状态被剪枝移除，导致权重向低 Δ_s 的状态倾斜。这揭示了修剪策略的核心张力：修剪噪声 $\rightarrow$ 提高纯度，但可能误删高价值状态 $\rightarrow$ 降低平均检测边际。

3.5 问题 3 的总结

结果	性质	状态
逐点单调性否定——反例构造 (Thm 3.1)	严格	反例存在
退化机制分析 (Prop 3.1)	严格	

结果	性质	状态
无偏 +Fisher 一致性下的期望单调性 (Thm 3.2)	严格 (在很强的假设下)	假设极强, 实际中难验证
保守进化的近似期望单调性 (Thm 3.3)	部分严格 + 猜想	
聚合度量的期望单调性 (Thm 3.4)	严格 (在 Thm 3.2 的假设下)	

核心结论: - 逐点单调性被严格否认: Spring 自进化可以使某些状态的检测边际退化。反例的核心机制是表示空间中的类内散布增加 (过拟合到噪声样本, 污染了干净样本的表示)。- 期望单调性需要极其强的假设 (Fisher 一致性 + 信息增益非负), 这些假设在实际中难以验证。- 保守进化提供近似单调性: 退化量级为 $O(1/\sqrt{t})$, 随训练衰减。

4. 全局诚实评估

4.1 三个核心发现的置信度矩阵

发现	数学严格性	实际可验证性	对 Spring 框架的影响
Q1: 收敛到驻点邻域, 速率 $O(\log T/\sqrt{T})$	高 (标准非凸 SGD 分析)	可验证 (监控梯度范数)	中性——收敛到驻点但不保证全局最优
Q1: $O(1/\sqrt{t})$ 速率需要在 PL 条件下	中 (PL 条件对 Spring 未验证)	需实验验证 PL 条件	若 PL 不成立 $\rightarrow$ Spring 收敛更慢
Q2: 遗憾上界 $\tilde{O}(\sqrt{T\ \mathcal{S}\ })$	高 (标准 Exp3 分析)	可验证 (离线回放)	中性——这是 minimax 最优速率
Q2: Lipschitz 改进需要验证 Δ_s 光滑性	中 (假设待验证)	需要实验估计 Δ_s 的空间相关性	若光滑性成立 $\rightarrow$ 显著加速探索
Q3: 逐点单调性不成立	高 (反例构造)	可直接实验验证	负面——Spring 不是万能的, 某些状态会退化

发现	数学严格性	实际可验证性	对 Spring 框架的影响
Q3: 期望单调性需要极强假设	中（假设的合理性存疑）	Fisher 一致性对实际 NN 不成立	警示 ——不应声称 Spring 总是改善检测

4.2 开放问题

- PL 条件的实验验证:** 对实际的 Multi-Head Spring 损失景观，计算 Hessian 谱并检查 PL 条件 ($\lambda_{\min}(\nabla^2 \mathcal{L}) \geq \mu$ 在梯度非零的方向上) 是否在驻点附近成立。
- Δ_s 的 **Lipschitz 连续性:** 设计实验测量 $|\Delta_s(p_i) - \Delta_s(p_j)|$ 作为 $\|p_i - p_j\|$ 的函数，验证或否证 $\text{PPE} \rightarrow \Delta_s$ 的 Lipschitz 传递。
- 反例的实验复现:** 在真实的 Spring 训练中监控 $\Delta_s(t)$ 的逐轮变化，寻找退化的具体实例。如果在实际数据上从未观测到退化，则理论反例的构造假设在实际中不成立——这反而说明 Spring 在实践中比理论预测的更好。
- 期望单调性的更弱条件:** 是否能在不依赖 Fisher 一致性的条件下，仅从 Spring 自重构的优化动态推导出某种形式的期望单调性？这需要更深入地分析自重构误差和噪声检测之间的信息论联系。
- 排列对称性的正面利用:** 设计优化算法显式利用 S_K 对称性（如通过 Weyl chamber 约束或对称性感知的初始化），观察是否能加速收敛。

参考文献

- Auer, P., Cesa-Bianchi, N., Freund, Y., & Schapire, R. E. (2002). The nonstochastic multiarmed bandit problem. *SIAM Journal on Computing*, 32(1), 48-77.
- Bubeck, S., & Cesa-Bianchi, N. (2012). Regret analysis of stochastic and nonstochastic multi-armed bandit problems. *Foundations and Trends in Machine Learning*, 5(1), 1-122.
- Ghadimi, S., & Lan, G. (2013). Stochastic first-and zeroth-order methods for nonconvex stochastic programming. *SIAM Journal on Optimization*, 23(4), 2341-2368.
- Jin, C., Ge, R., Netrapalli, P., Kakade, S. M., & Jordan, M. I. (2017). How to escape saddle points efficiently. *ICML*.
- Kleinberg, R., Slivkins, A., & Upfal, E. (2008). Multi-armed bandits in metric spaces. *STOC*.
- Liu, C., Zhu, L., & Belkin, M. (2022). Loss landscapes and optimization in over-parameterized non-linear systems and neural networks. *Applied and Computational Harmonic Analysis*, 59, 85-116.
- Robbins, H., & Monro, S. (1951). A stochastic approximation method. *The Annals of Mathematical Statistics*, 22(3), 400-407.
- Wainwright, M. J. (2019). *High-Dimensional Statistics: A Non-Asymptotic Viewpoint*. Cambridge University Press.

分析日期: 2026-06-29

作者注: 本分析在可处理的范围内是严格的——所有标准优化/在线学习结果被标注为 [严格证明], 所有依赖强假设的结果被标注为 [部分严格 + 猜想], 所有未被证明的猜想被明确标注为 [猜想]。本文是对 *Spring* 自进化理论框架的诚实数学审查, 不回避任何弱点。