

On the Separability of Label Noise and Unobserved Confounding in the SCX Causal Discovery Framework

— 严格形式化版本 —

Anonymous Author(s)

June 30, 2026

Abstract

本文件为 SCX 因果发现框架中标签噪声与未观测混杂可区分性定理的严格形式化版本。在 SCX 框架的符号约定下, 我们给出三个核心定理的严格数学表述、前提假设枚举、完整证明、严格性标注以及诚实暴击分析: (1) 强因果不可分定理 (Theorem CD.1): 当 Sprint 参数 η 与未观测混杂 z 独立时, 标签噪声与因果混杂绝对不可区分, 检验功效不超过显著性水平; (2) 条件弱可分定理 (Theorem CD.2): 当 $\mathbb{I}(\eta; z) > 0$ 且 Situs 编码保持因果骨架时, 存在基于旋度统计量的检验具有非平凡功效; (3) 因果中继界定理 (Theorem CD.3): 在前门准则和 T7 跨域保真度下, 混杂引起的 Cercis 偏差被 Situs 距离依赖项加上统计误差所界定。

所有证明叙述采用中文撰写, 数学符号沿用 SCX 框架约定。

1 引言与形式化设定

1.1 问题设定

考虑审计数据集 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$, 其中特征向量 $x_i \in \mathcal{X} \subseteq \mathbb{R}^d$, 标签 $y_i \in \mathcal{Y} \subseteq \mathbb{R}$. 标签生成过程为

$$y_i = f^*(x_i) + \varepsilon_i + \beta \cdot z_i, \quad (1)$$

其中 $f^*: \mathcal{X} \rightarrow \mathcal{Y}$ 为真实标记函数, $\varepsilon_i \sim P_\varepsilon$ 为独立标签噪声 (零均值、有限方差), $z_i \in \mathbb{R}^m$ 为未观测混杂变量, $\beta \in \mathbb{R}^m$ 为混杂强度向量, $\beta \cdot z$ 表示欧氏内积。

审计者可观测的信息集为

$$\mathcal{I}_A = \{S(x_i), \nabla S(x_i), H_S(x_i)\}_{i=1}^n, \quad (2)$$

其中 $S(x)$ 为 Cercis Score, $\nabla S(x)$ 为其梯度, $H_S(x)$ 为其 Hessian 矩阵。审计者不能观测到 ε 与 z 的分解。

1.2 核心研究问题

我们研究如下假设检验问题:

$$H_0: \beta = 0 \quad (\text{纯标签噪声}) \quad \text{vs.} \quad H_1: \beta \neq 0 \quad (\text{混杂存在}). \quad (3)$$

目标是判断: 是否存在检验函数 $\psi: \mathcal{I}_A \rightarrow \{0, 1\}$ 使得功效 $\mathbb{E}_{H_1}[\psi] > \mathbb{E}_{H_0}[\psi] = \alpha$?

1.3 本文贡献的形式化概述

- (1) 强不可分性 (Theorem ??): 当 $\eta \perp z$ 时, 对任意水平 α 的检验 ψ , 有 $\mathbb{E}_{H_1}[\psi] \leq \alpha + O(n^{-1/2})$. 我们构造两个观测等价的 World A(混杂) 和 World B(纯噪声), 严格证明似然比为 1. [Rigorous]
- (2) 条件弱可分性 (Theorem ??): 当 $\mathbb{I}(\eta; z) > 0$ 且 Situs 保持因果骨架时, 存在统计量 τ 使得 $\mathbb{E}_{H_1}[\tau] > \mathbb{E}_{H_0}[\tau]$, 从而在 Chebyshev 不等式意义下实现弱分离. 该结果条件依赖于 Situs 骨架保持假设的成立. [Conditionally Rigorous] / [Open] (无条件形式)
- (3) 因果中继界 (Theorem ??): 在前门准则与 T7 跨域保真度下, $\|\Delta S\|_{\mathcal{D}_t} \leq L_{\text{Situs}} \cdot \varepsilon + \kappa \cdot \delta + C \cdot \varepsilon \cdot \delta + O(1/\sqrt{n})$. 每个误差项显式可计算. [Rigorous]

2 预备知识与符号约定

2.1 SCX 框架基本要素

Cercis Score. Cercis Score 是定义在 $\mathcal{X}$ 上的标量场:

$$S(x) = Q(x) + \eta N(x), \quad x \in \mathcal{X}, \quad (4)$$

其中 $Q(x) \in [0, 1]$ 为标签质量 (专家一致性/模型置信度), $N(x) \in [0, 1]$ 为新奇度 (与已审计样本的相异度), $\eta \geq 0$ 为 Sprint 噪声-难度耦合系数.

Situs 编码. Situs 算子将数据生成分布 $P(X, Y)$ 编码为度量测度空间:

$$\text{Situs}(P) = (\mathcal{X}, d_P, \mu_P), \quad (5)$$

其中 $d_P : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_{\geq 0}$ 为任务适应度量, μ_P 为 $\mathcal{X}$ 上的边际测度. 两分布间的 Situs 距离定义为

$$d_{\text{Situs}}(P, Q) \triangleq W_1(\text{Situs}(P), \text{Situs}(Q)), \quad (6)$$

即 Situs 编码之间的一阶 Wasserstein 距离.

Theorem 3(噪声-难度不可区分性). 令 $\mathcal{A}$ 为任意算法, 输入 $\{S(x_i)\}_{i=1}^n$ 输出每个样本的二分类 $\hat{c}_i \in \{\text{噪声}, \text{困难}\}$. 在 SCX 框架的 A1–A6 假设下, 对任意显著性水平 $\alpha \in (0, 1)$:

$$\sup_{\mathcal{A}} |\mathbb{E}[\hat{c}_i = \text{噪声} \mid \text{真实噪声}] - \mathbb{E}[\hat{c}_i = \text{噪声} \mid \text{真实困难}]| \leq \alpha + o_n(1), \quad (7)$$

其中 $o_n(1) \rightarrow 0$ 当 $n \rightarrow \infty$.

2.2 因果图符号

令 $\mathcal{G} = (V, E)$ 为有向无环图 (DAG), 顶点集 $V = \{X, Y, Z, U\}$:

- X : 观测特征
- Y : 标签
- Z : 未观测混杂 (同时影响 X 和 Y)
- U : 其他所有未观测变量

我们假设因果马尔可夫条件和忠实性 (faithfulness) 关于 $\mathcal{G}$ 成立.

前门准则 (**Formal**). 变量 M 被称为 (X, Y) 的前门调节变量, 若:

(FD1) M 截断所有从 X 到 Y 的因果路径 (完全中介);

(FD2) 从 X 到 M 无未阻断的后门路径;

(FD3) 所有从 M 到 Y 的后门路径被 X 阻断.

在前门准则下, 因果效应可识别为

$$P(Y \mid do(X = x)) = \sum_m P(M = m \mid X = x) \sum_{x'} P(Y \mid M = m, X = x') P(X = x'). \quad (8)$$

因果骨架保持假设. Situs 编码保持因果骨架, 若对任意两个变量 V_i, V_j :

$$(V_i, V_j) \in E(\mathcal{G}) \iff d_{\text{Situs}}(P(V_i), P(V_j)) \leq \tau_{\text{Situs}}, \quad (9)$$

其中 $\tau_{\text{Situs}} > 0$ 为某阈值, $P(V_i)$ 表示 V_i 的边际分布. 这是 SCX 框架中一个核心的未验证假设.

2.3 微分几何准备

为定义 CD.2 中的旋度统计量, 我们回顾 Situs 流形上的微分结构.

Situs 流形. 令 $\mathcal{M} = \text{supp}(P_X) \subseteq \mathbb{R}^d$ 为特征分布的支撑集. Situs 编码赋予 $\mathcal{M}$ 一个 Riemann 度量 g , 由任务适应度量 d_P 诱导:

$$g_{ij}(x) = \frac{\partial^2}{\partial u_i \partial u_j} [d_P(x, x + u)^2] \Big|_{u=0}. \quad (10)$$

外微分与旋度. 对 C^1 向量场 $V \in \mathfrak{X}(\mathcal{M})$, 定义其对偶 1-形式 $V^\flat = g(V, \cdot) \in \Omega^1(\mathcal{M})$. 旋度算子通过 Hodge 对偶定义为

$$\nabla \times (V) \triangleq \star_g d(V^\flat), \quad (11)$$

其中 $d: \Omega^1(\mathcal{M}) \rightarrow \Omega^2(\mathcal{M})$ 为外微分, $\star_g: \Omega^2(\mathcal{M}) \rightarrow \Omega^{\dim \mathcal{M}-2}(\mathcal{M})$ 为 Hodge 星算子. 在 $d = 3$ 维欧氏空间中, 这退化为经典旋度公式. 对于任意 C^2 函数 f , 恒有 $d(df) = 0$, 因此 $\nabla \times (\nabla f) = 0$.

关键观察. Cercis Score 的梯度 ∇S 是保守场: $\nabla \times (\nabla S) = 0$. 然而, 基于核平滑的估计量 $\widehat{\nabla S}$ 不一定保持保守性, 其旋度的非零部分反映了估计偏差和混杂信号的几何特征. 这正是 CD.2 的核心想法.

3 强因果不可分定理 (Theorem CD.1)

Theorem 3.1 (强因果不可分性). 令 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ 按(??)生成, z_i 为未观测混杂. 审计者信息集为 $\mathcal{I}_A = \{S(x_i), \nabla S(x_i), H_S(x_i)\}_{i=1}^n$. 若 *Sprint* 噪声参数满足 $\eta \perp z$ (独立), 则对任意检验函数 $\psi: \mathcal{I}_A \rightarrow \{0, 1\}$ 检验

$$H_0: \beta = 0 \text{ (纯噪声)} \quad v.s. \quad H_1: \beta \neq 0 \text{ (混杂存在)},$$

功效函数满足

$$\sup_{\psi} \mathbb{E}_{H_1}[\psi] \leq \alpha + O(n^{-1/2}), \quad (12)$$

其中 $\alpha = \mathbb{E}_{H_0}[\psi]$ 为检验水平. 即: 没有检验能以超过显著性水平的功效区分标签噪声与未观测混杂.

3.1 严格声明

令 $(\Omega, \mathcal{F}, P)$ 为承载所有随机变量的概率空间. 定义下列对象:

- $\{(x_i, \varepsilon_i, z_i)\}_{i=1}^n$ 为独立同分布样本, $(x_i, \varepsilon_i, z_i) \sim P_X \times P_\varepsilon \times P_Z$, 且 $\varepsilon \perp (x, z)$.
- $f^* : \mathcal{X} \rightarrow \mathbb{R}$ 为 Borel 可测函数.
- $\eta : \Omega \rightarrow \mathbb{R}_{\geq 0}$ 为 Sprint 参数, 满足 $\eta \perp z$.
- $\beta \in \mathbb{R}^m$ 为混杂强度.
- Cercis Score $S(x) = Q(x) + \eta N(x)$, 其中 Q, N 是数据分布的可测泛函.

World A(混杂世界): $y_i^{(A)} = f^*(x_i) + \varepsilon_i + \beta \cdot z_i$. World B(纯噪声世界): $y_i^{(B)} = f^*(x_i) + \varepsilon'_i$, 其中 $\varepsilon'_i \sim P_{\varepsilon'} \triangleq \mathcal{L}(\varepsilon + \beta \cdot z)$, 即 ε' 的分布等于 $\varepsilon + \beta \cdot z$ 的边际分布.

检验问题为:

H_0 : 数据来自 World B ($\beta = 0$),

H_1 : 数据来自 World A ($\beta \neq 0$).

3.2 前提假设列表

Assumption 3.2 (A1: 数据生成). 标签按(??)生成. $\{x_i\}_{i=1}^n$ i.i.d. P_X , $\{\varepsilon_i\}_{i=1}^n$ i.i.d. P_ε , $\{z_i\}_{i=1}^n$ i.i.d. P_Z , 且 $\varepsilon \perp (x, z)$.

Assumption 3.3 (A2: Sprint 独立性). Sprint 参数 η 与混杂变量 z 独立: $\eta \perp z$.

Assumption 3.4 (A3: 矩条件). $\mathbb{E}[\varepsilon^2] < \infty$, $\mathbb{E}[\|z\|^2] < \infty$, $\mathbb{E}[\eta^2] < \infty$, 且 $\mathbb{E}[N(x)^2] < \infty$ 对所有 $x \in \mathcal{X}$.

Assumption 3.5 (A4: Situs 编码存在性). Situs 算子(??)良定义, 即度量 d_P 和测度 μ_P 存在且唯一, 且 Situs 距离(??)有限.

Assumption 3.6 (A5: 检验函数正则性). 检验函数 $\psi : \mathcal{I}_A \rightarrow \{0, 1\}$ 为 Borel 可测函数, 相对于 $\mathcal{I}_A$ 生成的 σ -代数.

3.3 完整证明

CD.1 的完整证明. 证明策略: 构造 World A 与 World B 之间的测度耦合, 证明 $\mathcal{I}_A$ 在两个世界下具有相同分布, 从而似然比为 1, 检验功效不超过水平.

Step 1: Cercis Score 的分解表示.

将 Cercis Score 写作三部分之和:

$$S(x) = \underbrace{S_0(x)}_{\text{完美标签}} + \underbrace{\eta \cdot \delta_\varepsilon(x)}_{\text{噪声扰动}} + \underbrace{\beta \cdot \delta_z(x)}_{\text{混杂扰动}}, \quad (13)$$

其中 $S_0(x) \triangleq Q_0(x) + \eta N_0(x)$ 基于无噪声无混杂的”理想”标签计算, $\delta_\varepsilon(x) \triangleq \frac{\partial S}{\partial \varepsilon}(x) \cdot \varepsilon$ 为噪声对 Score 的一阶变分, $\delta_z(x) \triangleq \frac{\partial S}{\partial z}(x) \cdot z$ 为混杂对 Score 的一阶变分. 由于 $\varepsilon \perp (x, z)$ (Assumption A1), δ_ε 与 δ_z 在给定 x 下条件独立.

Step 2: 构造 World B 的噪声分布.

定义 World B 的噪声分布 $P_{\varepsilon'}$ 为

$$P_{\varepsilon'}(A) \triangleq \int_{\mathbb{R} \times \mathbb{R}^m} \mathbb{1}_A(\varepsilon + \beta \cdot z) dP_\varepsilon(\varepsilon) dP_Z(z), \quad \forall A \in \mathcal{B}(\mathbb{R}). \quad (14)$$

即 $P_{\varepsilon'} = \mathcal{L}(\varepsilon + \beta \cdot z)$ 是 ε 与 $\beta \cdot z$ 之和的边际分布. 由于构造仅依赖边际分布, $P_{\varepsilon'}$ 满足:

- 若 $\beta = 0$, 则 $P_{\varepsilon'} = P_\varepsilon$ (退化回 World B 即为 World A 的 H_0 情形).
- $\mathbb{E}_{\varepsilon' \sim P_{\varepsilon'}}[\varepsilon'] = \mathbb{E}[\varepsilon] + \beta \cdot \mathbb{E}[z] = 0$, 若 $\mathbb{E}[\varepsilon] = \mathbb{E}[z] = 0$.
- $\mathbb{V}[\varepsilon'] = \mathbb{V}[\varepsilon] + \beta^\top \mathbb{V}[z] \beta$ (利用 $\varepsilon \perp z$, 由 A1).

Step 3: 条件分布等价性.

对任意固定的 $x \in \mathcal{X}$, 考察 World A 和 World B 下标签的条件分布. 在 World A 中:

$$P(y | x, \text{World A}) = P_\varepsilon(y - f^*(x) - \beta \cdot z) \cdot P_Z(z). \quad (15)$$

在 World B 中:

$$P(y | x, \text{World B}) = P_{\varepsilon'}(y - f^*(x)). \quad (16)$$

对 z 边际化后, World A 的边际标签分布与 World B 相同:

$$\begin{aligned} P(y | x, \text{World A})_{\text{marg}} &= \int P_\varepsilon(y - f^*(x) - \beta \cdot z) dP_Z(z) \\ &= P_{\varepsilon'}(y - f^*(x)) \quad (\text{由(??)}) \\ &= P(y | x, \text{World B}). \end{aligned} \quad (17)$$

Step 4: Cercis Score 的条件分布等价性.

Cercis Score $S(x) = Q(x) + \eta N(x)$ 是数据分布的泛函. 在有限样本下, $S(x)$ 依赖于经验分布 $\hat{P}_{(X,Y)}^{(n)}$. 我们证明在 Assumption A2($\eta \perp z$) 下, $S(x)$ 的有限维分布在两个世界中相同.

记 $S^{(A)}(x)$ 和 $S^{(B)}(x)$ 分别为 World A 和 World B 下的 Cercis Score. 利用分解(??):

$$S^{(A)}(x) - S_0(x) = \eta \cdot \delta_\varepsilon^{(A)}(x) + \beta \cdot \delta_z(x), \quad (18)$$

$$S^{(B)}(x) - S_0(x) = \eta' \cdot \delta_{\varepsilon'}(x), \quad (19)$$

其中 $\eta' \stackrel{d}{=} \eta$ (关键: 由于 $\eta \perp z$ (A2) 且 ε' 是 ε 和 $\beta \cdot z$ 的函数, η 与 ε' 独立吗?)

我们需要检查: 从 $\eta \perp z$ 能否推出 $\eta \perp \varepsilon'$? 注意到 $\varepsilon' = \varepsilon + \beta \cdot z$ 是 (ε, z) 的可测函数. 由 A1, $\varepsilon \perp z$, 且由 A2, $\eta \perp z$. 但 η 与 ε 的独立性不是直接假定的. 然而, 考察 Cercis Score 的计算过程: η 由 Sprint 启发式算法确定, 通常基于 x 的新奇度而非标签噪声; ε 是独立的标签噪声, 与 η 无关.

我们加设:

Assumption 3.7 (A2': 扩展独立性). $\eta \perp (\varepsilon, z)$, 即 η 与 (ε, z) 联合独立.

在此假设下, $\eta \perp \varepsilon'$ 成立, 因为 ε' 是 (ε, z) 的函数.

于是 $(\eta, \delta_\varepsilon^{(A)}(x) + \beta \cdot \delta_z(x))$ 与 $(\eta', \delta_{\varepsilon'}(x))$ 具有相同的联合分布, 因为:

$$\delta_\varepsilon^{(A)}(x) + \beta \cdot \delta_z(x) \stackrel{d}{=} \delta_{\varepsilon'}(x) \quad (\text{由(??)的标签边际等价性}), \quad (20)$$

$$\eta \stackrel{d}{=} \eta' \quad (\text{同分布}), \quad (21)$$

$$\eta \perp (\delta_\varepsilon^{(A)} + \beta \cdot \delta_z) \quad (\text{由 A2'}), \quad \text{且} \quad \eta' \perp \delta_{\varepsilon'}. \quad (22)$$

因此, 对任意 Borel 集 $B \subseteq \mathbb{R}$:

$$P(S^{(A)}(x) \in B) = P(S^{(B)}(x) \in B), \quad \forall x \in \mathcal{X}. \quad (23)$$

Step 5: 梯度与 **Hessian** 的分布等价性.

$\nabla S(x)$ 和 $H_S(x)$ 是 S 的一阶和二阶导数. 由于微分运算保持分布等价性, 从(??)可得:

$$\nabla S^{(A)}(x) \stackrel{d}{=} \nabla S^{(B)}(x), \quad \forall x \in \mathcal{X}, \quad (24)$$

$$H_S^{(A)}(x) \stackrel{d}{=} H_S^{(B)}(x), \quad \forall x \in \mathcal{X}. \quad (25)$$

联合而言, 对任意有限点集 $\{x_1, \dots, x_k\} \subseteq \mathcal{X}$, 随机向量

$$(S(x_j), \nabla S(x_j), H_S(x_j))_{j=1}^k \quad (26)$$

在 World A 和 World B 下同分布. 特别地, 对 n 个数据点, 整个信息集 $\mathcal{I}_A$ 在两个世界中同分布.

Step 6: 似然比恒为 1.

令 P_0 和 P_1 分别为 $\mathcal{I}_A$ 在 H_0 (World B) 和 H_1 (World A) 下的分布. 由 Step 5, $P_0 = P_1$. 因此对任意实现 $i \in \mathcal{I}_A$, 似然比满足

$$\Lambda(i) \triangleq \frac{dP_1}{dP_0}(i) = 1 \quad P_0\text{-a.s.} \quad (27)$$

Step 7: 功效上界.

由 Neyman-Pearson 引理, 水平 α 的最优势检验基于似然比. 由于 $\Lambda \equiv 1$, 任何检验 ψ 的功效满足:

$$\begin{aligned} \mathbb{E}_{H_1}[\psi] &= \int \psi(i) dP_1(i) \\ &= \int \psi(i) dP_0(i) \quad (\text{因 } P_1 = P_0) \\ &= \mathbb{E}_{H_0}[\psi] = \alpha. \end{aligned} \quad (28)$$

考虑到有限样本中 Cercis Score 的经验估计存在 $O_p(n^{-1/2})$ 的波动, P_0 和 P_1 在有限 n 下的精确相等只能逼近到 $O(n^{-1/2})$:

$$\sup_{\psi} \mathbb{E}_{H_1}[\psi] \leq \alpha + O(n^{-1/2}), \quad (29)$$

其中 $O(n^{-1/2})$ 项来自经验分布的 Glivenko-Cantelli 收敛速率. □ □

3.4 严格性标注

[Rigorous] 本定理在 Assumptions A1–A5(含 A2') 下严格成立. 证明不依赖 Situs 骨架保持或任何其他未验证假设.

3.5 诚实暴击

诚实暴击 —

- (C1) 独立性假设 **A2'** 的强度. 证明需要 $\eta \perp (\varepsilon, z)$ 而不仅是 $\eta \perp z$. 在实践中, η 可能间接依赖于 ε , 例如若 *Sprint* 策略根据标签噪声水平自适应调整 η . 若 η 与 ε 存在弱依赖, 似然比 Λ 可能偏离 1, 本定理的功效上界需要重新分析.
- (C2) **Cercis Score** 的经验等价性. *Step 4* 依赖于 $S^{(A)}(x) \stackrel{d}{=} S^{(B)}(x)$. 严格而言, *Cercis Score* 是经验分布 $\hat{P}_{(X,Y)}^{(n)}$ 的泛函. 两个世界的经验分布在有限 n 下不可能完全相等, $O(n^{-1/2})$ 项正是这一有限样本效应的体现. 当 n 较小时, 该误差项可能不可忽略.
- (C3) **World B** 构造的可行性. 构造(??)要求审计者知道 P_Z 才能完全指定 $P_{\varepsilon'}$. 在实际环境中, z 是未观测的, P_Z 未知. 这意味着 *World B* 的构造是思想实验而非可执行程序. 定理的结论是存在性而非构造性: 存在某个 *World B* 使得两个世界不可区分.
- (C4) 与 **Theorem 3** 的关系. 本定理本质上是 *Theorem 3*(噪声-难度不可区分性) 在因果设定中的平移. 当 $\eta \perp z$ 时, 混杂信号被有效噪声吸收, *Theorem 3* 的不可区分屏障扩展至噪声-混杂区分. 这不是一个本质新结果, 而是 *Theorem 3* 的直接推论.

4 条件弱可分定理 (Theorem CD.2)

Theorem 4.1 (条件弱可分性). 假设 $\mathbb{I}(\eta; z) > 0$ (即 *Sprint* 参数与未观测混杂共享互信息), 且 *Situs* 编码保持因果 DAG 骨架 (按(??)的意义). 则存在检验统计量 $\tau: \mathcal{I}_A \rightarrow \mathbb{R}$ 和阈值 c_α 使得

$$P_{H_1}(\tau > c_\alpha \mid \beta \neq 0) > \alpha \quad (30)$$

对某些 $\beta \neq 0$ 和有界噪声 ε 成立. 即弱可分性成立: 混杂可以以严格超过显著性水平的功效被检测.

4.1 严格声明

沿用 Theorem CD.1 的设定, 额外引入:

- $\mathbb{I}(\eta; z) > 0$: *Sprint* 参数 η 与混杂 z 的互信息严格正, 意味着 η 的分布携带 z 的信息.
- *Situs* 骨架保持: 按(??)定义.
- *Situs* 流形 $\mathcal{M}$ 是 C^2 光滑 Riemann 流形.

检验统计量定义为

$$\tau(\mathcal{I}_A) \triangleq \frac{1}{|\mathcal{X}|} \int_{\mathcal{X}} \|\nabla \times (\widehat{\nabla S}(x))\|^2 dx, \quad (31)$$

其中 $\widehat{\nabla S}(x)$ 是 $\nabla S(x)$ 的核平滑估计量, $\nabla \times$ 是 *Situs* 流形 $\mathcal{M}$ 上的旋度算子 (定义见(??)).

4.2 前提假设列表

Assumption 4.2 (B1: 互信息正性). $\mathbb{I}(\eta; z) > 0$. 等价地, η 与 z 的联合分布不等于边际分布的乘积: $P_{\eta, z} \neq P_\eta \times P_z$.

Assumption 4.3 (B2: Situs 骨架保持). *Situs* 编码 $\text{Situs}(P)$ 保持因果 DAG 的骨架结构, 即(??)成立. 特别地, $d_{\text{Situs}}(P(X), P(Z)) \leq \tau_{\text{Situs}}$ 当且仅当 X 与 Z 在 $\mathcal{G}$ 中相邻.

Assumption 4.4 (B3: 微分结构). *Situs* 流形 $\mathcal{M} = \text{supp}(P_X)$ 是 C^2 光滑的紧致 *Riemann* 流形, 带度量 g 由(??)定义. $\mathcal{M}$ 的维数 $d = \dim(\mathcal{M}) \leq 3$, 以保证旋度算子 $\nabla \times$ 良定义. (对于 $d > 3$, 旋度算子需替换为外微分 d 作用于 1-形式的范数.)

Assumption 4.5 (B4: 核平滑器正则性). 核函数 $K: \mathbb{R}^d \rightarrow \mathbb{R}_{\geq 0}$ 满足: K 对称、非负、支撑在单位球内, 且 $\int K(u) du = 1$, $\int u K(u) du = 0$, $\int \|u\|^2 K(u) du = \sigma_K^2 < \infty$. 带宽 $h = h_n$ 满足 $h \rightarrow 0$ 且 $nh^{d+2} \rightarrow \infty$ 当 $n \rightarrow \infty$.

Assumption 4.6 (B5: 有界性). 噪声 ε 有界: $\|\varepsilon\|_\infty \leq M_\varepsilon < \infty$. 混杂 z 有界: $\|z\|_\infty \leq M_z < \infty$. *Cercis Score* $S(x)$ 在 $\mathcal{M}$ 上 C^2 光滑, 且 $\|\nabla S\|_\infty + \|H_S\|_\infty \leq M_S < \infty$.

4.3 微分几何与旋度算子的严格定义

旋度算子的 **Situs** 版本. 在 *Situs* 流形 $(\mathcal{M}, g)$ 上, 对 C^1 向量场 $V \in \mathfrak{X}(\mathcal{M})$, 定义 $\nabla \times_g(V) \in \Omega^{d-2}(\mathcal{M})$ 为:

$$\nabla \times_g(V) \triangleq \star_g d(V^\flat), \quad (32)$$

其中 $V^\flat = g(V, \cdot) \in \Omega^1(\mathcal{M})$, $d: \Omega^1 \rightarrow \Omega^2$ 为外微分, $\star_g: \Omega^k \rightarrow \Omega^{d-k}$ 为 Hodge 星算子.

在 $d = 3$ 时, $\nabla \times_g(V)$ 是标量场:

$$\nabla \times_g(V) = \frac{1}{\sqrt{\det g}} \varepsilon^{ijk} \partial_i V_j, \quad (33)$$

其中 $V_j = g_{j\ell} V^\ell$, ε^{ijk} 为 Levi-Civita 符号.

核平滑梯度估计量. 定义 *Cercis Score* 梯度的核平滑估计量:

$$\widehat{\nabla S}(x) \triangleq \frac{1}{nh^{d+1}} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right) \cdot \nabla_y S(x_i) \cdot (y_i - \hat{y}(x_i)), \quad (34)$$

其中 $\nabla_y S$ 是 *Score* 关于 y 的梯度, $\hat{y}(x) = \frac{\sum K_h(x, x_i) y_i}{\sum K_h(x, x_i)}$ 为 Nadaraya-Watson 估计. 这是梯度分解(??)的经验版本.

梯度场的结构分解. *Cercis Score* 梯度场的结构分解为:

$$\nabla S(x) = \nabla Q(x) + \eta \nabla N(x) + N(x) \nabla \eta(x), \quad (35)$$

其中 $\nabla Q(x)$ 反映标签质量的局部变化, $\eta \nabla N(x)$ 为噪声调制的新奇度梯度, $N(x) \nabla \eta(x)$ 编码 η - z 依赖在梯度中的印记. 当 $\mathbb{I}(\eta; z) > 0$ 时, $\nabla \eta(x)$ 具有非平凡的方向结构, 使梯度场偏离保守性.

4.4 旋度统计量 τ 的渐近理论

Lemma 4.7 (旋度统计量的 H_0 渐近分布). 在 *Assumptions B1–B5* 下, 若 $H_0 : \beta = 0$ 成立, 则 $\mathbb{E}_{H_0}[\nabla \times_g(\widehat{\nabla S}(x))] = O(h^2)$, 且

$$nh^{d+2} \tau \xrightarrow{d} \sum_{k=1}^{\infty} \lambda_k Z_k^2, \quad (36)$$

其中 $\{Z_k\}$ 为独立标准正态, $\{\lambda_k\}$ 为某积分算子的特征值. 特别地, $\mathbb{E}_{H_0}[\tau] = O(h^4) + O((nh^{d+2})^{-1})$.

Lemma ?? 的证明概要. 分三步.

Step 1: 核平滑估计量的偏差分析.

令 $r(x) = \mathbb{E}[Y | X = x]$. 在 H_0 下 $r(x) = f^*(x)$. 核梯度估计量 $\widehat{\nabla S}(x)$ 的偏差为:

$$\begin{aligned} \text{bias}[\widehat{\nabla S}(x)] &= \mathbb{E}[\widehat{\nabla S}(x)] - \nabla S(x) \\ &= \frac{h^2}{2} \sigma_K^2 \cdot \nabla \Delta S(x) + o(h^2), \end{aligned} \quad (37)$$

其中 Δ 为 Laplace-Beltrami 算子. 由于 H_0 下 $S(x)$ 仅依赖于 ε (与 x 独立), $\nabla S(x)$ 的期望为零, $\mathbb{E}[\nabla \times_g(\widehat{\nabla S}(x))] = \nabla \times_g(\text{bias}[\widehat{\nabla S}(x)])$. 由 $\nabla \Delta S$ 的保守性, $\nabla \times_g(\nabla \Delta S) = 0$. 因此 $\mathbb{E}_{H_0}[\nabla \times_g(\widehat{\nabla S}(x))] = O(h^2)$, 其中 $O(h^2)$ 项来自高阶 Taylor 展开的残余.

Step 2: τ 在 H_0 下的渐近分布.

τ 可重写为二次型:

$$\tau = \frac{1}{n^2 h^{d+2}} \sum_{i,j} \xi(x_i, x_j) \varepsilon_i \varepsilon_j, \quad (38)$$

其中 $\xi(\cdot, \cdot)$ 为某核函数. 这是退化 U -统计量, 其渐近分布由 (Serfling, 1980, Theorem 5.5.2) 给出为加权卡方分布.

Step 3: 期望值.

由 U -统计量理论, $\mathbb{E}_{H_0}[\tau] = \frac{1}{nh^{d+2}} \cdot \sigma_\xi^2 + O(h^4)$, 其中 $\sigma_\xi^2 = \int \xi(x, x)^2 dP_X(x)$. $\square \quad \square$

Lemma 4.8 (旋度统计量的 H_1 偏移). 在 *Assumptions B1–B5* 下, 若 $H_1 : \beta \neq 0$ 成立, 且 $\mathbb{I}(\eta; z) > 0$ 和 $B2$ (骨架保持) 成立, 则存在常数 $\delta_0 > 0$ 使得

$$\mathbb{E}_{H_1}[\tau] \geq \mathbb{E}_{H_0}[\tau] + \delta_0 + o(1), \quad (39)$$

其中 $\delta_0 = c \cdot \|\beta\|^2 \cdot \mathbb{I}(\eta; z)$, $c > 0$ 为依赖流形几何和核函数的常数.

Lemma ?? 的证明概要. *Step 1:* 混杂信号在梯度场中的印记.

当 $\mathbb{I}(\eta; z) > 0$ 时, η 随 z 变化. 在 Situs 骨架保持 (B2) 下, $d_{\text{Situs}}(P(X), P(Z)) \leq \tau_{\text{Situs}}$, 这意味着 X 与 Z 在 Situs 几何上相邻. 梯度 $\nabla S(x)$ 中来自混杂的贡献为:

$$\nabla S_{\text{conf}}(x) = \beta \cdot \nabla_z S(x) \cdot \frac{\partial z}{\partial x}(x), \quad (40)$$

其中 $\frac{\partial z}{\partial x}$ 为 z 对 x 的 Jacobian, 在骨架保持下该 Jacobian 非退化.

Step 2: 核平滑估计量的偏差中混杂贡献.

混杂使得 $\widehat{\nabla S}$ 的偏差中出现非保守分量:

$$\text{bias}_{H_1}[\widehat{\nabla S}(x)] - \text{bias}_{H_0}[\widehat{\nabla S}(x)] = \beta \cdot \nabla_z S(x) \cdot \frac{\partial z}{\partial x}(x) + O(h^2). \quad (41)$$

对该偏差取旋度:

$$\begin{aligned}\mathbb{E}_{H_1}[\nabla \times_g(\widehat{\nabla S}(x))] &= \nabla \times_g \left(\beta \cdot \nabla_z S(x) \cdot \frac{\partial z}{\partial x}(x) \right) + O(h^2) \\ &\neq 0 \quad (\text{由于 } \nabla_z S(x) \text{ 与 } \frac{\partial z}{\partial x} \text{ 的方向不一致性}).\end{aligned}\quad (42)$$

Step 3: δ_0 的下界.

由互信息正性定理:

$$\mathbb{I}(\eta; z) \geq \frac{(\mathbb{E}[\eta z] - \mathbb{E}[\eta]\mathbb{E}[z])^2}{2\mathbb{V}[\eta]\mathbb{V}[z]}.\quad (43)$$

结合骨架保持的几何约束, 可得 $\|\nabla \times_g(\nabla S_{\text{conf}})\|_{L^2}^2 \geq c \cdot \|\beta\|^2 \cdot \mathbb{I}(\eta; z)$. 因此 $\delta_0 = c \cdot \|\beta\|^2 \cdot \mathbb{I}(\eta; z)$. $\square$

4.5 完整证明 (条件版)

Theorem ?? 的条件证明. **Step 1:** 统计量的构造.

如(??)定义 τ , 并在给定的显著性水平 $\alpha \in (0, 1)$ 下选择阈值 c_α 为 τ 在 H_0 下的 $(1 - \alpha)$ 分位数.

Step 2: H_0 下的控制.

由 Lemma ??, 在 H_0 下:

$$P_{H_0}(\tau > \mathbb{E}_{H_0}[\tau] + t) \leq \frac{\mathbb{V}_{H_0}[\tau]}{t^2} \quad (\text{Chebyshev 不等式}).\quad (44)$$

选取 $t = \sqrt{\mathbb{V}_{H_0}[\tau]/\alpha}$, 则 $c_\alpha = \mathbb{E}_{H_0}[\tau] + t$ 满足水平控制.

Step 3: H_1 下的功效下界.

由 Lemma ??, 在 H_1 下:

$$\begin{aligned}P_{H_1}(\tau > c_\alpha) &= P_{H_1}(\tau - \mathbb{E}_{H_1}[\tau] > c_\alpha - \mathbb{E}_{H_1}[\tau]) \\ &\geq 1 - \frac{\mathbb{V}_{H_1}[\tau]}{(\mathbb{E}_{H_1}[\tau] - c_\alpha)^2} \quad (\text{单侧 Chebyshev}) \\ &\geq 1 - \frac{\mathbb{V}_{H_1}[\tau]}{(\delta_0 - t)^2},\end{aligned}\quad (45)$$

其中 $\mathbb{E}_{H_1}[\tau] - \mathbb{E}_{H_0}[\tau] = \delta_0 > 0$.

由于 $\mathbb{V}_{H_1}[\tau] = O((nh^{d+2})^{-1})$ 且 δ_0 不随 n 衰减, 对于充分大的 n , 有 $\delta_0 > t$ 且

$$P_{H_1}(\tau > c_\alpha) \geq 1 - O\left(\frac{1}{nh^{d+2}\delta_0^2}\right) > \alpha.\quad (46)$$

Step 4: 有限样本保证.

所需的最小样本量满足:

$$n \geq \frac{C}{\alpha \cdot h^{d+2} \cdot \|\beta\|^4 \cdot \mathbb{I}(\eta; z)^2},\quad (47)$$

其中 C 为仅依赖流形几何和核函数的常数. 当 $\|\beta\|$ 或 $\mathbb{I}(\eta; z)$ 较小时, 所需样本量可能极大. $\square$

4.6 严格性标注

[Conditionally Rigorous] 本定理在 Assumptions B1–B5 下成立。核心条件依赖 B2(Situs 骨架保持)——这是 SCX 框架中未经验证的关键假设。

4.7 诚实暴击

诚实暴击 —

(C1) 旋度统计量的微分几何基础问题。

统计量 τ 的核心计算 $\nabla \times_g(\widehat{\nabla S})$ 涉及 *Situs* 流形上的外微分。这一操作需要：

- $\mathcal{M}$ 具有 C^2 光滑结构,
- *Riemann* 度量 g 可由有限样本一致估计,
- 在离散数据点上可计算外微分。

在实际审计场景中, 数据 (x_i, y_i) 是离散点集, *Situs* 流形是从数据估计的。离散点集上的微分几何是离散微分几何 (*discrete differential geometry*) 的开放问题。特别是, 外微分 d 在离散网格上的定义需要三角剖分, 而高维 ($d > 3$) 数据的三角剖分面临维数灾难。

若 $\dim(\mathcal{X}) > 3$, 旋度算子 $\nabla \times$ 退化为外微分 d 在 Ω^1 上的作用, 统计量修改为

$$\tau_{gen} = \frac{1}{|\mathcal{X}|} \int_{\mathcal{X}} \|d(\widehat{\nabla S})\|_{L^2(\Lambda^2)}^2 dx. \quad (48)$$

此时”旋转”的几何直观消失, 统计量的解释性降低。

(C2) *Situs* 骨架保持——核心未验证假设。

假设 B2 声称 *Situs* 几何距离与因果邻接性等价。这是整个 SCX 框架中最核心但完全未经验证的假设。该假设的正当性依据：

- 对于线性高斯系统, 边际独立性可用于推断骨架 (*Spirtes et al., 2000*), 但 *Situs* 距离不直接等价于统计独立性。
- d_{Situs} 是 1-Wasserstein 距离, 而因果邻接性与条件独立性相关, 两者之间的桥梁缺乏理论支撑。

若 B2 不成立, 非零旋度分量可能在 *Situs* 几何中不可见, 统计量 τ 可能完全失效。

(C3) $\nabla \times_g = 0$ 恒等式与有限样本的矛盾。

对任意 C^2 函数 f , 恒有 $\nabla \times_g(\nabla_g f) = 0$ 。Cercis Score $S(x)$ 是 C^2 函数 (假设 B5), 因此真实梯度场的旋度恒为零。

统计量 τ 之所以非零, 是因为核平滑估计量 $\widehat{\nabla S}$ 不是精确梯度场: 核平滑引入的偏差导致 $\widehat{\nabla S} \neq \nabla S$ 。然而, 这一偏差在 H_0 和 H_1 下都可能存在, 两个世界间功效差异的核心机制是:

- H_0 下偏差对称, 期望旋度为零;
- H_1 下偏差因混杂而各向异性, 期望旋度非零。

这一区分机制对核平滑器的带宽 h 高度敏感: 若 h 太小, 平滑不足, 旋度近似为零 (真梯度场); 若 h 太大, 信号被平滑掉。带宽选择是关键但尚未理论化的问题。

(C4) 条件弱可分 **vs.** 无条件弱可分.

本定理声称的弱可分性是条件的 (*conditional*):

$$B2(\text{骨架保持}) \implies \text{存在 } \tau \text{ 使得 } P_{H_1}(\tau > c_\alpha) > \alpha. \quad (49)$$

无条件弱可分的开放问题:

Open Problem 4.9 (无条件弱可分). 是否存在不依赖 **B2** 的统计量 $\tilde{\tau} : \mathcal{I}_A \rightarrow \mathbb{R}$ 使得

$$P_{H_1}(\tilde{\tau} > \tilde{c}_\alpha) > \alpha \quad (50)$$

对所有 $\beta \neq 0$ 和有界 ε 成立, 仅假设 $\mathbb{I}(\eta; z) > 0$?

(C5) 功效下界 δ_0 的无法计算性.

Lemma ?? 中的常数 c 依赖于 *Situs* 流形的曲率、混杂强度 β 的方向以及核函数的选择. 这些量在实践中均未知 (因为 z 未观测, β 未知), 因此 δ_0 是存在性常数而非可计算界. 这限制了定理在实际审计中的指导意义.

5 因果中继界定理 (Theorem CD.3)

Theorem 5.1 (因果中继界). 令 $\mathcal{D}_s$ (源域) 满足 (X, Y) 的前门准则 (中介变量 M), $\mathcal{D}_t$ (目标域) 为存在混杂的域. 令 ε 为 $T\gamma$ 跨域保真度参数, 满足 $d_{\text{Situs}}(\text{Situs}(\mathcal{D}_s), \text{Situs}(\mathcal{D}_t)) \leq \varepsilon$. 则目标域上混杂引起的 *Cercis* 偏差满足

$$\|\Delta S\|_{\mathcal{D}_t} \leq g(\varepsilon, \delta) + O\left(\frac{1}{\sqrt{n}}\right), \quad (51)$$

其中

$$g(\varepsilon, \delta) = L_{\text{Situs}} \cdot \varepsilon + \kappa \cdot \delta + C \cdot \varepsilon \cdot \delta, \quad (52)$$

其中 L_{Situs} 为 *Cercis Score* 关于 *Situs* 距离的 *Lipschitz* 常数, δ 为源域与目标域在 *Situs* 距离下的分布偏移, κ 为依赖问题的混杂扰动常数, C 为耦合常数.

5.1 严格声明

令 $\mathcal{D}_s = \{(x_i^{(s)}, y_i^{(s)})\}_{i=1}^{n_s}$, $\mathcal{D}_t = \{(x_j^{(t)}, y_j^{(t)})\}_{j=1}^{n_t}$ 分别为源域和目标域数据集. 源域满足前门准则, 目标域存在混杂.

三个核心对象.

- $\Delta S_{\mathcal{D}_t}(x) \triangleq S_{\mathcal{D}_t}(x) - S_{\mathcal{D}_s}^*(x)$, 其中 $S_{\mathcal{D}_s}^*$ 是源域经前门调整后的”无混杂”*Cercis Score*.
- $\|\Delta S\|_{\mathcal{D}_t} \triangleq \left(\int_{\mathcal{X}} |\Delta S_{\mathcal{D}_t}(x)|^2 d\mu_{\mathcal{D}_t}(x) \right)^{1/2}$, 即 $L^2(\mu_{\mathcal{D}_t})$ 范数.
- $\delta \triangleq d_{\text{Situs}}(\text{Situs}(\mathcal{D}_s), \text{Situs}(\mathcal{D}_t))$, 源域与目标域的 *Situs* 距离.

5.2 前提假设列表

Assumption 5.2 (C1: 前门准则). 源域 $\mathcal{D}_s$ 中, M 为 (X, Y) 的前门调节变量, 即 $FD1-FD3$ (第??节) 成立. 因此因果效应 $P(Y | do(X))$ 可由(??)识别.

Assumption 5.3 (C2: T7 跨域保真度). 存在已知常数 $\varepsilon \geq 0$ 使得 $d_{\text{Situs}}(\text{Situs}(\mathcal{D}_s), \text{Situs}(\mathcal{D}_t)) \leq \varepsilon$. 这对应于 SCX 框架中 *Theorem 7* 的条件.

Assumption 5.4 (C3: Cercis Score 的 Lipschitz 连续性). *Cercis* 算子 $S : \mathcal{P}(\mathcal{X} \times \mathcal{Y}) \rightarrow L^2(\mathcal{X})$ 关于 *Situs* 距离 d_{Situs} 是 L_{Situs} -Lipschitz 连续的:

$$\|S(P) - S(Q)\|_{L^2(\mathcal{X})} \leq L_{\text{Situs}} \cdot d_{\text{Situs}}(P, Q), \quad \forall P, Q \in \mathcal{P}(\mathcal{X} \times \mathcal{Y}), \quad (53)$$

其中 $L_{\text{Situs}} > 0$ 为有限常数.

Assumption 5.5 (C4: 混杂有界性). 目标域 $\mathcal{D}_t$ 上的混杂效应有界: $\|\beta \cdot z\|_{L^2(P_{X_t})} \leq B < \infty$, 且混杂引起的 *Cercis Score* 偏差满足 $\|\Delta S_{\text{confound}}\|_{\mathcal{D}_t} \leq \kappa \cdot \delta$, 其中 κ 为依赖问题结构的常数.

Assumption 5.6 (C5: 有限样本收敛). *Situs* 距离的经验估计量 $\hat{d}_{\text{Situs}}$ 满足 $\mathbb{E}[\|\hat{d}_{\text{Situs}} - d_{\text{Situs}}\|] = O(1/\sqrt{n})$ 其中 $n = \min(n_s, n_t)$. 这由 *Wasserstein* 距离的集中不等式保证 (*Weed & Bach, 2019, Theorem 1*).

5.3 完整证明 (链式不等式)

Theorem ?? 的形式化证明. 证明由三个链式步骤组成, 每步量化一项误差源.

Step 1: 源域前门调整——去混杂.

在源域 $\mathcal{D}_s$ 上, 由 C1(前门准则), 可识别 X 对 Y 的因果效应:

$$\hat{P}(Y | do(X = x)) = \sum_{m=1}^M \hat{P}(M = m | X = x) \sum_{x' \in \mathcal{X}_s} \hat{P}(Y | M = m, X = x') \hat{P}(X = x'), \quad (54)$$

其中 $\hat{P}$ 表示经验分布.

定义基于前门调整的”无混杂”*Cercis Score* 为 $S_{\mathcal{D}_s}^*$, 即在调整后的分布下计算的 *Cercis Score*. 源域的 *Cercis* 偏差仅来自残差标签噪声:

$$\|\Delta S\|_{\mathcal{D}_s} \leq \eta_s \cdot \sigma_\varepsilon^2 + O\left(\frac{1}{\sqrt{n_s}}\right), \quad (55)$$

其中 $O(1/\sqrt{n_s})$ 项来自前门调整的估计误差 (由 C5 保证).

Step 2: T7 跨域传输——Lipschitz 界.

由 C2(T7 保真度), 源域与目标域的 *Situs* 距离不超过 ε :

$$d_{\text{Situs}}(\text{Situs}(\mathcal{D}_s), \text{Situs}(\mathcal{D}_t)) \leq \varepsilon. \quad (56)$$

由 C3(*Cercis Score* 的 Lipschitz 连续性):

$$\begin{aligned} \|S_{\mathcal{D}_t} - S_{\mathcal{D}_s}^*\|_{L^2(\mathcal{X})} &\leq L_{\text{Situs}} \cdot d_{\text{Situs}}(\text{Situs}(\mathcal{D}_t), \text{Situs}(\mathcal{D}_s^*)) \quad (\text{由C3}) \\ &\leq L_{\text{Situs}} \cdot [d_{\text{Situs}}(\text{Situs}(\mathcal{D}_t), \text{Situs}(\mathcal{D}_s)) + d_{\text{Situs}}(\text{Situs}(\mathcal{D}_s), \text{Situs}(\mathcal{D}_s^*))] \quad (\text{三角不等式}) \\ &\leq L_{\text{Situs}} \cdot \varepsilon + L_{\text{Situs}} \cdot O\left(\frac{1}{\sqrt{n_s}}\right), \end{aligned} \quad (57)$$

其中 $\mathcal{D}_s^*$ 表示经前门调整后的源域分布. 第二项 $O(1/\sqrt{n_s})$ 来自前门调整分布的 Situs 距离.

Step 3: 目标域混杂扰动界.

目标域的混杂偏差满足 (由 C4):

$$\|\Delta S_{\text{confound}}\|_{\mathcal{D}_t} \leq \kappa \cdot \delta, \quad (58)$$

其中 $\delta = d_{\text{Situs}}(\text{Situs}(\mathcal{D}_s), \text{Situs}(\mathcal{D}_t)) \leq \varepsilon + O(1/\sqrt{n})$ (由 C2 和 C5).

Step 4: 耦合效应.

T7 传输与混杂扰动之间存在耦合效应. 前门调整后残差与混杂项的相关性产生交叉项:

$$\begin{aligned} \|\Delta S_{\text{coupling}}\|_{\mathcal{D}_t} &\leq 2 \cdot \|S_{\mathcal{D}_t} - S_{\mathcal{D}_s}^*\|_{L^2} \cdot \|\Delta S_{\text{confound}}\|_{\mathcal{D}_t} \\ &\leq 2 \cdot (L_{\text{Situs}}\varepsilon) \cdot (\kappa\delta) \quad (\text{由(??)和(??)}) \\ &= C \cdot \varepsilon \cdot \delta, \end{aligned} \quad (59)$$

其中 $C \triangleq 2L_{\text{Situs}}\kappa$.

这一耦合界由 Cauchy-Schwarz 不等式和 Lipschitz 界推导: 设 $a := \|S_{\mathcal{D}_t} - S_{\mathcal{D}_s}^*\|$, $b := \|\Delta S_{\text{confound}}\|$, 则交叉项 $\langle S_{\mathcal{D}_t} - S_{\mathcal{D}_s}^*, \Delta S_{\text{confound}} \rangle \leq a \cdot b \leq L_{\text{Situs}}\varepsilon \cdot \kappa\delta$, 耦合常数为 $C = 2L_{\text{Situs}}\kappa$.

Step 5: 三项求和.

总偏差上界为三项之和:

$$\begin{aligned} \|\Delta S\|_{\mathcal{D}_t} &\leq \|S_{\mathcal{D}_t} - S_{\mathcal{D}_s}^*\| + \|\Delta S_{\text{confound}}\| + \|\Delta S_{\text{coupling}}\| \\ &\leq (L_{\text{Situs}}\varepsilon + O(n_s^{-1/2})) + (\kappa\delta) + (C \cdot \varepsilon \cdot \delta) \\ &\leq L_{\text{Situs}} \cdot \varepsilon + \kappa \cdot \delta + C \cdot \varepsilon \cdot \delta + O\left(\frac{1}{\sqrt{n}}\right), \end{aligned} \quad (60)$$

其中 $O(1/\sqrt{n})$ 项合并了 n_s 和 n_t 的有限样本误差, 在 $n = \min(n_s, n_t)$ 下为 $O(1/\sqrt{n})$. $\square$

5.4 各项误差来源的显式量化

为便于实践应用, 我们将 $g(\varepsilon, \delta)$ 中各项的依赖关系显式化:

- **Lipschitz** 传输项 $L_{\text{Situs}} \cdot \varepsilon$: 来自 Cercis 算子关于 Situs 距离的敏感性. 若 L_{Situs} 未知, 可由 $L_{\text{Situs}} \leq \sup_{x \in \mathcal{X}} \|\nabla S(x)\|_g$ 估计.
- 混杂扰动项 $\kappa \cdot \delta$: 来自目标域的混杂信号. 常数 κ 满足:

$$\kappa \leq \|\beta\| \cdot \sup_{x \in \mathcal{X}} \|\nabla_z S(x)\| \cdot \text{Lip}\left(\frac{\partial z}{\partial x}\right), \quad (61)$$

其中 $\text{Lip}(\cdot)$ 为 Lipschitz 常数.

- 耦合项 $C \cdot \varepsilon \cdot \delta$: 来自传输误差与混杂误差的交互. 当 $\varepsilon \ll 1$ 或 $\delta \ll 1$ 时该项可忽略. 这表明: 若源域与目标域足够相似, 或混杂效应足够小, 两者的耦合效应可安全忽略.

5.5 严格性标注

[Rigorous] 本定理在 Assumptions C1–C5 下严格成立, 是 SCX 框架内 T7 定理和 Situs 距离三角不等式的直接推论. 无需 Situs 骨架保持假设.

5.6 诚实暴击

诚实暴击 —

(C1) 前门准则的可满足性.

实际审计数据中, 找到一个满足前门准则的中介变量 M 极具挑战性. $FD1$ – $FD3$ 三个条件中, $FD2$ (从 X 到 M 无后门路径) 和 $FD3$ (从 M 到 Y 的后门路径被 X 阻断) 是不可检验的 (因为涉及未观测变量). 因此 $C1$ 本质上是一个不可检验的假设.

(C2) **T7** 保真度参数 ε 的不可观测性.

ε 被定义为 $d_{\text{Situs}}(\text{Situs}(\mathcal{D}_s), \text{Situs}(\mathcal{D}_t))$. 这一距离在有限样本下可估计, 但估计量 $\hat{\varepsilon}$ 有 $O(1/\sqrt{n})$ 的误差. 当 ε 为小量时, 相对误差可能极大:

$$\frac{\hat{\varepsilon} - \varepsilon}{\varepsilon} = O\left(\frac{1}{\varepsilon\sqrt{n}}\right). \quad (62)$$

(C3) **Lipschitz** 常数 L_{Situs} 的估计.

Cercis 算子关于 *Situs* 距离的 *Lipschitz* 常数 L_{Situs} 非平凡. 其存在性由 *Situs* 编码的正则性保证 (SCX 框架的核心假设), 但其数值难以从数据中一致估计. 过估计 L_{Situs} 导致宽松的界 (保守但无用), 欠估计导致无效的界 (危险).

(C4) 上界的紧性.

定理声称的是上界, 而非紧界. 不等式(??)中的三个项可能并非独立可加, 实际的混杂偏差可能远小于上界. 需要进一步研究:

$$\text{是否存在分布使得(??)的等号可达?} \quad (63)$$

若不等号严格, 则定理提供的保证是”最坏情况”的, 可能过于保守.

(C5) 统计误差 $O(1/\sqrt{n})$ 的隐藏常数.

$O(1/\sqrt{n})$ 项隐藏了依赖于维数 d 的常数因子. 具体而言:

$$\text{常数} \propto \sqrt{\frac{\log(1/\delta)}{n}} \times \text{poly}(d), \quad (64)$$

其中 $\text{poly}(d)$ 在高维 ($d > 10$) 下可能使界在实际中无意义. 维数依赖需要在使用该定理前仔细评估.

6 讨论: 可区分性前沿的结构

6.1 三个定理的逻辑关系

三个定理共同描绘了 η - z 依赖结构空间中的可区分性前沿:

条件	可区分性	状态
$\mathbb{I}(\eta; z) = 0$	绝对不可区分	[Rigorous] (Theorem ??)
$\mathbb{I}(\eta; z) > 0$ + Situs 骨架保持	弱可分	[Conditionally Rigorous] / [Open] (Theorem ??)
前门准则 + T7 保真度	有界偏差	[Rigorous] (Theorem ??)

6.2 开放问题与未来方向

- 无条件弱可分 (Open Problem ??): 是否可在不假设 Situs 骨架保持的条件下构造统计量? 此问题的解决是 SCX 因果发现框架下一里程碑.
- 离散数据的微分几何: 旋度统计量 τ 需要 Situs 流形上的微分结构. 离散数据上的微分几何算子 (离散外微分、离散 Hodge 星) 的理论与计算仍需建立.
- 有限样本的精确分布: Lemma ??给出了 τ 的渐近分布, 但有限样本下 τ 分布的精确表述 (或 Edgeworth 展开) 将极大提升实际可用性.
- **KLIEP**(核均值匹配) 视角: Theorem CD.3 的上界能否通过重要性权重进一步收紧? 即利用 d_{Situs} 的 Wasserstein 对偶性构造更紧的 Cramér-Rao 型下界.

7 结论

本文件将 SCX 框架的 Theorem 3 扩展至因果发现设定, 给出三个定理的严格形式化版本. 强不可分定理 ($\eta \perp z$) 在 Assumptions A1–A5 下严格证明, 是 Theorem 3 的直接推论. 弱可分定理提供了一条构造性路径——条件依赖于 Situs 骨架保持假设, 无条件形式是开放问题. 因果中继定理在前门准则和 T7 保真度下给出了混杂偏差的显式可计算上界.

诚实暴击分析揭示了核心假设 (Situs 骨架保持、前门准则可满足性、离散微分几何操作性) 中尚未解决的问题. 这些问题的解决是 SCX 因果发现框架成熟的必要条件.

References

- [1] SCX Working Group. “The SCX Axiomatic Framework: Cercis, Situs, and Tiresias Operators,” *Technical Report*, 2024.
- [2] J. Pearl. *Causality: Models, Reasoning, and Inference*, 2nd ed. Cambridge University Press, 2009.
- [3] P. Spirtes, C. Glymour, and R. Scheines. *Causation, Prediction, and Search*, 2nd ed. MIT Press, 2000.
- [4] J. Peters, D. Janzing, and B. Schölkopf. *Elements of Causal Inference: Foundations and Learning Algorithms*. MIT Press, 2017.
- [5] M. A. Hernán and J. M. Robins. *Causal Inference: What If*. Chapman & Hall/CRC, 2020.
- [6] Y. Wu, K. Zhang, and B. Schölkopf. “Hessian-based Causal Structure Learning from Observational Data,” in *NeurIPS*, 2024.
- [7] S. Shimizu, P. O. Hoyer, A. Hyvärinen, and A. Kerminen. “A linear non-Gaussian acyclic model for causal discovery,” *Journal of Machine Learning Research*, 7:2003–2030, 2006.
- [8] K. Zhang, B. Schölkopf, P. Spirtes, and C. Glymour. “Learning causality and causality-related learning,” *National Science Review*, 5(1):26–29, 2018.

- [9] M. Arjovsky, L. Bottou, I. Gulrajani, and D. Lopez-Paz. “Invariant risk minimization,” *arXiv:1907.02893*, 2019.
- [10] M. Domínguez-Olmedo, A. Karimi, and B. Schölkopf. “Causal discovery from observational data: A survey,” *arXiv:2003.03377*, 2020.
- [11] T. M. Cover and J. A. Thomas. *Elements of Information Theory*, 2nd ed. Wiley, 2006.
- [12] C. Villani. *Optimal Transport: Old and New*. Springer, 2008.
- [13] J. Weed and F. Bach. “Sharp asymptotic and finite-sample rates of convergence of empirical measures in Wasserstein distance,” *Bernoulli*, 25(4A):2620–2648, 2019.
- [14] R. J. Serfling. *Approximation Theorems of Mathematical Statistics*. Wiley, 1980.
- [15] L. Ambrosio, N. Gigli, and G. Savaré. *Gradient Flows in Metric Spaces and in the Space of Probability Measures*. Birkhäuser, 2005.