

A2 的严格数学分析

触发: hostile review 指出 $\exp(-2M\Delta^2/(1 + (M-1)\rho))$ 不是严格定理结论: 正确。方差膨胀代入 Hoeffding 是指启发式, 不是严格界。但 A2 本身有更强的论证。

1. $\exp(-2Mt^2/(1 + (M-1)\rho))$ 是不是严格定理?

不是。

Hoeffding 不等式的证明依赖:

$$\mathbb{E} \left[\exp \left(\lambda \sum_{i=1}^M (X_i - \mu_i) \right) \right] = \prod_{i=1}^M \mathbb{E} [\exp(\lambda(X_i - \mu_i))]$$

这个因式分解要求 $\{X_i\}$ 独立。如果 X_i 相关, MGF 不能因式分解, 你不能简单地把 M 替换成 $M/(1 + (M-1)\rho)$ 就得到严格指数界。

方差膨胀 $(1 + (M-1)\rho)$ 对 $\text{Var}(\sum X_i)$ 是正确的, 但对 **指数集中** 不正确。方差只给 Chebyshev 界 (多项式速率 $1/t^2$), 不是指数界。

结论: 方差膨胀 Hoeffding 是启发式 (heuristic), 在调查抽样和群组随机试验中广泛使用, 但不是数学定理。把它写进 SI 会被审稿人抓。

2. 那 A2 本身到底站不站得住？

2.1 更强的论证: A1 蕴含 A2

A1 说: M 个专家在不相交的独立同分布子集上训练。

$$D_1, \dots, D_M \sim_{\text{i.i.d.}} P^n \quad \text{且} \quad D_i \cap D_j = \emptyset$$

每个 $f_m = \mathcal{A}(D_m)$ 是训练算法 $\mathcal{A}$ 作用于数据子集 D_m 的确定函数。

因为 $D_1, \dots, D_M$ 是独立随机变量, $f_1, \dots, f_M$ 也是独立的随机函数。

对任意固定的测试点 x :

$$e_m(x, y) = \mathbf{1}\{\ell(f_m(x), y) > \tau\}$$

因为 f_m 只依赖 D_m , 且 $D_1 \perp D_2 \perp \dots \perp D_M$:

$$e_1 \perp e_2 \perp \dots \perp e_M \quad | \quad x$$

A2 不是假设——它是 A1 的推论。

2.2 概率空间是什么？

Hoeffding 界的概率空间是训练数据的随机性, 不是测试数据的随机性。

$$\mathbb{P}_{D_1, \dots, D_M}(C(x) > \theta \mid \text{clean}, x) \leq \exp(-2M(\theta - \mu_s)^2)$$

意思是: 如果你随机划分训练数据 M 次、独立训练 M 个专家, 得到的专家集以高概率具有好的噪声检测性质。

训练完成后，你有一组固定的专家。对于给定的测试样本 x ， $C(x)$ 是一个确定性的数。Hoeffding 不适用。

但这不削弱定理——所有的泛化界都有这个性质。定理告诉你”这个方法好的”，不是”这组特定专家是好的”。

2.3 Hostile reviewer 的反驳为什么不对

“所有 CNN 在模糊图像上都一起错”

这是在说：给定已经训练好的 CNN，它们在模糊图像上的确定行为是一致的。

但 Hoeffding 问的是：在训练之前，随机划分数据并独立训练后，你有多大把握得到一组能检测噪声的专家？

两者不在同一个概率空间里。Hostile reviewer 混淆了训练后确定性行为和训练前概率保证。

2.4 但仍有一个残留问题

即使 A2 严格成立（作为 A1 的推论），估计 μ_s 仍然需要清洁标签。在有限样本下， $\hat{\mu}_s$ 的误差会转化为 $\hat{\Delta}_s$ 的误差。这是有限样本估计问题，不是独立性假设问题。推论 4（有限样本校正）已经用保守上界处理了这个问题。

3. 诚实的修改建议

3.1 不要引入 A2'

方差膨胀 Hoeffding 是启发式，不够格写进定理陈述。保持原有的 A2，但在正文和 SI 中诚实讨论。

3.2 在 SI 中加一节 “On the Role of Assumption A2”

内容: 1. A2 实际上是 A1 的推论 (不相交训练集 $\rightarrow$ 独立专家 $\rightarrow$ 独立错误) 2. 概率空间是训练随机性，不是测试行为 3. 有限样本下 μ_s 的估计误差有独立处理 (推论 4) 4. 在实践中，专家错误可能表现出表面相关 (同一张模糊图)，但这反映的是特征相似性导致相似的 μ_s ，而非统计相关性 5. 对 A2 的经验诊断: 在验证集上估计专家错误的条件相关系数; 如果显著偏离零，检查训练集是否真的不相交

3.3 在正文中诚实措辞

把 “conditional independence” 改为: > “conditional independence of expert errors, which follows from training on disjoint data subsets (Assumption A1)”

这样把 A2 从”假设”降级为”A1 的逻辑结果”，同时指出它依赖于 A1 的正确执行。

4. 最终判断

问题	状态
A2 是否站得住？	是 — A1 蕴含 A2（训练集不相交 $\rightarrow$ 专家独立）
在实践中是否违反？	取决于 A1 的执行 — 如果训练集真的不相交，A2 成立
$\exp(-2M\Delta^2/(1+(M-1)\rho))$ 是否严格？	否 — 这是启发式，不应写进定理
应该如何修改？	澄清 A2 是 A1 的推论；在 SI 中加入诚实讨论；不要引入虚假的 A2'
对论文的影响程度	低 — 不需要改定理陈述，只需要加一段诚实讨论

5. 对 hostile review 其他批评的回应

“CIFAR F1=0.617, 理论下界 F1 0.976”

这已经在 §4.3（紧致性讨论）中诚实处理了： μ_s 在 CIFAR 实验中约为 0.45（3-epoch CPU 训练后），而非假定的 0.20。代入正确的 μ_s 后下界为 F1 0.18，与经验值 0.617 一致。

“ μ_s 需要清洁标签 $\rightarrow$ 鸡生蛋”

冷启动协议需要少量锚点样本（推论 1），这是理论上的必要成本（Thm 3 证明了没有锚点时不可识别）。这不是循环定义——是对不可识别性定理的工程回应。

“Bootstrap 诊断的 $\tau=0.7$ 是拍脑袋”

承认。 $\tau = 0.7$ 是初始校准值，应在具体领域中根据已知噪声标签校准。SI 中应明确标注为” 建议初始值，需领域校准”。

关联: $[[01_noise_detection_guarantee]]$ • $[[03_unidentifiability]]$ •
 $[[a2_correlation_analysis]]$