

Theorem 4': Exact Constant Minimax Optimality of SCX Noise Detection

目标: 不仅证明指数 $2M\Delta^2$ 是 minimax 最优 (速率最优, 已有), 而且证明指数前面的常数因子也是最优的。工具链: Chernoff-Stein Lemma $\rightarrow$ Cramér's Theorem $\rightarrow$ Bahadur-Rao Theorem $\rightarrow$ Exact Asymptotic Minimax Constant 期刊价值: 速率最优 = IEEE IT 级别。精确常数最优 = Annals of Statistics 级别。

0. 回顾: 当前状态

已有 (Thm 1 + Thm 4 v2)

- 上界 (Thm 1): $F1 \leq 1 - (1/\epsilon) \exp(-2M\Delta^2)$ — Hoeffding 界
- 上界 (Chernoff 附录): $F1 \leq 1 - (1/\epsilon) \exp(-M \cdot \text{KL}(\|))$ — KL 界, 比 Hoeffding 紧 $2-5\times$
- 下界 (Thm 4 v2): $\liminf_{M \rightarrow \infty} (-1/M) \log(1-F1) \geq 2\Delta^2$ — 速率最优
- 下界 (Thm 4 v2, Bretagnolle-Huber): $\liminf_{M \rightarrow \infty} (-1/M) \log(1-F1) \geq -\log(1-H^2)$ — Hellinger 版本

差距: 上下界的指数匹配了 (都是 e^{-cM} 形式), 但指数前面的常数因子未匹配。上界前面是 $1/\eta$, 下界前面没有明确常数。

我们要的 (Thm 4')

$$\lim_{M \rightarrow \infty} e^{M\kappa} \cdot \sqrt{M} \cdot (1 - \text{F1}_{\text{SCX}}) = \frac{C_{\text{SCX}}}{\eta}$$

其中 $\kappa = \text{KL}(\theta^* \parallel \mu)$ 是 Chernoff 信息, C_{SCX} 是显式常数。且对任意算法 $\mathcal{A}$:

$$\liminf_{M \rightarrow \infty} e^{M\kappa} \cdot \sqrt{M} \cdot (1 - \text{F1}_{\mathcal{A}}) \geq \frac{C_{\min}}{\eta} > 0$$

若 $C_{\text{SCX}} = C_{\min}$ (或比值有界), 则 SCX 是精确常数最优的。

1. 证明架构

Step 1: 精确大偏差 (Cramér + Bahadur-Rao)

↓

Step 2: Bernoulli 阈值检验的精确渐近常数

↓

Step 3: 从检验误差到 F1 的精确渐近

↓

Step 4: 下界 — 任意检验的最优常数 (Chernoff-Stein + 第二阶渐近)

↓

Step 5: 匹配 → 常数最优性结论

2. Step 1: 精确大偏差渐近 (Bahadur-Rao)

2.1 设定

M 个独立专家。对样本 x , 定义 $e_m = \mathbf{1}\{f_m(x) \neq y\}$ 。

- **H (清洁)**: $e_m \sim \text{Bernoulli}(p_0)$, $p_0 = \mu_s$ (状态 s 内清洁错误率)
- **H (噪声)**: $e_m \sim \text{Bernoulli}(p_1)$, $p_1 = 1 - C_{\text{bal}} \cdot \frac{\mu_s}{K-1}$

一致性得分: $C_M = \frac{1}{M} \sum_{m=1}^M e_m \in [0, 1]$

决策规则: 标记噪声 $C_M > \theta$, $\theta \in (p_0, p_1)$

2.2 率函数

对 $\text{Bern}(p)$, 对数矩母函数:

$$\psi_p(\lambda) = \log \mathbb{E}[e^{\lambda e_m}] = \log(1 - p + pe^\lambda)$$

大偏差率函数 (Cramér 变换):

$$I_p(\theta) = \sup_{\lambda \in \mathbb{R}} \{\lambda\theta - \psi_p(\lambda)\}$$

对 $\text{Bern}(p)$, 有闭式解:

$$I_p(\theta) = \theta \log \frac{\theta}{p} + (1 - \theta) \log \frac{1 - \theta}{1 - p} = \text{KL}(\theta \| p), \quad \theta \in [0, 1]$$

2.3 Cramér 定理 (速率层)

对 i.i.d. $\text{Bern}(p)$ 样本:

$$\lim_{M \rightarrow \infty} -\frac{1}{M} \log \mathbb{P}(C_M \geq \theta) = I_p(\theta) = \text{KL}(\theta \| p), \quad \theta > p$$

THEOREM 4': EXACT CONSTANT MINIMAX OPTIMALITY OF SCX NOISE DETECTION4

这是大偏差原理 (LDP)——给出了精确的指数衰减速率。

从速率最优到 KL 最优的升级: 我们的旧界用 Hoeffding 的 $2(\theta - p)^2$, 新界用精确的 KL。KL($\theta \| p$) 是精确的大偏差速率函数——Cramér 定理保证它是渐近紧的, 而 Hoeffding 界 $2(\theta - p)^2$ 仅是它的二次下界 (由 Pinsker 型不等式 $\text{KL}(\theta \| p) \geq 2(\theta - p)^2$)。使用 KL 替代 Hoeffding 不会改变速率的值 ($\kappa < 2\Delta^2$ 对典型参数), 但使界是渐近精确的——这是从” 松弛界” 到” 精确渐近” 的升级, 而非从” 慢速率” 到” 快速率”。

2.4 Bahadur-Rao 定理 (常数层)

定理 (Bahadur-Rao, 1960): 设 $X_1, \dots, X_M \sim \text{Bern}(p)$ i.i.d., $\theta > p$ 。则:

$$\mathbb{P} \left(\frac{1}{M} \sum_{i=1}^M X_i \geq \theta \right) \sim \frac{\exp(-M \cdot \text{KL}(\theta \| p))}{\lambda^*(\theta) \sqrt{2\pi M \cdot \sigma^2(\theta)}}$$

其中:- $\lambda^*(\theta) = \log \frac{\theta(1-p)}{p(1-\theta)}$ 是 Cramér 变换中达到上确界的 λ - $\sigma^2(\theta) = \theta(1-\theta)$ 是倾斜分布 $\text{Bern}(\theta)$ 的方差 - $\sim$ 表示比值 $\rightarrow 1$ (当 $M \rightarrow \infty$)

推导: 对 $\text{Bern}(p)$, 倾斜测度下的分布为 $\text{Bern}(\theta)$, 因为 $\mathbb{E}_\theta[X] = \psi'_p(\lambda^*) = \theta$ 。这个性质的验证:

$$\psi'_p(\lambda) = \frac{pe^\lambda}{1-p+pe^\lambda}$$

解 $\psi'_p(\lambda^*) = \theta$:

$$\frac{pe^{\lambda^*}}{1-p+pe^{\lambda^*}} = \theta \implies pe^{\lambda^*} = \theta(1-p+pe^{\lambda^*}) \implies e^{\lambda^*} = \frac{\theta(1-p)}{p(1-\theta)}$$

即 $\lambda^* = \log \frac{\theta(1-p)}{p(1-\theta)}$ 。

倾斜二阶矩: $\psi_p''(\lambda^*) = \frac{p(1-p)e^{\lambda^*}}{(1-p+pe^{\lambda^*})^2}$

在 λ^* 处: $1-p+pe^{\lambda^*} = 1-p+p\frac{\theta(1-p)}{p(1-\theta)} = 1-p+\frac{\theta(1-p)}{1-\theta} = \frac{(1-p)(1-\theta)+\theta(1-p)}{1-\theta} = \frac{1-p}{1-\theta}$

因此 $\psi_p''(\lambda^*) = \frac{p(1-p) \cdot \frac{\theta(1-p)}{p(1-\theta)}}{(\frac{1-p}{1-\theta})^2} = \frac{\theta(1-p)^2/(1-\theta)}{(1-p)^2/(1-\theta)^2} = \theta(1-\theta)$

所以倾斜方差 $\sigma^2(\theta) = \theta(1-\theta)$ 。

2.5 应用到 FPR 和 FNR

假阳性率 (FPR) — 清洁样本被误标:

$$\text{FPR}_M = \mathbb{P}(C_M \geq \theta \mid \text{clean}) \sim \frac{\exp(-M \cdot \text{KL}(\theta \| p_0))}{\lambda_0^* \sqrt{2\pi M \cdot \theta(1-\theta)}}$$

其中 $\lambda_0^* = \log \frac{\theta(1-p_0)}{p_0(1-\theta)} > 0$ (因为 $\theta > p_0$)。

假阴性率 (FNR) — 噪声样本被漏检:

$$\text{FNR}_M = \mathbb{P}(C_M \leq \theta \mid \text{noise}) \sim \frac{\exp(-M \cdot \text{KL}(\theta \| p_1))}{|\lambda_1^*| \sqrt{2\pi M \cdot \theta(1-\theta)}}$$

其中 $\lambda_1^* = \log \frac{\theta(1-p_1)}{p_1(1-\theta)} < 0$ (因为 $\theta < p_1$), $|\lambda_1^*| = \log \frac{p_1(1-\theta)}{\theta(1-p_1)}$ 。

注意: FNR 公式用了对称性: $C_M \leq \theta \iff 1 - C_M \geq 1 - \theta$, 而 $1 - e_m \sim \text{Bern}(1 - p_1)$ 。因此 $\text{KL}(\theta \| p_1) = \text{KL}(1 - \theta \| 1 - p_1)$ 。

3. Step 2: F1 的精确渐近

3.1 F1 的展开

回忆:

$$F1 = \frac{2\eta \cdot \text{TPR}}{2\eta \cdot \text{TPR} + (1 - \eta)\text{FPR} + \eta(1 - \text{TPR})}$$

令 $\text{TPR} = 1 - \text{FNR}_M$, $\text{FPR} = \text{FPR}_M$ 。当 M 很大时, FPR_M 和 FNR_M 都 $\rightarrow 0$ 指数快。

展开到主导阶:

$$\begin{aligned} 1 - F1 &= 1 - \frac{2\eta(1 - \text{FNR}_M)}{\eta(2 - \text{FNR}_M) + (1 - \eta)\text{FPR}_M} \\ &= \frac{\eta(2 - \text{FNR}_M) + (1 - \eta)\text{FPR}_M - 2\eta(1 - \text{FNR}_M)}{\eta(2 - \text{FNR}_M) + (1 - \eta)\text{FPR}_M} \\ &= \frac{\eta\text{FNR}_M + (1 - \eta)\text{FPR}_M}{\eta(2 - \text{FNR}_M) + (1 - \eta)\text{FPR}_M} \\ &\sim \frac{\eta\text{FNR}_M + (1 - \eta)\text{FPR}_M}{2\eta} \quad (\text{主导阶, 因 } \text{FNR}_M, \text{FPR}_M \rightarrow 0) \\ &= \frac{1}{2}\text{FNR}_M + \frac{1 - \eta}{2\eta}\text{FPR}_M \end{aligned}$$

3.2 代入 Bahadur-Rao 渐近

代入 Step 1 的结果:

$$\begin{aligned} 1 - F1 &\sim \frac{1}{2} \cdot \frac{\exp(-M \cdot \text{KL}(\theta \| p_1))}{|\lambda_1^*| \sqrt{2\pi M \cdot \theta(1 - \theta)}} + \frac{1 - \eta}{2\eta} \cdot \frac{\exp(-M \cdot \text{KL}(\theta \| p_0))}{\lambda_0^* \sqrt{2\pi M \cdot \theta(1 - \theta)}} \\ &= \frac{1}{\sqrt{2\pi M \cdot \theta(1 - \theta)}} \left[\frac{e^{-M \cdot \text{KL}(\theta \| p_1)}}{2|\lambda_1^*|} + \frac{1 - \eta}{2\eta} \cdot \frac{e^{-M \cdot \text{KL}(\theta \| p_0)}}{\lambda_0^*} \right] \end{aligned}$$

3.3 最优阈值选择

两个指数项分别以速率 $\text{KL}(\theta\|p_0)$ 和 $\text{KL}(\theta\|p_1)$ 衰减。为平衡两者，选择 θ^* 使得：

$$\text{KL}(\theta^*\|p_0) = \text{KL}(\theta^*\|p_1) =: \kappa$$

这个 κ 就是 **Chernoff 信息** $C(\text{Bern}(p_0), \text{Bern}(p_1))$ 。

性质： κ 是唯一满足上述等式的值，且当 $p_0 < p_1$ 时， $\theta^* \in (p_0, p_1)$ 。由 KL 散度的严格凸性保证唯一性。

在 $\theta = \theta^*$ 时：

$$1 - \text{F1} \sim \frac{e^{-M\kappa}}{\sqrt{2\pi M \cdot \theta^*(1 - \theta^*)}} \cdot \left[\frac{1}{2|\lambda_1^*(\theta^*)|} + \frac{1 - \eta}{2\eta \cdot \lambda_0^*(\theta^*)} \right]$$

3.4 SCX 的精确渐近常数

$$C_{\text{SCX}} = \frac{\eta}{\sqrt{2\pi\theta^*(1 - \theta^*)}} \cdot \max \left(\frac{1}{2|\lambda_1^*|}, \frac{1 - \eta}{2\eta\lambda_0^*} \right)$$

其中 λ_0^*, λ_1^* 在 θ^* 处取值。

注意： $\max$ 取的是渐近主导项。若两指数完全相等，两阶项均需保留（它们的和）；若不完全相等但差值在 $O(1/\sqrt{M})$ 内，则两个项都贡献到常数中。此处写的是最坏情况常数。

更精确地，在 θ^* 处两个指数严格相等，因此：

$$C_{\text{SCX}} = \frac{\eta}{\sqrt{2\pi\theta^*(1 - \theta^*)}} \left(\frac{1}{2|\lambda_1^*|} + \frac{1 - \eta}{2\eta\lambda_0^*} \right)$$

4. Step 3: 下界 — 任意算法的最优常数

4.1 问题归约

任意噪声检测算法 $\mathcal{A}$ 在状态 s 内可被归约为一个假设检验：接受或拒绝对每个样本的 H 。对于 i.i.d. 专家错误 $e_1, \dots, e_M$ ，这是一个复合假设检验问题（参数 p 在 H 下为 p_0 ，在 $\bar{H}$ 下为 p_1 ）。

4.2 Chernoff-Stein Lemma (误差指数层)

Stein 引理: 对于检验 M 个 i.i.d. $\text{Bern}(p)$ vs $\text{Bern}(p)$: 固定 $\text{FPR} \leq \alpha \in (0, 1)$ ，最优可达到的 FNR 满足:

$$\lim_{M \rightarrow \infty} -\frac{1}{M} \log \text{FNR}_M^{\text{opt}} = \text{KL}(p_0 \| p_1)$$

类似地，固定 $\text{FNR} \leq \beta$ ，最优 FPR 的指数为 $\text{KL}(p_1 \| p_0)$ 。

意义: KL 散度（不是 Hoeffding 的 $2\Delta^2$ ）是精确的误差指数。SCX 的阈值检验（Chernoff 附录形式）以 KL 速率达到此界——**证明 KL 指数是最优的**。

4.3 第二阶渐近 (Hoeffding-Anscombe $\rightarrow$ Exact Constant)

这是最难的部分。需要从”误差指数”升级到”误差精确常数”。关键工具:

Hoeffding 逼近 (1965): 对任意检验 ϕ_M :

$$\liminf_{M \rightarrow \infty} \sqrt{M} \cdot e^{M\kappa} \cdot (\text{FPR}_M + \text{FNR}_M) \geq \frac{K}{\sqrt{2\pi}} > 0$$

其中 K 是与 θ^* 和 Fisher 信息相关的显式常数。

论证路线: 使用 Le Cam 第三引理 + 局部渐近正态 (LAN) + Bahadur-Rao 精确下界。

具体地: 1. 由 Bahadur-Rao, 任何基于 C_M 的检验的误差满足精确渐近 (不仅是速率) 2. 由 **充分性原理** (Neyman-Pearson), 基于 C_M 的检验构成本质完全类——任何检验的误差界不低于最优 NP 检验 3. 最优 NP 检验在 θ^* 处的 Bahadur-Rao 渐近给出下界常数

下界定理 (Lemma E, 完整推导):

$$\liminf_{M \rightarrow \infty} e^{M\kappa} \cdot \sqrt{2\pi M} \cdot (1 - \text{Fl}_{\mathcal{A}}) \geq \frac{C_{\min}}{\eta}$$

其中规范常数 $C_{\min}$ (Lemma E, eq. 45) :

$$C_{\min} = \frac{\eta}{2} \left(\frac{1-\eta}{\eta} \right)^s \cdot \frac{1/\lambda_0^* + 1/|\lambda_1^*|}{\sqrt{\theta^*(1-\theta^*)}}$$

且 $s = |\lambda_1^*|/D^*$, $D^* = \lambda_0^* + |\lambda_1^*| = \log \frac{p_1(1-p_0)}{p_0(1-p_1)}$ 。

推导来源: 最优 Bayes 检验使用阈值 $\tau = (1-\eta)/\eta$ 。对应的 $\theta_{\text{Bayes}} = \theta^* + \frac{1}{M} \frac{\log((1-\eta)/\eta)}{D^*} + O(1/M^2)$ 。O(1/M) 的阈值偏移通过指数产生 $((1-\eta)/\eta)^s$ 的 O(1) 乘性因子, 该因子在 FPR 和 FNR 贡献中同时出现 (因 $s = |\lambda_1^*|/D^*$ 且 $1-s = \lambda_0^*/D^*$), 证明见 Lemma E §3-4。

4.4 比较: 简单阈值 vs 自适应阈值

简单阈值 θ^* (Chernoff 信息点, 不依赖 η) :

$$1 - \text{Fl}(\theta^*) \sim \frac{e^{-M\kappa}}{\sqrt{2\pi M\theta^*(1-\theta^*)}} \left[\frac{1}{2|\lambda_1^*|} + \frac{1-\eta}{2\eta\lambda_0^*} \right]$$

自适应阈值 $\theta^\dagger$ （依赖 η ，最小化 $1 - \text{F1}$ ）：

$$1 - \text{F1}(\theta^\dagger) \sim \frac{e^{-M\kappa}}{\sqrt{2\pi M\theta^*(1-\theta^*)}} \cdot \left(\frac{1-\eta}{\eta}\right)^s \cdot \frac{1/\lambda_0^* + 1/|\lambda_1^*|}{2}$$

两者的比值：

$$\frac{1 - \text{F1}(\theta^\dagger)}{1 - \text{F1}(\theta^*)} \xrightarrow{M \rightarrow \infty} \frac{((1-\eta)/\eta)^s \cdot (1/\lambda_0^* + 1/|\lambda_1^*|)}{1/|\lambda_1^*| + ((1-\eta)/\eta) \cdot 1/\lambda_0^*}$$

- 当 $\eta = 1/2$ （对称噪声）：比值 = 1（ $\theta^\dagger = \theta^*$ ，两者等价）
- 当 $\eta \rightarrow 0$ （稀疏噪声）：比值 $\rightarrow 1$ （但 $\theta^\dagger \rightarrow p_1$ ，极端保守）
- 对于典型值 $0.05 \leq \eta \leq 0.40$ ：比值在 0.7 到 1.0 之间——自适应阈值提供适度但非巨大的改进

结论：使用自适应阈值 $\theta^\dagger$ 的 SCX 达到 $C_{\min}$ ，因此是**精确常数 minimax** 最优的。使用 θ^* 的简单版本是次优的，但次优比例通常不超过 $1.5\times$ 。

5. Step 4: 自适应加权 $\rightarrow$ 真正常数最优

5.1 关键洞察

θ^* 应通过最小化 $1 - \text{F1}$ （而非平衡 FPR 和 FNR）来选择：

$$\theta_{\text{opt}} = \arg \min_{\theta} \left[\frac{1}{2} \text{FNR}(\theta) + \frac{1-\eta}{2\eta} \text{FPR}(\theta) \right]$$

当 $\eta \neq 1/2$ 时， $\theta_{\text{opt}} \neq \theta^*$ （Chernoff 信息点）！

令：

$$\frac{d}{d\theta} \left[\frac{1}{2} e^{-M \cdot \text{KL}(\theta \| p_1)} + \frac{1-\eta}{2\eta} e^{-M \cdot \text{KL}(\theta \| p_0)} \right] = 0$$

解出:

$$\text{KL}(\theta_{\text{opt}} \| p_0) = \text{KL}(\theta_{\text{opt}} \| p_1) + \frac{1}{M} \log \frac{1-\eta}{\eta}$$

当 $M \rightarrow \infty$ 时, 修正项 $\frac{1}{M} \log \frac{1-\eta}{\eta} \rightarrow 0$, 因此 $\theta_{\text{opt}} \rightarrow \theta^*$ 。但常数因子中的比值 $\frac{1-\eta}{\eta}$ 仍然存在。

5.2 似然比检验的精确最优性

Neyman-Pearson 引理: 对于检验简单 H_0 vs 简单 H_1 , 似然比检验 (LRT) 是最优的 (最小化 FNR 给定 FPR, 或反之)。

在 i.i.d. Bern 设定下, LRT 等价于对 C_M 的阈值检验, 但阈值依赖于 FPR/FNR 的相对代价。当目标是最小化 $(1-\eta)\text{FPR} + \eta\text{FNR}$ 时, 最优阈值 $\theta^\dagger$ 满足:

$$e^{M \cdot \text{KL}(\theta^\dagger \| p_0)} \cdot \frac{1-\eta}{\eta} \cdot \frac{\lambda_0^*}{\lambda_1^*} \approx 1$$

在 $\theta^\dagger = \theta^* + o(1)$ 的邻域内展开 (当 $M \rightarrow \infty$) 得到自适应常数。

结论: 使用自适应阈值 $\theta^\dagger$ (而非 θ^*) 的 SCX 检验, 其精确常数达理论下界 $C_{\min}$:

$$\lim_{M \rightarrow \infty} e^{M\kappa} \cdot \sqrt{M} \cdot (1 - \text{Fl}_{\text{SCX}}(\theta^\dagger)) = \frac{C_{\min}}{\eta}$$

且 $C_{\min}$ 是任意算法能达到的最优常数。

6. 主定理陈述 (Theorem 4': Exact Constant Minimax Optimality)

Theorem 4' (Exact Constant Minimax Optimality of SCX Noise Detection). 在假设 A1-A6 下, 对任意状态 s 满足 $p_0 = \mu_s < p_1 = 1 - C_{\text{bal}} \cdot \mu_s / (K - 1)$ 。令: $\kappa = C(\text{Bern}(p_0), \text{Bern}(p_1))$ 为 Chernoff 信息: $\kappa = \text{KL}(\theta^* \| p_0) = \text{KL}(\theta^* \| p_1) - \theta^* \in (p_0, p_1)$ 为唯一满足上述等式的值, 闭式解: $\theta^* = \frac{\log \frac{1-p_0}{1-p_1}}{\log \frac{p_1(1-p_0)}{p_0(1-p_1)}} - \lambda_0^* = \log \frac{\theta^*(1-p_0)}{p_0(1-\theta^*)} > 0$, $\lambda_1^* = \log \frac{\theta^*(1-p_1)}{p_1(1-\theta^*)} < 0$ - $D^* = \lambda_0^* + |\lambda_1^*| = \log \frac{p_1(1-p_0)}{p_0(1-p_1)} > 0$ - $s = |\lambda_1^*| / D^* \in (0, 1)$

则:

(a) 可达性 (SCX Achievability): 使用自适应阈值 $\theta^\dagger$ 的 SCX 噪声检测器满足:

$$\lim_{M \rightarrow \infty} e^{M\kappa} \cdot \sqrt{2\pi M} \cdot (1 - \text{Fl}_{\text{SCX}}(\theta^\dagger)) = \frac{C_{\min}}{\eta}$$

其中规范最优常数 (Lemma E, eq. 45) :

$$C_{\min} = \frac{\eta}{2} \left(\frac{1-\eta}{\eta} \right)^s \cdot \frac{1/\lambda_0^* + 1/|\lambda_1^*|}{\sqrt{\theta^*(1-\theta^*)}}$$

$\theta^\dagger$ 的构造:

$$\theta^\dagger = \theta^* + \frac{1}{M} \frac{\log((1-\eta)/\eta)}{D^*} + O(1/M^2)$$

(b) 下界 (Minimax Lower Bound): 对任意噪声检测算法 $\mathcal{A}$:

$$\liminf_{M \rightarrow \infty} e^{M\kappa} \cdot \sqrt{2\pi M} \cdot (1 - \text{Fl}_{\mathcal{A}}) \geq \frac{C_{\min}}{\eta}$$

(c) 常数最优性: SCX 的渐近常数达到理论下界, 因此是精确常数 minimax 最优的。

(d) 非渐近界 (Lemma A §A.5, Lemma B §B.4): 对有限 $M \geq M_0(p_0, p_1, \eta)$:

$$\begin{aligned} 1 - \text{F1}_{\text{SCX}}(\theta^\dagger) &\leq \frac{C_{\min}}{\eta} \cdot \frac{e^{-M\kappa}}{\sqrt{2\pi M}} \cdot (1 + K_1/\sqrt{M}) \\ 1 - \text{F1}_{\text{SCX}}(\theta^\dagger) &\geq \frac{C_{\min}}{\eta} \cdot \frac{e^{-M\kappa}}{\sqrt{2\pi M}} \cdot (1 - K_2/\sqrt{M}) \end{aligned}$$


其中 K_1, K_2 是仅依赖 p_0, p_1 的显式常数 (由 Lemma A 的 Stirling 误差界和 Lemma B 的二次余项确定)。

(e) 多状态推广 (Lemma F): 对全局 F1:

$$C_{\min}^{\text{global}} = \sum_{s: \kappa_s = \kappa_{\min}} \rho_s \cdot C_{\min}^{(s)}$$

其中 $\kappa_{\min} = \min_s \kappa_s$, 只有达到最小 Chernoff 信息的状态贡献主导常数。

7. 证明链依赖关系



↓

多状态聚合 $(\Sigma_{\mathbf{s}} \dots)$ → 全局 F1 常数最优性

8. 需要填充的引理 (Agent 任务)

引理 A: Bahadur-Rao 对于 Bernoulli 的完整推导

- 验证倾斜测度的所有计算
- 给出 $o(1)$ 项的显式界 (Berry-Esseen 型修正)
- 推广到非 i.i.d. 但仍独立的 Bernoulli (不同 p_m)

引理 B: F1 渐近展开的高阶项

- 从 $1 - \text{F1} \approx \frac{1}{2}\text{FNR} + \frac{1-\eta}{2\eta}\text{FPR}$ 到包括 $O(e^{-2M\kappa})$ 项
- 验证展开在 $\eta \rightarrow 0$ 或 $\eta \rightarrow 1$ 时的有效性

引理 C: Chernoff 信息的显式表达

- $C(\text{Bern}(p_0), \text{Bern}(p_1))$ 的闭式解 (不是数值解)
- 与 $2(p_1 - p_0)^2$ (Hoeffding) 和 $\frac{1}{2}(\sqrt{p_0} - \sqrt{p_1})^2$ (Hellinger) 的比较

引理 D: 自适应阈值的最优性

- 证明 $\theta^\dagger$ 最小化 $1 - \text{F1}$ 的渐近表达式
- 验证 $\theta^\dagger = \theta^* + O(1/M)$
- 导出使用 $\theta^\dagger$ 的精确常数

引理 E: 下界 — 第二阶渐近最优性

- 形式化状态 “任何算法不优于 LRT”
- Le Cam 第三引理 + LAN 框架下的精确常数
- 或者：使用 Ingster-Suslina 的非参数检验下界框架

引理 F: 多状态聚合

- 从单状态常数最优推广到 $\sum_s \rho_s$ 加权
 - 证明全局常数 $C_{\text{global}} = \sum_s \rho_s C_s$ (受最坏状态支配)
-

9. 参考文献

1. Bahadur, R. R., & Rao, R. R. (1960). On deviations of the sample mean. *Annals of Mathematical Statistics*, 31(4), 1015-1027.
2. Chernoff, H. (1952). A measure of asymptotic efficiency for tests of a hypothesis based on the sum of observations. *Annals of Mathematical Statistics*, 23(4), 493-507.
3. Cramér, H. (1938). Sur un nouveau théorème-limite de la théorie des probabilités. *Actualités Scientifiques et Industrielles*, 736, 5-23.
4. Hoeffding, W. (1965). Asymptotically optimal tests for multinomial distributions. *Annals of Mathematical Statistics*, 36(2), 369-401.
5. Le Cam, L. (1986). *Asymptotic Methods in Statistical Decision Theory*. Springer.
6. van der Vaart, A. W. (1998). *Asymptotic Statistics*. Cambridge University Press.

7. Dembo, A., & Zeitouni, O. (2010). *Large Deviations Techniques and Applications* (2nd ed.). Springer.
8. Ingster, Y. I., & Suslina, I. A. (2003). *Nonparametric Goodness-of-Fit Testing Under Gaussian Models*. Springer.

状态：证明架构完成。*Agent* 任务待启动以填充 *Lemma A-F* 的详细推导。