

Proposition 2: High-Error Sampling Suboptimality under Noise

在噪声存在时，单纯基于残差（max-residual sampling）的主动采样策略不是最优的。高误差可能来自可学习的困难状态（应补充样本）或固有噪声（应丢弃）。

1 Statement

1.1 正式陈述

令 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ 为当前标注数据集，未标注池为 $\mathcal{U}$ 。对于 $x \in \mathcal{U}$ ，定义残差：

$$r(x) = \ell(f_{\text{current}}(x), \hat{y}(x))$$

其中 $\hat{y}(x)$ 是当前最佳预测。

定义：

- 可学习集 $H_{\text{learnable}} = \{x : \mathbb{E}[\ell(f(x), y) \mid x] \text{ 可通过更多采样降低} \}$
- 噪声集 $H_{\text{noise}} = \{x : \mathbb{E}[\ell(f(x), y) \mid x] \text{ 不可降低（固有噪声）} \}$

max-residual 采样： $x^* = \arg \max_{x \in \mathcal{U}} r(x)$

若 $P(H_{\text{noise}}) > 0$ ，则纯 residual-based 采样策略 $\pi_{\text{res}}(x) \propto r_i = \ell(f(x_i), y_i)$ 的期望预算浪费存在严格正下界。

1.2 假设

1. 噪声存在的假设：存在某个状态 s_0 ，使得 $\mathbb{E}[\varepsilon^2|x \in s_0] \geq \sigma_0^2 > 0$
 2. 有限采样预算：总标注预算为 $B \ll |\mathcal{U}|$
 3. 样本间独立性：标注噪声在不同样本间独立（给定 x ）
-

2 Formal Proof

2.1 风险最小化框架

定义采样策略 π 的收益为：

$$J(\pi) = \mathbb{E}_{(x_1^*, \dots, x_B^*) \sim \pi} \left[\sum_{t=1}^B \Delta R(f_t | x_t^*) \right]$$

其中 $\Delta R(f_t | x) = R(f_{t-1}) - R(f_t)$ 是标注 x 后模型的期望风险降低。

记 $r_i = r(x_i)$ ， $\hat{r}_i = \tilde{r}(x_i) - \varepsilon_i$ 为真实残差（不可观测）。

引理 1： max-residual 策略 π_{MR} 在 $B = 1$ 时选择：

$$x_{\text{MR}}^* = \arg \max_{i \in \mathcal{U}} \hat{r}_i + \varepsilon_i$$

引理 2： 最优策略 π^* 在 $B = 1$ 时选择：

$$x_{\pi^*}^* = \arg \max_{i \in \mathcal{U}} \mathbb{E}[\Delta R(f | x_i)] = \arg \max_{i \in \mathcal{U}} \int \Delta R(f | x_i) dP_{\varepsilon_i}(\varepsilon_i)$$

PROPOSITION 2: HIGH-ERROR SAMPLING SUBOPTIMALITY UNDER NOISE3

定理: 若存在至少一个 pair (i, j) 使得 $\hat{r}_i > \hat{r}_j$ 但 $\mathbb{E}[\Delta R(f|x_i)] < \mathbb{E}[\Delta R(f|x_j)]$, 则 $\pi_{\text{MR}} \neq \pi^*$ 。

2.2 证明

步骤 1: 建立 ΔR 与 r 的关系

对平滑损失 $L(f(x), y)$ 在 f_{current} 处做 Taylor 展开:

$$\Delta R(f|x) \approx r(x)^2 \cdot \left. \frac{\partial^2 \mathbb{E}[L]}{\partial f^2} \right|_{f_{\text{current}}} + \sigma_y^2(x)$$

其中 $\sigma_y^2(x)$ 是标签噪声方差。

步骤 2: 噪声 ε 引入偏差

观察到的残差平方 $[\tilde{r}(x)]^2 = [r_{\text{true}}(x) + \varepsilon]^2$ 满足:

$$\mathbb{E}[[\tilde{r}(x)]^2|x] = r_{\text{true}}(x)^2 + \sigma_\varepsilon^2(x)$$

当 $\sigma_\varepsilon^2(x)$ 大时, max-residual 倾向于选择噪声大的样本而非信息量大的样本。

步骤 3: 构造反例

考虑两个状态 s_1, s_2 , 各含 n 个点。

状态 s_1 (可学习): - $y_i = f^*(x_i) + \epsilon_i$, 其中 $\epsilon_i \sim N(0, \sigma_{\text{low}}^2)$ - 当前模型 f 在 s_1 上有系统偏差: $\mathbb{E}[f(x) | x \in s_1] = f^*(x) + \mu$, 其中 $\mu \gg 0$

状态 s_2 (噪声): - $y_i = \text{常数} + \eta_i$, 其中 $\eta_i \sim N(0, \sigma_{\text{high}}^2)$, $\sigma_{\text{high}}^2 \gg \sigma_{\text{low}}^2$ - 当前模型 f 在 s_2 上已最优: $\mathbb{E}[f(x) | x \in s_2] = \text{常数}$

PROPOSITION 2: HIGH-ERROR SAMPLING SUBOPTIMALITY UNDER NOISE4

残差分析:

在 s_1 中:

$$r_i^{(1)} = (f(x_i) - y_i)^2 = (\mu - \epsilon_i)^2 = \mu^2 - 2\mu\epsilon_i + \epsilon_i^2$$

$$\mathbb{E}[r^{(1)}] = \mu^2 + \sigma_{\text{low}}^2$$

在 s_2 中:

$$r_i^{(2)} = (f(x_i) - y_i)^2 = \eta_i^2$$

$$\mathbb{E}[r^{(2)}] = \sigma_{\text{high}}^2$$

参数条件: 令 $\mu^2 + \sigma_{\text{low}}^2 < \sigma_{\text{high}}^2$ 。那么 s_2 中的平均残差大于 s_1 中的平均残差。

Max-Residual Sampling 行为: 选取全局残差最大的 B 个点。由于 $\sigma_{\text{high}}^2 \gg \mu^2 + \sigma_{\text{low}}^2$, 几乎所有被选中的点都来自 s_2 (噪声状态)。

增益分析: 在 s_2 中采样额外的点无助于减少预测误差——模型已经最优。在 s_1 中每采样一个点, 可将偏差从 μ^2 降低到 $O(\sigma_{\text{low}}^2/n_{s_1})$ 。

期望增益下界: 若 Max-Residual 采了 B 个 s_2 中的点:

$$\mathbb{E}[\text{增益}_{\text{res}}] = O\left(\frac{\sigma_{\text{low}}^2}{n_{s_1}}\right) \cdot \left(\frac{n_{s_1}}{n_{s_1} + n_{s_2}}\right)^B \rightarrow 0 \quad \text{as } B \rightarrow \infty$$

差异分析: 设 B_{res} 为 Max-Residual 分配在 s_1 的预算, B_{state} 为 State-Level Sampling 分配在 s_1 的预算。由于 Max-Residual 偏向 s_2 , $B_{\text{res}} \ll B_{\text{state}}$ 。

更新后的期望损失: - Max-Residual: $\mathbb{E}[\mathcal{L}_{\text{res}}] \approx \frac{\sigma_{\text{low}}^2}{n_{s_1} + B_{\text{res}}} + \sigma_{\text{high}}^2$ - State-Level:

$$\mathbb{E}[\mathcal{L}_{\text{state}}] \approx \frac{\sigma_{\text{low}}^2}{n_{s_1} + B_{\text{state}}} + \sigma_{\text{high}}^2$$

差值: $\mathbb{E}[\mathcal{L}_{\text{res}}] - \mathbb{E}[\mathcal{L}_{\text{state}}] \approx \sigma_{\text{low}}^2 \left(\frac{1}{n_{s_1} + B_{\text{res}}} - \frac{1}{n_{s_1} + B_{\text{state}}} \right) > 0$ 。

因此 $\mathbb{E}[\text{增益}_{\text{state}}] - \mathbb{E}[\text{增益}_{\text{res}}] > 0$ 。□

2.3 信息论视角的补充证明

令 $I(X; Y|f)$ 为在给定当前模型时，未标注样本 X 和真实标签 Y 之间的条件互信息。max-residual 采样最大化的是 $H[\hat{Y}|f, X] = \mathbb{E}[\ell(\hat{Y}, Y)]$ ，而非 $I(X; Y|f)$ 。

由数据处理不等式：

$$I(X; Y|f) \leq H[\hat{Y}|f] - H[\hat{Y}|f, X, Y] + H[Y|f] - H[Y|f, X]$$

高噪声下， $H[Y|f, X]$ 增大，而 $I(X; Y|f)$ 减小。max-residual 无法区分”高不确定性源于信息缺失”与”高不确定性源于固有噪声”。

3 Noise Score Derivation

SCX 中的噪声分数定义为：

$$\text{NoiseScore}(x_i) = r_i \cdot \frac{1}{\rho(s_i) + \varepsilon} \cdot [1 - C(s_i)]$$

其中：

- $r_i = \ell(f(x_i), y_i)$ ：点态残差
- $\rho(s_i)$ ：状态 s_i 的出现概率（稀有状态降权）
- $C(s_i)$ ：状态 s_i 的内部一致性

该噪声分数可以理解为一个多因子校正的残差：

1. 残差因子 r_i ：基础误差信号
2. 稀有性校正 $1/(\rho(s_i) + \varepsilon)$ ：稀有状态的残差天然不可靠，需降权
3. 一致性校正 $[1 - C(s_i)]$ ：状态内部一致时，残差更可能是 learnable；不一致时更可能是 noise

噪声分数与 Tsybakov 噪声条件的联系： $C(s) \approx 1 - 2 \cdot \mathbb{E}_{x \in s} [|\eta(x) - 1/2|]$ ，其中 $\eta(x) = P(Y = 1|X = x)$ 。当 $C(s) \rightarrow 1$ 时，状态内部近似为贝叶斯最优决策 ($\alpha \rightarrow \infty$)；当 $C(s) \rightarrow 0$ 时，状态内标签接近随机 ($\alpha \rightarrow 0$)。

4 State-Level Alternative

4.1 状态级采样准则

SCX 的状态级主动采样选择：

$$s^* = \arg \max_s \bar{r}(s) \cdot \rho(s) \cdot C(s)$$

其中：- $\bar{r}(s)$ ：状态 s 的平均残差（代表改善潜力）- $\rho(s)$ ：状态 s 的出现概率（代表覆盖范围）- $C(s)$ ：状态 s 的内部一致性（代表可学习性）

4.2 改进上界

若 SCX 的状态获取函数 $V(s)$ 能够正确区分可学习状态和噪声状态（即 $L(s)$ 是 s 的可学习性的精确度量），则 SCX 采样的期望预算浪费至多为：

PROPOSITION 2: HIGH-ERROR SAMPLING SUBOPTIMALITY UNDER NOISE7

$$\mathbb{E}[\text{浪费}_{\text{SCX}}] \leq B \cdot \epsilon_{\text{est}}$$

其中 $\epsilon_{\text{est}} = P(L(s) \text{ 估计错误})$ 。相比之下，Max-Residual 的期望浪费下界为：

$$\mathbb{E}[\text{浪费}_{\text{res}}] \geq B \cdot P(x \in H_{\text{noise}} \mid \text{残差最高})$$

当 $P(x \in H_{\text{noise}} \mid \text{残差最高}) \gg \epsilon_{\text{est}}$ 时，SCX 显著优于 Max-Residual。

5 Implications for SCX

1. 解释了为什么 data poisoning 能被 SCX 检测：

- 高误差 + 孤立（低 ρ ）+ 状态不一致（低 C ） $\rightarrow$ noise / poison
- 高误差 + 密集（高 ρ ）+ 状态一致（高 C ） $\rightarrow$ learnable hard state

2. 预算分配策略：标注预算应优先分配给 $\bar{r}(s) \cdot \rho(s) \cdot C(s)$ 高的状态，而非残差最高的样本。

3. 与 Huber 污染模型的关系：噪声分数 $\text{NoiseScore}(x_i)$ 对应状态 s_i 中识别污染点的依据：

$$P_{X|s} = (1 - N(s)) \cdot P_{X|s}^0 + N(s) \cdot P_{X|s}^{\text{noise}}$$

其中 $N(s)$ 为噪声比例。

PROPOSITION 2: HIGH-ERROR SAMPLING SUBOPTIMALITY UNDER NOISES

4. 与 UCB bandit 的联系: $V(s)$ 可以理解为状态臂 bandit 的 UCB 获取函数的推广:

$$V(s) = \underbrace{\bar{r}(s) \cdot \rho(s)}_{\text{exploitation}} \cdot \underbrace{L(s) \cdot [1 - D(s)]}_{\text{exploration}} \cdot \underbrace{\max_m SCX_m(s)}_{\text{expertise}}$$

参考文献

1. SCX 核心框架数学分析. 01_SCX_ 核心框架 _ 数学分析.md Section 2.2
2. SCX 数学基础与证明建构. 05_ 数学根源与证明.md Proposition 2
3. Tsybakov, A. B. (2004). Optimal aggregation of classifiers in statistical learning. *Annals of Statistics*.
4. Huber, P. J. (1964). Robust estimation of a location parameter. *Annals of Mathematical Statistics*.
5. MacKay, D. J. C. (1992). Information-based objective functions for active data selection. *Neural Computation*.