

04 — Compression Fidelity of SCX-Compress

推导 SCX-Compress 模块的压缩保真定理、安全压缩比条件，以及
与经典 coresets 理论的关系。

关联代码: `src/scx/action/compress.py` 关联公式: 冗余分数
 $D(s)$, 压缩规模 $n'_s = \alpha\sqrt{|S_s|} + \beta \cdot \text{Boundary}(s) + \gamma \cdot \bar{r}(s)$

1 符号与设定 (Notation)

符号	含义
$\mathcal{S}$	状态空间, 通过 SCX 聚类划分
$s \in \mathcal{S}$	单个状态
$S_s = \{(x_i, y_i)\}_{i=1}^{N_s}$	状态 s 包含的训练样本
$N_s = S_s $	状态大小
$\mathcal{F}$	假设类 (hypothesis class)
$\ell : \mathcal{F} \times (\mathcal{X}, \mathcal{Y}) \rightarrow [0, B]$	有界损失函数
$D(s) \in [0, 1]$	状态 s 的冗余分数
$D_i \in [0, 1]$	样本 i 的个体冗余分数
$\rho(s) = N_s/N$	状态比例
$\bar{r}(s) = \frac{1}{N_s} \sum_i r_i$	平均归一化残差, $r_i \in [0, 1]$
$\text{Sim}(s) \in [0, 1]$	状态内部相似度
$\text{Boundary}(s) \in [0, 1]$	边界样本比例
$C_s \subset S_s$	压缩后保留的加权子集
$n'_s = C_s $	压缩集大小
w_i	样本 i 在压缩集中的权重, $\sum_{i \in C_s} w_i = N_s$

符号	含义
$R_S(f) = \frac{1}{N_s} \sum_{i \in S_s} \ell(f(x_i), y_i)$	原始经验风险
$R_C(f) = \frac{1}{N_s} \sum_{i \in C_s} w_i \ell(f(x_i), y_i)$	压缩后的加权经验风险估计
$\varepsilon(s) = \sup_{f \in \mathcal{F}} R_S(f) - R_C(f) $	压缩保真误差

冗余分数定义

状态级冗余分数为各因子的乘积形式：

$$D(s) = \rho(s) \cdot (1 - \bar{r}(s)) \cdot \text{Sim}(s) \cdot (1 - \text{Boundary}(s)). \quad (1)$$

代码实现中，个体冗余分数采用加权和形式（与乘积形式等价但在因子分解方式上略有不同）：

$$D_i = 0.4 \cdot \underbrace{\left(1 - \frac{\text{nn_dist}_i}{\max(\text{nn_dist})}\right)}_{\text{density}} + 0.4 \cdot \underbrace{\left(1 - \frac{r_i}{\max(r)}\right)}_{\text{residual}} + 0.2 \cdot \underbrace{\min(5\rho(s), 1)}_{\text{proportion}}. \quad (2)$$

状态级 $D(s)$ 与个体级 $\{D_i\}$ 通过 $D(s) \approx \frac{1}{N_s} \sum_i D_i$ 关联。

压缩规模公式

SCX-Compress 为目标状态保留的样本数由三项构成：

$$n'_s = \alpha \sqrt{N_s} + \beta \cdot \text{Boundary}(s) \cdot N_s + \gamma \cdot \bar{r}(s) \cdot \sqrt{N_s}. \quad (3)$$

- 第一项 (**coreset backbone**): $\alpha \sqrt{N_s}$ ，经典 coreset 的次线性规模

- 第二项 (**boundary preservation**): $\beta B_s N_s$, 边界样本强制保留
- 第三项 (**residual compensation**): $\gamma \bar{r}(s) \sqrt{N_s}$, 高残差区域增加容量

当 N_s 较大时, $n'_s = \Theta(\sqrt{N_s})$, 实现次线性压缩。

2 核心假设 (Assumptions)

(CA1) 有界损失 (Compression Assumption 1): 对任意 $f \in \mathcal{F}$ 和 $(x, y) \sim \mathcal{D}$,

$$0 \leq \ell(f(x), y) \leq B < \infty.$$

(CA2) 复合类复杂度 (Compression Assumption 2): 损失复合类 $\mathcal{L}_{\mathcal{F}} = \{\ell_f : \ell_f(x, y) = \ell(f(x), y) \mid f \in \mathcal{F}\}$ 是 VC 型类, 其伪维数 (pseudo-dimension) 为 $d = \text{Pdim}(\mathcal{L}_{\mathcal{F}}) < \infty$ 。等价地, 对任意经验分布 P_N , 其 $L_2(P_N)$ 覆盖数满足:

$$\mathcal{N}(\varepsilon, \mathcal{L}_{\mathcal{F}}, L_2(P_N)) \leq \left(\frac{C_K}{\varepsilon} \right)^{2d}, \quad \forall \varepsilon > 0. \quad (4)$$

(CA3) 冗余-敏感性关联 (Compression Assumption 3): 对任意样本 $i \in S_s$, 其灵敏度 (sensitivity) σ_i 被冗余分数控制:

$$\sigma_i := \sup_{f \in \mathcal{F}} \frac{|\ell(f(x_i), y_i)|}{\sum_{j \in S_s} |\ell(f(x_j), y_j)|} \leq \frac{1 - D_i}{\sum_{j \in S_s} (1 - D_j)} \cdot C_{\text{cal}}, \quad (5)$$

其中 C_{cal} 为校准常数。该假设的直观含义是: 高冗余样本 ($D_i \approx 1$) 在任意假设 f 下的边际贡献很小, 因此可以被安全地降采样。下文的推导取

$C_{\text{cal}} = 1$ (通过重新缩放吸收到常数中)。

(CA4) **边界保留** (Compression Assumption 4): 所有边界样本 ($b_i = 1$, 即 $D_i = 0$ 的样本) 被确定性保留。

3 压缩保真定理 (Compression Fidelity)

3.1 定理陈述

Theorem 1 (Compression Fidelity). 设状态 s 满足假设 (CA1)–(CA4)。令 C_s 为 SCX-Compress 以式 (3) 的规模 n'_s 和式 (2) 的冗余分数选择的加权子集, 且权重 $\{w_i\}_{i \in C_s}$ 按代码实现归一化满足 $\sum_{i \in C_s} w_i = N_s$ 。则对任意 $\delta \in (0, 1)$, 以概率至少 $1 - \delta$ 成立:

$$\sup_{f \in \mathcal{F}} |R_S(f) - R_C(f)| \leq B \cdot \frac{1 - D_{\text{eff}}(s)}{1 - n'_s/N_s} + \mathcal{O} \left(B \cdot \sqrt{\frac{d}{n'_s} \cdot \frac{1 - D_{\text{eff}}(s)}{1 - n'_s/N_s} \cdot \log \frac{N_s}{\delta}} \right), \quad (6)$$

其中 $D_{\text{eff}}(s) = D(s) \cdot (1 - \text{Boundary}(s))$ 为经边界校正的有效冗余。

3.2 显式上界的紧凑形式

更便于使用的紧凑形式为:

$$\varepsilon(s) \leq \underbrace{B \cdot (1 - D_{\text{eff}}(s)) \cdot \left(1 - \frac{n'_s}{N_s}\right)}_{\text{(i) 偏差项}} + \underbrace{\frac{4B}{\sqrt{n'_s}} \cdot \sqrt{d \cdot (1 - D_{\text{eff}}(s)) \cdot \left(1 - \frac{n'_s}{N_s}\right) \cdot \log \frac{2}{\delta}}}_{\text{(ii) 方差项}} \quad (7)$$

- **(i) 偏差项 (bias term):** 来自非均匀采样导致的系统偏移。当 $D_{\text{eff}}(s) \rightarrow 1$ (高度冗余) 或 $n'_s/N_s \rightarrow 1$ (几乎不压缩) 时偏差消失。
- **(ii) 方差项 (variance term):** 来自有限样本的随机波动。包含伪维数 d (模型复杂度) 和 $\log(1/\delta)$ (置信度)。

3.3 证明框架 (Proof Sketch)

Step 1 — 灵敏度分解

将误差重写为加权和形式。令 $a_i = 1 - w_i \cdot \mathbf{1}\{i \in C_s\}$, 则

$$R_S(f) - R_C(f) = \frac{1}{N_s} \sum_{i \in S_s} a_i \cdot \ell_f(x_i, y_i),$$

其中 $\sum_i a_i = 0$ (由权重归一化保证)。由假设 (CA3), $\{a_i\}$ 满足:

$$|a_i| \leq \max \left\{ \underbrace{\frac{N_s}{n'_s} \cdot \frac{e^\tau}{\bar{w}} - 1}_{\text{保留样本上界}}, \underbrace{1}_{\text{未保留样本上界}} \right\} \leq \frac{N_s}{n'_s} \cdot \frac{e^\tau}{\bar{w}},$$

其中 $\bar{w} = \frac{1}{n'_s} \sum_{i \in C_s} e^{-\tau D_i}$ 为平均指数权重, τ 为代码中的 `temperature` 参数。

Step 2 — 有效样本量与冗余的关系

定义有效样本量 (effective sample size):

$$N_{\text{eff}} = \frac{(\sum w_i)^2}{\sum w_i^2} = \frac{N_s^2}{\sum_{i \in C_s} w_i^2}.$$

当 $D_{\text{eff}}(s)$ 较高时, $w_i \approx N_s/n'_s$ (各样本权重接近), $N_{\text{eff}} \approx n'_s$; 当 $D_{\text{eff}}(s)$ 较低时, 权重发散, $N_{\text{eff}} < n'_s$ 。具体地:

$$N_{\text{eff}} \geq n'_s \cdot (1 - D_{\text{eff}}(s))^{-1}. \quad (8)$$

该式建立了 $D(s)$ 与采样效率之间的桥梁: 高冗余意味着高有效样本量。

Step 3 — 应用 uniform convergence 界

对于固定的加权机制, 对损失复合类 $\mathcal{L}_{\mathcal{F}}$ 应用标准 uniform convergence bound (见 Bartlett & Mendelson, 2002; Bousquet et al., 2004):

以概率 $\geq 1 - \delta$,

$$\sup_{f \in \mathcal{F}} |R_S(f) - R_C(f)| \leq 2 \cdot \mathfrak{R}_{N_{\text{eff}}}(\mathcal{L}_{\mathcal{F}}) + B \cdot \sqrt{\frac{\log(2/\delta)}{2N_{\text{eff}}}} + \mathbb{E}[|R_S - R_C|],$$

其中 $\mathfrak{R}_m(\mathcal{L}_{\mathcal{F}})$ 是 m 个样本上的 Rademacher 复杂度。由假设 (CA2) 的覆盖数条件, $\mathfrak{R}_m(\mathcal{L}_{\mathcal{F}}) \leq B\sqrt{d/m}$ 。

Step 4 — 代入 N_{eff} 与 n'_s 的关系

将式 (8) 代入, 并结合式 (3) 中 n'_s 的显式形式:

$$\frac{1}{\sqrt{N_{\text{eff}}}} \leq \sqrt{\frac{1 - D_{\text{eff}}(s)}{n'_s}} \leq \sqrt{\frac{1 - D_{\text{eff}}(s)}{\alpha\sqrt{N_s} + \beta B_s N_s + \gamma \bar{r}(s)\sqrt{N_s}}}.$$

偏差项直接来自权重非均匀性：

$$\mathbb{E}[|R_S - R_C|] \leq B \cdot (1 - D_{\text{eff}}(s)) \cdot \left(1 - \frac{n'_s}{N_s}\right).$$

合并即得式 (7)。□

3.4 讨论

Theorem 1 给出的保真界具有以下性质：

1. **自适应性**: 当 $D(s) \rightarrow 1$ （完美冗余）时, $\varepsilon(s) \rightarrow 0$, 即使 $n'_s \ll N_s$ 。
当 $D(s) \rightarrow 0$ （无冗余）时, $\varepsilon(s)$ 退化为无压缩的 ERM 泛化界。
2. **次线性压缩**: 由于 $n'_s = \Theta(\sqrt{N_s})$, 当 N_s 增大时压缩比 $n'_s/N_s = \Theta(1/\sqrt{N_s}) \rightarrow 0$, 而误差 $\varepsilon(s) \rightarrow B(1 - D_{\text{eff}}(s))$, 即被有效冗余控制。
3. **边界保护**: Boundary(s) 同时降低 $D_{\text{eff}}(s)$ （提高分子）和增加 n'_s （降低分母），双重机制确保关键样本不被过度压缩。
4. **模型复杂度依赖性**: 误差随 $\sqrt{d/n'_s}$ 增长, 这与标准 ERM 的 $\sqrt{d/N}$ 形式一致, 但分母从 N_s 变为 n'_s , 体现了压缩的成本。

4 安全压缩比推论 (Safe Compression Ratio)

Corollary 1 (Safe Compression Ratio). 设目标精度损失 $\varepsilon_0 \in (0, B)$ (即要求 $\varepsilon(s) \leq \varepsilon_0$)。定义压缩比 $r = n'_s/N_s$ 。则 SCX-Compress 达到 $\varepsilon(s) \leq \varepsilon_0$ 的充分条件是:

$$D_{\text{eff}}(s) \geq 1 - \frac{\varepsilon_0}{B \cdot (1-r)} \cdot \left(1 - \frac{4\sqrt{d \log(2/\delta)}}{\sqrt{rN_s}}\right)^{-1}. \quad (9)$$

特例: 当 N_s 充分大使得 $\frac{4\sqrt{d \log(2/\delta)}}{\sqrt{rN_s}} \ll 1$ 时, 条件退化为:

$$D_{\text{eff}}(s) \geq 1 - \frac{\varepsilon_0}{B \cdot (1-r)}. \quad (10)$$

50% 压缩 ($r = 0.5$) 时精度损失 $< 5\%$ 的条件:

代入 $\varepsilon_0 = 0.05B$ (损失相对 B 的 5%)、 $r = 0.5$, 得:

$$D_{\text{eff}}(s) \geq 1 - \frac{0.05}{0.5} = 0.90.$$

即: 状态冗余分数需不低于 0.90 时, 50% 压缩可保证精度损失不超过 5%。

更一般地, r 与 ε_0 的 trade-off 曲线由下式给出:

$$r \geq 1 - \frac{\varepsilon_0}{B \cdot (1 - D_{\text{eff}}(s))}. \quad (11)$$

该式说明: 安全压缩比由 $D(s)$ 线性控制—— $D(s)$ 每增加 0.1, 可额外压缩约 $\frac{\varepsilon_0}{B}$ 的比例。

5 与经典 Coreset 理论的联系

5.1 Feldman-Langberg 灵敏度采样

经典的 Feldman-Langberg 框架 (Feldman & Langberg, 2011; Feldman, 2020) 通过灵敏度加权采样构建 coreset:

Theorem (Feldman-Langberg, 概括). 设样本 $\{z_i\}_{i=1}^N$ 的灵敏度为 σ_i , 总灵敏度 $T = \sum_i \sigma_i$. 以概率 $p_i \geq \sigma_i/T$ 独立采样 m 个样本, 权重设为 $1/(mp_i)$, 则对任意 $\delta \in (0, 1)$, 以概率 $\geq 1 - \delta$:

$$\sup_{f \in \mathcal{F}} \left| \frac{1}{N} \sum_{i=1}^N \ell_f(z_i) - \frac{1}{N} \sum_{i \in C} w_i \ell_f(z_i) \right| \leq \frac{B}{N} \cdot (T + \sqrt{T \log(1/\delta)} + \sqrt{m \log(1/\delta)}).$$

SCX-Compress 与之相比的差异和优势:

维度	Feldman-Langberg	SCX-Compress
灵敏度估计	需计算 $\sup_{f \in \mathcal{F}} \frac{ \ell_f(z_i) }{\sum_j \ell_f(z_j)}$, 通常无闭式解	用 D_i 代理灵敏度, 可直接从数据计算
采样分布	$p_i \geq \sigma_i/T$, 需显式知道 σ_i	$p_i \propto 1 - D_i$, 无需额外计算
边界处理	无显式机制	$\beta \cdot \text{Boundary}(s)$ 强制保留
规模	m 需手动指定	n'_s 自动适应 N_s 、 B_s 、 $\bar{r}(s)$
计算成本	每点评估 σ_i 通常需 $O(N^2)$ 以上	$O(N_s d + N_s \log N_s)$

5.2 SCX-Compress 的灵敏度实现

由假设 (CA3)，SCX-Compress 实际上使用了 D_i 作为灵敏度的代理变量。将 $p_i \propto 1 - D_i$ 代入 Feldman-Langberg 框架，可得总灵敏度 T 的界：

$$T = \sum_i \sigma_i \leq \sum_i \frac{1 - D_i}{\sum_j (1 - D_j)} = 1.$$

这比 Feldman-Langberg 的一般情况（通常 $T = \Omega(\sqrt{N})$ 甚至 $T = \Omega(N)$ ）更有利。其原因正是 SCX 的状态划分：在同一状态内，样本的表达已通过聚类对齐，剩余差异被 D_i 捕获。

5.3 在 SCX 框架中的定位

SCX-Compress 可视为 LC (Lossless Compression) 假设下的 Feldman-Langberg 变体：

1. 聚类预处理（SCX 的状态划分）将原始数据集分解为 $|\mathcal{S}|$ 个近似同质的状态
2. 状态内压缩（SCX-Compress）在每个状态内应用冗余感知的加权 core-set
3. 整体保真度跨状态独立组合：

$$\varepsilon_{\text{total}} = \bigvee_{s \in \mathcal{S}} \varepsilon(s) \quad (\text{逐状态的误差以 union bound 组合}).$$

6 合成验证方案

6.1 实验设计

数据生成：在 $[0, 1]^2$ 上生成 4 个高斯混合状态，每个状态 $N_s = 2000$ 样本。

状态	均值	协方差	$D(s)$ (期望)	说明
s1	(0.2, 0.2)	$0.01I$	≈ 0.95	高度密集、高冗余
s2	(0.5, 0.5)	$0.05I$	≈ 0.75	中等密度
s3	(0.8, 0.8)	$0.15I$	≈ 0.50	较分散
s4	(0.1, 0.9)	$0.25I$	≈ 0.25	分散且靠近边界

标签函数： $y = \sin(2\pi x) \cdot \cos(2\pi y) + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, 0.05)$ 。

假设类 $\mathcal{F}$ ： RBF 核 SVM 或 3 层 MLP（作为 $\mathcal{F}$ 的替代）。

6.2 需要验证的命题

(P1) 保真界 **tightness**: 对不同 $D(s)$ 的状态，测量 $\varepsilon(s)$ 并对比 Theorem 1 的理论上界。预期：s1 的 ε 最小，且理论界紧因子 ≤ 2 。

(P2) 压缩比-误差 **trade-off**: 固定 α, β, γ ，变化压缩比 $r \in [0.1, 0.9]$ ，绘制 $\varepsilon(s)$ 随 r 的变化曲线。验证式 (11) 的线性关系。

(P3) 边界保留效果: 在 s4 中人工注入边界样本（Bayes 决策面附近），对比有/无强制保留时的分类精度。

(P4) 对比基线: - 随机采样 + 均匀权重 - K-Center coreset - Feldman-Langberg 灵敏度采样（用 $|y - \hat{y}|$ 作为灵敏度代理）

6.3 可视化方案

图号	类型	内容	验证目标
Fig 1	散点 + 等高线	4 个状态在 2D 空间中的分布, 颜色标记 D_i 大小	展示冗余分数与数据密度的关系
Fig 2	折线图 (双轴)	x 轴 = 压缩比 r , 左 y = $\varepsilon(s)$, 右 y = 理论界	(P2) 理论界 tightness
Fig 3	箱线图	对每个 $D(s)$ bin, 展示 $\varepsilon(s)$ 的 50 次重复分布	(P1) 误差随 $D(s)$ 减小
Fig 4	柱状图	不同方法在各状态上的 ε 对比	(P4) SCX-Compress vs 基线
Fig 5	热力图	(α, γ) 参数扫描下的 $\varepsilon(s)$	参数敏感性分析
Fig A1	棒棒糖图	权重分布 w_i 在压缩前后的对比	直观展示加权效果

6.4 预期结果

1. 误差排序: $\varepsilon(s1) < \varepsilon(s2) < \varepsilon(s3) < \varepsilon(s4)$, 严格与 $D(s)$ 负相关。
2. 临界点: $D(s) \geq 0.90$ 的状态 (s1) 在 $r = 0.5$ 时 $\varepsilon < 0.05B$, 验证

Corollary 1。

3. **边界保留**: 在 s_4 中, 无强制保留时精度损失约 12-15%, 有强制保留时降至 3-5%。
4. **计算效率**: SCX-Compress 的运行时间与 $N_s \log N_s$ 近似线性, 优于 K-Center 的 $O(N_s^2)$ 。
5. **参数敏感性**: α 控制基础 coreset 规模, β 仅在高 Boundary(s) 时显著, γ 在残差异质性高时重要。

7 补充：循环定义修复 (2026-06-27)

7.1 问题陈述

原始冗余分数 $D(s)$ 的定义（式 1）依赖于平均归一化残差 $\bar{r}(s)$ ：

$$D(s) = \rho(s) \cdot (1 - \bar{r}(s)) \cdot \text{Sim}(s) \cdot (1 - \text{Boundary}(s)).$$

其中 $\bar{r}(s) = \frac{1}{N_s} \sum_i r_i$, 而 $r_i = \ell(f(x_i), y_i)$ 是模型对样本 (x_i, y_i) 的损失。问题是：**残差 r_i 的计算需要真实标签 y_i** 。在无监督或弱监督场景下, 真实标签不可用, 无法直接计算 $\bar{r}(s)$, 导致 $D(s)$ 存在循环依赖——你需要知道哪些数据有噪声才能计算 $D(s)$, 但 $D(s)$ 的本意正是用于发现噪声数据。

7.2 解决方案：一致性替代

Theorem 1（多专家一致性噪声检测保证）证明了一种可靠的无监督噪声指示量——多专家一致性得分 $C(x)$ 。定义状态平均一致性得分：

$$\bar{C}(s) = \frac{1}{N_s} \sum_{x \in S_s} C(x), \quad C(x) = \frac{1}{M} \sum_{m=1}^M \mathbf{1}\{\ell(f_m(x), y) > \tau\}.$$

由 Theorem 1 的 Lemma 1 (均值分离), 清洁样本的一致性得分被 μ_s 控制, 而噪声样本的一致性得分接近 1。因此 $\bar{C}(s)$ 与 $\bar{r}(s)$ 存在以下关系:

$$\bar{r}(s) = 1 - \bar{C}(s) + \mathcal{O}\left(\frac{1}{\sqrt{M}}\right). \quad (12)$$

推导: 由 Lemma 1, 对清洁样本 $\mathbb{E}[C \mid \text{clean}] \leq \mu_s$, 对噪声样本 $\mathbb{E}[C \mid \text{noise}] \geq 1 - \mu_s/(K - 1)$ 。因此 $\bar{C}(s)$ 在清洁区域接近 0, 在噪声区域接近 1——与归一化残差 $\bar{r}(s)$ 的单调关系相反。 $\mathcal{O}(1/\sqrt{M})$ 项来自 Hoeffding 不等式对有限 M 个专家的浓度界 (见 Theorem 1 式 (6) 的指数收敛), 当 $M \geq 10$ 时该项通常可忽略。

7.3 修正后的冗余分数

将式 (12) 代入式 (1), 修正后的冗余分数为:

$$D_{\text{fix}}(s) = \rho(s) \cdot (1 - [1 - \bar{C}(s) + \mathcal{O}(1/\sqrt{M})]) \cdot \text{Sim}(s) \cdot (1 - \text{Boundary}(s))$$

化简为:

$$D_{\text{fix}}(s) = \rho(s) \cdot \bar{C}(s) \cdot \text{Sim}(s) \cdot (1 - \text{Boundary}(s)) + \mathcal{O}\left(\frac{1}{\sqrt{M}}\right). \quad (13)$$

关键改进: $\bar{C}(s)$ 仅基于多专家模型的预测一致性, 不需要任何真实标签。这打破了原始定义的循环依赖。

7.4 对压缩保真界的影响

替换 $\bar{r}(s)$ 为 $1 - \bar{C}(s)$ 后，压缩规模公式（式 3）变为：

$$n'_s = \alpha\sqrt{N_s} + \beta \cdot \text{Boundary}(s) \cdot N_s + \gamma \cdot (1 - \bar{C}(s)) \cdot \sqrt{N_s} + \mathcal{O}\left(\frac{\sqrt{N_s}}{\sqrt{M}}\right). \quad (14)$$

保真界的松弛程度：原始保真界（定理 1 / 式 7）的偏差项和方差项均涉及 $D_{\text{eff}}(s)$ 。替换后， $D_{\text{eff}}(s)$ 的估计误差传播到保真界中：

$$\varepsilon_{\text{fix}}(s) \leq \varepsilon_{\text{orig}}(s) + \mathcal{O}\left(B \cdot \frac{1}{\sqrt{M}}\right). \quad (15)$$

松弛是可接受的，原因有三：

1. **M 的典型规模：**噪声检测场景中 M （专家数）通常 ≥ 10 ，此时 $\mathcal{O}(1/\sqrt{M}) \leq 0.32$ ；当 $M \geq 50$ 时降低到 0.14 以下。
2. **指数收敛：**Theorem 1 的实际 F1 以 $\exp(-2M\Delta^2)$ 速率收敛，意味着 $\bar{C}(s)$ 对 $\bar{r}(s)$ 的近似误差随 M 指数级衰减——比式 (12) 的 $\mathcal{O}(1/\sqrt{M})$ 更乐观。
3. **理论完整性：**付出 $1/\sqrt{M}$ 的代价换来无监督可计算性，这在理论上是最优折衷——任何无监督近似必然引入有限样本误差。

7.5 总结

修复后的 $D_{\text{fix}}(s)$ 具有以下性质：

属性	原始 $D(s)$	修正 $D_{\text{fix}}(s)$
计算所需数据	真实标签 y_i	仅需多专家预测 $\{f_m(x_i)\}_m$

属性	原始 $D(s)$	修正 $D_{\text{fix}}(s)$
循环依赖	有（需标签才能算冗余）	无
理论保真度	精确	$+\mathcal{O}(1/\sqrt{M})$ 松弛
适用场景	有监督	无监督 / 弱监督
与 Theorem 1 的关系	无	核心依赖

结论： With Theorem 1, the compression fidelity theorem is now fully self-contained — all quantities can be estimated from observable data without ground truth labels.

Changelog

Date	Defect	Change	Severity
2026-06-28	B3	Renamed A1–A4 to CA1–CA4: Compression- specific assumptions renamed from A1–A4 to CA1–CA4 (Compression Assumptions) throughout the file to resolve notation collision with globally defined A1–A4 (disjoint training, conditional independence, bounded loss, uniform noise). Fixes FAIL-1 from cross-reference audit.	FATAL