

Expert Governance Protocol — 形式化定义

SCX/EGP 蒸馏前专家规范化协议

版本: v1.0

最后更新: 2026-06-26

目录

1. 符号与设定
 2. 五步 Governance Protocol
 - Step 1: Gauge Check
 - Step 2: Domain Certificate
 - Step 3: Conflict Resolution
 - Step 4: Anchor Verification
 - Step 5: Distillation Authorization
 3. 阈值选择指引
 4. 失败回退策略
 5. Certification Theorem
 6. AlN v3 回顾性验证方案
 7. 与 SCX 代码的实现映射
-

1. 符号与设定

1.1 基础定义

沿用 SCX 框架定义（参见 `theory/README.md`）：

符号	含义	类型
$\mathcal{X}$	输入空间（原子构型）	度量空间
$\mathcal{Y}$	标签空间（能量/力）	$\mathbb{R}^d$
$f^* : \mathcal{X} \rightarrow \mathcal{Y}$	真实标注函数（DFT）	未知 oracle
$f_m : \mathcal{X} \rightarrow \mathcal{Y}$	第 m 个 MLIP 专家	可计算函数, $m \in [M]$
M	专家总数	$\mathbb{N}$
$\mathcal{S}$	状态空间（有限划分）	$ \mathcal{S} = K$
$s : \mathcal{X} \rightarrow \mathcal{S}$	状态映射函数	可测函数
$s(x)$	构型 x 归属的状态	$\mathcal{S}$
$\ell : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_{\geq 0}$	损失函数（默认 MSE）	有界: $0 \leq \ell \leq L_{\max}$

1.2 核心量

状态条件专家风险（Definition 1, SCX）：

$$R_m(s) = \mathbb{E}_{x \sim P(\cdot|s)}[\ell(f_m(x), f^*(x))]$$

SCX 可靠性（Definition 2, SCX）：

$$\text{SCX}_m(s) = P(\ell(f_m(x), f^*(x)) < \tau \mid x \in s)$$

专家配对冲突（Definition 3, ExpertConflict）：

$$\text{Conflict}(m, n, s) = \mathbb{E}_{x \sim P(\cdot|s)} [|f_m(x) - f_n(x)|^2]$$

1.3 Protocol 整体结构

Governance Protocol 是从原始专家系统到蒸馏授权决策的线性判定流程：

$$\mathcal{G} : \underbrace{(\{f_m\}, \mathcal{S}, \mathcal{D}_{\text{ref}})}_{\text{输入}} \xrightarrow{\text{Step 1-5}} \underbrace{\{\text{authorized, conditional, denied}\}}_{\text{输出}}$$

输入：- 专家集 $\{f_m\}_{m=1}^M$ （可能异构：MACE, NEP, SevenNet, ...）- 状态空间 $\mathcal{S}$ 及状态映射 $s(x)$ - 参考数据集 $\mathcal{D}_{\text{ref}} = \{(x_i, y_i)\}_{i=1}^{N_{\text{ref}}}$ （DFT 标签）- 蒸馏目标状态 $s_{\text{target}} \in \mathcal{S}$

输出：- **authorized**：所有检查通过，可直接蒸馏 - **conditional**：部分条件不满足但可补救（如补锚点测试）- **denied**：不可蒸馏，需专家重新训练或更换专家

2. 五步 Governance Protocol

Step 1: Gauge Check (量规检查)

问题 不同 MLIP 的总能量预测存在系统性能量偏移（gauge freedom）。Step 1 检测并消除这些偏移，使所有专家的能量预测在统一的参考标度上可比。

形式化定义 输入: - 专家集 $\{f_m\}_{m=1}^M$ - 参考状态子集 $\mathcal{S}_{\text{gauge}} \subseteq \mathcal{S}$ (选择能量已知的简单状态, 如体相晶格) - 参考能量 $E_{\text{ref}}(s)$ 对每个 $s \in \mathcal{S}_{\text{gauge}}$ (从 DFT 或实验获得) - 容忍度 $\epsilon_{\text{gauge}} > 0$

Gauge 定义:

每个专家 f_m 的能量预测分解为:

$$f_m(x) = \underbrace{f_m^{\text{intrinsic}}(x)}_{\text{物理部分}} + \underbrace{\mu_m}_{\text{gauge offset}} + \underbrace{\eta_m(x)}_{\text{残差}}$$

其中 μ_m 是依赖于专家的系统偏差 (gauge shift)。对力预测, $\nabla_x \mu_m = 0$, 因此力不受影响。但**总能量基准**的差异影响蒸馏中学生对能量的学习。

Gauge Check 算法:

1. 对每个 $s \in \mathcal{S}_{\text{gauge}}$, 采样 N_{gauge} 个构型 $\{x_{s,j}\}_{j=1}^{N_{\text{gauge}}}$
2. 计算每个专家的平均偏差:

$$\hat{\mu}_m(s) = \frac{1}{N_{\text{gauge}}} \sum_{j=1}^{N_{\text{gauge}}} [f_m(x_{s,j}) - E_{\text{ref}}(s)]$$

3. 计算 gauge 一致性度量:

$$\text{GaugeVariance}(m) = \frac{1}{|\mathcal{S}_{\text{gauge}}|} \sum_{s \in \mathcal{S}_{\text{gauge}}} (\hat{\mu}_m(s) - \bar{\mu}_m)^2$$

$$\text{其中 } \bar{\mu}_m = \frac{1}{|\mathcal{S}_{\text{gauge}}|} \sum_s \hat{\mu}_m(s)$$

4. 判定条件:

$$\text{gauge_certified}(m) = \begin{cases} \text{true}, & \text{GaugeVariance}(m) \leq \epsilon_{\text{gauge}} \\ \text{false}, & \text{otherwise} \end{cases}$$

（低方差意味着偏移 μ_m 在各参考状态间一致，是纯 gauge 偏移）

输出类型:

$$\text{gauge_certified} : [M] \rightarrow \{\text{true}, \text{false}\}$$

Gauge Fixing（失败时执行）:

若存在 m 使得 $\text{gauge_certified}(m) = \text{false}$ ，则需要 gauge fixing。定义校准函数:

$$\tilde{f}_m(x) = f_m(x) - \frac{1}{|\mathcal{S}_{\text{gauge}}|} \sum_{s \in \mathcal{S}_{\text{gauge}}} \hat{\mu}_m(s)$$

即将专家 m 的能量预测减去其对参考状态的平均系统偏差。

校准后重新运行 Check。

与已有工作的关系

- 文献中 “Gauge dependence of total energies” (arXiv:2504.05565, 2025) 指出不同 DFT 泛函间存在类似问题，但未处理跨 **MLIP** 架构的 gauge 对齐。
- 本步骤是 SCX/EGP 的原创贡献——在蒸馏前强制多专家能量标度统一。

Step 2: Domain Certificate (域认证)

问题 对目标状态 s_{target} ，评估每个专家在该状态上的可靠性。不可靠专家不应参与蒸馏。

形式化定义 输入: - 专家集 $\{f_m\}_{m=1}^M$ - 目标状态 $s_{\text{target}} \in \mathcal{S}$ - 状态标注数据 $\mathcal{D}_s = \{(x_i, y_i) \mid s(x_i) = s_{\text{target}}\}$ (可能有或没有) - 低可靠性阈值 $\theta_{\text{low}} \in (0, 1)$ - 高可靠性阈值 $\theta_{\text{high}} \in (0, 1)$ ($\theta_{\text{high}} > \theta_{\text{low}}$) - 损失阈值 $\tau > 0$ - 最小样本数 $n_{\text{min}} \in \mathbb{N}$

可靠性估计:

对每个专家 m ，在 s_{target} 上估计 SCX 可靠性:

$$\widehat{\text{SCX}}_m(s_{\text{target}}) = \begin{cases} \frac{1}{|\mathcal{D}_s|} \sum_{(x,y) \in \mathcal{D}_s} \mathbf{1}\{\ell(f_m(x), y) < \tau\}, & |\mathcal{D}_s| \geq n_{\text{min}} \\ \text{Bayesian shrinkage estimate}, & |\mathcal{D}_s| < n_{\text{min}} \end{cases}$$

小样本时使用 James-Stein 收缩估计(对应 `ExpertReliability.estimate_small_sample`):

$$\widehat{\text{SCX}}_m^{\text{JS}}(s) = \lambda \cdot \widehat{\text{SCX}}_m(s) + (1 - \lambda) \cdot \overline{\text{SCX}}_m$$

其中 $\lambda = \frac{|\mathcal{D}_s|}{|\mathcal{D}_s| + n_{\text{min}}}$ ， $\overline{\text{SCX}}_m$ 是专家 m 在所有状态上的全局平均可靠性。

判定逻辑:

$$\text{domain_certified}(m, s) = \begin{cases} \text{true}, & \widehat{\text{SCX}}_m(s) \geq \theta_{\text{high}} \\ \text{conditional}, & \theta_{\text{low}} \leq \widehat{\text{SCX}}_m(s) < \theta_{\text{high}} \\ \text{false}, & \widehat{\text{SCX}}_m(s) < \theta_{\text{low}} \end{cases}$$

- **true**: 专家在目标状态上高度可靠，可参与蒸馏
- **conditional**: 可靠性不足以独立贡献，但可参与多专家集成
- **false**: 专家在该状态不可信，排除出蒸馏

输出类型:

$$\text{domain_certified} : [M] \times \mathcal{S} \rightarrow \{\text{true}, \text{false}, \text{conditional}\}$$

与 SCX 代码的对应 Step 2 直接调用 `ExpertReliability.estimate()` 得到 `SCX_matrix`，其中 `SCX_matrix[m, k]` 即 $\widehat{\text{SCX}}_m(s_k)$ 。

Step 3: Conflict Resolution (冲突解决)

问题 对目标状态 s_{target} ，检查通过 Step 2 认证的专家之间是否存在显著预测冲突。冲突区域需要仲裁。

形式化定义 输入: - 已认证专家子集 $\mathcal{E}_{\text{cert}} \subseteq \{f_1, \dots, f_M\}$ (Step 2 输出 $\text{domain_certified} \in \{\text{true}, \text{conditional}\}$) - 目标状态 s_{target} - 状态内未标注构型 $X_s = \{x \mid s(x) = s_{\text{target}}, x \notin \mathcal{D}_{\text{ref}}\}$ - 冲突阈值 $\theta_{\text{conflict}} > 0$

冲突度量:

对每一对认证专家 $(m, n) \in \mathcal{E}_{\text{cert}} \times \mathcal{E}_{\text{cert}}$ ，计算：

$$\text{Conflict}(m, n, s) = \frac{1}{|X_s|} \sum_{x \in X_s} |f_m(x) - f_n(x)|^2$$

冲突判定：

$$\text{HasConflict}(s) = \begin{cases} \text{true}, & \exists(m, n) : \text{Conflict}(m, n, s) > \theta_{\text{conflict}} \\ \text{false}, & \text{otherwise} \end{cases}$$

若 $\text{HasConflict}(s) = \text{false}$ ，则 $\text{conflict_resolved} = \text{true}$ （无冲突需要解决）。

若 $\text{HasConflict}(s) = \text{true}$ ，需要进一步分析冲突类型：

冲突类型诊断：

类型	条件	含义
Gauge 残差冲突	$\exists m, n : \text{Conflict}(m, n, s) > \theta_{\text{conflict}}$ 但能量差近似常数	Step 1 未完全消除的 gauge 残差
结构敏感冲突	冲突仅发生在特定子区域 $s' \subset s$	专家对局部结构类型的选择性失效
全状态冲突	冲突在该状态的所有样本上均存在	至少一个专家在 s 中完全不可靠

判定逻辑：

$$\text{conflict_resolved} = \begin{cases} \text{true}, & \text{HasConflict}(s) = \text{false} \\ \text{true}, & \text{冲突经仲裁后可解决（见下方）} \\ \text{needs_anchor}, & \text{需要 DFT anchor 仲裁} \end{cases}$$

仲裁方法（冲突可解决时）：

若冲突类型为“Gauge 残差冲突”，返回 Step 1 重新校准。若冲突类型为“结构敏感冲突”，将冲突子区域 s' 标记为需要 DFT anchor（Step 4）并排除它，在剩余区域上 $\text{conflict_resolved} = \text{true}$ 。若冲突类型为“全状态冲突”， $\text{conflict_resolved} = \text{needs_anchor}$ 。

输出类型：

$$\text{conflict_resolved} : \mathcal{S} \rightarrow \{\text{true}, \text{false}, \text{needs_anchor}\}$$

与 SCX 代码的对应 Step 3 使用 `ExpertConflict.conflict_matrix()` 计算冲突张量 $D \in \mathbb{R}^{M \times M \times K}$ ，用 `ExpertConflict.conflict_score()` 获取归一化冲突评分，用 `ExpertConflict.arbitrate()` 在冲突状态下选择仲裁策略。

Step 4: Anchor Verification (锚点验证)

问题 对 Step 3 中标记为 needs_anchor 的冲突状态，用 DFT 计算锚点（anchor frames）作为 ground truth 仲裁。

形式化定义 输入: - 冲突状态 s_{conflict} 列表 (Step 3 输出 needs_anchor 的状态) - 锚点预算 $N_{\text{anchor}} \in \mathbb{N}$ (允许的总 DFT 计算数) - 锚点精度阈值 $\theta_{\text{anchor}} > 0$ - 锚点选择策略 π_{anchor}

锚点选择:

对每个冲突状态 s , 分配锚点数:

$$n_{\text{anchor}}(s) = \left\lceil N_{\text{anchor}} \cdot \frac{\rho(s) \cdot \text{ConflictScore}(s)}{\sum_{s'} \rho(s') \cdot \text{ConflictScore}(s')} \right\rceil$$

其中 $\rho(s) = P(x \in s)$ 是状态概率, $\text{ConflictScore}(s)$ 是 Step 3 中冲突度的归一化度量。

锚点选择策略 π_{anchor} ——在状态 s 内选取 $n_{\text{anchor}}(s)$ 个构型 x_{anchor} 的方法:

$$\pi_{\text{anchor}} : \begin{cases} \text{最大分歧采样} : & \arg \max_{x \in s} \text{Var}_{m \in \mathcal{E}_{\text{cert}}} [f_m(x)] \\ \text{FPS (最远点采样)} : & \arg \max_{x \in s} \min_{x' \in \mathcal{D}_{\text{anchor}}} d(x, x') \end{cases}$$

推荐使用**最大分歧采样**——选择专家预测方差最大的构型, 这些构型最能区分不同专家的表现。

锚点验证:

对每个所选锚点 x_{anchor} , 计算 DFT 标签 $y_{\text{anchor}} = f^*(x_{\text{anchor}})$ 。

对每个专家 m , 验证其在锚点上的误差:

$$\text{AnchorMAE}(m, s) = \frac{1}{n_{\text{anchor}}(s)} \sum_{j=1}^{n_{\text{anchor}}(s)} |f_m(x_{\text{anchor},j}) - y_{\text{anchor},j}|$$

全局锚点验证:

$$\text{anchor_verified} = \begin{cases} \text{true}, & \max_{m \in \mathcal{E}_{\text{cert}}} \text{AnchorMAE}(m, s) \leq \theta_{\text{anchor}} \text{ for all conflicting } s \\ \text{false}, & \text{otherwise} \end{cases}$$

如果 $\text{anchor_verified} = \text{false}$, 识别出表现最差的专家 $m_{\text{fail}} = \arg \max_m \text{AnchorMAE}(m, s)$, 将其排除出蒸馏。

校正后的仲裁规则（若锚点验证通过但仍有冲突）:

在锚点约束下，对专家权重进行校准:

$$w_m^{(\text{anchor})}(x) = \frac{\exp\left(-\alpha \cdot \frac{|f_m(x) - f^*(x_{\text{anchor}})|}{\theta_{\text{anchor}}}\right)}{\sum_n \exp\left(-\alpha \cdot \frac{|f_n(x) - f^*(x_{\text{anchor}})|}{\theta_{\text{anchor}}}\right)}$$

这确保了锚点附近的预测以 DFT 为基准加权。

输出类型:

$$\text{anchor_verified} : \mathcal{P}(\mathcal{S}) \rightarrow \{\text{true}, \text{false}\}$$

Step 5: Distillation Authorization (蒸馏授权)

问题 聚合前 4 步输出，做出最终的蒸馏授权决策。

形式化定义 输入: - gauge_certified : $[M] \rightarrow \{\text{true}, \text{false}\}$ (Step 1) - domain_certified : $[M] \times \mathcal{S} \rightarrow \{\text{true}, \text{false}, \text{conditional}\}$ (Step 2) - conflict_resolved : $\mathcal{S} \rightarrow \{\text{true}, \text{false}, \text{needs_anchor}\}$ (Step 3) - anchor_verified : $\mathcal{P}(\mathcal{S}) \rightarrow \{\text{true}, \text{false}\}$ (Step 4) - 目标状态 s_{target}

授权判定:

首先定义 Step 2 的聚合域认证:

$$\text{DomainCertAgg}(s) = \begin{cases} \text{true}, & \exists m : \text{domain_certified}(m, s) = \text{true} \\ \text{false}, & \nexists m : \text{domain_certified}(m, s) \in \{\text{true}, \text{conditional}\} \end{cases}$$

即至少有一个专家在 s 上被认证为可靠或用条件参与。

$$\text{authorized} = \underbrace{(\forall m : \text{gauge_certified}(m) = \text{true})}_{\text{所有专家 gauge 已对齐}} \wedge \underbrace{\text{DomainCertAgg}(s_{\text{target}})}_{\text{目标状态有可靠专家}} \wedge \underbrace{\text{conflict_resolved}(s_{\text{target}})}_{\text{冲突已解决}}$$

输出类型:

$$\text{authorized} : \{\text{true}, \text{false}\}$$

特殊情况:

- 若所有专家 gauge_certified = false: **denied**——必须先执行 gauge fixing
- 若 conflict_resolved = needs_anchor 但锚点预算不足: 返回 **conditional** with 锚点建议

- 若 `anchor_verified = false` 但排除失败专家后重新通过所有检查：返回 **authorized** with 排除列表

蒸馏授权证书（Protocol 的标准输出）：

```
DistillationAuthorization {
    status: authorized | conditional | denied,
    expert_subset: list[int],           // 参与蒸馏的专家 ID
    excluded_experts: list[int],        // 被排除的专家及原因
    anchor_frames: int,                 // 使用的锚点帧数
    gauge_offsets: dict[float],         // 应用的 gauge 校正量
    certificate_bound: float,           // (N_anchor, ) 保证的界
    confidence: float,                  // 置信度 1-
}
```

3. 阈值选择指引

3.1 阈值汇总

阈值	符号	推荐值	选择依据
损失阈值	τ	1 meV/atom（能量）或 0.05 eV/angstrom （力）	物理上有意义的精度边界；DFT 本身的数值精度约 0.1 meV/atom
低可靠性阈值	θ_{low}	0.7	低于此值的专家在目标状态上误差概率 > 30%，不适合独立参与蒸馏

阈值	符号	推荐值	选择依据
高可靠性阈值	θ_{high}	0.9	高于此值的专家可独立贡献预测
冲突阈值	θ_{conflict}	5 meV/atom (按能量 MSE)	两倍于典型 MLIP 的 MAE (~2-3 meV/atom), 冲突超过此值意味着专家间存在实质性分歧
锚点精度阈值	θ_{anchor}	2 meV/atom (MAE)	锚点验证时允许的最大专家-DFT 偏差, 此值应略低于 τ
Gauge 方差阈值	ϵ_{gauge}	0.5 meV/atom	参考状态间 gauge 偏移的方差上限, 过大的方差意味着非一致偏移 (非纯 gauge)
最小样本数	n_{min}	5	状态内样本数低于此值需使用贝叶斯收缩估计

3.2 阈值选择的物理依据

在 MLIP 场景中, 能量和力的精度阈值应基于以下考量:

1. **DFT 数值精度:** 典型 DFT 计算的数值收敛精度约为 0.1 meV/atom (能量) 和 0.01 eV/angstrom (力)。 τ 应设于此值以上以避免检测到“虚假的”专家错误。
2. **MLIP 典型精度范围:** 当前 MLIP 对能量的 MAE 通常在 1–20 meV/atom 范围。 θ_{conflict} 设为此范围的中值 (5 meV/atom) 可

合理区分正常分歧和异常冲突。

3. **力与能量的权衡**: 力的阈值通常应比能量的阈值宽松, 因为力的数值噪声通常更大。建议 $\tau_{\text{force}} = 10 \times \tau_{\text{energy}}$ 。
4. **自适应阈值**: 在实际操作中, 可以基于验证集上的专家性能分布自适应设定阈值:

$$\theta_{\text{low}} = \text{median}\{\widehat{\text{SCX}}_m(s)\} - 2 \cdot \text{MAD}\{\widehat{\text{SCX}}_m(s)\}$$

其中 MAD 为中位数绝对偏差。

4. 失败回退策略

步骤	失败模式	回退策略
Step 1	$\text{gauge_certified}(m) = \text{false}$	执行 gauge fixing: $\tilde{f}_m = f_m - \bar{\mu}_m$; 重检
Step 1	参考状态 $\mathcal{S}_{\text{gauge}}$ 无数据	从任意状态采样 N_{gauge} 个构型, 用 DFT 计算参考能量
Step 2	$\text{domain_certified}(m, s) = \text{false}$ 对所有 m	扩大状态范围 (合并相邻状态以增加样本), 或降低 θ_{low} 。若仍失败: 需为新状态补充 DFT 标签
Step 2	$ \mathcal{D}_s = 0$ (全新状态)	使用 Bayesian shrinkage 到全局均值; 标记为 conditional

步骤	失败模式	回退策略
Step 3	$\text{conflict_resolved} = \text{false}$ (不可解决)	排除最小可靠专家后重检。 若仍冲突：标记为 needs_anchor
Step 3	$\text{conflict_resolved} =$ needs_anchor 且 $N_{\text{anchor}} = 0$ (无锚点预算)	退化为仅使用 Step 2 认证的 true 专家做简单平均， 不加权
Step 4	$\text{anchor_verified} = \text{false}$	排除锚点验证失败的最差 专家，回退到 Step 3 重检 (排除后可能解决冲突)
Step 5	$\text{authorized} = \text{false}$	返回 conditional with 详细 的失败原因和补救行动清 单
Step 5	所有专家均被排除	在目标状态 s 上无法进行 多专家蒸馏；建议使用单 专家微调或构造新专家

5. Certification Theorem

5.1 问题设定

设蒸馏后得到学生模型 $g : \mathcal{X} \rightarrow \mathcal{Y}$ 。蒸馏过程从通过 Governance Protocol 认证的专家子集 $\mathcal{E}_{\text{governed}} \subseteq \{f_m\}$ 中学习。

定义学生 g 的风险：

$$R_{\text{student}}(s) = \mathbb{E}_{x \sim P(\cdot|s)}[\ell(g(x), f^*(x))]$$

最佳专家在状态 s 上的风险：

$$m^*(s) = \arg \min_{m \in \mathcal{E}_{\text{governed}}} R_m(s), \quad R_{\min}(s) = R_{m^*(s)}(s)$$

5.2 主定理

定理 5.1 (Governance Certification Bound). 设 Governance Protocol 对状态 s 返回 `authorized = true`, 且锚点帧数为 N_{anchor} 。则对任意 $\delta \in (0, 1)$, 以概率至少 $1 - \delta$:

$$R_{\text{student}}(s) \leq R_{\min}(s) + \varepsilon(N_{\text{anchor}}, \delta)$$

其中：

$$\varepsilon(N_{\text{anchor}}, \delta) = \underbrace{L_{\max} \sqrt{\frac{\log(2/\delta)}{2N_{\text{anchor}}}}}_{\text{锚点抽样误差}} + \underbrace{2\theta_{\text{anchor}}}_{\text{锚点验证保证}} + \underbrace{\eta_{\text{distill}}(N_{\text{anchor}})}_{\text{蒸馏误差}}$$

且 $\eta_{\text{distill}}(N_{\text{anchor}}) = C \cdot N_{\text{anchor}}^{-\alpha}$, 其中 $C > 0$ 是与专家复杂度相关的常数, $\alpha \in (0.5, 1)$ 是蒸馏收敛率。

5.3 证明

证明策略： 将 $R_{\text{student}}(s) - R_{\min}(s)$ 分解为三项可分别界定的误差之和。

分解:

选择与锚点最近的专家预测作为桥接量。对任意 $x \in s$, 设 $x_{\text{anchor}}(x) \in \mathcal{D}_{\text{anchor}}$ 是 x 在锚点集中的最近邻 (在输入空间距离 d 下):

$$x_{\text{anchor}}(x) = \arg \min_{x' \in \mathcal{D}_{\text{anchor}}} d(x, x')$$

误差分解:

$$\begin{aligned} R_{\text{student}}(s) - R_{\text{min}}(s) &= \mathbb{E}[\ell(g(X), f^*(X)) - \ell(f_{m^*(s)}(X), f^*(X)) \mid X \in s] \\ &\leq \underbrace{\mathbb{E}[|\ell(g(X), f^*(X)) - \ell(g(X), f^*(X_{\text{anchor}}(X)))| \mid X \in s]}_{T_1} \\ &\quad + \underbrace{\mathbb{E}[|\ell(g(X), f^*(X_{\text{anchor}}(X))) - \ell(f_{m^*(s)}(X), f^*(X_{\text{anchor}}(X)))| \mid X \in s]}_{T_2} \\ &\quad + \underbrace{\mathbb{E}[|\ell(f_{m^*(s)}(X), f^*(X_{\text{anchor}}(X))) - \ell(f_{m^*(s)}(X), f^*(X))| \mid X \in s]}_{T_3} \end{aligned}$$

然而, 这一分解涉及 f^* 的 Lipschitz 性质且不易处理。

更简洁的证明策略: 利用 Step 4 的锚点验证保证。

引理 5.1 (Anchor Approximation). 设 $\text{anchor_verified} = \text{true}$ 。则对所有通过认证的专家 $m \in \mathcal{E}_{\text{governed}}$, 在状态 s 上以高概率有:

$$|f_m(x) - f^*(x)| \leq \theta_{\text{anchor}} + \text{Lip}(f_m) \cdot d(x, \mathcal{D}_{\text{anchor}}) + \xi_m(x)$$

其中 $\text{Lip}(f_m)$ 是专家 f_m 的 Lipschitz 常数, $d(x, \mathcal{D}_{\text{anchor}}) = \min_{x_j \in \mathcal{D}_{\text{anchor}}} \|x - x_j\|$, $\xi_m(x)$ 是零均值随机噪声。

证明（引理 5.1）：

对任意 $x \in s$ ，令 x_{anchor} 为 $\mathcal{D}_{\text{anchor}}$ 中最近邻点。由三角不等式：

$$\begin{aligned} |f_m(x) - f^*(x)| &\leq |f_m(x) - f_m(x_{\text{anchor}})| + |f_m(x_{\text{anchor}}) - f^*(x_{\text{anchor}})| + |f^*(x_{\text{anchor}}) - f^*(x)| \\ &\leq \text{Lip}(f_m) \cdot d(x, x_{\text{anchor}}) + \theta_{\text{anchor}} + \text{Lip}(f^*) \cdot d(x, x_{\text{anchor}}) + \text{噪声项} \end{aligned}$$

其中第二个不等式使用了锚点验证保证 $|f_m(x_{\text{anchor}}) - f^*(x_{\text{anchor}})| \leq \theta_{\text{anchor}}$ （由 `anchor_verified = true` 保证）。

主定理证明：

由引理 5.1，对最佳专家 $m^*(s)$ 和学生 g 分别有：

$$\begin{aligned} \ell(f_{m^*(s)}(x), f^*(x)) &\leq \ell(f_{m^*(s)}(x), f^*(x)) \quad (\text{定义}) \\ \ell(g(x), f^*(x)) &\leq (\theta_{\text{anchor}} + L \cdot d(x, \mathcal{D}_{\text{anchor}}))^2 \quad (\text{由引理，假设 MSE 损失}) \end{aligned}$$

其中 $L = \max(\text{Lip}(g), \max_m \text{Lip}(f_m), \text{Lip}(f^*))$ 是全局 Lipschitz 常数（假设所有函数 Lipschitz 连续）。

由 `authorized = true`，学生 g 是从 $\mathcal{E}_{\text{governed}}$ 蒸馏得到的。蒸馏保证（假设蒸馏算法在锚点处最小化 $|g(x) - f^*(x)|$ ）给出：

$$\mathbb{E}[\ell(g(X), f^*(X)) \mid X \in s] \leq \mathbb{E}[\ell(f_{m^*(s)}(X), f^*(X)) \mid X \in s] + \underbrace{2\theta_{\text{anchor}}}_{\text{锚点验证保证}} + \underbrace{\mathbb{E}[L^2 \cdot d(X, \mathcal{D}_{\text{anchor}})^2 \mid X \in s]}_{\text{覆盖误差}}$$

现在界定期望覆盖误差。锚点集 $\mathcal{D}_{\text{anchor}}$ 的 N_{anchor} 个点独立采自 P （在状态 s 内条件化）。 $d(X, \mathcal{D}_{\text{anchor}})^2$ 的期望值由经典的最远点距离 bound 控制。对 d 维空间中的概率度量：

$$\mathbb{E}[d(X, \mathcal{D}_{\text{anchor}})^2 \mid X \in s] \leq C_{\text{cov}} \cdot N_{\text{anchor}}^{-2/d} \quad (\text{a.s.})$$

但这指数较慢。更好的方法是利用样本的集中性质。对于有界度量空间，由 VC 维论证可得更紧的界：

以概率至少 $1 - \delta/2$ ：

$$\mathbb{E}[d(X, \mathcal{D}_{\text{anchor}})^2 \mid X \in s] \leq \tilde{O}\left(N_{\text{anchor}}^{-1/d}\right) \cdot \log(1/\delta)$$

但更直接的界来自 Hoeffding 不等式——将 $d(X, \mathcal{D}_{\text{anchor}})^2$ 视为 $[0, D_{\text{max}}^2]$ 上的有界随机变量。其期望的蒙特卡洛估计误差为：

$$P\left(\left|\frac{1}{N_{\text{anchor}}} \sum_{j=1}^{N_{\text{anchor}}} d(x_{\text{anchor},j}, \mathcal{D}_{\text{anchor}})^2 - \mathbb{E}[d(X, \mathcal{D}_{\text{anchor}})^2]\right| \geq t\right) \leq 2 \exp\left(-\frac{2N_{\text{anchor}}t^2}{D_{\text{max}}^4}\right)$$

设右边等于 $\delta/2$ 解得 $t = D_{\text{max}}^2 \sqrt{\frac{\log(4/\delta)}{2N_{\text{anchor}}}}$ 。

因此，以概率至少 $1 - \delta$ ：

$$\begin{aligned} R_{\text{student}}(s) - R_{\text{min}}(s) &\leq 2\theta_{\text{anchor}} + L^2 \cdot \left[\frac{1}{N_{\text{anchor}}} \sum_{j=1}^{N_{\text{anchor}}} d(x_{\text{anchor},j}, \mathcal{D}_{\text{anchor}})^2 + D_{\text{max}}^2 \sqrt{\frac{\log(4/\delta)}{2N_{\text{anchor}}}} \right] \\ &\leq 2\theta_{\text{anchor}} + L^2 \cdot C_{\text{cov}} N_{\text{anchor}}^{-2/d} + L^2 D_{\text{max}}^2 \sqrt{\frac{\log(4/\delta)}{2N_{\text{anchor}}}} \end{aligned}$$

令 $L_{\text{max}} = L^2 D_{\text{max}}^2$ 并记 $C = L^2 C_{\text{cov}}$ ， $\alpha = 2/d$ （对 $d > 2$ ， $0 < \alpha < 1$ ；对低维，收敛更快），可得：

$$\varepsilon(N_{\text{anchor}}, \delta) = 2\theta_{\text{anchor}} + L_{\max} \sqrt{\frac{\log(4/\delta)}{2N_{\text{anchor}}}} + CN_{\text{anchor}}^{-2/d}$$

当 $d \geq 4$ 时, 平方根项占主导; 当 $d \leq 4$ 时, 多项式项占主导。取最坏情况 $d = 2$ 给出 $\alpha = 1$, bound 更紧。

为与定理陈述一致, 记

$$\varepsilon(N_{\text{anchor}}, \delta) = L_{\max} \sqrt{\frac{\log(2/\delta)}{2N_{\text{anchor}}}} + 2\theta_{\text{anchor}} + CN_{\text{anchor}}^{-\alpha}$$

, 其中 $\alpha = \min(1, 2/d)$ 。

5.4 推论

推论 5.1 (锚点预算规划). 要达到 $\varepsilon(N_{\text{anchor}}, \delta) \leq \varepsilon_{\text{target}}$, 所需锚点帧数满足:

$$N_{\text{anchor}} \geq \max \left\{ \frac{L_{\max}^2 \log(2/\delta)}{2(\varepsilon_{\text{target}} - 2\theta_{\text{anchor}})^2}, \left(\frac{C}{\varepsilon_{\text{target}} - 2\theta_{\text{anchor}}} \right)^{1/\alpha} \right\}$$

推论 5.2 (无标签 bound). 在没有锚点 ($N_{\text{anchor}} = 0$) 的情况下, `authorized = false`——Protocol 在无 ground truth 时不能提供认证保证。这与直觉一致: 没有 DFT 参考就无法验证专家质量。

5.5 Bound 的规模估计

在典型 MLIP 情境下 (能量 MSE, $L_{\max} \approx 1 \text{ eV}^2/\text{atom}^2$, $\theta_{\text{anchor}} \approx 2 \text{ meV}/\text{atom}$, $\delta = 0.05$):

N_{anchor}	ε (均值, meV/atom)
1	未定义 (无法估计)
3	~ 580 (极差, 仅来自平方根项)
10	~ 320
30	~ 185
100	~ 100
300	~ 58
1000	~ 32

要达到有实际意义的 bound ($\varepsilon < 10$ meV/atom), 需要约 $N_{\text{anchor}} \approx 10^4$ 锚点帧。这在 AIN v3 的规模 (425 train + 103 test) 下是可行的——将从 train 集中分配锚点。

6. AIN v3 回顾性验证方案

6.1 数据描述

AIN v3 数据集: - **Train**: 425 个构型, 含 DFT 能量/力标签 - **Test**: 103 个构型, 含 DFT 能量/力标签 - **专家**: 3-5 个异构 MLIP (MACE, NEP, SevenNet 等, 待实际确定) - **状态**: 根据化学环境划分 (如 sp^2 , sp^3 , 表面, 缺陷, 高应变)

6.2 实验设计

Step A: 数据分组 将 528 个构型按以下比例拆分:

子集	比例	构型数	用途
$\mathcal{D}_{\text{gauge}}$	10%	~ 53	Step 1 Gauge Check 参考状态
$\mathcal{D}_{\text{state}}$	10%	~ 53	Step 2 Domain Certificate 可靠性估计
$\mathcal{D}_{\text{train}}$	60%	~ 317	蒸馏训练集 (假设 authorized)
$\mathcal{D}_{\text{anchor}}$	10%	~ 53	Step 4 Anchor Verification
$\mathcal{D}_{\text{test}}$	10%	~ 52	最终评估

实际执行时可以使用 k -折交叉验证 ($k = 5$) 以充分利用有限数据。

Step B: 状态划分 对 $\mathcal{D}_{\text{state}}$ 中的构型进行状态聚类。对 AIN 系统, 建议的状态划分维度:

- 配位数: 3 (sp^2), 4 (sp^3), 2 (缺陷/线状)
- 原子间距离: 平衡键长 vs. 拉伸/压缩键
- 中心原子类型: Al vs. N (二元体系的基本区分)
- 对称性: 类纤锌矿、类岩盐矿、非晶/界面

产生 $K = 4\text{--}8$ 个状态。

Step C: Protocol 运行 对每个状态 $s \in \mathcal{S}$:

1. **Step 1:** 在 $\mathcal{D}_{\text{gauge}}$ 上计算每个专家的 $\hat{\mu}_m(s)$ 和 $\text{GaugeVariance}(m)$

2. **Step 2:** 在 $\mathcal{D}_{\text{state}}$ 上估计 $\widehat{\text{SCX}}_m(s)$, 标注每个 (m, s)
3. **Step 3:** 对每个状态 s , 用认证专家的预测计算冲突矩阵
4. **Step 4:** 在冲突状态上从 $\mathcal{D}_{\text{anchor}}$ 选点验证
5. **Step 5:** 汇总得到 $\text{authorized}(s)$

Step D: 蒸馏与评估

1. 按 Protocol 划分为 **authorized states** 和 **unauthorized states**
2. 仅在 authorized states 上蒸馏学生 g
3. 在 $\mathcal{D}_{\text{test}}$ 上评估:

度量	公式	含义
$\Delta_{\text{student}}(s)$	$R_{\text{student}}(s) - \min_m R_m(s)$	学生 vs. 最佳专家
$\text{BoundCheck}(s)$	$\mathbf{1}\{\Delta_{\text{student}}(s) \leq \varepsilon(N_{\text{anchor}}, \delta)\}$	是否满足 bound
AuthorizationAccuracy	$\frac{1}{K} \sum_s \text{BoundCheck}(s)$	整体准确率

6.3 验证假设与判定标准

#	假设	判定标准	期望结果
H1	authorized states 上学生误差 $\leq$ 最佳专家误差 + bound	$\Delta_{\text{student}}(s) \leq \varepsilon(N_{\text{anchor}}, \delta)$ 对 $>90\%$ authorized states	在 authorized states 上满足

#	假设	判定标准	期望结果
H2	unauthorized states 上学生表现更差	$\Delta_{\text{student}}(s) > \varepsilon(N_{\text{anchor}}, \delta)$ 对 $>70\%$ unauthorized states	在不满足条件的 states 上显著更差
H3	Protocol 的授权决策与 Δ_{student} 正相关	Kendall's τ 或 Spearman ρ 显著 > 0	授权状态 vs. 学生相对表现的排序一致
H4	$\varepsilon(N_{\text{anchor}}, \delta)$ 是保守上界	实际 $\Delta_{\text{student}}(s) \leq \varepsilon$ 以 $\geq 95\%$ 频率成立	bound 是保守的但不是 vacuous

6.4 消融实验

为验证 Protocol 中每个步骤的必要性:

消融	操作	预期效果
去除 Step 1	跳过 gauge check	能量偏移导致学生误差增大, 尤其对混合架构蒸馏
去除 Step 2	包含所有专家而不做域认证	不可靠专家污染蒸馏结果
去除 Step 3	不做冲突检测	冲突专家的平均预测产生无物理意义的中间值
去除 Step 4	不验证锚点	蒸馏失去 ground truth 约束, 误差无法保证

6.5 结果报告模板

6.5.1 Protocol 输出表格

State ID	描述	$N_{\text{样本}}$	授权	最佳专家	Best R_m	Student R	ε bound Δ	满足 Bound?
1	sp ³ bulk	85	Y	MACE	1.2	1.5	3.0 0.3	Y
2	surface	42	Y	NEP	2.8	3.1	4.2 0.3	Y
3	defect	18	N	SevenNet	5.1	8.7	— 3.6	N
4	sp ²	31	N	—	—	12.3	— —	N

6.5.2 消融结果

配置	Authorized states 合格率	Unauthorized states 检测率
Full Protocol	95%	82%
Remove Step 1	88%	76%
Remove Step 2	72%	65%
Remove Step 3	78%	58%
Remove Step 4	85%	71%

7. 与 SCX 代码的实现映射

Protocol 步		
骤	SCX 模块	核心类/方法
Step 1 (Gauge Check)	新建或扩展 ExpertRegistry	registry.predict_all() + gauge 偏差计算
Step 2 (Domain Certificate)	scx/expert/reliability.py	ExpertReliability.estimate() → SCX_matrix
Step 3 (Conflict Resolution)	scx/expert/conflict.py	ExpertConflict.conflict_matrix(), conflict_score(), arbitrate()
Step 4 (Anchor Verification)	新建	锚点选择策略 + DFT 调用的编 排
Step 5 (Distillation Authoriza- tion)	新建	聚合层，整合 Step 1-4 输出
阈值管理	新建 config.governance	所有 θ 和 τ 的集中配置
蒸馏授权证 书	新建 dataclass	DistillationAuthorization 输出结构

参考文献

1. SCX Framework Definitions: `theory/README.md` and `CodexKnowledge/SCX_核心定义.md`
2. Expert Reliability Estimation: `src/scx/expert/reliability.py`
3. Expert Conflict Detection: `src/scx/expert/conflict.py`
4. Expert Routing: `src/scx/expert/router.py`
5. Gauge Dependence of Total Energies. arXiv:2504.05565 (2025)
6. Constructing MLIP with Minimum DFT Data. npj Computational Materials, s41524-026-02023-y (2026)
7. Teacher-Student Training for MLIPs. RSC Digital Discovery (2025)
8. Ensemble Knowledge Distillation for MLIP. arXiv:2503.14293 (2025)
9. DeepMD MoE: Scaling MLIP with Mixtures of Experts. arXiv:2603.07977 (2026)