

Proposition 6: Error-Driven State Discovery

最优状态划分不是由人类预设的，而是在误差相关特征子空间中自动发现的。状态应由”模型在哪里失败”来定义，而非”人类觉得什么重要”。

1 Statement

1.1 正式陈述

最优状态划分 $\mathcal{S}^*$ 不是由人类预设的，而是在误差相关特征子空间中自动发现的。

具体地，给定 Layer 1 编码 φ_1 和 residual vector r ，状态应该在与 r 最相关的 φ_1 维度子集中聚类：

$$\mathcal{S}^* = \text{Cluster}(\varphi_1[:, \text{top_dims}], K)$$

其中：

$$\text{top_dims} = \text{argsort}(\text{MI}(\varphi_1[:, j], r))$$

即选择与残差 r 互信息最大的 φ_1 维度子集作为聚类空间。

1.2 两层描述符体系

第一层描述符（研究人员提供）：材料的”身份标签” - 元素种类、化学计量比、晶体结构 - 温度/压力范围、结构类型（bulk/surface/defect/interface） - 这些描述符定义了**初始采样空间**

第二层描述符（算法发现）：误差分析揭示的失败模式 - 配位数 (CN)、最大键拉伸、局域应变 - sp2/sp3 比例、原子位移范数、局部配位变化 - ACE basis 残差分量、力误差的角向分布 - 这些描述符**不是**研究人员手动指定的——由算法在误差分析阶段自动计算、筛选、组合

1.3 核心思想

人类定义的描述符可能不捕捉模型的真实失败模式。

状态应该由”模型在哪里失败”来定义，而非”人类觉得什么重要”。

2 Formal Statement

2.1 数学形式化

令 $\varphi_1(x)$ 为 Layer 1 编码（如 SCXStateEncoder 的嵌入输出）， $r(x) = |f_{\text{model}}(x) - f_{\text{true}}(x)|$ 为残差。

定义 error-relevant subspace:

$$D^* = \{j : \text{MI}(\varphi_1[:, j], r) > \tau\}$$

即在第一层编码的各维度中，与残差 r 的互信息超过阈值 τ 的维度索引集。

则在 D^* 上的聚类 $\mathcal{S}^*$ 满足：

$$\mathbb{E}[\text{Var}(r \mid s \in \mathcal{S}^*)] \leq \mathbb{E}[\text{Var}(r \mid s \in \mathcal{S}_{\text{human}})]$$

即 error-driven states 的组内残差方差不超过人类定义状态的组内残差方差。

2.2 算法 workflow

Phase A: 初始训练

输入：第一层描述符定义的初始 DFT 数据集 D

过程：训练 Single ACE baseline M

输出： M ，测试集误差分布

Phase B: 误差景观分析

输入： M ，测试集

过程：

1. 对每个测试结构计算 per-atom force error 和 per-structure error
2. 为每个原子计算候选第二层描述符：
 - CN（不同截断半径）、最大/平均键拉伸
 - 局域应变张量不变量、键角分布统计
 - Voronoi 体积、ACE basis 各分量贡献
3. 用互信息 / SHAP / permutation importance 筛选与误差最相关的描述符
4. 在选中的描述符空间中做 UMAP/PCA 降维
5. HDBSCAN 聚类发现误差簇

输出：

- 误差簇地图 (`cluster_id` → 描述符范围 → 平均误差 → 样本数)
- 高误差区域的定义 (描述符空间中的凸包或区间)

Phase C: 结构建议

输入：高误差区域定义

过程：

1. 在高误差描述符区域中生成候选结构
2. 去重 (与已有训练集比较结构指纹)
3. 排序 (优先添加误差最大、信息量最大的结构)

输出：结构建议文件 + 预期误差改善估计

Phase D: 迭代增强

输入：新增 DFT 数据 `D_new`

过程：

1. 合并 $D = D_{old} \cup D_{new}$
2. 重新训练或增量训练
3. 回到 Phase B 重新评估误差景观
4. 如果出现新的高误差簇 → Phase C
5. 如果误差景观平坦化 → 结束

Phase E (可选) : Expert 化

输入：最终的误差簇定义

过程：

1. 每个误差簇自动定义一个 `expert domain`
 2. 为每个 `domain` 训练 `residual expert`
 3. 用 `Expert Algebra` 管理 `expert` 模块
 4. 导出为可部署的势函数
-

3 Theorem: Error-Driven States Dominate Human-Defined States

定理 6.1 (误差驱动状态的优势): 令 $\mathcal{S}_{\text{human}}$ 为由人类先验知识定义的状态划分 (如按晶体结构、化学组分等分类), $\mathcal{S}^*$ 为通过误差驱动发现的状态划分。在相同的状态数 $K = |\mathcal{S}|$ 下:

$$\mathbb{E}_{s \sim \mathcal{S}^*}[\text{Var}(r \mid s)] \leq \mathbb{E}_{s \sim \mathcal{S}_{\text{human}}}[\text{Var}(r \mid s)]$$

证明概要: 由互信息的数据处理不等式, 误差相关子空间 D^* 保留了最多关于 r 的信息。K-means 或 HDBSCAN 在 D^* 上的聚类目标等价于最小化组内方差:

$$\min_{\mathcal{S}} \sum_{s \in \mathcal{S}} \sum_{x \in s} \|\varphi_1(x)[D^*] - \mu_s\|^2$$

而 $\mathcal{S}_{\text{human}}$ 是在原始空间 φ_1 (可能包含与 r 无关的维度) 上定义的。因此 $\mathcal{S}^*$ 在 r 上的条件方差至少不劣于 $\mathcal{S}_{\text{human}}$ 。□

4 Connection to SCX Core

4.1 架构映射

- **Layer 1** = SCXStateEncoder.encode() — 初始嵌入映射
- **Layer 2** = ErrorDrivenEncoder.fit_error_states() — 误差条件状态发现
- **两层整合** = TwoLayerStateDiscovery — 完整的自动状态发现管线

4.2 为什么一层 encoder 不够

单纯的一层 encoder（如 12 维 MLIP encoder）的失败原因：

1. **通用嵌入与误差无关**：预训练嵌入可能编码了大量与专家失败模式无关的全局结构信息
2. **固定维度容量有限**：12 维嵌入可能无法同时编码化学环境信息和误差模式信息
3. **缺乏误差反馈**：没有将误差信号反向传播到状态构造过程

两层描述符体系通过误差条件投影解决了这些问题。

4.3 与信息瓶颈的关系

两层状态发现对应于**条件信息瓶颈**的迭代求解：

$$\min_{\Pi} I(\varphi_1; \tilde{X} \mid \mathcal{F}) - \beta I(\tilde{X}; r \mid \mathcal{F})$$

其中 $\mathcal{F} = \{f_1, \dots, f_M\}$ 为专家集合， r 为残差， $\tilde{X}$ 为状态表示。

5 Implications

1. **状态划分不是固定的**——随模型改进而演化。随着模型误差景观变平坦，状态边界需要重新定义。
2. **第二层描述符 = 第一层特征的 error-conditioned subset**——自动筛选出与模型失败最相关的特征维度，排除无关的”背景”维度。

3. 这使 SCX 区别于所有基于人类特征的聚类方法:
- 传统方法: 研究人员定义状态 (“bulk”, “surface”, “defect”), 但这些可能不反映模型的真实失败模式
 - SCX + 两层描述符: 算法从误差分布中自动发现状态
4. 专家分区的涌现性: 专家分区不应由人凭经验定义, 而应由算法从误差分布中涌现。
5. 与 Expert Governance Protocol 的整合:
- 两层描述符框架 (上层: 自动发现 expert 边界)

Expert Algebra 框架 (下层: 管理 expert 模块)

6 关键验证实验

实验	假设	成功标准
Error vs CN	CN<3.5 区域误差 > CN 4 区域	p<0.01, effect size>2x
Error vs bond stretch	stretch>10% 区域 误差显著增大	p<0.01
描述符分离度	不同 batch 在描述符空间中可分离	silhouette score > 0.3
Targeted vs uniform	error-guided 采样 用更少 DFT 达到同精度	等预算下 RMSE 降低 > 20%

实验	假设	成功标准
自动 expert vs 手动 expert	算法发现的 expert 分区不差于手动	等 expert 数下 metrics 相当

参考文献

1. EGP 两层描述符框架. EGP_ 两层描述符 _ 算法驱动专家分区 _2026-06-24.md
2. Tishby, N., Pereira, F. C., & Bialek, W. (1999). The information bottleneck method. *Allerton Conference*.
3. Gauge-Normalized Residual ACE Expert Algebra Framework. CodexKnowledge/
4. SCX State-Conditioned eXpertise 核心框架. 01_SCX_ 核心框架 _ 数学分析.md