

Multi-Head Spring 与 Physical Positional Encoding 的严格数学分析

对 SCX 框架定理基础的诚实审查

文档状态: 完整分析

依赖: Theorem 1-4 (theory/theorems/), SE-1, SE-2 (theory/self_evolution/)

方法论: 严格形式推导 + 诚实暴击 (不委婉)

0. 符号约定与框架重构

在进入分析之前, 我们先精确地重构 SCX 框架的数学基础。以下所有定义均从 prompt 中的定理描述严格形式化。

0.1 状态结晶 (State Crystallization)

设原始物理观测空间为 $\mathcal{X} \subset \mathbb{R}^{d_{\text{raw}}}$ (连续物理量: PBE 能量面、力场、电子密度等)。State Crystallization 是一个映射:

$$\mathcal{C} : \mathcal{X} \rightarrow \mathcal{S} = \{s_1, \dots, s_N\}$$

其中每个 $s_i \in \mathbb{R}^{d_s}$ 是一个离散状态原子的向量表示。与 BPE 的统计驱动不同, $\mathcal{C}$ 是物理驱动的: 它根据 PBE 能量面的自然曲率边界进行聚类。形式上有:

$s_i = \mathcal{C}(x)$ 其中 $x \in \mathcal{X}$ 且 $\nabla^2 E_{\text{PBE}}(x)$ 在 x 处有一个谱间隙

0.2 雅洁审计 (Yajie Audit)

设有 M 个独立专家模型 $\{E_1, \dots, E_M\}$ 。对于状态原子 s_i 及其标签 y_i ，定义：

$$c_m(s_i) = \mathbf{1}[E_m(s_i) \neq y_i] \quad (\text{专家 } m \text{ 不同意给定标签})$$

一致性计数：

$$C(s_i) = \sum_{m=1}^M c_m(s_i) \sim \text{Binomial}(M, p_{s_i})$$

其中 p_{s_i} 是专家”不同意”标签的概率。对于干净样本， $p_{s_i} = p_{\text{clean}} < 0.5$ ；对于噪声样本， $p_{s_i} = p_{\text{noisy}} > 0.5$ 。

Cercis Score:

$$S(s_i) = Q(s_i) + \eta(t) \cdot N(s_i)$$

其中 $Q(s_i)$ 是基础质量分（基于多专家一致性）， $N(s_i)$ 是新奇性奖励， $\eta(t)$ 是时间衰减探索权重。

0.3 Spring 自进化动力学

状态转移：

$$(S_t, \theta_t, M_t) \rightarrow (S_{t+1}, \theta_{t+1}, M_{t+1})$$

Spring 自注意力形式（单头）：

$$\text{Spring}(s_i, \mathcal{S}) = \text{softmax} \left(\frac{(Qs_i)(K\mathcal{S})^T}{\sqrt{d_k}} \right) \cdot (V\mathcal{S})$$

其中 $Q, K \in \mathbb{R}^{d_k \times d_s}$, $V \in \mathbb{R}^{d_v \times d_s}$ 。

1. 核心定理的精确定理陈述

Theorem 1（多专家一致性噪声检测）

$$F_1 \geq 1 - \frac{1}{\eta} \sum_{s \in \mathcal{S}} \rho_s \cdot \exp(-2M\Delta_s^2)$$

其中：- $\rho_s = |\{i : \mathcal{C}(x_i) = s\}| / N_{\text{total}}$ ：状态原子 s 的占比 - $\Delta_s = |p_{\text{clean},s} - p_{\text{noisy},s}|$ ：状态 s 的检测边际 - M ：独立专家数量 - $\eta > 0$ ：归一化因子

证明技术：Chernoff bound + Hoeffding 不等式。对每个状态 s ， $C(s)$ 是两个二项分布的混合。标记为噪声当 $C(s) \geq \tau_s$ 。Chernoff 给出：

$$P(\text{假阳性}) = P_{H_0}(C(s) \geq \tau_s) \leq \exp(-2M(\tau_s/M - p_{\text{clean},s})^2)$$

$$P(\text{假阴性}) = P_{H_1}(C(s) < \tau_s) \leq \exp(-2M(p_{\text{noisy},s} - \tau_s/M)^2)$$

选取 $\tau_s = M \cdot (p_{\text{clean},s} + p_{\text{noisy},s})/2$ 使两项平衡，得到 Δ_s 。

Theorem 2 (弱特征必然失效)

$$F_{1,\text{SCX}} \leq F_{1,\text{base}} + C_F \cdot \sqrt{\frac{\delta}{2}}$$

其中 $\delta > 0$ 刻画特征空间的信息不足程度。

证明技术：Fano 不等式。定义 $\delta = \min_f \mathbb{E}[\mathbf{1}[f(X) \neq Y]] - \text{Bayes error}$ ，即最优可行分类器与贝叶斯最优之间的最小差距。Fano 给出条件熵与错误率的关系：

$$P_e \geq \frac{H(Y|X) - 1}{\log |\mathcal{Y}|}$$

当 $H(Y|X)$ 较大（特征弱），任何方法（包括 SCX）的错误率下界由 δ 决定。

Theorem 3 (噪声与困难样本的不可区分性)

构造性双世界证明：存在两个世界 W_A, W_B ，具有观测等价的数据分布 $P_{W_A}(X, Y) = P_{W_B}(X, Y)$ ，但：

- 世界 W_A ：样本 (x, y) 是被错误标记的（标签噪声）
- 世界 W_B ：样本 (x, y) 正确标记但本质上困难（高贝叶斯不确定性）

没有算法能够仅通过观测数据区分这两个世界。

形式化： $\forall$ 决策规则 $d: (\mathcal{X} \times \mathcal{Y})^n \rightarrow \{W_A, W_B\}$,

$$\max_{W \in \{W_A, W_B\}} P_W(d(\text{data}) \neq W) \geq \frac{1}{2} - \frac{1}{2} \|P_{W_A}^{\otimes n} - P_{W_B}^{\otimes n}\|_{\text{TV}} = \frac{1}{2}$$

因为 $P_{W_A}^{\otimes n} = P_{W_B}^{\otimes n}$ （完全相同的观测分布）。

Theorem 4 (精确常数 Minimax 最优)

SCX 的噪声检测错误率在以下意义上达到精确常数最优：

$$\lim_{M \rightarrow \infty} -\frac{1}{M} \log P_{\text{FN}}^{(M)} = D_{\text{KL}}(P_{\text{noisy}} \| P_{\text{clean}}) \quad \text{subject to } P_{\text{FP}}^{(M)} \leq \alpha$$

且 Bahadur-Rao 展开给出的 $O(1/\sqrt{M})$ 修正项也匹配 minimax 下界。

证明技术： Chernoff-Stein 引理 + Bahadur-Rao 展开。

2. 组件 1：Physical Positional Encoding (PPE) 的数学分析

2.1 形式化定义

设每个状态原子 s_i 带有一个物理位置 $p_i \in \mathcal{P}$ ，其中： - 蛋白质序列： $\mathcal{P} = \mathbb{N}$ (残基索引) - 3D 结构： $\mathcal{P} = \mathbb{R}^3$ (原子坐标) - Docking： $\mathcal{P} = \mathbb{R}^3$ (结合口袋坐标)

定义 1 (Physical Positional Encoding)： PPE 是一个映射

$$\text{PE} : \mathcal{P} \rightarrow \mathbb{R}^{d_{\text{pe}}}$$

编码后的状态表示：

$$h_i = \phi(s_i) + \text{PE}(p_i)$$

其中 $\phi : \mathbb{R}^{d_s} \rightarrow \mathbb{R}^d$ 是特征映射，且我们要求 $d_{\text{pe}} = d$ 。

可选方案（拼接 + 投影）：

$$h_i = W \cdot [\phi(s_i); \text{PE}(p_i)]$$

其中 $W \in \mathbb{R}^{d \times (d+d_{\text{pe}})}$ 。数学上这是更一般的方案，但加法方案更简洁且在 $W = [I_d, I_d]$ 时退化为加法。以下分析以加法方案为主，结果可推广。

2.2 编码函数的具体形式

标量位置的正弦编码（类比 Transformer）：

$$\text{PE}(p, 2j) = \sin\left(\frac{p}{10000^{2j/d}}\right), \quad \text{PE}(p, 2j+1) = \cos\left(\frac{p}{10000^{2j/d}}\right)$$

其中 $j = 0, 1, \dots, d/2 - 1$ 。

3D 位置的旋转编码（类比 RoPE，适配物理空间）：

$$\text{PE}_{\text{rot}}(\mathbf{p}) = \mathbf{R}(\mathbf{p}) \cdot \mathbf{e}_0$$

其中 $\mathbf{R}(\mathbf{p}) \in SO(d)$ 是由坐标参数化的旋转矩阵。对于 $\mathbf{p} = (x, y, z)$ ：

$$\mathbf{R}(\mathbf{p}) = \mathbf{R}_x(\omega_x x) \cdot \mathbf{R}_y(\omega_y y) \cdot \mathbf{R}_z(\omega_z z)$$

其中 $\mathbf{R}_\alpha(\theta)$ 是在 α 轴上的 d 维旋转， $\omega_x, \omega_y, \omega_z$ 是可学习或固定的频率参数。

关键性质：与 NLP 的位置编码不同，物理位置具有**多维几何结构**。一个好的 PPE 应尊重物理对称性：

1. **平移等变性**（对 3D 结构）： $\text{PE}(\mathbf{p} + \mathbf{t})$ 与 $\text{PE}(\mathbf{p})$ 有可预测的关系
2. **旋转等变性**： $\text{PE}(\mathbf{R}\mathbf{p})$ 可以通过旋转编码空间来恢复
3. **Lipschitz 连续性**： $\|\text{PE}(\mathbf{p}) - \text{PE}(\mathbf{q})\| \leq L_{\text{PE}} \cdot \|\mathbf{p} - \mathbf{q}\|$

2.3 对 Theorem 1 的影响

核心问题： PPE 如何改变检测边际 Δ_s ?

命题 2.1 (PPE 下的修改后检测边际)： 在 PPE 增强的特征空间中，状态 s 的有效检测边际为：

$$\Delta_s^{\text{PPE}} = \Delta_s + \delta_s^{\text{PE}}$$

其中 $\delta_s^{\text{PE}} \in [-\Delta_s, 1 - p_{\text{clean},s} - \Delta_s]$ 满足：

$$\delta_s^{\text{PE}} = \underbrace{(p_{\text{clean},s}^{\text{PPE}} - p_{\text{clean},s})}_{\text{干净样本上的一致性增益}} - \underbrace{(p_{\text{noisy},s}^{\text{PPE}} - p_{\text{noisy},s})}_{\text{噪声样本上的混淆增益}}$$

证明： 在增强空间中，专家的预测概率变为 $p_{\text{clean},s}^{\text{PPE}} = \mathbb{E}[\mathbf{1}[E_m(h_i) = y_i] | H_0]$ 和 $p_{\text{noisy},s}^{\text{PPE}} = \mathbb{E}[\mathbf{1}[E_m(h_i) \neq y_i] | H_1]$ 。检测边际定义为 $\Delta_s^{\text{PPE}} = |p_{\text{clean},s}^{\text{PPE}} - (1 - p_{\text{noisy},s}^{\text{PPE}})| = |p_{\text{clean},s}^{\text{PPE}} + p_{\text{noisy},s}^{\text{PPE}} - 1|$ 。展开即得。□

定理 2.1 (PPE 下的 F1 下界)：

$$F_1^{\text{PPE}} \geq 1 - \frac{1}{\eta} \sum_{s \in \mathcal{S}} \rho_s \cdot \exp(-2M(\Delta_s + \delta_s^{\text{PE}})^2)$$

Chernoff-Hoeffding 不等式的**有效性不变**（指示变量仍在 $[0, 1]$ 内有界），但常数变化。

当 $\delta_s^{\text{PE}} > 0$ 对所有 s （PPE 总是帮助检测）：

$$F_1^{\text{PPE}} - F_1 \geq \frac{1}{\eta} \sum_s \rho_s [\exp(-2M\Delta_s^2) - \exp(-2M(\Delta_s + \delta_s^{\text{PE}})^2)] \geq 0$$

命题 2.2 (空间局部性正则化)： 若 PE 满足 Lipschitz 条件（Lipschitz 常数为 L_{PE} ），且专家模型 E_m 对其输入满足 L_E -Lipschitz，则对任意两个具有物理位置 p_i, p_j 的状态原子：

$$|\delta_i^{\text{PE}} - \delta_j^{\text{PE}}| \leq 2L_E \cdot L_{\text{PE}} \cdot \|p_i - p_j\|$$

证明：专家一致性概率的变化受输入变化约束：

$$\begin{aligned}
 |p_{\text{clean},i}^{\text{PPE}} - p_{\text{clean},j}^{\text{PPE}}| &\leq \mathbb{E}_E |\mathbf{1}[E(h_i) = y] - \mathbf{1}[E(h_j) = y]| \\
 &\leq \mathbb{E}_E [L_E \cdot \|h_i - h_j\|] \\
 &= L_E \cdot \|\text{PE}(p_i) - \text{PE}(p_j)\| \quad (\text{因为 } s_i = s_j = s) \\
 &\leq L_E \cdot L_{\text{PE}} \cdot \|p_i - p_j\|
 \end{aligned}$$

同样对 p_{noisy} 成立。两者的差得到因子 2。□

这意味着物理上邻近的状态原子具有相似的检测难度——一个可验证的预测。

2.4 对 Theorem 2 的影响

核心问题：不完美的 PPE 如何改变特征弱点的界？

定义 2（编码不完美度 ε_{PE} ）：

$$\varepsilon_{\text{PE}} = I(Y; P|X) - I(Y; \text{PE}(P)|X) \geq 0$$

其中 $I(Y; P|X)$ 是物理位置 P 在给定原始特征 X 下关于标签 Y 的条件互信息，而 $I(Y; \text{PE}(P)|X)$ 是编码后保留的信息。 ε_{PE} 量化了位置信息在编码过程中的丢失。

定理 2.2（不完美 PPE 下的失效上界）：

$$F_{1,\text{SCX}}^{\text{PPE}} \leq F_{1,\text{base}} + C_F \cdot \sqrt{\frac{\delta + \frac{2\varepsilon_{\text{PE}}}{C_F^2}}{2}}$$

证明：Fano 不等式给出 $P_e^{\text{PPE}} \geq \frac{H(Y|X, \text{PE}(P)) - 1}{\log |\mathcal{Y}|}$ 。我们有：

$$\begin{aligned} H(Y|X, \text{PE}(P)) &= H(Y|X) - I(Y; \text{PE}(P)|X) \\ &= H(Y|X) - [I(Y; P|X) - \varepsilon_{\text{PE}}] \\ &\geq H(Y|X) - I(Y; P|X) + \varepsilon_{\text{PE}} \end{aligned}$$

而 δ 的定义给出 $H(Y|X) - 1 \geq (\delta/2) \cdot \log |\mathcal{Y}|$ （通过 Fano 的逆方向）。因此：

$$H(Y|X, \text{PE}(P)) - 1 \geq \left(\frac{\delta}{2} + \frac{\varepsilon_{\text{PE}}}{C_F} \right) \cdot \log |\mathcal{Y}|$$

代入 SCX 的 F1 上界表达式即得。□

紧致性分析： - 当 $\varepsilon_{\text{PE}} = 0$ （完美编码）：上界恢复为原始 Theorem 2 - 当 $\varepsilon_{\text{PE}} > 0$ ：上界以 $\sqrt{\delta + O(\varepsilon_{\text{PE}})}$ 的速率放松 - 当 $\varepsilon_{\text{PE}} \rightarrow I(Y; P|X)$ （完全失败的编码，丢失了所有位置信息）：上界回到完全未使用位置信息的情况

推论 2.1（位置信息的价值）：如果物理位置 P 本身不携带任何关于标签 Y 的信息（即 $I(Y; P|X) = 0$ ），则 $\varepsilon_{\text{PE}} = 0$ （因为没有信息可丢失），Theorem 2 的上界完全不变。PPE 在这种情况下是纯粹的参数浪费。

2.5 对 Theorem 3 的影响

这是最关键的 analysis。Theorem 3 的不可区分性依赖于构造两个世界 W_A, W_B 具有完全相同的观测分布 $P(X, Y)$ 。

命题 2.3（固定 PPE 保持 Theorem 3）：如果 PE 是一个先验固定的函数（不依赖于训练数据或标签），则两个世界中的增强特征分布依然相同：

$$P_{W_A}(X, \text{PE}(P), Y) = P_{W_B}(X, \text{PE}(P), Y)$$

因此 Theorem 3 的不可区分性**保持不变**。PPE 没有帮助也没有损害最坏情况的可识别性。

证明：物理位置 P 由物理结构决定，独立于标签生成过程。因此 $P_{W_A}(P|X) = P_{W_B}(P|X)$ 。因为 PE 是固定的确定性函数, $P_{W_A}(\text{PE}(P)|X) = P_{W_B}(\text{PE}(P)|X)$ 。观测分布完全相同。□

命题 2.4 (学习型 PPE 破坏 Theorem 3): 如果 PE 的参数 θ_{PE} 是从数据中学习的 (包括标签 Y)，则在两个世界中学习到不同的编码：

$$\text{PE}_{W_A} \neq \text{PE}_{W_B}$$

因为 W_A 的噪声标签影响学习过程。此时：

$$P_{W_A}(X, \text{PE}_{W_A}(P), Y) \neq P_{W_B}(X, \text{PE}_{W_B}(P), Y)$$

两个世界变得可区分。Theorem 3 被破坏。

诚实评价：这实际上是好消息。Theorem 3 是一个不可能性结果——它说在最坏情况下，噪声和困难样本无法区分。如果学习型 PPE 能破坏定理 3 的前提条件，意味着位置信息提供了区分噪声和困难样本的能力。这不是框架的缺陷，而是框架的进步。但这确实意味着 Theorem 3 不再无条件成立——需要添加前提条件”PE 是固定的或位置信息不携带标签相关信息”。

2.6 对 Theorem 4 的影响

命题 2.5 (PPE 不减少最优误差指数):

$$D_{\text{KL}}(P_{\text{noisy}}^{\text{PPE}} \| P_{\text{clean}}^{\text{PPE}}) = D_{\text{KL}}(P_{\text{noisy}} \| P_{\text{clean}}) + \Delta D_{\text{KL}}^{\text{PE}}$$

其中 $\Delta D_{\text{KL}}^{\text{PE}} \geq 0$ (非负，由 KL 散度的数据处理不等式保证)。

证明：由 KL 散度的链式法则：

$$\begin{aligned} D_{\text{KL}}(P_{\text{noisy}}^{\text{PPE}} \| P_{\text{clean}}^{\text{PPE}}) &= D_{\text{KL}}(P_{\text{noisy}}(X, H) \| P_{\text{clean}}(X, H)) \\ &= D_{\text{KL}}(P_{\text{noisy}}(X) \| P_{\text{clean}}(X)) + \mathbb{E}_{X \sim P_{\text{noisy}}} [D_{\text{KL}}(P_{\text{noisy}}(H|X) \| P_{\text{clean}}(H|X))] \end{aligned}$$

因为 $H = \phi(X) + \text{PE}(P)$ ，且 PE 是固定的确定性函数，增强不会减少 KL 散度（信息处理不等式）。具体地：

$$\Delta D_{\text{KL}}^{\text{PE}} = \mathbb{E}_{X \sim P_{\text{noisy}}} [D_{\text{KL}}(P_{\text{noisy}}(\text{PE}(P)|X) \| P_{\text{clean}}(\text{PE}(P)|X))] \geq 0$$

□

PPE 从不降低最优误差指数。如果位置信息与标签相关， $\Delta D_{\text{KL}}^{\text{PE}} > 0$ ，误差指数严格更大（检测更准确）。如果位置信息无关， $\Delta D_{\text{KL}}^{\text{PE}} = 0$ ，不变。

Bahadur-Rao 常数因 PE 引入的方差项而修改，但总是朝更紧的方向（当 PE 有用时）。

3. 组件 2: Multi-Head Spring 的数学分析

3.1 形式化定义

定义 3 (Multi-Head Spring):

$$\text{Spring}_{\text{MH}}(s_i, \mathcal{S}) = \text{Concat}(\text{head}_1, \dots, \text{head}_K) \cdot W^O$$

其中：

$$\text{head}_k = \text{Spring}_k(s_i, \mathcal{S}) = \text{softmax} \left(\frac{(Q_k s_i)(K_k \mathcal{S})^T}{\sqrt{d_k}} \right) \cdot (V_k \mathcal{S})$$

参数：- $Q_k, K_k \in \mathbb{R}^{d_k \times d_s}$ ：第 k 个头的查询/键投影 - $V_k \in \mathbb{R}^{d_v \times d_s}$ ：第 k 个头的值投影 - $W^O \in \mathbb{R}^{Kd_v \times d_s}$ ：输出投影 - $d_k = d_s/K$ （标准多头的降维约定），或 $d_k = d_s$ （全维多头，每个头操作完整状态空间）

每个头 k 被设计为关注一个不同的物理维度：- 头 1：键角模式 — 关注状态原子间的角度关系 - 头 2：键长模式 — 关注状态原子间的距离关系 - 头 3：配位环境 — 关注状态原子的局部邻域拓扑 - 头 4：能量梯度/力场模式 — 关注状态原子的能量面曲率

物理维度约束（结构化多头）：为了实现真正的专业化，每个头的 Q_k, K_k 应被约束为仅作用于状态向量的特定子空间。若 $s_i = [s_i^{(1)}; s_i^{(2)}; s_i^{(3)}; s_i^{(4)}]$ 按物理维度分块，则：

$$Q_k = [\mathbf{0}_{d_k \times d_{<k}} \mid Q_k^{(k)} \mid \mathbf{0}_{d_k \times d_{>k}}]$$

其中 $Q_k^{(k)}$ 仅作用于第 k 个物理维度的子空间，其余为零。这强制专业化。

3.2 对 Theorem 1 的影响 — 有效专家数 M

核心问题： K 个头是否等价于 K 个独立专家？

答案：否。这是一个关键的区别。

命题 3.1（头不是独立专家）：Multi-Head Spring 的头输出在给定状态原子集合时是条件依赖的：

$$\text{Cov}(\text{head}_k(s_i), \text{head}_l(s_i) \mid \mathcal{S}) \neq 0 \quad (\text{一般情况})$$

证明：所有头共享相同的输入状态原子 $\mathcal{S}$ 和相同的 softmax 注意力池化结构。即使投影矩阵 Q_k, K_k 不同，注意力权重 $\alpha_{ij}^{(k)} = \text{softmax}_j((Q_k s_i)^T (K_k s_j) / \sqrt{d_k})$ 通过共同的 s_j 值耦合。因此：

$$\text{head}_k(s_i) = \sum_j \alpha_{ij}^{(k)} \cdot V_k s_j$$

$$\text{head}_l(s_i) = \sum_j \alpha_{ij}^{(l)} \cdot V_l s_j$$

两者的协方差通过共享的 $\{s_j\}$ 项非零。□

定义 4（有效专家多样性 ρ_{eff} ）:

$$\rho_{\text{eff}} = 1 - \frac{2}{K(K-1)} \sum_{k < l} |\text{Corr}(\text{head}_k, \text{head}_l)|$$

其中 $\text{Corr}(\text{head}_k, \text{head}_l) = \frac{\text{Cov}(\text{head}_k, \text{head}_l)}{\sqrt{\text{Var}(\text{head}_k) \cdot \text{Var}(\text{head}_l)}}$ （逐元素平均相关性）。

- $\rho_{\text{eff}} = 1$: 所有头完全独立（理想情况）
- $\rho_{\text{eff}} = 0$: 所有头完全相关（退化为单头）
- $\rho_{\text{eff}} < 0$: 头之间存在负相关（对抗性多样性）

有效专家数的启发式修正:

$$M_{\text{eff}} = M \cdot (1 + \alpha \cdot \rho_{\text{eff}} \cdot (K - 1))$$

其中 $\alpha \in [0, 1]$ 是”头多样性 $\rightarrow$ 专家多样性”的转换系数。

但这不是一个严格的界。严格的 Chernoff bound 需要处理依赖随机变量。

定理 3.1（Multi-Head Spring 下的严格 F1 下界）:

设 $A_k(s)$ 为第 k 个头对状态 s 产生的”伪一致性分数”（通过头输出与标签的一致性），则使用 union-Chernoff 方法:

$$F_1^{\text{MH}} \geq 1 - \frac{1}{\eta} \sum_s \rho_s \cdot \min_{\mathcal{J} \subseteq [K]} \exp(-2M \cdot \tilde{\Delta}_s^2(\mathcal{J}))$$

其中 $\tilde{\Delta}_s(\mathcal{J})$ 是在头子集 $\mathcal{J}$ 上的有效边际， $\mathcal{J}$ 选取一个最大独立子集（满足某种 β -混合条件）。

在最坏情况下（所有头完全相关， $\rho_{\text{eff}} = 0$ ）:

$$F_1^{\text{MH}} = F_1^{\text{single}} \quad (\text{Multi-Head 无增益})$$

在最好情况下（所有头完全独立， $\rho_{\text{eff}} = 1$ ，且 $\alpha = 1$ ）：

$$F_1^{\text{MH}} \geq 1 - \frac{1}{\eta} \sum_s \rho_s \cdot \exp\left(-2MK\tilde{\Delta}_s^2\right) \quad (\text{启发式, 非严格})$$

诚实暴击：严格处理头之间依赖结构的 Chernoff bound 极其复杂。实际上，如果不对头之间的依赖做额外假设（如 β -混合或 Dobrushin 条件），Theorem 1 形式的独立指数界不适用于 Multi-Head Spring。实际可得的界会松得多（因为要用 union bound 或 Azuma-Hoeffding 处理 martingale 依赖序列）。

3.3 对 SE-1（Robbins-Monro 收敛）的影响

SE-1 的原始陈述：Spring 的参数 θ_t 通过以下方式更新：

$$\theta_{t+1} = \theta_t - \alpha_t \cdot \nabla \mathcal{L}(\theta_t) + \xi_t$$

其中 $\mathbb{E}[\xi_t | \mathcal{F}_t] = 0$ ， $\text{Var}(\xi_t | \mathcal{F}_t) \leq \sigma^2$ 。在 Robbins-Monro 条件下：

$$\sum_{t=1}^{\infty} \alpha_t = \infty, \quad \sum_{t=1}^{\infty} \alpha_t^2 < \infty$$

有 $\theta_t \xrightarrow{a.s.} \theta^*$ （在凸性假设下）。

命题 3.2（Multi-Head Spring 下的收敛条件）：

- (1) 步长条件（ α_t 的渐近行为）不变：条件 $\sum \alpha_t = \infty$ 和 $\sum \alpha_t^2 < \infty$ 仅依赖于步长调度，不依赖于参数数量。
- (2) 但有效收敛要求更小的步长：

$$\boxed{\alpha_t^{\text{MH}} \leq \frac{\alpha_t^{\text{single}}}{\sqrt{K}} \cdot \frac{\sigma_{\text{single}}^2}{\sigma_{\text{MH}}^2}}$$

其中 $\sigma_{\text{MH}}^2 = \sigma_{\text{single}}^2 \cdot (1 + \gamma \cdot (K - 1))$, $\gamma \in [0, 1]$ 是头间梯度干扰系数。

证明概要： Multi-Head Spring 的梯度方差随头数增加。每个头的注意力权重 $\alpha_{ij}^{(k)}$ 对共享状态原子 $\{s_j\}$ 的依赖引入了交叉头梯度项。对于损失 $\mathcal{L} = \mathbb{E}[\|\text{Spring}_{\text{MH}}(s_i) - s_i^*\|^2]$:

$$\begin{aligned}\nabla_{\theta_k} \mathcal{L} &= \mathbb{E} \left[(\text{Spring}_{\text{MH}} - s_i^*)^T W_{:,k}^O \cdot \nabla_{\theta_k} \text{head}_k \right] \\ \text{Cov}(\nabla_{\theta_k} \mathcal{L}, \nabla_{\theta_l} \mathcal{L}) &\neq 0 \quad (\text{通过共享的 } W^O \text{ 和 } s_i^*)\end{aligned}$$

梯度噪声的有效方差为：

$$\sigma_{\text{MH}}^2 = \frac{1}{K} \sum_{k=1}^K \text{Var}(\nabla_{\theta_k} \mathcal{L}) + \frac{1}{K^2} \sum_{k \neq l} \text{Cov}(\nabla_{\theta_k} \mathcal{L}, \nabla_{\theta_l} \mathcal{L})$$

第一项是 $O(1)$ (每个头的方差与单头相同, 但除以 K), 第二项引入 $O((K-1)/K) \approx O(1)$ 的额外方差 (当交叉协方差非零时)。□

(3) 收敛目标从全局最优退化为驻点：

Multi-Head Spring 的损失景观具有**排列对称性** (交换 head k 和 head l 产生相同的函数)。这意味着有 $K!$ 个等价的驻点。损失景观高度非凸, Robbins-Monro 只能保证收敛到 $\nabla \mathcal{L} \approx 0$ (驻点), 不能保证全局最优。

修改后的收敛定理 (SE-1-MH)：

在 Robbins-Monro 步长条件和梯度 Lipschitz 连续性的前提下：

$$\liminf_{t \rightarrow \infty} \mathbb{E}[\|\nabla \mathcal{L}(\theta_t)\|^2] \leq \frac{C \cdot \sigma_{\text{MH}}^2 \cdot \bar{\alpha}}{(\text{与 } K \text{ 无关的常数})}$$

其中 $\bar{\alpha} = \limsup_{t \rightarrow \infty} \alpha_t$ 。当 K 增大时 σ_{MH}^2 增大, 收敛的残差梯度范数也增大。多头使收敛变得更差 (在有限步长下)。

3.4 过参数化条件

定义 5 (有效样本量): Spring 动力学通过记忆库 M_t 产生训练信号。设 T_{eff} 为每个状态原子在自进化过程中产生的有效”监督信号”数量（通过 Spring 重构误差提供）。则总有效样本量为 $N_{\text{eff}} = N \cdot T_{\text{eff}}$ 。

命题 3.3 (过参数化临界头数):

对于**标准多头**（每头降维 $d_k = d_s/K$ ）:

$$|\theta_{\text{MH}}| = \underbrace{K \cdot (2d_k d_s + d_v d_s)}_{\text{Q, K, V 投影}} + \underbrace{K d_v d_s}_{W^O} = 4d_s^2 \quad (\text{当 } d_k = d_v = d_s/K)$$

总参数不依赖 K —— 标准设计通过降维保持了参数恒定。在此情况下，Multi-Head Spring 不引入额外的过参数化风险。

对于**全维多头**（每头 $d_k = d_s$ ，各头关注不同物理子空间但可访问全维）:

$$|\theta_{\text{MH}}| = d_s^2 \cdot (3K + 1)$$

定理 3.2 (过拟合临界条件):

$$K_{\text{crit}} = \max \left(1, \left\lfloor \frac{N \cdot T_{\text{eff}}/d_s^2 - 1}{3} \right\rfloor \right)$$

当 $K > K_{\text{crit}}$ 时，模型参数多于有效训练信号，泛化误差以概率 $\geq 1 - \delta$ 至少为:

$$\text{GenError}(K) \geq \Omega \left(\sqrt{\frac{d_s^2 \cdot (3K + 1)}{N \cdot T_{\text{eff}}}} \right)$$

（由标准 Rademacher 复杂度界得出）。

数值示例 (保守假设): - $N = 500$ 状态原子, $d_s = 64$, $T_{\text{eff}} = 5$ - $K_{\text{crit}} = \lfloor (500 \cdot 5/4096 - 1)/3 \rfloor = \lfloor (0.61 - 1)/3 \rfloor = \max(1, -0.13) = 1$

结论：对于适中的状态空间，即使是 $K = 2$ 个全维头也可能已经过参数化。
对于标准降维多头， K 可以更大（因为参数恒定）。

3.5 对 SE-2 (Doob Martingale) 的影响

SE-2 声称参数的后验是鞅： $\mathbb{E}[\theta_{t+1}|\mathcal{F}_t] = \theta_t$ 。

对于 Multi-Head Spring，鞅性质在联合参数空间上保持（因为它是贝叶斯更新的直接后果），但：

1. **边际鞅性质可能失效：**对于单个头的参数 $\theta_t^{(k)}$ ， $\mathbb{E}[\theta_{t+1}^{(k)}|\mathcal{F}_t] \neq \theta_t^{(k)}$ （因为更新涉及所有头的交叉信息）。
2. **鞅差序列的方差增大：**

$$\text{Var}(\theta_{t+1} - \theta_t|\mathcal{F}_t) = O(K)$$

这意味着收敛的集中度降低。Azuma-Hoeffding 给出的置信区间宽度为 $O(\sqrt{K \cdot t})$ 而非 $O(\sqrt{t})$ 。

4. 组合分析

4.1 联合形式化

两个组件同时添加时的完整流水线：

$$\boxed{s_i \xrightarrow{\text{PPE}} h_i = \phi(s_i) + \text{PE}(p_i) \xrightarrow{\text{MH-Spring}} \text{Spring}_{\text{MH}}(h_i, \mathcal{H})}$$

其中 $\mathcal{H} = \{h_1, \dots, h_N\}$ 是编码后的状态原子集合。

4.2 Theorem 1 的联合界 — 交叉项分析

命题 4.1（联合检测边际的分解）：

$$\Delta_s^{\text{combined}} = \Delta_s + \delta_s^{\text{PE}} + \delta_s^{\text{MH}} + \delta_s^{\text{cross}}$$

其中交叉项 δ_s^{cross} 满足：

$$\delta_s^{\text{cross}} = \text{Cov}_{\text{experts}}(\text{Benefit}_{\text{PE}}, \text{Benefit}_{\text{MH}})$$

即 PPE 的边际收益与 Multi-Head 的边际收益在专家间的协方差。

展开：

$$\begin{aligned} F_1^{\text{combined}} &\geq 1 - \frac{1}{\eta} \sum_s \rho_s \cdot \exp(-2M_{\text{eff}} \cdot (\Delta_s + \delta_s^{\text{PE}} + \delta_s^{\text{MH}} + \delta_s^{\text{cross}})^2) \\ &= 1 - \frac{1}{\eta} \sum_s \rho_s \cdot \exp(-2M_{\text{eff}} \cdot [\Delta_s^2 + 2\Delta_s(\delta_s^{\text{PE}} + \delta_s^{\text{MH}} + \delta_s^{\text{cross}}) + (\delta_s^{\text{PE}} + \delta_s^{\text{MH}} + \delta_s^{\text{cross}})^2]) \end{aligned}$$

超加性 vs 次加性分析：

令 $A_s = \exp(-2M_{\text{eff}}\Delta_s^2)$ （原始误差）， $B_s^{\text{PE}}, B_s^{\text{MH}}, B_s^{\text{both}}$ 分别为单独 PPE、单独 MH、两者结合的误差。则：

$$\log \frac{B_s^{\text{both}}}{A_s} = -2M_{\text{eff}} \cdot [2\Delta_s(\delta_s^{\text{PE}} + \delta_s^{\text{MH}} + \delta_s^{\text{cross}}) + (\delta_s^{\text{PE}} + \delta_s^{\text{MH}} + \delta_s^{\text{cross}})^2]$$

$$\log \frac{B_s^{\text{PE}} \cdot B_s^{\text{MH}}}{A_s^2} = -2M_{\text{eff}} \cdot [2\Delta_s(\delta_s^{\text{PE}} + \delta_s^{\text{MH}}) + (\delta_s^{\text{PE}})^2 + (\delta_s^{\text{MH}})^2]$$

两者之差给出（在对数空间中）：

$$\text{Interaction} = -2M_{\text{eff}} \cdot [2\Delta_s\delta_s^{\text{cross}} + 2\delta_s^{\text{PE}}\delta_s^{\text{MH}} + 2\delta_s^{\text{cross}}(\delta_s^{\text{PE}} + \delta_s^{\text{MH}}) + (\delta_s^{\text{cross}})^2]$$

超加性条件（组合收益 > 单独收益之和）：交叉项为负（减少误差），即：

$$\delta_s^{\text{cross}} \cdot (2\Delta_s + 2\delta_s^{\text{PE}} + 2\delta_s^{\text{MH}} + \delta_s^{\text{cross}}) + 2\delta_s^{\text{PE}}\delta_s^{\text{MH}} < 0$$

当 $\delta_s^{\text{PE}} > 0$ 且 $\delta_s^{\text{MH}} > 0$ （两者都改善检测）且 $\delta_s^{\text{cross}} > 0$ （正向交互）时满足：

$$\boxed{\text{Superadditive when: } \delta_s^{\text{PE}} > 0, \delta_s^{\text{MH}} > 0, \delta_s^{\text{cross}} > 0}$$

次加性条件（组合收益 < 单独收益之和）：当两者之一或交叉项为负。

实际判断：Multi-Head Spring 可以利用 PPE 提供的空间局部性来实现更有意义的注意力模式（例如，头 k 关注物理位置 p_i 邻域内的状态原子）。这种协同大概率是**正向的**，即 $\delta_s^{\text{cross}} > 0$ 。但如果没有明确的物理约束，多头可能学到虚假的跨维相关性，此时 δ_s^{cross} 可能是负的。

4.3 Theorem 2 的联合界

特征弱点是次加性地恶化的（因为每个组件都可能引入额外的弱点）：

$$\boxed{\delta_{\text{combined}} = \delta + \delta_{\text{PE}} + \delta_{\text{MH}} + \delta_{\text{cross}} \geq \max(\delta + \delta_{\text{PE}}, \delta + \delta_{\text{MH}})}$$

其中：- $\delta_{\text{PE}} = 2\varepsilon_{\text{PE}}/C_F^2$ （来自 §2.4）- $\delta_{\text{MH}} \propto \frac{d_s^2 \cdot (3K+1)}{N \cdot T_{\text{eff}}}$ （来自过参数化, §3.4）

- $\delta_{\text{cross}} \geq 0$ ：PPE 的不完美编码 + Multi-Head 的过参数化产生复合效应

因此：

$$F_{1,\text{SCX}}^{\text{combined}} \leq F_{1,\text{base}} + C_F \cdot \sqrt{\frac{\delta_{\text{combined}}}{2}}$$

最坏情况（两者都很差）：界比单独使用任一组件更松。

最好情况（完美 PPE + 参数充足的 MH）： $\delta_{\text{PE}} = \delta_{\text{MH}} = 0$ ，界回到原始 Theorem 2。

4.4 Cercis Score 的修改

推荐修改：

$$S'(s_i) = Q_{\text{MH}}(h_i) + \eta(t) \cdot N(s_i) - \lambda \cdot \mathcal{R}_{\text{diversity}}$$

其中：

$$Q_{\text{MH}}(h_i) = \frac{1}{K} \sum_{k=1}^K w_k \cdot Q(\text{head}_k(h_i))$$

w_k 是头可靠性权重（可通过头输出与多数投票的一致性来估计）。

正则化项：

$$\mathcal{R}_{\text{diversity}} = (K - 1) \cdot \left(1 - \frac{1}{K} \sum_{k=1}^K \left\| \text{head}_k - \frac{1}{K} \sum_{j=1}^K \text{head}_j \right\|^2 \right)$$

惩罚头之间的过度相似（鼓励多样性），防止退化到单头。

$\lambda > 0$ 是正则化强度。当 $K = 1$ 时 $\mathcal{R}_{\text{diversity}} = 0$ （自动退化为原始形式）。

5. 诚实暴击（Honest Critique）

5.1 数学保证被削弱的地方

位置	原始保证	削弱后的状态	严重程度
Theorem 1 + MH	Chernoff bound on i.i.d. experts	头输出相关, i.i.d. 假设不成立。严格 bound 需要 β -mixing 条件, 而该条件可能不满足	高
SE-1 + MH	Robbins-Monro $\rightarrow$ 全局最优 (凸性下)	高度非凸损失景观 ($K!$ 对称驻点) $\rightarrow$ 只能保证驻点, 不能保证全局最优	高
Theorem 2 + MH	紧致 Fano 上界	过参数化时界仍然成立但变得过松 (vacuous), 实际性能可能远差于界	中
Theorem 3 + 学习型 PPE	最坏情况不可区分	学习型 PE 使得两个世界可区分 $\rightarrow$ 定理 3 被破坏 (但这是好事)	中 (实际上有益)
SE-2 + MH	联合鞅性质保持	边际鞅性质可能失效; 鞅差方差 $O(K)$ 增大, 置信区间变宽	中
组合 Theorem 1	独立 Chernoff bound	有效 M_{eff} 是启发式的, 非严格。交叉项 δ_s^{cross} 难以从理论上界定	高

5.2 完全无影响的地方 (加了等于白加)

条件	为什么无效
$I(Y; P \mid X) = 0$ (位置不携带标签信息)	PPE 是纯噪声。Theorem 2 的界不变。Theorem 1 的 Δ_s 不变。参数全部浪费

条件	为什么无效
$\rho_{\text{eff}} = 0$ (所有头坍塌为单一模式)	Multi-Head 等价于单头 + K 倍冗余参数。 Theorem 1 无增益。SE-1 收敛到相同点
固定、信息论可逆的 PE	仅是变量替换。KL 散度不变 $\rightarrow$ Theorem 4 不变。无实质贡献
$K > K_{\text{crit}}$ 且无正则化	过度参数化 $\rightarrow$ 泛化误差主导 $\rightarrow$ 任何定理的界都变为空集 (vacuous)
物理维度不相关 (例如头关注物理维度 D , 但 D 与任务无关)	该头的有效 $\Delta_s = 0 \rightarrow$ 纯噪声贡献 $\rightarrow$ 降低有效 M_{eff}

5.3 特定条件下破坏定理的情况

Theorem 3 被破坏的条件 (5 个条件, 按严重程度排序):

1. **学习型 PPE (最严重)**: §2.5 已分析。训练数据中的标签噪声导致 $\text{PE}_{W_A} \neq \text{PE}_{W_B}$ 。结果: 两个世界可区分, Theorem 3 的不可区分性不成立。

评价: **好事**。Theorem 3 是最坏情况不可能性结果。如果位置信息能打破这个不可能性, 说明 PPE 有用。
2. **Multi-Head Spring 中的维度泄漏**: 若某个头被设计为关注物理维度 A , 但实际上通过 softmax 的全局注意力也能访问维度 B 的信息, 则头的“专业化”是虚假的。这可能导致该头学到标签相关的虚假相关性, 改变 P_{clean} 和 P_{noisy} 的估计。
3. **$K > N$ (头数超过状态原子数)**: 多头的注意力模式无法被数据唯一确定。存在无限多个参数配置产生相同的 $\text{Spring}_{\text{MH}}(s_i)$ 。Theorem 3

的构造依赖于数据分布的唯一性——当参数化是欠定的，两个世界的分布可能有细微差异。

4. **PPE 维度与物理维度对齐**: 如果 $\text{PE}(p_i)$ 的维度与 Multi-Head Spring 中某头的物理维度**正交**（即编码碰巧擦除了该头需要的信息），则该头的注意力模式会产生系统性偏差。这引入了一个 Theorem 3 构造中未考虑的自由度。
5. $\eta(t)$ **衰减过快** + **Multi-Head**: 如果探索权重 $\eta(t)$ 衰减过快，Multi-Head Spring 可能过早地将某些模式”冻结”在次优状态。在 Theorem 3 的双世界构造中，一个世界可能学到更好的模式（因为标签更干净），而另一个世界学到差的模式——使两个世界可区分。

5.4 最诚实的总结

PPE 的底线: - 对 **Theorem 1**: 如果物理位置与任务相关 $\rightarrow$ 有正向贡献 ($\delta_s^{\text{PE}} > 0$)。如果无关 $\rightarrow$ 没有影响。Chernoff 结构保持。- 对 **Theorem 2**: 不完美的编码以 $\sqrt{\delta + O(\varepsilon_{\text{PE}})}$ 扩大上界。完美编码不影响上界。- 对 **Theorem 3**: 固定编码保持不可区分性。学习型编码**破坏** Theorem 3——但这是**进展**而非退步。- 对 **Theorem 4**: 不减少误差指数。有用时增加指数。

Multi-Head Spring 的底线: - 对 **Theorem 1**: 头**不是**独立专家。严格界比 naive $M \times K$ 松得多。头相关性的完整处理极其困难。- 对 **SE-1**: 收敛到驻点（不保证全局最优）。有效步长上限以 $O(1/\sqrt{K})$ 缩小。收敛更慢。- **过参数化**: 对于典型的状态空间大小， K_{crit} 可能只有 1-3 个头。超过此数的头会产生泛化惩罚。

组合的最诚实评价: - PPE 是**更有价值**的组件——它在理论上更清晰，影响更可预测，且风险更低 - Multi-Head Spring 的**理论风险更高**——它破坏了 Theorem 1 最优雅的部分 (i.i.d. 专家的 Chernoff bound) - 两者的**交叉项**在

理论上是正的（可能产生超加性收益），但在实际中可能为负（额外的复杂性引入新的失败模式）

一句话总结：PPE 是一个安全的赌注，数学上几乎纯粹有益（除了学习型 PPE 破坏 Theorem 3，但那是好事）。Multi-Head Spring 是一个高风险赌注——它在数学上削弱了 Theorem 1 的严格性，使 SE-1 收敛性变差，且很有可能过参数化。组合时，PPE 的收益可能被 Multi-Head 的复杂性部分抵消。

6. 开放问题

1. **严格的多头 Chernoff 界**：能否在头的依赖结构上建立 β -mixing 条件，使得 Theorem 1 的指数界可以严格扩展到多头情况？
 2. **PPE 的最优频率**：在正弦编码中，频率参数 $\omega_j = 10000^{-2j/d}$ 是为自然语言设计的。物理位置的最优频率谱是什么？能否从物理对称性推导？
 3. **头数 K 的自适应选择**：能否从数据中学习最优的 K （类似于 Bayesian non-parametric 中的中餐馆过程），在过参数化之前停止？
 4. **Theorem 3 的修改**：如何在定理陈述中加入”前提条件：不使用数据依赖的位置编码”来保持其数学完整性？
-

参考文献（框架内部）

- SCX Project (2026). Theorem 1-4: Multi-expert consistency, weak feature limits, unidentifiability, and minimax optimality. [theory/theorems/](#)
- SCX Project (2026). Spring Dynamics, SE-1 (Robbins-Monro convergence), SE-2 (Doob martingale). [theory/self_evolution/](#)
- SCX Project (2026). State Crystallization: Physics-driven discretization of continuous observables. [theory/propositions/](#)
- Wainwright, M. (2019). *High-Dimensional Statistics: A Non-Asymptotic Viewpoint*. Cambridge. （Chernoff-Hoeffding-Stein 的标准参考）
- Boucheron, S., Lugosi, G., & Massart, P. (2013). *Concentration Inequalities*. Oxford. （依赖变量的集中不等式）
- Vaswani, A., et al. (2017). Attention Is All You Need. *NeurIPS*. （多头注意力的原始公式）
- Su, J., et al. (2024). RoFormer: Enhanced Transformer with Rotary Position Embedding. *Neurocomputing*. （RoPE 的数学基础）

分析日期：2026-06-29

作者备注：所有定理编号指 SCX 框架内部定理，非本文序号。本分析的数学处理在可处理的范围内是严格的；已明确标注所有近似和启发式的部分。诚实的不可处理性（如依赖头的 Chernoff bound）已被诚实记录。