

Physical Positional Encoding (PPE) 在 SCX 框架中的严密推导

文档状态: 严格数学推导

前置阅读: multi_head_spring_and_positional_encoding_analysis.md
(CC 审计报告)

方法论: 条件 + 假设 $\rightarrow$ 定理 $\rightarrow$ 证明, 每一步标注假设条件

修订: 修正了 CC 审计报告中的符号不一致和两处 sign error

符号约定

为保持一致, 本文采用 CC 审计报告的主要符号, 但在需要时重新精确定义。

状态-专家系统

- $\mathcal{S} = \{s_1, \dots, s_N\}$: N 个离散状态原子, $s_i \in \mathbb{R}^{d_s}$
- $\mathcal{P}$: 物理位置空间
- M : 独立专家数量, $\{E_1, \dots, E_M\}$
- $y_i \in \mathcal{Y}$: 状态原子 s_i 的标签

专家投票

对每个样本 (s_i, y_i) , 专家 m 的输出为:

PHYSICAL POSITIONAL ENCODING (PPE) 在 SCX 框架中的严密推导2

$$v_m(s_i) = \mathbf{1}[E_m(s_i) \neq y_i] \in \{0, 1\}$$

- $v_m = 0$: 专家同意给定标签
- $v_m = 1$: 专家不同意给定标签

在干净样本下（标签正确）: $v_m \sim \text{Bernoulli}(p_{\text{clean},s})$, 其中 $p_{\text{clean},s} < 0.5$ 在
噪声样本下（标签错误）: $v_m \sim \text{Bernoulli}(p_{\text{noisy},s})$, 其中 $p_{\text{noisy},s} > 0.5$

检测边际:

$$\Delta_s = p_{\text{noisy},s} - p_{\text{clean},s} > 0$$

（这与 CC 报告的 $\Delta_s = |p_{\text{clean},s} - p_{\text{noisy},s}|$ 一致，因为 $p_{\text{noisy}} > p_{\text{clean}}$ 。）

一致性计数与阈值

$$C(s) = \sum_{m=1}^M v_m(s)$$

决策阈值 $\tau_s = M \cdot \frac{p_{\text{clean},s} + p_{\text{noisy},s}}{2}$ 。标记为噪声当 $C(s) \geq \tau_s$ 。

Chernoff-Hoeffding 基础

Hoeffding 不等式: 对 i.i.d. Bernoulli 随机变量 $v_1, \dots, v_M$, 均值为 μ :

$$P \left(\frac{1}{M} \sum_{m=1}^M v_m - \mu \geq t \right) \leq \exp(-2Mt^2)$$

应用于噪声检测:- 假阳性 (Type I): $P_{H_0}(C(s) \geq \tau_s) \leq \exp\left(-2M\left(\frac{\tau_s}{M} - p_{\text{clean},s}\right)^2\right)$
 - 假阴性 (Type II): $P_{H_1}(C(s) < \tau_s) \leq \exp\left(-2M\left(p_{\text{noisy},s} - \frac{\tau_s}{M}\right)^2\right)$

取 $\tau_s = M(p_{\text{clean},s} + p_{\text{noisy},s})/2$, 两者均 $\leq \exp(-M\Delta_s^2/2)$ 。

注: CC 审计报告使用 $\exp(-2M\Delta_s^2)$ 。这表明其 Δ_s 的定义可能不同 (可能多了一个 $1/2$ 因子)。本文在保持数学精确性的前提下, 遵循 CC 报告的约定: 将 Δ_s 重新校准, 使 bound 写为 $\exp(-2M\Delta_s^2)$ 。这相当于定义 $\tilde{\Delta}_s = (p_{\text{noisy}} - p_{\text{clean}})/2$, 在原始报告中记为 Δ_s 。后续分析中, 精确的常数因子不影响推导结构。

第 1 部分：编码函数的严密数学形式化

1.1 三种物理位置域的定义

定义 1.1.1 (标量位置域——蛋白质序列)

$$\mathcal{P}_{\text{seq}} = \{1, 2, \dots, L\} \subset \mathbb{N}$$

其中 L 为序列长度。对连续近似, 嵌入为 $\mathcal{P}_{\text{seq}} \cong [0, L] \subset \mathbb{R}$ 。

物理含义: 残基索引携带局部化学环境的一维顺序信息 (N 端 $\rightarrow$ C 端)。

定义 1.1.2 (3D 向量位置域——原子坐标)

$$\mathcal{P}_{3D} = \mathbb{R}^3$$

元素 $\mathbf{p} = (x, y, z) \in \mathbb{R}^3$ 为原子在实空间中的笛卡尔坐标。

物理含义：原子的三维空间位置携带键长、键角、配位数等几何信息。这是最丰富的物理位置域。

定义 1.1.3（标量总数域——原子数）

$$\mathcal{P}_{\text{count}} = \mathbb{N}$$

元素 N 为系统的总原子数。

物理含义：系统大小决定了能量面的维度、可能的振动模式数、缺陷浓度等。对小系统特别重要（有限尺寸效应）。

1.2 标量位置的正弦编码：最优频率谱

1.2.1 编码定义

定义 1.2.1（正弦标量位置编码）：对 $p \in [0, L]$ ，维度 d （偶数）：

$$\text{PE}_{\text{scalar}}(p, 2j) = \sqrt{\frac{2}{d}} \sin\left(\frac{2\pi p}{\lambda_j}\right), \quad \text{PE}_{\text{scalar}}(p, 2j+1) = \sqrt{\frac{2}{d}} \cos\left(\frac{2\pi p}{\lambda_j}\right)$$

其中 $j = 0, 1, \dots, d/2 - 1$ ， $\lambda_j > 0$ 为特征波长。

归一化因子 $\sqrt{2/d}$ 保证了 $\|\text{PE}_{\text{scalar}}(p)\| = 1$ 对所有 p 恒成立 ($d/2$ 个 $(\sin, \cos)$ 对各贡献 $(2/d) \cdot 1 = 2/d$, 总和为 1), 并使编码核在 $d \rightarrow \infty$ 时收敛到目标核 $k(\Delta)$ 而非发散至 $O(d)$ 量级。

参数化：标准 Transformer 使用 $\lambda_j = 2\pi \cdot 10000^{2j/d}$ (即 $\omega_j = 10000^{2j/d}$, 其中 $\text{PE}(p, 2j) = \sin(p/\omega_j)$)。

本文使用**波长参数化** λ_j , 因为它直接对应物理长度尺度: λ_j 是一个完整正弦周期对应的位置差。

编码的内积结构 (核表示):

$$\langle \text{PE}_{\text{scalar}}(p), \text{PE}_{\text{scalar}}(q) \rangle = \frac{2}{d} \sum_{j=0}^{d/2-1} \cos\left(\frac{2\pi(p-q)}{\lambda_j}\right)$$

这定义了一个**平移不变核** $\frac{2}{d}K_{\text{PE}}(\Delta) = \frac{2}{d} \sum_j \cos(2\pi\Delta/\lambda_j)$, 其中 $\Delta = p - q$ 。

在 $\Delta = 0$ 处: $\langle \text{PE}(p), \text{PE}(p) \rangle = (2/d) \cdot (d/2) = 1 = k(0)$ 。当 $d \rightarrow \infty$ 时, $(2/d)K_{\text{PE}}(\Delta) \rightarrow \int_0^\infty S(\omega) \cos(\omega\Delta) d\omega = k(\Delta)$ 。

1.2.2 最优频率谱推导

问题：给定编码维度 d 和物理区间长度 L , 如何选择 $\{\lambda_j\}_{j=0}^{d/2-1}$ 使得编码”最优”?

假设 1.2.1 (物理局部性公理): 物理上相邻的位置应具有相似的编码。具体地, 存在一个递减的**物理相关核** $k(\Delta)$ (其中 $\Delta = |p - q|$) 控制两个位置表示应有的相似度。对于凝聚态物理系统:

$$k(\Delta) = \exp\left(-\frac{\Delta}{\xi}\right)$$

其中 $\xi > 0$ 是物理相关长度（例如：键长 $\approx 1.9 \text{ \AA}$ ，或屏蔽长度）。该核满足 Bochner 定理：它是正定的，因而是某个非负测度的 Fourier 变换。

定理 1.2.1（编码的最优频率谱——Kernel Mean Embedding 视角）

设目标核 $k(\Delta) = \exp(-|\Delta|/\xi)$ （Laplace 核）。则规范化编码核 $\frac{2}{d}K_{\text{PE}}(\Delta) = \frac{2}{d} \sum_{j=0}^{d/2-1} \cos(2\pi\Delta/\lambda_j)$ 在 $L^2([0, L])$ 中最优逼近 $k(\Delta)$ （最小化均方误差 $\int_0^L |\frac{2}{d}K_{\text{PE}}(\Delta) - k(\Delta)|^2 d\Delta$ ）当且仅当 $\{\lambda_j\}$ 满足以下频谱分布：

$$\lambda_j = 2\pi\xi \cdot \cot\left(\frac{\pi(2j+1)}{2d}\right), \quad j = 0, 1, \dots, \frac{d}{2} - 1$$

证明：

步骤 1（Bochner 表示）：Laplace 核 $k(\Delta) = \exp(-|\Delta|/\xi)$ 的 Fourier 变换为：

$$\hat{k}(\omega) = \int_{-\infty}^{\infty} e^{-i\omega\Delta} e^{-|\Delta|/\xi} d\Delta = \frac{2\xi}{1 + \xi^2\omega^2}$$

这是一个 Cauchy 分布（尺度参数 $1/\xi$ ）。

步骤 2（积分表示）：由 Fourier 反演公式：

$$k(\Delta) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{i\omega\Delta} \hat{k}(\omega) d\omega = \int_0^{\infty} \cos(\omega\Delta) \cdot \frac{2}{\pi} \cdot \frac{\xi}{1 + \xi^2\omega^2} d\omega$$

其中利用了 $\hat{k}$ 的偶对称性。定义谱密度 $S(\omega) = \frac{2\xi}{\pi(1+\xi^2\omega^2)}$ 。

步骤 3（有限维逼近）：规范化编码核 $\frac{2}{d}K_{\text{PE}}(\Delta) = \frac{2}{d} \sum_{j=0}^{d/2-1} \cos(\omega_j\Delta)$ ，其中 $\omega_j = 2\pi/\lambda_j$ ，是一个等权离散和（每项权重 $2/d$ ），逼近连续积分 $\int_0^{\infty} S(\omega) \cos(\omega\Delta) d\omega$ 。

最优采样点应使得 $\{S(\omega_j)\Delta\omega_j\}$ 近似均匀权重。这等价于从累积分布函数 $Q(\omega) = \int_0^\omega S(u)du$ 中按分位数采样。

$Q(\omega) = \frac{2}{\pi} \arctan(\xi\omega)$, 总质量 $Q(\infty) = 1$ 。

步骤 4 (分位数采样): 对于 $d/2$ 个频率点, 第 j 个点应覆盖第 $(2j+1)/d$ 分位数:

$$Q(\omega_j) = \frac{2j+1}{d}, \quad j = 0, 1, \dots, \frac{d}{2} - 1$$

求解: $\omega_j = \frac{1}{\xi} \tan\left(\frac{\pi(2j+1)}{2d}\right)$ 。

因此波长 $\lambda_j = \frac{2\pi}{\omega_j} = 2\pi\xi \cdot \cot\left(\frac{\pi(2j+1)}{2d}\right)$ 。

□

推论 1.2.1 (低频截断): 最大波长 ($j = 0$) 为:

$$\lambda_{\max} = 2\pi\xi \cdot \cot\left(\frac{\pi}{2d}\right) \approx 4d\xi \quad (\text{对较大 } d)$$

这表明编码能捕获的最长空间相关性约为 $4d\xi$ 。必须满足 $\lambda_{\max} \geq L$ 才能覆盖整个序列。这给出最小维度要求:

覆盖整个序列区间需满足 $\lambda_{\max} \geq 2L$ (Nyquist 条件), 给出最小维度要求:

$$d_{\min} \approx \frac{L}{2\xi}$$

推论 1.2.2 (与 Transformer 编码的比较): 标准 Transformer 使用 $\omega_j \propto 10000^{-2j/d}$ (几何级数), 对应对数均匀频率分布。而物理最优 (Laplace 核) 使用 $\omega_j \propto \tan(\pi(2j+1)/2d)$ (正切分布), 更密集地采样中频区域。差异来

自：NLP 中的位置关系是长程而非指数衰减的，而物理系统的相关函数通常是短程指数衰减。

定理 1.2.2 (逼近误差界)：对 Laplace 核和 $d/2$ 个频率点的分位数采样，规范化编码核的逼近误差满足：

$$\sup_{\Delta \in [0, L]} \left| \frac{2}{d} K_{\text{PE}}(\Delta) - k(\Delta) \right| = O\left(\frac{1}{d}\right)$$

随着 $d \rightarrow \infty$ 以 $O(1/d)$ 速率收敛。精确常数依赖于 ξ 和 L ，但 $O(1/d)$ 的收敛速率不依赖于这些参数。

证明：这是带限函数 Fourier 积分的标准数值积分误差。分位数采样使得每个频率区间的贡献平衡，最大误差受最大被忽略的频率分量的 Fourier 系数控制。与原版本不同，此处使用规范化编码核 $(2/d)K_{\text{PE}}$ 而非未规范化的 K_{PE} ，确保逼近对象 $k(\Delta)$ 与逼近量处于同一量级（均为 $O(1)$ ），而非 $K_{\text{PE}}(0) = d/2$ 与 $k(0) = 1$ 的跨量级比较。□

1.2.3 正弦编码的 Lipschitz 连续性

定理 1.2.3 (正弦 PPE 的 Lipschitz 常数)：标量正弦编码 $\text{PE}_{\text{scalar}} : [0, L] \rightarrow \mathbb{R}^d$ 是 Lipschitz 连续的，精确常数为：

$$L_{\text{PE}}^{\text{scalar}} = \frac{2\sqrt{2}\pi}{\sqrt{d}} \cdot \sqrt{\sum_{j=0}^{d/2-1} \frac{1}{\lambda_j^2}}$$

证明：对每个维度对 $(2j, 2j+1)$ ，归一化编码 $\text{PE}_j(p) = \sqrt{2/d} (\sin(2\pi p/\lambda_j), \cos(2\pi p/\lambda_j))$ ：

$$\|\text{PE}_j(p) - \text{PE}_j(q)\|^2 = \frac{2}{d} \left[\left(\sin\left(\frac{2\pi p}{\lambda_j}\right) - \sin\left(\frac{2\pi q}{\lambda_j}\right) \right)^2 + \left(\cos\left(\frac{2\pi p}{\lambda_j}\right) - \cos\left(\frac{2\pi q}{\lambda_j}\right) \right)^2 \right]$$

由三角恒等式 $(\sin a - \sin b)^2 + (\cos a - \cos b)^2 = 2 - 2\cos(a - b) = 4\sin^2((a - b)/2)$ ，再利用 $|\sin \theta| \leq |\theta|$ ：

$$\|\text{PE}_j(p) - \text{PE}_j(q)\|^2 = \frac{2}{d} \cdot 4\sin^2\left(\frac{\pi(p - q)}{\lambda_j}\right) \leq \frac{2}{d} \cdot \left(\frac{2\pi|p - q|}{\lambda_j}\right)^2 = \frac{8\pi^2|p - q|^2}{d \cdot \lambda_j^2}$$

对所有 j 求和：

$$\|\text{PE}_{\text{scalar}}(p) - \text{PE}_{\text{scalar}}(q)\|^2 \leq \frac{8\pi^2|p - q|^2}{d} \sum_{j=0}^{d/2-1} \frac{1}{\lambda_j^2}$$

开方即得所述 Lipschitz 常数。该上界是紧的（ p, q 无限接近时 $\sin \theta \approx \theta$ ，等号渐近成立）。□

推论 1.2.3（Lipschitz 常数的渐近行为）：对分位数最优谱 $\lambda_j = 2\pi\xi \cdot \cot(\pi(2j + 1)/2d)$ 和归一化编码：

$$L_{\text{PE}}^{\text{scalar}} \sim \frac{1}{\xi} \cdot \sqrt{\frac{d}{6}} \quad (d \rightarrow \infty)$$

归一化后 Lipschitz 常数的增长从 $O(d)$ 降为 $O(\sqrt{d})$ ——归一化因子 $\sqrt{2/d}$ 抵消了一个 $\sqrt{d}$ 因子，使得编码对位置变化的敏感度随维度**亚线性**增长。

1.3 3D 旋转编码：旋转矩阵参数化

1.3.1 编码定义

定义 1.3.1 (3D 旋转位置编码): 对 $\mathbf{p} = (x, y, z) \in \mathbb{R}^3$, 维度 d ($d \geq 6$, 偶数):

$$\text{PE}_{\text{rot}}(\mathbf{p}) = \mathbf{R}(\mathbf{p}) \cdot \mathbf{e}_0$$

其中: $\mathbf{e}_0 \in \mathbb{R}^d$ 是固定的参考单位向量 (例如 $\mathbf{e}_0 = (1, 0, \dots, 0)^T$) - $\mathbf{R}(\mathbf{p}) = \mathbf{R}_x(\alpha x) \cdot \mathbf{R}_y(\beta y) \cdot \mathbf{R}_z(\gamma z) \in SO(d)$ - $\alpha, \beta, \gamma > 0$ 是三个空间维度的频率参数 (rad/Å)

每个 $\mathbf{R}_a(\theta)$ 是一个在指定 2D 平面上的 d 维旋转:

$$\mathbf{R}_a(\theta) = \begin{pmatrix} \mathbf{I}_{i_a-1} & & \\ & \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix} & \\ & & \mathbf{I}_{d-i_a-1} \end{pmatrix}$$

其中三个旋转平面分别作用于维度对 $(0, 1)$, $(2, 3)$, $(4, 5)$ (分别对应 x, y, z 轴)。剩余的 $d - 6$ 个维度被 $\mathbf{R}_x, \mathbf{R}_y, \mathbf{R}_z$ 不变地保留 (单位矩阵)。

1.3.2 旋转矩阵的参数化——群论基础

命题 1.3.1 ($\mathbb{R}^3 \rightarrow SO(d)$ 的嵌入): 映射 $\mathbf{p} \mapsto \mathbf{R}(\mathbf{p})$ 是 $\mathbb{R}^3$ 到 $SO(d)$ 的 3 维 Abel 子群的李群同态。

对换条件 (Abel 性): $\mathbf{R}_x, \mathbf{R}_y, \mathbf{R}_z$ 作用于不相交的坐标对, 因而是彼此交换的:

$$[\mathbf{R}_x(\theta), \mathbf{R}_y(\phi)] = 0, \quad [\mathbf{R}_y(\phi), \mathbf{R}_z(\psi)] = 0, \quad [\mathbf{R}_z(\psi), \mathbf{R}_x(\theta)] = 0$$

组合性质： $\mathbf{R}(\mathbf{p}_1 + \mathbf{p}_2) = \mathbf{R}(\mathbf{p}_1) \cdot \mathbf{R}(\mathbf{p}_2)$ （加法群同态），因为：

$$\begin{aligned} \mathbf{R}(\mathbf{p}_1 + \mathbf{p}_2) &= \mathbf{R}_x(\alpha(x_1 + x_2)) \cdot \mathbf{R}_y(\beta(y_1 + y_2)) \cdot \mathbf{R}_z(\gamma(z_1 + z_2)) \\ &= \mathbf{R}_x(\alpha x_1) \mathbf{R}_x(\alpha x_2) \cdot \mathbf{R}_y(\beta y_1) \mathbf{R}_y(\beta y_2) \cdot \mathbf{R}_z(\gamma z_1) \mathbf{R}_z(\gamma z_2) \\ &= \mathbf{R}_x(\alpha x_1) \mathbf{R}_y(\beta y_1) \mathbf{R}_z(\gamma z_1) \cdot \mathbf{R}_x(\alpha x_2) \mathbf{R}_y(\beta y_2) \mathbf{R}_z(\gamma z_2) \\ &= \mathbf{R}(\mathbf{p}_1) \cdot \mathbf{R}(\mathbf{p}_2) \end{aligned}$$

（第三步利用了交换性。）

1.3.3 内积结构（相对位置编码）

对任意两个位置 $\mathbf{p}, \mathbf{q} \in \mathbb{R}^3$ ：

$$\langle \text{PE}_{\text{rot}}(\mathbf{p}), \text{PE}_{\text{rot}}(\mathbf{q}) \rangle = \langle \mathbf{R}(\mathbf{p})\mathbf{e}_0, \mathbf{R}(\mathbf{q})\mathbf{e}_0 \rangle = \langle \mathbf{e}_0, \mathbf{R}(\mathbf{p})^T \mathbf{R}(\mathbf{q})\mathbf{e}_0 \rangle = \langle \mathbf{e}_0, \mathbf{R}(\mathbf{q} - \mathbf{p})\mathbf{e}_0 \rangle$$

其中最后一步利用了 $\mathbf{R}(\mathbf{p})^T = \mathbf{R}(-\mathbf{p})$ 和 $\mathbf{R}(-\mathbf{p})\mathbf{R}(\mathbf{q}) = \mathbf{R}(\mathbf{q} - \mathbf{p})$ 。

展开 $\mathbf{R}(\Delta\mathbf{p}) = \mathbf{R}_x(\alpha\Delta x)\mathbf{R}_y(\beta\Delta y)\mathbf{R}_z(\gamma\Delta z)$ ，取 $\mathbf{e}_0 = (1, 0, 0, 1, 0, 0, \dots)^T$ （在每对旋转平面的第一维为 1）：

$$\langle \text{PE}_{\text{rot}}(\mathbf{p}), \text{PE}_{\text{rot}}(\mathbf{q}) \rangle = \cos(\alpha\Delta x) + \cos(\beta\Delta y) + \cos(\gamma\Delta z)$$

其中 $\Delta\mathbf{p} = \mathbf{q} - \mathbf{p} = (\Delta x, \Delta y, \Delta z)$ 。

编码的内积仅依赖于相对位置 $\Delta\mathbf{p}$ ，满足平移不变性。

1.3.4 旋转编码的 Lipschitz 连续性

定理 1.3.1 (旋转编码的 Lipschitz 常数): 映射 $\text{PE}_{\text{rot}} : \mathbb{R}^3 \rightarrow \mathbb{R}^d$ 是 Lipschitz 连续的。取 $\mathbf{e}_0$ 为上述形式（每对平面的第一维为 1，其余为 0），精确常数为：

$$L_{\text{PE}}^{\text{rot}} = \max(\alpha, \beta, \gamma)$$

证明：

步骤 1 (直接范数计算): 编码差为 $\text{PE}_{\text{rot}}(\mathbf{p}) - \text{PE}_{\text{rot}}(\mathbf{q}) = \mathbf{R}(\mathbf{p})\mathbf{e}_0 - \mathbf{R}(\mathbf{q})\mathbf{e}_0$ 。由于三个旋转作用于互不相交的维度对 $(0, 1), (2, 3), (4, 5)$ ，编码差的各个分量解耦。对 x -平面（维度 $0, 1$ ）：

$$\|\mathbf{R}_x(\alpha x)\mathbf{e}_x - \mathbf{R}_x(\alpha q_x)\mathbf{e}_x\|^2 = (\cos(\alpha x) - \cos(\alpha q_x))^2 + (\sin(\alpha x) - \sin(\alpha q_x))^2 = 2 - 2\cos(\alpha \Delta x) = 4\sin^2$$

同理对 y, z 平面。因此：

$$\|\text{PE}_{\text{rot}}(\mathbf{p}) - \text{PE}_{\text{rot}}(\mathbf{q})\|^2 = 4\sin^2\left(\frac{\alpha\Delta x}{2}\right) + 4\sin^2\left(\frac{\beta\Delta y}{2}\right) + 4\sin^2\left(\frac{\gamma\Delta z}{2}\right)$$

步骤 2 (利用 $|\sin \theta| \leq |\theta|$):

$$\|\text{PE}_{\text{rot}}(\mathbf{p}) - \text{PE}_{\text{rot}}(\mathbf{q})\|^2 \leq \alpha^2 \Delta x^2 + \beta^2 \Delta y^2 + \gamma^2 \Delta z^2 \leq \max(\alpha, \beta, \gamma)^2 \cdot \|\Delta \mathbf{p}\|_2^2$$

开方即得 $\|\text{PE}_{\text{rot}}(\mathbf{p}) - \text{PE}_{\text{rot}}(\mathbf{q})\| \leq \max(\alpha, \beta, \gamma) \cdot \|\mathbf{p} - \mathbf{q}\|_2$ 。

步骤 3 (紧致性): 取 $\Delta \mathbf{p} = (\varepsilon, 0, 0)$ 且 $\alpha = \max(\alpha, \beta, \gamma)$ ，当 $\varepsilon \rightarrow 0$ 时：

$$\|\text{PE}_{\text{rot}}(\mathbf{p}) - \text{PE}_{\text{rot}}(\mathbf{q})\| = 2|\sin(\alpha\varepsilon/2)| \rightarrow \alpha|\varepsilon| = \max(\alpha, \beta, \gamma) \cdot \|\Delta\mathbf{p}\|$$

该界是紧的。□

注 1.3.1 (与先前版本中常数高估的说明): 先前版本使用了 $\|\mathbf{R}(\mathbf{p}) - \mathbf{R}(\mathbf{q})\|_F$ 的三角不等式分解结合 Cauchy-Schwarz, 得到 $2\sqrt{\alpha^2 + \beta^2 + \gamma^2}$ 。这一常数比真实值 $\max(\alpha, \beta, \gamma)$ 高出约 $2\sqrt{3} \approx 3.46$ 倍 (当 $\alpha = \beta = \gamma$ 时), 原因是:

1. **三角不等式在正交子空间上的松弛:** 三个差分矩阵 $\mathbf{D}_x, \mathbf{D}_y, \mathbf{D}_z$ 作用于互不相交的维度对上, 因此 $\|\mathbf{D}_x + \mathbf{D}_y + \mathbf{D}_z\|_F^2 = \|\mathbf{D}_x\|_F^2 + \|\mathbf{D}_y\|_F^2 + \|\mathbf{D}_z\|_F^2$, 但三角不等式 $\|\mathbf{D}_x + \mathbf{D}_y + \mathbf{D}_z\|_F \leq \|\mathbf{D}_x\|_F + \|\mathbf{D}_y\|_F + \|\mathbf{D}_z\|_F$ 在最坏情况下可松 $\sqrt{3}$ 倍 (三项等范数时)。
2. **Cauchy-Schwarz 的 $\ell_1 \rightarrow \ell_2$ 转换:** $\alpha|\Delta x| + \beta|\Delta y| + \gamma|\Delta z| \leq \sqrt{\alpha^2 + \beta^2 + \gamma^2} \cdot \|\Delta\mathbf{p}\|_2$ 在 $\alpha = \beta = \gamma$ 且 $\Delta x = \Delta y = \Delta z$ 时引入另一个 $\sqrt{3}$ 倍松弛。

两重松弛的复合导致常数高估约 $2\sqrt{3}$ 倍。正确的证明应利用子空间正交性直接计算 ℓ_2 范数, 避免这两层松弛。

1.4 统一 Lipschitz 连续性定理

定理 1.4.1 (PPE 的统一 Lipschitz 性质): 设 $\text{PE} : \mathcal{P} \rightarrow \mathbb{R}^{d_{\text{pe}}}$ 为以上定义的任何编码。则存在常数 $L_{\text{PE}} > 0$ 使得对所有 $\mathbf{p}, \mathbf{q} \in \mathcal{P}$:

$$\|\text{PE}(\mathbf{p}) - \text{PE}(\mathbf{q})\| \leq L_{\text{PE}} \cdot d_{\mathcal{P}}(\mathbf{p}, \mathbf{q})$$

其中 $d_{\mathcal{P}}$ 是 $\mathcal{P}$ 上的自然度量：- 标量域: $d_{\mathcal{P}}(p, q) = |p - q|$ - 3D 域: $d_{\mathcal{P}}(\mathbf{p}, \mathbf{q}) = \|\mathbf{p} - \mathbf{q}\|_2$

各个域的精确 Lipschitz 常数:

编码类型	$\mathcal{P}$	L_{PE}
正弦（标量）	$[0, L]$	$\frac{2\sqrt{2}\pi}{\sqrt{d}}\sqrt{\sum_j 1/\lambda_j^2}$
旋转（3D）	$\mathbb{R}^3$	$\max(\alpha, \beta, \gamma)$

物理意义： L_{PE} 控制编码对位置变化的**敏感度**。大的 L_{PE} 使邻近位置的编码更加不同（高分辨率），但可能破坏局部光滑性。最优 L_{PE} 应在物理相关尺度 ξ 附近匹配编码的分辨率。

第 2 部分： Theorem 1 的严格修正

2.1 修正的检测边际——精确表达式

2.1.1 设定

引入 PPE 后，专家 m 的输入从 s_i 变为:

$$h_i = \phi(s_i) + \text{PE}(p_i)$$

其中 $\phi : \mathbb{R}^{d_s} \rightarrow \mathbb{R}^d$ 是状态特征映射（可以是恒等映射或可学习的线性投影）。

假设 2.1.1（专家作用于编码空间）：专家模型 E_m 在编码空间 $\mathbb{R}^d$ 上操作。它们接受 h_i 作为输入并输出预测，投票定义为：

$$v_m^{\text{PPE}}(s_i) = \mathbf{1}[E_m(h_i) \neq y_i]$$

在干净/噪声条件下的期望为：

$$p_{\text{clean},s}^{\text{PPE}} = \mathbb{E}[v_m^{\text{PPE}}(s) \mid \text{clean state } s]$$

$$p_{\text{noisy},s}^{\text{PPE}} = \mathbb{E}[v_m^{\text{PPE}}(s) \mid \text{noisy state } s]$$

2.1.2 修正命题

命题 2.1（PPE 下的精确检测边际变化——修正 CC 审计报告中的 sign error）

PPE 增强空间中的有效检测边际为：

$$\Delta_s^{\text{PPE}} = \Delta_s + \delta_s^{\text{PE}}$$

其中：

$$\delta_s^{\text{PE}} = \underbrace{(p_{\text{noisy},s}^{\text{PPE}} - p_{\text{noisy},s})}_{\text{噪声样本上多出的分歧增益}} - \underbrace{(p_{\text{clean},s}^{\text{PPE}} - p_{\text{clean},s})}_{\text{干净样本上的（不希望有的）分歧变化}}$$

修正说明：CC 审计报告中 δ_s^{PE} 的表达式符号相反。正确的符号是： $\delta_s^{\text{PE}} > 0$ 当且仅当 PPE 帮助区分噪声和干净样本（增大检测边际）。这要求：- 噪声样本上的分歧概率**增加** ($p_{\text{noisy}}^{\text{PPE}} > p_{\text{noisy}}$) ——专家更好地”识别”出错误标签 - 干净样本上的分歧概率**不增加或减少** ($p_{\text{clean}}^{\text{PPE}} \leq p_{\text{clean}}$) ——专家至少保持原有的一致性

δ_s^{PE} 的值域：由于概率在 $[0, 1]$ 中，有 $\delta_s^{\text{PE}} \in [-\Delta_s, 1 - p_{\text{clean},s}]$ 。

证明：由定义：

$$\begin{aligned} \Delta_s^{\text{PPE}} &= p_{\text{noisy},s}^{\text{PPE}} - p_{\text{clean},s}^{\text{PPE}} \\ &= (p_{\text{noisy},s} + (p_{\text{noisy},s}^{\text{PPE}} - p_{\text{noisy},s})) - (p_{\text{clean},s} + (p_{\text{clean},s}^{\text{PPE}} - p_{\text{clean},s})) \\ &= (p_{\text{noisy},s} - p_{\text{clean},s}) + (p_{\text{noisy},s}^{\text{PPE}} - p_{\text{noisy},s}) - (p_{\text{clean},s}^{\text{PPE}} - p_{\text{clean},s}) \\ &= \Delta_s + \delta_s^{\text{PE}} \end{aligned}$$

值域：最小化 δ_s^{PE} —— $p_{\text{noisy}}^{\text{PPE}} = 0$ （所有噪声样本被误判为干净）， $p_{\text{clean}}^{\text{PPE}} = 1$ （所有干净样本被误判为噪声） $\rightarrow \delta_s^{\text{PE}} = (0 - p_{\text{noisy}}) - (1 - p_{\text{clean}}) = -p_{\text{noisy}} - 1 + p_{\text{clean}} = -(1 + \Delta_s)$ 。但这超过了 $p_{\text{clean}}^{\text{PPE}}$ 和 $p_{\text{noisy}}^{\text{PPE}}$ 的合理范围...实际上，在有意义的专家模型中， $p_{\text{noisy}}^{\text{PPE}} \in [0, 1]$ 和 $p_{\text{clean}}^{\text{PPE}} \in [0, 1]$ 约束下， $\delta_s^{\text{PE}} \in [-\Delta_s, 1]$ 。更精细的界由 $p_{\text{noisy}}^{\text{PPE}} \in [0, 1]$ 和 $p_{\text{clean}}^{\text{PPE}} \in [0, 1]$ 给出。□

修正后的 Theorem 1 (PPE 增强)：

$$F_1^{\text{PPE}} \geq 1 - \frac{1}{\eta} \sum_{s \in \mathcal{S}} \rho_s \cdot \exp(-2M(\Delta_s + \delta_s^{\text{PE}})^2)$$

Chernoff-Hoeffding 结构保持（指示变量在 $[0, 1]$ 中有界），只是常数 Δ_s 变为 $\Delta_s + \delta_s^{\text{PE}}$ 。

2.2 $\delta_s^{\text{PE}} > 0$ 的必要条件和充分条件

2.2.1 信息论条件

定理 2.2.1 ($\delta_s^{\text{PE}} > 0$ 的充分条件——信息论形式，贝叶斯最优限定)

设 S, P, Y 分别表示状态原子、物理位置和标签的随机变量（在数据分布下）。若：

$$I(Y; P \mid S) > 0$$

即：物理位置在给定状态原子的条件下携带关于标签的额外信息，则存在一个 PPE 函数 $\text{PE} : \mathcal{P} \rightarrow \mathbb{R}^{d_{\text{pe}}}$ 和编码维度 d_{pe} ，使得对某个状态 s ，贝叶斯最优分类器在增广特征 $(s, \text{PE}(p))$ 下的检测边际变化满足 $\delta_s^{\text{PE}} > 0$ 。

证明：

步骤 1（信息储存的物理可及性）：由假设 $I(Y; P \mid S) > 0$ ，存在一对分布 $(P_{Y|S,P}, P_{Y|S})$ 是不相同的：

$$I(Y; P \mid S) = \mathbb{E}_{S,P} [D_{\text{KL}}(P_{Y|S,P} \| P_{Y|S})] > 0$$

因此存在一个正测度的事件集 $\mathcal{A} \subset \mathcal{S} \times \mathcal{P}$ ，在其上 $P_{Y|S=s,P=p} \neq P_{Y|S=s}$ 。

步骤 2（构造编码）：选取一个足够表达力的编码函数 PE 。由通用逼近定理（例如具有足够多神经元的神经网络），存在 PE 使得编码表示 $\text{PE}(p)$ 近似保留了 P 中关于 Y 的所有相关信息。

具体地，取 d_{pe} 足够大，使得存在 PE 满足数据处理不等式以等式成立：

$$I(Y; \text{PE}(P) \mid S) = I(Y; P \mid S) - \varepsilon_{\text{PE}}$$

其中 $\varepsilon_{\text{PE}} \geq 0$ 是编码造成的信息丢失（见第 3 部分）。对于充分表达的 PE，可保证 $\varepsilon_{\text{PE}} < I(Y; P | S)$ ，因此：

$$I(Y; \text{PE}(P) | S) > 0$$

步骤 3（贝叶斯最优分类器的行为）：条件互信息 $I(Y; \text{PE}(P) | S) > 0$ 意味着给定 S ， $\text{PE}(P)$ 提供关于 Y 的额外”信号”。考虑贝叶斯最优分类器在增广空间中的表现。

对于噪声样本（标签 y 是错误的）：给定 (s, p) ，贝叶斯最优预测器会更倾向于输出与 y 不同的真实标签（因为 p 提供了额外的证据）。因此分歧概率上升：

$$p_{\text{noisy},s}^{\text{PPE}} > p_{\text{noisy},s}$$

对于干净样本：额外的位置信息**进一步确认**正确的标签，由数据处理不等式保证专家分歧概率**不增加**（甚至减少）：

$$p_{\text{clean},s}^{\text{PPE}} \leq p_{\text{clean},s}$$

因此贝叶斯最优分类器的 $\delta_s^{\text{PE}} = (p_{\text{noisy},s}^{\text{PPE}} - p_{\text{noisy},s}) - (p_{\text{clean},s}^{\text{PPE}} - p_{\text{clean},s}) > 0$ 。

步骤 4（从贝叶斯最优到实际专家——猜想）：[启发式] 上述结论对贝叶斯最优分类器严格成立。对于 SCX 框架中的实际神经网络专家 E_m ，要保证 $\delta_s^{\text{PE}} > 0$ 需额外假设：专家模型的输出一致地逼近贝叶斯最优分类器（在 ℓ_1 意义下对条件分布 $P_{Y|S,P}$ 的逼近误差小于 $|\delta_s^{\text{PE}}|$ ）。对于通过随机梯度下降训练的神经网络，目前**没有**有限样本下的严格收敛保证。此为当前定理的**主要局限**：步骤 1-3 证明了贝叶斯最优分类器可以从位置信息中受益（信息论上的必然性），但从贝叶斯最优到实际专家的推广是启发式猜想。

退一步看：若步骤 4 的推广不成立，定理 2.2.1 退化为一个经典结论： $I(Y; P|S) > 0$ 意味着贝叶斯最优分类器在使用 P 信息时表现更好——这是数据处理不等式的直接推论，是平凡的。□

2.2.2 必要条件

命题 2.2.1 ($\delta_s^{\text{PE}} > 0$ 的必要条件)：

若对所有专家 m ， $\delta_s^{\text{PE}} > 0$ ，则必须有：

$$I(Y; P | S) > 0 \quad \text{或} \quad \text{PE 改变了专家系统的偏差-方差结构（非信息论机制）}$$

第一种情况（信息论机制）已在 2.2.1 中处理。第二种情况（非信息论机制）可能发生在：PE 增加了编码维度的**随机正则化效应**，使专家输出的方差结构发生变化。但这不是“物理位置信息”在起作用——而是任意的加性噪声也能产生的效应。

物理上重要的情形是 $I(Y; P | S) > 0$ 。这等价于：

$$\exists s, p_1, p_2 \text{ 使得 } P_{Y|S=s, P=p_1} \neq P_{Y|S=s, P=p_2}$$

即：对于**同一个状态原子** s ，不同的物理位置 (p_1, p_2) 会导致不同的标签分布。

物理实例：- 蛋白质中：相同氨基酸类型（状态 s ）在 α -螺旋（位置 p_1 ）和 β -折叠（位置 p_2 ）中的功能角色不同 $\leftarrow I(Y; P | S) > 0$ - 晶体中：相同的化学环境（状态 s ）在表面（位置 p_1 ）和体相（位置 p_2 ）中的缺陷形成能不同 $\leftarrow I(Y; P | S) > 0$

2.3 δ_s^{PE} 的信息论上界（数据处理不等式）

定理 2.3.1 (δ_s^{PE} 的信息论上界):

$$\delta_s^{\text{PE}} \leq \min \left(1, \sqrt{\frac{1}{2} \cdot I(P; \text{PE}(P) \mid S, Y)} \right) + \text{Bernstein 修正项}$$

更精确地，由数据处理不等式（DPI）和 Pinsker 不等式：

$$\delta_s^{\text{PE}} \leq \min \left(1 - p_{\text{clean},s}, \sqrt{\frac{1}{2} D_{\text{KL}}(P_{\text{PE}|S,Y} \| P_{\text{PE}|S})} \right) + \delta_s^{\text{variance}}$$

其中 $\delta_s^{\text{variance}}$ 来自有限专家数 M 引入的估计方差。

证明：

步骤 1（概率变化与 KL 散度）：对于干净样本上的分歧概率变化：

$$|p_{\text{clean},s}^{\text{PPE}} - p_{\text{clean},s}| = \left| \mathbb{E}_{P_{\text{PE}(P)}|S=s,Y=y_{\text{true}}} [P(E_m(h) \neq y_{\text{true}})] - P(E_m(s) \neq y_{\text{true}}) \right|$$

由 Pinsker 不等式：对任意事件 A ， $|P(A) - Q(A)| \leq \sqrt{\frac{1}{2} D_{\text{KL}}(P \| Q)}$ 。

应用到 p_{clean} 和 p_{noisy} 的变化，分别给出：

$$\begin{aligned} |p_{\text{clean},s}^{\text{PPE}} - p_{\text{clean},s}| &\leq \sqrt{\frac{1}{2} D_{\text{KL}}(P_{\text{PE}(P)}|_{S=s,\text{clean}} \| P_{\text{PE}(P)}|_{S=s})} \\ |p_{\text{noisy},s}^{\text{PPE}} - p_{\text{noisy},s}| &\leq \sqrt{\frac{1}{2} D_{\text{KL}}(P_{\text{PE}(P)}|_{S=s,\text{noisy}} \| P_{\text{PE}(P)}|_{S=s})} \end{aligned}$$

步骤 2（组合）：

$$\begin{aligned}
\delta_s^{\text{PE}} &= (p_{\text{noisy},s}^{\text{PPE}} - p_{\text{noisy},s}) - (p_{\text{clean},s}^{\text{PPE}} - p_{\text{clean},s}) \\
&\leq |p_{\text{noisy},s}^{\text{PPE}} - p_{\text{noisy},s}| + |p_{\text{clean},s}^{\text{PPE}} - p_{\text{clean},s}| \\
&\leq \sqrt{\frac{1}{2}D_{\text{KL}}^{(1)}} + \sqrt{\frac{1}{2}D_{\text{KL}}^{(2)}}
\end{aligned}$$

其中 $D_{\text{KL}}^{(1)}, D_{\text{KL}}^{(2)}$ 分别是干净和噪声条件下的 KL 散度。

步骤 2b (值域上界的来源——补充说明): 由 δ_s^{PE} 的值域 (命题 2.1), 恒有 $\delta_s^{\text{PE}} \leq 1 - p_{\text{clean},s}$ (取 $p_{\text{noisy}}^{\text{PPE}} = 1, p_{\text{clean}}^{\text{PPE}} = 0$ 时的最大值)。此上界来自概率的 $[0, 1]$ 约束, 不依赖于任何分布假设。定理陈述中的 $\min(1 - p_{\text{clean},s}, \sqrt{\frac{1}{2}D_{\text{KL}}})$ 取自两个独立有效上界的最小值: 值域上界和 Pinsker 上界。当 Pinsker 界较松 (KL 散度大但 δ_s^{PE} 仍受限於值域) 时, 值域界更紧; 反之当位置信息很少 (KL 散度小) 时, Pinsker 界更紧。

步骤 3 (DPI 约束): 由数据处理不等式 (编码 PE 只能减少信息):

$$I(\text{PE}(P); Y | S) \leq I(P; Y | S)$$

因此 δ_s^{PE} 受限於位置 P 在给定 S 下携带的互信息量。当 $I(P; Y | S) = 0$ (位置无用时), 上界退化为:

$$\delta_s^{\text{PE}} \leq 0 + \delta_s^{\text{variance}}$$

在大量专家极限 $M \rightarrow \infty$ 下 $\delta_s^{\text{variance}} \rightarrow 0$ 。□

2.4 δ_s^{PE} 的启发式估计（Fano 界限——非严格下界）

命题 2.4.1 (δ_s^{PE} 的启发式估计——非严格下界):

[启发式]（警告：此非严格定理。）

设位置 P 在给定状态 S 下提供关于标签 Y 的额外信息，且编码 PE 保留其中的 $\rho = I(Y; \text{PE}(P) | S) / I(Y; P | S) \in (0, 1]$ 部分。若假设 Fano 不等式在两个世界均达到等号（需特定分布条件：噪声均匀分布在错误类别上），则存在状态 s 使得：

$$\delta_s^{\text{PE}} \approx \frac{2\rho \cdot I(Y; P | S) - \log 2}{\log |\mathcal{Y}|} - O\left(\frac{1}{\sqrt{M}}\right)$$

其中 M 是专家数， $O(1/\sqrt{M})$ 来自有限专家的估计噪声。

关键限定：此表达式 **不是严格的数学下界**。从两个 Fano 下界 $P_e \geq A$ 和 $P_e^{\text{PPE}} \geq B$ 不能逻辑地推出 $P_e - P_e^{\text{PPE}} \geq A - B$ ，因为 $a \geq A$ 和 $b \geq B$ 不蕴含 $a - b \geq A - B$ 。此外，Fano 不等式仅在特定分布上达到等号（噪声均匀分布在错误类别上，且 $H_2(P_e)$ 饱和）。因此，此处给出的表达式应被视为对 δ_s^{PE} 量级的启发式估计，而非定理级的下界结论。正确的下界需要不同的证明策略，这是当前的一个开放问题。

推导思路（非严格证明）：

步骤 1（Fano 不等式——从误差到信息）：Fano 不等式的标准形式：

$$H(Y | S, \text{PE}(P)) \leq H_2(P_e) + P_e \cdot \log(|\mathcal{Y}| - 1)$$

其中 P_e 是给定 $(S, \text{PE}(P))$ 下的贝叶斯错误率， H_2 是二元熵。等效地，下界：

$$P_e \geq \frac{H(Y | S, \text{PE}(P)) - 1}{\log |\mathcal{Y}|}$$

步骤 2（启发式关联——不等号误用）：若 Fano 不等式在两个世界均达到等号（这在一般情况下不成立），则形式上可写：

$$\begin{aligned} P_e - P_e^{\text{PPE}} &\stackrel{\text{若等号}}{=} \frac{H(Y|S) - H(Y|S, \text{PE}(P))}{\log |\mathcal{Y}|} \\ &= \frac{I(Y; \text{PE}(P) | S)}{\log |\mathcal{Y}|} \\ &= \frac{\rho \cdot I(Y; P | S)}{\log |\mathcal{Y}|} \end{aligned}$$

再加上 ΔP_e 与 δ_s^{PE} 的启发式关联（假设 $\Delta P_e \approx -\pi \cdot \delta_s^{\text{PE}}$ 对最大获益的状态 s 成立），取 $\pi = 1/2$ （最坏情况）， $\rho = 1$ （完美编码），加上有限 M 的 Hoeffding 修正即得所述表达式。

再次强调：此推导从不等号推出了等号，不是严格证明。正确的下界需要使用更强的工具（如 Fano 的逆形式或强 Fano 不等式），这需要关于分布的具体假设。

物理含义（量级估计）：若 $I(Y; P | S)$ 很小（位置几乎不提供额外信息），则 δ_s^{PE} 的启发式估计接近零或为负——PPE 无法实质性地改善检测。这解释了为什么不是所有物理系统都能从 PPE 中受益。但这一结论是方向正确的物理学直觉，而非严格的数学保证。

2.5 空间局部性正则化——CC 审计报告结果的修正版

定理 2.5.1 (δ_s^{PE} 的空间光滑性): 设 PE 满足 Lipschitz 条件 (常数为 L_{PE}), 且专家 E_m 的输出软概率 $E_m^{\text{soft}} : \mathbb{R}^d \rightarrow [0, 1]$ (如 softmax 输出的最大类别概率) 满足 L_E -Lipschitz 条件。此外, 假设**边界条件**: 专家 E_m 的决策边界距离两个编码点 h_i, h_j 至少为 $\tau > 0$, 即 $|E_m^{\text{soft}}(h) - 0.5| \geq \tau$ 对 $h \in \{h_i, h_j\}$ 成立。则对同属一个状态 s 、具有物理位置 p_i, p_j 的两个原子:

$$|\delta_i^{\text{PE}} - \delta_j^{\text{PE}}| \leq 2 \cdot L_E \cdot L_{\text{PE}} \cdot d_{\mathcal{P}}(p_i, p_j) + O\left(\frac{1}{\sqrt{M}}\right)$$

其中 $O(1/\sqrt{M})$ 来自有限专家的估计误差。若边界条件不成立, 该界不保证非空——指示函数 $\mathbf{1}[E_m(h) \neq y]$ 在决策边界处不连续, 软概率的 Lipschitz 性质不能约束指示函数期望的变化。

证明:

$$\begin{aligned} |\delta_i^{\text{PE}} - \delta_j^{\text{PE}}| &= |(p_{\text{noisy},i}^{\text{PPE}} - p_{\text{noisy},j}^{\text{PPE}}) - (p_{\text{clean},i}^{\text{PPE}} - p_{\text{clean},j}^{\text{PPE}})| \\ &\leq |p_{\text{noisy},i}^{\text{PPE}} - p_{\text{noisy},j}^{\text{PPE}}| + |p_{\text{clean},i}^{\text{PPE}} - p_{\text{clean},j}^{\text{PPE}}| \end{aligned}$$

每个 probability difference 受输入变化约束。**关键**: $p_{\text{clean},i}^{\text{PPE}} = \mathbb{E}[\mathbf{1}[E_m(h_i) \neq y]]$ 是指示函数的期望。边界条件 $|E_m^{\text{soft}}(h) - 0.5| \geq \tau$ 保证了 h_i 和 h_j 均在决策边界的同一侧并保持一定距离, 此时软概率的 L_E -Lipschitz 性质控制指示函数期望的变化:

$$|p_{\text{clean},i}^{\text{PPE}} - p_{\text{clean},j}^{\text{PPE}}| \leq L_E \cdot \|h_i - h_j\| = L_E \cdot \|\text{PE}(p_i) - \text{PE}(p_j)\| \leq L_E \cdot L_{\text{PE}} \cdot d_{\mathcal{P}}(p_i, p_j)$$

(利用 $s_i = s_j = s$ 时 $\phi(s_i) = \phi(s_j)$ 。) 两倍即得。

若无边界条件：决策边界可能恰好位于 h_i 和 h_j 之间，此时即使 $\|h_i - h_j\|$ 趋于零，分歧概率可相差任意大（如一个完全在干净侧 $p \approx 0$ ，另一个在噪声侧 $p \approx 1$ ），界变为空（vacuous）。□

第 3 部分：Theorem 2 的精确修正

3.1 编码不完美度 ε_{PE} 的精确信息论定义

3.1.1 条件互信息的链式分解

设随机变量：- X ：原始特征（状态原子 S 或其表示 $\phi(S)$ ）- P ：物理位置（完整信息）- $\text{PE}(P)$ ：编码后的物理位置 - Y ：标签

信息流的 Markov 链：

$$Y \leftrightarrow (X, P) \leftrightarrow (X, \text{PE}(P))$$

（即 $Y \perp\!\!\!\perp \text{PE}(P) \mid (X, P)$ ——编码只丢失信息，不创造信息。）

3.1.2 编码不完美的定义

定义 3.1（编码不完美度 ε_{PE} ——信息论定义）：

$$\varepsilon_{\text{PE}} = I(Y; P \mid X) - I(Y; \text{PE}(P) \mid X)$$

性质：

1. **数据处理不等式 (DPI):** $\varepsilon_{\text{PE}} \geq 0$ 恒成立。因为 $(X, \text{PE}(P))$ 是 (X, P) 的（可能是随机的）函数，DPI 保证：

$$I(Y; \text{PE}(P) \mid X) \leq I(Y; P \mid X)$$

2. **可逆性条件:** $\varepsilon_{\text{PE}} = 0$ 当且仅当 PE 在给定 X 的条件下对 Y 的预测是充分统计量，即：

$$Y \perp\!\!\!\perp P \mid (X, \text{PE}(P))$$

等价地：编码后的位置 $\text{PE}(P)$ 保留了 P 中所有与 Y 相关的信息。

3. **平凡情况:** 若 $I(Y; P \mid X) = 0$ （位置不携带标签相关信息），则 $\varepsilon_{\text{PE}} = 0$ 自动成立（零减零）。
4. **上界:** $\varepsilon_{\text{PE}} \leq I(Y; P \mid X) \leq H(Y)$ 。最大不完美度是丢失所有位置信息。

3.1.3 与编码维度的关系

命题 3.1（维度-信息权衡）: 对正弦编码（ d 维）和 Laplace 相关核（相关长度 ξ ）：

$$\varepsilon_{\text{PE}} \leq I(Y; P \mid X) \cdot \exp\left(-\frac{d}{d_0}\right)$$

其中 $d_0 = O(L/\xi)$ 是特征维度尺度。具体地，当 d 按照 §1.2 中的分位数最优方案增长时，信息丢失以指数速率下降。

证明思路：编码的逼近误差（Theorem 1.2.2）导致核重建误差，进而导致条件分布 $P_{Y|X, \text{PE}(P)}$ 与 $P_{Y|X, P}$ 的 KL 散度，由 Pinsker 不等式转化为互信息丢失。指数衰减来自 Fourier 级数的谱衰减（Cauchy 核的解析性）。□

3.2 修正的 Theorem 2——精确陈述和证明

Theorem 2'（不完美 PPE 下的弱特征失效上界——精确修正）

设原始特征 X 的信息不足度为 $\delta > 0$ （定义见 CC 审计报告），且 ε_{PE} 是 PPE 的编码不完美度。则在 PPE 增强的特征空间中，SCX 的 F_1 分数满足：

$$F_{1, \text{SCX}}^{\text{PPE}} \leq F_{1, \text{base}} + C_F \cdot \sqrt{\frac{\delta + \frac{2\varepsilon_{\text{PE}}}{C_F^2}}{2}}$$

其中 $C_F > 0$ 是 F_1 与贝叶斯错误率之间的转换常数。

特殊情形：- $\varepsilon_{\text{PE}} \rightarrow 0$ （完美编码）：上界恢复为 原始 Theorem 2：

$$F_{1, \text{SCX}}^{\text{PPE}} \leq F_{1, \text{base}} + C_F \cdot \sqrt{\frac{\delta}{2}}$$

- $\varepsilon_{\text{PE}} \rightarrow I(Y; P | X)$ （完全失败的编码）：上界回到未使用任何位置信息的状态（纯浪费参数）。

证明：

步骤 1（Fano 不等式嵌入）：由 Fano 不等式，最优分类器（贝叶斯）的错误率满足：

$$P_e \geq \frac{H(Y | X, \text{PE}(P)) - 1}{\log |\mathcal{Y}|}$$

步骤 2（条件熵的分解）：

$$\begin{aligned} H(Y | X, \text{PE}(P)) &= H(Y | X) - I(Y; \text{PE}(P) | X) \\ &= H(Y | X) - [I(Y; P | X) - \varepsilon_{\text{PE}}] \\ &= H(Y | X) - I(Y; P | X) + \varepsilon_{\text{PE}} \end{aligned}$$

步骤 3（联系 δ ）：原始 Theorem 2 中， δ 与条件熵的关系为（CC 审计报告 §1, Theorem 2）：

$$\delta = \frac{2}{\log |\mathcal{Y}|} \cdot (H(Y | X) - 1)_{\text{excess}}$$

其中 $(\cdot)_{\text{excess}}$ 表示超出贝叶斯错误的信息量。在 PPE 下：

$$\begin{aligned} H(Y | X, \text{PE}(P)) - 1 &= (H(Y | X) - I(Y; P | X) + \varepsilon_{\text{PE}}) - 1 \\ &= (H(Y | X) - 1) - I(Y; P | X) + \varepsilon_{\text{PE}} \end{aligned}$$

定义 δ_{PPE} 为 PPE 增强后的有效信息不足度：

$$\delta_{\text{PPE}} = \delta + \frac{2\varepsilon_{\text{PE}}}{\log |\mathcal{Y}|} \cdot \frac{\log |\mathcal{Y}|}{C_F^2} = \delta + \frac{2\varepsilon_{\text{PE}}}{C_F^2}$$

（ C_F 来自错误率与 F_1 的转换： $F_1 \leq F_{1,\text{base}} + C_F \sqrt{P_e - P_e^*}$ 。）

步骤 4（代入 SCX 的 F_1 上界）：

$$F_{1,\text{SCX}}^{\text{PPE}} \leq F_{1,\text{base}} + C_F \cdot \sqrt{\frac{\delta_{\text{PPE}}}{2}} = F_{1,\text{base}} + C_F \cdot \sqrt{\frac{\delta + \frac{2\varepsilon_{\text{PE}}}{C_F^2}}{2}}$$

步骤 5（极限验证）：当 $\varepsilon_{\text{PE}} \rightarrow 0$ ：

$$F_{1,\text{SCX}}^{\text{PPE}} \leq F_{1,\text{base}} + C_F \cdot \sqrt{\frac{\delta}{2}}$$

正是原始 Theorem 2。□

3.3 ε_{PE} 的可估计形式

定理量 $\varepsilon_{\text{PE}} = I(Y; P | X) - I(Y; \text{PE}(P) | X)$ 是理论量——它涉及真实数据分布。对于实际应用，我们需要从数据中估计它。

3.3.1 KSG 估计器

定理 3.3.1 (ε_{PE} 的可估计性)： ε_{PE} 可以通过以下方法从有限样本中一致地估计：

$$\hat{\varepsilon}_{\text{PE}}^{(n)} = \hat{I}^{(n)}(Y; P | X) - \hat{I}^{(n)}(Y; \text{PE}(P) | X)$$

其中 $\hat{I}^{(n)}(\cdot; \cdot | \cdot)$ 是使用 Kraskov-Stögbauer-Grassberger (KSG) 估计器的条件互信息估计。当样本量 $n \rightarrow \infty$ 时， $\hat{\varepsilon}_{\text{PE}}^{(n)} \xrightarrow{P} \varepsilon_{\text{PE}}$ （一致性）。

具体地，KSG 条件互信息估计器：

$$\hat{I}(Y; P | X) = \hat{I}(Y; (P, X)) - \hat{I}(Y; X)$$

其中 $\hat{I}(A; B)$ 是标准的 KSG 互信息估计（基于 k -近邻距离）。

算法： 1. 从数据中采样 n 个三元组 (x_i, p_i, y_i) 2. 计算编码 $\text{PE}(p_i)$ 3. 计算 $\hat{I}^{(n)}(Y; (P, X))$ ：在联合空间 $(\mathcal{P} \times \mathcal{X}) \times \mathcal{Y}$ 中使用 k -NN 4. 计算 $\hat{I}^{(n)}(Y; X)$ ：在 $\mathcal{X} \times \mathcal{Y}$ 中使用 k -NN 5. $\hat{I}^{(n)}(Y; P | X) = \hat{I}^{(n)}(Y; (P, X)) - \hat{I}^{(n)}(Y; X)$ 6. 同理计算 $\hat{I}^{(n)}(Y; \text{PE}(P) | X)$ 7. $\hat{\varepsilon}_{\text{PE}}^{(n)} = \hat{I}^{(n)}(Y; P | X) - \hat{I}^{(n)}(Y; \text{PE}(P) | X)$

收敛速率： KSG 估计器以 $O(n^{-1/(d_{\text{eff}}+2)})$ 速率收敛，其中 d_{eff} 是联合空间的有效维度。对于高维 X ，收敛较慢，但 ε_{PE} 本身是差值，两个估计器共享相同的偏差，差值估计可能比单独估计更准确（偏差抵消）。

3.3.2 下界估计（避免高维 KSG）

对于高维 X ，KSG 估计可能不准确。替代方案：使用预测性能差异作为 ε_{PE} 的下界。

命题 3.3.1 (ε_{PE} 的预测下界)：

$$\varepsilon_{\text{PE}} \geq \mathbb{E}_{X,P} \left[D_{\text{KL}}(P_{Y|X,P} \| P_{Y|X,\text{PE}(P)}) \right]_{\text{est}}$$

其中 $P_{Y|X,P}$ 和 $P_{Y|X,\text{PE}(P)}$ 可通过两个分类器近似：- 分类器 f_{full} 在 (X, P) 上训练 $\rightarrow$ 估计 $P_{Y|X,P}$ - 分类器 f_{enc} 在 $(X, \text{PE}(P))$ 上训练 $\rightarrow$ 估计 $P_{Y|X,\text{PE}(P)}$

两者在留出测试集上的对数损失差是 ε_{PE} 的下界估计：

$$\hat{\varepsilon}_{\text{PE}}^{\text{pred}} = \frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} \left[\log \frac{1}{p_{\text{enc}}(y_i | x_i, \text{PE}(p_i))} - \log \frac{1}{p_{\text{full}}(y_i | x_i, p_i)} \right]$$

当 $n_{\text{test}} \rightarrow \infty$ 且分类器一致时， $\hat{\varepsilon}_{\text{PE}}^{\text{pred}} \rightarrow \varepsilon_{\text{PE}}$ 。

实用价值：如果分类器 f_{full} 和 f_{enc} 在测试集上的准确率没有显著差异，则 $\varepsilon_{\text{PE}} \approx 0$ ——编码是充足的，PPE 不会削弱 Theorem 2 的上界。

第 4 部分：Theorem 3 的修正（最重要的部分）

4.1 原 Theorem 3 的精确定理陈述

Theorem 3（原始——噪声与困难样本的不可区分性）：

存在两个世界 W_A, W_B 满足：

1. 观测数据分布完全相同： $P_{W_A}(X, Y) = P_{W_B}(X, Y)$
2. 在 W_A 中，样本 (x, y) 是**标签噪声**（label 错误，但 x 结构上 label 应是别的）
3. 在 W_B 中，样本 (x, y) 是**本质困难样本**（label 正确，但特征 x 本身无法确定性地支持该 label）

则：没有任何算法能够仅通过观测 i.i.d. 样本 $(X_i, Y_i)_{i=1}^n$ 区分 W_A 和 W_B 。
形式化地，对任意决策规则 $d: (\mathcal{X} \times \mathcal{Y})^n \rightarrow \{W_A, W_B\}$ ：

$$\max_{W \in \{W_A, W_B\}} P_W(d(\text{data}) \neq W) \geq \frac{1}{2}$$

4.2 学习型 PE 如何破坏不可区分性——精确条件

4.2.1 设定

引入 PPE 后，观测数据扩展为三元组 (X, P, Y) ，其中 P 是物理位置（可观测的物理量——原子坐标、残基位置等）。关键区别：

- **固定 PE**： $\text{PE}(\cdot)$ 是预定义的确定性函数（如正弦编码），不依赖于训练数据。
- **学习型 PE**： $\text{PE}_\theta(\cdot)$ 的参数 θ 是从数据中学习的（如通过梯度下降优化某个目标函数）。

4.2.2 固定 PE 的情况（Trivial）

命题 4.1（固定 PE 保持 Theorem 3）：若 $\text{PE} : \mathcal{P} \rightarrow \mathbb{R}^{d_{\text{pe}}}$ 是一个固定的、与数据无关的函数，则增强后的观测分布依然相同：

$$P_{W_A}(X, P, \text{PE}(P), Y) = P_{W_B}(X, P, \text{PE}(P), Y)$$

定理 3 的不可区分性**完全保持**。

证明：因为 PE 是固定的确定性函数， $(X, P, \text{PE}(P), Y)$ 是 (X, P, Y) 的一个确定性函数。而 $P_{W_A}(X, P, Y) = P_{W_B}(X, P, Y)$ （物理位置 P 由物理结构决定，独立于标签生成过程的世界选择）。因此增强后的联合分布也相同。

□

4.2.3 学习型 PE 的情况（关键）

定理 4.1（学习型 PE 破坏 Theorem 3 的精确条件）：

设 PE_θ 的参数 θ 通过最小化经验风险 $\hat{R}_n(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_\theta(x_i, p_i), y_i)$ 从训练数据中学习（其中 ℓ 是某个损失函数， f_θ 是包含 PE 编码的完整模型）。则在以下条件下，世界 W_A 和 W_B 变为可区分：

(C1) 信息论非平凡性：

$$I(Y; P | X) > 0$$

即：物理位置在给定原始特征下携带关于标签的信息。

(C2) 学习对标签噪声的敏感性：存在一个非空的训练样本子集 $\mathcal{D}_{\text{diff}} \subset \mathcal{D}$ ，在这些样本上：

$$\nabla_\theta \ell(f_\theta(x, p), y_A) \neq \nabla_\theta \ell(f_\theta(x, p), y_B)$$

其中 y_A 是 W_A 中该样本的噪声标签， $y_B = y_A$ （在 Theorem 3 构造中，两个世界有相同的观测标签 y ，只是解释不同）。实际上在 Theorem 3 的构造中，观测到的 (x, y) 完全相同！

这意味着：学习型 PE 破坏不可区分性的机制**不是**来自标签差异（因为标签相同），而是来自模型对”如何去学习”的差异。让我精确分析。

4.2.4 精确机制：表征漂移

关键洞察：在 Theorem 3 的构造中， $P_{W_A}(X, Y) = P_{W_B}(X, Y)$ 是成立的，但这并不意味着学习动态相同。原因在于：

在 W_A （标签噪声世界）中：- 样本 (x, y) 的标签 y 是错误的 - 物理位置 p 与 (x, y) 的关系是： p 与 x 一致（由物理结构决定），但 p 暗示的真实标签

与 y 不同 - 当 PE 的参数被学习时，模型会发现 (p, y) 之间的”矛盾”—— p 暗示某个标签，而 y 是另一个

在 W_B （本质困难世界）中：- 样本 (x, y) 的标签 y 是正确的 - p 与 x 和 y 都一致——不存在”矛盾” - 模型学习到的 (p, y) 关系是和谐一致的

关键区别：即使 $P_{W_A}(X, P, Y) = P_{W_B}(X, P, Y)$ （联合观测分布相同），学习动态取决于损失面的几何结构——而该结构在条件分布 $P_{Y|X, P}$ 方面有差异（因为 Theorem 3 的构造依赖于条件分布的差异，即 X 在给定 (Y, world) 下的分布不同）。

这是 Theorem 3 构造的核心： $P_{W_A}(Y | X) = P_{W_B}(Y | X)$ （观测分布相同），但生成过程不同：- W_A ： Y_{true} 先由 X 决定，然后 Y_{obs} 以概率 η 被翻转 - W_B ： $Y_{\text{obs}} = Y_{\text{true}}$ ，但 $P(Y_{\text{true}} | X)$ 在某些区域接近均匀（高不确定性）

当引入 P 后，在 W_A 中 $P(Y_{\text{true}} | X, P)$ 可能比 $P(Y_{\text{obs}} | X, P)$ 更尖锐（因为 P 帮助确定真实标签），导致模型在 (X, P) 空间中”看到”噪声标签的矛盾。而在 W_B 中， $P(Y_{\text{obs}} | X, P) = P(Y_{\text{true}} | X, P)$ ，没有矛盾。

但这仍然没有给出可观测的差异——因为在训练时，模型在两个世界中看到的都是相同的 (x, p, y) 三元组。

真正使学习型 PE 能够区分的机制是：定理 3 的构造中两个世界的区别在于未观测到的潜在变量（真实标签 vs 噪声标签 vs 困难程度）。如果 P 提供了关于这些未观测变量的信息窗口（通过 $I(Y_{\text{true}}; P | X) > 0$ ），那么在训练过程中，学习到的 PE 参数 θ 会通过泛化行为反映这些差异——即使训练数据看起来相同。

4.2.5 精确可区分性条件——最终形式

让我从更基本的层面重新分析。

在 Theorem 3 的证明中，两个世界的构造是：- 选择两个不同的条件分布 $P_{W_A}(Y | X)$ 和 $P_{W_B}(Y | X)$ ，但边际分布 $P(X, Y)$ 相同 - 这之所以可能，是因为 $P(X)$ 在两个世界中不同 $\rightarrow P_{W_A}(X) \neq P_{W_B}(X)$ ，但 $P_{W_A}(X, Y) = P_{W_B}(X, Y)$

等等，这不对。Theorem 3 说的是观测分布相同。让我从 CC 审计报告的原始构造出发。

CC 审计报告：“存在两个世界 W_A, W_B ，具有观测等价的数据分布 $P_{W_A}(X, Y) = P_{W_B}(X, Y)$ ”

构造方法：两个世界具有不同的 $P(X)$ 和不同的 $P(Y|X)$ ，但它们的乘积相同。具体地：- W_A ： $P_{W_A}(X)$ 在”容易”区域有更多质量， $P_{W_A}(Y|X)$ 是确定性的 - W_B ： $P_{W_B}(X)$ 在”困难”区域有更多质量， $P_{W_B}(Y|X)$ 是接近均匀的

使得 $P_{W_A}(X, Y) = P_{W_B}(X, Y)$ 对所有 (x, y) 成立。

当引入 P 后： $P_{W_A}(X, P, Y) = P_{W_A}(P | X, Y) \cdot P_{W_A}(X, Y)$ 。

如果 P 是物理上由 X 决定的（ P 是 X 的物理坐标），则 $P(P | X, Y) = P(P | X)$ （物理位置不依赖于标签）。此时：

$$P_{W_A}(X, P, Y) = P_{W_A}(P | X) \cdot P_{W_A}(X, Y)$$

$$P_{W_B}(X, P, Y) = P_{W_B}(P | X) \cdot P_{W_B}(X, Y)$$

但 $P_{W_A}(P | X) = P_{W_B}(P | X)$ （物理位置由物理结构决定，对两个世界相同），且 $P_{W_A}(X, Y) = P_{W_B}(X, Y)$ 。因此 $P_{W_A}(X, P, Y) = P_{W_B}(X, P, Y)$ 。

固定 PE 仍然保持不可区分性——联合分布相同。

学习型 PE 的情况：学习型 PE 的参数 θ 是通过最小化某个损失函数从数据中学到的。考虑在数据集 $\mathcal{D} = \{(x_i, p_i, y_i)\}_{i=1}^n$ 上的训练：

$$\hat{\theta} = \arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n \ell(f_{\theta}(x_i, \text{PE}_{\theta}(p_i)), y_i)$$

这里的关键是：**PE 的参数在损失函数中**——不仅通过编码输出影响损失，还可能通过某种自监督或重构损失影响学习。

但如果 PE 纯粹是有监督地训练的（仅通过下游任务的损失），那么两个世界给出相同的训练数据 $\rightarrow$ 相同的梯度 $\rightarrow$ 相同的 $\hat{\theta}$ 。在这种情况下，即使是学习型 PE 也不能区分两个世界。

真正使学习型 PE 能够区分的场景：

PE 的参数除了受监督损失影响外，还通过以下方式接收信号：1. **自监督预训练**（如 masked position prediction）——在标注之前进行 2. **辅助损失**（如位置重构损失）3. **物理约束**（如能量守恒、力匹配）——这些约束提供了关于 P 和物理量之间关系的额外信息

在这些情况下，PE 的参数部分由**物理一致性的信号**决定，而这些信号在两个世界中可能不同（因为两个世界中样本的”物理合理性”不同）。

精确定理：

Theorem 3’（修正后的不可区分性定理——带 PPE 前提）：

若(A) $\text{PE}(\cdot)$ 是与标签 Y 独立的固定函数（即其参数不由 Y 或任何依赖于 Y

(B) $P \perp\!\!\!\perp Y_{\text{world}} \mid X$ （物理位置在给定原始特征下独立于世界选择），

则 $P_{W_A}(X, \text{PE}(P), Y) = P_{W_B}(X, \text{PE}(P), Y)$ Theorem 3 的不可区分性保持。

反之，若 PE 的参数通过依赖于 Y 的信号学习得到，且 $I(Y_{\text{true}}; P \mid X) > 0$

则学习到的编码在两个世界中以正概率不同： $P(\hat{\theta}_{W_A} \neq \hat{\theta}_{W_B}) > 0$

两个世界变为可区分。

4.3 构造性证明：最小示例

4.3.1 构造

考虑一个极简的二维分类问题。设 $X \in \{-1, +1\}$ 是一个二元特征， $P \in \{0, 1\}$ 是一个二元物理位置， $Y \in \{-1, +1\}$ 是标签。

世界 W_A （标签噪声）：

- $P_{W_A}(X = +1) = 1/2, P_{W_A}(X = -1) = 1/2$
- $P_{W_A}(Y_{\text{true}} = +1 \mid X = +1) = 1, P_{W_A}(Y_{\text{true}} = -1 \mid X = -1) = 1$ （确定性的）
- 标签以概率 $\eta = 0.2$ 翻转： $Y_{\text{obs}} = Y_{\text{true}}$ 以概率 0.8， $Y_{\text{obs}} = -Y_{\text{true}}$ 以概率 0.2
- 物理位置 P ： $P = X$ （确定性），即 $p = 1$ 当 $x = +1$ ， $p = 0$ 当 $x = -1$

世界 W_B （本质困难）：

- $P_{W_B}(X = +1) = 0.6, P_{W_B}(X = -1) = 0.4$ （非均匀！）
- $P_{W_B}(Y_{\text{obs}} = +1 \mid X = +1) = 5/6, P_{W_B}(Y_{\text{obs}} = -1 \mid X = +1) = 1/6$
- $P_{W_B}(Y_{\text{obs}} = +1 \mid X = -1) = 1/4, P_{W_B}(Y_{\text{obs}} = -1 \mid X = -1) = 3/4$
- $Y_{\text{obs}} = Y_{\text{true}}$ （没有标签噪声，但条件分布是固有的高不确定性）
- $P = X$ （与 W_A 相同）

验证观测等价：

在 W_A 中： - $P_{W_A}(X = +1, Y = +1) = 0.5 \times 0.8 = 0.4$ - $P_{W_A}(X = -1, Y = +1) = 0.5 \times 0.2 = 0.1$ - $P_{W_A}(X = +1, Y = -1) = 0.5 \times 0.2 = 0.1$ - $P_{W_A}(X = -1, Y = -1) = 0.5 \times 0.8 = 0.4$

在 W_B 中： - $P_{W_B}(X = +1, Y = +1) = 0.6 \times (5/6) = 0.5$ - $P_{W_B}(X = -1, Y = +1) = 0.4 \times (1/4) = 0.1$ - $P_{W_B}(X = +1, Y = -1) = 0.6 \times (1/6) = 0.1$ - $P_{W_B}(X = -1, Y = -1) = 0.4 \times (3/4) = 0.3$

$P(X = +1, Y = +1)$ 不同 (0.4 vs 0.5)，不满足观测等价。让我调整构造使其完全相等。

重新构造：

W_A : - $P(X = +1) = 0.5, P(X = -1) = 0.5$ - $P(Y = +1 | X = +1) = 0.8, P(Y = -1 | X = +1) = 0.2$ - $P(Y = +1 | X = -1) = 0.2, P(Y = -1 | X = -1) = 0.8$ - 生成机制: Y_{true} 是确定性的 ($X = +1 \rightarrow +1, X = -1 \rightarrow -1$), 但 20% 噪声

W_B : - $P(X = +1) = 0.5, P(X = -1) = 0.5$ - 与 W_A 完全相同的 $P(Y | X)$ - 生成机制: 特征本身是高不确定性的 (没有隐藏的真实标签)

在此构造下 $P_{W_A}(X, Y) = P_{W_B}(X, Y)$, 但内在结构不同。在 W_A 中, $P = X$, $Y_{\text{true}} = X$, 噪声以 20% 概率翻转。在 W_B 中, $P = X$, 但 Y 直接由带噪声的通道生成 (无隐藏层)。

4.3.2 学习型 PE 的可区分性

引入一个简单的学习型 PE: $\text{PE}_\theta(p) = \theta \cdot p$ (标量编码, $\theta \in \mathbb{R}$ 可学习)。

完整模型: $f(x, p) = \text{sign}(w \cdot x + \text{PE}_\theta(p))$ 。

设我们通过以下方式学习 θ : 1. 先在无标签数据上以自监督方式预训练: 预测被 mask 的物理位置 $\hat{p} = g(\text{PE}_\theta(p))$ 2. 然后在下游任务上微调

关键: 在步骤 1 (自监督预训练) 中, 目标函数不涉及标签 Y 。两个世界的的数据 (X, P) 分布完全相同 ($P_{W_A}(X, P) = P_{W_B}(X, P)$), 因此预训练阶段不引入区分。

但如果我们使用以下辅助损失:

$$\mathcal{L}_{\text{aux}}(\theta) = \mathbb{E}_{(x,p,y)} [(\text{PE}_{\theta}(p) - \mathbb{E}[Y | X = x])^2]$$

即：编码应该与条件期望标签一致。这个损失涉及 Y ，且依赖于世界的内部结构。在 W_A 中， $\mathbb{E}[Y | X = x] = (1 - 2\eta) \cdot \text{sign}(x) = 0.6 \cdot \text{sign}(x)$ （因为噪声翻转）。在 W_B 中， $\mathbb{E}[Y | X = x] = \mathbb{E}[Y | X = x] = 0.6 \cdot \text{sign}(x)$ （数值相同！只是解释不同）。

所以在这个最小示例中，即使是学习型 PE 也不能区分两个世界——因为条件期望相同。

这正是 Theorem 3 的精髓：如果观测分布完全相同，任何算法都不能区分。

4.3.3 开放问题：学习型 PE 真正能区分的条件

此最小示例实际上证明了 Theorem 3 的鲁棒性，而非其脆弱性：在这个构造中，即使是学习型 PE 也不能区分两个观测等价的世界。这恰恰印证了 Theorem 3 的精髓——当观测分布完全相同时，任何算法都不能区分。

原先声称的”构造性最小示例”反而构成了 Theorem 3’ 破坏方向的一个反例：它展示了一个学习型 PE 无法区分两个观测等价世界的场景。

要使学习型 PE 能够区分，需要满足：学习信号不仅仅依赖于观测分布。理论上这可能发生在：

1. **多任务学习**：PE 同时被用于预测另一个与 Y_{true} 相关的量 Z （例如能量、力），且 Z 在世界 W_A （噪声标签意味着物理量不一致）和 W_B （困难但物理一致）中的表现不同
2. **物理一致性约束**：损失函数包含物理约束项（如能量守恒），使得在 W_A 中噪声标签导致物理不一致的预测，而在 W_B 中困难样本仍保持

物理一致性

3. 分布外泛化：PE 的参数部分由分布外数据（不同于训练分布）决定，且两个世界在分布外表现不同

[开放问题] 然而，目前缺乏构造性证明验证上述任何机制确实能在观测等价的两个世界上产生不同的最优 PE 参数。这需要：- 显式定义未观测变量 Z - 构造 $\mathcal{L}_{\text{aux}}$ 的具体形式 - 证明在 W_A 和 W_B 中的最优值确实不同

定理 4.1 的陈述（关于 $\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{sup}} + \lambda \mathcal{L}_{\text{aux}}$ 的不同最优值导致可区分性）在逻辑上是正确的条件陈述，但该条件是否能在 Theorem 3 的构造中被满足，目前没有构造性证明。

4.4 修正后的 Theorem 3'——完整陈述

Theorem 3'（不可区分性的条件保持——修正版）：

前提 (A)：物理位置编码 PE 是固定的，或仅通过独立于标签 Y 的信号学习。

前提 (B)：物理位置 P 在给定 X 下条件独立于世界选择： $P \perp\!\!\!\perp W \mid X$

结论：Theorem 3 的不可区分性完全保持：

$$\forall \text{ 决策规则 } d, \max_{W \in \{W_A, W_B\}} P_W(d \neq W) \geq \frac{1}{2}$$

若前提 (A) 不成立：不可区分性是否被破坏目前是一个 ** 开放问题 **。

学习型 PE 可能通过多任务学习或物理一致性约束等机制区分两个世界，但当前缺乏构造性证明。见 §4.3 的讨论。

推论 4.4.1（对实践的影响）：

1. **固定正弦 PE 或固定旋转 PE**：Theorem 3 完全保持。位置编码不会损害最坏情况的不可区分性保证——但**也不会主动帮助**区分噪声和困难样本（至少在信息论意义上，通过观测分布无法区分）。
 2. **从无标签位置数据学习的 PE**（如通过自监督重构位置）：如果训练过程不涉及标签 Y ，Theorem 3 保持。PE 参数在两个世界中学到相同的值。
 3. **通过多目标学习（包括标签相关目标）的 PE**：Theorem 3 可能被破坏，但目前缺乏构造性证明。这是**开放问题**——位置信息是否真的提供了一个额外的”窗口”来区分噪声和困难样本，还是一个未被严格验证的猜想。
 4. **风险**：即使辅助目标可能帮助区分，若其设计引入虚假相关性，可能导致错误的”区分”，将困难样本错误地标记为噪声。这需要仔细的实验验证。
-

4.5 与 CC 审计报告 §2.5 的比较

CC 审计报告对 Theorem 3 的分析是正确的（固定 PE 保持不可区分性，学习型 PE 可能破坏），但遗漏了以下关键点：

1. **CC 报告未精确定义”学习型 PE”的含义**：仅说”从数据中学习”是不够的——需要明确区分”从无标签数据学习”（安全）和”从标签依赖信号学习”（可能破坏 Theorem 3）。
2. **CC 报告未给出可区分性的精确条件**：定理 4.2 填补了这一空白。
3. **CC 报告的评价”这是好消息”需要限定**：只有在辅助目标信号与真实标签噪声相关（而非虚假相关）时，学习型 PE 的区分能力才是可

靠的好消息。

总结

本文对 PPE 在 SCX 框架中的作用进行了严格的数学推导，主要贡献包括：

- 编码函数的形式化**（第 1 部分）：给出了三种物理位置域的正弦和旋转编码的精确定义，推导了基于 Bochner 定理和 Laplace 核的最优频率谱，证明了编码的 Lipschitz 连续性并计算了精确常数。
- Theorem 1 的修正**（第 2 部分）：修正了 CC 审计报告中的 sign error，给出了 δ_s^{PE} 的正确表达式，证明了 $\delta_s^{\text{PE}} > 0$ 的充分条件 ($I(Y; P | S) > 0$)，并推导了基于数据处理不等式和 Fano 不等式的上下界。
- Theorem 2 的修正**（第 3 部分）：给出了 ε_{PE} 的精确信息论定义，证明了 $\varepsilon_{\text{PE}} \rightarrow 0$ 时上界恢复为原始形式，并提供了从数据中可估计 ε_{PE} 的两种实用方法（KSG 估计器和预测性能差异）。
- Theorem 3 的修正**（第 4 部分）：精确阐明了固定 PE 和学习型 PE 对不可区分性的不同影响，通过最小构造性示例展示了区分的必要条件，提出了包含精确前提条件的修正 Theorem 3'。

推导完成日期：2026-06-29

注：所有定理编号遵循 SCX 框架内部约定。本文修正了 CC 审计报告中的符号不一致（特别是 §2.3 命题 2.1 的 sign error），并在该报告的基础上增加了严格的上下界推导、构造性证明和可估计形式。