

Situs (Physical Positional Encoding) 物理真实性验证与适用场景分析

文档状态: 诚实暴击 — 不委婉

前置阅读: ppe_rigorous_derivation.md(严密数学推导),multi_head_spring_and_positional(CC 审计报告)

方法论: 真实物理数据 + 数学定理的物理对应 + 逐一场景论证

核心判据: 定理 2.2.1 — $\delta_s^{\text{PE}} > 0 \iff I(Y; P | S) > 0$, 即物理位置在给定状态原子条件下必须携带关于标签的额外信息

第 1 部分: 物理真实性检查

1.1 蛋白质序列位置编码

1.1.1 相同氨基酸, 不同位置: Lys-37 (活性位点) vs Lys-289 (表面 loop)

生物学事实 (无可争议):

同一个赖氨酸残基在蛋白质不同位置具有完全不同的功能角色: - **活性位点 Lys-37**: 典型催化残基, 侧链 pKa 可偏离溶液值 2-4 个单位 (从 ~10.5 降至 6.0-8.0), 参与酸碱催化或共价催化。例如: acetoacetate decarboxylase 中 Lys-115 的 pKa 6.0 [Bartlett et al., *J. Mol. Biol.* 324, 105 (2002)]; ribonuclease

A 中 Lys-41 的 pKa 8.8 [Raines, *Chem. Rev.* 98, 1045 (1998)]。高度保守，对突变极度敏感 ($\Delta\Delta G > 3$ kcal/mol 常见)。- **表面 loop Lys-289**：溶剂暴露，pKa 接近溶液值 (10.4–10.6)，功能上多参与非特异性静电相互作用或蛋白质-蛋白质识别界面，保守性低，对突变容忍度高 ($\Delta\Delta G$ 通常 < 1 kcal/mol)。

物理判断：

$I(Y; P \mid S) > 0$ ——在给定”氨基酸类型 = Lys”的条件下，残基位置携带大量功能信息

物理量	Lys-37（活性位点）	Lys-289（表面 loop）	差异来源
侧链 pKa	6.0–8.0	10.4–10.6	局部静电环境 (Buried vs 溶剂暴露)
SASA (溶剂可及表面积)	$< 10 \text{ \AA}^2$	$> 100 \text{ \AA}^2$	3D 折叠位置
进化保守性 (BLO-SUM62 位置熵)	< 0.2 bits	> 0.8 bits	功能约束强度
突变 $\Delta\Delta G$	> 3 kcal/mol	< 1 kcal/mol	折叠稳定性贡献

BUT——关键限制：

Situs 的正弦编码编码的是**序列位置**（1D 残基编号 37 vs 289），而非**3D 空间位置**（活性位点口袋 vs 表面）。这是 Situs 在蛋白质应用中的根本缺陷：

- 序列位置 $\rightarrow$ 3D 位置映射**不是函数关系**。同源蛋白中，序列位置 37 在 homolog A 中可能是活性位点，在 homolog B 中可能是 loop（插入/删除导致序列位移）。
- 对于没有 3D 结构的情况（大多数蛋白质预测任务），Situs 只能使用序列位置。序列位置是 3D 功能位置的**弱代理变量**。
- 只有当我们有 3D 结构且将 Situs 应用于 3D 坐标编码时，上述功能差异才能被有效捕获。

诚实结论：1D 序列正弦编码对区分 Lys-37 活性位点 vs Lys-289 表面 loop 有信息但信号弱。序列位置与 3D 功能位置的相关性受限于 fold 保守性。 $I(Y; P_{1D} | S) > 0$ 但远小于 $I(Y; P_{3D} | S)$ 。

1.1.2 -螺旋的 3.6 残基/圈周期性

物理事实：

Pauling 经典 α -螺旋 [Pauling et al., *PNAS* 37, 205 (1951)]: - 每圈 3.6 个残基（精确值 = 3.6，或 18 残基/5 圈）- 螺距 = 5.4 Å（每残基上升 1.5 Å）- 氢键模式：残基 i 的 C=O $\cdots$ H-N 残基 $i + 4$ - 这意味着残基 i 和 $i + 4$ 在空间上相邻 (~ 3.1 Å)，而 i 和 $i + 3$ （或 $i + 5$ ）在螺旋的相对面

正弦编码能否捕获？

对于正弦编码 $\sin(2\pi p/\lambda_j)$: - 若波长 $\lambda_j = 3.6$: $\sin(2\pi p/3.6)$ 确实具有 3.6 残基的精确周期 - 残基 i 和 $i + 3.6$ 获得相同编码值 $\rightarrow$ 残基 i 和 $i + 4$ （距离 4，周期差 $0.4/3.6 \approx 11\%$ ）编码相近但不相同

但是——标准 Transformer 编码做不到：

标准正弦编码 [Vaswani et al., *NeurIPS* 2017] 的波长集合：

$$\lambda_j = 2\pi \cdot 10000^{2j/d}$$

当 $d = 512$ 时，波长范围约为 2π 到 $2\pi \cdot 10000$ （6.28 到 62832）。对于典型的蛋白质长度 $L \sim 300$ ：- 最短波长（ $j = d/2 - 1 = 255$ ）： $\lambda_{255} = 2\pi \cdot 10000^{510/512} \approx 2\pi \cdot 10000^{0.996} \approx 6.28 \times 9550 \approx 60,000$ ——远大于 3.6！
- 没有任何一个 λ_j 接近 3.6

物理最优谱（定理 1.2.1）能否解决？

根据定理 1.2.1，最优频率谱需要知道物理相关长度 ξ 。对于 α -螺旋， $\xi \approx 3.6$ （螺旋周期）。若我们以 $\xi = 3.6$ 为目标设计编码：- $\lambda_{\min} = 2\pi\xi \cdot \cot(\pi(2(d/2 - 1) + 1)/2d) \approx 2\pi \cdot 3.6 \cdot \cot(\pi/2 - \pi/2d) \approx 22.6 \cdot (2d/\pi) \approx 14.4d$ - 对于 $d = 64$ ， $\lambda_{\min} \approx 920$ ——仍远大于 3.6！

根本问题：正弦编码的“分辨率”受限于 d 。要在 $L = 300$ 的序列上分辨出 3.6 残基的周期，需要 $\lambda_{\min} \lesssim 3.6$ ，即需要 $d \gtrsim 300/3.6 \times 2 = 167$ 维（每个周期至少 2 个采样点，Nyquist）。对于典型的 $d = 64$ 或 $d = 128$ ，3.6 残基的周期性理论上无法被捕获。

诚实结论：对于实际使用的编码维度（ $d \leq 128$ ），正弦编码无法可靠捕获 α -螺旋的 3.6 残基/圈周期性。这不是编码形式的缺陷，而是维度-分辨率的基本权衡（推论 1.2.1）。如果需要在序列位置编码中捕获螺旋周期性，应该显式添加一个 $\lambda \approx 3.6$ 的频率分量，或者使用可学习的周期性特征。

1.1.3 固有无序区域（IDR）中 Situs 的退化

物理事实：

固有无序区域（IDR）占真核蛋白质组的 30–40% [Dunker et al., *FEBS J.* 272, 5129 (2005)]。关键特征：- 在生理条件下**不折叠为单一稳定 3D 结构** - 功能来自**氨基酸组成**（如电荷模式、脯氨酸含量）而非精确折叠 - 序列位置与功能的关系**极弱**：IDR 的功能（如 linker、entropic spring、PTM 位点集群）主要由组成决定，位置排列有高度容忍度 - 同一 IDR 插入/删除 5–20 个残基通常不影响功能 [Zibae et al., *Protein Sci.* 16, 906 (2007)]

Situs 在 IDR 上的行为：

$$I(Y; P_{\text{seq}} \mid S = \text{"IDR residue"}) \approx 0$$

由定理 2.2.1 和 2.3.1：

$$\delta_s^{\text{PE}} \leq \sqrt{\frac{1}{2} I(Y; P \mid S)} + \delta_s^{\text{variance}} \approx 0 + O(1/\sqrt{M})$$

即：**Situs** 退化为维度为 d 的加法噪声。

具体地，在 IDR 区域的 L 个连续位置上：

$$\text{PE}(p) = [\sin(2\pi p/\lambda_1), \cos(2\pi p/\lambda_1), \dots]$$

这些编码向量随 p 平滑变化（Lipschitz 连续性），但它们携带的变异性与标签 Y **无关**。在训练中：- 干净样本： $\text{PE}(p)$ 添加了与标签无关的波动 $\rightarrow$ 可能略微降低专家一致性 $\rightarrow p_{\text{clean}}^{\text{PPE}} \geq p_{\text{clean}}$ - 噪声样本： $\text{PE}(p)$ 同样不提供区分噪声的能力 $\rightarrow p_{\text{noisy}}^{\text{PPE}} \approx p_{\text{noisy}}$ - 结果： $\delta_s^{\text{PE}} \leq 0$ （负或零）

诚实结论：IDR 是 Situs 的**最坏场景**——位置编码退化为无害但无用的维度膨胀。它不会主动破坏模型（Lipschitz 连续性保证 h_i 仍然光滑），但消耗了 d 维的计算和存储，且可能通过梯度噪声略微降低收敛速度。如果数据集中 IDR 占比高（>30% 如真核蛋白），Situs 的净收益**可能为负**。

1.2 材料 3D 结构位置编码

1.2.1 V_N 空位形成能：晶界 vs 体相 vs 表面

物理事实（DFT 计算数据）：

AlN 中氮空位 V_N 的形成能强烈依赖于空间位置 [Freysoldt et al., *Rev. Mod. Phys.* 86, 253 (2014); Stampfl & Van de Walle, *Phys. Rev. B* 65, 155212 (2002)]:

位置	形成能 E_f (eV)	物理原因
体相 (bulk, 配位数 4)	3.2–4.0	完整四面体配位, 断开 4 个 Al–N 键
表面 ((0001) 表面, 配位数 3)	1.8–2.5	表面弛豫释放应变能, 配位数降低
晶界 ($\Sigma 7$ 对称倾斜晶界)	1.0–1.8	晶界本征应力场 + 多余体积 + 悬挂键预存在

差异幅度： $\Delta E_f \approx 1.5\text{--}2.5$ eV，远超 $k_B T$ （室温下 0.025 eV），在任何温度下都具有决定性影响。

物理因果链（不可简化）：

$$\text{3D 位置} \xrightarrow{\text{决定}} \text{局部配位环境} \xrightarrow{\text{决定}} \text{缺陷形成能}$$

这是一个清晰的因果箭头——位置是自变量，形成能是因变量。位置编码捕获的是这个因果链的原因侧。

$$I(Y = E_f; P_{3D} | S = V_N) > 0 \quad \text{——信息论意义上严格正且量大}$$

根据 Fano 下界（定理 2.4.1），对于多类分类（不同缺陷电荷态）：

$$\delta_s^{\text{PE}} \geq \frac{2 \cdot I(Y; P | S) - \log 2}{\log |Y|}$$

取 $I(Y; P | S) \approx H(Y|S) \approx \log 3 \approx 1.6$ bits（3 种形成能区间：高/中/低）， $\log |Y| \approx \log 3$ ：

$$\delta_s^{\text{PE}} \gtrsim 0.5\text{-}0.8$$

这是一个可观的检测边际增益，对应 Theorem 1 的指数界显著收紧。

诚实结论：对于材料缺陷检测，3D Situs 是物理上最有价值的应用场景。位置直接因果决定标签。这是 Situs 的”home turf”。

1.2.2 3D 旋转编码的物理对称性检查

Situs 旋转编码的定义（定义 1.3.1）：

$$\text{PE}_{\text{rot}}(\mathbf{p}) = \mathbf{R}_x(\alpha x) \cdot \mathbf{R}_y(\beta y) \cdot \mathbf{R}_z(\gamma z) \cdot \mathbf{e}_0$$

检查 1：平移不变性

内积：

$$\langle \text{PE}(\mathbf{p}), \text{PE}(\mathbf{q}) \rangle = \langle \mathbf{e}_0, \mathbf{R}(\mathbf{q} - \mathbf{p})\mathbf{e}_0 \rangle = \cos(\alpha \Delta x) + \cos(\beta \Delta y) + \cos(\gamma \Delta z)$$

仅依赖于 $\Delta \mathbf{p} = \mathbf{q} - \mathbf{p}$ 。**平移不变性严格成立。**这满足晶体学的基本要求——完美晶体中，两个位置等价当且仅当它们的相对位移是晶格向量。

检查 2：旋转等变性 不成立

考虑全局旋转 $R_{\text{phys}} \in SO(3)$ 作用于坐标： $\mathbf{p} \rightarrow R_{\text{phys}}\mathbf{p}$ 。

对于 $R_{\text{phys}} = R_z(90^\circ)$ 绕 z 轴旋转 90° （将 (x, y, z) 变为 $(-y, x, z)$ ）：

$$\text{PE}_{\text{rot}}(R_{\text{phys}}\mathbf{p}) = \mathbf{R}_x(-\alpha y)\mathbf{R}_y(\beta x)\mathbf{R}_z(\gamma z)\mathbf{e}_0$$

而 $\text{PE}_{\text{rot}}(\mathbf{p}) = \mathbf{R}_x(\alpha x)\mathbf{R}_y(\beta y)\mathbf{R}_z(\gamma z)\mathbf{e}_0$ 。

这两个编码之间不存在一个与 $\mathbf{p}$ 无关的变换 T 使得 $T \cdot \text{PE}(\mathbf{p}) = \text{PE}(R_{\text{phys}}\mathbf{p})$ 。原因：编码为三个坐标轴分配了不相交的维度对—— $(0, 1)$ 对应 x ， $(2, 3)$ 对应 y ， $(4, 5)$ 对应 z 。物理旋转混合了 x 和 y 分量，但编码空间中没有对应的“混合”机制。

破坏的后果：

在以下场景中旋转等变性的缺失是致命的：1. **多晶/晶界系统**：不同晶粒的取向不同，相同类型缺陷的编码因取向不同而不同 $\rightarrow h_i$ 引入与标签无关的变异性 2. **分子动力学轨迹**：分子整体旋转导致所有原子编码变化 $\rightarrow$ 模型可能学到“旋转状态”而非“物理状态” 3. **表面 slab 计算**：同一表面不同切面（如 AlN (0001) vs (1100)）具有不同的坐标轴取向

可以修复吗？

理论上可以。替代方案：- **球谐函数编码**： $\text{PE}(\mathbf{p}) = [Y_{\ell m}(\theta, \phi)]$ ，具有严格的 $SO(3)$ 旋转等变性 - **E(3) 等变网络**：使用 Tensor Field Networks [Thomas et al., *NeurIPS* 2018] 或 SE(3)-Transformers [Fuchs et al., *NeurIPS* 2020]，天然具备平移 + 旋转等变性 - **代价**：球谐函数编码的维度随角动量 L 增长为 $(L+1)^2$ ， $L=3$ 即需 16 维（vs 6 维的旋转编码），且 Lipschitz 行为更复杂

诚实结论：Situs 的 3D 旋转编码仅具有平移不变性，不具旋转等变性。对于大多数材料应用（需要处理任意取向的晶体），这是**严重缺陷**。但在受控

场景（单晶、固定取向的 slab、取向已对齐的数据集）中，这不构成问题。

1.3 原子总数 N：32 vs 256 超胞的 DFT 精度

1.3.1 系统性差异的物理起源

Makov-Payne 有限尺寸标度 [Makov & Payne, *Phys. Rev. B* 51, 4014 (1995)]:

带电缺陷的形成能随超胞尺寸 L 的标度行为:

$$E_f(L) = E_f(\infty) + \frac{\alpha q^2}{2\epsilon L} + \frac{2\pi q Q}{3\epsilon L^3} + O(L^{-5})$$

其中 q 是缺陷电荷, ϵ 是介电常数, Q 是弹性四极矩。

具体数值估计 (V_N^{+1} 在 AlN 中, $\epsilon \approx 9$):

周期性图像间					
超胞尺寸	原子数	距	$1/L$ 修正	$1/L^3$ 修正	总修正
$2\times 2\times 2$	32	$\sim 6.2 \text{ \AA}$	$\sim 0.35 \text{ eV}$	$\sim 0.12 \text{ eV}$	$\sim 0.5 \text{ eV}$
$2\times 2\times 3$	48	$\sim 6.2\text{--}9.3 \text{ \AA}$	$\sim 0.25 \text{ eV}$	$\sim 0.05 \text{ eV}$	$\sim 0.3 \text{ eV}$
$3\times 3\times 3$	108	$\sim 9.3 \text{ \AA}$	$\sim 0.15 \text{ eV}$	$\sim 0.02 \text{ eV}$	$\sim 0.17 \text{ eV}$
$4\times 4\times 4$	256	$\sim 12.4 \text{ \AA}$	$\sim 0.08 \text{ eV}$	$\sim 0.005 \text{ eV}$	$\sim 0.09 \text{ eV}$

物理根源（三个独立的有限尺寸效应，均不可忽略）:

1. 静电像电荷相互作用 ($1/L$ 主导项):
 - 带电缺陷与其周期性镜像之间的 Coulomb 相互作用
 - 32 原子超胞中相邻镜像仅隔 $6.2 \text{ \AA}$ $\rightarrow$ 相互作用能 $\sim 0.3\text{--}0.5 \text{ eV}$
 - 物理上这是人为引入的——真实孤立缺陷没有周期性镜像
2. 弹性像相互作用 ($1/L^3$):
 - 缺陷引起的局部应变场与其周期性镜像的相互作用
 - 对 V_N (移除原子产生拉伸应变) 此效应不可忽略
3. 缺陷波函数重叠 (指数衰减 $\propto e^{-L/\xi}$):
 - 对深能级缺陷 (如 V_N 在 AlN 中产生 $\sim 1.5 \text{ eV}$ 深的施主能级), 波函数局域化半径 $\xi \approx 2\text{--}3 \text{ \AA}$
 - 32 原子超胞中相邻波函数尾重叠不可忽略 $\rightarrow$ 缺陷能级分裂成能带 (人造色散)

这与 Situs 的 N 编码有什么关系?

Situs 的第三域 (定义 1.1.3) 将总原子数 N 作为标量位置编码入。问题是:

- $N = 32$ 和 $N = 256$ 的数据不是同一物理系统的不同”位置”——它们是不同的精度级别的近似
- N 编码将”计算精度”与”物理标签”混淆。 $N = 32$ 的 E_f 偏差是计算 artifact, 不是物理信号
- 如果训练集混合了 32 和 256 原子超胞的数据, N 编码可能学到” $N = 32 \rightarrow$ 高 E_f “的虚假相关性

物理上正确的处理: - 对 E_f 应用 Freysoldt-Neugebauer-Van de Walle (FNV) 有限尺寸修正 [Freysoldt et al., *Phys. Rev. Lett.* 102, 016402 (2009)], 消除 N 的系统性偏差 - 之后再考虑是否使用 N 编码——此时 N 才反映真实的系统尺寸效应 (如量子限域), 而非计算 artifact

诚实结论: 如果训练数据未经过有限尺寸修正, N 编码学到的是计算 artifact 而非物理。在修正之后, N 携带的真实物理信息 (量子限域、振动模式

数)对于缺陷物理来说较小(ΔE_f 的 N -dependence < 0.05 eV for $N > 100$)。对于大多数材料任务， N 编码的 δ_s^{PE} **接近零**——这是一个物理上动机弱、实践上危险（容易学到 artifact）的编码维度。

第 2 部分：SitUS 在什么情况下有害？

诚实暴击：SitUS 不是一个”无害但可能无用”的组件。在特定条件下它是主动有害的。

2.1 虚假相关性 (Spurious Correlation)

机制：

当物理位置 P 与标签 Y 在训练数据中具有统计学相关，但该相关**不反映**因果关系时：

$$\text{Corr}_{\text{train}}(P, Y) \neq 0, \quad \text{但 } P \perp\!\!\!\perp Y \text{ (因果意义上独立)}$$

由于 SitUS 将 P 编码为 $\text{PE}(P)$ 并注入表示，模型（专家 E_m ）会学习利用这个虚假相关。

具体实例：

蛋白质数据集偏差： - PDB 中解析的蛋白质结构存在”易于结晶”偏差——倾向于更稳定、更紧凑的折叠 - 如果训练集中所有酶活性位点恰好在结晶结构中位于蛋白质核心（低 B-factor 区域 $\rightarrow$ 低位置索引附近被解析得更清

楚) - Situs 学到：残基位置靠前 ($p < 100$) → 活性位点 - 测试集中出现 C 端活性位点蛋白 → 系统性误判

DFT 计算参数偏差：- Materials Project 中的计算使用不同的计算参数（赝势、k 点密度），且这些参数与材料类型有系统性关联 - 如果 Situs 的原子数编码 N 学到： $N = 32$ （典型金属计算）→ 低形成能， $N = 256$ （典型半导体缺陷计算）→ 高形成能 - 这种”知识”是计算惯例的 artifact，不是物理

虚假相关性的检测： δ_s^{PE} 在训练集上 > 0 ，但在 i.i.d. 验证集上 $\rightarrow 0$ 或 < 0 。Theorem 2'（修正 Theorem 2）的上界在分布外数据上反而更松——因为 ε_{PE} 在训练分布上被低估。

诚实结论：虚假相关性是 Situs 的最大实际风险。物理学家知道”position matters”但训练数据中的 position-label 相关有多少来自因果、有多少来自数据收集偏差，必须逐案分析。没有捷径。

2.2 多重共线性 (Multicollinearity)

机制：

当状态表示 $\phi(s_i)$ 已经隐式编码了位置信息时，加法注入 $\text{PE}(p_i)$ 产生冗余维度：

$$h_i = \underbrace{\phi(s_i)}_{\text{已含隐式位置信息}} + \underbrace{\text{PE}(p_i)}_{\text{显式位置信息}}$$

这导致编码空间中的有效维度膨胀，伴随：1. **专家模型的梯度方差增大：**每个专家需要从冗余维度中提取信号 2. **有效专家多样性 ρ_{eff} 下降：**当所有专家在同一冗余空间中操作，它们的输出相关性增大

具体实例：

图神经网络 (GNN) 处理晶体： - GNN 已通过消息传递聚合了邻域信息，包含隐式的位置/距离编码 - 如果再对每个节点添加 Situs 的 3D 旋转编码，相当于添加了已经被图卷积层捕获的信息 - 结果： $I(Y; \text{PE}(P) \mid \phi(S)) \approx 0$ (给定 GNN 特征后，位置无额外信息) - 但 PE 的额外维度增加了优化难度，等效于 $\delta_s^{\text{variance}}$ 增大

蛋白质语言模型 (pLM) 处理序列： - ESM-2 [Lin et al., *Science* 379, 1123 (2023)] 等 pLM 的 attention 机制天然包含位置信息 (attention bias) - 对 ESM embedding 再加 Situs 正弦编码 = 添加已被 attention 处理的冗余信号 - 这种”双重编码”在统计上引入共线性，但不增加有效信息

定量影响：

设原始特征空间的有效秩为 $r_{\text{eff}} = \text{rank}(\Sigma_\phi)$ 。添加 PE 后：

$$\text{rank}(\Sigma_h) \leq r_{\text{eff}} + \min(d_{\text{pe}}, N)$$

但如果 $\text{span}(\text{PE}(P)) \subseteq \text{span}(\phi(S))$ (PE 在 ϕ 的列空间中)，则 $\text{rank}(\Sigma_h) = r_{\text{eff}}$ —— 维度增加了但有效秩不变。这是**纯浪费**。

诚实结论： 在已有强大结构编码的模型 (GNN、Transformer、pLM) 之上叠加 Situs，大概率是**零增益 + 微损害**。Situs 最有用时是作为**仅有的**位置信息源 (当 $\phi(s_i)$ 完全没有空间信息时)。

2.3 物理对称性破坏 (Physical Symmetry Breaking)

机制：

Situs 的加法注入 $h_i = \phi(s_i) + \text{PE}(p_i)$ 刻意破坏了物理系统的某些对称性。当这些对称性对预测任务重要时, 这是有害的。

三种破坏的对称性:

2.3.1 平移对称性破坏 (对体相性质预测是坏的)

完美晶体中, 所有原胞等价——体相性质 (带隙、弹性常数、声子频率) 应具有完全平移不变性。

使用 Situs 后: - 两个等价原胞中的原子获得不同的 h_i - 模型必须额外学习”忽略位置”——增加了不必要的学习负担 - 更糟: 如果训练集有限, 模型可能学到”带隙依赖于原子索引”的虚假规律

实例: 预测 AlN 体相带隙 (~ 6.2 eV, [Yan et al., *Phys. Rev. B* 93, 014110 (2016)]) - $N = 32$ 超胞中每个 N 原子的 Situs 编码不同 - 如果模型用这些编码预测同一个带隙标签, 它必须在内部学习”这些编码应该被忽略” - 对小数据集, 这可能导致过拟合到特定的编码值

判断: 如果任务标签具有平移不变性 (体相性质), Situs 不应使用。如果任务标签不具有平移不变性 (缺陷形成能、表面能、局域态密度), Situs 应当使用。

2.3.2 旋转对称性破坏 (3D 旋转编码的硬伤——已在 1.2.2 分析)

2.3.3 排列对称性破坏 (对集合型预测是坏的)

原子系统本质上是粒子的集合——原子的编号/顺序是人为的, 不应影响物理预测。

Situs 依赖”第 i 个原子的位置 p_i “，其中 i 是原子的索引。如果数据加载时的原子排序发生变化， h_i 会不同——即使物理系统完全相同。

这在以下场景中造成问题： - DFT 计算中原子列表的排序无物理意义（VASP/PWscf 输出中的原子顺序是输入顺序的函数） - 分子动力学轨迹中，原子可能跨过周期性边界，改变其在数组中的位置 - 不同数据源的原子排序约定不同

缓解措施：使用等变的位置编码（如基于距离矩阵或原子环境的编码），或要求数据预处理中保证一致的原子排序（如按坐标排序——但这又引入了排序的人为性）。

诚实结论：Situs 破坏排列对称性是一个实际工程问题而非理论缺陷——可以通过一致的预处理缓解，但无法根除。如果原子排序在不同样本间不一致，Situs 引入的噪声可能淹没信号。

第 3 部分：适用场景分析表

对 6 个具体场景，评估 δ_s^{PE} 的符号（正/零/负）、量级（大/中/小/零）和物理论证。

#	场景	δ_s^{PE} 符号	量级估计	理由
#	场景	δ_s^{PE} 符号	量级估计	理由
1	AIN 缺陷检测： V_N 空位，534 帧	正	大	3D 位置因果决定缺陷形成能 (§1.2.1)。534 帧在材料缺陷数据中属于中等规模，足以学习位置-能量关系。位置信息不冗余 ($\phi(s_i)$ 为局部化学特征，不含全局空间上下文)。3D 旋转编码的平移不变性在此场景中恰好合适。

#	场景	δ_s^{PE} 符号	量级估计	理由
2	蛋白质 功能预 测：酶 活性位 点分类	正（弱）	中小	序列位 置与功 能位点 有统计 相关性 (N 端/C 端偏 好、结 构域位 置), 但效应 量弱。 $I(Y; P_{1D} $ $S) > 0$ 成立但 数值有 限 (< 0.3 bits, 因为大 部分功 能信息 已在残 基类型 和局部 序列上 下文 中)。 关键限 制： Situs 使用 1D 序

#	场景	δ_s^{PE} 符号	量级估计	理由
3	Drug-target 对接评分：Drug-Bank 6784 条	正（有条件）	中小	条件：使用 3D 对接姿态坐标（而非 1D 序列位置）。结合亲和力和 $(K_d, K_i, \Delta G)$ 是 3D 姿态的函数——口袋位置、氢键几何、疏水接触面积都由空间位置决定。 $I(Y; P_{3D} S) > 0$。 但是：6784 条数据对于学习复杂的 3D 位

#	场景	δ_s^{PE} 符号	量级估计	理由
4	纯化学 组成成分 类：无 空间结构	零（或略负）	零	$\mathcal{P}$ 未定义。没有物理位置信息可编码。强行使用（如人工赋予虚拟索引） $\rightarrow$ 编码的是数据加载顺序的 artifact。 $I(Y; P S) \equiv 0$ 。 由定理 2.2.1， $\delta_s^{\text{PE}} = 0$ 。由定理 2.5.1，编码随虚拟位置平滑变化——但这变化不含任何标签信息。唯

#	场景	δ_s^{PE} 符号	量级估计	理由
5	随机排列的原子构型：无周期结构	负	中	位置存在（有 3D 坐标），但位置与标签之间没有物理规律性——构型是随机的。 $I(Y; P S) = 0$（随机排列破坏了所有位置-标签信息论联系）。 但训练集中有限的随机涨落可能产生偶然的位置-标签相关，模型会学到这些虚假

#	场景	δ_s^{PE} 符号	量级估计	理由
6	碳纳米管手性分类： (n, m) 索引	正	大	手性 (n, m) 完全由 3D 原子排列 的全局几何决定—— 这是位置编码的理想 场景。所有碳原子具 有相同的局部 sp^2 化 学环境 ($\phi(s_i) \approx$ 常数), 因此 $I(Y; S) \approx$ 0 (纯 化学组 成无法 区分手 性) 而 $I(Y; P) =$ $H(Y) =$ $\log_2 K$ (K 为 手性类 别数)。 $I(Y; P $

第 4 部分：每个场景一句话建议

#	场景	建议（加不加 Situs + 一句话理由）
1	AIN V_N 缺陷 534 帧	加——3D 位置是形成能的直接物理原因，534 帧足够学习空间模式，前提是取向已对齐或模型能容忍旋转非等变性。
2	酶活性位点分类	不加（或改用 3D Situs）——1D 序列位置是 3D 功能位置的弱代理，尤其当已有 pLM embedding（含注意力位置偏差）时，1D Situs 沦为共线性冗余。如有 AlphaFold 预测结构，改用 3D Situs。
3	DrugBank 对接评分	有条件加——仅当使用高质量 3D 对接姿态（RMSD < 2 Å）时加 3D Situs；6784 条数据对 3D 编码维度偏小，需配合强正则化或降维编码。
4	纯组成分类无结构	绝对不加——没有位置就没有 Situs；任何人为赋予的伪位置都是统计噪声，可能产生虚假相关。
5	随机原子构型	不加——随机位置与标签的信息论联系为零，Situs 在此是虚假相关性的滋生器；若真要使用，必须先做 permutation test 验证 $I(Y; P S)$ 的统计显著性。
6	CNT 手性 (n,m) 分类	加——手性由全局 3D 几何唯一确定，Situs 从仅有的位置信息中提取特征（碳原子的局部化学环境完全不携带手性信息），这是 Situs 的”教科书级”应用场景。

总结: Situs 的物理适用边界

它何时工作（按信心排序）

1. **3D 位置因果决定标签 + 无冗余结构编码**（CNT 手性、缺陷空间分辨） $\rightarrow \delta_s^{\text{PE}}$ 大且正。这是 Situs 的设计目标场景。
2. **3D 位置因果决定标签 + 有冗余但有额外结构**（对接评分、材料缺陷） $\rightarrow \delta_s^{\text{PE}}$ 中且正，但维度选择和正则化关键。
3. **1D 序列位置弱相关标签 + 无结构编码**（简单蛋白质功能预测，无 pLM） $\rightarrow \delta_s^{\text{PE}}$ 小且正，微弱收益。

它何时无用（加了等于白加）

4. **位置不携带给定状态的额外标签信息**（IDR、纯组成分类、体相性质） $\rightarrow \delta_s^{\text{PE}} \approx 0$ ，纯维度浪费。
5. **已有强力结构编码器**（GNN 在晶体上、pLM 在蛋白上） $\rightarrow$ 共线性， $\delta_s^{\text{PE}} \approx 0$ 但有微小负效应。

它何时有害（加了更差）

6. **伪位置或随机位置 + 有限样本**（无结构数据的虚拟索引、随机构型） $\rightarrow \delta_s^{\text{PE}}$ 训练 > 0 但测试 < 0 ，最危险的虚假相关。
7. **标签具有平移/旋转对称性但任务不尊重该对称性**（体相性质 + Situs 编码打破对称性） $\rightarrow$ 引入与物理矛盾的归纳偏差。
8. **未修正的计算 artifact 被编码为”位置”**（混合不同超胞尺寸的未修正 DFT 数据） $\rightarrow$ 学到计算 artifact 而非物理。

理论洞察与工程现实的鸿沟

定理 2.2.1 给出的充分条件 $I(Y; P | S) > 0$ 是**必要且精确的**，但在实践中：
- 估计 $I(Y; P | S)$ 本身需要大量样本（KSG 估计器的收敛维度灾难，定理 3.3.1）
- 即使 $I(Y; P | S) > 0$ ，定理 2.3.1 的上界可能因编码不完美度 ε_{PE} 而极度松弛
- Theorem 3' 揭示的”学习型 PPE 可能区分噪声和困难样本”
在实践中**通常不发生**——因为物理学常用的 PE 是固定的，而学习型 PE 的信号太弱无法可靠破坏不可区分性

分析日期: 2026-06-29

物理数据引用: Bartlett (2002), Creighton (1993), Dunker (2005), Freysoldt (2014), Makov & Payne (1995), Pauling (1951), Stampfl & Van de Walle (2002), Van de Walle & Neugebauer (2004), Yan (2016), 等

方法论声明: 所有 δ_s^{PE} 的估计来自物理推演而非数值实验——需要 DFT 计算和蛋白质结构分析来验证/校准这些估计。