

Theorem 1: Multi-Expert Consistency Guarantees for Label Noise Detection

核心主张: 当 M 个在不相交数据子集上独立训练的专家对某个样本的一致性得分 $C(x)$ 超过阈值 θ 时，该样本是标签噪声的置信度以指数速率收敛到 1。

修正记录: 2026-06-27 — Lemma 3 证明重构（新增 A6 平衡误差分布假设）；Chernoff 附录 KL 方向修正；主定理陈述更新为 (A1)-(A6)。两个 bug 均来自验证报告。

1 定理陈述

1.1 符号与设定 (Setup)

设以下对象：

符号	含义
$\mathcal{X}$	输入空间，可测
$\mathcal{Y}$	标签空间， $ \mathcal{Y} = K$ （分类）或 $\mathcal{Y} \subseteq \mathbb{R}^d$ （回归）
$\mathcal{D}$	数据分布， $(X, Y) \sim \mathcal{D}$
$f^* : \mathcal{X} \rightarrow \mathcal{Y}$	真实标注函数（未知 Oracle）
$\{f_m\}_{m=1}^M$	M 个专家模型， $f_m : \mathcal{X} \rightarrow \mathcal{Y}$
$\Pi = \{s_1, \dots, s_K\}$	状态划分， $\mathcal{X}$ 的可测分割
$\ell : \mathcal{Y} \times \mathcal{Y} \rightarrow [0, B]$	有界损失函数
$\tau > 0$	专家错误的阈值

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

符号	含义
$\theta \in (0, 1)$	噪声检测阈值

标签噪声模型: 对于每个样本 (x, y^*) (其中 $y^* = f^*(x)$ 为真实标签), 观察到的标签 y 生成如下:

$$y = \begin{cases} y^* & \text{以概率 } 1 - \eta \\ \text{Uniform}(\mathcal{Y} \setminus \{y^*\}) & \text{以概率 } \eta \end{cases}$$

其中 $\eta \in (0, 1/2)$ 为全局噪声率, 噪声事件与 x 和所有训练数据独立。

一致性得分: 对样本 (x, y) , 定义专家错误指示变量和一致性得分:

$$e_m(x, y) = \mathbf{1}\{\ell(f_m(x), y) > \tau\}, \quad C(x) = \frac{1}{M} \sum_{m=1}^M e_m(x, y)$$

检测规则: 样本 (x, y) 被标记为噪声当且仅当 $C(x) > \theta$ 。

1.2 假设 (Assumptions)

(A1) 不相交训练集: M 个专家在 M 个不相交的独立同分布子集上训练:

$$D_m \sim \mathcal{D}^{n_m}, \quad D_m \cap D_{m'} = \emptyset, \quad D_m \perp D_{m'} \text{ for } m \neq m'$$

(A2) 清洁数据上的条件独立: 对任意清洁样本 (x, y) ($y = y^*$), 给定 x 的条件下, 错误指示变量 $\{e_m(x, y)\}_{m=1}^M$ 是条件独立的。

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

合理性说明与局限: A2 是一种**结构性假设**, 由专家实验设计 (不相交训练集 A1、独立初始化) 所论证, 但 **A1 并不蕴含 A2**。即使训练集完全不相交, 在相似数据分布上训练的专家可能在分布外样本上产生**相关错误** (源于共享归纳偏置, 非共享训练数据)。因此 A2 在 SCX 流水线的数据中**不可经验检验**——对连续输入空间 $\mathcal{X}$, 每个 x 在有限数据集中最多出现一次, 联合分布 $P(e_1, \dots, e_M | x)$ 不可观测。>> **当 A2 被违反时** (实际中常见): 用 $M_{\text{eff}} = M / (1 + (M-1)\bar{\rho})$ 替换所有集中不等式中的 M , 其中 $\bar{\rho}$ 为专家错误指标的平均成对相关系数。对典型深度集成, $\bar{\rho} \approx 0.1\text{--}0.3$ 。建议在留置验证集上估计 $\bar{\rho}$, 并用 M_{eff} 得到保守保证。详细分析参见 01_symbol_system.md §12.5。

(A3) 有界损失: $\ell(a, b) \in [0, B]$, $\forall a, b \in \mathcal{Y}$, 其中 $B < \infty$ 。

(A4) 均匀独立噪声: 标签翻转事件与 x 和所有 D_m 独立。噪声标签在 $\mathcal{Y} \setminus \{y^*\}$ 上均匀分布。

(A5) 状态同质性 (状态划分充分性): 状态划分 Π 使得在每个状态 s 内, 专家的清洁数据错误率近似均匀。形式化地, 存在状态级常数 $\{\mu_s\}_{s \in \mathcal{S}}$ 使得:

$$\sup_{x \in s} \mathbb{E}[C(X) \mid \text{clean}, X = x] \leq \mu_s, \quad \forall s \in \mathcal{S}$$

即状态 s 内清洁样本的平均专家错误率被 μ_s 一致上界控制。

(A6) 平衡误差分布: 专家的错误概率在所有错误类别上不能过度集中。存在常数 $C_{\text{bal}} \geq 1$ 使得对任意状态 s 和 $x \in s$:

$$\max_{c \neq y^*} \mu_c(x) \leq C_{\text{bal}} \cdot \frac{\mu_s}{K-1}, \quad \mu_c(x) = \frac{1}{M} \sum_{m=1}^M \mathbb{P}(f_m(x) = c \mid x)$$

$C_{\text{bal}} = 1$ 对应完全均匀的误差分布 (每个错误类别等概率); $C_{\text{bal}} = 2$ 是典型的保守选择。此假设可检验且在实践中几乎自动满足——在不相交干净

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

数据上训练的专家没有理由将错误集中到特定类别。

1.3 关键引理 (均值分离)

Lemma 1 (Mean Separation). 在假设 (A1)-(A5) 下 (A6 不影响期望), 对任意 $x \in s$:

(清洁样本)

$$\mathbb{E}[C(X) \mid \text{clean}, X = x] \leq \mu_s$$

(噪声样本)

$$\mathbb{E}[C(X) \mid \text{noise}, X = x] = 1 - \frac{1}{K-1} \cdot \mathbb{E}[C(X) \mid \text{clean}, X = x] \geq 1 - \frac{\mu_s}{K-1}$$

因此, 当 $\mu_s < \frac{K-1}{K}$ 时, 存在 θ 使得:

$$\mathbb{E}[C \mid \text{clean}] < \theta < \mathbb{E}[C \mid \text{noise}]$$

且分离间隙为:

$$\Delta_s(\theta) = \min \left(\theta - \mu_s, 1 - \frac{\mu_s}{K-1} - \theta \right)$$

当选择最优阈值 $\theta_s^* = \frac{1}{2} (1 + \mu_s \cdot \frac{K-2}{K-1})$ 时, 分离间隙最大化 (在 $C_{\text{bal}} = 1$ 的理想情况下):

$$\Delta_s^* = \frac{1}{2} \left(1 - \mu_s \cdot \frac{K}{K-1} \right)$$

当 $C_{\text{bal}} > 1$ 时, 最优阈值向 μ_s 方向微调以补偿非均匀误差分布。 θ_s^* 的精确表达式需求解 $\theta - \mu_s = 1 - C_{\text{bal}} \cdot \mu_s / (K-1) - \theta$ 。

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

Proof. 清洁样本的界由 (A5) 直接给出。对噪声样本：

$$\begin{aligned}
 \mathbb{E}[C \mid \text{noise}, X = x] &= \frac{1}{M} \sum_{m=1}^M \mathbb{P}(\ell(f_m(x), y) > \tau \mid \text{noise}, x) \\
 &= \frac{1}{M} \sum_{m=1}^M \mathbb{P}(f_m(x) \neq y \mid \text{noise}, x) \quad (\text{对0-1 损失}) \\
 &= 1 - \frac{1}{M} \sum_{m=1}^M \mathbb{P}(f_m(x) = y \mid \text{noise}, x)
 \end{aligned}$$

由 (A4)，噪声标签 y 在 $\mathcal{Y} \setminus \{y^*\}$ 上均匀分布，且独立于所有专家：

$$\begin{aligned}
 \mathbb{P}(f_m(x) = y \mid \text{noise}, x) &= \sum_{c \neq y^*} \mathbb{P}(y = c \mid \text{noise}) \cdot \mathbb{P}(f_m(x) = c \mid x) \\
 &= \frac{1}{K-1} \sum_{c \neq y^*} \mathbb{P}(f_m(x) = c \mid x) \\
 &= \frac{1}{K-1} \cdot \mathbb{P}(f_m(x) \neq y^* \mid x) \\
 &= \frac{1}{K-1} \cdot \mathbb{E}[e_m \mid \text{clean}, x]
 \end{aligned}$$

因此：

$$\begin{aligned}
 \mathbb{E}[C \mid \text{noise}, x] &= 1 - \frac{1}{K-1} \cdot \frac{1}{M} \sum_{m=1}^M \mathbb{E}[e_m \mid \text{clean}, x] \\
 &= 1 - \frac{1}{K-1} \cdot \mathbb{E}[C \mid \text{clean}, x] \\
 &\geq 1 - \frac{\mu_s}{K-1} \quad \text{由 (A5)}
 \end{aligned}$$

分离间隙的存在性由 $\mu_s < \frac{K-1}{K}$ 保证，此时 $1 - \frac{\mu_s}{K-1} > \mu_s$ 。□

1.4 主定理 (Main Result)

Theorem 1 (SCX 噪声检测保证). 设假设 (A1)-(A6) 成立, 且 $M \geq 1$ (至少一个专家), $K \geq 2$ (至少两个标签类别, 以保证 $K - 1 > 0$)。令 $\rho_s = \mathbb{P}(X \in s)$ 为状态概率。对任意阈值 θ 满足 $\mu_s < \theta < 1 - C_{\text{bal}} \cdot \frac{\mu_s}{K-1}$ 的状态 s , 定义状态级分离间隙:

$$\Delta_s = \min \left(\theta - \mu_s, 1 - C_{\text{bal}} \cdot \frac{\mu_s}{K-1} - \theta \right) > 0$$

当 $C_{\text{bal}} = 1$ (最佳情形) 时, Δ_s 恢复原始定义; 当 $C_{\text{bal}} > 1$ 时, 噪声侧的间隙收窄 (因为错误可能不是完全均匀分布的)。

则 SCX 噪声检测器的 F1 得分满足以下下界:

$$\text{F1} \geq 1 - \sum_{s \in \mathcal{S}} \rho_s \cdot \left[\exp(-2M\Delta_s^2) + \frac{1-\eta}{\eta} \cdot \exp(-2M\Delta_s^2) \right]$$

或等价地:

$$\text{F1} \geq 1 - \frac{1}{\eta} \sum_{s \in \mathcal{S}} \rho_s \cdot \exp(-2M\Delta_s^2)$$

其中 η 为全局噪声率。

更紧的 Chernoff 形式: 对相同设定, 使用 Chernoff 界代替 Hoeffding 可得更紧的指数速率:

$$\text{F1} \geq 1 - \frac{1}{\eta} \sum_{s \in \mathcal{S}} \rho_s \cdot \left[\exp(-M \cdot \text{KL}(\theta \| \mu_s)) + \frac{1-\eta}{\eta} \cdot \exp(-M \cdot \text{KL}(\theta \| 1 - C_{\text{bal}} \cdot \frac{\mu_s}{K-1})) \right]$$

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

其中 $\text{KL}(p \parallel q) = p \log \frac{p}{q} + (1-p) \log \frac{1-p}{1-q}$ 。Chernoff 界在 μ_s 接近 θ 或 $1 - C_{\text{bal}} \cdot \mu_s / (K-1)$ 接近 θ 时显著优于 Hoeffding（可紧 2-5 倍）。

2026-06-27 修正：原版 Chernoff 使用了 $\text{KL}(1-\theta \parallel 1-\mu_s/(K-1))$ ，KL 方向有误，且未纳入 C_{bal} 。现已修正为 $\text{KL}(\theta \parallel 1 - C_{\text{bal}} \cdot \mu_s / (K-1))$ 。

关键推论：当 $M \rightarrow \infty$ 时，对所有满足 $\mu_s < \frac{K-1}{K}$ 的状态，F1 以指数速率收敛到 1：

$$\text{F1} = 1 - \mathcal{O}_P\left(\frac{1}{\eta} \cdot e^{-2M\Delta_{\min}^2}\right)$$

其中 $\Delta_{\min} = \min_{s \in \mathcal{S}} \Delta_s$ 为最差状态分离间隙。

2 证明

2.1 清洁数据的假阳性率 (False Positive Rate)

Lemma 2 (FPR 上界). 对任意状态 $s \in \mathcal{S}$ 满足 $\mu_s < \theta$ ，清洁样本被误标为噪声的概率满足：

$$\mathbb{P}(C > \theta \mid \text{clean}, X \in s) \leq \exp(-2M(\theta - \mu_s)^2)$$

Proof. 固定 $x \in s$ ，由 (A5) 知 $\mathbb{E}[C \mid \text{clean}, X = x] \leq \mu_s$ 。由 (A1)-(A2)，给定 x 时 $\{e_m\}$ 条件独立。由 (A3) 知 $e_m \in [0, 1]$ 。对 $C = \frac{1}{M} \sum_m e_m$ 应用 Hoeffding 不等式 (Pollard, 1990)：

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

$$\mathbb{P}(C - \mathbb{E}[C] > \theta - \mu_s \mid \text{clean}, x) \leq \exp(-2M(\theta - \mu_s)^2)$$

由于 $\theta > \mu_s$, $(\theta - \mu_s) > 0$ 。该界对任意 $x \in s$ 成立, 因此:

$$\begin{aligned} \mathbb{P}(C > \theta \mid \text{clean}, X \in s) &= \mathbb{E}_{X|s}[\mathbb{P}(C > \theta \mid \text{clean}, X)] \\ &\leq \sup_{x \in s} \mathbb{P}(C > \theta \mid \text{clean}, x) \\ &\leq \exp(-2M(\theta - \mu_s)^2) \end{aligned}$$

此即所需。□

2.2 噪声数据的真阳性率 (True Positive Rate)

新增假设 (A6) — 平衡误差分布: 对任意状态 s 和样本 $x \in s$, 专家的错误概率在所有错误类别上不能过度集中。形式化地, 存在常数 $C_{\text{bal}} \geq 1$ 使得:

$$\max_{c \neq y^*} \mu_c(x) \leq C_{\text{bal}} \cdot \frac{\mu_s}{K-1}, \quad \text{其中 } \mu_c(x) = \frac{1}{M} \sum_{m=1}^M \mathbb{P}(f_m(x) = c \mid x)$$

合理性: 专家在不相交的干净数据子集上训练, 没有理由将错误集中到特定的错误类别。均匀噪声模型下, 每个错误类别的概率天然约为 $\mu_s/(K-1)$ 。 $C_{\text{bal}} = 2$ 已是保守选择。此假设可检验: 在实际数据上估计 $\max_c \mu_c(x)/(\mu_s/(K-1))$ 。

Lemma 3 (TPR 下界). 在假设 (A1)-(A6) 下, 对任意状态 $s \in \mathcal{S}$ 满足 $\theta < 1 - C_{\text{bal}} \cdot \frac{\mu_s}{K-1}$, 噪声样本被正确检测的概率满足:

$$\mathbb{P}(C > \theta \mid \text{noise}, X \in s) \geq 1 - \exp\left(-2M \left(1 - C_{\text{bal}} \cdot \frac{\mu_s}{K-1} - \theta\right)^2\right)$$

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

证明： 固定 $x \in s$ 。给定噪声标签 $y = c$ ($c \neq y^*$)，对于 0-1 损失，专家 m 的错误指示为 $e_m = \mathbf{1}\{f_m(x) \neq c\}$ 。由于 f_m 仅依赖 D_m (A1)，给定 x 时 $\{f_m(x)\}$ 条件独立 (A2)，因此 $\{e_m\}$ 在给定 (x, c) 下条件独立。

每个 e_m 的期望为 $\mathbb{E}[e_m \mid x, c] = 1 - \mathbb{P}(f_m(x) = c \mid x) = 1 - \mu_{c,m}(x)$ 。因此：

$$\mathbb{E}[C \mid x, c] = 1 - \mu_c(x) \geq 1 - C_{\text{bal}} \cdot \frac{\mu_s}{K-1} \quad (\text{由 A6})$$

由于 $e_m \in [0, 1]$ 条件独立，应用 Hoeffding 不等式：

$$\begin{aligned} \mathbb{P}(C \leq \theta \mid x, c) &= \mathbb{P}\left(\frac{1}{M} \sum_{m=1}^M e_m \leq \theta \mid x, c\right) \\ &\leq \exp\left(-2M(1 - \mu_c(x) - \theta)^2\right) \\ &\leq \exp\left(-2M\left(1 - C_{\text{bal}} \cdot \frac{\mu_s}{K-1} - \theta\right)^2\right) \end{aligned}$$

其中 Hoeffding 的 gap 条件 $1 - \mu_c(x) > \theta$ 由定理假设 $\theta < 1 - C_{\text{bal}} \cdot \frac{\mu_s}{K-1}$ 和 A6 保证： $1 - \mu_c(x) \geq 1 - C_{\text{bal}} \cdot \frac{\mu_s}{K-1} > \theta$ 。

对噪声标签 c 取平均（均匀分布 over $K-1$ 类）：

$$\begin{aligned} \mathbb{P}(C \leq \theta \mid \text{noise}, x) &= \frac{1}{K-1} \sum_{c \neq y^*} \mathbb{P}(C \leq \theta \mid x, c) \\ &\leq \exp\left(-2M\left(1 - C_{\text{bal}} \cdot \frac{\mu_s}{K-1} - \theta\right)^2\right) \end{aligned}$$

因此 $\mathbb{P}(C > \theta \mid \text{noise}, x) \geq 1 - \exp(-2M(1 - C_{\text{bal}} \cdot \frac{\mu_s}{K-1} - \theta)^2)$ 。对 $x \in s$ 取期望即得。□

注记： 当 $C_{\text{bal}} = 1$ （完全均匀的错误分布）时，Lemma 3 恢复原始命题中的最优 bound。 C_{bal} 可在实际数据上估计，并用于校准检测阈值 θ 。

2.3 F1 下界

现在组合 Lemma 2 和 Lemma 3 推导 F1 下界。

令检测规则为 $R(x) = \mathbf{1}\{C(x) > \theta\}$ 。定义：

$$\text{TPR}_s = \mathbb{P}(R = 1 \mid \text{noise}, X \in s) \geq 1 - \exp(-2M(1 - \mu_s/(K-1) - \theta)^2)$$

$$\text{FPR}_s = \mathbb{P}(R = 1 \mid \text{clean}, X \in s) \leq \exp(-2M(\theta - \mu_s)^2)$$

由 (A4)，噪声事件与 X 独立，因此 $\mathbb{P}(\text{noise} \mid X \in s) = \eta$ 对所有状态成立。
整体 TPR 和 FPR 为：

$$\text{TPR} = \sum_s \rho_s \cdot \text{TPR}_s, \quad \text{FPR} = \sum_s \rho_s \cdot \text{FPR}_s$$

F1 得分为：

$$\begin{aligned} \text{F1} &= \frac{2 \cdot \text{TP}}{2 \cdot \text{TP} + \text{FP} + \text{FN}} \\ &= \frac{2\eta \cdot \text{TPR}}{2\eta \cdot \text{TPR} + (1 - \eta) \cdot \text{FPR} + \eta \cdot (1 - \text{TPR})} \\ &= \frac{2\eta \cdot \text{TPR}}{\eta(1 + \text{TPR}) + (1 - \eta) \cdot \text{FPR}} \end{aligned}$$

代入 $\text{TPR} \geq 1 - \delta_1$ 和 $\text{FPR} \leq \delta_2$ ，其中：

$$\begin{aligned} \delta_1 &= \sum_s \rho_s \cdot \exp(-2M(1 - C_{\text{bal}} \cdot \mu_s/(K-1) - \theta)^2) \\ \delta_2 &= \sum_s \rho_s \cdot \exp(-2M(\theta - \mu_s)^2) \end{aligned}$$

得到：

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

$$\begin{aligned}
\text{F1} &\geq \frac{2\eta(1-\delta_1)}{\eta(2-\delta_1) + (1-\eta)\delta_2} \\
&= 1 - \frac{\eta\delta_1 + (1-\eta)\delta_2}{\eta(2-\delta_1) + (1-\eta)\delta_2} \\
&\geq 1 - \frac{\eta\delta_1 + (1-\eta)\delta_2}{\eta} \quad (\text{因分母} \geq \eta) \\
&= 1 - \delta_1 - \frac{1-\eta}{\eta}\delta_2
\end{aligned}$$

代入 δ_1, δ_2 的表达式, 并注意当 $\Delta_s = \min(\theta - \mu_s, 1 - C_{\text{bal}} \cdot \mu_s / (K-1) - \theta)$ 时有 $\exp(-2M(\theta - \mu_s)^2) \leq \exp(-2M\Delta_s^2)$ 和 $\exp(-2M(1 - C_{\text{bal}} \cdot \mu_s / (K-1) - \theta)^2) \leq \exp(-2M\Delta_s^2)$, 因此:

$$\text{F1} \geq 1 - \sum_s \rho_s \left[\exp(-2M\Delta_s^2) + \frac{1-\eta}{\eta} \exp(-2M\Delta_s^2) \right] = 1 - \frac{1}{\eta} \sum_s \rho_s \exp(-2M\Delta_s^2)$$

证毕。□

3 推论 (Corollaries)

3.1 推论 1: 对称专家 (Symmetric Experts)

当所有专家具有相同的清洁数据错误率 ε (称为”对称专家”) 时, $\mu_s = \varepsilon$ 对所有状态一致。此时:

$$\Delta = \frac{1}{2} \left(1 - \varepsilon \cdot \frac{K}{K-1} \right)$$

且 F1 下界简化为:

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

$$\text{F1} \geq 1 - \frac{1}{\eta} \exp \left(-\frac{M}{2} \left(1 - \frac{\varepsilon K}{K-1} \right)^2 \right)$$

当 $K = 2$ （二分类）时，进一步简化为：

$$\text{F1} \geq 1 - \frac{1}{\eta} \exp \left(-2M \left(\frac{1}{2} - \varepsilon \right)^2 \right)$$

意义：在二分类对称专家场景下，检测质量完全由专家错误率 ε 与 $1/2$ 的差距决定。 ε 每远离 $1/2$ 一个标准差 ($\approx 1/\sqrt{2M}$)，F1 下界提升一个指数数量级。

3.2 推论 2：最优阈值选择 (Optimal Threshold)

对给定的噪声率 η 、类别数 K 、专家数 M 和最大清洁错误率 $\mu_{\max} = \max_s \mu_s$ ，最优检测阈值 θ^* 应满足：

$$\theta^* = \arg \max_{\theta} \min_s \Delta_s(\theta) = \frac{1}{2} \left(1 + \mu_{\max} \cdot \frac{K-2}{K-1} \right)$$

此时最小分离间隙为：

$$\Delta_{\min}^* = \frac{1}{2} \left(1 - \mu_{\max} \cdot \frac{K}{K-1} \right)$$

所需的最少专家数（达到 $\text{F1} \geq 1 - \varepsilon_0$ ）为：

$$M \geq \frac{1}{2\Delta_{\min}^{*2}} \log \left(\frac{1}{\eta \varepsilon_0} \right)$$

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

证明: 直接解 $1 - \frac{1}{\eta}e^{-2M\Delta^2} \geq 1 - \varepsilon_0$ 得 $e^{-2M\Delta^2} \leq \eta\varepsilon_0$, 取对数即得。若需同时控制多个状态的误差 (联合界), 分子中的 1 替换为状态数 $|\mathcal{S}|$ 。□

3.3 推论 3: 一致可检测的充分条件 (Uniform Detectability)

如果存在 $\delta > 0$ 使得对所有状态 s 有 $\mu_s \leq \frac{K-1}{K} - \delta$, 则令 $\theta = \frac{1}{2}$ (固定阈值), 对所有状态有 $\Delta_s \geq \frac{\delta}{2}$, 且:

$$\text{F1} \geq 1 - \frac{1}{\eta} \exp\left(-\frac{M\delta^2}{2}\right)$$

意义: 只要每个状态的清洁平均专家错误率一致低于 $(K-1)/K$ (当 $K=2$ 时为 $1/2$), 使用固定阈值 $\theta = 1/2$ 即可获得指数级别的 F1 保证。

3.4 推论 4: 有限样本校正 (Finite-Sample Correction)

在实践中, μ_s 必须从有限验证数据估计。设每个状态 s 有 n_s 个清洁验证样本。用 $\hat{\mu}_s = \frac{1}{M} \sum_m \hat{\varepsilon}_m(s)$ 估计 μ_s , 其中 $\hat{\varepsilon}_m(s)$ 是专家 m 在状态 s 上的经验错误率。

由 Hoeffding 不等式和联合界: 对任意 $\delta_0 \in (0, 1)$, 以概率 $\geq 1 - \delta_0$:

$$|\hat{\mu}_s - \mu_s| \leq B \sqrt{\frac{\log(2M/\delta_0)}{2n_s}}, \quad \forall m, s$$

设校正后的阈值为 $\tilde{\mu}_s = \hat{\mu}_s + B \sqrt{\frac{\log(2M/\delta_0)}{2n_s}}$ (保守上界)。则 Theorem 1 的结论对校正后的 $\tilde{\mu}_s$ 以概率 $\geq 1 - \delta_0$ 成立, 只需在 Δ_s 中用 $\tilde{\mu}_s$ 替代 μ_s 。

4 紧致性讨论 (Tightness)

4.1 何时紧致

1. **大 M 极限:** 当 $M \rightarrow \infty$, $C \xrightarrow{\text{a.s.}} \mathbb{E}[C]$ (由大数定律), 检测变成确定性的: $C > \theta$ 当且仅当 $\mathbb{E}[C] > \theta$ 。此时 F1 由 η 和 μ_s 完全决定, 定理下界紧致。
2. **状态同质性:** 当 (A5) 严格成立 (状态内清洁错误率完全均匀) 且专家对称, Hoeffding 界的常数因子 2 是最优的 (由 Hoeffding 下界保证)。
3. $K \rightarrow \infty$: 分离间隙 $\Delta_s \rightarrow \frac{1}{2}$ (固定 μ_s), 检测渐近完美。

4.2 何时松弛

1. **小 M:** 当 $M \leq 3$ 时, Hoeffding 界较松弛。此时应用精确二项式分布 (而非 Hoeffding) 可得更紧的界。经验规则: $M \geq 10$ 时 Hoeffding 界合理紧致; $M \leq 5$ 时使用精确二项式累积分布 (Corollary 4.1)。
2. μ_s 接近 $\frac{K-1}{K}$: 当 $\mu_s \uparrow (K-1)/K$ 时 $\Delta_s \rightarrow 0$, 指数衰减因子消失。此时所需专家数 $M \propto 1/\Delta_s^2$ 发散。这是本质性的: 当专家在新清洁数据上接近随机猜测时, 噪声检测必然不可靠。
3. **弱特征退化:** 当状态划分无法分离噪声主导区域和清洁主导区域时, (A5) 不成立。此时 Theorem 1 不适用, 需借助交叉验证或外部分布检测 (详见 Prop 6 二层状态发现)。这是 SCX 框架的已知边界 (参见弱特征失效概念文档)。
4. **噪声非均匀:** 当 η 依赖 x 时 ($P(\text{noise} | x)$ 非常数), F1 的表达式需用 $\eta_s = \mathbb{P}(\text{noise} | X \in s)$ 替代全局 η :

$$\text{F1} \geq 1 - \frac{1}{\min_s \eta_s} \sum_s \rho_s \exp(-2M\Delta_s^2)$$

在 $\eta_s \rightarrow 0$ 的极端状态，检测无意义——该状态本身没有噪声。

4.3 紧致性对比实验

对典型值 $K = 10$ 、 $\eta = 0.1$ 、 $M = 20$ 、 $\mu_s = 0.2$ ，Theorem 1 给出：

$$\Delta_s = \frac{1}{2}(1 - 0.2 \cdot 10/9) \approx 0.389, \quad \text{F1} \geq 1 - 10 \cdot e^{-2 \cdot 20 \cdot 0.389^2} \approx 1 - 10 \cdot e^{-6.05} > 0.976$$

注意：上述计算假设 $\mu_s = 0.2$ ，即专家在清洁数据上的错误率为 20%。在实际 CIFAR-10 实验中 ($M = 20$, $\eta = 0.1$)，SCX-Noise 的 F1 实测为 0.617。这个值远低于 0.976 的下界，说明 CIFAR-10 实验中**假设不满足**——最可能的原因是：(i) 专家仅在 3 epoch 的 CPU 训练后使用，实际 $\mu_s \approx 0.45$ （而非假定的 0.2），此时 $\Delta_s \approx 0.25$ ，下界退化为 $\text{F1} \geq 0.18$ （与实测 $0.617 > 0.18$ 一致）；(ii) (A5) 状态同质性在低质特征下不严格成立。**教训：**定理下界对 μ_s 高度敏感，实践中必须在验证集上准确估计 μ_s 后再应用公式。在 AIN v3 全 GPU 训练场景中， μ_s 可低至 0.03–0.18，下界得以紧致（见正文 Table 2）。

5 与 Dawid-Skene 的关系

5.1 Dawid-Skene 模型回顾

Dawid 和 Skene (1979) 提出用 EM 算法从多标注者（专家）的独立标注中估计真实标签和标注者可靠性。核心假设是每个标注者 m 有一个**全局混淆矩阵**：

$$\pi_m(c' | c) = \mathbb{P}(f_m(x) = c' | y^* = c), \quad \forall x \in \mathcal{X}$$

即标注者的错误模式不依赖具体样本 x ——这是一个全局常数。

最终的标签估计通过加权投票完成：

$$\hat{y}_{\text{DS}} = \arg \max_c \sum_{m=1}^M w_m \cdot \mathbf{1}\{f_m(x) = c\}$$

其中权重 w_m 由 π_m 的对角元素（精度）决定，或更一般地，由混淆矩阵的逆决定。

5.2 SCX 的改进：状态条件可靠性

SCX 将混淆矩阵推广为**状态条件**形式：

$$\pi_m(c' | c, s) = \mathbb{P}(f_m(x) = c' | y^* = c, x \in s)$$

SCX 权重因此依赖于状态：

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

$$w_m(x) = \frac{\exp(-\alpha \hat{R}_m(s(x)))}{\sum_{m'} \exp(-\alpha \hat{R}_{m'}(s(x)))}$$

其中 $\hat{R}_m(s) = \sum_c \pi_m(c | s)$ 为状态条件风险估计。

5.3 SCX 严格优于 Dawid-Skene 的条件

Proposition 5.1 (SCX-DS 比较). 令 R_{DS} 为 Dawid-Skene 加权的期望 0-1 损失, R_{SCX} 为 SCX 状态条件加权的期望损失。则:

$$R_{\text{SCX}} \leq R_{\text{DS}}$$

等号成立当且仅当对每个标注者 m 和所有状态 $s, s' \in \mathcal{S}$, 混淆矩阵在状态间不变:

$$\pi_m(\cdot | \cdot, s) = \pi_m(\cdot | \cdot, s'), \quad \forall s, s' \in \mathcal{S}$$

即标注者可靠性不依赖样本状态。

Proof. 对任意 $x \in s$, 加权投票的贝叶斯最优权重是状态条件权重 $w_m^*(s)$, 它最小化点态期望损失:

$$w^*(s) = \arg \min_{w \in \Delta^{M-1}} \mathbb{E}[\ell(\text{vote}_w(x), y^*) | x \in s]$$

Dawid-Skene 使用的全局权重 $\bar{w}$ 是常数:

$$\bar{w} = \arg \min_w \mathbb{E}_{X, Y^*}[\mathbb{E}[\ell(\text{vote}_w(X), Y^*) | X]]$$

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

由逐点最优性，对每个 $x \in s$ ：

$$\mathbb{E}[\ell(\text{vote}_{w^*(s)}(x), y^*) \mid x \in s] \leq \mathbb{E}[\ell(\text{vote}_{\bar{w}}(x), y^*) \mid x \in s]$$

在状态分布上取期望即得 $R_{\text{SCX}} \leq R_{\text{DS}}$ 。

等号条件由逐点不等式的严格性导出：只有当全局权重也是每个状态的最优权重时等号成立，即 $\bar{w} \in \arg \min_w \mathbb{E}[\ell(\text{vote}_w(x), y^*) \mid x \in s]$ 对所有 s 成立。这要求各状态的最优权重相同，等价于混淆矩阵不依赖于状态。□

5.4 在噪声检测语境下的具体差异

Theorem 1 的检测规则建立在”一致性”概念上——噪声样本对所有专家都呈现高错误。这是 SCX 框架的特有优势，与 Dawid-Skene 的全局可靠性估计有本质差异：

维度	Dawid-Skene	SCX (Theorem 1)
可靠性	全局常数 π_m	状态条件 $\pi_m(s)$
噪声检测	依赖标注者一致性后验	依赖多专家错误一致性
所需标注	需要多个 (通常 ≥ 3) 标注者	需要多个专家模型
抗类别不平衡	弱 (全局混淆矩阵受主导类别支配)	强 (状态级估计不受影响)
区分 Noise vs Hard	不能 (仅给出后验概率)	能 (一致性得分 C 天然分离两者)
理论保证	渐近一致性 ($M \rightarrow \infty$)	指数收敛 (M 和 K 都加速)

5.5 Dawid-Skene 作为 SCX 的特例

当状态划分退化到平凡划分 $\mathcal{S} = \{\mathcal{X}\}$ （即所有样本在一个状态中）时：

- SCX 权重退化为 $\bar{w}_m \propto \exp(-\alpha \hat{R}_m)$ ，即全局常数权重
- 一致性得分 $C(x)$ 退化为全局平均错误率
- Theorem 1 的检测保证退化为依赖 $\mu = \frac{1}{M} \sum_m \varepsilon_m$ 的全局保证

此时 SCX 的噪声检测等价于 Dawid-Skene 的全局可靠性加权方法。这证明了 SCX 框架的严格推广性。

5.6 改进幅度的量化

SCX 相对于 Dawid-Skene 的改进幅度与状态间的可靠性变异直接相关：

$$\Delta R = R_{\text{DS}} - R_{\text{SCX}} = \sum_{s \in \mathcal{S}} \rho_s \cdot \mathcal{D}_s$$

其中 $\mathcal{D}_s = \sum_{m=1}^M (\bar{w}_m - w_m^*(s)) \cdot R_m(s)$ 是状态 s 上使用全局权重而非状态条件权重的额外风险。

由 Proposition 3（状态条件权重命题）的定理 3.1：

$$\Delta R \geq \frac{1}{\alpha} \cdot I(s; w)$$

其中 $I(s; w) = \mathbb{E}_s[\text{KL}(w(s) \parallel \bar{w})]$ 是状态与权重之间的互信息。

结论： SCX 严格优于 Dawid-Skene 当且仅当专家可靠性的状态变异 $I(s; w) > 0$ ——这在实践中几乎总是成立。Theorem 1 的检测保证只是 SCX 整体框架优势在噪声检测任务上的集中体现。

参考文献

1. Dawid, A. P., & Skene, A. M. (1979). Maximum likelihood estimation of observer error-rates using the EM algorithm. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 28(1), 20-28.
 2. Hoeffding, W. (1963). Probability inequalities for sums of bounded random variables. *Journal of the American Statistical Association*, 58(301), 13-30.
 3. Pollard, D. (1990). Empirical Processes: Theory and Applications. *NSF-CBMS Regional Conference Series in Probability and Statistics*, 2, i-86.
 4. Bartlett, P. L., & Mendelson, S. (2002). Rademacher and Gaussian complexities: Risk bounds and structural results. *Journal of Machine Learning Research*, 3(Nov), 463-482.
 5. SCX Framework Definitions. `../definitions/01_state_conditioned_risk.md`.
 6. Proposition 3: State-Conditioned Expert Weighting. `../propositions/03_state_conditioned_expert_weighting.md`.
 7. Proposition 4: Compression Fidelity. `../propositions/04_compression_fidelity.md`.
 8. 数据防中毒概念. `../knowledge/02_概念/数据防中毒.md`.
 9. 数据四分类概念. `../knowledge/02_概念/数据四分类.md`.
-

附录 A：Chernoff 界的推导

Lemma 2 和 Lemma 3 可以使用 Chernoff 界（而非 Hoeffding）获得更紧的指数速率。

对清洁数据, 令 $\{e_m\}$ 为独立的 Bernoulli 变量, 均值为 $\mu = \mathbb{E}[C \mid \text{clean}, x] \leq \mu_s$ 。对 $\theta > \mu$:

$$\begin{aligned} \mathbb{P}(C > \theta \mid \text{clean}, x) &= \mathbb{P}\left(\frac{1}{M} \sum_m e_m > \theta\right) \\ &\leq \inf_{\lambda > 0} e^{-\lambda M \theta} \mathbb{E}\left[e^{\lambda \sum_m e_m}\right] \\ &= \inf_{\lambda > 0} e^{-\lambda M \theta} \prod_{m=1}^M (1 - \mu_m + \mu_m e^{\lambda}) \\ &\leq \exp(-M \cdot \text{KL}(\theta \parallel \mu_s)) \end{aligned}$$

其中 $\text{KL}(p \parallel q) = p \log \frac{p}{q} + (1-p) \log \frac{1-p}{1-q}$, 且最后一步使用了联合界和 $\mu_m \leq \mu_s$ 。

对噪声数据, 由 Lemma 3 的修正证明（给定 c 条件下 Hoeffding）, Chernoff 形式为:

$$\mathbb{P}(C \leq \theta \mid \text{noise}, x, c) \leq \exp\left(-M \cdot \text{KL}\left(\theta \parallel 1 - \mu_c(x)\right)\right) \leq \exp\left(-M \cdot \text{KL}\left(\theta \parallel 1 - C_{\text{bal}} \cdot \frac{\mu_s}{K-1}\right)\right)$$

注意 KL 的方向: $\text{KL}(\theta \parallel q)$ 对应 Chernoff 上界 $\mathbb{P}(\hat{p} \leq \theta) \leq \exp(-n \cdot \text{KL}(\theta \parallel p))$, 其中 $\hat{p}$ 是 p 的样本均值。这里 $p = \mathbb{E}[C \mid \text{noise}] = 1 - \mu_c(x) \geq 1 - C_{\text{bal}} \cdot \mu_s / (K-1)$, 我们 bound $\mathbb{P}(C \leq \theta)$ （下尾）, 所以第二个参数是真实期望 $p \approx 1 - C_{\text{bal}} \cdot \mu_s / (K-1)$ 。

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

2026-06-27 修正：原版 Chernoff 附录使用了 $\text{KL}(1 - \theta \| 1 - \mu_s / (K - 1))$ ，KL 方向有误。正确形式为 $\text{KL}(\theta \| 1 - C_{\text{bal}} \cdot \mu_s / (K - 1))$ ——下尾 bound 中第一个参数是阈值 θ ，第二个参数是真实期望。

Chernoff 界优于 Hoeffding 界的程度由以下不等式刻画（Hoeffding 是 Chernoff 的一阶近似）：

$$\exp(-2M\Delta^2) \geq \exp(-M \cdot \text{KL}(\mu + \Delta \| \mu))$$

等号仅当 $\Delta \rightarrow 0$ 时渐近成立。在实际参数范围（ $\Delta \approx 0.1-0.4$ ）内，Chernoff 界可紧 2-5 倍。

DEFECT-06 同步 (2026-06-28) — Bahadur-Rao 格点修正：当专家错误为 Bernoulli 分布（格点跨度 $h = 1$ ）时，正确的 Bahadur-Rao 展开在 Chernoff 界中引入因子 $(1 - e^{-\lambda^*})^{-1}$ 替代 $1/\lambda^*$ 。修正后的极小极大常数 $C_{\min}^{(\text{corr})}$ 与原始 $C_{\min}$ 相差约 5–12%，极小极大最优性结论不变（可达界与下界接受相同的格点修正因子）。详细推导见 `06_fixed_point_convergence.md` §12（Remark on Bahadur-Rao Lattice Correction）。

附录 B：非 0-1 损失的推广

Theorem 1 对一般有界损失 $\ell \in [0, B]$ 也成立，只需将 Lemma 1 中的 e_m 解释为 $\mathbf{1}\{\ell(f_m(x), y) > \tau\}$ 。核心推导不变，因为 Lemma 1 仅依赖条件期望的线性性质和噪声标签的均匀性假设 (A4)，不依赖 0-1 损失的具体形式。

具体地，对回归任务（ $\mathcal{Y} \subseteq \mathbb{R}^d$ ）， K 的概念需重新解释。Lemma 1 中的 K 在回归场景下退化为：

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

$$\mathbb{E}[C \mid \text{noise}, x] \geq 1 - \mathbb{E}[C \mid \text{clean}, x]$$

即 $K \rightarrow \infty$ 的极限情况。此时分离间隙对任意 $\mu_s < 1/2$ 为正。这是因为在连续标签空间中，专家恰好预测到噪声标签的概率为零，使噪声检测更容易。Theorem 1 的其余部分不变。

Changelog

Date	Issue	Change	Severity
2026-06-28	B1	Fixed A2 self-contradiction. Updated A2 rationale to acknowledge A1 does NOT guarantee A2. Added M_{eff} degradation formula and cross-reference to 01_symbol_system.md §12.5.	BLOCKING

THEOREM 1: MULTI-EXPERT CONSISTENCY GUARANTEES FOR LABEL NOISE DETECTION

Date	Issue	Change	Severity
2026-06-28	B6	Added $M \geq 1$, $K \geq 2$ to Theorem 1 preamble. Explicitly excludes degenerate edge cases where consensus score is undefined or $K - 1 = 0$.	BLOCKING
2026-06-28	B10	Synced DEFECT-06 (Bahadur-Rao lattice correction) to Theorem 1 appendix. Added cross-reference to 06_fixed_point_convergence.md §12.	BLOCKING