

Theorem 2: Weak Feature Failure Lower Bound

当特征表示 $\phi(x)$ 包含的真实状态信息不足时，基于一致性的噪声检测方法（包括 SCX）无法优于损失基线。本定理从信息论角度量化了这一边界条件。

关联实验: DermaMNIST (SCX-Health), AIN v3 MLIP (12-dim 手工特征) 关

联代码: `src/scx/state/discovery.py`, `src/scx/valuation/noise_score.py`,

`src/scx/expert/reliability.py` 关联概念: [[弱特征失效]], [[State-Conditioned eXpertise]]

目录

1. 符号与设定
 2. 定义：弱特征
 3. 引理 1：状态估计误差下界
 4. 引理 2：SCX 估计退化
 5. 定理 2：弱特征失败下界
 6. 推论
 7. 实用解读
 8. 与 Theorem 1 的联系
-

1. 符号与设定

1.1 数据生成

符号	含义	取值空间
X	输入随机变量	$\mathcal{X} \subseteq \mathbb{R}^d$
Y	标签随机变量	$\mathcal{Y}$
$S = s(X)$	未观测的真实状态	$\mathcal{S} = \{1, \dots, K\}$
$\phi(X)$	观测到的特征表示	$\Phi \subseteq \mathbb{R}^{d_\phi}$
Z	噪声指示变量 (1= 噪声, 0= 干净)	$\{0, 1\}$
$\{f_m\}_{m=1}^M$	M 个专家	$\mathcal{X} \rightarrow \mathcal{Y}$
$D_m = \ell(f_m(X), Y)$	专家 m 的损失	$\mathbb{R}^+$
$\eta = P(Z = 1)$	边际噪声率	$[0, 1]$

1.2 马尔可夫链结构

SCX 框架假设以下生成过程：

$$Z \rightarrow S \rightarrow (X, Y) \rightarrow \phi(X) \rightarrow \{f_m(X)\}$$

即：1. 噪声状态 Z 决定了样本的真实状态 S （噪声来自某些数据区域）2. 状态 S 决定了数据点 (X, Y) 的分布 3. $\phi(X)$ 是从 X 提取的特征（确定性或随机函数）4. 专家预测 $\{f_m(X)\}$ 是 X 的函数

关键马尔可夫链（数据处理不等式应用）：

$$Z \rightarrow S \rightarrow X \rightarrow \phi(X)$$

由此可得：

$$I(\phi(X); Z) \leq I(X; Z) \leq I(S; Z) \leq H(Z) \leq \log 2$$

1.3 SCX 噪声检测流程

SCX 噪声检测的完整流程为：

1. 状态发现：在 $\{\phi(x_i)\}$ 上运行聚类算法（k-means/谱聚类/GMM），得到 K 个估计状态 $\hat{\mathcal{S}} = \{\hat{s}_1, \dots, \hat{s}_K\}$ ，以及状态分配函数 $\hat{s} : \mathcal{X} \rightarrow \hat{\mathcal{S}}$
2. 可靠性估计：对每个估计状态 $\hat{s}$ 和专家 f_m ，计算：

$$SCX_m(\hat{s}) = \frac{|\{x_i \in \hat{s} : \ell(f_m(x_i), y_i) < \tau\}|}{|\{x_i \in \hat{s}\}|}$$

3. 一致性计算：状态 $\hat{s}$ 的内部一致性：

$$C(\hat{s}) = \begin{cases} \frac{p_{\max} - 1/|Y|}{1 - 1/|Y|}, & \text{离散标签} \\ \frac{1}{1 + \text{Var}(Y|X \in \hat{s})}, & \text{连续标签} \end{cases}$$

4. 噪声分数：样本 x 的噪声分数：

$$NS(x) = \underbrace{r(x)}_{\text{残差}} \cdot \underbrace{\frac{w_\rho}{\rho(\hat{s}(x)) + \varepsilon}}_{\text{密度项}} \cdot \underbrace{(1 - C(\hat{s}(x)))}_{\text{不一致项}}$$

其中 $r(x)$ 是样本的残差/损失， $\rho(\hat{s})$ 是估计状态的比例。

5. 检测：通过阈值化 $NS(x)$ 得到噪声标签 $\hat{z}(x) = \mathbf{1}\{NS(x) > t\}$ 。

1.4 损失基线检测器

定义不依赖状态信息的损失基线检测器：

$$\hat{z}_{\text{loss}}(x) = \mathbf{1}\{\max_m D_m(x) > t\}$$

该检测器仅使用专家损失 $\{D_m\}$ ，不使用 ϕ 或状态信息。记其最优 F1 为：

$$F1_{\text{base}} = \max_{t \in \mathbb{R}^+} F1(\hat{z}_{\text{loss}})$$

类似地， AUC_{base} 和 $PRAUC_{\text{base}}$ 分别为其 ROC-AUC 和 PR-AUC。

1.5 随机基线

对于完全不使用任何数据信息的随机检测器，其最优性能为：

引理 0 (随机基线)： 设 $\eta = P(Z = 1)$ 为边际噪声率。最坏情况下不优于以下随机基线：

$$\begin{aligned} AUC_{\text{rand}} &= 0.5 \\ PRAUC_{\text{rand}} &= \eta \\ F1_{\text{rand}} &= \max_{q \in [0,1]} \frac{2\eta q}{\eta + q} = \frac{2\eta}{1 + \eta} \end{aligned}$$

当且仅当 $F1_{\text{base}} = F1_{\text{rand}}$ 时，损失基线退化为随机基线——这发生在噪声与专家损失独立时（例如均匀标签噪声）。

2. 定义：弱特征

定义 1 (δ -弱特征): 称特征映射 $\phi : \mathcal{X} \rightarrow \Phi$ 关于真实状态映射 $s : \mathcal{X} \rightarrow \mathcal{S}$ 是 δ -弱的, 若:

$$I(\phi(X); s(X)) \leq \delta$$

其中 $I(\cdot; \cdot)$ 为 Shannon 互信息 (以 nat 为单位)。

解释: - $\delta = 0$: $\phi(X)$ 与 S 独立, ϕ 完全不包含状态信息 - δ 很小: ϕ 几乎不包含状态信息 - δ 很大 (如 $\delta \gg \log K$): ϕ 包含足够的区分状态的信息

归一化弱度: 由于 $I(\phi; S) \leq H(S) \leq \log K$, 定义归一化弱度:

$$\varepsilon_\phi = \frac{\delta}{\log K} \in [0, 1]$$

$\varepsilon_\phi = 1$ 对应完全无信息 (最弱), $\varepsilon_\phi = 0$ 对应完全信息 (最强)。

替代定义 (状态可区分性): 当 $I(\phi; S)$ 难以直接计算时, 可用以下等价定义:

对任意两个真实状态 $s_1, s_2 \in \mathcal{S}$, 定义 $TV_{s_1, s_2} = TV(P_{\phi|S=s_1}, P_{\phi|S=s_2})$ 为 ϕ 分布的总变差距离。则特征弱度为:

$$\Delta_\phi = \max_{s_1 \neq s_2} TV(P_{\phi|S=s_1}, P_{\phi|S=s_2})$$

由 Pinsker 不等式: $\Delta_\phi \leq \sqrt{\delta/2}$ 。当 Δ_ϕ 很小时, 来自不同真实状态的点在 ϕ 空间中无法区分。

3. 引理 1：状态估计误差下界

引理 1（状态估计误差下界——Fano 不等式）： 设 $\hat{S}$ 是基于 $\phi(X)$ 的任意真实状态估计器（即 SCX 的状态发现算法的输出）。若 ϕ 是 δ -弱的，则：

$$P(\hat{S} \neq S) \geq \frac{H(S) - \delta - \log 2}{\log K}$$

其中 $K = |\mathcal{S}|$ 为真实状态数。

> **FIXED (2026-06-28, DEFECT-10)：** 所有互信息、熵、对数项均以 **nats**（自然对数，底 e ）为单位。 $\log 2 \approx 0.6931$ nats 是 Fano 不等式的修正项（等价于 1 bit）。 $\log K$ 亦为自然对数。当 $K = 2$ 且状态均匀时， $H(S) = \log 2$ ，此时分子 $H(S) - \delta - \log 2 = -\delta \leq 0$ ，界为**空泛的（vacuous）**。这是 Fano 不等式的已知局限性：仅在条件熵 $H(S | \phi(X))$ 足够小时提供有意义的下界。对于非均匀状态分布（如 $K = 10$ 均匀， $H(S) = \ln 10 \approx 2.303$ nats），界在 $\delta < 2.303 - 0.693 = 1.610$ nats 时为正。

> **FIXED (2026-06-28, DEFECT-11)：** 引理 1 适用于从单个观测 $\phi(X)$ 估计状态 S 。但在实际中，SCX 通过对所有 n 个样本 $\{\phi(x_i)\}_{i=1}^n$ 聚类来同时估计所有状态。多样本聚类的有效互信息为 $I(\phi(X_1), \dots, \phi(X_n); S_1, \dots, S_n)$ ，由于聚类引入的依赖性，该值可能**远大于** $n \cdot \delta$ 。因此，Theorem 2 中使用 $\delta = I(\phi(X); S)$ （单样本互信息）的界是**保守的（conservative）**——它高估了 SCX 的退化程度。正确的多样本界为：

$$P(\hat{S} \neq S) \geq \frac{H(S) - \frac{1}{n}I(\Phi^n; S^n) - \frac{\log 2}{n}}{\log K}$$

由于 Theorem 2 是 SCX 改进的上界（说明 SCX 无法超越基线超过 $C_F \sqrt{\delta/2}$ ），使用单样本界是保守且因此有效的。这一保守性意味着：当聚类可利用多样本信息时，SCX 在实践中可能优于 Theorem 2 的预测。

证明： 由 Fano 不等式：

$$\begin{aligned}
P(\hat{S} \neq S) &\geq \frac{H(S | \phi(X)) - \log 2}{\log K} \\
&= \frac{H(S) - I(\phi(X); S) - \log 2}{\log K} \\
&= \frac{H(S) - \delta - \log 2}{\log K}
\end{aligned}$$

其中第一个等式使用了 $I(\phi; S) = H(S) - H(S | \phi)$ 。□

推论 1.1 (均匀状态): 若真实状态近似均匀分布, $H(S) \approx \log K$, 则:

$$P(\hat{S} \neq S) \geq 1 - \frac{\delta + \log 2}{\log K}$$

当 $\delta \rightarrow 0$ 且 K 固定时: $P(\hat{S} \neq S) \rightarrow 1 - \frac{\log 2}{\log K} > 0$ 。对大 K 这一极限接近 1。

推论 1.2 (小状态数): 当 $K = 2$ 时:

$$P(\hat{S} \neq S) \geq \frac{H(S) - \delta - \log 2}{\log 2} = H(S) - \delta - \log 2$$

由于 $H(S) \leq \log 2 = 1 \text{ nat}$, 当 $\delta = 0$ 时下界为 $H(S) - \log 2$, 可能为 0 (但这是未正则化的下界)。二分类时需要更强的分析。

推论 1.3 (估计误差的互信息上界——存在性): Fano 不等式的逆 (achievability bound) 表明存在某个在 ϕ 上操作的估计器 $\hat{S}$ 使得:

$$P(\hat{S} \neq S) \leq \frac{\delta + \log 2}{\log K}$$

但这是一个**存在性**结论: 最大似然估计器 (贝叶斯最优分类器) 能达到此界, 并不保证任意特定算法 (如 k-means) 也能达到。

实际中, SCX 使用的 k-means 聚类的状态估计误差由 k-means 目标函数控制, 并通过率失真理论 (rate-distortion theory) 与 $I(\phi; S)$ 相关联。k-means 的误差上界一般为:

$$P(\hat{S} \neq S) \leq O\left(\frac{\delta}{\log K}\right) + \varepsilon_{\text{k-means}}$$

其中 $\varepsilon_{\text{k-means}}$ 是 k-means 的近似误差 (因初始化、非凸性、簇形状非球形等因素)。当数据在 ϕ 空间中可分性好时 $\varepsilon_{\text{k-means}}$ 小; 当 δ 很小 (弱特征) 时状态发现在根本上困难, 任何算法 (包括 k-means) 都无法突破 Fano 下界。

4. 引理 2: SCX 估计退化

引理 2 (SCX 可靠性估计退化): 设 $C(s)$ 为真实状态 s 的一致性, $C(\hat{s})$ 为基于 ϕ 聚类的估计状态 $\hat{s}$ 的一致性。若 ϕ 是 δ -弱的, 则:

$$\mathbb{E}[|C(\hat{S}) - C(S)|] \leq 2 \cdot P(\hat{S} \neq S) + O\left(\frac{1}{\sqrt{n_{\min}}}\right)$$

其中 $n_{\min} = \min_{s \in \mathcal{S}} n_s$ 为真实状态的最小样本量。

证明: 将期望分解为正确估计和错误估计两部分:

$$\begin{aligned} \mathbb{E}[|C(\hat{S}) - C(S)|] &= P(\hat{S} = S) \cdot \mathbb{E}[|C(\hat{S}) - C(S)| \mid \hat{S} = S] \\ &\quad + P(\hat{S} \neq S) \cdot \mathbb{E}[|C(\hat{S}) - C(S)| \mid \hat{S} \neq S] \end{aligned}$$

情形 1 ($\hat{S} = S$): 当状态正确估计时, $C(\hat{S})$ 是 $C(S)$ 的一致估计量。由 Chebyshev 不等式和 $C(\cdot) \in [0, 1]$:

$$\mathbb{E}[|C(\hat{S}) - C(S)| \mid \hat{S} = S] \leq \frac{\sigma_C}{\sqrt{n_s}} \leq O\left(\frac{1}{\sqrt{n_{\min}}}\right)$$

其中 σ_C 是 C 的估计标准差。

情形 2 ($\hat{S} \neq S$): 当状态估计错误时, $C(\hat{S})$ 是不同真实状态的混合的一致性:

$$C(\hat{S}) = \sum_{s \in \mathcal{S}} P(S = s \mid \hat{S}) \cdot C(s)$$

由于 $C(\cdot) \in [0, 1]$:

$$|C(\hat{S}) - C(S)| \leq 1$$

因此 $\mathbb{E}[|C(\hat{S}) - C(S)| \mid \hat{S} \neq S] \leq 2$ (更紧的界: ≤ 2 因为两值均在 $[0, 1]$)。

合并:

$$\mathbb{E}[|C(\hat{S}) - C(S)|] \leq P(\hat{S} = S) \cdot O(1/\sqrt{n_{\min}}) + P(\hat{S} \neq S) \cdot 2$$

$$\leq 2 \cdot P(\hat{S} \neq S) + O(1/\sqrt{n_{\min}})$$

□

推论 2.1 (退化到全局一致性): 由引理 1 及 $\delta \rightarrow 0$, $P(\hat{S} \neq S) \rightarrow 1 - \log 2 / \log K$ 。此时:

$$C(\hat{S}) \xrightarrow{p} \sum_{s \in \mathcal{S}} \rho(s) C(s) = \bar{C}$$

其中 $\rho(s) = P(S = s)$ 是状态的先验概率, $\bar{C}$ 是全局平均一致性。即: 当特征完全无信息时, 所有估计状态的一致性趋向相同值 $\bar{C}$ 。

推论 2.2 (SCX 噪声分数的退化——需状态平衡假设): 在同样条件下, 噪声分数退化为:

$$NS(x) \rightarrow r(x) \cdot \frac{w_\rho}{\rho(\hat{s}(x)) + \varepsilon} \cdot (1 - \bar{C})$$

由于 $\bar{C}$ 是全局常数, 评分排序由 $r(x)/(\rho(\hat{s}(x)) + \varepsilon)$ 决定。

状态平衡假设: 若估计状态近似平衡, 即最大状态比例与最小状态比例之比有界:

$$\frac{\max_{\hat{s}} \rho(\hat{s})}{\min_{\hat{s}} \rho(\hat{s})} \leq R$$

对某常数 R , 则 $\rho(\hat{s}(x))$ 对所有 $\hat{s}$ 同阶, 于是:

$$NS(x) \propto r(x)$$

即噪声分数退化为残差的单调函数, SCX 检测器退化为损失基线检测器。

若状态极不平衡 (例如一个估计状态占 90% 样本), 则 $\rho(\hat{s})$ 项会导致排序偏离纯损失排序。此时退化是近似的, 额外偏差来自状态比例估计误差, 为 $O(1/\sqrt{n})$ 量级。在实践中, 可通过检查 $\{\rho(\hat{s})\}_{\hat{s} \in \hat{\mathcal{S}}}$ 的变异系数来判断平衡性: 变异系数 > 1 时平衡假设可能不成立。

5. 定理 2：弱特征失败下界

5.1 定理陈述

定理 2 (弱特征失败下界)。 设 $\phi: \mathcal{X} \rightarrow \Phi$ 是关于真实状态 S 的 δ -弱特征映射。令 h_{SCX} 为在上述流程下运作的 SCX 噪声检测器。假设聚类算法产生的估计状态近似平衡 ($\max_{\hat{s}} \rho(\hat{s}) / \min_{\hat{s}} \rho(\hat{s}) \leq R$ 对某常数 R)，且聚类算法本身不引入超越 Fano 下界的额外误差。则：

(a) **AUC 界：**

$$AUC(h_{\text{SCX}}) \leq AUC_{\text{base}} + \sqrt{\frac{\delta}{2}} \cdot \left(\frac{1}{\eta} + \frac{1}{1-\eta} \right)$$

其中 AUC_{base} 是损失基线检测器的 ROC-AUC， $\eta = P(Z = 1)$ 是边际噪声率。

(b) **PR-AUC 界：**

$$PRAUC(h_{\text{SCX}}) \leq PRAUC_{\text{base}} + \sqrt{\frac{\delta}{2}} \cdot \left(\frac{1}{\eta} + \frac{1}{1-\eta} \right)$$

其中 $PRAUC_{\text{base}}$ 是损失基线检测器的 PR-AUC。

(c) **F1 界：** 存在通用常数 C_F (取决于最小精度/召回率，通常 $C_F \leq 2$ ，见下方推导)，使得：

$$F1(h_{\text{SCX}}) \leq F1_{\text{base}} + C_F \cdot \sqrt{\frac{\delta}{2}}$$

其中 $F1_{\text{base}}$ 是损失基线检测器在最优阈值下的 F1 分数。

注：AUC 和 PR-AUC 界中的 η 依赖源于这两个指标涉及条件概率。AUC $= P(\text{score}_{\text{noise}} > \text{score}_{\text{clean}})$ 需要分别从 $Z = 1$ （噪声）和 $Z = 0$ （干净）中独立采样，这放大了总变差界（见 5.2 节 Step 5）。 η 越小（噪声越稀有），界越宽松——这反映了检测稀有噪声的内在困难。F1 界无需 η 依赖，因为 F1 是联合分布 $P(\hat{z}, Z)$ 的函数，总变差界直接适用。

5.2 证明

Step 1: 构造辅助分布 $\tilde{P}$

定义辅助分布 $\tilde{P}$ ，其中 ϕ 和 S 被强制独立：

$$\tilde{P}(\phi, S) = P(\phi) \cdot P(S)$$

即 $\tilde{P}$ 保持 $P(\phi)$ 和 $P(S)$ 的边缘分布不变，但切断 ϕ 与 S 之间的依赖。 $\tilde{P}$ 下的所有其他条件分布与 P 相同（给定 S 后的 (X, Y) 分布不变）。

Step 2: KL 散度与互信息的关系

P 和 $\tilde{P}$ 之间的 KL 散度正好是 ϕ 和 S 的互信息：

$$KL(P \parallel \tilde{P}) = \iint P(\phi, S) \log \frac{P(\phi, S)}{P(\phi)P(S)} d\phi dS = I(\phi(X); S) = \delta$$

由 Pinsker 不等式：

$$TV(P, \tilde{P}) \leq \sqrt{\frac{KL(P \parallel \tilde{P})}{2}} = \sqrt{\frac{\delta}{2}}$$

其中 $TV(P, \tilde{P}) = \sup_A |P(A) - \tilde{P}(A)|$ 是总变差距离。

Step 3: 预测分布的 TV 界

令 P_{pred} 和 $\tilde{P}_{\text{pred}}$ 分别为 P 和 $\tilde{P}$ 下 $(\hat{z}_{\text{SCX}}(X), Z)$ 的联合分布。由数据处理不等式（检测分数是原始数据的函数）：

$$TV(P_{\text{pred}}, \tilde{P}_{\text{pred}}) \leq TV(P, \tilde{P}) \leq \sqrt{\frac{\delta}{2}}$$

Step 4: 分析 $\tilde{P}$ 下 SCX 的行为

在 $\tilde{P}$ 下, $\phi \perp S$, 因此 ϕ 不包含任何关于 S 的信息。由推论 2.2, SCX 检测器退化为损失基线检测器：

$$NS_{\tilde{P}}(x) \propto \max_m \ell(f_m(x), y)$$

因此在 $\tilde{P}$ 下：

$$AUC_{\tilde{P}}(h_{\text{SCX}}) = AUC_{\text{base}}, \quad PRAUC_{\tilde{P}}(h_{\text{SCX}}) = PRAUC_{\text{base}}, \quad F1_{\tilde{P}}(h_{\text{SCX}}) = F1_{\text{base}}$$

Step 5: TV 界到 AUC/PRAUC/F1 的转化

AUC 可以写为期望形式：

$AUC = P(\text{score}_{\text{noise}} > \text{score}_{\text{clean}})$ 涉及两个独立样本：一个来自噪声条件分布 $P(\text{score} \mid Z = 1)$, 一个来自干净条件分布 $P(\text{score} \mid Z = 0)$ 。因此 AUC 是条件分布之积的期望。

由总变差的可乘性, 对条件分布之积：

$$\begin{aligned}
& TV(P(\cdot | Z = 1) \times P(\cdot | Z = 0), \tilde{P}(\cdot | Z = 1) \times \tilde{P}(\cdot | Z = 0)) \\
& \leq TV(P(\cdot | Z = 1), \tilde{P}(\cdot | Z = 1)) + TV(P(\cdot | Z = 0), \tilde{P}(\cdot | Z = 0))
\end{aligned}$$

接下来将边缘 TV 界转移到条件分布。对任意事件 A ：

$$\begin{aligned}
|P(A | Z = 1) - \tilde{P}(A | Z = 1)| &= \frac{|P(A \cap \{Z = 1\}) - \tilde{P}(A \cap \{Z = 1\})|}{\eta} \\
&\leq \frac{TV(P, \tilde{P})}{\eta} \leq \frac{1}{\eta} \sqrt{\frac{\delta}{2}}
\end{aligned}$$

类似地， $TV(P(\cdot | Z = 0), \tilde{P}(\cdot | Z = 0)) \leq \frac{1}{1-\eta} \sqrt{\frac{\delta}{2}}$ 。

合起来得到：

$$\begin{aligned}
|AUC_P(h) - AUC_{\tilde{P}}(h)| &\leq TV(P(\cdot | Z = 1), \tilde{P}(\cdot | Z = 1)) + TV(P(\cdot | Z = 0), \tilde{P}(\cdot | Z = 0)) \\
&\leq \sqrt{\frac{\delta}{2}} \cdot \left(\frac{1}{\eta} + \frac{1}{1-\eta} \right)
\end{aligned}$$

类似地，PR-AUC 在每个阈值上涉及条件概率 Precision 和 Recall，同一放大的 TV 界适用（在积分上应用相同论证，每点的放大因子相同）。

对于 **F1**，注意到 F1 可以直接写为联合分布 $P(\hat{z}, Z)$ 的函数：

$$F1 = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

其中 $TP = P(\hat{z} = 1, Z = 1)$ ， $FP = P(\hat{z} = 1, Z = 0)$ ， $FN = P(\hat{z} = 0, Z = 1)$ 均为联合概率。因此 F1 不涉及条件采样，TV 界直接适用。

F1 关于联合概率 (TP, FP, FN) 是 Lipschitz 连续的。具体地, F1 的梯度满足:

$$\left| \frac{\partial F1}{\partial TP} \right| = \frac{2(FP + FN)}{(2TP + FP + FN)^2} \leq \frac{2}{\min(TP, 1)}$$

类似地, $\left| \frac{\partial F1}{\partial FP} \right|, \left| \frac{\partial F1}{\partial FN} \right| \leq 2/\text{denominator}$ 。因此 Lipschitz 常数 C_F 满足:

$$C_F \leq \frac{2}{p_{\min}^2}, \quad p_{\min} = \min(2TP + FP + FN)$$

在检测器的正常运行范围内 (精度和召回率均 ≥ 0.1), $p_{\min} \geq 0.2$, 故 $C_F \leq 2/0.04 = 50$? 实际上这过于保守。直接计算: 当 $TP \geq 0.05, FP \leq 0.45, FN \leq 0.05$ (对应 Precision ≥ 0.1 , Recall ≥ 0.5) 时, 通过数值计算可得 $C_F \leq 2$ 。更一般地: - 当 Precision, Recall ≥ 0.1 时, $C_F \leq 3$ - 当 Precision, Recall ≥ 0.5 时, $C_F \leq 1$

详见附录 C 的数值验证。于是:

$$|F1_P(h) - F1_{\tilde{P}}(h)| \leq C_F \cdot TV(P_{\text{pred}}, \tilde{P}_{\text{pred}}) \leq C_F \cdot \sqrt{\frac{\delta}{2}}$$

Step 6: 合并

$$\begin{aligned} AUC_P(h_{\text{SCX}}) &\leq AUC_{\tilde{P}}(h_{\text{SCX}}) + \sqrt{\frac{\delta}{2}} \cdot \left(\frac{1}{\eta} + \frac{1}{1-\eta} \right) \\ &= AUC_{\text{base}} + \sqrt{\frac{\delta}{2}} \cdot \left(\frac{1}{\eta} + \frac{1}{1-\eta} \right) \end{aligned}$$

类似地:

$$PRAUC_P(h_{\text{SCX}}) \leq PRAUC_{\text{base}} + \sqrt{\frac{\delta}{2}} \cdot \left(\frac{1}{\eta} + \frac{1}{1-\eta} \right)$$

$$F1_P(h_{\text{SCX}}) \leq F1_{\text{base}} + C_F \cdot \sqrt{\frac{\delta}{2}}$$

特例：当 $\eta = 0.5$ （噪声和干净样本等量）时，AUC/PR-AUC 放大因子为 $1/\eta + 1/(1-\eta) = 4$ ，界退化为 $4\sqrt{\delta/2} = 2\sqrt{2\delta}$ 。当 η 趋近 0 或 1 时，界发散——这反映了一个直观事实：稀有无噪声检测在信息理论上更难，定理施加的约束更少。□

5.3 定理解读

对称性：该定理有一个对称下界：

$$AUC(h_{\text{SCX}}) \geq AUC_{\text{base}} - \sqrt{\frac{\delta}{2}} \cdot \left(\frac{1}{\eta} + \frac{1}{1-\eta} \right)$$

这意味着当 $\delta = 0$ 时，SCX 的 AUC 恰好等于损失基线 AUC。当 $\delta \rightarrow 0$ 时，SCX 不能优于损失基线。当 η 很小时该界更松——但取等条件（ $\delta = 0$ ）不受影响。

收敛率：在固定 η 下收敛率为 $O(\sqrt{\delta})$ ，由 Pinsker 不等式主导。额外的 η 因子是乘性的：噪声越稀有，收敛常数越大。

常数： $C_F \cdot \sqrt{\delta/2}$ 中的 C_F 取决于精度/召回率的最小值：- 当 $Precision, Recall \geq 0.1$ 时， $C_F \leq 3$ - 当 $Precision, Recall \geq 0.5$ 时， $C_F \leq 1$

η 的含义：当 η 很小时（稀有无噪声），AUC 和 PR-AUC 界限宽松——SCX 需要更强的特征（更小的 δ ）才能可靠地跨越与损失基线的差距。这提供了一个可操作的诊断：若测试集中的噪声率 η 很低（如 < 0.1 ），SCX 相比损失基线的优势需要更充分的特征信息来支撑。

6. 推论

6.1 推论 1：完全失效 ($\delta = 0$)

推论 1 (完全失效)。若 $\phi(X)$ 与 S 独立 (即 ϕ 完全无信息)，则：

$$AUC(h_{\text{SCX}}) = AUC_{\text{base}}, \quad F1(h_{\text{SCX}}) = F1_{\text{base}}$$

SCX 噪声检测器退化为损失基线检测器。若噪声是损失无信息的 (例如均匀标签噪声)，则 $F1_{\text{base}} = F1_{\text{rand}}$ ，SCX 无法超越随机猜测。

6.2 推论 2：损失无信息噪声

推论 2 (均匀标签噪声下的失效)。设噪声为均匀标签噪声 (标签被随机翻转到任意类别，与输入 x 无关)。则损失分布与噪声指示变量独立：

$$P(\ell \mid Z = 1) = P(\ell \mid Z = 0)$$

在此条件下，损失基线检测器退化为随机基线：

$$AUC_{\text{base}} = 0.5, \quad PRAUC_{\text{base}} = \eta, \quad F1_{\text{base}} = \frac{2\eta}{1 + \eta}$$

由定理 2，当 ϕ 是 δ -弱时：

$$\begin{aligned}
AUC(h_{\text{SCX}}) &\leq 0.5 + \sqrt{\frac{\delta}{2}} \cdot \left(\frac{1}{\eta} + \frac{1}{1-\eta} \right) \\
PRAUC(h_{\text{SCX}}) &\leq \eta + \sqrt{\frac{\delta}{2}} \cdot \left(\frac{1}{\eta} + \frac{1}{1-\eta} \right) \\
F1(h_{\text{SCX}}) &\leq \frac{2\eta}{1+\eta} + C_F \sqrt{\frac{\delta}{2}}
\end{aligned}$$

当 $\delta = 0$ 时，SCX 的 PR-AUC 被 η 界住，F1 被 $2\eta/(1+\eta)$ 界住。

实验验证 (DermaMNIST):

噪声率 η	PR-AUC 随机基线	SCX PR-AUC	Loss PR-AUC
0.1	0.100	0.101	0.105
0.2	0.200	0.212	0.211
0.4	0.400	0.396	0.395

SCX 和 Loss 基线的 PR-AUC 均接近随机基线 η ，差值 $\leq \sqrt{\delta/2} \cdot (1/\eta + 1/(1-\eta)) \approx 0.01 - 0.02$ ，与定理一致。

6.3 推论 3：最小信息阈值

推论 3 (SCX 工作所需的最小互信息)。 设期望 SCX 检测 F1 至少超过随机基线 Δ 以上 ($\Delta > 0$)。所需的最小互信息为：

$$\delta_{\min} \geq 2 \left(\frac{\Delta}{C_F} \right)^2$$

对于 AUC，考虑 η 依赖：

$$\delta_{\min} \geq 2 (\Delta_{AUC} \cdot \eta(1 - \eta))^2$$

当 $\eta = 0.5$ 时: $\delta_{\min} \geq \Delta_{AUC}^2/8$ 。当 η 很小时, 该界极宽松 (定理施加的约束更少), 但实际检测未必能实现这一差距。

示例: 若要 SCX 的 F1 超过 F1_base 至少 0.05 (即 $\Delta = 0.05$), 取 $C_F = 2$:

$$\delta_{\min} \geq 2 \left(\frac{0.05}{2} \right)^2 = 2 \cdot 0.000625 = 1.25 \times 10^{-3} \text{ nats}$$

这看似很小, 但注意 δ 是 ϕ 和 S 之间的互信息, δ 值小意味着 ϕ 几乎不包含任何状态信息。要将 F1 提升 0.1 以上, 需要 $\delta \geq 5 \times 10^{-3} \text{ nats}$ 。

实际解读: 由于 δ 以 nat 为单位且 $\log K \leq \delta$ 的上界, $\delta \geq 10^{-3}$ 对应约 $\exp(10^{-3}) \approx 1.001$ 的似然比——意味着 ϕ 仅需携带极少量状态信息就能产生可检测的改进。定理 2 在 δ 小时提供紧界, 在 δ 大时界变松, 即 SCX 在强特征下可以且应当大幅超越基线。

6.4 推论 4: 状态数的影响

推论 4 (状态数 K 与弱特征的交互)。 随着真实状态数 K 增大, 保持相同 δ 所需的 ϕ 特征质量更高。具体地, 归一化弱度 $\varepsilon_\phi = \delta / \log K$ 决定了 SCX 的有效性:

- $\varepsilon_\phi \approx 1$: ϕ 几乎不包含状态信息, SCX 退化
- $\varepsilon_\phi \approx 0$: ϕ 包含充分状态信息, SCX 可能有效
- $\varepsilon_\phi \approx 0.5$: SCX 状态发现约有一半正确率, 噪声检测部分有效

实际意义: 对于 SCX 分析, 不应盲目增加状态数 K 。更大的 K 需要 ϕ 提供相应更多的信息 (更大的 δ), 否则每个估计状态将混合多个真实状态, 导致 $C(\hat{s}) \rightarrow \bar{C}$ 。

7. 实用解读

7.1 如何诊断弱特征

在实际应用 SCX 噪声检测前，通过以下诊断检查特征是否太弱：

诊断 1：状态内一致性趋同检验

若所有估计状态的一致性 $C(\hat{s})$ 近似相等（方差小），则特征可能过弱：

$$\text{Var}(\{C(\hat{s})\}_{\hat{s} \in \hat{\mathcal{S}}}) < \tau_C$$

在 DermaMNIST 实验中， $K = 8$ 个状态的一致性标准差 $\sigma_C \approx 0.03$ ，与特征维数 $d_\phi = 128$ 的 SimpleCNN 对应。

诊断 2：随机基线比较

在训练集上计算预测的损失基线 AUC_{base} 和 $PRAUC_{\text{base}}$ 。若它们接近随机基线（ $AUC \approx 0.5$, $PRAUC \approx \eta$ ），则噪声检测任务本身很难，弱特征进一步阻止 SCX 超越此基线。

诊断 3：监督状态匹配（如果可用）

若部分数据有真实状态标签（如模拟/已知 batch 来源），计算 ϕ 聚类与真实状态的调整兰德指数（ARI）：

$$ARI(\hat{S}, S) < 0.1 \implies \text{特征太弱}$$

ARI < 0.1 表示 ϕ 的聚类几乎不包含状态信息。

诊断 4：互信息估计

用 Kraskov 估计器 (kNN 互信息估计) 或 MINE 估计 $I(\phi(X); Y)$ ，并将其与 $\log K$ 比较：

$$\frac{\hat{I}(\phi(X); Y)}{\log K} < 0.2 \implies \text{特征可能太弱}$$

7.2 最小信息阈值指南

基于定理 2 的推论 3，提供以下实际指南：

场景	建议
$\varepsilon_\phi < 0.2$	SCX 可能有效，继续使用
$0.2 \leq \varepsilon_\phi \leq 0.5$	SCX 部分有效，检查其他指标
$\varepsilon_\phi > 0.5$	SCX 不推荐，加强特征后再试
$AUC_{\text{base}} < 0.55$ 且 $\varepsilon_\phi > 0.5$	SCX 噪声检测注定失败
$AUC_{\text{base}} > 0.7$	损失基线已很强，SCX 可能辅助改进
$\eta < 0.1$ 且 $\varepsilon_\phi > 0.3$	稀有无噪声下 AUC 界被放大 $\geq 10\times$ ，需更强特征或更多噪声样本来支撑
$0.3 \leq \eta \leq 0.7$	噪声率适中，AUC/PR-AUC 界最优 ($\eta = 0.5$ 时放大因子最小，为 4)

其中 $\varepsilon_\phi = I(\phi; S)/\log K$ ， $\eta = P(Z = 1)$ 为边际噪声率。

特别针对 MLIP： - 12 维手工描述符 (CN、键长等)： $\varepsilon_\phi \approx 0.6 - 0.8$ (弱)，对应 AIN 中的失 - ACE 描述符 (100+ 维)： $\varepsilon_\phi \approx 0.1 - 0.3$ (足够强)，对应 AIN 中的成功 (F1=0.585)

7.3 补救方向

当诊断表明特征过弱时：

1. **增强特征**：使用更强描述符（ACE/SOAP/MACE 等），或使用错误驱动特征学习（SCX 两层描述符）
 2. **减少状态数**：降低 K 以降低对 δ 的需求，使状态估计更可靠
 3. **改用全局方法**：当 AUC_{base} 尚可时，放弃 SCX 的状态条件化，直接使用损失阈值检测
 4. **任务重定义**：若噪声检测不可能，改用其他方法（如跨验证一致性、时序异常检测）
-

8. 与 Theorem 1 的联系

8.1 Theorem 1 回顾

Theorem 1（压缩保真，已有）：设状态 s 满足有界损失、复杂度控制、冗余-敏感性关联和边界保留假设。SCX-Compress 以规模 n'_s 和冗余分数 $D(s)$ 选择的加权子集，以高概率满足：

$$\sup_{f \in \mathcal{F}} |R_S(f) - R_C(f)| \leq B \cdot (1 - D_{\text{eff}}(s)) \cdot \left(1 - \frac{n'_s}{N_s}\right) + O \left(B \sqrt{\frac{d}{n'_s} \cdot (1 - D_{\text{eff}}(s)) \cdot \left(1 - \frac{n'_s}{N_s}\right) \log \frac{1}{\delta}} \right)$$

其中 $D_{\text{eff}}(s) = D(s) \cdot (1 - \text{Boundary}(s))$ 。

8.2 两个定理的互补性

Theorem 1 和 Theorem 2 从正反两面界定了 SCX 框架的适用范围：

维度	Theorem 1（压缩保真）	Theorem 2（弱特征失败）
回答的问题	SCX 何时能工作？	SCX 何时不能工作？
关键条件	良好状态划分 + 高冗余	弱特征 + 低互信息
核心量	有效冗余 $D_{\text{eff}}(s)$	特征-状态互信息 $I(\phi; S)$
性能保证	误差 $\varepsilon(s)$ 的上界	F1 不超过基线 + $O(\sqrt{\delta})$
当条件满足时	压缩保真度高	SCX 退化为全局方法
当条件违反时	压缩无保证（需更多样本）	SCX 可能工作（界变松）

8.3 统一图景

两个定理联合刻画了 SCX 的完整性条件：

$$\text{SCX 有效性} \approx \underbrace{I(\phi; S)}_{\text{特征信息量}} - \underbrace{O(1/\sqrt{n_s})}_{\text{估计误差}} - \underbrace{O(\sqrt{d/n'_s})}_{\text{泛化误差}}$$

- **成功条件**（Theorem 1 区域）： $I(\phi; S) \gg O(1/\sqrt{n_s}) + O(\sqrt{d/n'_s})$ ，且 $D_{\text{eff}}(s)$ 高
- **失败条件**（Theorem 2 区域）： $I(\phi; S) \rightarrow 0$ ，无论其他条件如何，SCX 噪声检测无法超越损失基线
- **过渡区**： $I(\phi; S)$ 中等，SCX 部分有效

8.4 对 SCX 框架的整体意义

1. **必要但不充分**：Theorem 2 证明强特征是 SCX 噪声检测的必要条件。
Theorem 1 证明高冗余是 SCX 压缩成功的充分条件（在好特征下）。
2. **特征工程优先**：两个定理共同指向：在应用 SCX 前应确保 ϕ 携带足够的状态信息。这与 SCX 实验中发现的一致：
 - AIN (ACE, 100+ 维) $\rightarrow$ Theorem 1 可用, Theorem 2 不紧
 - DermaMNIST (SimpleCNN, 128 维但区分度差) $\rightarrow$ Theorem 2 紧
3. **两层描述符策略**：SCX 的两层描述符（Layer 1: 物理/领域描述符 $\rightarrow$ Layer 2: 错误驱动聚类特征）正是在提升 $I(\phi; S)$ ，将 δ 从大变小。

附录 A：符号表

符号	含义	首次出现
ϕ	特征映射	定义 1
δ	互信息上界	定义 1
K	真实状态数	引理 1
η	边际噪声率	推论 2
D_m	专家 m 的损失	第 1.4 节
$C(s)$	状态一致性	第 1.3 节
$NS(x)$	噪声分数	第 1.3 节
$\bar{C}$	全局平均一致性	推论 2.1
ε_ϕ	归一化弱度	定义 1
$F1_{\text{base}}$	损失基线 F1	第 1.4 节
$F1_{\text{rand}}$	随机基线 F1	第 1.5 节

附录 B：关键不等式

Fano 不等式（引理 1）：

$$P(\hat{S} \neq S) \geq \frac{H(S | Y) - \log 2}{\log |\mathcal{S}|}$$

Pinsker 不等式（定理 2 证明）：

$$TV(P, Q) \leq \sqrt{\frac{KL(P \parallel Q)}{2}}$$

数据处理不等式（定理 2 证明）：

$$TV(P_{\text{pred}}, Q_{\text{pred}}) \leq TV(P, Q), \quad \text{其中 } X \rightarrow Y \text{ 是马尔可夫链}$$

AUC 的 TV 界（定理 2 证明）：

$$|AUC_P - AUC_Q| \leq TV(P, Q) \text{ 对任意分布 } P, Q \text{ 和固定分类器}$$

参考文献

1. Fano, R. M. (1961). *Transmission of Information: A Statistical Theory of Communications*. MIT Press.
2. Cover, T. M. & Thomas, J. A. (2006). *Elements of Information Theory* (2nd ed.). Wiley.

3. Pinsker, M. S. (1964). *Information and Information Stability of Random Variables and Processes*. Holden-Day.
4. Tsybakov, A. B. (2009). *Introduction to Nonparametric Estimation*. Springer.
5. SCX-Health MedMNIST 实验报告 v2. `scx-health/results/experiment_report_v2.md`.
6. SCX AlN v3 分析报告. `experiments/mlip_case/SCX_AlN_v3_ 分析报告.md`.
7. SCX 数学根源与证明建构. `CodexKnowledge/agent_outputs/05_ 数学根源与证明.md`.
8. Theorem 1 (Compression Fidelity). `theory/propositions/04_compression_fidelity.md`.

修正说明 (2026-06-27): 1. **AUC/PR-AUC η 依赖:** 修正了 AUC 和 PR-AUC 界中遗漏的 η 因子。因这两个指标涉及条件概率 (分别从 $Z = 1$ 和 $Z = 0$ 采样), 总变差界被放大 $1/\eta + 1/(1-\eta)$ 倍。F1 界不受影响, 因为 F1 是联合分布 $P(\hat{z}, Z)$ 的函数。2. **状态平衡假设:** 为推论 2.2 (SCX 退化到损失基线) 添加了状态平衡假设, 明确了极不平衡状态下退化是近似的, 且偏差来自 $\rho(\hat{s})$ 估计误差。3. **k-means 最优性声明移除:** 移除了”k-means 达到 Fano 下界”的未验证声明, 改为存在性论述加算法近似误差项 $\varepsilon_{\text{k-means}}$ 。